



西北农林科技大学

硕士学位论文

非独立同分布场景下的鲁棒联邦学习
方法研究

培 养 单 位：_____信息工程学院
专业学位类别：_____电子信息
专业学位领域：_____计算机技术
论 文 作 者：_____王晨
指 导 教 师：_____孙红光 副教授
合作指导教师：_____

2025 年 5 月

Dissertation Submitted to Northwest A&F University
in Partial Fulfillment of the Requirements
for the Professional Degree of
Master of Electronic Information

Research on Robust Federated Learning Methods in Non-IID Scenarios

Colleges: College of Information & Engineering

Major: Computer Technology

Candidate: Chen Wang

Supervisor: Associate Prof. Hongguang Sun

Co-Supervisor:

May, 2025

分类号：TP391.9

学校代码：10712

UDC：004.9

密级：公开

研究生学号：2022056042

西北农林科技大学硕士学位论文

非独立同分布场景下的鲁棒联邦学习方法研究

论文作者：王晨

指导教师：孙红光 副教授

答辩委员会：

西北农林科技大学信息工程学院 吴丹阳 教授

西北农林科技大学信息工程学院 聂炎明 副教授

西北农林科技大学信息工程学院 赵建邦 讲师

西北农林科技大学信息工程学院 冯明晨 讲师

杨凌乾泰电子科技有限公司 李皓 工程师

答辩日期：2025 年 5 月 20 日

本研究得到陕西省自然科学基金面上项目：面向无人机通信的蜂窝网络性能分析与优化技术研究 (编号：2022JM-356) 资助

本研究得到中央高校基本业务费项目：物联网中大数据的可靠传输技术研究 (编号：2452021129) 资助

摘要

联邦学习 (Federated Learning, FL) 作为一种隐私保护的分布式机器学习, 通过客户端本地训练与中心化模型聚合的协同机制, 在医疗影像分析、金融风控等数据敏感领域展现出重要价值。然而, 实际场景中客户端数据的非独立同分布 (Non-IID) 特性与系统开放性导致的投毒攻击风险, 严重制约全局模型的收敛性、泛化能力及鲁棒性。本文针对 Non-IID 数据分布与恶意攻击耦合作用下的模型退化问题进行研究, 分析了其对联邦学习模型训练的影响, 并提出了两种鲁棒的联邦学习方法, 以提高全局模型的稳定性和安全性。

(1) 首先, 本文基于 CIFAR-10 与 Fashion-MNIST 数据集构建 Non-IID 实验环境, 设计非独立同分布数据划分策略, 通过可视化数据分布验证划分策略的有效性。以 FedAvg 为基准模型, 实验表明 Non-IID 数据可使模型准确率下降 3%, 且恶意客户端 (模拟数据中毒攻击) 可导致全局模型准确率进一步恶化 28%。通过理论分析揭示: Non-IID 加剧模型参数偏移, 而恶意攻击放大模型发散效应, 二者协同作用显著破坏联邦学习效能, 验证了鲁棒联邦学习机制的设计必要性。

(2) 针对 Non-IID 环境下的客户端选择问题, 本文提出了一种基于贡献度和可信度双重评估的鲁棒联邦学习方法 FL-CSBC²。该方法通过边际贡献量化客户端模型价值, 利用秩和比方法建立客户端可信度模型, 构建了客户端的动态评分机制, 在服务器端实现“贡献度-可信度”双维度筛选, 确保参与聚合的客户端始终对全局模型产生正向增益。实验表明: 在 Fashion-MNIST 数据集分类任务 (Non-IID 程度为 0.5, 50% 恶意客户端) 中, FL-CSBC² 达到 88.4% 的平均准确率, 较 FedAvg (46.4%)、RFA (33.5%) 等基准方法提升 6.1-54.9 个百分点, 误选率收敛至 0 且稳定性显著优于对比算法 (较 AFedSV+ 降低 13.6%)。该方法在不同数据分布和恶意客户端占比的情况下, 均能有效提升全局模型的准确率和收敛稳定性, 且在超大规模 (节点个数大于 10^8) 场景下仍保持高效, 验证了其应对复杂联邦环境的鲁棒性。

(3) 针对 FL-CSBC² 算法时间复杂度高的问题, 本文提出一种基于 AP 聚类 and 动态贡献度更新的联邦学习方法 FL-CSBAC。该方法通过 AP 聚类划分客户端并选取聚类中心, 服务器端基于聚类中心边际贡献筛选客户端集群参与聚合, 并通过动态更新贡献度持续优化组合策略。实验表明: 在 CIFAR-10 数据集分类任务 (Non-IID 程度为 0.5, 50% 恶意客户端) 中, FL-CSBAC 平均准确率达 59.6%, 较 AFedSV+ 提升 2.5%; 当恶意客户端占比升高时, 模型收敛稳定性显著优于 FL-CSBC² 和 AFedSV+。结果表明, FL-CSBAC 在高恶意节点占比与严重 Non-IID 场景下具有更强的鲁棒性, 且适用

于小规模和大规模（节点个数小于 10^8 ）的联邦学习任务。

关键词：联邦学习; 非独立同分布; 中毒攻击; 贡献度; 可信度; 客户端选择; AP 聚类

ABSTRACT

Federated Learning (FL), as a privacy-preserving distributed machine learning paradigm, has demonstrated significant value in data-sensitive domains such as medical image analysis and financial risk control through its collaborative mechanism of local client training and centralized model aggregation. However, in practical scenarios, the non-independent and identically distributed (Non-IID) nature of client data combined with poisoning attack risks introduced by system openness severely constrain the convergence, generalization capability, and robustness of global models. This paper investigates the model degradation problem under the coupled effects of Non-IID data distribution and malicious attacks, analyzes their impact on FL model training, and proposes two robust federated learning methods to enhance global model stability and security.

(1) First, we establish a Non-IID experimental environment using CIFAR-10 and Fashion-MNIST datasets by designing a specialized Non-IID data partitioning strategy, with its effectiveness verified through data distribution visualization. Using FedAvg as the baseline model, experiments demonstrate that Non-IID data reduces model accuracy by 3%, while malicious clients (simulating data poisoning attacks) further degrade global accuracy by 28%. Theoretical analysis reveals that Non-IID exacerbates parameter deviation while malicious attacks amplify model divergence, with their synergistic effect significantly impairing FL performance - thus validating the necessity for robust FL mechanisms.

(2) To address client selection in Non-IID environments, we propose FL-CSBC², a robust FL method featuring dual evaluation of contribution and credibility. This approach quantifies client model value through marginal contribution, establishes client credibility using rank-sum ratio analysis, and implements a dynamic scoring mechanism to enable server-side "contribution-credibility" dual-dimensional filtering, ensuring participating clients consistently provide positive gains to the global model. Experimental results on Fashion-MNIST classification tasks (Non-IID degree=0.5, 50% malicious clients) show FL-CSBC² achieves 88.4% average accuracy, outperforming FedAvg (46.4%) and RFA (33.5%) by 6.1-54.9 percentage points, with zero misselection rate and 13.6% better stability than AFedSV+. The method effectively improves global model accuracy and convergence stability across varying data distributions and malicious client ratios, while maintaining efficiency even in ultra-large-scale scenarios (over 10^8 nodes), demonstrating its robustness in complex FL environments.

(3) To address FL-CSBC²'s high time complexity, we propose FL-CSBAC, an AP clustering-based FL method with dynamic contribution updates. This approach clusters clients via AP clustering, selects cluster representatives based on marginal contribution, and continuously optimizes aggregation strategies through dynamic contribution updates. Experiments on CIFAR-10 classification tasks (Non-IID degree=0.5, 50% malicious clients) show FL-CSBAC achieves 59.6% average accuracy (2.5% improvement over AFedSV+), with significantly better convergence stability than both FL-CSBC² and AFedSV+ under increasing malicious client ratios. The results demonstrate FL-CSBAC's superior robustness in high-malicious-node and severe Non-IID scenarios, with applicability to both small-scale and large-scale (under 10^8 nodes) FL tasks.

KEY WORDS: Federated Learning; Non-IID; Poisoning Attack; Contribution; Credibility; Client Selection; AP Clustering

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 联邦学习.....	2
1.2.2 非独立同分布.....	2
1.2.3 联邦学习中的攻击.....	4
1.2.4 联邦学习中的防御.....	6
1.3 研究动机与研究内容.....	7
1.3.1 研究动机.....	7
1.3.2 研究内容.....	7
1.4 技术路线.....	8
1.5 论文组织架构.....	10
第二章 相关技术和理论基础	11
2.1 引言.....	11
2.2 联邦学习基础.....	11
2.2.1 联邦学习的分类.....	11
2.2.2 联邦学习的基本框架.....	12
2.3 联邦学习中的非独立同分布数据	13
2.3.1 非独立同分布数据的定义.....	13
2.3.2 非独立同分布数据的分类.....	14
2.3.3 非独立同分布数据的划分策略.....	15
2.4 边际贡献.....	15
2.4.1 留一法.....	16
2.4.2 夏普利值法.....	16
2.5 秩和比.....	17
2.6 AP 聚类.....	18
2.7 本章小结.....	20
第三章 非独立同分布和恶意攻击对联邦学习影响的定量分析	23
3.1 引言.....	23
3.2 数据集和模型设置.....	23
3.2.1 数据集介绍.....	23
3.2.2 神经网络模型设置.....	23
3.3 数据集的划分.....	25
3.3.1 非独立同分布数据集的划分策略.....	25

3.3.2 非独立同分布数据集分布情况可视化	25
3.4 非独立同分布对模型性能的影响	26
3.4.1 FedAvg 算法介绍	27
3.4.2 实验设置	27
3.4.3 实验结果与分析	28
3.5 数据中毒攻击对模型性能的影响	31
3.5.1 实验设置	32
3.5.2 实验结果与分析	32
3.6 非独立同分布与数据中毒攻击复合场景对模型性能的影响	34
3.7 本章小结	35
第四章 基于贡献度和可信度的鲁棒联邦学习方法	37
4.1 引言	37
4.2 根数据集	37
4.3 基于贡献度和可信度的客户端选择算法	38
4.3.1 设计思路	38
4.3.2 根数据集的设置	38
4.3.3 基于边际贡献的贡献度模型	39
4.3.4 基于秩和比的可信度模型	40
4.3.5 客户端选择与聚合策略	41
4.4 仿真实验与结果分析	43
4.4.1 实验设置	43
4.4.2 对比算法与评价指标	44
4.4.3 关键参数的选择	46
4.4.4 实验结果与分析	47
4.5 本章小结	57
第五章 基于 AP 聚类 and 贡献度的鲁棒联邦学习方法	59
5.1 引言	59
5.2 AP 聚类的可视化	59
5.3 基于 AP 聚类 and 边际贡献的客户端选择算法	60
5.3.1 设计思路	60
5.3.2 AP 聚类策略	61
5.3.3 贡献度更新与客户端选择策略	62
5.4 仿真实验与结果分析	64
5.4.1 实验设置	64
5.4.2 实验结果与分析	64
5.5 本章小结	76
第六章 总结与展望	79
6.1 总结	79

6.2 展望.....	80
参考文献.....	81

主要符号对照表

N	参与联邦学习任务的总客户端数量
$\mathcal{C}$	参与联邦学习任务的客户端集合
C_i	索引为 i 的客户端
C_0	中心服务器
D_i	客户端 i 的本地数据集
$ D_i $	客户端 i 的本地数据集大小
x_k	第 k 个数据样本
y_k	第 k 个数据样本对应的标签
D_0	根数据集
D_v	验证数据集
M	验证集样本数
d	样本空间特征的维度
ω_i^t	客户端 i 第 t 轮通信的本地模型参数
ω^t	第 t 轮通信的全局模型
ω_0	服务器端模型
E	本地训练轮数
T	全局通信轮数
$f(\cdot)$	损失函数
$F(\cdot)$	联邦学习任务的目标函数
α_i	聚合期间分配给客户端 C_i 的权重
η	学习率
$\mathcal{S}^t$	第 t 轮选择的客户端聚合集合
$V_{k,i}^t$	第 t 轮训练中, 客户端 i 作为第 k 个客户端加入聚合集合时的边际贡献
$\mathbf{X}$	评价矩阵
$\mathbf{R}_v$	秩矩阵
$\mathbf{S}$	相似度矩阵
$\mathbf{R}$	吸引度矩阵
$\mathbf{A}$	归属度矩阵
λ	阻尼系数

μ	数据的 Non-IID 程度
m	恶意客户端的比例
Cr_i^t	第 t 轮中客户端 i 的可信度
$M_{k,i}^t$	第 t 轮中客户端 i 作为第 k 个客户端加入聚合集合时的评分
β	可信度的权重
p	聚合阈值
δ	开始计算可信度的轮次
L	聚类后的客户端集群个数
G_q	客户端集群
C_g	聚类中心
H	训练模型的参数量

第一章 绪论

1.1 研究背景与意义

近年来,人工智能在现实领域中的应用越来越广泛,如可穿戴智能设备、仿生机器人、自动驾驶、智慧医疗等,这些应用不仅给人们的生活带来了巨大的变化,也在各行各业引领着科技发展与生产变革。数据作为人工智能发展的基础,在人工智能的各个环节中都扮演着重要的角色,人工智能的发展离不开海量数据的支撑,而人工智能的应用也会产生大量的数据。无论是机器学习、自然语言处理,还是计算机视觉,都要从终端设备中收集大量的数据来完成对某一模型的训练,该模型通过不断地学习海量数据中的特征,最终实现判断和决策。然而,在实际的场景中,由于人工智能技术的普及,终端设备在地理位置的分布上十分分散,再加上人们对数据隐私和安全的重视程度越来越高,数据的拥有者不会轻易地共享和传播数据,训练数据越来越碎片化,形成了大量的数据孤岛,收集数据变得越来越困难。如何在保障数据隐私和安全的前提下解决数据孤岛问题,引起了人工智能领域的大量关注和思考。

随着人工智能芯片组的出现,终端设备的计算能力变得更加强大,模型训练逐渐从中央服务器向终端设备转移,联邦学习(Federated Learning, FL)应运而生。联邦学习是一种基于分布式数据集的机器学习框架,它主要从技术角度出发,探究如何在侵犯客户端隐私和安全的前提下,训练出一个高性能的机器学习模型。它允许所有可能包含敏感信息的私人数据保留在客户端上,每个客户端独立训练模型的同时与其他客户端进行协作,最后在服务器端聚合得到一个共享的全局模型(McMahan et al. 2017)。具体而言,每个客户端设备用自己的本地数据训练本地模型,并将模型参数上传到中心服务器,服务器在接收到本地模型参数后,按照一定的策略将其聚合成全局模型,随后把全局模型下发给每个客户端,客户端用全局模型更新自己的本地模型,开启下一轮的训练。这个过程不断重复,直到全局模型收敛。由于每一轮通信中客户端上传的是模型参数而不是原始数据,所以可以有效防止用户隐私泄露,同时也节省了大量通信资源。因此,联邦学习成为了当下和未来人工智能领域最具应用前景的技术之一。

但在大部分实际场景中,数据分布、模型结构、通信网络和系统边缘设备之间可能存在相当大的差异,这给联邦学习的实现带来了挑战。与这些情况相关联的联邦学习被称为异构联邦学习。在所有的异构中,统计异质性是普遍存在并受到广泛关注的。统计异质性是指联邦学习中不同客户端之间的数据分布不一致,非同分布采样的情况,即非独立同分布(Non-Independent and Identically Distributed, Non-IID)。根据以往的研

究 (Hsu et al. 2019), 非独立同分布的数据会使不同客户端训练的模型参数差距较大, 模型更新方向偏离全局模型的更新方向, 导致聚合后的全局模型远离全局最优值, 最终降低全局模型的准确率和收敛速度。随着非独立同分布程度的提高, 对全局模型性能的影响也越来越严重。

除此之外, 由于联邦学习框架的开放性和复杂性, 边缘客户端设备容易受到恶意客户端的攻击, 从而影响全局模型的精度。中毒攻击试图阻止模型学习数据特征, 使模型的学习方向偏离原来的目标。例如攻击者可以通过标签翻转和后门插入等方法破坏训练数据的完整性, 从而降低模型性能。传统的恶意客户端检测算法基于良性客户端与恶意客户端模型之间的距离或相似度来检测恶意攻击, 而非独立同分布场景下的数据分布特性使得良性客户端之间的距离也很大, 导致这一方法不再有效。

因此, 如何在非独立同分布的场景下把恶意客户端排除在聚合之外, 增强复杂环境下联邦学习的鲁棒性并提高全局模型的性能, 是目前亟待解决的问题, 也是本工作的出发点。

1.2 国内外研究现状

1.2.1 联邦学习

联邦学习的概念最早是由谷歌提出的(Konečný et al. 2016), 其基本思路和主要思想是基于分布在各个终端设备上的数据集构建机器学习模型, 同时防止用户的数据隐私泄露。谷歌最开始在 Android Gboard 上部署了联邦学习算法, 以此来实现对输入法的下一个单词的预测(Cao et al. 2022)。随后, 谷歌又将其用于浏览器内部, 开发出一项新型广告分析与推荐技术——联邦队列学习(瞿祥谋 2022), 该技术在浏览器内置机器学习算法, 在本地分析用户的浏览数据, 在不上传用户数据的同时对用户行为进行建模, 以此来指定个性化的广告推送策略。后来, 微众银行开发出第一个工业级联邦学习开源框架——联邦智能使能器 (Federated AI Technology Enabler, FATE) (杨强等 2020), 并于 2019 年正式对外开源, 为机器学习、深度学习、迁移学习提供了高性能的联邦学习机制, 实现了在保护数据隐私和安全的前提下进行跨地域跨机构的人工智能协作问题。目前, 已经有多家世界领先的医疗制药公司在 MELLODDY(Cao et al. 2021) 项目中利用 FL 进行药物发现, 并进化出联邦车险定价、联邦信贷风控、联邦销量预测、联邦视觉安防、联邦辅助诊断、隐私保护广告、联邦自动驾驶等应用实例(杨强等 2020)。

1.2.2 非独立同分布

随着联邦学习技术的普及和深入研究, 人们发现非独立同分布是联邦学习中常见且关键的影响因素和挑战。一些研究从理论与技术的角度来解释非独立同分布数据对

模型性能的影响。(Zhao et al. 2021) 提出非独立同分布对联邦学习全局模型的影响是通过权重发散实现的, 模型训练过程中的权重发散受每个客户端上的数据类别分布与总体数据分布之间距离的限制, 该距离可以通过计算 EMD 来进行量化; (Li et al. 2022) 提出非独立同分布场景中的客户端数据集分布与全局数据分布有很大不同, 导致每一个客户端的局部优化目标与全局优化目标不一致, 局部更新相对全局更新存在漂移现象, 导致聚合后的全局模型偏离全局最优值, 较独立同分布场景下模型的准确率有很大程度的下降。

为了应对联邦学习场景中非独立同分布所带来的影响, 研究人员提出了很多种算法, 也取得了一定的成效。目前提出的算法主要有三种, 包括:

(1) 通过制定聚合策略和优化本地更新来提升全局模型的泛化性能。例如(McMahan et al. 2017) 提出的 FedAvg 算法通过设计全局模型聚合时每个客户端模型的权重来应对非独立同分布数据和不平衡数据带来的影响, 权重与客户端本地数据集的大小成正比, 以更好的趋近于传统机器学习的效果; (Li et al. 2020) 在 FedAvg 的基础上提出 FedProx 算法, 通过在本地目标函数中加入正则化项来惩罚模型参数偏离初始全局模型参数的程度, 保证聚合模型不会偏离全局最优值太远; (Wang, Liu, et al. 2020) 认为具有更多本地更新步骤的客户端应该具有更大的本地更新权重, 所以它在 FedAvg 的基础上提出 FedNova 算法, 对客户端的本地更新进行规范化和缩放, 以此来应对不同客户端之间数据数量分布不平衡的问题; (Hsu et al. 2019) 应用方差减少技术设计出 SCAFFOLD 算法, 该算法通过在本地训练中添加漂移来矫正本地更新, 漂移通过计算服务器模型的更新方向与各个客户端更新方向的差值来得到, 其实验结果证明该方法可以有效应对 Non-IID 场景下模型的漂移和发散。(Wang et al. 2023) 提出 FedCDA 算法, 它通过有选择地聚合各轮的本地模型来减少本地模型之间的差异。

(2) 通过共享一小部分数据来降低客户端数据集的非独立同分布程度。例如, (Zhao et al. 2021) 提出一种策略, 通过收集一个在所有客户端设备之间共享的全局数据集来提高全局模型的性能, 其研究表明, 5% 的全局共享数据可以提高约 30% 的模型准确度。(Yoshida et al. 2020) 的作者在(Zhao et al. 2021) 的基础上提出混合式联邦学习算法 (Hybrid-FL), 该算法通过从用户处购买数据, 获得一个近似独立同分布的数据集, 并在服务器端利用该数据集与客户端同步训练模型, 该模型也将参与到全局模型的聚合当中。

(3) 通过数据生成来降低客户端的非独立同分布程度。该策略主要是通过数据生成器生成部分数据来改善客户端的特征或标签倾斜情况, 修正数据分布。大部分的数据生成器都是基于生成对抗网络(Goodfellow et al. 2014) 或变分自动编码器(Kingma and Welling 2014)。例如, (Jeong et al. 2018) 提出了基于生成对抗网络的数据生成方案 FAug,

该方案利用预先收集的近似独立同分布的数据集训练生成对抗网络,然后将该网络下发到各个客户端,客户端运用该网络生成部分数据以对本地数据进行填充,降低本地数据的非独立同分布程度。(Wen et al. 2020) 提出一种基于变分自动编码器的数据生成方案 RFA,它首先在边缘设备上训练本地数据生成器,然后在云服务器上根据上传的本地生成器生成的 IID 数据集训练全局生成器,最后,设备通过下载全局生成器来纠正 Non-IID 数据集。除此之外,还有部分算法根据用户上传的数据标签信息,把数量较少的数据类别通过旋转、复制等手段进行增强,以此来消解数据的分布不平衡问题(Duan et al. 2019)。

然而,这些研究只针对解决非独立同分布问题,却没有考虑到联邦学习系统中普遍存在的恶意攻击问题,因而很难在现实场景中得到广泛应用。

1.2.3 联邦学习中的攻击

FL 提供了一种可以实现隐私保护的机器学习方法,它不需要参与者共享私人数据,只需要提供本地训练的模型参数,并且允许参与者自由地加入和离开。但也正是因为 FL 的这一特性,导致市场上出现了一些针对 FL 的恶意攻击。这些攻击主要分为对抗性攻击和非对抗性攻击两类(高莹等 2023)。

1.2.3.1 对抗性攻击

对抗性攻击会使系统遭受安全威胁。数据收集阶段的对抗性攻击主要包括数据中毒攻击、搭便车攻击和女巫攻击。模型训练阶段的对抗性攻击主要包括模型中毒攻击和搭便车攻击。

投毒攻击是指恶意终端设备通过提供假的模型参数影响全局训练过程。攻击者可以向 FL 注入虚假的客户端或者控制原有的客户端,让其在训练过程中进行恶意攻击。例如,攻击者可以使用功能强大的计算机来模拟许多假智能手机。此类恶意客户端可以通过精心篡改其本地训练数据或发送到服务器的模型更新来破坏全局模型(Cao et al. 2022)。根据攻击方式的不同,FL 中的攻击可以分为数据中毒攻击(Xie et al. 2019; Wang, Sreenivasan, et al. 2020) 和模型中毒攻击(Bhagoji et al. 2019; Bagdasaryan et al. 2020; Fung et al. 2020)。数据中毒攻击通过恶意篡改客户端本地训练数据破坏模型性能,而模型中毒攻击则通过伪造梯度参数误导全局模型更新,两者均会导致全局模型收敛困难、分类准确率下降,甚至可在模型中植入后门触发器,具有较高的隐蔽性。按照攻击目标进行划分,中毒攻击可以分为目标中毒攻击和非目标中毒攻击,目标中毒攻击又叫后门攻击,其目的是将触发器植入到全局模型中,使得全局模型在特定的分类任务中产生错误,而不会影响其他分类任务的正常进行。这种攻击具有很强的隐蔽性,不易被发现,会给特定目标分类任务造成致命的打击。非目标中毒攻击又叫拜占庭攻击,主要是通过操纵本地模型更新,对所有分类任务进行无差别攻击,使全局模型偏离正常更新

的方向，破坏全局模型整体的收敛性和性能(Blanchard et al. 2017; Bernstein et al. 2019)。

搭便车攻击是指一些用户不参与联邦学习的协作训练或不具备训练条件，却试图从系统中获取良好的服务，破坏了联邦学习的公平性。他们一般通过伪造更新以获得相应的激励，对模型性能也会产生影响。(Fraboni et al. 2021) 介绍了一个搭便车攻击的理论框架。提出攻击者通过向随机构造的模型梯度中加入噪音，并应用随机梯度下降来提高与其他良性用户模型梯度的相似性，以便更好地隐藏。(Wan et al. 2021) 提出一种新型的搭便车攻击方式，一些只拥有小型数据集的客户端通过伪装成大数据集或者提高自己的贡献值以获取更大的激励和服务。

女巫攻击(John 2002) 是指攻击者利用单个设备在网络中创建和控制多个虚假身份，并实施恶意攻击行为。尤其在联邦学习中，用户认证的强度低，攻击者很容易捏造用户身份实现恶意攻击。(Fung et al. 2020) 研究了联邦学习中女巫攻击的目标和策略，定义了一种新的女巫特定拒绝服务 (DoS) 攻击类别，又叫做训练膨胀，并评估了联邦学习中的女巫攻击所带来的影响。

1.2.3.2 非对抗性攻击

非对抗性攻击会使系统遭受隐私威胁。在数据收集阶段，客户端容易遭受隐私数据泄露的威胁。在模型训练阶段，容易遭受推理攻击 (Inference Attack)。在模型推理阶段，联邦学习系统容易遭受模型提取攻击 (Model Extraction Attack) 和推理攻击。

模型提取攻击是指通过构造数据隐藏自己的身份，进而窃取训练成果，破坏模型的机密性。(Tramèr et al. 2016) 首次提出机器学习中模型提取攻击的概念，并对谷歌等公司的预测系统进行攻击，轻松窃取了与全局模型等效的模型。(Jagielski et al. 2020) 提出了一种不需要训练就能直接提取模型梯度的攻击方法，提高了模型提取攻击的效率。

推理攻击是指攻击者通过非法窃取上传至服务器的各模型参数，进而推理出客户端的原始数据，造成用户隐私泄露。最近的研究表明，只需要观察客户端模型的梯度，恶意攻击者就可以成功推理出部分原始数据(Zhu et al. 2019)。即使是一小部分梯度也可以泄露大量有关本地数据的敏感信息(Aono et al. 2017)。按照攻击目的的不同，推理攻击可以分为成员推理攻击和属性推理攻击。成员推理攻击主要是通过模型参数尝试推理某个训练数据是否用于训练该模型，造成隐私泄露(Shokri et al. 2017)。(Nasr et al. 2019) 设计了一种白盒模型下的成员推理攻击方案，并通过实验证明，对于能够获取到本地模型参数的攻击者，实施白盒模型下的成员推理攻击准确率可以达到 70% 以上。属性推理攻击是指攻击者尝试推断训练数据集的特征信息，包括样本的具体数值或数据集的整体属性(高莹等 2023)。(Hitaj et al. 2017) 提出一种基于 GAN 的属性推理攻击，试图恢复出原有的训练数据特征，并指出模型反转攻击在联邦学习中是普遍存在的。

1.2.4 联邦学习中的防御

针对上述提到的联邦学习中的攻击方式，人们进行了大量的研究，提出了很多针对性的防御方法。这些方法都各有长处，但没有一种方法能够适用于所有的联邦学习攻击场景。针对联邦学习攻击场景所提出的防御方法大致也可以分为两类，一类是为了提高联邦学习系统的鲁棒性，获得更高的模型性能，另一类是为了提高联邦学习系统的隐私性，实现数据隐私保护。

1.2.4.1 联邦学习的鲁棒性

由于恶意客户端更新通常偏离其他客户端更新，以实现对其全局模型的影响。所以越偏离整体分布的客户端模型参数就越有可能是恶意更新。因此一些研究基于联邦学习各客户端的统计特征来实现鲁棒性聚合。(Yin et al. 2018) 提出中值算法 (Median) 和裁剪均值 (Trimmed Mean) 算法，对于模型中的每个参数，选择客户端中该参数的中值或者计算去除极端数据后的平均值作为该轮次的全局模型参数。(Blanchard et al. 2017) 提出 Krum 算法，Krum 算法的基本思想是计算每个客户端模型更新与全局更新之间的欧氏距离，选择距离最小的更新作为全局更新。(Guerraoui, Rouault, et al. 2018) 整合了 Krum 算法和裁剪均值算法的优势，提出 Bulyan 算法。该算法首先使用 Krum 算法来选择一定数量的客户端模型，然后使用裁剪均值算法计算全局更新。(Pillutla et al. 2022) 提出 RFA 算法，利用几何中值来筛选用户模型，把恶意用户排除在聚合之外。其他一些方法使用相似性度量来检测可疑客户端并降低它们的聚合权重。例如，FLTrust (Cao et al. 2021) 在服务器上维护一个干净的小数据集 (称为根数据集)，并与客户端同步训练服务器模型。它通过计算服务器模型和每个客户端模型之间的余弦相似度来调整模型聚合权重。然而，在恶意攻击者比例较高的场景中，基于相似度的检测方法可能会失败，因为全局模型与恶意客户端模型的相似度更高。此外，一些算法，如 ShapleyFL (Sun et al. 2023) 和基于声誉的调度算法 (Song et al. 2021)，利用客户端贡献或声誉来调整聚合权重或为客户端设计调度策略。具体而言，ShapleyFL 将 FL 视为一个顺序合作博弈。客户端之间的 Shapley 值差异被用于调整聚合权重，增强了对恶意客户端投毒攻击的抵御能力。

1.2.4.2 联邦学习的隐私性

为了应对联邦学习中的隐私威胁，保证联邦学习的隐私安全，联邦学习中引入了很多密码学相关的加密技术。如今，联邦学习中的同态加密技术、差分隐私加密技术、基于多方安全计算的隐私保护技术以及基于区块链的隐私保护技术都日趋成熟。例如，(Lee et al. 2018) 提出了一种基于联邦学习的患者诊断平台，并将同态加密应用于跨机构搜索任务中。(Liu, Zhang, et al. 2020) 中运用同态加密技术来保护训练过程中的中间结果。(Liu, Peng, et al. 2020) 提出了一个基于区块链的联邦学习安全框架，利用智能合

约来抵御恶意或不可靠的用户发起的投毒攻击，并使用本地差分隐私来防止成员推理攻击。(Bonawitz et al. 2017) 基于 (t, n) 门限秘密分享和密钥协商协议提出了一种可以防止半诚实服务器根据用户参数推断相关敏感信息的架构，该架构可以保证更新参数的安全性和私密性。为了应对推理攻击，(Wu et al. 2025) 提出了一种新型训练后联邦遗忘框架 Aegis，该框架在模型训练完成后基于私有属性请求执行遗忘操作。

1.3 研究动机与研究内容

1.3.1 研究动机

通过对国内外相关研究现状的系统梳理与整合分析，发现当前研究存在以下主要问题：

(1) 现实联邦学习场景普遍存在数据非独立同分布现象，但传统联邦学习方法仍基于理想化的独立同分布假设设计，导致实际性能显著下降。Non-IID 会引发全局模型收敛速度减慢、准确率下降和性能不稳定，对联邦学习训练造成显著影响。所以传统的联邦学习方法在 Non-IID 场景下将不再适用，亟需开发适配 Non-IID 特性的新型训练范式。

(2) 现有研究普遍存在视角割裂的问题，大多仅针对联邦学习中的单一挑战展开研究：或聚焦于 Non-IID 数据分布导致模型性能下降的问题，或单独处理恶意客户端发起的拜占庭攻击。这种孤立的研究范式导致缺乏能够统一分析 Non-IID 与恶意攻击相互影响的理论框架，进而导致现有解决方案在两者同时存在的复杂实际场景中表现不佳。

(3) 在 Non-IID 数据环境下，现有的恶意攻击检测方法面临严重挑战。一方面，基于模型更新差异性的传统检测算法难以区分正常 Non-IID 客户端和恶意客户端，导致误将合法更新判定为攻击行为；另一方面，攻击者可以利用数据分布差异来伪装恶意梯度更新，使得攻击行为更加隐蔽。更严重的是，为了降低漏检率而采取更严格的检测阈值时，又会错误排除大量正常但数据分布特殊的客户端，这种安全性和参与度之间的失衡进一步加剧了系统整体效能的下降。

1.3.2 研究内容

为了解决上述研究存在的问题，加快联邦学习的落地与应用，本文对联邦学习场景中的非独立同分布问题和恶意中毒攻击问题展开研究。具体来说，本文的主要研究内容包括以下方面：

(1) 模拟了现实中非独立同分布数据下的联邦学习场景和恶意中毒攻击下的联邦学习场景。针对非独立同分布和恶意攻击对联邦学习算法的影响开展实验研究，并从实验结果和原理层面进行了深度分析，统一分析了 Non-IID 与恶意攻击的相互影响，验

证了非独立同分布场景下鲁棒联邦学习方法研究的必要性，为后续针对性地提出相应算法打下基础。

(2) 设计了一种基于贡献度和可信度的客户端选择算法 (Federated Learning with Client Selection Based on Contribution and Credibility, FL-CSBC²), 用以应对非独立同分布场景下联邦学习中的恶意中毒攻击问题。该算法首先基于边际贡献构建了客户端的贡献度模型, 并基于贡献度秩和比构建了客户端的可信度模型, 然后基于贡献度和可信度设计了联邦学习系统中的客户端评分与选择机制。本文在独立同分布场景、非独立同分布场景和不同程度的恶意攻击场景中对 FL-CSBC² 进行了广泛的实验并对比了多个基准算法, 实验结果表明 FL-CSBC² 在抵抗恶意中毒攻击和非独立同分布问题上展现出了极大的优势, 具有较强的鲁棒性。适用于非独立同分布和恶意攻击的复合场景, 适合处理超大规模联邦学习任务。

(3) 设计了一种基于 AP 聚类的贡献度更新机制, 并在此基础上提出另一种联邦学习客户端选择算法 (Federated Learning with Client Selection Based on AP Clustering and Contribution, FL-CSBAC)。该算法在 FL-CSBC² 的基础上对贡献度模型进行了改进, 将 AP 聚类应用于客户端模型分簇当中, 用以降低算法的时间复杂度。FL-CSBAC 利用 AP 聚类划分客户端集群并找出聚类中心, 在此基础上设计贡献度更新机制并选出最优的客户端组合。本文将 FL-CSBAC 与 FL-CSBC² 等算法进行对比实验, 并对各算法结果和时间复杂度进行分析。实验结果表明, 相比于 FL-CSBC², FL-CSBAC 在高度非独立同分布和高恶意客户端占比的场景下能够发挥更好的性能, 适合处理小规模和大规模联邦学习任务。

1.4 技术路线

本研究围绕非独立同分布场景下的鲁棒联邦学习方法展开, 提出了两种算法。首先, 通过构建非独立同分布和恶意中毒攻击场景, 设计相应的数据集划分机制, 为算法验证提供实验环境。然后从实验和理论层面分析非独立同分布数据和恶意攻击对联邦学习算法的影响, 为后续的算法设计打下基础。在算法设计部分, 基于贡献度和可信度的方法通过构建贡献度模型、可信度模型, 并设计客户端选择策略, 实现鲁棒聚合。为了解决算法时间复杂度高的问题, 本文又设计了另一条技术路径。该方法基于 AP 聚类和边际贡献, 通过设计 AP 聚类策略、贡献度更新策略以及客户端集群选择策略, 有效提升聚合模型的鲁棒性。在仿真实验中, 本文通过设置非独立同分布程度和恶意客户端比例, 评估算法在测试准确率、误选率以及时间复杂度等方面的性能表现, 为非独立同分布场景下的鲁棒联邦学习方法提供理论和实践支持。技术路线如图 1-1 所示。

非独立同分布场景下的鲁棒联邦学习方法研究




图 1-1 技术路线图

Figure 1-1 Technology Roadmap

1.5 论文组织架构

针对非独立同分布场景下的鲁棒联邦学习方法的研究，本文共分为六个章节，具体的组织结构如下：

第一章：绪论。阐述研究的背景与意义，梳理联邦学习、非独立同分布数据、攻击与防御技术的国内外研究现状，总结现有研究存在的问题，明确本文的研究内容和技术路线，并概述论文的组织架构。

第二章：相关技术和理论基础。系统介绍联邦学习的分类与基本框架，深入分析非独立同分布数据的定义、分类及划分策略。重点讨论边际贡献评估方法（留一法、夏普利值法）、秩和比与 AP 聚类算法，为后续章节提供理论支撑。

第三章：非独立同分布和恶意攻击对联联邦学习算法的影响。基于 CIFAR-10 和 Fashion-MNIST 数据集，设计非独立同分布数据划分策略，并通过可视化展示数据分布特性。以 FedAvg 算法为基准，量化分析 Non-IID 数据对模型收敛速度与准确率的影响。进一步模拟数据中毒攻击场景，验证恶意客户端对全局模型的破坏性，揭示鲁棒联邦学习研究的必要性。

第四章：基于贡献度和可信度的鲁棒联邦学习方法。提出一种融合贡献度与可信度的客户端选择框架。首先服务器利用根数据集与本地客户端一起同步训练服务器端模型，并将服务器端模型加入初始聚合集合。然后结合边际贡献量化客户端模型加入聚合集合时的贡献度，利用秩和比动态评估客户端历史行为可信度，设计加权选择策略。实验结果表明，该方法在 Non-IID 与恶意攻击场景下能显著提升模型鲁棒性，降低恶意客户端参与聚合的比例，适用于独立同分布场景、非独立同分布场景、恶意攻击场景和超大规模联邦学习场景。

第五章：基于 AP 聚类和贡献度的鲁棒联邦学习方法。为了降低算法的时间复杂度，在第四章基础上引入 AP 聚类算法，通过相似度矩阵分析客户端模型参数的分布特征，实现恶意客户端的聚类隔离。结合贡献度评估动态选择高价值簇参与聚合，优化全局模型更新效率。实验显示该方法在高度非独立同分布和高恶意客户端占比的场景下能够发挥更好的性能，适合处理小规模和大规模联邦学习任务。

第六章：总结与展望。总结全文研究成果，指出本文所提算法的优势。同时，分析当前工作的局限性，提出未来研究方向。

第二章 相关技术和理论基础

2.1 引言

本章首先对联邦学习的基础理论进行介绍，重点描述了联邦学习的分类和基本框架，然后描述了联邦学习中非独立同分布数据的定义、分类和划分策略，紧接着介绍了设计算法所用的相关技术和理论知识，包括边际贡献的定义与应用、秩和比的定义、AP 聚类的原理，为后文的研究提供相应的理论基础。

2.2 联邦学习基础

2.2.1 联邦学习的分类

联邦学习是一种特殊的分布式机器学习，各个客户端在服务器的协调下进行协作训练，并将训练好的模型梯度上传至服务器，在服务器端聚合成为全局模型，实现跨设备跨地域协作。联邦学习为机器学习提供了新的范式，使机器学习模型训练系统不需要收集原始数据就能获得等效的训练结果，使个人隐私数据得到了很好的保护，同时模型数据规模较原始数据规模较小，减少了对通信资源的消耗。联邦学习是人工智能的一个方向，随着联邦学习的发展和不断细化，联邦学习也形成了不同的分类领域。

从数据的分布特征和参与方之间的关系来看，联邦学习可以划分为横向联邦学习、纵向联邦学习和联邦迁移学习。横向联邦学习适用于参与方的数据在特征空间上重叠较多，但样本空间不同的场景。即参与方的数据具有相似的特征，但是来自于不同的用户或设备。比如智能手机用户之间包含相似的特征（使用时间，浏览兴趣等），但样本来自于不同的用户；每家银行存储的客户数据特征相似（消费记录、收支明细等），但是来自不同的群体。纵向联邦学习适用于各个参与方的数据在样本空间上有较多重叠，而在特征空间上没有重叠的场景。即参与方的数据来自相同的用户或设备，但是各自拥有的数据特征不同。比如医院有患者的就诊数据，银行有客户的消费记录，两者的样本可能重叠，但是所拥有的特征不同。联邦迁移学习适用于参与方之间在样本空间和特征空间均重叠较少的场景。该场景下的参与方数据分布有较大差异，迁移学习可以实现不同参与方之间的数据共享。如跨语言的自然语言处理和跨领域的企业协作。目前横向联邦学习应用较为广泛，各行各业都希望借助横向联邦学习在不需要数据共享的情况下获得数据共享的模型训练效果，本文也是基于横向联邦学习来展开研究。

从联邦学习分布式框架的角度来看，其分布式结构可以划分为中心化（客户端/服务器端，C/S）联邦学习架构和去中心化联邦学习架构。其中，中心化联邦学习架构中

有多个分布式终端设备和一个中心服务器，每个终端设备与中心服务器之间进行通信交互；而去中心化联邦学习架构存在多个分布式终端设备，但不存在服务器，各个设备之间进行点对点通信。这两种架构各有优势，中心化联邦学习架构能够节约通信资源，减少了通信消耗，能够应用于复杂且庞大的场景当中，而去中心化联邦学习架构基于点对点的通信方式在任意两个终端设备间进行传输，这无疑增大了系统的通信开销和终端设备的计算开销。所以目前基于服务器和客户端的中心化联邦学习架构仍是主流，本文也是在中心化联邦学习架构上展开研究的。

2.2.2 联邦学习的基本框架

假设联邦学习系统中有 N 个客户端和一个中心服务器，如图 2-1 所示。每个客户端用 $C_i (i = 1, 2, \dots, N)$ 来表示，中心服务器用 C_0 来表示。每个客户端拥有自己的本地数据集 $D_i = \{(x_k, y_k)\}_{k=1}^{|D_i|}$ ，其中 $|D_i|$ 为客户端 C_i 的数据集大小， $x \in \mathbb{R}^d$ 为样本的特征空间， d 表示维度， y 为样本对应的标签。如果用向量 $\omega \in \mathbb{R}^d$ 来表示训练的模型参数，用 $f(\omega; b)$ 来表示模型 ω 在抽样数据集 b 上的损失，那么客户端 C_i 的目标函数可以表示为 $F_i(\omega) = \mathbb{E}_{b \sim D_i}[f(\omega; b)]$ 。而中心服务器的任务就是找到一个模型 ω^* 使得所有客户端的加权平均损失最小，即

$$\omega^* = \arg \min_{\omega \in \mathbb{R}^d} [\sum_{i=1}^N \alpha_i F_i(\omega)], \quad (2-1)$$

其中 α_i 是客户端模型聚合期间分配给客户端 C_i 的权重，通常与客户端数据集的大小成正比。在训练开始之前，服务器 C_0 随机初始化一个全局模型 ω^0 。以第 t 轮的训练过程为例，联邦学习的模型训练过程可以分为以下几个主要步骤：

(1) 服务器端广播全局模型。服务器向所有的系统用户广播上一次训练得到的全局模型 ω^t 。

(2) 客户端更新本地模型。客户端 C_i 在接收到全局模型 ω^t 后，用其初始化其本地模型，并开始进行本地训练。本地模型采用随机梯度下降（Stochastic Gradient Descent, SGD）最小化损失函数，更新其模型在本地数据集 D_i 上的参数，即

$$\omega_i^t = \omega^t - \eta \cdot \frac{\partial F_i(\omega^t)}{\partial \omega^t} \quad (2-2)$$

其中， η 为学习率。最后，客户端将本地模型参数 ω_i^t 上传到中心服务器。

(3) 服务器端更新全局模型。服务器选择部分客户端接收其本地更新，这些客户端可能是随机抽样也可能是精心挑选的。假设把第 t 轮选择的客户端作为集合 $\mathcal{S}^t$ 。中心服务器接收到各客户端 $C_i (C_i \in \mathcal{S}^t)$ 上传的模型参数 ω_i^t 后，根据选择概率或者本地数据集大小确定聚合权重，然后对各客户端模型进行加权平均，得到本轮的全局模型




图 2-1 联邦学习基本框架

Figure 2-1 Federated Learning Framework

ω^{t+1} 。以 FedAvg(McMahan et al. 2017) 算法为例，聚合过程可以表示为：

$$\omega^{t+1} = \sum_{C_i \in \mathcal{S}^t} \frac{|D_i| \omega_i^t}{\sum_{C_i \in \mathcal{S}^t} |D_i|} \quad (2-3)$$

随后，中心服务器又开启下一轮的广播，发送更新后的全局模型以启动下一轮的训练。这个过程一直持续到全局模型收敛或达到系统预定训练轮次为止。

2.3 联邦学习中的非独立同分布数据

2.3.1 非独立同分布数据的定义

之前的联邦学习研究大都基于各客户端数据为独立同分布的假设，而现实联邦学习场景中的数据分布大都是非独立同分布的。例如，由于不同地区居民的生活习惯差异和环境差异，这些地区的疾病分布可能非常不同，导致收集的疾病数据特征分布倾斜；由于世界各地的文化差异，即使是同一种文字，写作风格和语言习惯也不尽相同，导致标签分布倾斜。具体而言，独立同分布是概率论和统计学中的重要概念，描述了随机变量的两个重要的性质：独立性与同分布性。独立性是指两个随机变量 X 和 Y 之间是相互独立的，且一个随机变量的取值不会影响另一个随机变量的取值，即

$$P(X, Y) = P(X) \cdot P(Y) \quad (2-4)$$

同分布性是指一组变量 $X_1, X_2, \dots, X_n$ 具有相同的概率分布, 即

$$P(X_1) = P(X_2) = \dots = P(X_n) \quad (2-5)$$

在机器学习中, 独立同分布表示为一个客户端 i 的本地数据集分布 $(x, y) \sim P_i(x, y)$ 与另一个客户端 j 的本地数据集分布 $(x, y) \sim P_j(x, y)$ 之间满足

$$P_i(x, y) \neq P_j(x, y) \Leftrightarrow P_i(y_i|x_i) \cdot P(x_i) \neq P_j(y_j|x_j) \cdot P(x_j) \quad (2-6)$$

而非独立同分布数据的特性与独立同分布数据的特性完全相反, 数据之间既不相互独立, 也存在不同分布的情况。

2.3.2 非独立同分布数据的分类

根据非独立同分布数据的定义, 非独立同分布在不同的场景中表现出不同的特点, 这里将 $P_i(x, y)$ 表示为 $P_i(y|x)P_i(x)$ 和 $P_i(x|y)P_i(y)$ 以便进行更好的描述。按照用户数据的特征分布和标签分布的差异, 联邦学习中的非独立同分布数据可以分为以下五种类型:

(1) 特征分布偏移

不同客户端的数据在特征分布 $P_i(x)$ 上存在显著差异, 而条件分布 $P(y|x)$ 相同。例如不同人的汉字书写习惯特征可能不同, 但汉字种类相同。即

$$P_i(x) \neq P_j(x), P_i(y|x) = P_j(y|x) \quad (2-7)$$

(2) 标签分布偏移

不同客户端的数据在标签分布 $P_i(y)$ 上有较大差异, 而条件分布 $P(x|y)$ 相同。例如不同专科医院收治的患者差异较大, 导致患病类型标签分布不均衡。即

$$P_i(y) \neq P_j(y), P_i(y|x) = P_j(y|x) \quad (2-8)$$

(3) 标签相同, 特征不同

即使是相同的标签, 其在不同的客户端中可能对应于不同的特征, 也就是条件分布 $P_i(x|y)$ 不同, 例如由于风俗文化的差异, 不同地区房屋和服饰的样式有很大不同。即

$$P_i(y) = P_j(y), P_i(x|y) \neq P_j(x|y) \quad (2-9)$$

(4) 特征相同, 标签不同

即使数据特征相同, 在一些不同的客户端中可能对应不同的标签, 也就是条件分布 $P_i(y|x)$ 不同。例如相同的单词在不同的语境中可能代表不同的含义, 相同的手势在不同的国家和地区也会代表不同的含义。即

$$P_i(x) = P_j(x), P_i(y|x) \neq P_j(y|x) \quad (2-10)$$

(5) 样本数量偏移

不同客户端的训练数据集大小不同，甚至有较大差异。例如大型医院和小型医院所拥有的诊疗数据量差距较大。即不同客户端的 $|D_i|$ 差距较大。

2.3.3 非独立同分布数据的划分策略

关于如何近似地模拟现实场景中的非独立同分布场景，以便对相关算法进行性能仿真，研究人员也提出了各种各样的数据集分割方法。(McMahan et al. 2017) 中按照数字标签对 MNIST 数据集中的数据进行排序，将训练数据划分为大小相同的分片，并把这些分片平均分配给每个客户端，该数据集分割方法实现了每个客户端只包含个别类型的数据，且每个客户端所拥有的数据量是平衡的。(Sattler et al. 2019) 先对数据集进行排序，然后按照预先设定的各客户端数据量占比为每个客户端分配 z 个类别的数据，其中类别种类是随机的，每个客户端所有拥有的各个类别的数据量相等，每个客户端数据集之间不存在交叉，实现了数据类别分布的倾斜。(Caldas et al. 2018) 考虑到联邦学习现实中的应用场景，通过收集不同作者的书写作品来实现 Non-IID 数据集的划分，每个用户分发一个作者的作品，每个作者的作品风格和作品数量都不尽相同。(Hsu et al. 2019; Yurochkin et al. 2019) 通过一个参数 α 调控 Dirichlet 分布，并按照该分布从原始 IID 数据集中采样生成非独立同分布数据集。参数 α 越大，Dirichlet 分布越趋向于均匀分布，数据集越趋向于独立同分布；参数 α 越小，Dirichlet 分布越趋向于集中分布，数据集越趋向于非独立同分布；在(Fang et al. 2020) 中，假设数据集中有 Z 类，将客户端随机分成 Z 组，标签为 y 的训练数据以概率 q 分配给其中一组，以 $\frac{1-q}{Z-1}$ 的概率分配给其他组。 q 越大表示客户端本地训练数据的 Non-IID 程度越高。先前的工作(Zhao et al. 2021) 表明，与独立同分布情况相比，在高度非独立同分布数据集上训练神经网络，联邦学习的模型准确率降低了约 55%。

2.4 边际贡献

边际贡献 (Marginal Contribution) (Gollapudi et al. 2017) 是经济学和管理学中的一个重要概念，用于衡量某一变量单位变动对目标变量的影响。它在生产决策、成本分析、投资评估等领域具有广泛的应用。边际贡献是指某一变量（如生产要素、成本或收入）的单位变动对目标变量（如产量、利润或效用）的增量影响。其核心思想是分析“最后一单位”变动所带来的额外收益或成本。具体来说，团队中参与方的收益是当他们加入团队时团队所获得的效用。参与方的加入会遵从一定的顺序，每一个参与方的边际贡献是基于他们按照同一顺序加入团队时计算的边际收益。

在联邦学习中，边际贡献是指某一客户端加入联邦学习系统后，对整体模型性能

提升的增量贡献。具体而言，边际贡献衡量了某一客户端的数据或计算资源对联邦学习任务的独特价值。从博弈论的角度看，联邦学习中的边际贡献评估是一个典型的合作博弈问题。客户端的贡献不仅取决于其自身数据的价值，还取决于其与其他客户端数据的协同效应。例如，某些客户端可能持有稀缺的互补数据，尽管其个体数据价值较低，但对联邦整体的边际贡献却可能非常显著。

目前联邦学习中客户端边际贡献的计算方法主要包括留一法(Leave-One-Out)(Song et al. 2021) 和夏普利值法(Shapley Value)(Sun et al. 2023)。边际贡献是设计激励机制的重要依据。通过准确评估参与方的边际贡献，可以制定公平的收益分配方案，从而激励高质量数据的长期参与。例如，基于夏普利值的激励机制能够根据参与方的边际贡献动态调整收益分配。边际贡献还可用于数据估值和资源分配。例如，在电力巡检图像目标检测的联邦学习任务中，边际贡献评估可以帮助识别对模型性能提升最显著的数据源，从而优化资源分配策略。通过分析各客户端的边际贡献，可以识别联邦学习中的性能瓶颈。例如，某些参与方的数据可能对模型性能的提升有限，移除这些参与方可以降低计算成本，同时保持模型的整体性能。

2.4.1 留一法

留一法的核心思想是通过移除特定参与者的训练数据，分析其对整体模型效果的作用。具体来说，该方法计算当某一方存在和不存在两种情况下模型性能的差异，通过该差异来衡量该参与方的边际贡献。具体公式为：

$$V_i = U(\mathcal{S}) - U(\mathcal{S} \setminus \{i\}) \quad (2-11)$$

其中， U 表示效能函数， $U(\mathcal{S})$ 表示 $\mathcal{S}$ 中所有参与方联合训练时的模型性能， $U(\mathcal{S} \setminus \{i\})$ 表示移除参与方 i 后的模型性能。

留一法一直被广泛应用于机器学习任务当中的交叉验证。近些年来，有些学者创造性地将其引入联邦学习，用于衡量参与方对联邦学习系统整体的边际贡献。留一法具有很大的应用优势，包括计算逻辑简单、实现成本较低等，但也存在明显的任务盲区。例如，当多个参与方持有相似度较高的高价值数据时，单独剔除掉任意一方可能不会引起显著的性能波动，但若同时移除所有相似数据持有者，则会导致模型性能断崖式下跌。这种现象揭示了该方法在价值分配上的局限性，仅关注个体移除的独立影响，却忽视了数据冗余性与群体协作效应的复杂关系，这种影响在非独立同分布场景下尤其明显。

2.4.2 夏普利值法

夏普利值法是一种基于合作博弈理论的贡献评估方法。它先系统性地计算所有可能的参与者组合方式，然后对每种组合方式进行全排列，这样就获得了所有可能的参

与者加入组合和加入顺序。然后计算每一个参与者在所有组合中的边际增益，将其加权平均后作为其边际贡献。该方法要求遍历所有参与者的排列组合，精确量化每个参与者在不同合作场景下对整体价值的提升幅度。例如，在包含三个参与者的联邦学习中，需要分别计算在空集、单个合作、双人合作等全部八种组合中的价值增量，最终通过加权平均得出公平的贡献评估。用公式可以表示为：

$$V_i = \frac{1}{|\mathcal{N}|} \sum_{\mathcal{S} \subseteq \mathcal{N} \setminus \{i\}} \frac{U(\mathcal{S} \cup \{i\}) - U(\mathcal{S})}{\binom{|\mathcal{N}| - 1}{|\mathcal{S}|}} \quad (2-12)$$

$$= \sum_{\mathcal{S} \subseteq \mathcal{N} \setminus \{i\}} \frac{|\mathcal{S}|!(|\mathcal{N}| - |\mathcal{S}| - 1)!}{|\mathcal{N}|!} [U(\mathcal{S} \cup \{i\}) - U(\mathcal{S})] \quad (2-13)$$

其中， $\mathcal{N}$ 为 N 个参与方的集合， $\mathcal{S}$ 为不包括参与方 i 的参与方子集。

这种计算机制不仅确保了个体贡献与整体协作的动态平衡，还满足了博弈论四大公理性原则（对称性、有效性、可加性、虚拟参与者无关性），因而成为解决联邦学习中价值分配问题的理论最优解。但缺点是其复杂度为 $O(2^N)$ ，复杂程度随着参与者数量增加而呈指数级增长。目前主要是通过蒙特卡洛采样（Monte Carlo Sampling）或特征哈希（Feature Hashing）等近似算法来降低其复杂度。

蒙特卡洛采样通过随机采样 M 次参与方排列，近似计算边际贡献的期望值，计算公式如下：

$$V_i \approx \frac{1}{M} \sum_{m=1}^M [U(\mathcal{P}_i^{(m)} \cup \{i\}) - U(\mathcal{P}_i^{(m)})] \quad (2-14)$$

其中， $\mathcal{P}_i^{(m)}$ 表示第 m 次采样中排在参与方 i 之前的子集。该方法使得复杂度由 $O(2^N)$ 下降至 $O(MN)$ 。随着采样次数 M 的增加，蒙特卡洛采样的结果无限接近于夏普利值。

针对高维特征场景，可以利用哈希函数将原始特征映射到低维空间。假设原本的特征维度为 d ，映射过程可以表示为：

$$\tilde{x}_i = h(x_i), \tilde{x}_i \in \mathbb{R}^f (f \ll d) \quad (2-15)$$

其中 h 为一致性哈希或随机投影函数。该方法通过减少特征维度（从 d 下降到 f ）显著降低边际增益计算量，适用于图像、文本等冗余数据场景。

2.5 秩和比

在多指标综合评价中，如何科学、合理地整合多个指标的观测值是一个关键问题。传统的参数统计方法通常要求数据满足特定的分布假设（如正态分布），且对指标的量纲和权重敏感。然而，实际数据往往存在分布未知、量纲不一致等问题，限制了传统方法的应用。

秩和比 (Rank Sum Ratio, RSR) 是一种基于秩次的统计信息分析方法, 用于多指标综合评价等方面, 具有非参数性、无量纲性和直观性的特点。它通过将原始数据转化为秩次, 消除了量纲和分布的影响, 为多指标综合评价提供了一种有效的解决方案。秩和比的基本思想是在一个 n 行 (n 个评价对象) m 列 (m 个评价指标或等级) 矩阵中, 通过秩转换, 获得无量纲的统计量 RSR , 用 RSR 来衡量评价对象的优劣。 RSR 值的范围在 $[\frac{1}{n}, 1]$ 之间, 其中 n 为评价对象的数量。秩和比的一般计算步骤如下:

(1) 根据评价的目的, 选择评价指标, 判断评价指标是效益型指标还是成本型指标, 效益型指标的数值越大越理想, 成本型指标的数值越小越理想, 构建一个 n 行 (n 个评价对象) m 列 (m 个评价指标或等级) 矩阵 $\mathbf{X}$

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix} \quad (2-16)$$

(2) 按照评价指标值的大小进行编秩, 效益型指标从大到小编秩, 成本型指标从小到大编秩, 得到各指标的秩次 R_{ij} , 用秩次 R_{ij} 来代替原来的评价指标值, 得到秩矩阵 $\mathbf{R}_v$

$$\mathbf{R}_v = \text{Rank}(\mathbf{X}) = \begin{bmatrix} R_{11} & R_{12} & \cdots & R_{1m} \\ R_{21} & R_{22} & \cdots & R_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ R_{n1} & R_{n2} & \cdots & R_{nm} \end{bmatrix} \quad (2-17)$$

(3) 计算各评价对象之间的秩和比 RSR , 并按 RSR 的值对评价对象进行排序。秩和比的计算表达式如下:

$$RSR_i = \frac{1}{n} \sum_{j=1}^m W_j R_{ij} \quad (2-18)$$

其中, $i = 1, 2, \dots, n$, $j = 1, 2, \dots, m$, W_j 是各个评价指标的权重。 RSR 值无量纲, 最小值 $RSR_{min} = \frac{1}{n}$, 最大值 $RSR_{max} = 1$ 。

(4) 根据 RSR 的值对评价对象进行排序, 或通过概率单位变换、回归分析等方法将其分为若干等级。

2.6 AP 聚类

AP 聚类 (Affinity Propagation Clustering) (Frey and Dueck 2007) 是一种基于消息传递的聚类算法, 又被称为近邻传播算法或者亲和力传播算法。该算法的主要思想就是将所有训练数据样本视为网络中的节点, 通过节点之间的消息传递来确定最优的聚类

中心，进而把数据划分为不同簇。数据节点间主要依靠两种信息进行交互——吸引度（Responsibility）和归属度（Availability）。AP 算法通过迭代过程不断更新每一个点的吸引度和归属度，直到产生 C 个高质量的代表点（Exemplars）作为聚类中心，最后将所有的数据样本划分到不同的聚类当中。AP 聚类计算中用到的相关名词包括：

相似度 $s(i, k)$ ：将数据样本 i 和样本 k 之间的相似度记为 $s(i, k)$ ，相似度描述了 i 和 k 之间的相似程度，一般用欧氏距离来计算并全部取负值，如式 (2-19) 所示

$$s(i, k) = -||x_i - x_k||^2 \quad (2-19)$$

$s(i, k)$ 越大说明两个数据样本之间的距离越近，数据样本 k 越适合作为样本 i 的聚类中心。所有的相似度可以构成一个相似度矩阵 $\mathbf{S}$ 。

参考度 $p(i)$ ($s(i, i)$)：参考度（Preference）是指样本 i 能成为自己的聚类中心的潜力。该值是相似度矩阵对角线上的值，理论上如果用欧氏距离计算，该值应为 0，表示样本 i 到自己的距离是最小的。但在实际应用中，作为聚类中心的潜力不能为 0，并且在迭代开始之前所有样本成为聚类中心的潜力应该是相同的，所以常常把所有样本的参考度统一设为所有相似度中的中位数或者最小值，有的还会将其统一设置为一个极小的负值。数据样本的参考度越大，表示该样本成为聚类中心的潜力越大，最终的聚类个数越多。

吸引度 $r(i, k)$ ：吸引度从节点 i 发送到拟聚类中心节点 k ，吸引度的计算考虑了除节点 k 以外的其他潜在的聚类中心，反映了节点 k 适合作为节点 i 的聚类中心的程度。所有的吸引度可以构成一个吸引度矩阵 $\mathbf{R}$ 。

归属度 $a(i, k)$ ：归属度从拟聚类中心节点 k 发送到节点 i ，归属度的计算考虑了所有节点，反映了节点 i 选择节点 k 作为其聚类中心的倾向。所有的归属度可以构成一个归属度矩阵 $\mathbf{A}$ 。

阻尼系数：由于选择最优聚类中心和聚类的迭代过程存在波动，为了避免震荡，AP 算法引入衰减系数 λ ，用于控制本地迭代更新与上次迭代的差距。

假设存在一个样本数据集 $D_d = \{x_1, x_2, \dots, x_n\}$ 。具体来说，该数据样本的聚类过程可以分为如下步骤：

(1) 计算相似度矩阵 $\mathbf{S}$ 。计算样本数据集中任意两个样本之间欧氏距离的负值，形成相似度矩阵 $\mathbf{S}$ 。

(2) 初始化吸引度矩阵 $\mathbf{R}$ 和归属度矩阵 $\mathbf{A}$ 为 0，设置阻尼系数 λ ，并把参考度设置为相似度矩阵的最小值或中位数，用于控制聚类数量。

(3) 在给定相似度矩阵和归属度矩阵的条件下，按照如下公式更新吸引度矩阵：

$$r(i, k) \leftarrow s(i, k) - \max_{k' \neq k} \{a(i, k') + s(i, k')\} \quad (2-20)$$

该公式表明每一个聚类中心的值都会对其他拟聚类中心的值产生影响，各个聚类中心彼此之间会互相影响互相牵制。

(4) 在给定吸引度矩阵的条件下，按照如下公式更新归属度矩阵：

$$a_{t+1}(i, k) \leftarrow \begin{cases} \min\{0, r_t(k, k) + \sum_{i' \notin \{i, k\}} \max\{0, r_t(i', k)\}\}, i \neq k \\ \sum_{i' \notin \{i, k\}} \max\{0, r_t(i', k)\}, i = k \end{cases} \quad (2-21)$$

该公式反映了当 $i \neq k$ 时，节点 i 选择节点 k 作为其聚类中心的倾向受到节点 k 自身的吸引度和节点 k 对其他节点的积极吸引度的影响。积极吸引度是指 $r_t(i', k) > 0$ ，因为只有吸引度为正值的这些节点才会支持节点 k 作为他们的聚类中心。如果 $r_t(k, k)$ 为负数，则说明节点 k 不适合作为聚类中心，更适合归属于其他聚类中心。而当 $i = k$ 时，归属度 $a_{t+1}(k, k)$ 只等于节点 k 从其他节点获得的积极吸引度的和。

(5) 使用阻尼系数处理吸引度矩阵和归属度矩阵，避免在更新过程中出现较大的数值振荡。计算公式如下：

$$r_{t+1}(i, k) = \lambda \cdot r_t(i, k) + (1 - \lambda) \cdot r_{t+1}(i, k) \quad (2-22)$$

$$a_{t+1}(i, k) = \lambda \cdot a_t(i, k) + (1 - \lambda) \cdot a_{t+1}(i, k) \quad (2-23)$$

具体来说，每条信息更新为本次迭代更新的 $1 - \lambda$ 倍加上上次迭代更新的 λ 倍。其中， λ 介于 $[0.5, 1)$ 之间，默认取 0.5。当 λ 较小时（接近 0.5），消息更新较快，可能导致振荡或不收敛。当 λ 较大时（接近 1.0），消息更新较慢，算法更稳定，但收敛速度可能变慢。

(6) 确定聚类中心。对于每个样本数据 i ，选择使 $a(i, k) + r(i, k)$, $i, k \in D_d$ 最大的节点 k 作为节点 i 的聚类中心。如果 $k = i$ ，那么 i 是它自己的聚类中心。

(7) 不断更新迭代吸引度矩阵和归属度矩阵，直到聚类中心不再发生变化或者已经达到预设的最大迭代次数。

相对于 K-Means 聚类算法，AP 聚类方法在各个方面都有极大的优势。首先，AP 聚类算法无需指定聚类的数量，不需要获取先验的知识条件，不要求距离矩阵的对称性，适用的范围也更加广泛；其次，AP 聚类具有明确的聚类中心。AP 聚类中的聚类中心就是某些数据样本本身，而不是通过平均得到的聚类中心；除此之外，AP 聚类具有较低的误差平方和，具有较强的鲁棒性和准确度，多次执行 AP 聚类算法可以得到完全一样的结果。

2.7 本章小结

本章主要介绍了本研究中所涉及到的相关理论与技术基础。首先介绍了联邦学习的相关理论，包括联邦学习的分类和联邦学习的基本框架，对联邦学习算法的基本流

程做了大概的描述，为本文的研究提供了基础；然后对联邦学习领域的非独立同分布数据进行了阐述，包括非独立同分布数据的定义、分类，以及目前已有的相关数据集划分策略，为后续实验的非独立同分布数据场景建模提供了理论和技术保证；接着介绍了联邦学习当中的中毒攻击原理以及带来的影响，侧面印证了本研究的必要性，为后续实验的中毒攻击场景建模提供了理论支持；随后，对本研究用到的相关理论，如边际贡献、秩和比和 AP 聚类进行了仔细地阐述，揭示了其内部的基本原理，为后续的算法设计提供理论支持。总体而言，本章通过深入分析各项技术和理论，为后续的研究开展和算法设计提供了原理支撑和技术指导。

第三章 非独立同分布和恶意攻击对联邦学习影响的定量分析

3.1 引言

由第一章和第二章的介绍可以知道,联邦学习非独立同分布数据的分布特性和恶意攻击会给模型训练带来很大的负面影响,降低模型的准确率。本章主要探究非独立同分布数据和恶意攻击如何对联邦学习算法造成影响,并对影响进行量化和理论分析。本章将首先介绍本研究所用到的数据集、神经网络模型设置和数据集划分策略,然后从实验和理论层面对非独立同分布数据和中毒攻击的影响做进一步的分析和验证。

3.2 数据集和模型设置

3.2.1 数据集介绍


本文主要使用常见的比较成熟的 Fashion-MNIST 数据集和 CIFAR-10 数据集来进行仿真实验。Fashion-MNIST 是一个经典的灰度图像数据集,由 70000 张衣服的灰度图像组成。其中包含 60000 张训练图像和 10000 张测试图像,涵盖了 T 恤、长裤、毛衣、连衣裙、外套、凉鞋、衬衫、运动鞋、手提包和短靴共 10 个类别。每张都是一个像素大小为 28×28 ,通道数为 1,灰度级为 256 的图像。Fashion-MNIST 的数据样本如图 3-1a 所示。Fashion-MNIST 数据集的图像较为简单、易于处理,图像规模适中,具有较高的识别准确率,所以近年来被广泛应用于机器学习和深度学习领域各种算法的测试和实验当中,是计算机视觉研究的重要基准数据集之一。CIFAR-10 数据集是一个较为复杂的彩色数据集图像,由 60000 张物品的彩色图像组成。其中包含 50000 张训练图像和 10000 张测试图像,涵盖了飞机、汽车、鸟、猫、鹿、狗、青蛙、马、船和卡车共 10 个类别的物体图像。每张都是一个像素大小为 32×32 ,有 RGB 三个通道的图像。CIFAR-10 的数据样本如图 3-1b 所示。与 Fashion-MNIST 相比, CIFAR-10 的图像内容更加复杂,识别的难度更高,适合于评估图像分类算法的性能和训练深度学习模型,它的出现大大推动了图像识别技术的发展。

3.2.2 神经网络模型设置

Fashion-MNIST 和 CIFAR-10 数据集均为 10 分类问题,这类问题通过训练集数据训练网络模型,得到一个具有图片分类能力的机器学习模型。给定该模型一张图片,它就能正确地标识出该图片所属的类别标签。为了提高模型训练效率,本文针对性地设计了较为简单的 CNN 网络模型,如表 3-1 和表 3-2 所示。



(a) Fashion-MNIST 数据集示例



(b) CIFAR-10 数据集示例

图 3-1 数据集样本示例

Figure 3-1 Dataset Sample Examples

表 3-1 Fashion-MNIST 数据集训练的 CNN 模型结构

Table 3-1 CNN Model Architecture Trained on Fashion-MNIST Dataset

网络类型	输入通道	输出通道	卷积核大小	步长	激活函数
Conv2d	1	16	5	1	ReLU
MaxPool2d	-	-	2	2	-
Conv2d	16	32	5	1	ReLU
MaxPool2d	-	-	2	2	-
全连接层	7×7×32	10	-	-	Softmax

表 3-2 CIFAR-10 数据集训练的 CNN 模型结构

Table 3-2 CNN Model Architecture Trained on CIFAR-10 Dataset

网络类型	输入通道	输出通道	卷积核大小	步长	激活函数
Conv2d	3	16	3	1	ReLU
MaxPool2d	-	-	2	2	-
Conv2d	16	32	3	1	ReLU
MaxPool2d	-	-	2	2	-
全连接层	32×8×8	512	-	-	ReLU
全连接层	512	10	-	-	Softmax

对于 Fashion-MNIST 数据集,本研究采用两层卷积层和一层全连接层组成 CNN 模型结构。每个卷积层后接批归一化 (Batch Normalization)、ReLU 激活函数和最大池化层 (MaxPooling)。第一层卷积将输入的单通道灰度图像转换为 16 通道特征图,第

二层卷积进一步将通道数增加到 32。经过两次池化操作后，特征图尺寸从 28×28 减小到 7×7 。最后，通过一个全连接层将展平后的特征映射到 10 个输出类别，并使用对数 Softmax 函数计算每个类别的对数概率。批归一化可以保证数据分布的稳定性，而激活函数可以防止过拟合，进一步增强模型的表达能力。池化操作可以增强网络的平移不变性。CIFAR-10 数据集包含 32×32 的彩色图像，因此输入为 3 通道（RGB）。模型首先通过两个卷积层提取特征，每个卷积层后接 ReLU 激活函数和最大池化层，将特征图尺寸从 32×32 逐步减小到 8×8 。第一层卷积将输入的 3 通道图像转换为 16 通道特征图，第二层卷积进一步将通道数增加到 32。池化操作后，特征图被展平并通过两个全连接层进行分类，其中第一个全连接层将特征映射到 512 维，第二个全连接层输出 10 个类别的分数。为了防止过拟合，模型在全连接层之间加入了 Dropout 层。最后，使用对数函数计算每个类别的对数概率。

3.3 数据集的划分

3.3.1 非独立同分布数据集的划分策略

为了模拟客户端数据标签分布的异构性，使用(Fang et al. 2020) 中一种基于类别划分的非独立同分布数据分配方法。该方法通过将数据集中的样本按照标签进行分类，并根据预设的 Non-IID 程度将不同类别的数据分配给各个客户端，从而实现对数据分布的灵活调控。具体而言，首先对数据集的索引进行排序，确保相同标签的样本连续排列。随后，根据类别将样本索引分组，形成按类别划分的数据索引集合。在分配阶段，本文引入了一个关键参数——Non-IID 程度，并用 $\mu (\mu \in [0.1, 1.0])$ 来表示该参数。该参数用于控制数据分配的集中度。对于每个类别的样本，依据 Non-IID 程度动态选择将样本分配给哪个客户端。这种方法允许某些客户端集中获取特定类别的数据，而其他客户端则可能获得较少或不同类别的数据，从而模拟出不同程度的 Non-IID 分布。

通过这种方式能够灵活地调整数据分配的 Non-IID 程度，以适应不同的实验需求。当 μ 较小时，数据的 Non-IID 程度较低，分布接近独立同分布（IID），客户端之间的数据差异较小；而当 μ 较大时，数据的 Non-IID 程度较高，分布的 Non-IID 特性显著增强，部分客户端可能仅包含少数几个类别的数据。这种灵活的数据分配策略为研究 Non-IID 特性对联邦学习算法性能的影响提供了有力支持，有助于深入理解数据分布异构性对模型收敛和泛化能力的影响机制。

3.3.2 非独立同分布数据集分布情况可视化

本研究把 CIFAR-10 数据集按照上述策略分成 100 份数据，并分配给 100 个客户端。然后采用随机抽样的方式，从 100 个客户端当中随机抽取 20 个样本来观察他们

的数据类别分布情况。本研究借助散点图来对各类别数据的相对数量多少进行可视化，横坐标代表所取客户端样本的编号，纵坐标代表各客户端样本所拥有的数据类别的编号，点的面积越大，说明该类别的数据量相对越多。当 $\mu = 0.1$ 时，各客户端数据之间近似为独立同分布，如图3-2a所示。可以看出此时各个客户端的各类别数据呈现均匀分布。随着 μ 的增大，如图3-2b、图3-2c和图3-2d所示，散点图中点的大小差距也越来越大，说明数据越来越趋向于非独立同分布。




图 3-2 不同参数 μ 对应的 CIFAR-10 数据分布图

Figure 3-2 CIFAR-10 Data Distribution under Different Parameters μ

3.4 非独立同分布对模型性能的影响

FedAvg 算法是联邦学习中的经典算法，在各联邦学习框架中的应用较为广泛，因此具有很强的代表性。为了探究非独立同分布数据对联邦学习算法的影响及其原理，本文在 Fashion-MNIST 数据集和 CIFAR-10 数据集上进行了相关实验，研究在不同非独立同分布程度下 FedAvg 算法的全局模型性能，并对结果进行分析。

3.4.1 FedAvg 算法介绍

本文通过探究联邦平均算法 FedAvg 在不同非独立同分布程度下的表现来衡量非独立同分布数据对联邦学习的影响。在 FedAvg 算法中, 首先中心服务器将全局模型参数广播给每一个客户端, 然后客户端利用接收到的全局模型进行初始化, 并用本地数据在此基础上执行梯度下降算法, 实现本地模型更新, 最后, 各个客户端将更新后的模型参数发送至中心服务器, 并在服务器端进行模型的聚合, 得到全局模型。该过程不断重复, 直到全局模型收敛。算法的伪代码如算法1所示。

算法 1 FedAvg

```

1: 初始化全局模型参数  $w^0$ 
2: 选择超参数: 学习率  $\eta$ , 通信轮数  $T$ , 每轮选择的客户端数量  $k$ 
3: for  $t = 1, 2, \dots, T$  do
4:   从所有客户端中随机选择  $k$  个客户端, 组成客户端子集  $\mathcal{S}^t$ 
5:   for 每个被选中的客户端  $i \in \mathcal{S}^t$  do
6:     客户端  $i$  接收全局模型参数  $w^t$ 
7:     客户端  $i$  在本地数据集上执行以下步骤:
8:     初始化本地模型参数  $w_i^t = w^t$ 
9:     for 本地迭代次数  $E$  do
10:      使用本地数据集对模型进行梯度下降更新:
11:      
$$w_i^t = w^t - \eta \cdot \frac{\partial F_i(w^t)}{\partial w^t}$$

12:    end for
13:    客户端  $i$  将更新后的本地模型参数  $w_i^t$  发送给服务器
14:  end for
15:  服务器对选中的所有客户端的模型参数进行加权平均聚合:
16:  
$$w^{t+1} = \sum_{C_i \in \mathcal{S}^t} \frac{|D_i| w_i^t}{\sum_{C_i \in \mathcal{S}^t} |D_i|}$$

17:  其中  $|D_i|$  是客户端  $i$  的数据量,  $\sum_{C_i \in \mathcal{S}^t} |D_i|$  是所有选中客户端数据量的总和
18: end for
19: 输出最终全局模型参数  $w^T$ 

```

3.4.2 实验设置

本文的所有仿真测试皆在高性能服务器上完成, 采用 Python 编程语言, 并使用 Pytorch 框架构建深度学习模型。相关配置如表 3-3 所示。

表 3-3 系统配置信息

Table 3-3 System Configuration Information

配置项	配置信息
Python	3.6.15
PyTorch	1.10.2
操作系统	Windows 10 专业版 64 位
处理器	Intel(R) Core(TM) i9-9900K @ 3.60GHz
内存	64GB
GPU	NVIDIA GeForce RTX 2080 Ti

本章实验采用如图 2-1 所示的联邦学习架构。假设有一个联邦学习系统，其中包括一个中心服务器和 100 个客户端，各个客户端之间的数据是非独立同分布的。本章将 Fashion-MNIST 数据集按照 3.3 章节中的划分策略划分成 100 份数据，并将数据分配给 100 个客户端来模拟现实当中的非独立同分布场景。其中，每个客户端含有 600 张左右的训练图像，具体数目会由于分配随机性而上下浮动。同时，为了保证结果的普适性，本文也按照同样的实验方法探究在 CIFAR-10 数据集上的影响。其中，每个客户端含有 500 张左右的训练图像。在深度学习模型训练当中，常常采用梯度下降方法来寻找最优解。为了控制变量，所有客户端的模型训练均采用动量梯度下降算法（Gradient Descent with Momentum），并将学习率 η 统一设置为 0.01，动量设置为 0.5，本地批处理大小设置为 32，全局通信轮数 T 设置为 100 轮。对于本地训练轮次 E 来说，若本地轮次太少，则会使通信轮次增加，系统通信开销增大；若本地训练轮次太多，可能会导致本地模型对本地数据的过拟合，降低全局模型性能和训练效率。在实际应用中往往需要在通信开销和算法效率之间进行权衡，选择合适的本地训练轮次。由(瞿祥谋 2022) 可知当 $E = 5$ 时，本地迭代较为完全，模型梯度下降较为稳定，性能可以得到平稳地提升。所以本文经验性地将本地训练轮次设置为 5。本章所用到的数据集和神经网络模型设置与 3.2 章节中保持一致。除此之外，在联邦学习系统中，考虑到通信资源的限制，每一轮并不需要所有的客户端模型均参与聚合，只需要选择客户端子集进行训练和聚合即可。本研究在每一轮中随机选择一定比例的客户端参与训练，每次参与训练的客户端可能是不同的。如果没有额外说明，本研究中将该比例设置为 10%，即每轮选择的客户端数量 $K = 10$ 。

3.4.3 实验结果与分析

本研究通过衡量全局模型在测试数据集上的准确率来评价模型的性能。通过刻画在 μ 分别取 0.1, 0.3, 0.5, 0.7, 0.9 时全局模型的准确率曲线，可以直观地看出非独立同分布程度对模型性能的影响。为了降低数据随机性带来的影响，本研究在每一个 μ 的参数取值下重复进行五次实验，然后对五次实验中的模型准确率进行平均，最后取

前 100 轮次的准确率进行平滑处理和分析。如图 3-3 所示是 Fashion-MNIST 数据集下的全局模型准确率曲线，图 3-4 所示是 CIFAR-10 数据集下的全局模型准确率曲线。




图 3-3 不同 μ 取值下 FedAvg 算法在 Fashion-MNIST 上的模型准确率

Figure 3-3 Model Accuracy of FedAvg Algorithm on Fashion-MNIST under Different μ Values




图 3-4 不同 μ 取值下 FedAvg 算法在 CIFAR-10 上的模型准确率

Figure 3-4 Model Accuracy of FedAvg Algorithm on CIFAR-10 under Different μ Values

由上面的实验结果可以看出，随着数据非独立同分布程度的提高，模型的准确率逐步下降，这与本文之前的分析是相符合的。FedAvg 算法在 Fashion-MNIST 训练集上的模型准确率在 $\mu = 0.9$ 时比在 $\mu = 0.1$ 下降了将近 3%，在 CIFAR-10 训练集上的模

型准确率在 $\mu = 0.9$ 时比在 $\mu = 0.1$ 下降了将近 17%。可见对于越复杂的训练图像，数据非独立同分布带来的影响也就越大。除此之外，随着数据非独立同分布程度的提高，模型的训练过程出现明显震荡，模型的收敛速度变慢。非独立同分布程度越高，震荡越明显。这是因为随着数据非独立同分布程度的提高，客户端模型的漂移现象更加明显，造成全局模型权重发散，不仅降低模型的准确率，还会使整体的收敛速度变慢。

值得说明的是，FedAvg 算法在 Fashion-MNIST 训练集上的模型准确率整体比在 CIFAR-10 训练集上的模型准确率偏高是因为 Fashion-MNIST 数据集较为简单，简单的 CNN 神经网络就能实现较高的模型分类性能，而对于 CIFAR-10 数据集，需要更深更复杂的网络才能实现较高的模型分类性能，也意味着需要更多的模型训练时间。而本文的研究目的只是为了探究不同场景下的全局模型性能，高性能的深度学习网络模型并不是本次研究的主要目标，简单的 CNN 网络就可以满足仿真要求。所以本研究并没有采用目前性能最好、准确率最高的网络模型，参数也未必是最优的。




图 3-5 IID 场景下与 Non-IID 场景下全局模型更新时的差异

Figure 3-5 Differences in Global Model Updates between IID and Non-IID Scenarios

从原理的角度出发进行分析，在联邦学习中，非独立同分布对系统的影响主要是通过局部漂移来实现的。局部漂移是指本地模型在训练过程中逐渐偏离全局最优解的现象。局部漂移产生的本质是因为局部优化目标和全局优化目标不一致。每个客户端在训练本地模型的时候，其目标函数是对本地数据上的损失函数进行优化，而联邦学习的总体目标是优化全局数据上的损失函数。当数据是非独立同分布的时候，每个客户端的本地数据分布与全局数据分布不一致，导致局部和全局优化目标不一致，使本地模型的更新偏离全局最优解，进而影响全局模型的性能。如图 3-5所示，假设有两个

客户端的模型更新 ω_1^t 和 ω_2^t ，他们的局部最优解分别为 ω_1^* 和 ω_2^* ，同样的数据在集中式模型训练中的全局最优解为 ω^* 。在 IID 的场景中，全局最优解 ω^* 接近局部最优解 ω_1^* 和 ω_2^* ，因此聚合后的全局模型 ω^{t+1} 也接近全局最优解；而在 Non-IID 的场景中，全局最优解 ω^* 远离局部最优解 ω_1^* ，导致最后聚合的全局模型 ω^{t+1} 也远离全局最优解。还有一个角度的解释是权重发散。在非独立同分布数据下，每个客户端的本地模型更新方向可能不同，导致全局模型在聚合时偏离集中式训练的最优解。这种发散会随着本地更新次数的增加而累积，当客户端在本地进行多次训练后，这种发散所带来的影响尤其明显。假设全局模型权重为 ω^f ，集中式训练的模型权重为 ω^c ，那么权重发散就可以表示为 $\|\omega^f - \omega^c\|$ ，权重发散程度的大小取决于客户端数据的非独立同分布程度。地球移动距离（Earth Mover's Distance, EMD）可以用来量化客户端数据分布与全局数据分布之间的差异，用公式表示为

$$EMD = \sum_{i=1}^N \|p^{(k)}(y=i) - p(y=i)\| \quad (3-1)$$

EMD 越大，表示客户端数据分布与全局分布差异越大，权重发散和局部漂移的影响也越显著。

3.5 数据中毒攻击对模型性能的影响

攻击者可以通过操纵用于训练模型的局部数据或直接发送错误的模型参数来破坏全局模型的训练，这种类型的攻击被称为中毒攻击。它会降低局部模型的性能，并最终使全局模型失效。在传统的联邦学习系统中，服务器只能确认接收到的本地模型，而不能分辨客户端发送的恶意制作的模型参数。此外，由于数据中毒攻击通常发生在客户端本地，且攻击数据与正常数据混合在一起，因此具有较高的隐蔽性，难以被检测和防御。根据(Fang et al. 2020)，标签翻转攻击的累积效应会降低模型识别恶意标签的能力。因此，解决联邦学习中的中毒攻击一直是一个关键问题。

假设恶意攻击者 C_a 在第 t 轮上传的模型为 ω_a^t ， C_a 的数据集为 D_a ，则恶意攻击可以描述为：

$$\omega^t = \frac{|D_a|\omega_a^t + \sum_{C_i \in \mathcal{S}^t \setminus \{C_a\}} |D_i|\omega_i^t}{|D_a| + \sum_{C_i \in \mathcal{S}^t \setminus \{C_a\}} |D_i|}, \quad (3-2)$$

对于多个攻击者，情况也是类似的。当 ω_a^t 明显偏离其他 ω_i^t 时，会导致全局模型 ω^t 偏离正确的更新方向。一般来说，恶意客户端的占比越高，权重越大，全局模型偏离得就越严重。

为了深入研究数据中毒攻击对联邦学习系统的影响，本研究设计了一个模拟实验，模拟现实中的攻击场景。实验中，本研究假设中心服务器和部分客户端是诚实可信的，

部分客户端被攻击者控制，这些客户端在本地训练过程中注入恶意数据或篡改数据标签。通过这种方式，攻击者试图误导全局模型的训练方向，使其在特定任务上表现不佳或产生错误预测。本研究在不同的攻击强度下（不同比例的恶意客户端）对全局模型的性能进行了评估，并分析了攻击对模型精度、收敛速度和鲁棒性的影响。

3.5.1 实验设置

本节仍然采用 Fashion-MNIST 数据集和 CIFAR-10 数据集进行实验，系统设置、神经网络模型设置和参数设置均与 3.4 节保持一致。为了控制变量，本研究将在独立同分布场景下（ $\mu = 0.1$ ）进行实验，所以本研究将数据集随机划分成 100 份，并将数据分配给 100 个客户端。本节实验仍然使用经典的 FedAvg 算法来评估数据中毒攻击对联邦学习算法的影响。

本文主要研究由标签翻转引起的客户端恶意中毒攻击。在这种攻击中，攻击者通常通过改变客户端的训练数据集标签来诱导本地模型产生分类错误，最终对全局模型产生影响。例如，在 Fashion-MNIST 数据集分类模型中，攻击者可能会将某些客户端数据集中的标签“毛衣”更改为“衬衫”，从而导致本地模型对“毛衣”图片的错误分类，以及聚合后全局模型的错误收敛。本文设置一个参数 m 来控制恶意客户端的比例。例如，当 $m = 0.1$ 时，随机挑选 10 个客户端，并将其本地数据标签全部进行翻转。

3.5.2 实验结果与分析

本研究通过衡量全局模型在测试数据集上的准确率来评价模型的性能。通过刻画在 m 分别取 0.0, 0.3, 0.5, 0.7, 0.9 时全局模型的准确率曲线，可以直观地看出数据中毒攻击对模型性能的影响。为了降低数据随机性带来的影响，本研究在每一个 m 的参数取值下重复进行五次实验，然后对五次实验中的模型准确率进行平均，最后取前 100 轮次的准确率进行平滑处理和分析。如图 3-6 所示是 Fashion-MNIST 数据集下的全局模型准确率曲线，图 3-7 所示是 CIFAR-10 数据集下的全局模型准确率曲线。

由实验结果可以看出，随着恶意客户端占比的提高，模型的准确率逐步降低，这与本文之前的分析高度相符。当联邦学习系统中不存在恶意客户端时，模型性能稳步提升，截止 100 轮，FedAvg 算法在 Fashion-MNIST 测试数据集上能够达到 90.14% 的准确率，在 CIFAR-10 测试数据集上能够达到 65.23% 的准确率。随着恶意客户端占比越来越高，全局模型的准确率出现大幅度震荡，甚至不能收敛。这是因为当恶意客户端的系统占比较高时，每次聚合随机选择的客户端中恶意的占比也会同步提高，由式 (3-2) 可知，聚合阶段恶意客户端的占比越高，全局模型更新就偏离得越严重，表现在准确率上就会产生振荡。这种振荡在由 Fashion-MNIST 训练出的模型中更为显著，这本质上还是因为 Fashion-MNIST 数据集和 CNN 网络模型都较为简单，很容易便能学习到

客户端数据的特征，而标签翻转又可以对模型梯度产生较大影响，所以当每次聚合选择到恶意客户端时，就会产生更大的影响，表现在准确率上就会产生更大的震荡幅度。




图 3-6 不同比例恶意用户下 FedAvg 算法在 Fashion-MNIST 测试集上的模型准确率

Figure 3-6 Impact of Malicious Client Proportion on FedAvg Accuracy in Fashion-MNIST




图 3-7 不同比例恶意用户下 FedAvg 算法在 CIFAR-10 测试集上的模型准确率

Figure 3-7 Impact of Malicious Client Proportion on FedAvg Accuracy in CIFAR-10

从原理的角度出发进行分析，数据中毒攻击使客户端的模型更新偏离正确的更新方向，甚至与原本的更新方向完全相反。而当恶意客户端占比较高时，恶意模型参数

的聚合权重也较高,造成全局模型的更新方向大大偏离。如图 3-8所示,假设在某次聚合选择的客户端当中,良性客户端的整体模型更新为 g_p , 恶意客户端的整体模型更新为 g_m , 全局模型更新为 g_0 。当良性客户端占比较高时, g_0 虽然较 g_p 有所偏离,但更新的方向大致一致;当恶意客户端占比较高时, g_m 居于主导地位, g_0 大大远离 g_p 。




图 3-8 不同恶意客户端占比时全局模型更新的差异

Figure 3-8 Divergence in Global Model Updates with Varying Proportions of Malicious Clients

3.6 非独立同分布与数据中毒攻击复合场景对模型性能的影响

为了探究非独立同分布与数据中毒攻击复合场景下联邦学习模型的性能,本文在 CIFAR-10 数据集上对 FedAvg 算法进行实验,实验结果如图 3-9所示。当在 IID 场景下,模型的准确率能达到 65%, Non-IID 场景 ($\mu = 0.5$) 可导致模型的准确率下降 3%, 恶意中毒攻击 ($m = 0.5$) 可导致模型准确率进一步下降 28%。




图 3-9 非独立同分布与数据中毒攻击复合场景对模型性能的影响

Figure 3-9 The Impact of Non-IID and Data Poisoning Attack Composite Scenarios on Model Performance

由以上分析可知，非独立同分布和恶意攻击都会扩大客户端模型之间的分布差异，导致全局模型偏离最优的更新方向。而且在联邦学习环境中，非独立同分布数据与恶意中毒攻击之间存在明显的相互影响。以下是两者相互作用的关键表现：

（1）Non-IID 数据会放大攻击隐蔽性。Non-IID 场景下，客户端模型更新的统计差异（如梯度方向、参数范数）本身较大，导致基于相似性的检测算法难以区分恶意更新与正常异构更新。

（2）恶意攻击加剧 Non-IID 的负面影响。攻击者可以通过数据投毒（如标签翻转），刻意扩大客户端间的分布差异，进一步破坏全局模型收敛。

（3）协同作用导致防御机制失效。现有的防御策略通常针对单一威胁设计：Non-IID 优化方法假设所有客户端诚实，无法抵御恶意攻击；拜占庭防御算法在 Non-IID 场景下会误判合法客户端为恶意节点。

综上所述，现实场景中非独立同分布与恶意中毒攻击的相互耦合会显著增加系统安全性和模型性能的挑战。如何在非独立同分布的场景下把恶意客户端排除在聚合之外，增强复杂环境下联邦学习的鲁棒性并提高全局模型的性能，是目前亟待解决的问题。

3.7 本章小结

本章深入分析了非独立同分布数据和恶意攻击对联邦学习算法的影响。首先介绍了本研究中用到的数据集、神经网络模型设置和数据集划分策略，对非独立同分布数据进行可视化，然后分别搭建了非独立同分布场景和恶意攻击场景，并在两个场景下对 FedAvg 算法进行仿真实验。实验证明非独立同分布和数据中毒攻击会给联邦学习算法带来很大的负面影响，包括降低模型的准确率，降低模型收敛速度，甚至导致模型不能正常收敛。而且，通过实验可以直观地看出，随着非独立同分布程度和恶意客户端占比的增加，所带来的模型性能下降也更加明显。除此之外，本章从原理方面分析和探讨了导致模型性能下降的底层逻辑，对模型性能下降的原因有了更清楚的认识。本章的仿真实验证明，研究如何在非独立同分布和恶意攻击场景中实现高性能的联邦学习是一个至关重要且具有挑战性的课题。

第四章 基于贡献度和可信度的鲁棒联邦学习方法

4.1 引言

基于前三章的探讨和研究可以知道，尽管联邦学习的出现为机器学习发展提供了新的方向，顺利解决了数据孤岛和隐私安全的问题，但非独立同分布数据和恶意攻击问题严重阻碍了联邦学习的落地和应用，而目前大部分的算法无法同时解决这两个问题。为了降低这两个因素带来的负面影响，本章设计了一个非独立同分布场景下的鲁棒联邦学习方法——联邦学习中基于贡献度和可信度的客户端选择算法（Federated Learning with Client Selection Based on Contribution and Credibility, FL-CSBC²）。为了验证该算法的有效性，本文搭建了一个非独立同分布和数据中毒攻击并存的复杂场景，并在该场景下对 FL-CSBC² 和其他对比算法进行广泛实验，通过分析实验结果来评估该算法面对非独立同分布和数据中毒攻击场景时的性能。

4.2 根数据集

根数据集是联邦学习或其他分布式机器学习系统中的核心数据集合，由中心服务器收集维护或作为全局基准数据，通常规模较小且不受恶意攻击的侵扰。在(Cao et al. 2021) 中作者首次提出了根数据集的概念，但在此之前，也有一些在服务器端进行维护的小型基准数据集，只是没有冠以根数据集的名称。

根数据集往往作为协作学习流程的起点，承担着模型初始化、性能校准、贡献衡量与知识迁移等多重功能。一方面，根数据集通过预训练生成初始全局模型参数，为客户端本地训练提供基础（如 ResNet、Transformer 等架构的初始化权重）。例如，在跨医院协作的医疗影像分析场景中，根数据集可由公开的标准化病理切片构成，确保模型具备基础特征提取能力。另一方面，根数据集作为独立测试集，用于评估全局模型的泛化性能，避免因客户端本地数据分布不均（Non-IID）或质量差异导致的评估偏差。在金融风控场景中，根数据集可通过平衡的正负样本验证各银行客户端的反欺诈模型效果，从而辅助中心服务器动态调整聚合策略。此外，根数据集还可用于量化客户端贡献（如结合夏普利值法），通过对比客户端本地更新对根数据集性能的影响，区分高价值参与者（如提供稀有数据或高效计算资源的设备）与低贡献节点。在客户端数据稀疏或质量低下时，根数据集还可通过迁移学习（如特征提取、模型蒸馏）补充知识，辅助客户端设备优化本地模型。

根数据集和本地数据集虽然都用于训练相同的模型，但他们在特征和用途方面有

很大的区别。根数据集来源于中心服务器的自主收集或是从公共数据池当中提取而来，而本地数据集则来源于用户设备、企业数据库等分布式客户端；根数据集往往聚焦数据的关键特征或典型场景，而本地数据集数量庞杂，分布呈现碎片化的特点；为了更具有泛化性和代表性，根数据集往往被人工设计为 IID 的形式，而本地数据集则反映了现实的数据场景，具有高度 Non-IID 的特性；根数据集的目的主要是为了保证全局模型与本地模型更新的一致性，而本地数据集主要实现了本地模型的个性化。

4.3 基于贡献度和可信度的客户端选择算法

4.3.1 设计思路

一些已有的方法如通过余弦相似度(Chen et al. 2022) 来检测恶意客户端的算法是基于良性客户端与全局模型之间的差异比恶意客户端与全局模型之间的差异要小的前提，这是因为在恶意客户端较少的情况下，恶意客户端模型的整体收敛趋势是与全局模型差距较大甚至相反的，所以在这种场景下通过余弦相似度是可以鉴别出恶意客户端的。但是若是在 Non-IID 数据的场景下，由于客户端数据集之间的分布不同，即使是良性客户端，它与全局模型之间的差距也会很大，所以在这种情况下不仅不能很好的鉴别出恶意客户端，反而会把一些重要的良性客户端排除在聚合之外。

尽管恶意攻击的形势复杂多变，但恶意攻击的目的都在于破坏训练过程，降低全局模型的性能。所以恶意客户端上传的模型一旦参与聚合，必然会导致全局模型在测试数据集上的性能下降，即恶意客户端对于全局模型的边际贡献较低，甚至为负值。而随着边际贡献的持续低值，该客户端也逐渐变得不再可信。对于非独立同分布的联邦学习场景来说，为了接近集中式机器学习训练模型的性能，尽可能地保证参与聚合的模型的多样性是关键。而客户端模型对全局模型的边际贡献越高，说明其与参与聚合的其他模型的差异越大，它的加入能够大大提高参与聚合的模型的多样性，并且还能够说明它是恶意客户端的概率较低。考虑到这两点，本文从客户端模型的贡献度和可信度角度出发，将贡献度和可信度较低的客户端模型排除在聚合之外，尽可能地保证每一轮参与聚合的客户端是良性的同时提高参与聚合的模型的多样性。

4.3.2 根数据集的设置

本章中定义了两个根数据集，分别用于训练服务器端模型和衡量客户端贡献度，两个数据集均在服务器端进行维护。为了便于区分，本文将用于训练服务器端模型的数据集的称为根数据集 D_0 ，将用于衡量客户端贡献度的数据集称为验证数据集 D_v 。

验证数据集 D_v 用于计算各客户端加入聚合集合时的边际贡献。该数据集主要从测试数据集中分离而来，也可以从公共数据集中抽样而来，所以往往是独立同分布的。本文用聚合模型在验证数据集上的准确率提升幅度或者损失值下降幅度来作为客户端

的边际贡献。

根数据集 D_0 的规模比验证数据集小很多, 通过服务器收集并进行人工修正来得到。这主要是为了保证数据集完全干净, 没有收到任何恶意攻击的污染。服务器端模型利用 D_0 与本地模型同步进行训练, 获得服务器端模型 ω_0 。将服务器 C_0 加入最初的客户端聚合集合, 这也意味着将 ω_0 作为最初的聚合模型, 后续客户端模型的边际贡献均是在该模型的基础上进行计算。之所以以该模型作为基础, 是因为若最初的客户端聚合集合是空集, 那么所有客户端相对聚合集合的边际贡献均为正值, 而本地模型在初始化的时候具有一定的随机性, 某些恶意用户可能在训练初始具有比良性用户还高的积极贡献, 导致恶意客户端的贡献度和可信度在初始阶段虚高, 容易被误选入聚合集合, 造成全局模型收敛速度降低。而将 ω_0 作为最初的聚合模型, 无疑提高了客户端加入聚合集合的初始门槛。尤其是根数据集作为干净的不受恶意攻击污染的数据集, 其训练出的模型也相对正确, 恶意客户端的模型的加入相对于良性客户端更有可能降低它的性能, 有利于筛选出良性客户端。

4.3.3 基于边际贡献的贡献度模型

在边际收益利润分享(Gollapudi et al. 2017) 中, 团队成员的收益与团队成员参与后团队效用的提升呈正相关。参与者按照特定的顺序加入团队时, 每个参与者的边际贡献来自于他们加入团队时所收获的边际效用。由第二章中边际贡献的相关介绍可以知道, 目前联邦学习中客户端边际贡献的计算方法主要包括留一法和夏普利值法。留一法计算当某一方存在和不存在两种情况下模型性能的差异, 并通过该差异来衡量该参与方的边际贡献。然而这种方法忽视了数据冗余性和群体协作效应的复杂关系, 所以可能无法公平地衡量参与者的边际效益。而夏普利值法虽然能从理论上解决这一问题, 但因其复杂度较高, 应用于参与方众多的联邦学习场景中并不现实。蒙特卡洛采样虽然可以降低夏普利值法的复杂度, 但却也是牺牲性能来换取时间和空间的做法, 而且由于采样具有随机性, 每一次得到的模型性能可能并不稳定。

本研究基于夏普利值法的启发, 结合边际贡献的定义和原理, 提出了一种基于边际贡献的贡献度计算方法。考虑一组参与者 $\mathcal{C} = \{C_i(i = 1, 2, \dots, N)\}$ 。设 $\mathcal{S}$ 为协作完成某一任务的参与者的子集, $U(\mathcal{S})(\mathcal{S} \subseteq \mathcal{C})$ 为子集 $\mathcal{S}$ 对该任务所产生的效用。参与者 $C_i(C_i \in \{\mathcal{C} \setminus \mathcal{S}\})$ 对 $\mathcal{S}$ 的边际贡献可以表示为 $V_i = U(\mathcal{S} \cup \{C_i\}) - U(\mathcal{S})$ 。

与留一法不同的是, 本研究考虑了客户端加入的顺序, 之前加入的客户端会对后续加入的客户端的边际贡献产生影响。与夏普利值法不同的是, 本研究没有预设所有客户端的组合方式, 而是通过计算客户端的边际贡献来逐个选择客户端, 用以获得一种较优的客户端组合。

客户端在联邦学习中的边际贡献定义如下: 客户端即为上述团队工作的参与者, 这

些客户端需要按照一定的顺序加入用于聚合全局模型的客户端集合 $\mathcal{S}$ ，共同完成聚合任务。在这里，效用函数即为全局模型在验证数据集上的准确率或损失值。每个客户端模型的边际贡献就是其加入当前客户端聚合集合时的边际收益。

如上所述，本研究将服务器 C_0 加入初始客户端聚合集合，并使用根数据集训练的服务器模型 ω_r^t 作为第 r 轮训练的初始全局模型，计算每个客户端加入聚合时的边际贡献。本文将全局模型在验证数据集上的准确率作为效用函数，客户端 C_i 的边际贡献计算公式如下：

$$V_{k,i}^t = U\left(\omega_{\mathcal{S}^t \cup \{C_i\}}^t, D_v\right) - U\left(\omega_{\mathcal{S}^t}^t, D_v\right) \quad (4-1)$$

$$\omega_{\mathcal{S}^t \cup \{C_i\}}^t = \sum_{C_j \in \mathcal{S}^t \cup \{C_i\}} \frac{|D_j| \omega_j^t}{\sum_{C_j \in \mathcal{S}^t \cup \{C_i\}} |D_j|} \quad (4-2)$$

$$\omega_{\mathcal{S}^t}^t = \sum_{C_j \in \mathcal{S}^t} \frac{|D_j| \omega_j^t}{\sum_{C_j \in \mathcal{S}^t} |D_j|} \quad (4-3)$$

其中 D_v 为验证数据集，可以从客户端数据集中收集而来， t 表示第 t 次训练， k 表示 $\mathcal{S}^t$ 已经包含了 $k-1$ 个客户端。该式的目的是为了计算客户端 i 作为第 k 个客户端加入聚合集合时的边际贡献。

由于边际贡献是一个正向指标，也就是说，边际贡献越高，客户端是良性的可能性越大，对模型性能的改进就越显著。因此，本研究采用 Min-Max 归一化方法(Panda and Jana 2015) 对客户端的边际贡献进行归一化：

$$VN_{k,i}^t = \frac{V_{k,i}^t - \min V_k^t}{\max V_k^t - \min V_k^t}, \quad i = 1, 2, \dots, N \quad (4-4)$$

$\min V_k^t$ 是指在选择第 k 个客户端加入聚合集合时，每一个客户端边际贡献的最小值。 $\max V_k^t$ 是指在选择第 k 个客户端加入聚合集合时，每一个客户端边际贡献的最大值。该式允许在不改变数据分布的情况下将数据映射到 $[0,1]$ 的范围内。具体来说，它将最大值映射为 1，将最小值映射为 0。本文将标准化的边际贡献作为客户端 i 在这一轮选择中的贡献度。

4.3.4 基于秩和比的可信度模型

基于本章设计思路中的分析，边际贡献越高的客户端，其成为良性客户端的概率越高，反之，则更有可能为恶意用户。所以本研究在边际贡献的基础上，借助秩和比 (RSR) 来定义每一轮客户端的可信度。

在计算 RSR 时，首先确定个 n 评价对象和 m 个评价指标或等级，然后用它们构造一个 n 行 m 列的评价矩阵 $\mathbf{X}$ 。数值越大结果越理想的指标被归类为效益型指标，反之则被归类为成本型指标。本文假设选取 k (其中 $k < N$) 个客户端参与第 t 轮聚合。

每次客户端选择都需要计算 N 个客户端的贡献度。经过一轮训练，将计算 k 次 N 个客户端的贡献度，从而得到 k 组客户端贡献度。本算法的评价对象是 $\mathcal{C}$ 中的所有客户端，评价指标是 k 轮选拔中所有客户端的 k 组贡献度。评价矩阵 $\mathbf{X}$ 可以构造为：

$$\mathbf{X} = \begin{bmatrix} VN_{11}^t & VN_{12}^t & \dots & VN_{1k}^t \\ VN_{21}^t & VN_{22}^t & \dots & VN_{2k}^t \\ \vdots & \vdots & \ddots & \vdots \\ VN_{N1}^t & VN_{N2}^t & \dots & VN_{Nk}^t \end{bmatrix} \quad (4-5)$$

其中 VN_{nm}^t 为客户端 C_n 在第 t 轮训练中选择第 m 个客户端时的归一化贡献度。由于贡献度是一个效益型指标，因此将第 j 列客户端的归一化贡献按降序排序，得到该列各指标值的秩 R_{ij} 。对其余列应用相同的过程，然后将原有的评价指标值替换为评价指标值的秩，得到秩矩阵 $\mathbf{R}_V$ ：

$$\mathbf{R}_V = Rank(\mathbf{X}) \begin{bmatrix} R_{11} & R_{12} & \dots & R_{1k} \\ R_{21} & R_{22} & \dots & R_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ R_{N1} & R_{N2} & \dots & R_{Nk} \end{bmatrix} \quad (4-6)$$

进一步，计算每个客户端的 RSR 。由于每个评价指标代表一个贡献度等级序列，所以权重 W_j 设为 1。第 t 轮中客户端 C_i 的秩和比计算可以表示为：

$$RSR_i^t = \frac{1}{n} \sum_{j=1}^k W_j R_{ij} \quad (4-7)$$

在这里，客户端贡献度等级越高， RSR 越小，说明客户端为良性的概率越高，对全局模型性能的改善越显著。为了保持与贡献度的一致性，本研究对 RSR 进行归一化，得到客户端可信度 Cr ，其在第 t 轮中为：

$$Cr_i^t = \frac{\max RSR^t - RSR_i^t}{\max RSR^t - \min RSR^t}, \quad i = 1, 2, \dots, N \quad (4-8)$$

由于 RSR 是一个负向指标，而可信度是一个正向指标，因此本研究将 RSR 的最大值映射为 0，最小值映射为 1。

4.3.5 客户端选择与聚合策略

从前面的讨论中可以明显看出，贡献度是在当前轮次客户端选择时计算的度量，而可信度是从前一轮客户端选择中派生的度量。根据进化聚类(Chakrabarti et al. 2006) 中的规定，当有两个相互冲突的指标需要同时优化的时候，需要满足以下规则：

- (1) 在任何时间点的聚类都要遵循当前结果的特征；
- (2) 从一个时间片到下一个时间片的聚类不能有太大变化。

所以在联邦学习中，客户端选择的顺序应该基于当前轮次贡献度的计算，同时也要考虑之前轮次计算中可信度更高的客户端。

因此，本研究为贡献度和可信度分配不同的权重来计算当前轮次客户端选择时各个客户端的评分，其中贡献度的权重表示为 β ，可信度的权重表示为 $1 - \beta$ 。客户端 C_i 的评分计算公式为：

$$M_{k,i}^t = \beta V N_{k,i}^t + (1 - \beta) Cr_i^{t-1}, \quad (4-9)$$

对于两种特殊情况， $\beta = 0$ 表示客户端得分仅基于前一轮客户端的可信度，而 $\beta = 1$ 表示客户端评分仅仅取决于当前轮次客户端的贡献度。本文设置 β 的取值范围为 $[0.5, 1]$ 。

本文采用贪心算法设计 FL-CSBC²。当要选择一个客户端加入这一轮的客户端聚合集合时，先计算每个客户端模型对于已经选择的客户端子集的边际贡献 $V_{k,i}^t$ ，将其归一化以获得该客户端对当前轮次的贡献度 $V N_{k,i}^t$ ，然后根据贡献度和前一轮客户端的可信度 Cr_i^{t-1} 计算客户端评分 $M_{k,i}^t$ 。选择评分最高的客户端加入聚合集合。重复计算客户端评分并持续选择客户端加入，直到达到聚合阈值 p 。具体来说，如果连续 p 次选择加入聚合集合的客户端的贡献度小于等于 0，则终止这一轮的客户端选择过程。同时，本算法将根据客户端的贡献度计算这一轮的客户端可信度 Cr_i^t ，并在后续的计算中使用。

对于聚合阶段各个客户端模型的权重，本研究仍然采用 FedAvg 中的聚合策略，将客户端数据集大小占全部数据集大小的比重作为该客户端模型的权重，客户端数据集大小将跟随客户端模型一起上传至中心服务器，服务器在收到所有客户端数据集的大小后进行加和并计算出每一个客户端的权重。算法2提供了客户端选择和聚合过程的详细描述。

算法 2 FL-CSBC²

输入： 客户端 $C_i \in \mathcal{C}$ ，服务器 C_0 ，贡献度权重 β ，客户端聚合集合 $\mathcal{S}^t$ ，迭代轮数 T ，客户端 C_i 的本地模型 ω_i^t ，客户端 C_i 的本地数据集 D_i ，根数据集 D_0 ，验证数据集 D_v ，聚合阈值 p ，参与聚合的客户端个数 k ，开始计算可信度的轮次 δ

输出： 全局模型 ω^T

- 1: $\omega^0 \leftarrow$ 初始化全局模型
- 2: $Cr = \vec{0}$
- 3: **for** $t = 1, 2, \dots, T$ **do**
- 4: 服务器和客户端用全局模型 ω^t 初始化服务器端模型和本地模型
- 5: $k = 0$
- 6: $\mathcal{S}^t.push(C_0)$

```

7:  while  $count < p$  do
8:     $k = k + 1$ 
9:    for  $C_i$  in  $\mathcal{C}$  but not in  $\mathcal{S}^t$  in parallel do
10:       $V_{k,i}^t = U(\omega_{\mathcal{S}^t \cup \{C_i\}}^t, D_v) - U(\omega_{\mathcal{S}^t}^t, D_v)$ 
11:       $VN_{k,i}^t = \text{Normalization}(V_{k,i}^t)$ 
12:       $M_{k,i}^t = \beta VN_{k,i}^t + (1 - \beta)Cr_i^{t-1}$ 
13:    end for
14:     $index = \max(M_k^t).key$ 
15:     $\mathcal{S}^t.push(C_{index})$ 
16:     $count \leftarrow count + 1$  if  $VN_{k,i}^t \leq 0$ , else 0
17:  end while
18:   $\mathcal{S}^t.pop(1 \text{ to } p)$ 
19:  if  $t > \delta$  then
20:     $\mathbf{X} = [VN_1^t, VN_2^t, \dots, VN_k^t]$ ,  $\mathbf{R}_V = \text{Rank}(\mathbf{X})$ ;
21:    for  $i = 1, 2, \dots, N$  in parallel do
22:       $RSR_i^t = \frac{1}{n} \sum_{j=1}^k R_{ij}$ ;
23:       $Cr_i^t = \text{Normalization}(RSR_i^t)$ 
24:    end for
25:  end if
26:   $\omega^{t+1} = \sum_{C_i \in \mathcal{S}^t} \frac{|D_i| \omega_i^t}{\sum_{C_i \in \mathcal{S}^t} |D_i|}$ 
27: end for
28: return  $\omega^T$ 

```

4.4 仿真实验与结果分析

4.4.1 实验设置

4.4.1.1 系统和参数设置

本节仿真实验使用的平台系统设置同表 3-3，这里不再给出。为了保证服务器端模型和客户端模型的一致性，服务器端和客户端的模型训练均采用动量梯度下降算法(Sutskever et al. 2013)，学习率统一设置为 $\eta = 0.01$ ，动量设置为 $m = 0.5$ ，本地批处理大小设置为 32，全局通信轮数 T 设置为 100 轮，本地训练轮次 $E = 5$ 。默认情况下，本研究设置 $\beta = 0.7$ ， $\delta = 20$ 。换句话说，本研究将从联邦学习训练的第 20 次迭代开始计算可信度，以避免初始迭代不稳定带来的影响。

4.4.1.2 场景设置

本节采用中心化联邦学习架构进行仿真，包括一个中心服务器和 100 个客户端。我们将整个架构置于一个非独立同分布和恶意中毒攻击并存的复杂场景当中。服务器端主要包括四个功能，包括训练服务器端网络模型、计算各客户端的边际贡献、客户端选择和全局模型聚合。除此之外，服务器端维护着根数据集和验证数据集两个独立同分布数据集。各个客户端本地数据集之间是非独立同分布的，非独立同分布程度用参数 μ 来调节，具体方法参考 3.3.1 节。本研究主要探究当 $\mu = 0.1$ 和 $\mu = 0.5$ 时 FL-CSBC² 下的模型性能。 $\mu = 0.1$ 时，客户端数据接近独立同分布，而 $\mu = 0.5$ 是大部分前沿算法所采用的仿真环境。本研究通过参数 m 来控制系统中恶意用户的占比，并对当 m 分别取 0.2, 0.5, 0.7, 0.9 时 FL-CSBC² 下的模型性能进行仿真。 $m = 0.2$ 代表恶意客户端占比为 20%。假设恶意用户中所有的数据标签均进行了翻转。

4.4.1.3 数据集和模型设置

本节实验在 Fashion-MNIST 和 CIFAR-10 数据集上进行广泛实验，相关数据集介绍见 3.2.1 节。客户端和服务端端的神经网络模型设置也与 3.2.2 节保持一致。

对于 Fashion-MNIST 数据集，本文在训练集当中随机抽取 100 张图像作为根数据集，由于训练集当中各类别的数据是独立同分布的，所以根数据集也是独立同分布的。本研究把剩余的 59900 张图像按照 3.3.1 中的非独立同分布数据集划分策略分配给 100 个客户端，每个客户端拥有 599 张左右的训练图像，具体数目会由于分配随机性而上下浮动。同时，将 10000 张测试图像随机划分为两部分，一部分作为服务器端的验证数据集，另一部分作为测试数据集，用于评估全局模型的性能。本节仿真实验将验证数据集大小设置为 2000，测试数据集大小为 8000。

同理，对于 CIFAR-10 数据集，本文从训练集当中随机抽取 100 张图像作为根数据集，然后将剩余 49900 张图像划分给客户端，划分策略与 Fashion-MNIST 数据集相同。验证数据集和测试数据集的大小和划分方式也与 Fashion-MNIST 数据集相同。

4.4.2 对比算法与评价指标

4.4.2.1 对比算法

为了客观地评估 FL-CSBC² 的性能，本文将其与以下方法进行了比较。这些方法也在一定程度上解决了联邦学习中的非独立同分布问题和恶意攻击问题：

- AFedSV+(Sun et al. 2023): 一种基于自适应夏普利值的联邦学习贡献评估算法，通过动态蒙特卡洛采样技术，在非独立同分布场景和恶意攻击场景下实现高效、公平的客户端贡献量化，选择贡献度高的用户参与聚合，同时显著降低计算复杂度，保障大规模联邦系统的可扩展性与鲁棒性。

- FedAvg(McMahan et al. 2017): 一种经典的联邦学习算法，通过在分布式客户端本

地训练模型并聚合其参数更新（加权平均），实现在保护数据隐私的同时高效协作优化全局模型，尤其适用于 Non-IID 数据场景。

•**FedProx**(Li et al. 2020): 一种改进的联邦学习算法，通过引入局部更新的正则化项来平衡客户端的局部优化与全局模型的更新，从而提高算法的稳定性和收敛速度。

•**FLTrust**(Cao et al. 2021): 一种拜占庭鲁棒的联邦学习算法，通过在服务器端维护一个根数据集，并利用余弦相似度信任函数来筛选和加权可信的本地模型更新，从而在存在恶意客户端的情况下仍能有效训练出准确的全局模型。

•**RFA**(Pillutla et al. 2022): 是一种增强鲁棒性的联邦学习算法，通过引入几何中位数机制有效抵御恶意客户端攻击与数据异质性干扰，提升全局模型在 Non-IID 及对抗性环境下的安全性与收敛稳定性。

4.4.2.2 评价指标

为了更好地量化各个算法在复杂环境下的表现，本章从模型效能与安全鲁棒性两个层面对各算法进行评估。具体指标定义如下：

(1) 测试准确率 (Testing Accuracy, TACC)

TACC 是衡量全局模型性能的核心指标，定义为全局模型在测试数据集上的预测准确率：

$$TACC = \frac{\text{正确预测样本数}}{\text{测试集总样本数}} \times 100\% \quad (4-10)$$

该指标反映了算法在非独立同分布和恶意攻击并存的复杂场景中的学习能力。TACC 越高表明模型在该算法下的学习能力越好，越能有效捕捉跨客户端的共性特征；而 TACC 的波动性（如不同通信轮次间的方差）则反映了算法是否能稳定收敛。实验设计中，测试集需独立于客户端本地数据，以避免过拟合本地分布的评估偏差。为了方便，本文在后续表述中将测试准确率简写为准确率。

(2) 误选率 (False Selection Rate, FSR)

FSR 用于量化算法对对抗性攻击的防御能力，定义为被选择参与聚合的客户端中恶意节点的比例：

$$FSR = \frac{\text{参与聚合的客户端当中恶意客户端的数量}}{\text{参与聚合的客户端总数}} \times 100\% \quad (4-11)$$

该指标反映了算法筛选良性客户端的能力。FSR 越低表明算法识别并排除恶意参与者的能力越强，FSR 的波动性也从侧面反映了算法性能的稳定性。在本研究中，只有本算法和 AFedSV+ 具有筛选良性客户端的功能，因此只在这两个算法下对 FSR 进行比较。

需要强调的是，FSR 与 TACC 存在动态博弈关系——过度严格的恶意客户端过滤条件可能误把高价值节点排除在外，导致 TACC 下降；而宽松策略则可能引入攻击风险。因此，理想算法应在 TACC 与 FSR 间实现最优平衡。

4.4.3 关键参数的选择

关键参数的选择往往会对实验结果产生较大的影响，为了更科学地设置关键参数，本节在恶意客户端占比 $m = 50\%$ ，非独立同分布程度 $\mu = 0.5$ 时的 CIFAR-10 数据集分类任务场景中进行相关实验，探究关键参数的取值。

4.4.3.1 β 的选择

在 FL-CSBC² 中， β 是一个关键的参数。图 4-1 描述了 FL-CSBC² 在 β 取不同值时的性能表现。如图所示，随着 β 值的增大，全局模型在测试数据集上的准确率先上升后下降，当 $\beta = 0.7$ 时达到最佳性能。这符合进化聚类关于当前优化过程需要以当前轮次的结果为主导的要求。因此在本文后续的仿真实验中经验性地将 β 设置为 0.7。




图 4-1 CIFAR-10 分类任务下不同 β 对 FL-CSBC² 性能的影响

Figure 4-1 Impact of β on FL-CSBC² Performance in CIFAR-10 Classification

4.4.3.2 阈值 p 的选择




图 4-2 CIFAR-10 分类任务下不同聚合阈值 p 对 FL-CSBC² 性能的影响

Figure 4-2 Impact of Aggregation Threshold p on FL-CSBC² Performance in CIFAR-10 Classification

在 FL-CSBC² 中, p 是一个关键的阈值。图 4-2 描述了 FL-CSBC² 在 p 取不同值时的性能表现。如图所示, 随着 p 值的增大, 全局模型在测试数据集上的准确率先上升后下降, 当 $p = 3$ 时达到最佳性能。这是因为当 p 值较小时, 阈值条件过于严格, 导致每轮选择的客户端太少, 这可能会阻碍非独立同分布场景下客户端多样性的有效整合。然而, 当 p 值太大时, 阈值条件会过于宽松, 从而导致部分恶意客户端破坏聚合过程, 降低全局模型的性能。因此在本文后续的仿真实验中经验性地将 p 设置为 3。

4.4.3.3 本地批处理大小的选择

为了得到更好的模型性能, 本节对本地批处理大小取不同值时的模型性能进行仿真实验, 探究 FL-CSBC² 在本地批处理大小分别取 32 和 64 时的性能表现。如图所示, 在本地批处理大小为 32 时, 模型能获得更好的泛化性能。这与我们的经验相同, 较小的批处理大小可以通过梯度噪声的正则化效应、平坦最小值的偏好以及隐式数据多样性增强, 显著提升模型的泛化性能。





图 4-3 CIFAR-10 分类任务下不同本地批处理大小对 FL-CSBC² 性能的影响

Figure 4-3 Impact of Local Batch Size on FL-CSBC² Performance in CIFAR-10 Classification

4.4.4 实验结果与分析

4.4.4.1 测试准确率分析

图 4-4 和图 4-5 分别展示了在 CIFAR-10 分类任务中, 当非独立同分布程度 $\mu = 0.1$ 和 $\mu = 0.5$ 时, FL-CSBC² 与基线方法在四种不同比例的恶意客户端场景中训练模型的准确率变化趋势。对于每个算法, 本文进行了平均操作和平滑处理: 对每个算法分别进行了 5 次独立的实验, 并对结果进行平均, 把平均后的结果每 2 个点再取一个平均值, 以该值做折线图。除此之外, 本研究取各算法第 96-100 轮的准确率进行平均, 得到表 4-1, 该表反映了 100 轮附近各算法所能达到的测试准确率。各项研究结果表明, 在不同恶意客户端占比的独立同分布场景和非独立同分布场景中, FL-CSBC² 的性能明显优于其他算法。

图 4-4 $\mu = 0.1$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 TACCFigure 4-4 TACC of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.1$ and Varying m

以恶意客户端占比 20% 的独立同分布场景实验为例, 如图 4-4a 所示。经过 100 轮联邦学习训练后, FL-CSBC² 在测试集上的平均准确率达到 63.6%, 与 AFedSV+ 性能相当, 比 FedAvg、FedProx、FLTrust 和 RFA 分别提高了 5.1%、49.7%、28.5% 和 3.3%。除了 FL-CSBC² 和 AFedSV+, 其他算法均有不同幅度的震荡, 且震荡幅度随着恶意客户端占比的提高而增加, 有些算法甚至不能收敛。AFedSV+ 只能在恶意客户端占比较低时保持稳定, 在恶意客户端占比较高时, 虽有整体上涨的趋势, 但却相当不稳定, 且收敛速度不如 FL-CSBC²。随着恶意客户端占比的提高, 所有算法的准确率均有不同程度的下降, 这与本文之前的分析相符。当恶意客户端占比大于 50% 时, FedAvg、FedProx、FLTrust 和 RFA 已经无法发挥效能, 甚至不如初始化的模型性能。这是因为它们依赖于所有客户端模型的信息, 一旦恶意客户端占主导地位, 算法就无法将更新矫正至正确的方向, 全局模型在相反的更新方向上越走越远, 甚至不如随机初始化的模型。而 FL-CSBC² 和 AFedSV+ 的性能虽然有一定程度的下降, 但仍然能够实现正向增长。这也是其他实验研究中常把恶意客户端占比限制在 50% 以内的原因。




图 4-5 $\mu = 0.5$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 TACC

Figure 4-5 TACC of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.5$ and Varying m

表 4-1 CIFAR-10 分类任务下不同联邦学习算法的 TACC(%)

Table 4-1 TACC (%) of Federated Learning Algorithms on CIFAR-10 Classification Task								
数据集	μ	m	FL-CSBC ²	AFedSV+	FedAvg	FedProx	FLTrust	RFA
CIFAR-10	0.1	0.2	63.6	63.6	58.5	13.9	35.1	60.3
		0.5	60.5	57.5	31.2	12.5	20.3	31.7
		0.7	60.2	51.9	13.4	10.4	17.5	15.8
		0.9	50.9	28.5	4.7	10.3	8.0	4.4
	0.5	0.2	61.2	60.8	57.2	26.2	35.6	57.1
		0.5	59.6	57.1	34.5	18.1	23.2	33.6
		0.7	56.1	51.9	14.7	12.3	17.5	12.3
		0.9	48.3	25.2	4.8	8.1	7.0	4.6

在非独立同分布场景下，以图4-5b为例。当非独立同分布程度为 0.5，恶意客户端占比为 50% 时，经过 100 轮联邦学习训练后，FL-CSBC² 在测试集上的平均准确率达

到了 59.6%，比 AFedSV+、FedAvg、FedProx、FLTrust 和 RFA 分别提高了 2.5%、25.1%、41.5%、36.4% 和 26.0%。其中，FedProx 的性能较差是因为其虽在一定程度上可以降低恶意攻击带来的影响，但同时也降低了各客户端模型的多样性，限制了模型更新的幅度。随着非独立同分布程度的提高，FL-CSBC²、AFedSV+、FedAvg、FLTrust 和 RFA 的 TACC 大都有小幅度的下降，个别 TACC 的提高应归咎于曲线的振荡。但 FedProx 整体在非独立同分布程度较高的场景下性能更高，这是因为非独立同分布场景大大提高了客户端模型之间的多样性，使全局模型更新有更多的可能性，在一定程度上弥补了一些 FedProx 本身的不足。

综上所述可以看出，无论是 IID 还是 Non-IID 场景下，中毒攻击带来的影响要比非独立同分布带来的影响更大。恶意客户端占比为 90% 与恶意客户端占比为 20% 时相比，各算法 TACC 的下降幅度均超过 FL-CSBC²。这些完全可以说明 FL-CSBC² 对于中毒攻击有明显的抵抗效果。整合 CIFAR-10 分类任务中各个场景下的实验结果来看，无论是在独立同分布场景还是非独立同分布场景，无论是高恶意客户端占比场景还是低恶意客户端占比场景，FL-CSBC² 的 TACC 均能达到与基准算法相当甚至更高的水平。尤其是在高恶意客户端占比的情况下，FL-CSBC² 有非常明显的优势。

为了保证实验的泛化性，本文在 Fashion-MNIST 上也进行了广泛的实验。图 4-6 和图 4-7 分别展示了在 Fashion-MNIST 分类任务中，当非独立同分布程度 $\mu = 0.1$ 和 $\mu = 0.5$ 时，FL-CSBC² 与基线方法在四种不同比例的恶意客户端场景中训练模型的准确率变化趋势。表 4-2 则展示了不同场景下算法准确率所能达到的具体数值。实验设置与 CIFAR-10 分类任务相似，实验结果结果和结论也与 CIFAR-10 分类任务相一致，FL-CSBC² 下的模型性能明显优于其他算法。

表 4-2 Fashion-MNIST 分类任务下不同联邦学习算法的 TACC(%)

Table 4-2 TACC (%) of Federated Learning Algorithms on Fashion-MNIST Classification Task

数据集	μ	m	FL-CSBC ²	AFedSV+	FedAvg	FedProx	FLTrust	RFA
Fashion-MNIST	0.1	0.2	89.4	89.5	80.1	71.2	82.7	81.4
		0.5	88.8	87.9	44.5	44.7	47.9	50.2
		0.7	88.3	76.4	23.8	14.1	15.8	14.2
		0.9	87.4	50.2	1.2	1.5	2.0	0.7
	0.5	0.2	88.9	88.8	78.8	81.0	78.7	80.7
		0.5	88.4	82.3	46.4	45.9	42.8	33.5
		0.7	88.1	76.3	22.5	14.9	20.4	17.4
		0.9	86.0	46.9	2.3	1.2	2.6	1.0

以恶意客户端占比 50% 的独立同分布场景实验为例，如图 4-6b 所示。经过 100 轮联邦学习训练后，FL-CSBC² 在测试集上的平均准确率达到 88.8%，比 AFedSV+、FedAvg、FedProx、FLTrust 和 RFA 分别提高了 0.9%、44.3%、44.1%、40.9% 和 38.6%。

虽然 AFedSV+ 最终达到与 FL-CSBC² 相当的准确率, 但其收敛稳定性和收敛速度却远不如 FL-CSBC²。FedAvg、FedProx 和 RFA 的 TACC 受恶意攻击的影响下上下振荡, 无法正常收敛。而 FLTrust 虽然没有上下振荡, 但模型准确率却收敛于一个较低水平。





图 4-6 $\mu = 0.1$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 TACC

Figure 4-6 TACC of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.1$ and Varying m

在非独立同分布场景下, 以图4-7a为例。当非独立同分布程度为 0.5, 恶意客户端占比为 20% 时, 经过 100 轮联邦学习训练后, FL-CSBC² 在测试集上的平均准确率达到了 88.9%, 与 AFedSV+ 性能相当, 比 FedAvg、FedProx、FLTrust 和 RFA 分别提高了 10.1%、7.9%、10.2% 和 8.2%。可以看出在恶意客户端占比较低的情况下, FLTrust 最初的性能可以与 FL-CSBC² 最初的性能相媲美, 但随着训练轮次的增加, 全局模型一步步被恶意模型腐蚀, 导致借助全局模型进行权重调整的机制被破坏, 模型性能逐步下降。而 FedProx 由于有正则化项的存在, 全局模型的前几轮性能不高, 随着训练过程的增加, TACC 逐步增高。虽然模型的振荡幅度较其他几个算法相对较小, 但模型的最终性能并不高。

图 4-7 $\mu = 0.5$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 TACCFigure 4-7 TACC of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.5$ and Varying m

综合来看,相较于 CIFAR-10,在 Fashion-MNIST 分类任务中,各场景下的算法准确率波动较大且整体上偏高。这是因为 Fashion-MNIST 数据集的特征相对简单,简单的 CNN 网络就可以达到较高的模型性能。与此同时,标签翻转攻击对梯度产生的影响更大,一旦选择恶意客户端进行聚合,全局模型性能就会产生较大的波动。相比之下,对于 CIFAR-10 数据集,由于其在简单 CNN 网络中训练的模型准确率较低,因此偶尔选择恶意客户端参与聚合对全局模型的影响相对较小。整合各场景下的结果来看,CIFAR-10 训练任务下的结论也同样适用于 Fashion-MNIST 分类任务,FL-CSBC² 的 TACC 能达到与基准算法相当甚至更高的水平。尤其是在高恶意客户端占比的情况下,FL-CSBC² 有非常明显的优势。

4.4.4.2 误选率分析

图 4-8和图 4-9分别展示了在 CIFAR-10 分类任务中,当非独立同分布程度 $\mu = 0.1$ 和 $\mu = 0.5$ 时,FL-CSBC² 与 AFedSV+ 在四种不同比例的恶意客户端场景中误选率的

变化趋势。对于每个算法，本文进行了平均操作和平滑处理：对每个算法分别进行了 5 次独立的实验，并对 TACC 和 FSR 结果进行平均，把平均后的结果每四个点取一个中位数，以该值做折线图。除此之外，本研究取各算法第 97-100 轮的准确率中位数，得到表 4-1，该表反映了 100 轮附近算法的模型准确率和误选率。各项研究结果表明，在不同恶意客户端占比的独立同分布场景和非独立同分布场景中，FL-CSBC² 的性能明显优于基准算法。通过对 FSR 的分析，能够更加清楚地理解 FL-CSBC² 高性能的底层原因。





图 4-8 $\mu = 0.1$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 FSR

Figure 4-8 FSR of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.1$ and Varying m

由图 4-8 和图 4-9 可以看出误选率 FSR 与测试准确率 TACC 呈负相关，当 FSR 升高时，TACC 下降；当 FSR 降低时，TACC 升高。这与常识相符合，参与聚合的恶意客户端越多，全局模型的性能也就越低。整体来看，FSR 随着恶意客户端占比 m 的增加而提高。这是因为当 m 增加时，每轮聚合选择到恶意客户端的概率增加，FSR 自然也就增加。降低 FSR 是大部分联邦学习应对恶意攻击的底层策略。FL-CSBC²、AFedSV+ 与 FedAvg 均存在客户端选择机制。FedAvg 由于没有筛选机制，每轮参与聚合的客户

图 4-9 $\mu = 0.5$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 FSRFigure 4-9 FSR of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.5$ and Varying m

端是随机选择的, 导致 FSR 等于整体的恶意客户端占比, 所以对恶意攻击的抵抗能力较弱。AFedSV+ 的准确率虽然较 FedAvg 有较大提升, 但还是远远不及 FL-CSBC², 这是因为其客户端选择具有显著的随机性, 虽然可以通过选择概率进行调整, 但当恶意占比较高时, 也很难避免恶意客户端被误选。FL-CSBC² 制定了更严格的客户端选择标准, 既考虑了当前轮次客户端的贡献度, 也考虑了前一轮客户端的可信度。而贡献度和可信度的计算仅与客户端模型本身以及测试数据集有关, 所以它受非独立同分布数据和客户端之间交互的影响较小, 能够降低误选率, 将大部分恶意客户端排除在聚合之外, 进而训练出准确率更高的全局模型。除此之外, 可以观察到 FSR 在训练伊始阶段较高, 随着训练轮次的增加, FSR 逐渐降低。这是因为随着客户端与服务器不断交互, 有效的算法能够使全局模型向正确的方向更新, 此时进行反方向更新的恶意客户端更容易被识别。

由表 4-3 可以看出, 非独立同分布对 FSR 有一定程度的影响, 但影响远小于恶意

中毒攻击。除了恶意客户端占比为 90%， $\mu = 0.5$ 的极端场景，FL-CSBC² 均能将 FSR 降至 0，相对于 AFedSV+ 有明显的优势。

表 4-3 CIFAR-10 分类任务下不同联邦学习算法的 TACC(%) 和 FSR(%)

Table 4-3 TACC (%) and FSR (%) for Federated Learning Algorithms on CIFAR-10

数据集	μ	m	FL-CSBC ²		AFedSV+	
			TACC	FSR	TACC	FSR
CIFAR-10	0.1	0.2	63.6	0	63.6	6.6
		0.5	60.6	0	58.5	12.8
		0.7	60.1	0	51.1	24.8
		0.9	51.0	0	29.4	46.3
	0.5	0.2	61.3	0	60.8	3.9
		0.5	59.6	0	57.0	14.8
		0.7	56.0	0	52.7	21.5
		0.9	48.3	4.5	26.7	45.4




图 4-10 $\mu = 0.1$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 FSR

Figure 4-10 FSR of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.1$ and Varying m


图 4-11 $\mu = 0.5$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 FSRFigure 4-11 FSR of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.5$ and Varying m

表 4-4 Fashion-MNIST 分类任务下不同联邦学习算法 TACC(%) 和 FSR(%)

Table 4-4 TACC (%) and FSR (%) for Federated Learning Algorithms on Fashion-MNIST

数据集	μ	m	FL-CSBC ²		AFedSV+	
			TACC	FSR	TACC	FSR
Fashion-MNIST	0.1	0.2	89.4	0	89.5	5.2
		0.5	88.3	0	88.2	11.2
		0.7	88.7	0	77.4	21.9
		0.9	87.4	0	56.7	45.2
	0.5	0.2	88.9	0	89.1	5.4
		0.5	88.1	0	86.4	13.6
		0.7	88.4	0	75.8	20.2
		0.9	85.9	0	53.0	40.3

为了保证实验的泛化性, 本文在 Fashion-MNIST 也进行了广泛的实验。图 4-10和图

4-11分别展示了在 Fashion-MNIST 分类任务中,当非独立同分布程度 $\mu = 0.1$ 和 $\mu = 0.5$ 时,FL-CSBC² 与 AFedSV+ 在四种不同比例的恶意客户端场景中误选率的变化趋势。除此之外,本研究取各算法第 97-100 轮的准确率中位数,得到表 4-4,该表反映了 100 轮附近算法的模型准确率和误选率。实验设置与 CIFAR-10 分类任务相似,实验结论也与 CIFAR-10 分类任务相一致,FL-CSBC² 下的模型性能明显优于基线算法。折线图的趋势和表格的数据变化也进一步印证了上面结果分析的正确性。

4.5 本章小结

本章设计了一种在非独立同分布场景下应对恶意攻击的鲁棒联邦学习方法,其核心是 FL-CSBC² 算法。本章首先介绍了根数据集的定义及其在算法中的应用,然后构建了基于边际贡献的贡献度模型以及基于秩和比的可信度模型,最后设计了相应的客户端选择与聚合策略,这些模块共同组合成为 FL-CSBC²。经过在 Fashion-MNIST 和 CIFAR-10 数据集上的广泛实验与评估,验证了 FL-CSBC² 在非独立同分布和恶意中毒攻击并存的复杂场景中的有效性,并分析了该算法领先于其他算法的底层原因。除此之外,本章还介绍了本算法中对于根数据集的设计方法以及最佳阈值的选择,提供了更多的参数选择依据。

第五章 基于 AP 聚类 and 贡献度的鲁棒联邦学习方法

5.1 引言

在第四章中设计了一种可以有效应对非独立同分布和恶意攻击问题的联邦学习算法。但是通过分析可以发现，由于要频繁地在验证数据集上进行验证，当训练模型的参数规模庞大时，算法的时间复杂度会很高。为了降低时间复杂度，在算法性能和效率之间寻找平衡点，本章设计了另一种基于 AP 聚类和贡献度的客户端选择算法——（Federated Learning with Client Selection Based on AP Clustering and Contribution, FL-CSBAC）。为了验证该算法的有效性，本章在非独立同分布和恶意攻击共存的场景中进行广泛实验，并与 FL-CSBC² 以及其他基准算法进行对比，分析了各算法的测试准确率、误选率以及时间复杂度，并对平均聚类数量进行统计分析。

5.2 AP 聚类的可视化

AP 聚类(Frey and Dueck 2007) 作为一种基于消息传递的无监督聚类方法，其核心优势在于无需预先指定聚类数量即可自动识别数据内在结构。本节通过构建合成数据集，结合 Python 可视化工具，系统呈现 AP 聚类的动态过程与结果特征，旨在为算法调优与模式分析提供直观依据。

本节实验采用随机生成的包含 4 个聚类的二维合成数据集，其聚类中心坐标为 (3, 3), (1, 1), (3, 1), (1, 3)，共含 300 个样本点，标准差为 0.5。该设计通过对称分布模拟理想化的类间分离场景，实现数据分类可视化。AP 聚类模型初始化时设定参考度 $p(i) = -50$ ，该值通过调节数据点成为聚类中心的倾向性，直接影响最终聚类数量。算法通过迭代消息传递（责任度与可用度更新）确定聚类中心，并完成样本分配。成员点以散点形式绘制，从聚类中心到各成员点绘制连线，直观反映聚类的辐射状结构。实验结果如图 5-1 所示，AP 聚类成功识别预设的 4 个聚类，聚类中心与生成数据的理论坐标偏差小于 0.1，如表 5-1 所示。

表 5-1 聚类中心的理论值与估计值

Table 5-1 Theoretical vs. Estimated Cluster Centers

聚类编号	理论中心 (x,y)	估计中心 (x,y)	欧氏距离误差
1	(3, 3)	(3.02, 2.98)	0.028
2	(1, 1)	(0.97, 1.03)	0.042
3	(3, 1)	(2.99, 0.99)	0.014
4	(1, 3)	(1.01, 3.02)	0.022




图 5-1 AP 聚类可视化

Figure 5-1 Theoretical vs. Estimated Cluster Centers

5.3 基于 AP 聚类和边际贡献的客户端选择算法

5.3.1 设计思路

鉴于 FL-CSBC² 在客户端选择阶段采用贪心算法的策略，而且在计算贡献度时需要频繁在验证数据集上进行实验，导致其时间复杂度较高。为了在保证训练模型性能的同时尽可能地降低时间复杂度，本研究计划降低每轮客户端选择时贡献度的计算次数，并且增加每次选择的客户端数量，即计算一次客户端的贡献度，选择多个客户端加入聚合。这样就可以从两个方面降低算法的时间复杂度。要想完成这一设计，就需要对各个客户端模型进行分类聚合。而由于不清楚最佳的聚类数量，AP 聚类成为了实现该算法的首选方法。本研究在 AP 聚类的基础上设计贡献度更新策略、客户端选择策略以及模型聚合策略。这些模块共同组合成为 FL-CSBAC。本章研究也将基于根数据集和验证数据集进行相关设计，具体设置与 4.2 节保持一致。

对于机器学习任务来说，在初始化神经网络模型参数相同的情况下，若客户端拥有相似的数据分布特征，其训练出来的神经网络参数往往也有较高的相似度，因此可以将训练出来的神经网络模型参数看作一个能够反映本地数据分布的高维向量。在 IID 场景中，各客户端模型之间的差异较小；而在 Non-IID 场景中，客户端模型之间的差异较大。所以在 Non-IID 场景中，很难通过模型之间的差异大小来区分良性用户和恶意用户。但无论是在 IID 还是在 Non-IID 场景中，恶意客户端模型与良性客户端模型之间均有较大差异。所以可以先通过聚类算法把客户端分为若干良性客户端集群和若干恶意客户端集群，然后再从这些集群当中筛选出良性集群，让其中的客户端参加全局模型聚合任务，这样就能尽可能地把恶意客户端排除在聚合之外。

5.3.2 AP 聚类策略

为了减少贡献度的计算次数，本算法先对本轮次所有的客户端模型进行 AP 聚类，划分客户端集群并确定聚类中心。然后计算作为聚类中心的各客户端模型的边际贡献，并以该贡献值作为该客户端集群的贡献度。假设 AP 聚类后得到了 L 个客户端集群，贡献度的计算次数就可以从客户端总数 N 降低至 L 。第 t 轮训练中 AP 聚类的过程如下：

(1) 服务器广播全局模型 ω^t ，客户端接收到 ω^t 后用其初始化本地模型，然后各客户端利用本地数据集进行训练得到本地网络模型参数 ω_i 。

(2) 使用负的欧氏距离来计算各客户端模型之间的相似度 $s(i, j)$ ，如式 (5-1) 所示：

$$s(i, j) = -\|\omega_i^t - \omega_j^t\|^2 \quad (5-1)$$

$s(i, j)$ 越大说明两个模型参数之间的距离越近，客户端 j 越适合作为客户端 i 的聚类中心。所有的相似度构成一个相似度矩阵 $\mathbf{S}$ ：

$$\mathbf{S} = \begin{bmatrix} s(1, 1) & s(1, 2) & \dots & s(1, N) \\ s(2, 1) & s(2, 2) & \dots & s(2, N) \\ \vdots & \vdots & \ddots & \vdots \\ s(N, 1) & s(N, 2) & \dots & s(N, N) \end{bmatrix} \quad (5-2)$$

(3) 将 i 和 j 之间的吸引度表示为 $r(i, j)$ ， $r(i, j)$ 反映了 j 适合作为 i 的聚类中心的程度，初始全部为 0。所有的吸引度构成吸引度矩阵 $\mathbf{R}$ ：

$$\mathbf{R} = \begin{bmatrix} r(1, 1) & r(1, 2) & \dots & r(1, N) \\ r(2, 1) & r(2, 2) & \dots & r(2, N) \\ \vdots & \vdots & \ddots & \vdots \\ r(N, 1) & r(N, 2) & \dots & r(N, N) \end{bmatrix} \quad (5-3)$$

将 i 和 j 之间的归属度表示为 $a(i, j)$ ， $a(i, j)$ 反映了 i 选择 j 作为其聚类中心的倾向，初始全部为 0。所有的归属度构成归属度矩阵 $\mathbf{A}$ ：

$$\mathbf{A} = \begin{bmatrix} A(1, 1) & A(1, 2) & \dots & A(1, N) \\ A(2, 1) & A(2, 2) & \dots & A(2, N) \\ \vdots & \vdots & \ddots & \vdots \\ A(N, 1) & A(N, 2) & \dots & A(N, N) \end{bmatrix} \quad (5-4)$$

(4) 按照如下公式更新吸引度矩阵和归属度矩阵：

$$r(i, j) \leftarrow s(i, j) - \max_{j' \neq j} \{a(i, j') + s(i, j')\} \quad (5-5)$$

$$a_{t+1}(i, j) \leftarrow \begin{cases} \min\{0, r_t(i, j) + \sum_{i' \notin \{i, j\}} \max\{0, r_t(i', j)\}\}, & i \neq j \\ \sum_{i' \notin \{i, j\}} \max\{0, r_t(i', j)\}, & i = j \end{cases} \quad (5-6)$$

(5) 使用阻尼系数处理吸引度矩阵和归属度矩阵, 计算公式如下:

$$r_{t+1}(i, j) = \lambda \cdot r_t(i, j) + (1 - \lambda) \cdot r_{t+1}(i, j) \quad (5-7)$$

$$a_{t+1}(i, j) = \lambda \cdot a_t(i, j) + (1 - \lambda) \cdot a_{t+1}(i, j) \quad (5-8)$$

(6) 确定聚类中心。对于每个客户端 i , 选择使 $a(i, j) + r(i, j)$ 最大的客户端 j 作为客户端 i 的聚类中心。如果 $j = i$, 那么 i 是它自己的聚类中心。

(7) 不断更新迭代吸引度矩阵和归属度矩阵, 直到聚类中心不再发生变化或者已经达到预设的最大迭代次数。

5.3.3 贡献度更新与客户端选择策略

本文采用与第四章相似的边际贡献计算方法。假设在上一节中通过聚类获得了 L 个客户端集群, 每个集群用 $G_q (q = 1, 2, \dots, L)$ 表示, 对应集群中的聚类中心表示为 C_g , g 为聚类中心在所有客户端中的索引。具体的贡献度更新和客户端选择过程如下:

(1) 在服务器端维护一个根数据集, 并用其训练服务器端模型, 训练过程与客户端训练保持同步。将服务器端模型加入最初的客户端聚合集合 $\mathcal{S}^t$ 。

(2) 采用式 (5-9)-式 (5-12) 计算该训练轮次当中每一个聚类中心的边际贡献并进行归一化, 将聚类中心的边际贡献作为其所在的客户端集群的边际贡献, 将归一化后的边际贡献作为聚类中心所在的客户端集群的贡献度。

$$V_{k,q}^t = U(\omega_{\mathcal{S}^t \cup \{C_g\}}^t, D_v) - U(\omega_{\mathcal{S}^t}^t, D_v) \quad (5-9)$$

$$\omega_{\mathcal{S}^t \cup \{C_g\}}^t = \sum_{C_j \in \mathcal{S}^t \cup \{C_g\}} \frac{|D_j| \omega_j^t}{\sum_{C_j \in \mathcal{S}^t \cup \{C_g\}} |D_j|} \quad (5-10)$$

$$\omega_{\mathcal{S}^t}^t = \sum_{C_j \in \mathcal{S}^t} \frac{|D_j| \omega_j^t}{\sum_{C_j \in \mathcal{S}^t} |D_j|} \quad (5-11)$$

其中 D_v 为验证数据集, t 表示第 t 轮训练, k 表示 $\mathcal{S}^t$ 已经包含了 $k-1$ 个客户端集群。该式的目的是为了计算客户端集群 G_q 作为第 k 个集群加入聚合集合时的边际贡献。

$$VN_{k,q}^t = \frac{V_{k,q}^t - \min V_k^t}{\max V_k^t - \min V_k^t}, \quad i = 1, 2, \dots, N \quad (5-12)$$

$\min V_k^t$ 是指在选择第 k 个客户端集群加入聚合集合时, 每一个客户端集群边际贡献的最小值。 $\max V_k^t$ 是指在选择第 k 个客户端集群加入聚合集合时, 每一个客户端集群边际贡献的最大值。

(3) 将贡献度最高的若干客户端集群 (有可能存在不同集群贡献度相等的情况) 加入 $\mathcal{S}^t$ 。

(4) 重新计算剩余集群相对于当前客户端聚合集合的边际贡献, 重复步骤 (3), 直到选择的客户端集群的贡献度小于 0, 该轮的客户端选择过程停止。需要注意的是, 每轮至少要选择一客户端集群。

(5) 将 $\mathcal{S}^t$ 中的所有客户端模型按照式 (2-3) 进行聚合, 得到本轮的全局模型 ω^{t+1} 。

算法3提供了 FL-CSBAC 算法的详细描述。

算法 3 FL-CSBAC

输入: 客户端 $C_i \in \mathcal{C}$, 服务器 C_0 , 客户端聚合集合 $\mathcal{S}^t$, 迭代轮数 T , 客户端 C_i 的本地模型 ω_i^t , 客户端 C_i 的本地数据集 D_i , 根数据集 D_0 , 验证数据集 D_v , 客户端集群 G_q , 聚类中心 C_g , 参与聚合的客户端集群个数 k

输出: 全局模型 ω^T

```

1:  $\omega^0 \leftarrow$  初始化全局模型
2: for  $t = 1, 2, \dots, T$  do
3:   服务器和客户端用全局模型  $\omega^t$  初始化服务器端模型和本地模型
4:    $k = 0$ 
5:    $\mathcal{S}^t.push(C_0)$ 
6:    $G_q, C_g \leftarrow AP(\mathcal{C})$ 
7:   repeat
8:     for  $q = 1, 2, \dots, L$  do
9:       取  $G_q$  的聚类中心  $C_g$ 
10:       $V_{k,q}^t = U(\omega_{\mathcal{S}^t \cup \{C_g\}}^t, D_v) - U(\omega_{\mathcal{S}^t}^t, D_v)$ 
11:    end for
12:    for  $q = 1, 2, \dots, l$  do
13:       $VN_{k,q}^t = \text{Normalization}(V_{k,q}^t)$ 
14:    end for
15:     $index = \max(VN_k^t).key$ 
16:     $\mathcal{S}^t \leftarrow \mathcal{S}^t \cup G_{index}$ 
17:     $k = k + 1$ 
18:  until  $V_{k,index}^t < 0$ 
19:   $\omega^{t+1} = \sum_{C_i \in \mathcal{S}^t} \frac{|D_i| \omega_i^t}{\sum_{C_i \in \mathcal{S}^t} |D_i|}$ 
20: end for
21: return  $\omega^T$ 

```

5.4 仿真实验与结果分析

5.4.1 实验设置

为了控制变量，本章仿真实验的系统设置、场景设置、数据集设置与模型设置均与第四章保持一致。在此，只对 AP 聚类过程中的参数设置进行简要说明。本研究将参考度 $p(i)$ 设置为相似度矩阵中的中位数，将阻尼系数 λ 设置为 0.8。

除此之外，通过第四章的实验可以发现，在进行对比的六个算法当中，FL-CSBC² 和 AFedSV+ 算法的模型性能最好。由于本章实验场景设置与第四章相同，为了减少冗余，本章只将 FL-CSBAC 与 FL-CSBC² 和 AFedSV+ 算法进行对比。

5.4.2 实验结果与分析

5.4.2.1 测试准确率分析




图 5-2 $\mu = 0.1$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 TACC

Figure 5-2 TACC of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.1$ and Varying m

图 5-2 和图 5-3 分别展示了在 CIFAR-10 分类任务中, 当非独立同分布程度 $\mu = 0.1$ 和 $\mu = 0.5$ 时, FL-CSBC², FL-CSBAC, AFedSV+ 三种联邦学习算法在四种不同比例的恶意客户端场景中训练模型的准确率变化趋势。依旧对结果进行平均操作和平滑处理: 对每个算法分别进行 5 次独立的实验, 并对结果进行平均, 把平均后的结果每 2 个点再取一个平均值, 以该值做折线图。除此之外, 本研究取各算法第 96-100 轮的准确率进行平均, 得到表 5-2, 该表反映了 100 轮附近各算法所能达到的测试准确率。各项研究结果表明, 在不同恶意客户端占比的独立同分布场景和非独立同分布场景中, FL-CSBAC 在测试准确率上能够达到与 FL-CSBC² 相当的水平, 在高恶意客户端占比的情况下远胜于 AFedSV+, 但在准确率稳定性上与 FL-CSBC² 有一定差距。详细分析如下:




图 5-3 $\mu = 0.5$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 TACC

Figure 5-3 TACC of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.5$ and Varying m

(1) 非独立同分布程度 μ 的影响:

随着 μ 从 0.1 增加到 0.5, 客户端数据分布的非独立同分布程度提高, 联邦学习任务难度加大, 各算法的测试准确率整体有所下降, 但 FL-CSBC² 和 FL-CSBAC 依旧保

持较强的鲁棒性。具体来说, FL-CSBC² 在两种 μ 取值下均展现出较高的测试准确率和稳定的收敛曲线; 除了极端恶意客户端占比的情况, FL-CSBAC 在 IID 场景下的准确率略逊于 FL-CSBC², 但在非独立同分布场景下可以达到与 FL-CSBC² 相当的水平; AFedSV+ 在两种 μ 取值下的趋势大致相同, 但在非独立同分布场景下的准确率有小幅度的下降。

通过分析, 上述现象出现的原因归咎于各算法的逻辑特点以及非独立同分布环境自身的特性。FL-CSBC² 虽然可以每一次都将贡献度最高的客户端加入聚合集合, 但在该客户端加入集合之后, 与其相似度较高的客户端的贡献度就会变低, 甚至为负值。所以后续即使这类客户端个体对系统有较高的贡献, 也不会被选择加入聚合集合, 这在一定程度上降低了聚合集合的客户端多样性。而 FL-CSBAC 先通过聚类将客户端分为不同的簇, 同一个簇中客户端的模型相似度较高, 在计算出每一个簇的贡献度之后, 将贡献度最高的簇包含的所有客户端加入聚合集合, 这样就避免了 FL-CSBC² 中的问题, 大大提高了聚合集合的客户端多样性。尤其在非独立同分布场景下, 客户端之间表现出明显的分簇特征, FL-CSBAC 能更大程度地保证所选客户端的多样性。AFedSV+ 是基于动态蒙特卡洛采样技术的客户端选择方法, 由于采样存在随机性, 在高非独立同分布场景下, 可能会把高价值的客户端遗漏, 进而造成测试准确率下降。

表 5-2 CIFAR-10 分类任务下不同联邦学习算法的 TACC(%)

Table 5-2 TACC (%) of Federated Learning Algorithms on CIFAR-10 Classification Task

数据集	μ	m	FL-CSBC ²	FL-CSBAC	AFedSV+
CIFAR-10	0.1	0.2	63.6	60.9	63.6
		0.5	60.5	60.1	57.5
		0.7	60.2	58.6	51.9
		0.9	50.9	52.0	28.5
	0.5	0.2	61.2	60.0	60.8
		0.5	59.6	59.9	57.1
		0.7	56.1	55.3	51.9
		0.9	48.3	51.0	25.2

(2) 恶意客户端占比 m 的影响:

当 m 从 0.2 增加到 0.9 时, 所有算法的测试准确率都不同程度下降。FL-CSBC² 在所有 m 值场景下表现相对稳定, FL-CSBAC 在大部分场景下呈现出比 FL-CSBC² 更大的波动性, AFedSV+ 在高恶意用户占比时波动最剧烈, 几乎无法有效收敛。从最终达到的准确率来看, FL-CSBC² 的准确率在所有 m 值场景下保持较高水平, 显示出对恶意攻击场景的良好适应能力; FL-CSBAC 在大部分场景下能够达到与 FL-CSBC² 相当的水平, 在高恶意客户端占比的情况下表现更佳; AFedSV+ 在恶意客户端占比为 20% 时能够达到与 FL-CSBC² 和 FL-CSBAC 相当的模型性能, 在占比大于 20% 时测试准确

率和收敛稳定性都不及 FL-CSBC² 和 FL-CSBAC，当占比为 70% 和 90% 时 AFedSV+ 基本失效，说明该算法对恶意攻击的鲁棒性较差。

通过分析，上述现象出现的原因归咎于各算法的逻辑特点以及恶意中毒攻击的特性。FL-CSBC² 设置有较为严格的客户端筛选策略，并且以模型性能增长为筛选的主要导向，所以准确率的收敛过程较为稳定，也能最终收敛到一个较高的水平。虽然随着恶意占比的提高，模型准确率有所下降，但仍然具有较高的鲁棒性。由于恶意客户端模型与良性模型的训练目标不同，导致二者的参数有较大差异，所以在聚类过程中可以根据相似度，把恶意客户端与良性客户端划分到不同的聚类之中。尤其在高恶意客户端占比的情况下，恶意客户端之间表现出更加明显的聚类倾向。FL-CSBAC 基于 AP 聚类计算各集群的贡献度，可以将恶意客户端集群排除在聚合之外。FL-CSBAC 不仅提高了客户端选择的效率，也提高了联邦学习系统应对高恶意客户端占比等极端场景的能力。由于不能保证每一轮集群的选择都百分百正确，这种依靠聚类选择客户端集群的算法也存在一定缺陷。当某次选择的客户端集群是恶意的时候，模型准确率就会大幅度下降，训练过程也会产生波动。AFedSV+ 基于随机采样，所以当系统整体恶意客户端占比较高的时候，采样到的客户端中的恶意占比也会很高，导致算法机制失效，进而模型准确率下降，产生较大波动，甚至无法收敛。

综上所述，在 CIFAR-10 分类任务中，随着非独立同分布程度的升高和恶意客户端占比的增加，FL-CSBC² 和 FL-CSBAC 均展现出优异的性能和鲁棒性。其中，FL-CSBC² 在各种场景下都有较强的稳定性，FL-CSBAC 的稳定性不如 FL-CSBC²，但在非独立同分布场景和恶意客户端占比极高的场景下训练的模型具有较高的测试准确度。AFedSV+ 在恶意客户端占比较低的情况下性能较优，而在恶意客户端占比较高的情况下无法正常收敛。

表 5-3 Fashion-MNIST 分类任务下不同联邦学习算法的 TACC(%)

Table 5-3 TACC (%) of Federated Learning Algorithms on Fashion-MNIST Classification Task

数据集	μ	m	FL-CSBC ²	FL-CSBAC	AFedSV+
Fashion-MNIST	0.1	0.2	89.4	90.2	89.5
		0.5	88.8	88.8	87.9
		0.7	88.3	88.0	76.4
		0.9	87.4	87.3	50.2
	0.5	0.2	88.9	89.6	88.8
		0.5	88.4	88.9	82.3
		0.7	88.1	86.6	76.3
		0.9	86.0	86.4	46.9

为了保证实验的泛化性，本文也在 Fashion-MNIST 上对三个算法进行了广泛的实验。图 5-4 和图 5-5 分别展示了在 Fashion-MNIST 分类任务中，当非独立同分布程度

$\mu = 0.1$ 和 $\mu = 0.5$ 时, FL-CSBC², FL-CSBAC, AFedSV+ 三种联邦学习算法在四种不同比例的恶意客户端场景中训练模型的准确率变化趋势。表 5-3 则展示了不同场景下算法准确率所能达到的具体数值, 实验设置与 CIFAR-10 分类任务相似。




图 5-4 $\mu = 0.1$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 TACC

Figure 5-4 TACC of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.1$ and Varying m

与 CIFAR-10 分类任务下有所不同的是, FL-CSBAC 在 IID、恶意客户端占比 50% 的场景下表现出很大的波动性, 波动幅度甚至超过 AFedSV+, 这种波动在 $\mu = 0.1$ 时明显下降。这恰恰证明了本文之前分析的正确性。FL-CSBAC 在非独立同分布和恶意攻击特征明显的场景中才能更好的捕捉高价值的客户端模型, 而在 IID 和恶意用户占比低的场景中则更容易选择到恶意客户端集群, 再加上 Fashion-MNIST 分类任务较为简单, 抗中毒攻击的能力较差, 所以出现大幅度的准确率波动。虽然 IID、恶意客户端占比 20% 的场景中非独立同分布和恶意攻击特征也不够明显, 但其波动幅度小于占比 50% 的场景, 这主要是因为该场景整体的恶意客户端占比较低, 导致选择恶意客户端集群的概率本身就低。

除此之外, FL-CSBAC 在恶意客户端占比 90% 的场景下表现出更明显的稳定性。通过输出该场景下选择的客户端索引可以看出, FL-CSBAC 几乎选出了所有的良性客户端, 这进一步证明了 FL-CSBAC 更加适用于高恶意客户端占比的场景。




图 5-5 $\mu = 0.5$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 TACC

Figure 5-5 TACC of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.5$ and Varying m

5.4.2.2 误选率分析

图 5-6和图 5-7分别展示了在 CIFAR-10 分类任务中, 当非独立同分布程度 $\mu = 0.1$ 和 $\mu = 0.5$ 时, FL-CSBC², FL-CSBAC, AFedSV+ 三种联邦学习算法在四种不同比例的恶意客户端场景中训练模型的误选率变化趋势。依旧对每个算法结果进行平均操作和平滑处理: 对每个算法分别进行了 5 次独立的实验, 并对 FSR 结果进行平均, 把平均后的结果每两个点再进行平均值计算, 以该值做折线图。除此之外, 本研究取各算法第 97-100 轮的误选率中位数, 得到表 5-4, 该表反映了 100 轮附近算法的误选率。各项研究结果表明, 在不同恶意客户端占比的独立同分布场景和非独立同分布场景中, FL-CSBAC 在误选率上能够达到与 FL-CSBC² 相当的水平, 远胜于 AFedSV+。


图 5-6 $\mu = 0.1$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 FSRFigure 5-6 FSR of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.1$ and Varying m

表 5-4 CIFAR-10 分类任务下不同联邦学习算法的 FSR(%)

Table 5-4 FSR (%) for Federated Learning Algorithms on CIFAR-10

数据集	μ	m	FL-CSBC ²	FL-CSBAC	AFedSV+
CIFAR-10	0.1	0.2	0	0	6.6
		0.5	0	0	12.8
		0.7	0	0	24.8
		0.9	0	0	46.3
	0.5	0.2	0	0	3.9
		0.5	0	0	14.8
		0.7	0	0	21.5
		0.9	4.5	0	45.4

由图 5-6和图 5-7可以看出误选率 FSR 在该任务下与非独立同分布程度和恶意客户端占比成正比，非独立同分布程度越高，FSR 越高；恶意客户端占比越高，FSR 也越

高。FL-CSBC² 和 FL-CSBAC 在 100 轮时的 FSR 近似收敛于 0，AFedSV+ 则无法收敛，因此 FL-CSBAC 有着近似于 FL-CSBC² 的良好性能。除此之外，可以观察到，在恶意客户端占比为 90% 的场景中，FL-CSBAC 的 FSR 整体上小于 FL-CSBC²，处于较低水平。这印证了本文对该场景下测试准确率分析的正确性——恶意客户端占比极高的情况下，不同客户端集群的特征差异非常明显，有利于 FL-CSBAC 分辨出良性客户端集群。




图 5-7 $\mu = 0.5$, m 取不同值时 CIFAR-10 分类任务下不同联邦学习算法的 FSR

Figure 5-7 FSR of Federated Learning Algorithms on CIFAR-10 with $\mu = 0.5$ and Varying m

为了保证实验的泛化性，本文在 Fashion-MNIST 也进行了广泛的实验。图 5-8 和图 5-9 分别展示了在 Fashion-MNIST 分类任务中，当非独立同分布程度 $\mu = 0.1$ 和 $\mu = 0.5$ 时，FL-CSBC²，FL-CSBAC，AFedSV+ 三种联邦学习算法在四种不同比例的恶意客户端场景中误选率的变化趋势。除此之外，本研究取各算法第 97-100 轮的误选率中位数，得到表 5-5，该表反映了 100 轮附近算法的误选率。实验设置与 CIFAR-10 分类任务相似，实验结果和结论也与 CIFAR-10 分类任务基本一致。


图 5-8 $\mu = 0.1$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 FSRFigure 5-8 FSR of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.1$ and Varying m

表 5-5 Fashion-MNIST 分类任务下不同联邦学习算法的 FSR(%)

Table 5-5 FSR (%) for Federated Learning Algorithms on Fashion-MNIST

数据集	μ	m	FL-CSBC ²	FL-CSBAC	AFedSV+
Fashion-MNIST	0.1	0.2	0	0	5.2
		0.5	0	8.1	11.2
		0.7	0	3.3	21.9
		0.9	0	0	45.2
	0.5	0.2	0	1.6	5.4
		0.5	0	0	13.6
		0.7	0	1.7	20.2
		0.9	0	0	40.3

由图5-8b可以进一步解释图5-4b中 FL-CSBAC 产生剧烈波动的原因。从图5-8b中可以看出 FL-CSBAC 的 FSR 在整个联邦学习过程中都极其不稳定，这意味着会频繁选择恶意客户端加入到聚合集合，导致 TACC 产生剧烈波动。图5-8a中 FL-CSBAC 的

FSR 虽然也产生了波动,但其波动幅度和波动频率都远不及图5-8b,所以并没有产生毁灭性的影响。图5-9a中 FL-CSBAC 的 FSR 虽然在波动幅度和波动频率上都与图5-8b相似,但对应图5-5a中 FL-CSBAC 的 TACC 却并没有特别大的波动。通过进一步的分析可以发现,虽然二者 FSR 的趋势相似,但在恶意客户端占比为 20% 的场景中,选择的客户端数量要更多,这意味着其中的良性客户端数量会更多,多样性也随之增加。而良性客户端的多样性会进一步保证训练过程的稳定,也就造成了二者 TACC 的差异。通过表 5-5可以进一步看出,在 Fashion-MNIST 分类任务中,FL-CSBC² 的 FSR 优于 FL-CSBAC, AFedSV+ 的 FSR 最差,FL-CSBAC 在 $\mu = 0.5$ 时的 FSR 整体上低于 IID 场景。




图 5-9 $\mu = 0.5$, m 取不同值时 Fashion-MNIST 分类任务下不同联邦学习算法的 FSR

Figure 5-9 FSR of Federated Learning Algorithms on Fashion-MNIST with $\mu = 0.5$ and Varying m

综上所述,FL-CSBAC 的 FSR 在 CIFAR-10 等复杂数据集分类任务中优于 FL-CSBC² 和 AFedSV+,而在 Fashion-MNIST 等简单数据集分类任务中 FL-CSBAC 的 FSR 可能会产生较大波动,略逊于 FL-CSBC²,但优于 AFedSV+。

5.4.2.3 平均聚类数量分析

表 5-6 展示了在 Fashion-MNIST 分类任务下, FL-CSBAC 在不同数据分布和不同恶意客户端比例下平均每轮聚类的数量。详细分析如下:

(1) 非独立同分布程度 μ 的影响:

当恶意客户端占比较低时 Non-IID 场景 ($\mu = 0.5$) 下的平均聚类数量略高于 IID 场景 ($\mu = 0.1$)。但随着 m 增大, μ 的影响力先增大后减弱, $m = 0.7$ 附近时 μ 的影响力达到峰值。当 $m = 0.9$ 时, Non-IID 场景与 IID 场景下的聚类数量几乎相同。

(2) 恶意客户端占比 m 的影响:

随着 m 的增大, 聚类数量显著上升。当 $\mu = 0.1$ 时, 随着恶意客户端占比从 0% 增至 90%, 平均聚类数量从 10.43 增至 81.91; 当 $\mu = 0.5$ 时, 随着恶意客户端占比从 0% 增至 90%, 平均聚类数量从 11.09 增至 81.50。

由以上分析可知, 非独立同分布和恶意客户端均会导致 FL-CSBAC 聚类数量增加。其原因在于非独立同分布和恶意客户端都会增加数据分布的复杂性, 导致客户端模型之间距离增大, 变得更加分散, 要想更加合理地划分各客户端集群, 就需要更多的聚类。

表 5-6 Fashion-MNIST 分类任务下 FL-CSBAC 平均每轮的聚类数量

Table 5-6 Average Number of Clusters per Round for FL-CSBAC on Fashion-MNIST Classification Task

数据集	μ	m					
		0	0.2	0.3	0.5	0.7	0.9
Fashion-MNIST	0.1	10.43	20.74	25.53	38.18	49.05	81.91
	0.5	11.09	26.57	39.41	50.05	56.36	81.50

5.4.2.4 算法时间复杂度分析

假设每个客户端的本地训练时间是 T_{local} , 客户端数量为 N , 本地训练迭代次数为 E , 验证集样本数为 M , 模型训练单次向前或反向传播的复杂度为 $O(H)$, 其中 H 为模型参数量, 接下来本节将计算并分析 FL-CSBC² 和 FL-CSBAC 每一轮训练的时间复杂度。

(1) FL-CSBC² 算法时间复杂度:

客户端接收到全局模型后, 各客户端同时进行本地训练, 本地训练的时间复杂度 $T_{local} = O(E \cdot H)$, 服务器接收到客户端上传的本地更新后计算每一个模型的贡献度, 计算单个客户端贡献度的时间复杂度 $T_i = O(M \cdot H)$, 计算所有客户端贡献度的时间复杂度 $T_c = O(N \cdot M \cdot H)$, 归一化并与可信度加权计算的时间复杂度 $T_g = O(N)$, 所有客户端按照贡献度高低进行排序, 选择贡献度最高的加入聚合集合, 排序的时间复杂

度 $T_{sort} = O(N \log N)$ ，重复以上步骤，直至达到规定的阈值条件，由于最高的选择次数为客户端数量，所以该轮次客户端选择过程所需时间复杂度

$$T_{select} = O(N \cdot (T_c + T_g + T_{sort})) \quad (5-13)$$

$$= O(N \cdot (O(N \cdot M \cdot H) + O(N) + O(N \log N))) \quad (5-14)$$

$$= O(N^2 \cdot M \cdot H + N^2 + N^2 \log N) \quad (5-15)$$

FL-CSBC² 算法每一轮训练的时间复杂度

$$T_{\text{FL-CSBC}^2} = T_{local} + T_{select} \quad (5-16)$$

$$= O(E \cdot H + N^2 \cdot M \cdot H + N^2 + N^2 \log N) \quad (5-17)$$

由于 E 是固定的常数，且通常较小，所以 $O(E \cdot H)$ 可以忽略。由于 M 和 H 的数量级都很大，相比于 $O(N^2 \cdot M \cdot H)$ ， $O(N^2)$ 和 $O(N^2 \log N)$ 的影响较小，也可以忽略。故主导项为 $O(N^2 \cdot M \cdot H)$ ，即

$$T_{\text{FL-CSBC}^2} \approx O(N^2 \cdot M \cdot H) \quad (5-18)$$

(2) FL-CSBAC 算法时间复杂度：

本地训练的时间复杂度与 FL-CSBC² 相同，即 $T_{local} = O(E \cdot H)$ 。在 AP 聚类过程中，计算相似度矩阵的时间复杂度 $T_{sim} = O(N^2 \cdot H)$ ，迭代更新过程中亲和传播的复杂度 $T_{iter} = O(N^2 \cdot K)$ ，其中 K 为迭代次数，通常情况下 $K \propto N$ ，所以 AP 聚类过程的时间复杂度

$$T_{AP} = T_{sim} + T_{iter} \quad (5-19)$$

$$= O(N^2 \cdot H + N^3) \quad (5-20)$$

假设 AP 聚类得到 L 个聚类中心， L 通常比 N 小得多，计算这 L 个聚类中心的贡献度 $T_c = O(L \cdot M \cdot H)$ ，归一化贡献度的时间复杂度 $T_g = O(L)$ ，把聚类中心的贡献度作为该聚类的贡献度。按照贡献度高低进行排序，选择贡献度最高的聚类加入聚合集合，排序的时间复杂度 $T_{sort} = O(L \log L)$ ，重复以上步骤，直至达到规定的阈值条件，由于最高的选择次数为聚类数量，所以该轮次客户端选择过程所需时间复杂度

$$T_{select} = O(L \cdot (T_c + T_g + T_{sort})) \quad (5-21)$$

$$= O(L \cdot (O(L \cdot M \cdot H) + O(L) + O(L \log L))) \quad (5-22)$$

$$= O(L^2 \cdot M \cdot H + L^2 + L^2 \log L) \quad (5-23)$$

FL-CSBAC 算法每一轮训练的时间复杂度

$$T_{\text{FL-CSBAC}} = T_{local} + T_{AP} + T_{select} \quad (5-24)$$

$$= O(E \cdot H + N^2 \cdot H + N^3 + L^2 \cdot M \cdot H + L^2 + L^2 \log L) \quad (5-25)$$

由于 $L \ll N$ ，所以相对于 $O(N^3)$ 来说， $O(L^2 \cdot M \cdot H)$ 、 $O(L^2)$ 和 $O(L^2 \log L)$ 均不是主导项。对于 $O(N^2 \cdot H)$ 和 $O(N^3)$ 则需要分情况讨论：

①当 $N < H$ 时， $O(N^2 \cdot H)$ 是主导项，此时

$$T_{\text{FL-CSBAC}} \approx O(N^2 \cdot H) \quad (5-26)$$

②当 $N > H$ 时， $O(N^3)$ 是主导项，此时

$$T_{\text{FL-CSBAC}} \approx O(N^3) \quad (5-27)$$

(3) 时间复杂度的比较：

分情况讨论 $T_{\text{FL-CSBAC}}$ 和 $T_{\text{FL-CSBC}^2}$ 的大小：

①当 $N < H$ 时， $O(N^2 \cdot H) < O(N^2 \cdot M \cdot H)$ ，此时 $T_{\text{FL-CSBAC}} < T_{\text{FL-CSBC}^2}$ ；

②当 $H < N < M \cdot H$ 时， $O(N^3) < O(N^2 \cdot M \cdot H)$ ，此时 $T_{\text{FL-CSBAC}} < T_{\text{FL-CSBC}^2}$ ；

③当 $N > M \cdot H$ 时， $O(N^3) > O(N^2 \cdot M \cdot H)$ ，此时 $T_{\text{FL-CSBAC}} > T_{\text{FL-CSBC}^2}$ 。

综上所述，当 $N < M \cdot H$ 时， $T_{\text{FL-CSBAC}} < T_{\text{FL-CSBC}^2}$ ，当 $N > M \cdot H$ 时， $T_{\text{FL-CSBAC}} > T_{\text{FL-CSBC}^2}$ 。

根据参与联邦学习训练任务客户端数量的多少，联邦学习可以分为小规模联邦学习、大规模联邦学习和超大规模联邦学习，由(Kairouz et al. 2021) 和(Bonawitz et al. 2019) 可知，小规模联邦学习一般为跨机构合作，客户端个数一般在 2-100 之间；大规模联邦学习一般为跨设备合作，客户端个数一般在 $10^3 - 10^8$ 之间；超大规模联邦学习一般为全球部署，客户端个数一般超过 10^8 。验证数据集大小一般大于 1000，具体数量要根据实际任务来确定。模型参数量一般大于 10^6 ，如 CNN 等轻量级模型大约为 10^6 。因此验证数据集规模与模型参数数量的乘积 $M \cdot H$ 大小一般大于 10^9 。进而可以推出小规模和大规模联邦学习任务的客户端数量 N 一般小于 $M \cdot H$ ，超大规模联邦学习任务的客户端数量 N 一般大于 $M \cdot H$ 。

所以从时间复杂度的角度分析，FL-CSBC² 在 $N > M \cdot H$ 时表现更优，适用于超大规模联邦学习任务。相比之下，FL-CSBAC 在 $N < M \cdot H$ 时更具优势，适用于小规模和大规模联邦学习任务。而在现实中，超大规模的联邦学习任务数量较少，所以 FL-CSBAC 的应用更加广泛。

5.5 本章小结

本章设计了一种基于 AP 聚类 and 贡献度的鲁棒联邦学习方法，其核心是 FL-CSBAC 算法，可用于解决联邦学习中的非独立同分布问题和恶意中毒攻击问题。本章先对 AP 聚类的效果进行可视化，然后详细描述了 FL-CSBAC 中的 AP 聚类策略、贡献度更新策略和客户端选择策略。接着本章在 Fashion-MNIST 和 CIFAR-10 数据集上对 FL-CSBAC

进行了广泛的实验与评估, 并与 FL-CSBC² 和 AFedSV+ 进行了充分的对比。相比于 FL-CSBC², FL-CSBAC 的稳定性较差, 但在高度非独立同分布和高恶意客户端占比的场景下能够发挥更好的性能, 在小规模和大规模的联邦学习任务中具有较低的时间复杂度。

第六章 总结与展望

6.1 总结

联邦学习是一种分布式机器学习框架，它允许多个客户端在不共享本地数据的情况下协作训练全局模型。其核心思想是通过本地数据训练模型，仅将模型更新上传至中心服务器进行聚合。联邦学习不仅可以解决机器学习领域“数据孤岛”的问题，而且还保护了客户的数据隐私，减少了系统通信开销。然而由于联邦学习的客户端之间存在相当大的差异，客户端数据集非独立同分布现象普遍存在，这在一定程度上会影响全局模型的性能。除此之外，联邦学习系统的开放性也使其容易遭受各种恶意攻击，严重影响全局模型的训练过程。在现实场景中，非独立同分布与恶意攻击往往同时存在，这大大增加了全局模型训练的难度。

因此，为了应对联邦学习中的非独立同分布和恶意中毒攻击问题，本文进行了一系列的研究。本文先深入分析了非独立同分布和恶意中毒攻击阻碍模型训练的原因，然后提出了两种非独立同分布场景下的鲁棒联邦学习方法，最后通过仿真实验验证了本文所提算法的有效性。本文的创新性成果可概括如下：

(1) 本研究基于 CIFAR-10 和 Fashion-MNIST 数据集构建了 Non-IID 实验环境，通过设计非独立同分布数据划分策略并验证其有效性，系统模拟了现实场景中的联邦学习环境。以 FedAvg 为基准模型的实验结果表明，Non-IID 数据特性导致模型准确率下降 3%，而恶意中毒攻击进一步使准确率恶化 28%。理论分析揭示了 Non-IID 会加剧模型参数偏移，恶意攻击则放大模型发散效应，二者的协同作用显著降低联邦学习效能。通过从实验现象到理论原理的深入分析，本研究不仅验证了 Non-IID 场景下研究鲁棒联邦学习方法的必要性，更首次系统解析了 Non-IID 与恶意攻击的相互作用机制，为后续开发能同时应对数据异构性和安全威胁的联邦学习算法奠定了坚实的理论和实验基础。

(2) 设计了一种基于贡献度和可信度的鲁棒联邦学习方法 FL-CSBC²，以应对联邦学习场景中的非独立同分布问题和恶意中毒攻击问题。该方法首先在服务器端用根数据集维护一个服务器端模型，该模型与客户端模型同步训练，并加入最初的聚合集合。随后在每一轮选择客户端加入聚合集合时计算各客户端的贡献度与可信度，根据贡献度与可信度计算客户端评分，并以此作为选择客户端的依据。在每一次选择客户端加入聚合集合之后，更新客户端贡献度，继续选择过程，直到达到阈值。最后，将聚合集合中的客户端模型进行加权计算，得到本轮的全局模型。该过程不断重复，直到

全局模型收敛。本文探究了不同阈值对模型准确率的影响，并在准确率和误选率方面与基准算法进行对比。经过在两个数据集上的广泛实验，该方法在各种数据分布和恶意客户端占比场景中都具有较强的鲁棒性，适用于非独立同分布和恶意攻击的复合场景，适合处理超大规模联邦学习任务。

(3) 设计了一种基于 AP 聚类 and 贡献度的鲁棒联邦学习方法 FL-CSBAC，以降低算法的时间复杂度。该方法同样在服务器端维护一个服务器端模型。与第四章方法不同的是，该方法首先对所有的客户端模型进行 AP 聚类，把客户端划分为不同的集群，同时获得这些集群的聚类中心。然后在服务器端计算各个聚类中心相对于聚合集合的贡献度，将该贡献度作为选择客户端集群的依据。在每一次选择客户端集群加入聚合集合之后，更新客户端集群的贡献度，继续选择过程，直到所选客户端集群的贡献度为负，本轮客户端选择过程结束。本文在测试准确率、误选率、算法时间复杂度方面对该方法和其他基准算法进行了广泛的对比实验与结果分析。实验结果证明，该方法在高度非独立同分布和高恶意客户端占比的场景下能够发挥更好的性能，适合处理小规模和大规模联邦学习任务。

6.2 展望

随着人工智能技术的不断发展以及人们对数据隐私的日趋重视，联邦学习在未来各领域都有着极大发展空间与潜力。本文对非独立同分布场景下的鲁棒联邦学习进行了深入研究，并取得了一定的研究成果，但有许多问题值得进一步的研究与完善：

(1) 在常见的小规模和大规模联邦学习任务中，FL-CSBC² 算法训练出的模型的准确度和稳定性都较高，但时间复杂度也较高；而 FL-CSBAC 算法虽然在此类任务中具有较低的时间复杂度，但在独立同分布场景和低恶意客户端占比的场景中稳定性较差。所以未来研究可以探索和优化算法逻辑，在降低算法的时间复杂度的同时提高全局模型的性能，以更好地解决各场景下联邦学习中的非独立同分布问题和恶意攻击问题。

(2) 本文仅考虑了联邦学习系统中的非独立同分布问题和恶意攻击问题，但联邦学习面临的威胁远不止于此。联邦学习还易遭受窃听攻击、模型推理攻击等隐私威胁，严重阻碍了联邦学习落地应用。所以，未来可以继续探索更加安全的联邦学习框架，或将防御性能更好的加密算法应用于联邦学习系统中，为客户隐私提供更安全的保障。

(3) 本文所提的两种联邦学习方法考虑了非独立同分布和恶意中毒攻击，但没有考虑客户端设备的计算能力和能耗、信道质量以及通信资源问题，而在实际部署当中，这些问题都需要考虑在内。所以，未来可以从信道质量、通信资源分配和设备性能等角度出发，在选择客户端模型时加入更多维度的考量，从而做出更合理的决策。

参考文献

- 高莹, 陈晓峰, 张一余, 王玮, 邓煌昊, 段培, 陈培炫. 2023. 联邦学习系统攻击与防御技术研究综述[J]. 计算机学报, 46(9): 1781~1805.
- 瞿祥谋. 2022. 基于生成对抗网络的联邦学习非独立同分布数据问题研究[D]. [硕士学位论文]. 重庆大学.
- 杨强, 刘洋, 程勇, 康焱, 陈天健, 于涵. 2020. 联邦学习[M]. 电子工业出版社.
- Aono Y, Hayashi T, Wang L, Moriai S, et al. 2017. Privacy-preserving deep learning via additively homomorphic encryption[J]. IEEE transactions on information forensics and security, 13(5): 1333–1345.
- Bagdasaryan E, Veit A, Hua Y, Estrin D, Shmatikov V. 2020. How to backdoor federated learning[C]. In: International conference on artificial intelligence and statistics: 2938–2948.
- Bernstein J, Zhao J, Azizzadenesheli K, Anandkumar A. 2019. signSGD with Majority Vote is Communication Efficient and Fault Tolerant[C]. In: 7th International Conference on Learning Representations.
- Bhagoji A N, Chakraborty S, Mittal P, Calo S. 2019. Analyzing federated learning through an adversarial lens[C]. In: International conference on machine learning: 634–643.
- Blanchard P, El Mhamdi E M, Guerraoui R, Stainer J. 2017. Machine learning with adversaries: Byzantine tolerant gradient descent[J]. Advances in neural information processing systems, 30.
- Bonawitz K, Eichner H, Grieskamp W, Huba D, Ingerman A, Ivanov V, Kiddon C, Konečný J, Mazzocchi S, McMahan B, et al. 2019. Towards federated learning at scale: System design[J]. Proceedings of machine learning and systems, 1: 374–388.
- Bonawitz K, Ivanov V, Kreuter B, Marcedone A, McMahan H B, Patel S, Ramage D, Segal A, Seth K. 2017. Practical secure aggregation for privacy-preserving machine learning[C]. In: proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security: 1175–1191.
- Caldas S, Duddu S M K, Wu P, Li T, Konečný J, McMahan H B, Smith V, Talwalkar A. 2018. Leaf: A benchmark for federated settings[J]. arXiv preprint arXiv:1812.01097,
- Cao X, Fang M, Liu J, Gong N Z. 2021. FLTrust: Byzantine-robust Federated Learning via Trust Bootstrapping[C]. In: 28th Annual Network and Distributed System Security Symposium. The Internet Society.
- Cao X, Zhang Z, Jia J, Gong N Z. 2022. Flcert: Provably secure federated learning against poisoning attacks [J]. IEEE Transactions on Information Forensics and Security, 17: 3691–3705.
- Chakrabarti D, Kumar R, Tomkins A. 2006. Evolutionary Clustering[J]. ACM,
- Chen Q, Chen B, Hu F, Zhang J. 2022. Edge-based protection against malicious poisoning for distributed federated learning[C]. In: 2022 IEEE 25th international conference on computer supported cooperative work in design (CSCWD): 459–464.
- Duan M, Liu D, Chen X, Tan Y, Ren J, Qiao L, Liang L. 2019. Astraea: Self-balancing federated learn-

- ing for improving classification accuracy of mobile deep learning applications[C]. In: 2019 IEEE 37th international conference on computer design (ICCD): 246–254.
- Fang M, Cao X, Jia J, Gong N. 2020. Local model poisoning attacks to Byzantine-Robust federated learning [C]. In: 29th USENIX security symposium (USENIX Security 20): 1605–1622.
- Fraboni Y, Vidal R, Lorenzi M. 2021. Free-rider attacks on model aggregation in federated learning[C]. In: International Conference on Artificial Intelligence and Statistics: 1846–1854.
- Frey B J, Dueck D. 2007. Clustering by passing messages between data points[J]. science, 315(5814): 972–976.
- Fung C, Yoon C J, Beschastnikh I. 2020. The limitations of federated learning in sybil settings[C]. In: 23rd International Symposium on Research in Attacks, Intrusions and Defenses (RAID 2020): 301–316.
- Gollapudi S, Kollias K, Panigrahi D, Pliatsika V. 2017. Profit sharing and efficiency in utility games[C]. In: 25th Annual European Symposium on Algorithms (ESA 2017): 43–1.
- Goodfellow I, Pouget-Abadie J, Mirza M, Xu B, Warde-Farley D, Ozair S, Courville A, Bengio Y. 2014. Generative adversarial nets[J]. Advances in neural information processing systems, 27.
- Guerraoui R, Rouault S, et al. 2018. The hidden vulnerability of distributed learning in byzantium[C]. In: International conference on machine learning: 3521–3530.
- Hitaj B, Ateniese G, Perez-Cruz F. 2017. Deep models under the GAN: information leakage from collaborative deep learning[C]. In: Proceedings of the 2017 ACM SIGSAC conference on computer and communications security: 603–618.
- Hsu T M H, Qi H, Brown M. 2019. Measuring the effects of non-identical data distribution for federated visual classification[J]. arXiv preprint arXiv:1909.06335,
- Jagielski M, Carlini N, Berthelot D, Kurakin A, Papernot N. 2020. High accuracy and high fidelity extraction of neural networks[C]. In: 29th USENIX security symposium (USENIX Security 20): 1345–1362.
- Jeong E, Oh S, Kim H, Park J, Bennis M, Kim S L. 2018. Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data[J]. arXiv preprint arXiv:1811.11479,
- John R. 2002. Douceur[C]. In: The Sybil attack. Revised Papers from the First International Workshop on Peer-to-Peer Systems: 251–260.
- Kairouz P, McMahan H B, Avent B, Bellet A, Bennis M, Bhagoji A N, Bonawitz K, Charles Z, Cormode G, Cummings R, et al. 2021. Advances and open problems in federated learning[J]. Foundations and trends® in machine learning, 14(1–2): 1–210.
- Kingma D P, Welling M. 2014. Auto-Encoding Variational Bayes[C]. In: 2nd International Conference on Learning Representations.
- Konečný J, McMahan H B, Ramage D, Richtárik P. 2016. Federated optimization: Distributed machine learning for on-device intelligence[J]. arXiv preprint arXiv:1610.02527,
- Lee J, Sun J, Wang F, Wang S, Jun C H, Jiang X, et al. 2018. Privacy-preserving patient similarity learning

- in a federated environment: development and analysis[J]. JMIR medical informatics, 6(2): e7744.
- Li Q, Diao Y, Chen Q, He B. 2022. Federated learning on non-iid data silos: An experimental study[C]. In: 2022 IEEE 38th international conference on data engineering (ICDE): 965–978.
- Li T, Sahu A K, Zaheer M, Sanjabi M, Talwalkar A, Smith V. 2020. Federated optimization in heterogeneous networks[J]. Proceedings of Machine learning and systems, 2: 429–450.
- Liu Y, Zhang X, Wang L. 2020. Asymmetrical vertical federated learning[J]. arXiv preprint arXiv:2004.07427,
- Liu Y, Peng J, Kang J, Iliyasu A M, Niyato D, Abd El-Latif A A. 2020. A secure federated learning framework for 5G networks[J]. IEEE Wireless Communications, 27(4): 24–31.
- McMahan B, Moore E, Ramage D, Hampson S, y Arcas B A. 2017. Communication-efficient learning of deep networks from decentralized data[C]. In: Artificial intelligence and statistics: 1273–1282.
- Nasr M, Shokri R, Houmansadr A. 2019. Comprehensive privacy analysis of deep learning: Passive and active white-box inference attacks against centralized and federated learning[C]. In: 2019 IEEE symposium on security and privacy (SP): 739–753.
- Panda S K, Jana P K. 2015. Efficient task scheduling algorithms for heterogeneous multi-cloud environment [J]. The Journal of Supercomputing, 71: 1505–1533.
- Pillutla K, Kakade S M, Harchaoui Z. 2022. Robust aggregation for federated learning[J]. IEEE Transactions on Signal Processing, 70: 1142–1154.
- Sattler F, Wiedemann S, Müller K R, Samek W. 2019. Robust and communication-efficient federated learning from non-iid data[J]. IEEE transactions on neural networks and learning systems, 31(9): 3400–3413.
- Shokri R, Stronati M, Song C, Shmatikov V. 2017. Membership Inference Attacks against Machine Learning Models[J]. IEEE,
- Song Z, Sun H, Yang H H, Wang X, Quek T Q S. 2021. Reputation-based Federated Learning for Secure Wireless Networks[J]. IEEE Internet of Things Journal, PP(99): 1–1.
- Sun Q, Li X, Zhang J, Xiong L, Liu W, Liu J, Qin Z, Ren K. 2023. Shapleyfl: Robust federated learning based on shapley value[C]. In: Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining: 2096–2108.
- Sutskever I, Martens J, Dahl G, Hinton G. 2013. On the importance of initialization and momentum in deep learning[C]. In: International conference on machine learning: 1139–1147.
- Tramèr F, Zhang F, Juels A, Reiter M K, Ristenpart T. 2016. Stealing machine learning models via prediction APIs[C]. In: 25th USENIX security symposium (USENIX Security 16): 601–618.
- Wan W, Lu J, Hu S, Zhang L Y, Pei X. 2021. Shielding federated learning: A new attack approach and its defense[C]. In: 2021 IEEE wireless communications and networking conference (wcnc): 1–7.
- Wang H, Xu H, Li Y, Xu Y, Li R, Zhang T. 2023. Fedcda: Federated learning with cross-rounds divergence-aware aggregation[C]. In: The Twelfth International Conference on Learning Representations.
- Wang H, Sreenivasan K, Rajput S, Vishwakarma H, Agarwal S, Sohn J y, Lee K, Papailiopoulos D. 2020.

- Attack of the tails: Yes, you really can backdoor federated learning[J]. *Advances in neural information processing systems*, 33: 16070–16084.
- Wang J, Liu Q, Liang H, Joshi G, Poor H V. 2020. Tackling the objective inconsistency problem in heterogeneous federated optimization[J]. *Advances in neural information processing systems*, 33: 7611–7623.
- Wen H, Wu Y, Yang C, Duan H, Yu S. 2020. A unified federated learning framework for wireless communications: Towards privacy, efficiency, and security[C]. In: *IEEE INFOCOM 2020-IEEE conference on computer communications workshops (INFOCOM WKSHPS)*: 653–658.
- Wu W, Jiang J, Hu C. 2025. Aegis: Post-Training Attribute Unlearning in Federated Recommender Systems against Attribute Inference Attacks[C]. In: *Proceedings of the ACM on Web Conference 2025*: 3783–3793.
- Xie C, Huang K, Chen P Y, Li B. 2019. Dba: Distributed backdoor attacks against federated learning[C]. In: *International conference on learning representations*.
- Yin D, Chen Y, Kannan R, Bartlett P. 2018. Byzantine-robust distributed learning: Towards optimal statistical rates[C]. In: *International conference on machine learning*: 5650–5659.
- Yoshida N, Nishio T, Morikura M, Yamamoto K, Yonetani R. 2020. Hybrid-FL for wireless networks: Cooperative learning mechanism using non-IID data[C]. In: *ICC 2020-2020 IEEE International Conference On Communications (ICC)*: 1–7.
- Yurochkin M, Agarwal M, Ghosh S, Greenewald K, Hoang N, Khazaeni Y. 2019. Bayesian nonparametric federated learning of neural networks[C]. In: *International conference on machine learning*: 7252–7261.
- Zhao Z, Feng C, Hong W, Jiang J, Jia C, Quek T Q, Peng M. 2021. Federated learning with non-IID data in wireless networks[J]. *IEEE Transactions on Wireless communications*, 21(3): 1927–1942.
- Zhu L, Liu Z, Han S. 2019. Deep leakage from gradients[J]. *Advances in neural information processing systems*, 32.