

学校代码: 10255

学 号: 2222730

中图分类法:



专业学位硕士学位论文

非独立同分布场景下联邦学习优化方案研究

学 位 申 请 人: 朱小龙

指 导 教 师: 石秀金教授

一 级 学 科: 电子信息

研 究 方 向: 联邦学习

所 在 学 院: 计算机科学与技术学院

提 交 日 期: 2025 年 4 月

University Code: 10255

Student ID:

CLC Index:



PROFESSIONAL MASTER DISSERTATION

Research on Federated Learning Optimization Schemes in Non-IID Scenarios

Candidate: Xiaolong Zhu
Supervisor: Prof. Xiujin Shi
Major: Electronic Information
Research Direction: Federated Learning
Affiliation: College of Computer Science and Technology
Date of Submit: Apr, 2025

硕士学位论文答辩委员会名单

姓名	职称	单位	备注
			主席
			委员
			秘书

答 辩 人：

答辩地点：

答辩日期：

非独立同分布场景下联邦学习优化方案研究

摘 要

联邦学习作为一种分布式机器学习框架，近年来在数据隐私保护和跨设备协同建模方面显示出巨大的应用前景。但是联邦学习在非独立同分布场景下，可能会导致客户端漂移的现象，进而导致模型收敛变慢，模型性能下降等问题。为了应对客户端偏差带来的后果，一些学者通过在本地图训中引入正则化损失解决。例如，通过引入漂移变量，并采用 L2 正则化来对与漂移变量相关的近端项进行约束，以期缩小本地模型与全局模型之间的差距。但单一正则化往往不足以完全消除因数据分布差异引起的漂移问题。以此为切入点，本文在此模型基础上提出了三项改进方案：

(1) 针对仅采用 L2 正则化对漂移变量相关近端项进行约束而难以实现自动特征选择、进而影响模型对关键信息识别与利用的问题，本文提出了一种基于混合正则化的改进方法以优化联邦学习中的本地训练过程。这种混合正则化策略能够更好地适应不同客户端数据分布的差异性，从而提升模型对重要特征的自动识别能力。在 CIFAR100 与 CIFAR10 数据集上的所有数据分布场景中，所提出的模型均取得了更高的准确度以及通信效率。

(2) 针对上述模型在聚合阶段依然沿用了传统的联邦平均策略，未能充分考虑每个客户端的个性化特征，限制了个性化联邦学习的表现这一问题，在聚合过程中引入了余弦相似度，为每个客户端分配不同的重要性权重，更准确地反映其对全局模型优化的实际贡献。在相同数据集场景下加入余弦相似度，结果表明模型在准确度和通信效率上都有了提升。

(3) 为使各客户端在训练过程中获得更具区分性的特征嵌入，并提升全局模型在数据异构环境下的模型性能，提出了一种基于度量学习的本地训练优化方法。该方法在客户端本地训练时引入度量学习损失，以增强模型的泛化能力和特征表达质量。在 (1) 和 (2) 基础上引入度量学习，对比实验结果表明，在联邦学习

中引入度量学习损失显著提升了模型的整体性能。

关键词：联邦学习；非独立同分布；混合正则化；余弦相似度；度量学习

Research on Federated Learning Optimization Schemes in Non-IID Scenarios

ABSTRACT

Federated learning, as a distributed machine learning framework, has shown great application prospects in data privacy protection and cross-device collaborative modeling in recent years. However, federated learning may lead to the phenomenon of client-side drift in non-independent and co-distributed scenarios, which in turn leads to problems such as slower model convergence and degradation of model performance. In order to cope with the consequences of client-side bias, some scholars solve it by introducing regularization loss in local training. For example, by introducing a drift variable and using L2 regularization to constrain the proximal term associated with the drift variable, with a view to narrowing the gap between the local model and the global model. However, a single regularization is often insufficient to completely eliminate the drift problem caused by the difference in data distribution. Taking this as an entry point, this paper proposes three improvement schemes based on this model:

(1) This paper proposes a mixed regularization strategy to address the issue that solely using L2 regularization to constrain the proximal term associated with the drift variable makes automatic feature selection difficult, thereby affecting the model's ability to identify and utilize key information. This approach better adapts to the differences in data distributions among clients, enhancing the model's ability to automatically recognize important features. Experimental results on all data distribution scenarios of the CIFAR100 and CIFAR10 datasets demonstrate that the proposed model achieves higher accuracy and improved communication efficiency.

(2) This paper proposes incorporating cosine similarity during the aggregation phase to resolve the issue that the existing model still relies on the traditional federated averaging strategy, which fails to fully consider the personalized characteristics of each client and thus limits the performance of personalized federated learning. This method assigns different importance weights to each client, more accurately reflecting their actual contributions to the global model's optimization. Adding cosine similarity to the same dataset scenario, the results show that the model improves in accuracy and communication efficiency.

(3) This paper proposes a local training optimization method based on metric learning to enable each client to obtain more discriminative feature embeddings during training and to enhance the global model's robustness in heterogeneous data environments. This method introduces a metric learning loss during local training to improve the model's generalization capability and feature representation quality. With metric learning added on the basis of the

improvements in (1) and (2). Comparative experimental results demonstrate that introducing a metric learning loss in federated learning significantly enhances the overall performance of the model.

Supervised by:

KEY WORDS: Federated Learning; Non-IID; Mixed Regularization; Cosine
Similarity; Metric Learning

目 录

1. 绪论.....	1
1.1 研究背景与意义.....	1
1.2 研究现状.....	3
1.2.1 联邦学习研究现状.....	3
1.2.2 客户端漂移现象.....	6
1.2.3 客户端漂移研究.....	8
1.2.4 当前研究工作总结.....	9
1.3 研究内容.....	10
1.4 组织结构.....	11
2. 相关技术介绍	13
2.1 联邦学习.....	13
2.1.1 联邦学习概念.....	13
2.1.2 非独立同分布场景.....	14
2.1.3 客户端漂移.....	15
2.2 正则化方法.....	16
2.3 余弦相似度.....	17
2.4 度量学习.....	18
2.5 数据集介绍.....	19
2.6 本章小结.....	20
3. 基于混合正则化优化联邦学习本地训练	21
3.1 Fed DC	21
3.2 混合正则化改进.....	22
3.3 算法流程.....	23
3.3.1 本地模型更新.....	23
3.3.2 模型聚合阶段.....	24
3.4 实验结果及分析.....	25
3.4.1 实验设置.....	25
3.4.2 实验结果.....	26
3.5 本章小结.....	30
4. 基于余弦相似度优化联邦学习聚合	31
4.1 余弦相似度介绍.....	31
4.2 利用余弦相似度优化联邦学习聚合过程	32
4.2.1 合理性分析.....	32
4.2.2 优化方案.....	33

4.3 实验结果与分析.....	34
4.3.1 实验设置.....	35
4.3.2 实验结果.....	35
4.4 本章小结.....	38
5. 基于度量学习优化联邦学习本地训练	39
5.1 度量学习.....	39
5.2 基于度量学习的本地优化	41
5.2.1 模型结构与嵌入提取.....	41
5.2.2 三元组损失的构造与应用.....	41
5.2.3 客户端本地训练过程.....	42
5.3 实验结果与分析.....	42
5.3.1 实验设置.....	42
5.3.2 实验结果.....	43
5.4 本章小结.....	45
6. 结论与展望.....	47
6.1 研究结论.....	47
6.2 研究展望.....	48
参考文献.....	49

图录

图 1-1 IID 场景下正常的联邦学习	8
图 1-2 NON-IID 场景下联邦学习出现客户端漂移现象	8
图 2-1 联邦学习过程图.....	14
图 3-1 损失项构成	24
图 3-2 不同方法在 CIFAR100(NON-IID 为 0.6)的测试准确度随通信轮次变化图	28
图 3-3 不同方法在 CIFAR100 (NON-IID 为 0.3)的测试准确度随通信轮次变化图.....	28
图 3-4 不同方法在 CIFAR10(NON-IID 为 0.3)的测试准确度随通信轮次变化图	29
图 3-5 不同方法在 CIFAR10(NON-IID 为 0.6)的测试准确度随通信轮次变化图	29
图 4-1 引入余弦相似度的聚合过程	34
图 4-2 不同方法在 CIFAR100(NON-IID 为 0.3)的测试准确度随通信轮次变化图	36
图 4-3 不同方法在 CIFAR10(NON-IID 为 0.6)的测试准确度随通信轮次变化图	37
图 5-1 不同方法在 CIFAR100(IID)的测试准确度随通信轮次变化图	44
图 5-2 不同方法在 CIFAR100(NON-IID 为 0.3)的测试准确度随通信轮次变化图	45
图 5-3 不同方法在 CIFAR10(NON-IID 为 0.6)的测试准确度随通信轮次变化图	45

表录

表 3-1 不同方法在不同数据集不同数据分布下的 TOP-1 测试准确度对比.....	27
表 3-2 不同方法在不同数据集不同数据分布下到达相同准确度所需通信轮次对比对比	29
表 4-1 不同方法在不同数据集不同数据分布下的 TOP-1 测试准确度对比.....	36
表 4-2 不同方法在不同数据集不同数据分布下到达相同准确度所需通信轮次对比对比	37
表 5-1 不同方法在不同数据集不同数据分布下的 TOP-1 测试准确度对比.....	43
表 5-2 不同方法在不同数据集不同数据分布下到达相同准确度所需通信轮次对比对比	44

1. 绪论

伴随信息技术的飞速发展，人工智能（AI）和大数据分析在各个领域实现广泛的运用，数据隐私与安全相关问题日益突显，尤其是在医疗、金融、工业物联网等对数据敏感度要求较高的范畴，传统的集中式学习模式受数据泄露、存储风险的影响，面临挑战。联邦学习（Federated Learning）可在保障数据本地存储的基础上进行模型训练，以此减少数据隐私被暴露的风险，同时满足各方数据合作相关需求，在实际应用期间，联邦学习会碰到客户端数据非独立同分布（Non-IID, Non - Independent and Identically Distributed）的问题。由于不同参与方（客户端）的数据分布大概存在较大差异，直接采用常规联邦优化方法也许会让模型收敛变慢、性能下降，甚至会对全局模型泛化能力形成一定影响，论文就联邦学习于非独立同分布场景下表现欠佳的场景加以研究，并挖掘出了对应的解决办法，本章作为论文开篇首章，主要陈述论文的研究背景及意义，对 No-IID 场景下联邦学习的研究现状进行综述，又对论文的研究内容与结构做了简述。

1.1 研究背景与意义

在人工智能这个范畴，数据是基础支撑，模型训练的质量和性能极大地依赖于数据的数量、质量以及分布情形，现实世界中的数据，大多以数据孤岛（Data Silos）的形式存在，即数据分别保存在不同的机构、企业或设备里面，彼此之间不能马上直接共享，此种数据分割的现象阻碍了人工智能技术的发展，尤其是在医疗、工业物联网这类高隐私要求的领域，数据流通及共享面临众多挑战^[1]。

为应对数据孤岛困境，一种显而易见的方法是把分散的数据集中到一个服务器进行统一的处理训练，但这种集中化的数据处理方法会带来严重的隐私及安全风险，数据的集中保存和传输也许会造成数据泄露、无授权获取，甚至会因数据合规性的要求（如 GDPR、CCPA 等）而无法开展实施，处于跨行业和跨国家的数据合作情形里，法律法规的管束让数据自由流动变得更费劲，仅靠传统的集中式

数据存储与训练模式，当前对数据安全和隐私保护方面的要求已无法达成。

为了同时处理数据孤岛及数据隐私保护的问题，联邦学习（Federated Learning, FL）应需求诞生^[2]，FL 作为一种非中心化的机器学习范式，让多个数据持有方得以在不直接共享原始数据的情形下，协同练就一个高效的全局模型，由此可以充分利用分散的数据资源，又能保障用户隐私不被窥探^[3]。

FL 训练进程中，主服务器（还称作协调服务器，中央服务器（Central Server）首先对一个全局模型做初始化，并把该模型传递至所有参与的本地设备，各个本地设备拿到初始的模型后，采用本地数据开展训练操作，而不必把数据上传至中心服务器^[4]。本地训练通常采用小批量梯度下降（SGD, Stochastic Gradient Descent）等优化算法，在轮训练后逐步优化模型参数^[5]。每个设备在本地训练完成后，并不会直接上传其原始数据，而是生成模型更新（即权重调整），并通过安全通信协议（如加密传输、差分隐私等）将这些更新发送回主服务器，从而降低数据泄露的风险^[6]。

主服务器当接收到全部参与设备的模型更新后，借助某种聚合算法（如联邦平均算法 FedAvg）对模型参数进行合并，借此生成新的全局模型，在聚合流程时，服务器会考量各设备的数据量、计算能力、训练轮次等要素，从而更合理地实施加权平均，以此提高全局模型的性能与应用适配性^[7]。更新过的全局模型又一次下发到所有本地设备，替换掉旧版模型，该过程会不断做迭代操作，直至全局模型在整个联邦环境达到收敛，也就是达到预先期望的性能水平或者符合设定的终止要求^[8]。

常规的集中式处理方式得把训练数据集存到单一服务器之上，而联邦学习属于一种非集中化的机器学习方法，由一个或多个中心服务器实施协调，牵涉多个客户端，当处于联邦学习阶段，中心服务器不会直接触碰客户端的数据，进而保障数据的隐私性^[9]。FL 能让多个数据持有方在不直接共享数据的前提下，共同训练出高质量的机器学习模型，它成为数据隐私保护、跨机构协同以及边缘智能（Edge AI）等领域的核心技术^[10]。

1.2 研究现状

1.2.1 联邦学习研究现状

作为一种分布式机器学习框架的联邦学习，近些年在数据隐私保护和跨设备联合建模方面展现出极大的应用潜力，其核心要义是在不直接把数据共享的前提下，于各参与节点处开展局部模型训练，并凭借安全聚合机制实现全局模型的更新，以此实现多方数据的联合建模，下面要从下面这几个方面对联邦学习的研究现状进行总结性概述：

基础理论与算法发展：最早提出联邦学习的是 McMahan 等人，该代表性算法 FedAvg^[11]于客户端本地实施多次梯度下降更新，还会按周期把模型参数传到中心服务器做加权平均，从而切实减少了通信方面的开销，学者们针对数据分布呈现非独立同分布（Non-IID）状况的问题，推出了多种改进策略，诸如个性化模型、分层聚合以及自适应优化的方法，以应对数据异构性给全局模型收敛速度和性能造成的挑战。个性化模型方法为每个客户端设计与局部数据特点相适应的专用模型，诸如 pFedMe^[12]和 FedAMP^[13]等相关方法，不仅可对全局信息进行共享，还能在局部训练的时候进行个性化微调，以此更恰当地应对各客户端数据分布的差异现象；分层聚合策略把客户端按照数据特征、地理位置等相关因素分组，首先在组内进行模型聚合，再跨组开展整体聚合，如此便可以保留局部特性，还能提升整体模型的抗压能力；诸如 FedProx^[14]的自适应优化方法，往本地优化目标中增添正则项，规范各客户端模型跟全局模型之间的差异，由此减轻了数据异构性对模型收敛造成的负面后果，利用这些策略的实施，研究者们不仅在理论意义上为联邦学习提供了更强的适应性保障，还在实际应用场景里证实了这些方法可大幅提高模型性能与收敛速度。

隐私保护与安全性研究：隐私保护属于联邦学习的核心优势范畴，为进一步增进数据隐私及安全性，研究人员引入了多样先进技术，比如差分隐私、同态加密以及安全多方计算之类，差分隐私技术将噪声引入客户端更新的梯度或模型参数之内，使单个数据样本的影响难以进行逆向推导，从而切实防止了敏感信息外

泄；典型应用里有 Google 在移动设备上采用的差分隐私算法^[15-17]。同态加密支持在数据加密状态下开展运算，让服务器无需解密数据就能完成聚合任务，这在保证数据安全的基础上，不降低模型训练的精准度，Bonawitz^[18]等人提出的安全聚合协议与同态加密技术相结合，保证了各客户端上传的加密模型参数在聚合之际不被外界解读。安全多方计算技术使得多个参与方能够在不透露各自原始数据的情形下，共同合作算出全局模型的更新结果，因而在理论上对数据安全有较高的保障效果，为防备恶意攻击者从局部模型中恢复敏感资讯，这些技术不仅在单个客户端上实现保护作用，还依靠协议设计保证了联邦学习系统的整体安全性。针对通信流程里的数据泄露和中间人攻击相关问题，研究者们也给出了相应的安全防护办法，采用端到端加密通信协议与身份验证机制，能有效防范敏感数据在传输期间被窃取或篡改，这些隐私保护及安全技术在保证模型训练效率的时候，显著提高了联邦学习系统在实际应用场景下的安全性与可信度^[19]。

通信效率与系统优化：鉴于联邦学习涉及大量分布式设备相互的通信，怎样在保证模型精度的基础上降低通信成本成为研究焦点，不少研究工作针对通信压缩、局部更新策略以及异步通信机制开展，以减轻通信负荷并提升系统效率^[20]。针对通信进行压缩时，研究者们采用了梯度量化、稀疏化与剪枝等手段，把上传的参数信息压缩至更低的比特率，从而在一定程度上降低了网络带宽的占用^[21]；典型的例子是梯度稀疏化技术，仅传输关键梯度信息，从而有效削减上传数据量。局部更新策略同样成为降低通信频率的主要手段，联邦学习框架中常见的 FedAvg 算法，容许各客户端在本地完成多次迭代训练后再上传模型更新，这样可利用本地数据实现充分训练，又能削减每轮通信的数据传输量，这种方法同样面临局部模型出现偏差的问题，推动后续像 FedProx 这类研究在局部目标函数里添加正则项，从而平衡本地更新和全局模型间的差异。引入异步通信机制，为处理大规模分布式系统中由设备计算能力差异和网络延时所引起的同步问题提供有效举措，通过许可各客户端根据自身计算及通信条件灵活进行更新上传，不必等所有节点达成统一同步，进而提升了整个系统的响应速度与容错能力^[22]。就资源受限的边缘设备而言，研究者们不仅聚焦通信效率，还在探究能耗、延时等实际系统指标

的优化途径，在实际操作应用里，边缘设备一般采用电池来供电，计算资源有限，采用设计低功耗通信协议和轻量级的模型的方式，可以明显降低能源的耗费，同时降低通信延迟，保障实时状态和高效成果，这些策略在大规模网络环境里实现了高效模型更新，不仅在理论层面为联邦学习的算法框架增添内容，于实际部署环节中也体现出显著的有利之处^[23]。

应用场景与实证研究：联邦学习理论与算法的持续成熟，使其在实际应用实践中的效果也获广泛验证^[24]。就金融领域而言，联邦学习已应用在信用评估、欺诈检测等各类任务中，各参与方在不把原始数据拿出来共享的情况下协同训练模型，极大降低了数据泄露的几率；在医疗范畴，多家医院利用联邦学习一起联合训练诊断模型，做到了跨机构患者数据的协同分析事宜，由此提升了疾病预测的精准程度和个性化治疗方案的形成^[25]；对于物联网这个领域内，联邦学习对海量设备的数据协同处理予以支持，让智能家居、智慧城市等场景的数据整合与实时决策更高效^[26]；就智能制造领域而言，厂商借助联邦学习开展设备状态监测与故障预报，不仅实现了对生产数据的高效整合，也保障了商业机密不被泄露^[27]。大量的实证研究说明，联邦学习在保证数据隐私和安全的情形下，可以在多方数据协同学习的时候达成与集中式模型相近甚至更卓越的效果^[28]。某些研究在跨机构数据量较少或数据分布呈现较大差异时，采用联邦学习训练出的模型，可更好地抓取各参与方数据的特定特性，由此在模型泛化能力和鲁棒性方面呈现出显著优势^[29]。联邦学习为各行各业的数据共享跟合作开辟了新方法，让不同主体在不泄露敏感信息之际实现优势互补，一起促进智能化应用的拓展，这不仅为企业减少了数据整合的阻碍，也为缔造安全、高效的数据协同生态系统提供了技术后盾^[30]。

挑战与未来发展方向：尽管联邦学习在理论跟实践里均取得显著进步，但在实际应用的时候依旧面临很多挑战，怎样更科学地应对客户端数据的非独立同分布特征，一直是影响全局模型性能发挥的关键问题，由于各客户端之间的数据分布差异明显，让全局模型容易产生收敛速度慢甚至偏离最优解的现象^[31]。研究者们正积极探索个性化模型、分层聚合以及自适应优化等多种技术手段，力图在充分借助全局信息之际，更贴切地适应局部数据特性，提升通信效率是当前急待解

决的问题，联邦学习必须在大量分布式设备之间频繁传送模型参数，由于通信带宽和设备能耗受限，怎样压缩传输数据、减少通信轮次成了研究热点^[32]。就这一问题而言，学术界制订了梯度压缩、局部多步更新以及异步通信等策略，意在干扰模型精度的前提之下，降低系统通信开销与能耗，增进整体训练效率，就隐私安全的情况而言，尽管联邦学习采用不直接公开原始数据的手段来守护用户隐私，但在实际操作里，还是存在侧信道攻击、模型反演等风险^[33]。怎样在使模型训练维持高效的同时，进一步把差分隐私、同态加密和安全多方计算等技术引入，创建更可靠的安全防护体系，依旧是一个存在挑战的课题，怎样去设计有效的激励机制，激励各参与方积极贡献数据和计算资源，还是联邦学习落地应用期间不可忽视的要点。目前的研究主要留意怎样采用经济激励、信誉机制或资源共享策略，统筹各方利益，防止因数据质量参差不齐、贡献不均衡出现系统性能下降或参与方流失，伴随深度学习、分布式系统以及隐私保护技术不断发展，联邦学习或许会在算法优化、系统架构设计和跨领域应用等方面实现更突破性的进展^[34]。逐步优化的理论研究与技术实践会推动数据协同建模技术向更高水准迈进，进一步拓宽联邦学习在医疗、金融、物联网等各范畴领域的应用前景，为构建安全、高效、智能的数据共享生态系统给予坚实技术后盾^[35]。

新兴的分布式学习技术——联邦学习，已在理论算法、隐私保护、安全方面、通信效率和实际应用等多个范畴开展了深入研究，未来研究将进一步把焦点放在解决现存挑战上，加强模型性能以及系统的稳定水平，以顺应持续上扬的实际应用要求。

1.2.2 客户端漂移现象

客户端漂移（Client Drift）是指由于不同客户端（参与设备）之间的数据分布存在差异，也称客户端间的数据分布是非独立同分布（Non-IID）的关系，导致某些客户端在本地训练过程中，模型参数逐渐向其数据分布的最优方向漂移^[36]。这种现象会影响联邦学习中的全局模型训练，使得聚合后的全局模型偏离全局最优解^[37]。

在一般的联邦学习框架里，常常假设各个客户端持有的数据呈独立同分布，即各个客户端的数据分布相似或者一样，在实际的场景里，客户端的数据一般存在明显的异质性，部分客户端也许主要具备某一类别的数据，而不存在其他类别的数据，造成全局数据类别分布的失衡状态^[38]。不同客户端的数据或许呈现特征分布不均衡的状态，犹似在物联网（IoT）应用的情形里面，不同地区环境传感器采集的数据，可能受地理位置、设备差异这两方面影响，促成不同的特征分布格局，各个客户端的数据量也许会有较大差异，部分客户端的数据量比其余客户端多得多，在模型聚合时对全局模型的功劳更大，而数据规模小的客户端影响相对微弱，这有概率导致全局模型更倾向数据量大的客户端，却将数据较少的客户端特性忽略掉，因为这些数据呈现出差异性，各个客户端在开展本地训练时都会调整模型参数，让模型更贴合自身数据分布，而不是整个数据的全局分布，因而在模型更新时形成客户端偏差^[39]。

在联邦学习推进的过程当中，若存在客户端漂移现象时，借助标准的 FedAvg 做模型聚合时，会引起一系列麻烦，鉴于不同客户端之间模型更新方向不一致，全局模型的优化路径大概会出现震荡或偏斜，引起全局训练的收敛速度开始变慢。跟在 IID 数据分布状态下相比，FedAvg 可稳定收敛至全局最优(如图 1-1 所示)，处于 Non-IID 数据分布的场景里，不同客户端的模型更新方向可能完全不同。FedAvg 聚合这些更新的时候，可能引发模型在参数空间里来回抖动，难以迅速达成收敛（如图 1-2 所示）。客户端漂移可能引起模型的泛化能力降低，在联邦学习中，要达成的目标是训练适合所有客户端的全局模型，一旦客户端漂移严重的时候，全局模型大概会更倾向于部分数据分布较多的客户端，而在其余客户端上的表现欠佳，这种非均衡的训练造成了模型泛化能力下降，即其在不同客户端上的适应能力变差劲了。处于一个包含多家医院数据的联邦学习系统中，若部分医院的数据在模型训练中起主导作用，而其他一些医院的数据贡献量较小，那么训练得到的模型或许无法很好地与所有医院的数据相适配，引起预测的精确性出现下降^[40]。客户端漂移会导致模型难以达成全局最佳解，由于各客户端的模型更新方向在参数空间内彼此抵消，再或者是方向的多样性造成了全局模型的漂移，致使

FedAvg 在聚合这些更新时没办法得到一个高效的模型更新方向，最终或许会让训练失败或者模型性能下滑^[41]。




图 1-1 iid 场景下正常的联邦学习

Table 1-1 Standard Federated Learning in IID




图 1-2 non-iid 场景下联邦学习出现客户端漂移现象

Table 1-2 Client Drift Phenomenon in Federated Learning in Non-IID

1.2.3 客户端漂移研究

为应对客户端漂移引发的后果，相当多研究者进行了相关的探讨。可以去调整客户端的数据分布，使数据接近独立同质分布的样子，Jeong 等人^[42]提出 FAug 这一方法，该手段在服务器端训练生成对抗网络（GAN）的相关模型，GAN 凭借来自客户端的少量数据生成额外的数据，然后把 GAN 生成的数据传回客户端，借此增加客户端的样本数目，最终生成独立同分布数据集。Zhao^[43]等人设计了一种数据共享策略，把少量全局数据按类别均匀地分发给每个客户端，进而提升数据集的独立同分布特性，尽管基于数据的方法借助缓解客户端漂移问题增强了全局

FL 模型的收敛性，但它们一般都需要改动本地数据分布。这说不定会引起与客户端行为自身多样性相连的有价值信息流失，而这些信息对个性化全局模型有着关键意义，甚至有引发隐私泄露问题的潜在风险，比较合理的途径是在本地模型训练中实施优化，使本地模型的训练更呈现个性化，进而强化本地模型的自适应效能，模型正则化是普遍的提高机器学习训练稳定性、防止过拟合的方式，能借助正则化技术来约束本地更新的效应，进而提升全局模型的收敛稳定性与泛化能力，这反过来能助力生成更好的个性化模型。

1.2.4 当前研究工作总结

联邦学习在理论跟实践上取得了重大进展，但与此同时之际，实际应用中揭露出来的一系列问题也成了研究热点，客户端漂移（Client Drift）问题极为突出，它反映了鉴于各客户端的数据分布差异明显，引发各自本地训练期间模型参数慢慢偏向各自数据分布的最优解，进而影响全局模型更新效果及其收敛的速度。现今研究工作主要是聚焦于以下几个方面，其一涉及客户端漂移问题：在惯用的联邦学习框架之处，一般假设各个客户端的训练数据是独立同分布（IID）的，然而在真实存在的场景里，客户端的数据往往有类别分布不均匀、特征分布有区别以及数据量差异悬殊等问题^[44]。在物联网的实际应用里，不同地方的环境传感器受地理位置及设备差异影响，数据分布或许显著不一样；在不同机构的医疗数据协同工作里，不同医院大概仅留存部分疾病样本，这很容易让各客户端在本地训练时出现明显偏差，客户端漂移不仅会造成全局模型训练路径出现震荡情况，还会让收敛变得迟缓，还可能造成全局模型偏向数据量较大或者分布较单一的客户端，从而降低了模型的泛化能力^[45]。二是全局模型聚合策略碰到的挑战：鉴于各客户端更新方向的差异较为明显，使用传统的 FedAvg 聚合办法也许无法充分协调各客户端间的更新，全局模型在实施聚合的进程里，说不定会因各客户端参数在参数空间中相互抵消、来回振荡，导致难以达成全局最优解，甚至在有些极端情形里造成模型训练失利或性能大幅下降，研究者们提出了含有个性化模型、分层聚合、自适应优化等多种策略，以求在充分利用各客户端局部模型特征的同时，降低数

据异构性引发的负面效应^[46]。

1.3 研究内容

论文主要针对联邦学习模型优化问题展开研究，将提升模型泛化能力以及适应非 IID 数据分布作为主要研究目标，就传统 L2 正则化和简单加权平均在联邦学习中的欠缺而言，论文提出了一种将混合正则化和余弦相似度加权平均相结合的方法，用以优化损失函数，增强全局模型的聚合质量，以下是具体研究内容。

（1）论文就基于混合正则化的联邦学习优化方法开展研究，为把传统 L2 正则化替换，论文给出混合正则化方法，兼备 L1 和 L2 正则化的长处，能开展特征的筛选，还能防止出现过度拟合，混合正则化方法能更出色地适应不同客户端的异构数据分布，增强联邦学习模型的泛化水平，基于这一基础，论文把混合正则化用到 FedDC 框架里，这种混合正则化方法在联邦学习场景下适应表现更佳，适应各客户端数据的分布状态。

（2）论文就基于余弦相似度的加权平均方法做了研究，用以优化联邦学习中的模型聚合步骤，针对非 IID 数据状况下传统简单平均方法的诸多局限，论文在(1)改进的条件上，提出基于余弦相似度的加权聚合办法，通过测算各客户端梯度与全局梯度之间的余弦相似度，动态调整每个客户端模型在全局聚合操作中的权重系数，跟传统方法对比，该方法会根据客户端的本地训练状态自适应地重新设定贡献权重，加大重要客户端对全局模型的影响力道，以此提升全局模型的泛化水平，哪怕是在非 IID 数据分布的态势下，依旧能维持稳定性能。

（3）论文对基于度量学习的联邦学习本地优化办法进行研究，为使各客户端在训练的时候学习到区分效果好的特征嵌入，增强模型的泛化能力与特征表达水准，并且就之前（1）和（2）的改进进行了对比实验，实验结果表明，在联邦学习本地引入度量学习损失切实让模型性能显著变好。

1.4 组织结构

根据以上研究内容，论文分为六个章节，整体的组织结构如下。

第一章，绪论。本章最先说明了联邦学习在数据隐私保护以及分布式机器学习中的重要性，又分析了传统联邦学习方法在处理数据异构性、客户端漂移以及通信效率等方面的弊端，接着表明了混合正则化和余弦相似度加权聚合方法在优化全局模型训练时的潜在优点与应用意义，对本文研究目标、主要贡献及整体结构做了概述。

第二章，相关技术介绍。本章详细说明了本文所涉及的关键技术和背景知识，内容涉及到联邦学习基本原理、常用的联邦平均算法（FedAvg）以及数据异构性问题的起因；然后引入了混合正则化技术，探讨了该技术在特征选择以及预防过拟合上的好处；进而对余弦相似度及其在模型聚合中的应用加以阐释；接下来对度量学习的基本概念及其在联邦学习里的用途进行了介绍，本章对实验用到的数据集、仿真平台等做了详细说明，为后续实验验证打下基础铺垫。

第三章，基于混合正则化的联邦学习优化算法。本章从理论跟实践两个方面出发，深度探究了混合正则化在联邦学习中的运用，首先对传统 L2 正则化自身的局限性做了分析，继而拿出结合 L1 与 L2 正则化优点的混合正则化办法，用于在保有特征筛选能力的同时预防过度拟合，利用在联邦学习框架里引入混合正则化，本章说明了怎样有效减轻客户端数据异构性造成的影响，同时经实验验证了此方法在增强全局模型泛化能力与收敛速度方面的有效性。

第四章，基于余弦相似度加权聚合的模型优化方法。本章主要对非独立同分布（Non-IID）条件下的客户端漂移问题进行研究，拟定了一种基于余弦相似度的加权聚合方案，具体说明了怎样计算各个客户端梯度和全局梯度之间的余弦相似度，并根据这一结果动态调整各客户端在全局聚合中的权重，进而优化模型的更新方向，采用对比实验，证实了该方法在增强模型收敛效率和全局性能上的优势。

第五章，基于度量学习的联邦学习优化算法。本章在本地训练阶段引入了度量学习目标，以推动各客户端在训练时学习到区分效果更佳的特征嵌入，进而增

强全局模型在数据异构环境下的鲁棒性，一开始对度量学习的基本概念进行介绍，继而说明了度量学习接入联邦学习的详细步骤，后面开展对比试验，体现了该方法在前面两种改进的基础上进一步大幅改善了模型性能。

第六章，结论与展望，本章把全文的工作做了总结，归纳出基于混合正则化和余弦相似度加权聚合方法以及度量学习在联邦学习优化中的主要贡献及创新亮点，同时也说明了现有方法存在的局限，展望未来算法优化、系统架构完善以及跨领域应用等方面的研究方向，为后续工作提供了理论支撑及实践启示。

2. 相关技术介绍

伴随数据隐私与分布式学习技术在各领域的普遍应用，联邦学习正稳步成为保障数据安全、带动多方协同建模的关键技术手段，借助混合正则化和余弦相似度加权聚合的联邦学习优化方法，作为应对非独立同分布（Non-IID）数据及客户端漂移问题的关键策略，也越发受到学术界和工业界的看重，本章主要把联邦学习的基本概念介绍了一下，以及本文所使用的混合正则化、余弦相似度加权聚合和度量学习等相关技术手段，给后续章节的研究工作打下理论根基。

2.1 联邦学习

2.1.1 联邦学习概念

联邦学习是崭露头角的分布式机器学习框架，其核心要义是在各参与方不共享原始数据这个前提下，依靠在本地设备上独自训练模型，接着把模型参数和梯度上传到中心服务器进行统一聚合，以此实现多方联合建模^[47]。伴随着数据隐私保护需求的持续上涨以及各行业对大规模数据协同处理的迫切需求，金融、医疗、物联网等领域普遍关注并应用了联邦学习^[48]。

为了达成数据的安全共享与高效协同，联邦学习系统一般采用的是一种分布式架构，可查看图 2-1，该架构中，各个参与设备（例如智能手机、传感器、边缘服务器等）利用本地数据独自训练模型，继而把模型更新结果上传至中心服务器；中心服务器接收到多个参与方上传的更新后，凭借聚合算法（如联邦平均算法 FedAvg）更新全局模型，接着把全局模型分发给各客户端进行下一轮训练，该过程不会将任何原始数据泄露出去，实现了跨越设备、跨越机构的数据协同建模，切实保护了数据隐私及安全。

按照参与方数据的分布差异，联邦学习一般会分成横向联邦学习和纵向联邦学习两种模式，横向联邦学习适用于各参与方具备相似特征、样本却不重叠的场景，就像不同地区银行一起对客户数据进行协同建模；而纵向联邦学习适合各参

与方有着相同样本但特征不重叠的情形，如同不同医疗机构分别掌管着患者不同的诊疗信息，两种模式各自存在一定优势，皆可在不同应用场景里有效把控数据隐私保护和模型性能的关系。

凭借上述途径，联邦学习不仅为处理数据隐私和安全问题开拓了全新技术路径，还为多方协同开展建模与跨域数据整合找到了新思路，伴随联邦学习技术持续发展，其在实际应用里的效果跟影响力会进一步拓展，为各个行业构建安全、可靠的数据共享生态环境提供坚实后盾^[49]。




图 2-1 联邦学习过程图
Fig 2-1 Federated Learning process

2.1.2 非独立同分布场景

在非独立同分布（Non-IID）场景中，数据样本之间分布差异十分显著，这对机器学习模型的训练和性能构成了诸多挑战，因为每个客户端或数据源所携带的数据分布不一致，模型的泛化能力极易受影响，在这样的境遇下，模型在训练期

间也许会对某一特定数据分布造成过拟合现象，进而造成其在全局数据方面表现欠佳，难以有效应对不同分布形式的数据^[50]。非 IID 场景下，数据的偏差及不平衡问题尤为突显，各个数据集也许包含数量或类别不同的样本，甚至有些数据集会完全没有某些类别的样本，这种不平衡会让训练过程的难度进一步加大，导致模型对某些类别的预测准确率下降，非 IID 数据会引入更高的计算复杂度，因为模型得一直去适应和调整不同分布的数据，拉高了收敛难度，也把训练时间延长了，应对非独立同分布的挑战，需采用更精细的算法设计与优化策略，以保障模型在不同数据源之间协同运转可取得理想的成效^[51]。

2.1.3 客户端漂移

在分布式学习和联邦学习的环境中，客户端漂移（Client Shift）指的是各客户端持有的数据分布跟全局数据分布间的差异，客户端漂移是独立同分布（Non - IID）问题的一个关键体现，一般体现为客户端数据存在异质性，也就是说不同客户端的数据在数量上存在差别，而且在类别分布、样本特征等方面也出现显著的漂移现象。

这种漂移产生了多层面的挑战，客户端数据的不一致或许会让模型在某个客户端的数据上呈现良好表现，但在别的客户端及全局数据上的表现欠佳，这是鉴于在训练进程里，模型会依照各个客户端的数据实施局部更新，也许会倾向于对特定的某些客户端数据分布过拟合，从而造成全局模型的泛化能力下降^[52]。

客户端漂移会引起优化过程的不稳定，在传统所采用的集中式训练中，全部数据的分布是一样的，而于联邦学习的情况里，各客户端之间数据分布的差异极大提升了训练过程的复杂程度，尤其是在处理像深度学习这类复杂模型的时候，模型在各客户端上进行局部更新之际，大概会受到极端数据分布的波及，引起局部梯度更新的波动性变强，进而影响模型在全局上的收敛性^[53]。

客户端漂移或许会引起训练过程里的数据不平衡状况，在某些情况的时候，某些客户端也许只囊括特定类别的数据，又或者某些客户端的数据量比别的客户

端大得多，这种不平衡状况会造成模型在某些类别或任务上表现更欠佳，进而影响到整体的学习成效。

面对客户端出现漂移现象时，得设计合适的算法去缓解这个难题，常用策略有调整客户端的权重、采取分布式正则化方式、引入公平性约束等，以尽量降低客户端漂移对全局模型性能的负面冲击，这些方法的目的是保证各客户端在联邦学习期间可平等地提供其数据，同时保障全局模型面对异质数据时依旧具备出色的泛化能力。

2.2 正则化方法

正则化（Regularization）作为一种技术可防止模型过拟合，其目的是对模型参数施加约束从而提升泛化能力，在机器学习与深度学习的范畴里，一般的正则化方法有 L1 正则化（Lasso）、L2 正则化（Ridge）、弹性网络（Elastic Net）以及 Dropout 等。L1 正则化借助对参数施加 L1 范数约束，让一部分参数趋向零，从而实现特征筛选的效果；L2 正则化借助对参数添加 L2 范数约束，遏制模型参数的大小变动，提高模型的平稳性，Dropout 在训练阶段随机扔掉部分神经元，进而降低对特定神经元的过度依赖，增强模型的泛化本领，正则化方法的核心要义是引入某类形式的约束，使得模型在学习过程中不会对训练数据过度贴合，而是能更有效地适应未知数据^[54]。

在联邦学习（Federated Learning 的环境里, FL）中，鉴于数据分布呈现出非独立同分布（Non-IID）特性，不同客户端之间的数据差异明显，这会造成模型在不同客户端的学习效果参差不齐，进而对全局模型的泛化能力形成影响，正则化方法在联邦学习里有着重要的应用意义，主要体现在下面几个方面^[55]。

全局模型正则化的目的是减少不同客户端相互间的模型参数差异，在实施联邦学习的阶段，普遍采用的方法为 FedProx 和 FedCurv^[56]，其中 FedProx 在目标函数中增添额外的 L2 约束，让每个客户端的局部模型与全局模型的偏离距离不过大，进而增强全局模型的稳定性，FedCurv 采用曲率正则化约束模型的更新走向，以保证优化过程更为平稳，缩减因客户端数据分布差异引发的剧烈参数浮动。

局部模型正则化主要是针对单个客户端存在的数据异质性问题，在一些情形下，单个客户端也许会因为数据量少或者数据类别不平衡，导致模型对自己的数据过拟合，为了应对这一问题，客户端局部训练之际，可以采用 L1 或 L2 正则化手段，从而对模型参数的更新幅度加以约束，防止模型陷入过度拟合困境，Dropout 也可在局部训练里发挥作用，于每轮训练中随机阻挡部分神经元工作，增强模型的容错性，保证其在合并全局模型的时候可以适应不同客户端的数据分布。

正则化还能在梯度隐私保护方面发挥作用，当进行联邦学习之际，为防止客户端私有数据出现泄露，一般都需要对梯度进行扰动或添加噪声，别样隐私

(Differential Privacy, DP 借助在梯度更新过程引入噪声，阻止攻击者借助梯度反推客户端的数据，为保证模型收敛性及稳定性，可在差分隐私框架里结合 L2 正则化，从而限制梯度更新的大小，减少隐私保护引起的模型性能的下降幅度^[57]。

在联邦学习当中应用正则化，可缓解数据异质性问题，改善全局模型的泛化水平，还能进一步增强模型的稳定性，而且在隐私保护场景中发挥关键功效，恰如其分地结合不同类型正则化方法，可以切实增强联邦学习系统的整体能力，使其更契合真实世界中的分布式数据环境。

2.3 余弦相似度

余弦相似度是一种普遍使用的度量方法，它依靠测量两个向量之间的夹角去衡量相似性，就任意两个样本而言，若它们之间的欧氏距离增加时，这两个样本被认为没那么近似，而当样本间的余弦相似度呈现增大时，就被看作越发相似，实现余弦相似度方法在基于特定相似性对象数量对数据分类上极为有用，比如可以用余弦相似度计算文档向量的余弦角度，再在文档上着手层次聚类算法的研发，以此提升效率与性能指标^[58]。余弦相似度在大量领域都有广泛的用途：在聚类算法里，余弦相似度可用来衡量各数据点之间的相似性，尤其是在高维空间环境里效果不错，原因是它留意的是向量方向，从而躲开了数据尺度不同带来的负面效应；在图像检索、目标判别等各类任务里，可采用余弦相似度对比特征向量之间的相似性，让其对旋转、缩放这类变换具备一定的鲁棒性，还能对神经网络起到

改善效果，凭借余弦相似度取代传统的点积，由此改善神经网络的训练成效与泛化本领，后续章节会把余弦相似度的相关内容详细说明。

2.4 度量学习

度量学习（Metric Learning）作为一种关键技术存在，其目的是自动学习一个适配当前任务的距离度量函数，进而让在特征空间里，相似样本彼此间的距离尽量拉近，让不同类别样本之间的距离尽量拉大，传统的距离度量（像欧氏距离、曼哈顿距离等种类）虽说简单好操作，但一般难以捕捉数据内部复杂的结构及语义详情，而度量学习借助数据驱动的手段，学习出更贴合任务需求的度量准则。

在度量学习的基本框架当中，首先要设计合理的目标函数让模型学习得到引导，对比损失（Contrastive Loss）通过组建正负样本对，引导模型在特征空间拉近同类样本的相互距离，同时把不同类样本距离拉开；而三元组损失（Triplet Loss）则更进一步利用锚点、正样本和负样本之间的相对关系，规定锚点与正样本间的间距小于锚点与负样本间的间距，且维持一个预先设定的间距，这些损失函数给模型界定了明确的优化对象，进而让学习到的特征的区分特性更明显，还能有效抓住数据的局部与全局结构^[59]。

深度度量学习在图像检索、目标识别、行人重识别等领域实现了显著成效，以深度神经网络作为特征提取器，经由多层非线性变换可将原始数据映射到一个高维特征空间，在这个空间里采用度量学习方法，可更出色地处理复杂视觉语义和样本间细微的差别，当领域自适应、跨模态检索等问题呈现在大家面前，研究者们不断去探索利用度量学习解决数据不平衡、样本稀缺等现实状况的手段。

在联邦学习等这样的分布式环境内，鉴于各客户端的数据分布往往呈现显著差异，度量学习同样起着关键作用，经由在各客户端训练阶段引入度量学习策略，能在全局模型聚合过程中更精准地评估各客户端更新的有效性，利用余弦相似度这类度量指标对客户端梯度或特征表示进行比对，有利于设计更合理的加权聚合方案，以此有效缓解客户端漂移、数据异质性等困扰，度量学习在联邦环境下还能实现更优的特征选择，减少噪声的干扰，增强模型的整体泛化水平。

度量学习不仅为传统的监督学习跟无监督学习提供了强有力工具，同时为分布式和联邦学习应对数据异质性情况、设计自适应聚合策略给出新途径，采用合理结合深度学习与度量学习的做法，研究者可于多个领域达成更精准且鲁棒的模型搭建，这还是当前以及未来智能系统发展中的一个关键研究方向。

2.5 数据集介绍

本实验借助 CIFAR-10 和 CIFA-100 数据集进行模型的训练与评估工作，这两个数据集是计算机视觉领域普遍应用的标准数据集，格外适合图像分类这一任务，常用来检验深度学习模型的性能强弱。CIFAR-10 与 CIFAR-100 数据集皆源自 Tiny Images 数据库，其中存有多种现实场景下的彩色图像，覆盖了常见的物体。CIFAR-10 数据集包含 60000 张彩色图像聚合而成，这里头有 50000 张用作训练，10000 张用作测试，所有的图像皆为 RGB 格式，数据集囊括 10 个类别，分别为：飞机、汽车、鸟、猫、鹿、狗、青蛙、马、船、卡车。数据集的类别呈现出均衡分布，即表明每个类别都含有 6,000 张图像样本，5000 张拿去训练，1000 张用作测试，因为 CIFAR-10 的类别数量不多且图像尺寸较小，一般用来评估轻量级深度学习模型或者联邦学习算法在相对简易分类任务上的成效。CIFAR-100 属于 CIFAR-10 的扩展版，数据规模彼此相同，同样有 60000 张彩色图片（50000 张作为训练用，10000 张做测试用），但类别数量明显增多至 100 类，每一个类别仅含有 600 张图像（500 张是训练用，100 张做测试）。跟 CIFAR-10 相比，CIFAR-100 展现出更高的分类难度，因为每个类别对应的训练样本数量不多，且不同类别间的视觉特征也许较为近似，CIFAR-100 采用分层式的分类结构，即每个类别属于 20 个超类（superclass）这一范围中的一个，例如：大型哺乳动物：熊、豹、狮子、虎、狼；家养动物：狗、猫、鼠、兔；水生动物：鲸鱼、海豚、海豹；车辆：自行车、摩托车、公交车、卡车、火车。这一层次模式让 CIFAR-100 在一些应用场景里更贴合真实世界的分类任务，好比在对大规模的数据集做分类时，某些类别大概是属于同一超类，但要分辨不同子类别，需要更细粒度的特征提取能力，CIFAR-100 一般用于评测更复杂的深度学习模型，诸如 ResNet、ViT（Vision

Transformer) [60]。

2.6 本章小结

本章主要介绍了联邦学习的基本理论以及论文用到的关键技术。先是介绍了联邦学习，包括其概念、非独立同分布场景下可能带来的挑战以及客户端漂移问题。接下来依次介绍了本文用到的主要技术，包括正则化方法、余弦相似度、以及度量学习。最后介绍了论文所用的数据集。通过本章节的介绍，为后续章节的介绍以及实验做铺垫。

3. 基于混合正则化优化联邦学习本地训练

在联邦学习的框架范畴内，各个客户端在本地数据上开展模型训练，随后把局部更新的内容上传至中心服务器完成全局模型聚合，因为各个客户端的数据分布一般存在明显差异，此类非独立同分布，由此影响到全局模型的收敛速度以及最终性能，为了应对这一难题，学者们开始探索在本地训练环节中引入正则化策略，借助约束局部模型的更新方向，缓和不同客户端间的偏差积累问题。

本研究提出了一种依托混合正则化的优化做法，目标是对联邦学习中客户端漂移问题实施系统性的改进，混合正则化方法综合了多种正则化技术的长处，通过设计恰当的正则项，使本地模型在优化阶段能充分运用各自的数据特征，又可从全局层面保持一定的一致性，由此在缓和客户端漂移问题的同时，提升全局模型的泛化水平，本文将在后面的小节中详细说明混合正则化的理论根基、具体实现途径及其在联邦学习场景中的应用效果。

3.1 FedDC

联邦学习（FL）过程中，客户端数据分布异质性（non-iid）引发的本地模型与全局模型的不一致现象，作者提出的解决策略是 FedDC 算法^[61]，通过引入本地漂移变量，对本地模型与全局模型的差距进行跟踪和纠正，以此提升模型收敛的速度以及性能。

FedDC 采用了本地漂移变量 h_i ，用以描述每个客户端本地模型参数 θ_i 与全局模型参数 w 之间的偏差，从理想角度看 $h_i = w - \theta_i$ 。基于这一观念，FedDC 在每轮训练中通过以下三部分构建了客户端的目标函数：本地经验损失：即在客户端数据上计算得到的损失 $L_i(\theta_i)$ 。惩罚项：形式为

$$R_i(h_i, \theta_i, w) = \|h_i + \theta_i - w\|^2 \quad (3-1)$$

用于约束本地漂移变量与实际差距的一致性。梯度校正项： $G_i(\theta_i; g_i, g)$ 用于减少局部梯度的方差，其中 g_i 和 g 分别表示客户端自身及所有客户端上一轮更新

的梯度信息。此设计不仅使各客户端在留存本地数据特征的时候，还可对全局模型偏离情况做有效校正，同时为后续混合正则化方法夯实了理论基础。

FedDC 算法主要有两个阶段：本地模型更新和全局模型更新，就本地模型更新阶段而言，在训练起始阶段，每个客户端都借助全局模型参数 w 初始化本地模型 θ_i 。客户端通过最小化目标函数：

$$F(\theta_i; h_i, D_i, w) = L_i(\theta_i) + \alpha R_i(h_i, \theta_i, w) + G_i(\theta_i; g_i, g) \quad (3-2)$$

来更新本地模型参数。模型参数更新后，客户端通过公式： $h_i^+ = h_i + (\theta_i^+ - \theta_i)$ 近似去更新本地漂移变量，进而不断跟踪本地和全局模型的偏差。客户端将更新后的本地参数 θ_i^+ 和漂移变量 h_i^+ 上传至服务器，服务器按照各客户端数据量 $|D_i|$ 的权重，对所有客户端上传的纠正后参数进行加权平均，更新全局模型参数：

$$w^+ = \frac{1}{|D|} \sum_{i=1}^N |D_i| (h_i^+ + \theta_i^+) \quad (3-3)$$

总的来说，FedDC 算法通过对本地漂移的解耦与校正，为解决联邦学习里因数据分布异质性造成的模型更新偏差给出了一种有效思路，其双重校正机制在理论上让本地更新与全局目标达成了一致，于实际实验当中同样呈现出优越的收敛速度和模型性能。

3.2 混合正则化改进

在 FedDC 模型里，为缓解非独立同分布（non-IID）环境下本地模型与全局模型之间的差距，作者引入了漂移变量，还借助 L2 正则化对与漂移变量相关的近端项进行约束。L2 正则化的主要作用是利用惩罚权重平方和来防止模型过拟合，进而保证模型参数不会出现过大的数值。但是，L2 正则化的缺陷在于它只是对所有权重施加均匀的衰减作用，而不会将其中任何一个权重直接变成零，这说明模型中的所有特征依然被保留，因此难以实现自动的特征选择。在联邦学习中，缘于不同客户端之间数据分布的异质性，某些客户端可能拥有较多噪声或冗余信息。采用 L2 正则化后，虽然能抑制过拟合，但这些冗余特征依然存在，不利于模型对重要特征的自动识别和利用，从而可能影响整体性能。混合正则化则通过结合 L1

正则化和 L2 正则化的优势，弥补了单一 L2 正则化在特征选择方面的不足：

L1 正则化的一个重要特性是能够将部分权重推向零值，达成特征的自动筛选。这说明那些对模型贡献较小或噪声较大的特征可以在正则化过程中被剔除，从而提高模型的解释性和泛化能力。

通过将 L1 和 L2 正则化结合起来，混合正则化既维持了 L2 在防止过拟合方面的平滑效果，又利用 L1 对不重要特征的自动筛选作用。该方法在联邦学习场景中具有更好的适应性，适应不同客户端的数据分布。各客户端数据分布存在较大差异，混合正则化可依据不同客户端的数据特点，自动剔除那些噪声较大的冗余特征，保证了各客户端更新更加精准有效；提升模型整体性能：在在多客户端联合进行训练的阶段，可突出关键特征、消除多余的干扰成分，使全局模型在归集各客户端贡献的阶段，整体效果愈发明显。

通过调整 L1 和 L2 正则化的比例，可以在不同的联邦学习场景中灵活应对数据异质性带来的挑战。能在各类联邦学习场景里灵活应对数据异质性造成的挑战，这种灵活性使混合正则化更能契合实际应用中不同客户端的数据分布情形，进而增强整体模型的收敛速度与泛化性能。

3.3 算法流程

本部分详细描述采用混合正则化的联邦学习算法的具体流程，该流程在 FedDC 的基础上做出改进，关键是对漂移变量正则化的部分运用了混合正则化，以更好地适应非独立同分布（non-IID）环境下各客户端数据的异质性。本文称该算法为 FedReg，整体算法步骤如算法 1 所示。

3.3.1 本地模型更新

在本地模型更新阶段，每个客户端先以全局模型参数 $\mathbf{w}$ 作为本地模型的初始参数 θ_i 同时初始化漂移变量 $\mathbf{h}_i$ （设置为零向量）。客户端构建的本地目标函数主要由三个部分组成：一是基于本地数据 D_i 计算得到的经验损失 $L_i(\theta_i)$ ；二是针对漂移变量的混合正则化惩罚项，该惩罚项结合了 L1 与 L2 正则化的优势，形式为

$$T_i(h_i, \theta_i, w) = \lambda_1 \|h_i + \theta_i - w\|^2 + \lambda_2 \|h_i + \theta_i - w\| \quad (3-4)$$

其中 λ_1 和 λ_2 分别控制 L1 和 L2 正则化的权重。三是用于降低局部梯度方差的梯度校正项 $G_i(\theta_i; g_i, g)$ ，其中 g_i 为客户端上轮的梯度，而 g 为所有客户端梯度的平均值。客户端通过最小化综合目标函数

$$F(\theta_i; h_i, D_i, w) = L_i(\theta_i) + T_i(h_i, \theta_i, w) + G_i(\theta_i; g_i, g) \quad (3-5)$$

来更新本地模型参数。损失项构成如图 3-1 所示，在完成本地模型更新后，客户端根据参数变化更新漂移变量，更新公式为

$$h_i^+ = h_i + (\theta_i^+ - \theta_i) \quad (3-6)$$

其中 θ_i^+ 表示更新后的本地模型参数。




图 3-1 损失项构成
Fig 3-1 Composition of Loss Terms

3.3.2 模型聚合阶段

最终，全局模型参数更新公式为客户端将更新后的本地参数 θ_i^+ 和漂移变量 h_i^+ 上传至服务器，服务器依据各客户端数据量 $|D_i|$ 的权重，对所有客户端上传的纠正后参数进行加权平均，更新全局模型参数：

$$w^+ = \frac{1}{|D|} \sum_{i=1}^N |D_i| (h_i^+ + \theta_i^+) \quad (3-7)$$

输入: 全局模型 w_0 , 通信轮次 T , 本地轮次 E , 学习率 η , L1 正则化超参数 λ_1 , L2 正则化超参数 λ_2

- 1: 对于 $t = 1$ 到 T
- 2: 将全局模型 w_0 下发至参与训练的客户端
- 3: 对于每个客户端（并行执行）:
- 4: 接收来自服务器的模型 w_t^i
- 5: 对于 $e = 1$ 到 E
- 6: 使用本地数据和给定学习率 η 更新模型 w_t^i
- 7: 并最小化公式 (3-5) 所示的目标函数。
- 8: 结束每个客户端的本地训练。
- 9: 聚合本地模型以更新全局模型 w_{t+1}

输出: 训练好的全局模型 w_T

3.4 实验结果及分析

在介绍完混合正则化之后, 本节在 Cifar10 和 Cifar100 进行实验, 以验证混合正则化改进后的性能。本节首先介绍实验设置, 包括数据集的预处理、数据集的划分以及实验的软硬件环境, 然后对实验结果进行分析。

3.4.1 实验设置

本节内容为实验环境和参数设置, 以此验证提出的混合正则化方法在联邦学习场景下的有效性。实验主要在多个公共数据集上开展, 以充分体现数据分布异质性下各方法的性能表现。

本研究选定 CIFAR10 和 CIFAR100 作为实验所用数据集, 分别就三种场景开展实验: iid、non-iid(0.3) 以及 non-iid(0.6) 环境。在 iid 场景中, 训练样本随机选择并均匀分配至各客户端; 而在 non-iid 场景下, 通过 Dirichlet 分布进行数据划分, 其中 Dirichlet 参数分别取 0.6 和 0.3, 以模拟客户端数据分布的不同程度的非独立同分布情况。所有数据集均经过标准预处理, 包括归一化、数据增强（如随机裁剪和翻转）等操作。

实验平台采用具有 GPU 加速的服务器, 依靠 Python 和 PyTorch 框架实现各算法, 全部客户端在本地均采用卷积神经网络 (CNN) 作为自身训练模型, 以便

充分发挥其在图像识别任务里的有利点，为达成实验结果的稳定与可重复，所有实验皆设置固定随机种子，且对多次实验得到的结果取平均值开展评估。

本研究把所提模型和多种先进联邦学习方法开展对比，涉及 FedAvg、FedProx、Scaffold^[62]、FedDyn^[63] 以及 FedDC。FedProx 通过在本地图标函数中引入近端项来减少梯度方差；Scaffold 尝试采用梯度校正项对本地更新进行纠正；FedDyn 采用动态正则器来校准客户端模型；而 FedDC 凭借本地漂移变量来修正客户端漂移。在 FedDC 的基础上利用混合正则化策略，以期在特征选择和全局模型融合上取得更优性能。

具体的实验参数设置如下：本地训练批次大小设为 50；每轮通信中，本地训练周期（epoch）设为 5；初始学习率为 0.1，学习率衰减率设为 0.998；通信轮次总数设置为 600；每轮参与训练的客户端比例为 15%。L2 正则化项超参数设置为 0.01，L1 正则化项超参数设置为 0.01/100。

为全面评估所提出的混合正则化方法在联邦学习中的性能，主要聚焦以下两个评价指标：模型准确率：在 CIFAR10 和 CIFAR100 测试集上的分类准确率，用以衡量模型的预测性能。通信效率：记录达到预定精度所需的通信轮次数，以比较不同方法在通信开销上的差异。

3.4.2 实验结果

(1) 模型准确度

从图 3-2 和图 3-3 不难看出，这是在 CIFAR100 数据集的 non-iid(0.6) 以及 non-iid(0.3) 设置下，不同联邦学习方法随通信轮次增加而呈现的测试准确度变化曲线。横轴表示通信轮次，纵轴表示测试准确度，曲线颜色分别对应 FedAvg、FedDC、FedDyn、FedProx、Scaffold 以及提出的 FedReg 模型。FedReg 的曲线在所有方法中最终准确度最高，而且在中后期依旧能保持相对稳定的上升走势，FedAvg 与 FedProx 应对客户端间数据分布差异时表现相对乏力，准确度到中后期呈现明显停滞，最终的收敛精度还是相对偏低；Scaffold 与 FedDyn 虽说在一定程度上减少了客户端漂移现象，但后期在收敛精度上，仍然比 FedReg 与 FedDC 要

差。在非 IID 环境下，FedDC 依靠本地漂移变量的表现胜过了其他基线方法，而 FedReg 在这个基础上还进一步融合了混合正则化，曲线在整个训练过程中都能稳定提升，最终准确度明显高于其他方法。同样对于 CIFAR10 数据集，从图 3-4 和图 3-5 中，可以看出 FedReg 模型对比其他模型的优势表现。

从表 3-1 可看出，在 CIFAR100 与 CIFAR10 数据集上的所有数据分布场景中，所提出的模型均取得了更高的 top-1 准确度。例如，在 CIFAR100 的 iid 情况下，本文模型的准确率为 55.25%，略高于 FedDC 的 55.00% 和 Scaffold 的 51.24%；在 non-iid(0.3) 与 non-iid(0.6) 条件下，模型分别达到 54.18%和 55.21%，远高于其他基线方法。同样，在 CIFAR10 数据集上，模型在 iid、non-iid(0.3) 和 non-iid(0.6) 场景下分别获得了 85.52%、84.84% 和 85.15% 的准确率，远高于 FedAvg 和 FedProx 等方法。这表明，混合正则化与聚合优化策略的引入不仅改善了特征选择和过拟合问题，还更合理的应对了客户端数据分布的不均衡，从而使得全局模型在多种场景下均能实现更高的准确度。

总的来说，FedReg 通过对漂移变量施加混合正则化，不仅有效防止了过拟合，还能够实现一定的特征选择，从而在本地训练阶段得到更精炼的模型更新。这一结果说明，FedReg 能够更好地应对非 IID 环境下的异质性挑战，在保证收敛速度的同时，显著提升了最终模型性能。

表 3-1 不同方法在不同数据集不同数据分布下的 top-1 测试准确度对比

Table 3-1 Comparison of top-1 test accuracy of different methods with different data distributions in different datasets

数据集	数据分布 (iid/non-iid)	方法(top-1 准确度)					
		FedReg	FedDC	Scaffold	FedProx	FedAVG	FedDyn
Cifar100	iid	55.25%	55%	51.24%	40.45%	39.68%	50.89%
	0.3	54.18%	53.84%	51.15%	41.01%	40.91%	50.12%
	0.6	55.21%	53.95%	51.82%	40.22%	40.52%	50.34%
Cifar10	iid	85.52%	85.40%	84.88%	81.64%	82.08%	84.92%
	0.3	84.84%	83.78%	82.68%	78.62%	79.04%	82.95%
	0.6	85.15%	84.76%	83.06%	80.83%	80.33%	82.99%




图 3-2 不同方法在 Cifar100(non-iid 为 0.6)的测试准确度随通信轮次变化图

Fig 3-2 test accuracy of different methods on Cifar100 (non-iid of 0.6) with communication rounds




图 3-3 不同方法在 Cifar100(non-iid 为 0.3)的测试准确度随通信轮次变化图

Fig 3-3 test accuracy of different methods on Cifar100 (non-iid of 0.3) with communication rounds




图 3-4 不同方法在 Cifar10(non-iid 为 0.3)的测试准确度随通信轮次变化图
Fig 3-4 test accuracy of different methods on Cifar10 (non-iid of 0.3) with communication rounds




图 3-5 不同方法在 Cifar10(non-iid 为 0.6)的测试准确度随通信轮次变化图
Fig 3-5 test accuracy of different methods on Cifar10 (non-iid of 0.6) with communication rounds

表 3-2 不同方法在不同数据集不同数据分布下到达相同准确度所需通信轮次对比对比
Table 3-2 Comparison of the number of communication rounds required for different methods to reach the same accuracy under different data distributions in different datasets

数据集	数据分布 (目标准确度)	方法（通信轮次）	
		FedReg	FedDC
Cifar100	iid (54%)	376	421
	0.3(54%)	363	398
	0.6(54%)	356	426
Cifar10	iid(84%)	281	304
	0.3(84%)	305	377
	0.6(84%)	276	306

(2) 通信效率

表 3-2 统计了在达到 54% 目标标准度条件下, 不同算法在 CIFAR100 和 CIFAR10 数据集 (不同数据分布设置下) 所需的通信轮次数。在 CIFAR100 数据集上, 无论是在 iid 环境还是在 non-iid 环境下 (Dirichlet 参数为 0.3 或 0.6), FedReg 均显著优于 FedDC。在 iid 条件下, FedReg 仅需 376 轮就可达到 54% 准确度, 而 FedDC 则需要 421 轮; 在 non-iid(0.3) 设置下, FedReg 需要 363 轮, 相比之下, FedDC 需要 398 轮; 在 non-iid(0.6) 场景中, FedReg 只需 356 轮, 而 FedDC 却需 426 轮。这说明, 基于混合正则化的 FedReg 模型能够在异构数据分布下更快地达到目标标准度, 从而降低通信开销。在 CIFAR10 数据集上, 情况与 CIFAR100 类似。在 iid 环境下, FedReg 需要 281 轮, 而 FedDC 需要 304 轮; 在 non-iid(0.3) 环境下, FedReg 只需 305 轮, 相比之下 FedDC 需要 377 轮; 在 non-iid(0.6) 场景中, FedReg 需要 276 轮, 均明显低于 FedDC 的 306 轮。

不管是针对 CIFAR100 数据集还是 CIFAR10 数据集而言, 所提出的 FedReg 模型都能够更快地达到预设的目标标准度, 相比于 FedDC, 通信轮次大幅减少。这充分说明, 采用混合正则化结合聚合优化策略, 不仅改善了模型对特征选择和过拟合问题的处理, 还在非独立同分布环境下有效应对了客户端数据分布不均衡的问题, 由此加快了模型收敛的进程, 该结果对联邦学习在实际运用中降低通信成本、提升效率意义重大。

3.5 本章小结

本章先是介绍了前人提出的 FedDC 模型, 后提出了基于混合正则化优化联邦学习的本地训练阶段, 主要解决了联邦学习非独立同分布场景下导致的客户端漂移现象带来的模型性能下降的问题。FedReg 以 FedDC 提出的漂移量 L2 正则化为依托, 引入了 L1 正则化, 既保留了 L2 在防止过拟合方面的平滑效果, 又利用 L1 对不重要特征的自动筛选作用。这种方法在联邦学习场景中具有更好的适应性, 适应不同客户端的数据分布。实验结果说明, 不管是测试准确度, 还是通信效率, FedReg 都远胜过其他基准模型。

4. 基于余弦相似度优化联邦学习聚合

随着数据隐私与分布式计算需求不断攀升，联邦学习是一种既能保护用户隐私，又能充分利用分散数据资源的机器学习模式，由此受到越来越多的关注。但是，鉴于各参与方数据分布表现出的异质性，传统简单参数平均策略在聚合进程里容易受到噪声、异常更新或偏离全局目标的干扰，进而造成模型整体性能和收敛速度降低。为了解决这一问题，为了应对这一问题，在最近几年，研究者们开始探索基于相似性度量的手段，以达成更精准、可靠的模型聚合策略，余弦相似度凭借其可对向量间方向相似性加以量化的优点，普遍应用在文本分析、推荐系统等领域，还渐渐被引入到联邦学习的聚合机制当中。余弦相似度能衡量各个客户端模型更新方向上的一致性，还能通过动态权重调整，过滤噪声和异常更新，以此优化全局模型的训练过程。本章节会详细介绍基于余弦相似度优化联邦学习聚合的方法。回顾余弦相似度的基本原理及其它在衡量模型更新相似性时的作用；探究如何借助这一度量机制为不同客户端确定合理的聚合权重；采用理论分析与实验验证，展现该方法在提升模型收敛速度和增进全局泛化能力方面的长处。

4.1 余弦相似度介绍

余弦相似度作为指标可衡量两个向量方向的相似程度，其关键思想是计算出两个向量夹角的余弦值，以此反映它们在方向上的靠拢程度，而不受向量模长（幅度）的影响^[64]。对于两个非零向量 a 和 b ，其余弦相似度可以定义为：

$$\text{cosine_similarity}(a,b)=\frac{a \cdot b}{\|a\|\|b\|} \quad (4-1)$$

其中： $a \cdot b$ 表示向量的内积， $\|a\|$ 和 $\|b\|$ 分别是向量 a 和 b 的欧几里得范数。

余弦相似度的取值范围在 $[-1,1]$ 之间，当两个向量完全同向时，其值为 1；当两个向量正交时，其值为 0；当两个向量方向完全相反时，其值为 -1。

在很多实际应用中（例如文本分析、推荐系统和聚类分析），由于数据通常为非负向量，余弦相似度的取值范围常被认为在 $[0,1][0,1][0,1]$ 之间。

4.2 利用余弦相似度优化联邦学习聚合过程

4.2.1 合理性分析

在第三章当中，提出采用混合正则化这途径来优化联邦学习（Federated Learning, FL）的本地训练阶段。实验结果表明，混合正则化策略有效地缓解了联邦学习在非独立同分布场景下的性能下降问题。采用在本地训练中引入混合正则化的做法，不仅提升了模型的泛化能力，还在一定程度上缓和了数据分布不一致造成的训练不稳定性。尽管混合正则化的引入改善了每个客户端的本地模型训练效果，但当前方法在全局模型聚合阶段依然延续了传统的联邦平均算法思路。这种简单的平均聚合方式，在非独立同分布场景下会忽略每个客户端的个性化特征，导致全局模型无法充分留住客户端的多样化信息，进而对个性化联邦学习的效果产生限制。

找到一种更加合理的模型聚合策略十分关键。可以通过充分分析客户端上传的本地模型参数与全局模型参数之间的关系，为每个客户端动态分配恰当的权重，由此在模型聚合阶段引入额外的信息。这种基于权重的聚合方式相比传统的简单平均方法更具灵活性，能够更好地适应非独立同分布场景下的数据分布差异。该方法还可以结合客户端的特定特征（例如数据量、分布特性、训练损失等）对权重进行动态调整，进而达成更具个性化的模型聚合。在该框架下，全局模型不仅可以更合理地把不同客户端信息整合，还可以在在一定程度上留存客户端的个性化特质，以此增强联邦学习在非独立同分布场景下的表现能力。这为解决联邦学习在异构数据环境中的个性化和泛化问题提供了新的思路，也为未来联邦学习算法的优化奠定了基础。

在进一步优化联邦学习的模型聚合策略时，引入余弦相似度（Cosine Similarity）以度量客户端模型参数与全局模型参数之间的相似性，以此动态调节聚合的权重数值。该方法的核心思想为利用余弦相似度来捕捉不同客户端模型与

全局模型之间的方向性一致程度，进而给每个客户端模型赋予不同的重要性权重。余弦相似度通过计算两个向量的夹角余弦值，能够反映它们在高维空间中的相似程度^[65]。比起直接基于参数值的聚合方法，采用余弦相似度能够更好地衡量模型间的相对关系^[66]。

4.2.2 优化方案

首先，各客户端在完成本地训练后，将更新后的模型参数以及对应的局部梯度上传至服务器。服务器接收到所有客户端的更新后，首先计算所有客户端上传的梯度的全局平均值：

在本方法中，引入了基于余弦相似度的加权聚合策略，借此更确切地体现各客户端对全局模型优化的实际贡献度。设全局模型的梯度更新为 $\nabla L(w)$ ，客户端 i 当前轮的梯度更新为 $\nabla L_i(w)$ ；其对应的 L2 范数分别记为 $\|\nabla L(w)\|$ 和 $\|\nabla L_i(w)\|$ 。客户端 i 的梯度更新与全局模型梯度更新之间的余弦相似度定义为：

$$\cos Sim(\nabla L(w), \nabla L_i(w)) = \frac{\nabla L(w) \cdot \nabla L_i(w)}{\|\nabla L(w)\| \|\nabla L_i(w)\|} \quad (4-2)$$

其中， $\nabla L(w) \cdot \nabla L_i(w)$ 表示两向量的点积。余弦相似度的值域为 $[-1, 1]$ ，值越大表示客户端 i 的梯度更新方向与全局梯度更新方向越一致，即该客户端更新更符合全局优化方向，应获得更高的聚合权重。

在全局聚合阶段，服务器首先把所有客户端上传的更新信息收集起来，并计算每一个客户端的余弦相似度，为保证聚合时各客户端权重的合理性，将所有余弦相似度进行归一化，使各客户端权重相加结果为 1。具体而言，令客户端 i 的权重 w_i 定义为

$$w_i = \frac{\cos Sim(\nabla L(w), \nabla L_i(w))}{\sum_{j=1}^N \cos Sim(\nabla L(w), \nabla L_j(w))} \quad (4-3)$$

其中 N 为参与本轮通信的客户端数量。归一化后的权重 w_i 能够有效反映各客户端的更新质量：方向与全局梯度一致性越高的客户端，其权重越大，对全局模型更新的贡献也越显著。

最后，服务器采用加权平均策略对各客户端上传的模型参数进行聚合，从而更新全局模型参数。更新公式为：

$$w^{t+1} = \sum_{i=1}^N w_i \cdot \theta_i^{t+1} \quad (4-4)$$

其中 θ_i^{t+1} 表示客户端 i 在当前通信轮次更新后的模型参数。这种基于余弦相似度的加权聚合方式不仅能有效削弱那些更新方向与全局优化方向偏离较大的客户端对全局模型的不利影响，同时也充分放大了数据质量高、更新方向与全局趋势一致的客户端的贡献（流程图如 4-1 所示），从而提升全局模型的收敛速度和最终准确度。




图 4-1 引入余弦相似度的聚合过程
Fig 4-1 Aggregation process based on cosine similarity

4.3 实验结果与分析

在介绍完余弦相似度优化联邦学习聚合过程后，本节在 CIFAR10 和 CIFAR100 数据集上进行实验，在混合正则化的基础上再引入余弦相似度聚合，以验证该方法对模型的改进效果。利用混合正则化改进的方法称为 FedReg，在此基础上引入余弦相似度的方法称为 FedReg*。本节首先介绍实验设置，然后对实验结果进行分析。

4.3.1 实验设置

本实验在数据集预处理和数据集的划分上与 3.4.1 节大致相同，在三种场景下进行实验：iid、non-iid(0.3) 以及 non-iid(0.6) 环境。在 iid 场景中，训练样本随机选择并均匀分配至各客户端；而在 non-iid 场景下，通过 Dirichlet 分布进行数据划分，其中 Dirichlet 参数分别取 0.6 和 0.3，以模拟客户端数据分布的不同程度的非独立同分布情况。

把所提出的模型与多种先进联邦学习方法作了对比，这些方法包括 FedAvg、FedProx、Scaffold、FedDyn 以及 FedDC 几种，FedProx 在本地目标函数里引入近端项，以此降低梯度方差；Scaffold 意图利用梯度校正项对本地更新进行纠错；FedDyn 采用动态正则器对客户端模型进行校准；而 FedDC 用本地漂移变量来修正客户端存在的漂移。FedReg 以 FedDC 为基础进一步引入混合正则化，FedReg* 基于 FedReg 引入余弦相似度来对聚合进行优化处理，本实验主要对比 FedReg* 和 FedReg 在性能与通信效率上的优化差异，以检验余弦相似度聚合策略的有效性。

具体的实验参数设置和 3.4.1 节大致相同：本地训练批次大小设为 50；每轮通信中，本地训练周期（epoch）设为 5；初始学习率为 0.1，学习率衰减率设为 0.998；通信轮次总数设置为 600；每轮参与训练的客户端比例为 15%。L2 正则化项超参数设置为 0.01，L1 正则化项超参数设置为 0.01/100。

主要关注以下两个评价指标：模型准确率：在 CIFAR10 和 CIFAR100 测试集上的分类准确率，用以衡量模型的预测性能。通信效率：记录达到预定精度所需的通信轮次数，以比较不同方法在通信开销上的差异。

4.3.2 实验结果

(1)模型准确度

如表 4-1 实验所示，在 Cifar100 数据集中，FedReg*在 iid 和 0.3 分布下分别比 FedReg 提升了约 0.39 和 0.56 个百分点，尽管在 0.6 分布下略低于 FedReg，但整体表现依然稳定；而在 Cifar10 数据集中，FedReg*在 iid、0.3 和 0.6 分布下均

取得了准确度的提升, 其中 0.6 分布下的提升近 0.74 个百分点。该改进方法通过引入余弦相似度, 在聚合阶段为各客户端更新分配更合理的权重, 有效强化了与全局模型更新方向一致的客户端贡献, 同时抑制了异常或噪声较大的更新, 从而提升了模型的泛化能力和鲁棒性。图 4-2 和图 4-3 较为直观的展示了分别在 Cifar100 数据集(non-iid 为 0.3)以及在 Cifar10 数据集(non-iid 为 0.3)场景下 MetricFedReg, FedReg*相较于 FedReg 准确度方面有了提升。

表 4-1 不同方法在不同数据集不同数据分布下的 top-1 测试准确度对比
Table 4-1 Comparison of top-1 test accuracy of different methods with different data distributions in different datasets

数据集	数据分布 (iid/non-iid)	方法(top-1 准确度)						
		FedReg*	FedReg	FedDC	Scaffold	FedProx	FedAVG	FedDyn
Cifar100	iid	55.64%	55.25%	55%	51.24%	40.45%	39.68%	50.89%
	0.3	54.74%	54.18%	53.84%	51.15%	41.01%	40.91%	50.12%
	0.6	54.60%	55.21%	53.95%	51.82%	40.22%	40.52%	50.34%
Cifar10	iid	85.56%	85.52%	85.40%	84.88%	81.64%	82.08%	84.92%
	0.3	85.11%	84.84%	83.78%	82.68%	78.62%	79.04%	82.95%
	0.6	85.89%	85.15%	84.76%	83.06%	80.83%	80.33%	82.99%




图 4-2 不同方法在 Cifar100(non-iid 为 0.3)的测试准确度随通信轮次变化图
Fig 4-2 test accuracy of different methods on Cifar100 (non-iid of 0.3) with communication rounds




图 4-3 不同方法在 Cifar10(non-iid 为 0.6)的测试准确度随通信轮次变化图

Fig 4-3 test accuracy of different methods on Cifar10 (non-iid of 0.6) with communication rounds

(2)通信效率

如表 4-2 所示，在达到 54%目标标准度时，FedReg*相比 FedReg 在通信效率上大多数场景具有明显优势。在 Cifar100 数据集上，FedReg*分别需要 331、350 和 327 轮，而 FedReg 则分别需要 376、363 和 356 轮，减少了 45、13 和 29 轮的通信次数；在 Cifar10 数据集中，FedReg*在 iid 和 0.6 分布下也分别节省了 28 和 12 轮，尽管在 0.3 分布下 FedReg 需要 325 轮略高于 FedReg 的 305 轮，但总体来看，FedReg*通过引入余弦相似度优化聚合，有效加快了全局模型收敛速度，从而提升了通信效率。

表 4-2 不同方法在不同数据集不同数据分布下到达相同准确度所需通信轮次对比对比
Table 4-2 Comparison of the number of communication rounds required for different methods to reach the same accuracy under different data distributions in different datasets

数据集	数据分布 (目标标准度)	方法（通信轮次）		
		FedReg*	FedReg	FedDC
Cifar100	iid (54%)	331	376	421
	0.3(54%)	350	363	398
	0.6(54%)	327	356	426
Cifar10	iid(84%)	253	281	304
	0.3(84%)	325	305	377
	0.6(84%)	264	276	306

4.4 本章小结

本章先是介绍了余弦相似度的基本概念，之后在应用了正则化方法的 FedReg 这一基础，添加了余弦相似度机制，对联邦学习中的模型聚合过程进行改进，改进后的 FedReg* 利用余弦相似度来衡量各客户端模型更新方向和全局更新的契合程度，进而为每个客户端分配更为合理的聚合权重，使得聚合过程更能突出与全局模型更新方向一致的有效信息，同时抑制了异常或噪声更新对整体模型的负面影响。通过对比实验数据，在达成相同目标标准度时，相比于 FedReg，FedReg* 在通信效率上凸显出明显的优势，在 Cifar100 和 Cifar10 数据集上均能在更少的通信轮次内实现模型收敛。将余弦相似度引入不仅加快了模型全局的收敛速度，还为系统处理数据异质性问题赋予了更强的鲁棒性和泛化能力，本章展示的基于余弦相似度优化的 FedReg* 方法，在模型聚合以及通信效率两方面均实现了令人满意的改善效果。

5. 基于度量学习优化联邦学习本地训练

本章基于度量学习优化联邦学习本地训练的思想，就分布式环境下如何提升模型本地训练的效果做了深入探讨，采用引入三元组损失等度量学习方式，增强模型在嵌入空间中对同类样本的集聚和异类样本的区分能力，进而提高模型的表征能力与泛化特性；该优化策略能够在联邦学习情境中更好地减轻各参与方数据分布不均与异构性问题，促进全局模型的协同更新与安全传输。开始介绍了度量学习的基本原理、在特征提取和表示学习中的应用。随后说明如何将度量学习技术适当地整合到联邦学习框架里面，优化本地模型的训练，在 FedReg* 的基础上引入度量学习，进一步提升联邦学习在非独立同分布场景下的性能水平。实验结果验证了该方法在提升模型性能方面的有效性。

5.1 度量学习

在近年来大数据和深度学习迅速发展的背景下，怎样有效捕捉高维数据中的内在结构成为研究热点。以往的欧式距离、曼哈顿距离等固定度量方式，在复杂数据中往往无法展现样本间的真正相似性，度量学习（Metric Learning）恰恰是针对这一问题而提出的一种自适应途径，其核心思想在于通过学习一个适合的数据空间距离度量，使得相似样本之间的距离更近，而不相似样本之间的距离更远，进而为分类、聚类、检索以及人脸识别等任务提供支持^[67]。

度量学习关注在数据空间中定义或学习出一个满足特定性质的距离函数。传统距离函数通常由专家预先设定，如欧氏距离或曼哈顿距离，但这类固定距离往往难以适应不同任务中数据分布的复杂性。度量学习借助数据驱动的手段，自动从数据里面学习出一个度量空间，在该空间中，数据的结构信息能够被更清晰地呈现。常见的距离度量有马氏距离^[68]。

在度量学习中，距离与相似性是两个紧密关联却又存在差异的概念。距离度量可对数据点间的数值差异进行量化，而相似性一般是通过将距离函数进行转换

后获取的,用以说明数据点之间的相似程度高低^[69]。由此产生的度量空间不仅要求满足非负性、对称性和三角不等式等基本性质,还得根据具体任务进行自适应调节。根据是否利用标签信息,度量学习方法分为监督和非监督两大类。监督方法利用标签构造正负样本对或三元组(anchor、positive、negative),并通过设计对比损失、三元组损失或中心损失等损失函数来优化距离函数;而所依赖的是数据本身的结构,如采用局部邻域信息或图结构,做到无标签时候的距离度量学习^[70]。

在实际应用中,线性和非线性度量学习方法各有侧重。线性方法里马氏距离学习堪称代表,其主要思路是学习正定矩阵 M 以界定数据之间的距离,其中 LMNN 和 ITML 属于两种典型算法。非线性度量学习方法则试图通过核方法或深度学习模型解决数据中的非线性关系。核方法借助核函数把数据映射到高维特征空间,再在这个空间里进行线性度量学习,实现非线性效果;深度度量学习则直接利用神经网络,诸如 Siamese 网络、Triplet 网络以及近年来兴起的对比学习方法,通过端到端训练获得更加鲁棒的嵌入表示。损失函数的设计起着极其重要的作用,其中对比损失通过缩小同类样本间的距离、增大异类样本间的距离来优化模型,而三元组损失采用三元组数据作为输入,要使 anchor 与 positive 之间的距离始终小于 anchor 与 negative 之间的距离,且保证有一定的间隔。中心损失通过学习各类别的中心,同类样本在特征空间中更加集中,以此增强分类器的判别水平^[71]。

度量学习技术已在多个领域成功应用。在人脸识别任务中,采用学习人脸图像的嵌入表示方式,可让同一人的不同图像在嵌入空间集中在一起,由此显著提升识别的精准度。在图像检索领域,度量学习将相似图像映射到相邻区域,极大增强检索效率。在文本相似性判断和推荐系统中,通过将数据映射到同一嵌入空间,度量学习同样为攻克数据异构问题提供了有效手段。

度量学习作为连接传统机器学习与深度学习的重要桥梁,以自适应学习手段学习数据彼此间的距离函数,可大幅增进各种任务的功效,未来研究有机会在训练效率、跨模态学习以及无监督 and 自监督学习等方面取得新的突破点,以此促进

度量学习在更多实际场景中的落地。度量学习不仅丰富了对数据内在结构的理解，也为解决现实问题提供了有力的支持。

5.2 基于度量学习的本地优化

在联邦学习场景中，鉴于各客户端数据分布存在明显不同，直接对全局模型做简单平均（类似 FedAvg）可能引起特征表示不一致，进而让模型在新客户端上的泛化能力变差，在本地训练过程当中引入度量学习目标，以推动各客户端在训练时学到有更佳区分性的特征嵌入，由此增强全局模型在数据异构环境下的性能。在 FedReg*基础上应用度量学习优化的方法称为 MetricFedReg。

5.2.1 模型结构与嵌入提取

在常规的分类任务里，模型一般仅输出最终的预测结果，然而中间层的特征表示（embedding）未得到充分运用，对模型的结构做了改进处理，在原有分类网络的基础上添加了特征提取接口 `getEmbedding`，就不同的模型构造而言，均设计了对应的 `getEmbedding` 方法，返回由中间层（例如经过第一层全连接或卷积池化后的激活）得到的特征向量。目的是借助这些较低级特征表示构造度量学习的损失，进一步提升特征分辨能力。

5.2.2 三元组损失的构造与应用

在本研究中，采用三元组损失（Triplet Loss）作为度量学习的目标。对于一个锚点样本（anchor），与它同类别的正样本（positive）的距离要比与异类别负样本（negative）的距离更小，且至少相差一个预设的 `margin`。鉴于联邦学习环境下客户端可利用数据有限，采用了在 `batch` 内部构造三元组的途径：就每个锚点样本而言，在当前 `batch` 里探寻与其同类且与锚点有别的正样本；同时在 `batch` 里选取类别相异的样本作为负样本，若在当前批次中没办法构造完整的三元组，则把该样本对应的度量损失省去。借助 PyTorch 自带的 `TripletMarginLoss`（设定 `margin` 为 1.0）计算三元组损失，并将其作为辅助损失添加进总的训练目标里面。

5.2.3 客户端本地训练过程

在本地训练过程中，保证模型在入侵检测任务的分类准确性，同时添加度量学习损失，以提高模型的泛化能力与特征表示水平，度量学习的核心要点是打造三元组，该实现利用函数 `get_triplets` 得以完成。该函数接收一批数据的嵌入向量和对应标签，遍历每个样本，将当前样本作为锚点，选择同一类别中另一个样本作为正样本，以及选择类别不同的样本作为负样本。通过这种方式构造的三元组能够用于计算三元组损失，该损失通过保证锚点与正样本之间的距离小于锚点与负样本之间的距离（且两者差距不小于预设的 `margin`）来优化嵌入空间。最终，在本地训练中，各项损失被组合为总损失函数：

$$F(\theta_i; h_i, D_i, w) = L_i(\theta_i) + T_i(h_i, \theta_i, w) + G_i(\theta_i; g_i, g) + \lambda_{\text{metric}} \cdot \text{loss_metric} \quad (4-5)$$

其中， $L_i(\theta_i)$ 为交叉熵损失， $T_i(h_i, \theta_i, w)$ 表示前面提到的混合化项， $G_i(\theta_i; g_i, g)$ 为降低局部梯度方差的梯度校正项， λ_{metric} 作为超参数调节度量学习损失在整体损失中的贡献。

5.3 实验结果与分析

5.3.1 实验设置

本实验在数据集预处理和数据集的划分上与 3.4.1 节以及 4.3.1 节大致相同，实验场景也与前面章节相同，即在三种场景下进行实验：`iid`、`non-iid(0.3)` 以及 `non-iid(0.6)` 环境。在 `FedReg*` 的基础上应用度量学习，优化联邦学习本地训练，以验证度量学习对于联邦学习性能的优化。

具体的实验参数设置和 3.4.1 节大致相同：本地训练批次大小设为 50；每轮通信中，本地训练周期（`epoch`）设为 5；初始学习率为 0.1，学习率衰减率设为 0.998；通信轮次总数设置为 600；每轮参与训练的客户端比例为 15%。L2 正则化项超参数设置为 0.01，L1 正则化项超参数设置为 0.01/100，度量学习权重设置为 0.1。

主要关注以下两个评价指标：模型准确率：在 `CIFAR10` 和 `CIFAR100` 测试

集上的分类准确率，用以衡量模型的预测性能。通信效率：到达预定精度所需的通信轮次数，以比较不同方法在通信开销上的差异。

5.3.2 实验结果

(1)模型准确度

如表 5-1 所示，在 Cifar100 数据集上，无论是在 iid 还是 non-iid (0.3 和 0.6) 分布下，MetricFedReg 均取得了最高的 top-1 准确度。例如，在 iid 分布下，MetricFedReg 达到了 56.81%，较 FedReg* 的 55.64% 提升了约 1.17 个百分点；在 0.3 分布下分别为 55.71% 和 54.74%，在 0.6 分布下则为 56.02% 对比 54.60%。在 Cifar10 数据集上，MetricFedReg 同样领先，iid 分布下达到 86.42% (比 FedReg 高约 0.86 个百分点)，而在 0.3 和 0.6 分布下分别达到 85.73% 和 86.57%，均明显优于 FedReg*。这些结果表明，在 FedReg* 的基础上引入度量学习机制能够极大的提高模型的测试准确度。图 5-1、图 5-2 以及图 5-3 分别展示了在 Cifar100 数据集(iid)、Cifar100 数据集(non-iid 为 0.3)、Cifar10 数据集(non-iid 为 0.6)场景下不同方法在测试准确度随通信轮次变化图，明显看出随着训练轮次增加，MetricFedReg 在测试准确度上一直远超 FedReg*。

表 5-1 不同方法在不同数据集不同数据分布下的 top-1 测试准确度对比
Table 5-1 Comparison of top-1 test accuracy of different methods with different data distributions in different datasets

数据集	数据分布 (iid/non-iid)	方法(top-1 准确度)			
		MetricFedReg	FedReg*	FedReg	FedDC
Cifar100	iid	56.81%	55.64%	55.25%	55%
	0.3	55.71%	54.74%	54.18%	53.84%
	0.6	56.02%	54.60%	55.21%	53.95%
Cifar10	iid	86.42%	85.56%	85.52%	85.40%
	0.3	85.73%	85.11%	84.84%	83.78%
	0.6	86.57%	85.89%	85.15%	84.76%

(2)通信效率

如表 5-2 所示，在达到相同目标准确度的情况下，MetricFedReg 在通信效率上明显高过 FedReg*。在 Cifar100 数据集的 iid 分布下，MetricFedReg 只需 205

轮即可达到 54% 的准确度，而 FedReg* 则需要 331 轮，节省了 126 轮；在 0.3 和 0.6 分布下，MetricFedReg 分别需 323 轮和 290 轮，相较于 FedReg* 的 350 轮和 327 轮，也分别减少了 27 和 37 轮。在 Cifar10 数据集中，MetricFedReg 在 iid、0.3 和 0.6 分布下分别需 204、278 和 224 轮，而 FedReg* 则分别为 253、325 和 264 轮，相应减少了 49、47 和 40 轮。上述数据表明，通过在 FedReg* 基础上引入度量学习机制，MetricFedReg 能够更精准地捕捉和衡量客户端模型更新之间的差异，以此加快全局模型收敛的速度，显著提高了通信效率。

表 5-2 不同方法在不同数据集不同数据分布下到达相同准确度所需通信轮次对比对比
Table 5-2 Comparison of the number of communication rounds required for different methods to reach the same accuracy under different data distributions in different datasets

数据集	数据分布 (目标准确度)	方法（通信轮次）			
		MetricFed -Reg	FedReg*	FedReg	FedDC
Cifar100	iid (54%)	205	331	376	421
	0.3(54%)	323	350	363	398
	0.6(54%)	290	327	356	426
Cifar10	iid(84%)	204	253	281	304
	0.3(84%)	278	325	305	377
	0.6(84%)	224	264	276	306




图 5-1 不同方法在 Cifar100(iid) 的测试准确度随通信轮次变化图

Fig 5-1 test accuracy of different methods on Cifar100 (iid) with communication rounds




图 5-2 不同方法在 Cifar100(non-iid 为 0.3)的测试准确度随通信轮次变化图
Fig 5-2 test accuracy of different methods on Cifar100 (non-iid of 0.3) with communication rounds




图 5-3 不同方法在 Cifar10(non-iid 为 0.6)的测试准确度随通信轮次变化图
Fig 5-3 test accuracy of different methods on Cifar10 (non-iid of 0.6) with communication rounds

5.4 本章小结

本章先是介绍了度量学习的概念，以及度量学习在联邦学习中如何应用。在 FedReg*基础上，在本地训练阶段添加了度量学习机制，以推动各客户端在训练时

学到有更佳区分性的特征嵌入，由此增强全局模型在数据异构环境下的鲁棒性。通过对比实验数据，在 Cifar100 和 Cifar10 数据集上，不管是在测试准确度上还是在通信效率上，MetricFedReg 均优于 FedReg*。

6. 结论与展望

6.1 研究结论

论文主要研究了联邦学习在非独立同分布（Non-IID）场景下，数据样本之间的分布存在显著差异，带来的客户端漂移现象，进而对联邦学习的训练和性能带来了挑战的问题。并提出了三点改进方案，保证全局模型能够在面对异质数据时依然具备良好的泛化能力。

论文首先介绍了联邦学习的研究背景和意义、研究现状以及在非独立同分布场景下联邦学习所遇到的客户端漂移问题，通过对当前研究工作的总结引出可能解决客户端漂移问题的几种思路，进而介绍论文的研究内容。

为解决前人运用 L2 正则化对与漂移变量有关的近端项进行约束时存在难以达成自动的特征筛选，不利于模型对重要特征展开自动识别和利用，因而可能造成整体性能受影响的问题，论文提出采用混合正则化改进联邦学习的本地训练进程，在原有 L2 正则化对和漂移变量有关的近端项加以约束的基础上，再额外添加 L1 正则化来约束漂移变量。该混合正则化方法在联邦学习场景之中展现出更好的适应性，适应不同客户端所具有的数据分布，通过在 CIFAR100 和 CIFAR10 数据集实施的实验，验证了借助混合正则化改进的联邦学习模型在非独立同分布情形下优于其他基准模型。

为了进一步解决上述方法尽管通过引入混合正则化改善了每个客户端的本地模型训练效果，但在全局模型聚合阶段依然依照传统的联邦平均算法思路来做，导致忽略每个客户端的个性化特征，进而造成了个性化联邦学习效果受限的问题。论文使用余弦相似度来发觉不同客户端模型跟全局模型之间的方向性一致性，进而为每个客户端模型赋予各不相同的重要性权重，以更准确地反映各客户端对全局模型优化的实际贡献。通过在 CIFAR100 和 CIFAR10 数据集进行实验，验证了利用余弦相似度改进的联邦学习模型能够在非独立同分布场景下优于只利用混合正则化方法改进。

为使各客户端在训练时学习到具有更好区分性的特征嵌入，从而提高全局模型在数据异构环境下的鲁棒性，论文提出了基于度量学习优化联邦学习本地训练。在本地训练过程中引入度量学习损失，以提升模型的泛化能力和特征表示质量。并且在先前论文的改进上进行对比实验，实验结果表明在联邦学习本地引入度量学习损失的确使得模型的性能得到了改进。

6.2 研究展望

尽管以上对联邦学习的三点改进使得联邦学习在非独立同分布场景下的性能得了一定的提升，但是还有很多不足之处，后续还需要做更深入的研究。可以继续深入研究的方向包括但不限于以下几点。

（1）论文的实验仅在两个公开数据集（CIFAR100 和 CIFAR10）上进行，这在一定程度上限制了算法在更复杂和多样化场景中的适用性。未来工作可以考虑在更多的且更复杂的公开数据集上进行实验。

（2）除了提升模型准确度和通信效率外。未来的研究可聚焦于防御对抗攻击和恶意客户端，通过合理恶意设计识别机制，在保证性能的同时，进一步增强系统的安全性。

（3）在实际场景中，尤其是大规模分布式设备环境下，如何在有限带宽和计算资源的约束下使得模型效果仍然高效是一种挑战。未来可以结合模型剪枝，设计轻量化的模型结构和高效的局部更新策略，进一步降低通信开销和计算负担。

参 考 文 献

- [1] Konečný J, McMahan H B, Yu F X, et al. Federated learning: Strategies for improving communication efficiency[J]. arXiv preprint arXiv:1610.05492, 2016.
- [2] Li L, Fan Y, Tse M, et al. A review of applications in federated learning[J]. Computers & Industrial Engineering, 2020, 149: 106854.
- [3] Zhang C, Xie Y, Bai H, et al. A survey on federated learning[J]. Knowledge-Based Systems, 2021, 216: 106775.
- [4] Wen J, Zhang Z, Lan Y, et al. A survey on federated learning: challenges and applications[J]. International Journal of Machine Learning and Cybernetics, 2023, 14(2): 513-535.
- [5] Kairouz P, McMahan H B, Avenet B, et al. Advances and open problems in federated learning[J]. Foundations and trends® in machine learning, 2021, 14(1–2): 1-210.
- [6] Li Q, He B, Song D. Model-contrastive federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 10713-10722.
- [7] Zhao Y, Li M, Lai L, et al. Federated learning with non-iid data[J]. arXiv preprint arXiv:1806.00582, 2018.
- [8] Banabilah S, Aloqaily M, Alsayed E, et al. Federated learning review: Fundamentals, enabling technologies, and future applications[J]. Information processing & management, 2022, 59(6): 103061.
- [9] Rieke N, Hancox J, Li W, et al. The future of digital health with federated learning[J]. NPJ digital medicine, 2020, 3(1): 119.
- [10] Tan A Z, Yu H, Cui L, et al. Towards personalized federated learning[J]. IEEE transactions on neural networks and learning systems, 2022, 34(12): 9587-9603.
- [11] Li X, Huang K, Yang W, et al. On the convergence of fedavg on non-iid data[J]. arXiv preprint arXiv:1907.02189, 2019.
- [12] T Dinh C, Tran N, Nguyen J. Personalized federated learning with moreau envelopes[J]. Advances in neural information processing systems, 2020, 33:

21394-21405.

- [13] Huang Y, Chu L, Zhou Z, et al. Personalized cross-silo federated learning on non-iid data[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(9): 7865-7873.
- [14] Yuan X, Li P. On convergence of fedprox: Local dissimilarity invariant bounds, non-smoothness and beyond[J]. Advances in Neural Information Processing Systems, 2022, 35: 10752-10765.
- [15] Yin X, Zhu Y, Hu J. A comprehensive survey of privacy-preserving federated learning: A taxonomy, review, and future directions[J]. ACM Computing Surveys (CSUR), 2021, 54(6): 1-36.
- [16] Truex S, Baracaldo N, Anwar A, et al. A hybrid approach to privacy-preserving federated learning[C]//Proceedings of the 12th ACM workshop on artificial intelligence and security. 2019: 1-11.
- [17] Liu Y, James J Q, Kang J, et al. Privacy-preserving traffic flow prediction: A federated learning approach[J]. IEEE Internet of Things Journal, 2020, 7(8): 7751-7763.
- [18] Bonawitz K, Ivanov V, Kreuter B, et al. Practical secure aggregation for privacy-preserving machine learning[C]//proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security. 2017: 1175-1191.
- [19] Xie Q, Jiang S, Jiang L, et al. Efficiency optimization techniques in privacy-preserving federated learning with homomorphic encryption: A brief survey[J]. IEEE Internet of Things Journal, 2024, 11(14): 24569-24580.
- [20] Pei J, Liu W, Li J, et al. A review of federated learning methods in heterogeneous scenarios[J]. IEEE Transactions on Consumer Electronics, 2024.
- [21] Zhao Z, Mao Y, Liu Y, et al. Towards efficient communications in federated learning: A contemporary survey[J]. Journal of the Franklin Institute, 2023, 360(12): 8669-8703.
- [22] Kishor K. Communication-efficient federated learning[M]//Federated Learning for IoT Applications. Cham: Springer International Publishing, 2022: 135-156.
- [23] Wen J, Zhang Z, Lan Y, et al. A survey on federated learning: challenges and

- applications[J]. International Journal of Machine Learning and Cybernetics, 2023, 14(2): 513-535.
- [24] Guan H, Yap P T, Bozoki A, et al. Federated learning for medical image analysis: A survey[J]. Pattern Recognition, 2024: 110424.
- [25] Guo K, Chen T, Ren S, et al. Federated learning empowered real-time medical data processing method for smart healthcare[J]. IEEE/ACM Transactions on Computational Biology and Bioinformatics, 2022.
- [26] Imteaj A, Thakker U, Wang S, et al. A survey on federated learning for resource-constrained IoT devices[J]. IEEE Internet of Things Journal, 2021, 9(1): 1-24.
- [27] Xing H, Simeone O, Bi S. Federated learning over wireless device-to-device networks: Algorithms and convergence analysis[J]. IEEE Journal on Selected Areas in Communications, 2021, 39(12): 3723-3741.
- [28] Llisterri Giménez N, Monfort Grau M, Pueyo Centelles R, et al. On-device training of machine learning models on microcontrollers with federated learning[J]. Electronics, 2022, 11(4): 573.
- [29] Rey V, Sánchez P M S, Celdrán A H, et al. Federated learning for malware detection in IoT devices[J]. Computer Networks, 2022, 204: 108693.
- [30] Cho H, Mathur A, Kawsar F. Flame: Federated learning across multi-device environments[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2022, 6(3): 1-29.
- [31] Lu Z, Pan H, Dai Y, et al. Federated learning with non-iid data: A survey[J]. IEEE Internet of Things Journal, 2024.
- [32] Luo M, Chen F, Hu D, et al. No fear of heterogeneity: Classifier calibration for federated learning with non-iid data[J]. Advances in Neural Information Processing Systems, 2021, 34: 5972-5984.
- [33] Zhang J, Guo S, Qu Z, et al. Adaptive federated learning on non-iid data with resource constraint[J]. IEEE Transactions on Computers, 2021, 71(7): 1655-1667.
- [34] Liu S, Yu G, Chen X, et al. Joint user association and resource allocation for wireless hierarchical federated learning with IID and non-IID data[J]. IEEE

- Transactions on Wireless Communications, 2022, 21(10): 7852-7866.
- [35] Zeng Y, Mu Y, Yuan J, et al. Adaptive federated learning with non-IID data[J]. The Computer Journal, 2023, 66(11): 2758-2772.
 - [36] Shi Y, Zhang Y, Xiao Y, et al. Optimization strategies for client drift in federated learning: a review[J]. Procedia Computer Science, 2022, 214: 1168-1173.
 - [37] Varno F, Saghai M, Rafiee Sevyeri L, et al. Adabest: Minimizing client drift in federated learning via adaptive bias estimation[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 710-726.
 - [38] Venkatesha Y, Kim Y, Park H, et al. Addressing client drift in federated continual learning with adaptive optimization[J]. Available at SSRN 4188586, 2022.
 - [39] Shen T, Li Z, Li Y, et al. FedEve: On Bridging the Client Drift and Period Drift for Cross-device Federated Learning[J]. 2023.
 - [40] Kang H, Kim M, Lee B, et al. FedAND: Federated learning exploiting consensus ADMM by nulling drift[J]. IEEE Transactions on Industrial Informatics, 2024.
 - [41] Jiang X, Rodomanov A, Stich S U. Federated optimization with doubly regularized drift correction[J]. arXiv preprint arXiv:2404.08447, 2024.
 - [42] Jeong E, Oh S, Kim H, et al. Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data[J]. arXiv preprint arXiv:1811.11479, 2018.
 - [43] Zhao Y, Li M, Lai L, et al. Federated learning with non-iid data[J]. arXiv preprint arXiv:1806.00582, 2018.
 - [44] Babendererde N, Fuchs M, Gonzalez C, et al. Jointly exploring client drift and catastrophic forgetting in dynamic learning[J]. Scientific Reports, 2025, 15(1): 5857.
 - [45] Thomas J, Saile F, Fischer M, et al. Adaption via selection: on client selection to counter concept drift in federated learning[C]//European Conference on Service-Oriented and Cloud Computing. Cham: Springer Nature Switzerland, 2025: 3-17.
 - [46] Jothimurugesan E, Hsieh K, Wang J, et al. Federated learning under distributed concept drift[C]//International Conference on Artificial Intelligence and Statistics.

- PMLR, 2023: 5834-5853.
- [47] Cheng K, Fan T, Jin Y, et al. Secureboost: A lossless federated learning framework[J]. IEEE intelligent systems, 2021, 36(6): 87-98.
 - [48] Liu J, Huang J, Zhou Y, et al. From distributed machine learning to federated learning: A survey[J]. Knowledge and Information Systems, 2022, 64(4): 885-917.
 - [49] Zeng D, Liang S, Hu X, et al. Fedlab: A flexible federated learning framework[J]. Journal of Machine Learning Research, 2023, 24(100): 1-7.
 - [50] Jamali-Rad H, Abdizadeh M, Singh A. Federated learning with taskonomy for non-IID data[J]. IEEE transactions on neural networks and learning systems, 2022, 34(11): 8719-8730.
 - [51] Abdel-Basset M, Hawash H, Moustafa N, et al. Privacy-preserved learning from non-iid data in fog-assisted IoT: A federated learning approach[J]. Digital Communications and Networks, 2024, 10(2): 404-415.
 - [52] Jhunjhunwala D, Sharma P, Nagarkatti A, et al. Fedvarp: Tackling the variance due to partial client participation in federated learning[C]//Uncertainty in Artificial Intelligence. PMLR, 2022: 906-916.
 - [53] Tang Z, Zhang Y, Shi S, et al. Fedimpro: Measuring and improving client update in federated learning[J]. arXiv preprint arXiv:2402.07011, 2024.
 - [54] Moradi R, Berangi R, Minaei B. A survey of regularization strategies for deep models[J]. Artificial Intelligence Review, 2020, 53(6): 3947-3986.
 - [55] Kukačka J, Golkov V, Cremers D. Regularization for deep learning: A taxonomy[J]. arXiv preprint arXiv:1710.10686, 2017.
 - [56] Shoham N, Avidor T, Keren A, et al. Overcoming forgetting in federated learning on non-iid data[J]. arXiv preprint arXiv:1910.07796, 2019.
 - [57] Santos C F G D, Papa J P. Avoiding overfitting: A survey on regularization methods for convolutional neural networks[J]. ACM Computing Surveys (Csur), 2022, 54(10s): 1-25.
 - [58] Xia P, Zhang L, Li F. Learning similarity with cosine similarity ensemble[J]. Information sciences, 2015, 307: 39-52.

- [59] Kaya M, Bilge H Ş. Deep metric learning: A survey[J]. Symmetry, 2019, 11(9): 1066.
- [60] Singla S, Singla S, Feizi S. Improved deterministic l2 robustness on CIFAR-10 and CIFAR-100[J]. arXiv preprint arXiv:2108.04062, 2021.
- [61] Gao L, Fu H, Li L, et al. Feddc: Federated learning with non-iid data via local drift decoupling and correction[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10112-10121.
- [62] Karimireddy S P, Kale S, Mohri M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]//International conference on machine learning. PMLR, 2020: 5132-5143.
- [63] Acar D A E, Zhao Y, Navarro R M, et al. Federated learning based on dynamic regularization[J]. arXiv preprint arXiv:2111.04263, 2021. Li L, Fan Y, Tse M, et al. A review of applications in federated learning[J]. Computers & Industrial Engineering, 2020, 149: 106854.
- [64] Dehak N, Dehak R, Glass J R, et al. Cosine similarity scoring without score normalization techniques[C]//Odyssey. 2010, 15.
- [65] Li B, Han L. Distance weighted cosine similarity measure for text classification[C]//Intelligent Data Engineering and Automated Learning–IDEAL 2013: 14th International Conference, IDEAL 2013, Hefei, China, October 20-23, 2013. Proceedings 14. Springer Berlin Heidelberg, 2013: 611-618.
- [66] Luo C, Zhan J, Xue X, et al. Cosine normalization: Using cosine similarity instead of dot product in neural networks[C]//Artificial Neural Networks and Machine Learning–ICANN 2018: 27th International Conference on Artificial Neural Networks, Rhodes, Greece, October 4-7, 2018, Proceedings, Part I 27. Springer International Publishing, 2018: 382-391.
- [67] Kedem D, Tyree S, Sha F, et al. Non-linear metric learning[J]. Advances in neural information processing systems, 2012, 25.
- [68] Yang L, Jin R. Distance metric learning: A comprehensive survey[J]. Michigan state university, 2006, 2(2): 4.
- [69] Bellet A, Habrard A, Sebban M. A survey on metric learning for feature vectors

- and structured data[J]. arXiv preprint arXiv:1306.6709, 2013.
- [70] Zhuang F, Moulin P. Deep semi-supervised metric learning with mixed label propagation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 3429-3438.
- [71] Liu C, Yang G, Zuo W, et al. MetricDepth: Enhancing Monocular Depth Estimation with Deep Metric Learning[J]. arXiv preprint arXiv:2412.20390, 2024.