

单位代码：10610

学 号：2021223045211

四川大學

硕士研究生学位论文

（专业学位）

题目： 面向非独立同分布数据的
个性化联邦学习算法研究

培养单位： 计算机学院（软件学院）

作者姓名： 唐剑吾

指导教师： 蒋玉明教授

学位类别： 工程硕士

领域名称： 人工智能

论文答辩时间：二〇二四年五月

学位授予时间：二〇二四年六月

**Research on Personalised Federated Learning Algorithms
for Non-Independent and Identically Distributed Data**

**A dissertation submitted to Sichuan University
in partial fulfillment of the requirements
for the degree of
Master of Engineering
in computer technology**

**By
Jianwu Tang
Supervisor: Prof. Yuming Jiang**

**Computer Science, Sichuan University, Chengdu, China
Date June 2024**

摘 要

人工智能的发展与数据规模的增長促使深度学习在各类任务中大获成功，但其成效显著依赖于数据量的大小。单一服务器的训练往往私有数据量不足，同时数据类别存在一定局限，分布式共享数据则存在数据隐私安全的问题。联邦学习能够在用户数据隐私受限的场景下完成多方协同训练，打破节点间的“数据孤岛”现象。目前，联邦学习已在金融、医疗等领域被广泛应用。

然而联邦学习的应用实践也面临着诸多挑战，其中非独立同分布数据导致的模型性能不佳是制约联邦学习的核心问题。现实场景中各参与方所拥有的数据往往具备不同的标签分布和数据倾斜，极大影响了联邦学习模型的收敛效率和模型准确率。同时目前主流的联邦学习算法主要通过共享模型参数的方式进行协作训练，限制了各参与方针对自身需求独立设计个性化模型结构。本文围绕上述问题展开研究，针对联邦学习在本地训练和全局聚合两个阶段，分别提出了基于协作知识蒸馏的个性化联邦学习方法 FedCRD 和基于生成对抗网络的联邦学习全局聚合方法 FedGA，对不同训练过程的知识遗忘现象进行了改进优化。主要研究内容如下：

(1) 针对联邦学习本地训练阶段的知识遗忘现象和个性化训练问题，提出基于协作蒸馏的本地训练优化方法 FedCRD，同时引入关系知识结合响应知识共同蒸馏以提升正向知识传输，增强模型训练的鲁棒性。并且，该方法将全局模型与本地模型解耦，使各参与方能够根据自身条件和需求定制个性化的本地模型结构，突破传统联邦学习要求模型一致的限制。最后，将 FedCRD 与 FedAvg 在不同数据集和分布场景下进行比较，实验结果表明 FedCRD 在测试准确率和收敛速度上均优于 FedAvg。

(2) 针对联邦学习全局聚合阶段的模型知识遗忘、精度下降与泛化效果不佳问题，提出基于生成器对抗训练的改进方法 FedGA。该方法通过将生成器与聚合后的全局模型对抗训练，针对性地挖掘全局模型聚合后丢失的知识并通过知识蒸馏重新指导模型训练。同时，针对生成器输出样本的“模式坍塌”问题和不同参与方模型的蒸馏知识贡献比例提出优化方法，引入对应损失模块以分别提升样本多样性及蒸馏知识质量。最后，将 FedGA 与 FedAvg 在不同场景下进行比较，实验结果表明 FedGA 能够有效帮助全局模型聚合，使模型测试准确率及收敛速度得到提升。

(3) 将提出的联邦学习本地训练与全局聚合优化方法进行整合并形成 FedCGA 算法，将两个互补性的方法结合并使其相互促进，保证高质量知识传输学习。通过不同分布划分及不同激活比例场景下的实验对比，验证了该算法在非独立同分布数据下对比基线算法的优越性。

关键词：联邦学习；非独立同分布；知识蒸馏；生成对抗网络；自适应权重

Abstract

The development of artificial intelligence and the growth of data scales have contributed to the success of deep learning in a wide variety of tasks, but its effectiveness is significantly depended on the data volume. A single-server training often has insufficient private data volume, as well as certain limitations in data categories, while distributed sharing of data has data privacy and security issues. Federated Learning is an approach that enables multi-party collaborative training in scenarios where user data privacy is restricted, and can break the phenomenon of "data isolation" between nodes. At present, Federated Learning has been widely used in finance, healthcare and other fields.

However, the application practice of Federated Learning also faces many challenges, in which the poor model performance caused by non-independent identical distributed data is the core problem that restricts Federated Learning. In real-world scenarios, the data owned by each participant often has different label distributions and data skews, which greatly affects the convergence efficiency and model accuracy of Federated Learning models. Meanwhile, the current mainstream Federated Learning algorithms mainly share model parameters for collaborative training, which restricts each participant from independently designing their own personalised model structure for their own needs. In this paper, we focus on the above problems and propose FedCRD, a personalised Federated Learning method based on collaborative knowledge distillation, and FedGA, a Federated Learning global aggregation method based on Generative Adversarial Networks, to improve and optimise the knowledge forgetting phenomenon in different training processes, respectively, for local training and global aggregation of Federated Learning. The main research content is as follows:

(1) Aiming at the knowledge forgetting phenomenon and personalised training problem in the local training phase of Federated Learning, we propose FedCRD, a local training optimisation method based on collaborative distillation, while introducing relational knowledge combined with response knowledge to improve the positive knowledge transfer and enhance the robustness of model training. Moreover, the method decouples the global model and the local model, so that each participant can customise the personalized local model structure according to its own conditions and needs, breaking through the restriction of traditional Federated Learning that requires model homogeneity. Finally, FedCRD is compared with FedAvg under different datasets and distribution scenarios, and the experimental results show that FedCRD outperforms FedAvg in terms of test accuracy and convergence speed.

(2) Aiming at the problems of knowledge forgetting, accuracy degradation and poor generalisation in the global aggregation phase of Federated Learning, we propose FedGA, an improved method based on the adversarial training with a generator, which is trained against the aggregated global model, to exploit the lost knowledge of the aggregated global model and guide the training again through knowledge distillation. Meanwhile, an optimisation method is proposed to address the "pattern collapse" problem of the generator output samples and the distillation knowledge contribution ratio of different participant models, and different loss modules are introduced to improve the sample diversity and distillation knowledge quality, respectively. Finally, FedGA is compared with FedAvg in different scenarios, and the experimental results show that FedGA can effectively help the global model aggregation and improve the model testing accuracy and convergence speed.

(3) The proposed Federated Learning local training and global aggregation optimal methods are integrated and formed into the FedCGA algorithm, which combines the two complementary methods and makes them mutually reinforcing to jointly learn high-quality knowledge. The superiority of the algorithm over the baselines under non-independent identical distributed data is verified through experiments in different scenarios.

Key words: Federated Learning; Non-IID; Knowledge Distillation; Generative Adversarial Networks; Adaptive Weights

目 录

第 1 章 引言.....	1
1.1 选题背景及意义.....	1
1.2 国内外研究现状.....	5
1.2.1 Non-IID 数据下的个性化联邦学习.....	5
1.2.2 联邦学习的通信效率.....	8
1.2.3 联邦学习的激励机制.....	8
1.3 研究内容与实施框架.....	9
1.4 主要创新点.....	11
1.5 本文结构安排.....	12
第 2 章 预备知识及相关理论技术	13
2.1 神经网络.....	13
2.1.1 前馈神经网络.....	13
2.1.2 卷积神经网络.....	15
2.1.3 残差神经网络.....	16
2.1.4 VGG 神经网络	17
2.1.5 神经网络模型训练.....	17
2.2 分布式机器学习.....	18
2.3 联邦学习.....	19
2.4 联邦学习中的 Non-IID 数据.....	21
2.4.1 Non-IID 数据简介	22
2.4.2 Non-IID 数据造成的权重发散.....	23
2.5 知识蒸馏.....	25
2.5.1 基于响应的知识蒸馏.....	26
2.5.2 基于关系的知识蒸馏.....	26
2.5.3 基于特征的知识蒸馏.....	27
2.6 生成对抗网络.....	27
第 3 章 基于协作知识蒸馏的本地训练方法	29
3.1 Non-IID 数据下的知识遗忘.....	29
3.1.1 基于 Dirichlet 分布生成的 Non-IID 数据	31
3.2 协作与关系蒸馏模式.....	31
3.2.1 联邦学习问题定义.....	32
3.2.2 本地训练的协作蒸馏方式.....	33
3.2.3 关系知识蒸馏.....	34
3.2.4 蒸馏知识的自适应权重调节.....	35

3.3 实验与分析.....	36
3.3.1 实验环境.....	36
3.3.2 数据集选取与划分方式.....	37
3.3.3 模型选取与超参数设置.....	38
3.3.4 实验结果.....	39
3.4 小结.....	46
第4章 基于生成对抗网络的全局聚合方法	47
4.1 Non-IID 数据下全局聚合问题分析.....	47
4.2 基于生成器对抗训练的聚合调优策略	48
4.2.1 生成器挖掘数据与蒸馏学习.....	49
4.2.2 生成数据多样性.....	50
4.2.3 整体损失函数.....	51
4.2.4 动态权重系数.....	52
4.3 实验与分析.....	52
4.3.1 实验设置.....	52
4.3.2 实验结果.....	53
4.4 小结.....	57
第5章 FedCGA 算法集成与验证	59
5.1 本地训练与全局聚合优化方法集成	59
5.2 实验与分析.....	61
5.2.1 推理准确率对比.....	61
5.2.2 超参数实验.....	63
5.2.3 模型泛化与个性化能力.....	64
5.2.4 权重发散.....	65
5.2.5 模型异构场景测试精度.....	66
5.3 小结.....	67
第6章 结论与展望	69
6.1 结论.....	69
6.2 展望.....	70
参考文献.....	71

图目录

图 1.1 联邦学习总体框架	2
图 1.2 横向联邦学习	3
图 1.3 纵向联邦学习	3
图 1.4 联邦迁移学习	4
图 1.5 研究内容及实施框架	10
图 2.1 神经元模型	14
图 2.2 感知机模型	14
图 2.3 卷积神经网络	15
图 2.4 残差神经网络	17
图 2.5 联邦学习的漂移现象	23
图 2.6 FedAvg 在不同分布场景下的权重发散	24
图 2.7 知识蒸馏模型结构	25
图 2.8 基于响应的知识蒸馏	26
图 2.9 基于关系的知识蒸馏	26
图 2.10 基于特征的知识蒸馏	27
图 2.11 生成对抗网络模型	28
图 3.1 联邦学习的知识遗忘现象	30
图 3.2 本地训练及全局聚合阶段的遗忘现象	30
图 3.3 FedCRD 整体结构	33
图 3.4 蒸馏知识的自适应调整过程	35
图 3.5 不同 β 下数据划分情况	38
图 3.6 CIFAR-10 不同 Non-IID 场景下各算法性能对比	40
图 3.7 CIFAR-100 不同数据分布场景下各算法性能对比	41
图 3.8 FMNIST 在 $\beta = 0.01$ 场景下各算法性能对比	42
图 3.9 模型异构场景下各参与方模型推准确率	43
图 3.10 不同 Non-IID 程度 β 及活跃比例 C 下测试准确率	44
图 3.11 超参数 η 对算法准确率的影响	45
图 4.1 FedGA 聚合训练过程	48
图 4.2 生成遗忘样本纠正全局模型拟合	51
图 4.3 CIFAR-10 数据集在不同分布场景下的算法性能对比	54
图 4.4 CIFAR-100 数据集在不同分布场景下的算法性能对比	55

图 4.5 FMNIST 数据集 $\beta = 0.01$ 分布场景下算法性能	55
图 4.6 不同分布场景 β 及系数 λ_G 对 FedGA 的影响.....	56
图 4.7 不同本地训练轮数 E 对算法准确率的影响	57
图 5.1 FedCGA 算法集成框架.....	59
图 5.2 FedCGA 关键步骤.....	60
图 5.3 FedCGA 及基线算法在不同场景下的模型性能.....	62
图 5.4 不同 Non-IID 程度及参与方活跃比例对算法精度的影响	64
图 5.5 FedCGA 与基线算法的全局/本地模型精度比较.....	65
图 5.6 FedCGA 权重发散.....	66
图 5.7 FedCGA 在模型异构场景下的推理准确率.....	67

表目录

表 2.1 CIFAR10 数据集下 FedAvg 的权重发散	24
表 3.1 实验环境配置信息	37
表 3.2 数据集信息	37
表 3.3 CNN 模型结构	39
表 3.4 各算法在 IID 场景下的性能对比	40
表 3.5 不同活跃比例 C 对各算法性能的影响	44
表 3.6 不同算法模块对 FedCRD 的影响	45
表 4.1 生成器 CGAN 模型结构	53
表 4.2 不同算法模块对 FedGA 的影响	57
表 5.1 不同活跃比例 C 下各算法性能对比	64

第1章 引言

1.1 选题背景及意义

现阶段人工智能（Artificial Intelligence, AI）在大数据和硬件算力的支撑下蓬勃发展，机器学习模型强大的数据处理和泛化能力正逐渐改变人类生活。其中，大数据作为 21 世纪信息技术与人工智能领域的关键创新要素，正以前所未有的深度和广度影响着全球经济活动的各个环节，包括生产过程的智能化、供应链的优化管理、商品和服务的精准推送以及消费需求的个性化预测等。党的十九大和 2018 年全国网络安全和信息化工作会议等多次强调推动互联网、大数据、人工智能和实体经济的深度融合，大数据的发展已上升至国家战略层面^[1]。然而，如何有效收集、获取并整合利用高质量数据依然是制约 AI 技术进一步突破的关键瓶颈，解决这一问题有助于释放 AI 更大的潜力。大数据不仅是新一轮工业革命的核心动力之一，推动着制造业向智能制造和服务业向智慧服务转型，而且其作为新型生产要素的地位已上升至与传统的劳动、资本、土地要素同等重要的位置，在资源配置和价值创造过程中发挥着不可或缺的作用。在数字经济的高速发展下，大数据如同创新发展的引擎，持续地孕育出新颖的商业模式和经济增长点。

AI 的迅猛发展建立在对大数据的需求之上，然而目前深度学习仍以集中式学习为主，即将各方数据集中汇聚于中心服务器进行存储和训练。这种集中式学习的方式存在带宽与存储压力，中心化存储易受到黑客攻击威胁，同时还有最重要的数据隐私难题。随着人们对数据安全问题的重视，数据安全方面的监管也愈加严密。在数据安全保障方面，监管力度正日趋强化。2018 年欧盟出台了有史以来最为严格的网络数据管理法规——《通用数据保护条例》^[2]，该法规全方位增强了全体网络用户的数据隐私权益保障，并明确加重了企业对于数据保护的法律责任。深度学习的研究与应用中，充分且高质量的训练数据是实现其强大功能与精准预测能力的关键要素，但现实世界中除了部分大型企业外，其余中小型企业往往并没有充足且高质量的数据支撑其完成模型的训练任务。数据大量离散于不同公司、服务器之间分离存储，从而形成了封闭的数据壁垒并导致数据无法有效交互并整合利用。不同设备或组织收集到的数据难以物理汇聚并进行集中式学习，进而形成了由多个“数据孤岛”^[3]组成的分布式数据节点。将这类孤立数据从本地设备转移到中央服务器需要面临两个关键挑战：首先，该方法损害了数据的隐私和安全；其次，该方法增加了用户间通信开销。特别在医疗保健、工业金融等领域，拥有并维护大型数据集通常既困难又昂贵，同时需要维护用户数据的隐私安全。因此，在“数据孤岛”场景下高效地利用好数据，充分挖掘数据价

值并令企业更好地协同训练，是当前 AI 及大数据发展浪潮下的一大挑战。

在隐私保护及数据安全等法律法规的限制背景下，随着物联网（Internet of Things, IoT）^[4,5]、云计算^[6-9]等技术的蓬勃发展，联邦学习（Federated Learning, FL）^[10]的出现打破了各企业“数据孤岛”的场景，在近年来愈发流行并受到学者们的广泛研究。联邦学习是分布式机器学习的一个子领域，由谷歌于 2016 年首次提出并应用于其 Gboard 键盘产品中，能够以一种保护隐私的方式协作训练涉及多个数据源的神经网络模型。在 FL 范式下各参与方仅需共享模型梯度或参数即可完成训练，该方式能够有效保护各方数据隐私并降低数据传输的通信成本。具体地，联邦学习采用不共享数据而共享梯度/模型参数的方式，使各参与方在满足身份、地位平等的条件下，协作训练并构建出性能完善的全局机器学习模型。在该框架下，用户能够在本地保留自己的隐私数据避免泄露的同时，完成与其余用户的协作，打破“数据孤岛”所带来的窘境。图 1.1 展示了联邦学习的总体框架和流程。如图所示，在一个联邦学习系统中存在三个不同的企业 A、B、C。由于各企业拥有的私有数据量或是数据特征不足以支撑其独自进行机器学习训练，并且数据集中式的机器学习又会打破用户数据的隐私限制，各企业为了能协作训练得到较高性能的模型，采用了联邦学习的方式共同构建一个全局模型以实现协作共赢。在实际场景中，根据各参与方数据集中用户与特征的情况，可以将联邦学习分为三种场景。




图 1.1 联邦学习总体框架

Figure 1.1 Overall framework for Federated Learning

横向联邦学习指各参与方的数据具有相同的特征空间（即数据的结构和属性一致），但包含不同的样本实例。例如多家银行希望共同训练一个信用等级模型，其各自拥有的客户数据包含相同特征如年龄、收入、职业等，但不同银行的客户个体不一致。本

文的主要工作即基于横向联邦学习展开。图 1.2 展示了横向联邦学习场景。




图 1.2 横向联邦学习

Figure 1.2 Horizontal Federated Learning

纵向联邦学习（VFL）^[1]主要用于解决多参与方拥有相同样本实例但特征空间不一致的问题。如图 1.3 所示，该场景下各参与方拥有相同的数据个体，但仅持有该样本个体的部分特征。例如某区域银行拥有其区域客户的财务信息，而当地的电商公司拥有相同客户的购买行为、浏览行为信息。二者可通过纵向联邦学习的方式协同获得完整的用户画像以训练更为准确的模型。




图 1.3 纵向联邦学习

Figure 1.3 Vertical Federated Learning

联邦迁移学习是机器学习领域中的一门复合技术，其结合了联邦学习与迁移学习的特点。如图 1.4 所示，联邦迁移学习主要针对的是不同参与方之间，样本实例与特征空间重叠很小的情况。该方法能够跨越多个数据域进行模型学习，允许源域的模型知识迁移到目标域，例如两个城市的银行和保险公司想要合作开发一个风控模型，就可以采用联邦迁移学习进行协作训练。




图 1.4 联邦迁移学习

Figure 1.4 Federated Transfer Learning

在实际应用情境中，尽管联邦学习展现出了多方面的优势与潜力，然而其亦不可避免地面临一系列严峻挑战。其中最大的挑战源自于不同参与方的私有数据可能存在较大差异。在传统的集中式机器学习场景下，理想状态下的数据分布假设通常是独立同分布的（Independent and Identically Distributed, IID），这意味着训练数据中的每个样本都是独立抽取，并且服从相同的概率分布。然而在联邦学习场景中，由于不同参与方所拥有的数据在采集方式、用户差异性、数据类别、获取到的特征及数据数量级上都存在客观差异，从而形成了数据的非独立同分布（Non-Independently Identical Distribution, Non-IID）^[12]。Non-IID 现象为联邦学习带来了极大阻碍，其不但会影响模型收敛速度，而且会直接影响到全局模型的推理准确率。

数据的 Non-IID 一般分为以下几类：1）样本数量偏移；2）特征分布偏移；3）标签分布偏移；4）概念偏移。其中第三种情况在实际应用中对联邦学习影响尤甚，例如不同医院收治的患者病情数据可能标签分布（疾病类别）偏差较大，容易直接影响其联邦学习结果。集中式机器学习由于其训练数据集中于一处，只要训练数据准备得当，其模型拟合能力便能够得到保障。然而联邦学习中由于各参与方持有数据独立参与训练，分布不同所带来的数据倾斜和拟合偏差将严重削弱模型的训练效果，最终由服务器聚合后得到的全局模型其收敛速度和测试精度将会大受影响。因此，对 Non-IID 数据场景下的联邦学习算法进行性能优化具有重要的学术研究意义，亦能发挥联邦学习在实践应用层面的更大价值。

针对 Non-IID 数据所带来的挑战，个性化联邦学习作为一种应对策略被提出，旨在减轻 Non-IID 数据对模型性能带来的负面影响，并致力于全局与本地模型的平衡以适应本地数据，而不是仅追求训练较好的全局模型。个性化联邦学习通常从全局模型个性化和学习个性化的本地模型这两个方向入手，即提升全局模型泛化能力以更好适应不同参与方本地数据分布，或者为参与方或相似参与方训练更为个性化的本地模型。

目前我国正处在面向数字经济转型、产业化改革的关键阶段，智慧城市^[13,14]、智慧交通^[15]、智慧医疗^[16-20]、科技金融^[21-24]等概念近年来被广泛提及。作为实现数据隐私安全保护、打破数据孤岛的新兴分布式学习范式，联邦学习的大力发展和痛点解决显得尤为迫切。本文以 Non-IID 数据这一现实中广泛存在的场景作为背景，对个性化联邦学习性能优化方向进行研究，为该场景下模型收敛速度慢及推理精度低的难题提供了可行有效的解决思路，并实现了联邦学习各参与方独立定制个性化本地模型的需求。

1.2 国内外研究现状

数据隐私安全的研究发展历程可追溯至上世纪 80 年代的密码学相关研究，多方安全计算^[25,26]作为解决物联网中数据加密与共享之间矛盾的主要方法，在过去得到了广泛应用。随着 GDPR 等数据保护法规的出台，以及 AI、区块链等技术的广泛应用，多方安全计算与其他隐私保护技术如同态加密、差分隐私等相结合，形成了一套完整的数据隐私保护方案。然而，虽然这类方法能够一定程度上保证数据隐私，但其在深度学习应用背景下造成的大量累积错误与计算成本仍使其难以应用于深度学习训练任务。

谷歌于 2016 年首次提出了一种新颖的分布式机器学习方式，并将其称为联邦学习。联邦学习能够将各方隐私受限下的敏感数据保留在各方本地，不必像传统机器学习那样集中汇聚数据进行训练，取得了隐私保护和协同训练的平衡。同时谷歌也明确了联邦学习在研究应用中遭遇的核心难题，主要归类为网络带宽受限下的通信效率、数据 Non-IID 以及如何激励优质参与方参与等。McMahan 等人^[10]在该研究中提出了 FedAvg 算法，该算法已被普遍认可为基准模型，在众多研究应用中得以广泛采用。

联邦学习目前所面临的挑战主要集中于数据 Non-IID、通信开销、隐私保护和激励机制等方面^[27]。鉴于当前联邦学习的应用场景普遍面临着数据 Non-IID 环境下的挑战，同时本文也专注于探究该环境下的个性化联邦学习优化方法，故本节后续内容将重点聚焦于 Non-IID 数据下的个性化联邦学习研究现状。

1.2.1 Non-IID 数据下的个性化联邦学习

FedAvg 是传统经典的联邦学习范式，在每个参与方本地进行一定轮次的更新后将模型的参数或梯度进行上传，由服务器进行聚合并生成全局模型，聚合采用加权平均的方式且权重与每个参与方的本地数据规模成正比。这种经典范式面临的一个关键挑战是不同参与方中数据分布通常是不同的，其在本地训练和全局聚合阶段都可能导致模型遗忘过去知识，影响模型收敛和最终的准确率。

个性化联邦学习已被证实能够有效缓解由数据 Non-IID 特性带来的不良影响，在当前研究中，该领域主要分为两大策略分支：1) 全局模型个性化，旨在提升联邦学习全局模型的泛化性能；2) 学习更加个性化的本地模型，旨在为不同参与方提供个性化

的解决方案。全局模型个性化通过“联邦训练+本地适应”两步策略以训练具备良好泛化能力的全局模型，取得全局目标于本地目标的平衡，以捕获更多本地私有知识并使模型贴合私有数据分布。学习个性化的本地模型则指利用正则损失、相似性计算等为参与方训练个性化的本地模型。不同策略分支包含了具体的解决方法，目前主流的解决方法主要集中于三类：基于知识蒸馏、基于相似性的簇类划分、基于正则化控制。

知识蒸馏 (Knowledge Distillation, KD)^[28]是一种基于“教师-学生网络思想”的机器学习方式，最初用于将大型模型或模型集中存在的知识转移至较小的学生模型中——由于传统的 one-hot 标签信息量过小，知识蒸馏利用训练好的教师模型产生的软预测分布指导学生模型训练。相比于硬标签，软标签包含了更多信息，以使学生模型得到更好的性能表现。在联邦学习框架下，全局模型和本地模型都可以作为教师模型用以指导特定的学生模型完成训练。这类方法可以缓解 Non-IID 数据带来的负面影响。Li 等人提出 FedMD^[29]利用迁移学习和知识蒸馏完成联邦学习训练，其通过迁移学习公共数据集并汇聚所有参与方作为“教师模型”，然后采用公共数据集在服务器聚合教师知识并分发以指导各方本地模型训练。Lin 等人^[30]在服务器中使用未标记的公共数据集聚合接收到的客户端知识，设计出 FedDF 算法从而将全局模型作为学生进行知识蒸馏以保留知识，其在客户端模型异构程度高的情况下会退化为 FedMD，而异构程度低时则退化为 FedAvg 与蒸馏优化。FedGEMS^[31]在 FedMD 基础上改进，在服务器端持有一个大模型并利用公共数据集进行自蒸馏以更好地保存知识，缓解数据异质所带来的模型对知识的遗忘。这种方式需要在服务器端维护一个参数规模很大的模型，增加了计算开销且一定程度上降低了训练速度。一些研究试图在不使用额外公共数据集的情况下提取知识，Jeong 等人^[32]将每个客户端在服务器传输的不同类别的 logits 聚合并简单平均，作为提炼知识进行分发，以避免对公共数据集的依赖。不过，这种方法直接对同一类别的所有 logits 求平均值，往往会模糊各参与方的知识。He 等人^[33]结合拆分学习，将本地模型拆分为一个特征提取网络和一个分类网络，将中间特征作为输入传输给服务端分类网络进行知识提炼，该方法降低了边缘计算对计算能力的高要求。部分方法^[34,35]利用一个预训练好的生成模型增补数据。然而，这些使用生成器添加数据的方法由于是直接扩充原始数据集，对生成样本的质量要求较高，同时也难以针对性挖掘对模型提升最大的生成数据。

参与方簇类划分联邦学习的基本思想是将具有相似数据分布的参与方划分为相同的簇，每个簇内的数据在某种程度上满足独立同分布条件，或是相较于全局数据分布更为均衡。Sattler 等人^[36]以各参与方数据分布存在不同程度相似性为前提，通过模型间余弦相似度进行类似二分法分类并不断迭代，不同分类（即簇）间的模型进行联合训练并得到全局模型。训练过程中若发现某簇中参与方在经过一段时间的训练后，其本地模型与该簇的全局模型之间的参数差异小于预设阈值时，可以认为该簇内部数据

分布较一致且无需再次划分。相反若参数差异仍大于预设阈值,则表明该簇内部数据分布仍然存在较大差异,需要将该簇进一步细分为两个或多个新的簇。通过这样采用簇间差异最大且簇内差异最小的划分方式,依次迭代下去。Caldarola 等人^[37]提出一种基于集群驱动的联邦学习算法 FedCG,利用参与方聚类缓解分布倾斜问题并由图卷积网络实现参与方间知识共享。该方法利用基于教师-学生领域分类器的迭代聚类算法,通过发现不同的输出分布域,实现特定领域参数在图卷积网络上的相互作用。Ghosh 等人^[38]提出利用迭代式聚类和簇间共享的方式进行联邦学习,该方法需要事先指定聚类簇的个数,属于簇间共享。然而,这类动态分簇的方法需要精心设计合理的簇分裂准则和算法,以及高昂的计算与通信开销,以确保分簇的有效性和合理性。

基于正则化控制的方法指通过对损失函数进行正则项限制,协调全局模型与本地模型间差异,使模型训练尽可能不要与期望偏离过大的过程。这类方法能够有效地降低各本地模型与全局模型间的模型权重差异,典型的基于正则化控制的方法是 FedProx^[39],其通过增加正则项对本地模型训练的方向进行约束控制以缓解 Non-IID 数据带来的影响。L2GD^[40]与 FedProx 类似,在本地模型与全局模型间达到某种平衡,通过增加正则项约束引导算法找出一种全局模型与本地模型的混合模型。Dinh C 等人^[41]利用 Moreau Envelope 作为正则化损失函数,提出 pFedMe 将联邦学习的个性化过程与全局模型学习过程解耦,通过引入“近端算子”以依靠全局模型进一步指导个性化模型,控制其个性化程度以获得最优。Yao 等人^[42]提出 FedCL 以通过评估参数重要性模型并针对模型参数施加惩罚,减少模型间的权重分歧,最终防止全局模型的重要参数在训练过程被改变。Karimireddy 等人^[43]发现 Non-IID 场景下联邦学习本地训练若为了降低通信效率采用较多 epoch 更新参数,会导致客户端漂移现象进而导致模型性能下降,针对此现象提出了 Scaffold 算法。Scaffold 通过为每个参与方引入控制变量以调整模型参数更新方向,缩小本地模型与全局模型差异。Tian 等人^[44]提出了 FedProto 框架将不同参与方的本地模型聚合在服务器,参与方与服务器之间传输抽象类原型以取代传输梯度,服务器分发聚合后的全局原型模型给参与方并纠正本地训练。本地训练时模型不仅需要最小化分类损失,还要令其局部原型与全局原型差异最小。

总体来看,上述算法均表现出一定程度的局限性,如引入了额外的公共数据集,在现实场景中难以应用;仅利用正则化项强制约束本地模型更新方向,忽略了服务器端模型聚合导致的泛化性能下降;通过加大计算与通信开销的方式划分簇类,不能很好地利用各参与方本地数据,且对于分布倾斜较大的参与方不够友好。同时,大部分方法在服务器聚合模型参数的方式需要各参与方使用统一的神经网络模型,而 Non-IID 数据或各方具体条件不同导致各参与方针对自身条件独立设计不同的网络模型效果往往更佳。因此在改善 Non-IID 数据影响的同时设计允许各参与方模型与服务器模型解耦的方法能够进一步提升算法的适应能力与性能,并且满足实际中潜在的参与方独

立设计网络模型的需求。随着元学习^[45-47]、迁移学习^[48-51]、域适应学习^[52-54]与移动边缘计算^[55-58]的兴起,将其应用与联邦学习结合以解决数据 Non-IID 等挑战发展迅速,为之后的研究提供了更多方向。如何保证各参与方在数据 Non-IID 情形下依旧能协同训练出优质模型,降低通信开销并提升安全性是联邦学习未来发展的趋势。

1.2.2 联邦学习的通信效率

联邦学习中的一项关键瓶颈在于其训练时所产生的通信开销。现代数据最重要的特点是时效性,因为现代数据的生命周期短,迭代更新速度快。同时联邦学习中大量的参与方设备处于下游网络链路中,其网络带宽通常低于中心服务器链路带宽。为了应对网络带宽受限场景,并使联邦学习能够应用于大数据规模下的机器学习,减少通信开销的各类优化方法被广泛研究。目前主流的优化方向主要有两个方面:减少联邦学习通信总轮次大小,以及加快每轮各模型上传速度。具体的通信效率优化策略可以分为模型参数压缩、本地训练增强、结构化通信剪枝分解和高效聚合算法等。

为了缩减联邦学习中的通信总轮次,可以通过增加各参与方本地训练轮次以降低全局聚合次数,以达到在较小的通信轮次下较高质量的聚合每轮全局模型。McMahan 等人^[10]于 2017 年提出通过增加每轮通信之间各参与方本地模型的计算量以提升训练效果,进而变相提升通信效率。同时该方法还提出增加并行性以激励更多客户端参与每轮训练以进一步减少整体通信量。Nishio 等人^[59]构建了 FedDC 框架以在每轮训练中最大程度地整合各参与方,并在算法中加入最大均值差异以强制各本地模型尽可能获取更多知识从而加快模型收敛。随机梯度下降法利用小样本子集梯度以近似整体数据集梯度,目前广泛应用于集中式机器学习和深度学习中的参数优化任务^[60,61]。然而已有研究表明,在联邦学习的应用场景中该方法未能有效平衡通信开销与计算资源消耗,进而未能充分利用分布式数据中所蕴含的潜力^[62,63]。如果优化目标函数是各向异性的,随机梯度下降往往是低效的。基于上述特点,Yang 等人^[64]运用动量梯度下降法,借由整合本地训练阶段的历史梯度信息,进而加速模型的收敛进程。但该方法并不适用于所有联邦学习场景,例如医疗领域等的高效率场景需求。

总体来看,当前主流的联邦学习通信效率优化方法主要集中于:1)将模型参数压缩、编码以减少每轮训练的通信量;2)通过本地训练增强,使参与方在一次通信轮内执行多次本地训练或采用数据增强技术以加速训练进而减少通信量;3)通过模型剪枝或低秩分解等方法减少通信数据量;4)通过高效聚合策略减少通信负担。在不同的应用场景下可采用相适应的通信优化方法,以达到最好性能。

1.2.3 联邦学习的激励机制

联邦学习的有效性需要大量高质量参与者作为保障,因此,如何激励更多参与方

加入联邦学习贡献其宝贵资源成为研究热点。联邦学习会消费参与方的计算能力、带宽以及私有数据，有缺陷的参与方也会导致联邦学习效果下降甚至故障。好的激励机制需要做到积极调动高质量客户参与积极性，保障参与方数据质量以及维护公平性和可持续性。联邦学习中的激励机制技术常结合如拍卖机制、契约理论和强化学习等技术，以确保整个联邦学习系统的健康发展与高效运作。

拍卖是一种基于定价、任务分配和节点选择的高效调度过程，Zeng 等人^[65]提出了一种轻量化且多维度的激励方案 FMore 并在移动边缘计算场景下进行联邦学习应用。Deng 等人^[66]提出了一种基于质量的拍卖方案，并提出了一种简单有效的贪心算法进行实时任务和报酬分配。契约理论能够帮助参与方在利益冲突且信息水平不等的场景下构建协作发展协议，Kang 等人^[67]采用契约列表将贡献的资源映射作为激励，并假设了一个强烈不完备信息场以研究复杂场景下联邦学习的激励复杂性。强化学习可以在连续决策场景下通过不断最大化奖励分数逼近最优解，将强化学习引入以推导近似解可以解决联邦学习复杂场景下求解纳什均衡解困难的问题。Zhan 等人^[68]使用了一种名为 PPO 的算法计算了不完备信息下的参与方支付问题，PPO 算法能够使决策主体在缺少其余参与方先验信息的情况下逼近纳什均衡解，最大化系统性能的同时使成本最小化。

总体而言，激励机制能够鼓励吸引更多优质参与方，保障数据质量并抵制不良行为。联邦学习中的激励机制是连接技术与经济行为的关键桥梁，通过巧妙的设计和实施，它可以极大地促进联邦学习系统的有效运作，同时兼顾数据隐私保护和经济效益的双重目标。未来激励机制的研究可以从“Cross-Silo”环境的激励方案、综合激励设计等入手，并结合新场景下的前沿技术，进一步提升联邦学习。

1.3 研究内容与实施框架

本文针对联邦学习存在的 Non-IID 数据引发的模型性能下降、收敛速度缓慢等问题，针对联邦学习的两大阶段（本地训练阶段、服务器全局聚合阶段）分别进行改进及优化，对应本文的第三、第四章。在本地训练阶段保留本地模型持续训练，并采用全局模型与本地模型协作蒸馏^[69]的方式对模型结构进行解耦。同时引入关系知识结合响应知识以充分挖掘参与方数据的嵌入空间知识，引导高质量知识传输并为后续聚合后全局模型质量提供基础保障。在服务器聚合阶段，利用生成器对抗训练并生成聚合后全局模型的遗忘样本。通过知识蒸馏重新指导全局模型加以巩固，提升模型泛化能力并为次轮模型分发后的本地训练提供支撑。本文分别改善联邦学习训练过程的两个阶段以最大限度地传输并保留优质数据知识避免遗忘，最终缓解参与方之间由 Non-IID 数据带来的负面影响，提升模型性能表现。图 1.5 展示了本文的内容框架安排。

具体而言，在联邦学习的本地训练阶段，本文设计了一种能够解耦参与方本地模型与全局模型的协作蒸馏方式，使各参与方能够根据其存储条件、数据特点及自身需

求独立设计适合自己的网络模型。参与方在每轮训练阶段下载全局模型副本并在整个训练阶段一直保留自身本地模型，通过全局模型副本与本地模型间的协作蒸馏方式交换模型知识。将本地模型与全局模型结构解耦合的同时，保证了本地模型训练的连续性，同时避免了模型的知识遗忘。具体地，将关系知识蒸馏纳入损失函数与响应知识蒸馏联合，使双方充分学习对方模型预测空间的知识表征，最大程度地提升正向知识传输。并且，进一步设计一种基于预测信息熵的自适应权重调节方式以动态调整损失函数中两种不同蒸馏知识的贡献比例，减少负面知识转移。




图 1.5 研究内容及实施框架

Figure 1.5 Research content and implementation framework

在服务器的全局聚合阶段，针对各联邦学习参与方在数据 Non-IID 场景下由于简

单参数聚合所产生的数据特征削弱、抵消与知识遗忘，本文结合生成对抗网络设计了一种遗忘知识提炼方式。通过生成器对本地模型输入空间的探索和与全局模型的对抗训练，生成新数据以对参数聚合后的全局模型进行调优。同时，针对生成器易产生的“模式坍塌”问题和不同参与方作为教师的知识贡献比例提出优化方法，引入不同模块以分别提升生成样本多样性，以及教师知识质量。通过对聚合后的全局模型进行调优，改善全局模型聚合阶段所带来的性能下降，进一步提升联邦学习模型表现。

1.4 主要创新点

(1) 针对个性化联邦学习所面临的基本挑战——在 Non-IID 数据上收敛速度和模型准确率下降，同时仅训练单一的全局模型从而缺乏个性化的解决方案，本文在联邦学习本地训练阶段引入协作蒸馏机制。通过协作蒸馏将本地模型与全局模型进行结构上的解耦，打破传统联邦学习算法全局模型与所有本地模型结构必须一致的限制。相比每轮接收新的全局模型覆盖旧模型并重新训练的方式，协作蒸馏方式能够保留本地模型持续训练以充分学习私有数据知识，同时分发的全局模型和本地模型通过协作蒸馏交替充当“教师”角色高效传输知识，从而降低本地训练阶段的知识遗忘现象，提升本地训练效果。在具体蒸馏损失方面，本文引入关系知识与响应知识相结合，利用预测嵌入空间中更具鲁棒性的关系知识进行蒸馏训练，同时设计了一种自适应权重调节策略，根据全局模型预测的信息熵动态调节本地模型的蒸馏损失，防止负面知识过度转移。不同场景下的实验表明，通过改进本地训练方式，我们方法在模型收敛速度和测试准确率上均优于 FedAvg 方法。

(2) 针对个性化联邦学习在 Non-IID 场景下全局聚合阶段所面临的数据特征削弱及知识遗忘，本文在全局服务器上训练一个生成对抗网络，通过将聚合后的全局模型与生成器对抗训练，挖掘全局模型聚合阶段丢失的遗忘样本，并通过知识蒸馏指导全局模型重新掌握遗忘知识。具体地，生成器通过收集到的本地模型集群进行训练以拟合本地数据集分布。同时依赖知识蒸馏，将生成器产生的样本用于构建本地模型集群与全局模型的蒸馏损失，由生成器与全局模型对抗训练该损失，达到挖掘遗忘知识并指导全局模型的目的。并且，将不同本地模型作为教师的贡献权重进行动态计算，保留对生成样本正确预测的模型并依靠信息熵反映其预测信心，提升高质量教师模型的指导权重。不同场景下的实验表明，我们方法在模型收敛速度和测试准确率上均优于 FedAvg 方法，有效提升了全局模型聚合质量，减少了聚合后的知识遗忘。

(3) 个性化联邦学习性能的提升依赖本地训练和全局聚合两个阶段的知识学习和留存效果，本文将两个阶段的改进算法相结合，通过提升本地训练阶段模型的知识捕获能力以及全局聚合阶段的聚合质量，进一步提升了模型的性能表现。在各场景下与基线方法的实验对比显示，本文提出的算法在收敛速度和测试精度上均取得最优结果。

1.5 本文结构安排

本文总共包含 6 个章节，章节组织结构安排如下：

第 1 章，阐述了集中式机器学习的弊端并引出联邦学习及其在数据非独立同分布场景下面临的挑战，详细介绍了联邦学习各个研究方向的研究意义、研究现状，并给出了本文的研究内容，创新点以及具体结构安排。

第 2 章，对预备知识及相关理论技术进行概述，介绍了分布式学习，联邦学习训练过程及知识蒸馏技术，生成对抗网络基本知识和用到的神经网络结构，以及 Non-IID 数据及其为联邦学习带来的负面影响。

第 3 章，在个性化联邦学习的本地训练阶段，提出一种基于协作与关系知识蒸馏的优化方法 FedCRD。首先分析了联邦学习中由于 Non-IID 数据所导致的知识遗忘现象，并由此提出协作蒸馏方式使本地模型训练连续完整，同时解耦本地与全局模型结构。其次，损失项引入了关系知识并与响应知识结合，利用自适应权重策略动态调节蒸馏知识贡献比例，增强正向知识传输。最后，在不同的实验场景进行实验，验证了所提出 FedCRD 方法的有效性。

第 4 章，在联邦学习的全局聚合阶段，提出一种基于生成对抗网络的对抗训练方法 FedGA。首先对 Non-IID 数据在联邦学习全局聚合阶段产生的负面影响进行分析，然后基于生成对抗网络，将聚合后全局模型与生成器对抗训练并生成遗忘知识。此外，针对不同参与方的教师知识贡献，设计了一种自适应的淘汰与权重计算策略，达到优化联邦学习全局聚合的目的。最后，在不同的实验场景中验证了 FedCGA 方法的效果。

第 5 章，整合前两章方法内容。将第三章和第四章所提出的本地训练改进方法与全局聚合阶段的优化方法进行整合，并通过实验验证整合后的联邦学习算法在不同实验场景下相比基线算法能够有效提升模型测试精度并加快模型收敛。

第 6 章，总结及展望。针对本文在联邦学习的两个部分所进行的重点工作和改进进行总结分析，阐述其优点及不足之处，并对未来的工作进行展望。

第2章 预备知识及相关理论技术

本章主要围绕数据非独立同分布下的联邦学习相关背景知识和本文所用到的相关理论技术进行介绍。首先对机器学习中的神经网络及后文所用到的不同网络模型（MLP、CNN、ResNet 和 VGG 等）进行结构和概念上的介绍。然后针对分布式学习和联邦学习场景定义进行介绍，详细阐述经典联邦学习算法 FedAvg，并引申出 Non-IID 数据以及其对 FedAvg 算法带来的负面影响与挑战。最后对本文研究工作中运用的关键技术进行详细介绍，包含知识蒸馏以及生成对抗网络的结构，类型与基本概念。

2.1 神经网络

神经网络是一种模拟人类大脑中神经元连接与交互机制的数学方法，其通过模拟大量高度互联的神经元工作，以解决复杂的工作任务。这种计算模型旨在通过学习从输入数据中提取特征并进行复杂的模式识别和决策制定。神经网络在诸多领域展现出了卓越的能力，如图像与语音识别、大语言模型、医学诊断和自动驾驶等，其强大的表征学习和泛化能力使其成为现代人工智能技术的核心组成部分。本节将从神经网络的基本组成单元进行介绍，并阐述神经网络模型训练所涉及的前向传播算法与反向传播算法，最后介绍目前图像识别领域主流的卷积神经网络、残差神经网络等。

2.1.1 前馈神经网络

神经网络（Neural Network, NN）是一种模仿人脑中神经元之间连接和交互机制的计算模型，它由一系列高度互联的人工神经元组成。在现代机器学习和人工智能领域中，神经网络被广泛应用于模式识别、分类、回归分析、强化学习以及自然语言处理等多种任务。神经网络的基本结构往往包括输入层、隐藏层（可能有一个或多个）和输出层。每个神经元接收由前一层传递过来的加权信号，并通过一个激活函数对其进行非线性变换，然后将结果传递给下一层的神经元。整个网络通过训练来调整这些权重，以便于对特定任务进行预测或决策。训练过程则常用反向传播（BackPropagation）进行模型权重参数的更新，通过最小化目标函数损失来减少预测结果与真实标签之间的差值。在计算机视觉方向，深度学习与神经网络近年来发展迅速，在图像分类、物体检测、语义分割以及视频分析等方面尤为突出。

神经网络通过模拟生物神经元的连接与交互来实现各类机器学习任务，其基本组成单元是一个个神经元。人的大脑神经元作为一个信息处理单元负责加工并传输电信号，当某个神经元的电位强度超越其激活阈值时，该神经元将触发激活状态，并释放

化学信使物质——递质，向与其相连接的所有其他神经元传递信号，从而实现信息的传导功能。人脑中神经元包含树突、轴突与突触等组成部分，在一定程度上启发了后续神经网络中神经元的构建。

随着人工智能的不断发展，人们发现仅通过对计算机输入程序来模拟人类的推理过程存在很多弊端。如早期的专家系统需要维护大量知识库进行手动编码，同时这样的系统往往针对特定情景编码，缺乏泛化能力。在后续研究中，人们借鉴了生物神经元信息处理的原理，将其抽象为经典的数学模型并得到了现在广泛使用的 MP 神经元模型。




图 2.1 神经元模型

Figure 2.1 Neurons model

如图 2.1 所示，图中圆圈代表单个神经元，其中 x_i 代表第 i 个输入， w_i 代表第 i 个输入的权重系数， θ 代表该神经元的阈值或偏置系数。 y 则代表该神经元的输出结果，通过激活函数 f 计算得到：

$$y = f\left(\sum_{i=1}^n w_i x_i - \theta\right) \quad (2-1)$$

感知机是最早的人工神经网络模型之一，通常包含一层输入神经元及一层输出神经元，没有隐藏层。经过感知机的输入特征通过加权和加上偏置系数进行处理，然后通过激活函数得到输出。由于其学习能力的局限性，感知机只能解决线性可分问题。




图 2.2 感知机模型

Figure 2.2 Perceptual machine model

前馈神经网络又称为多层感知机（MultiLayer Perceptron, MLP），它在感知机的基础上增加了至少一个隐藏层，如图 2.2 所示。前馈神经网络可以有多层神经元，信息从前一层流向后一层，直到到达输出层，但不会形成反馈环路。每个神经元的工作原理与感知机中的单个神经元相似，都是对输入进行加权求和并施加激活函数。通过引入多层结构和非线性激活函数，前馈神经网络能够学习和表示更为复杂的函数映射关系，从而解决非线性分类和回归问题。通过训练其可以学习到输入数据的多层次抽象特征，大大拓展了模型的能力范围。

2.1.2 卷积神经网络

在生物学中，动物视觉细胞的感受野指的是该细胞仅对其视野内的特定区域的刺激做出响应，而对其他区域的刺激则反应较弱甚至不反应。例如，猫科动物视网膜上的锥状细胞和杆状细胞对光的局部区域敏感，只有当光线落在其感受野内时才会激发神经脉冲。这种局部敏感和重复排列的特性有助于视觉信息的初步处理和抽象。

卷积神经网络（Convolutional Neural Network, CNN）是一种处理网格结构输入数据的深度学习模型，它的设计灵感主要便来源于生物视觉皮层组织的结构和功能。CNN 借鉴了视觉细胞的感受野概念，使用特征图逐层提取感受野中的数据特征，能够自动从原始输入数据中学习有用的知识，并进行高效识别和分类。LeCun 等人于 1989 年提出了基本的卷积神经网络模型，并首次展示了其在手写邮政编码识别任务上取得的良好效果，这是首个在实际应用场景中获得成功的 CNN 模型之一。随着图像处理领域的不断发展，对 CNN 的理论研究与应用实践也愈加深入，后续又相继出现了诸如 VGG、ResNet、GoogLeNet 等变体模型，在图像识别、物体检测、语义分割等领域都取得了显著的成功。

CNN 的具体网络结构如图 2.3 所示，其输入层与输出层与前馈神经网络类似，但隐藏层更为复杂，主要由三部分组成：卷积层、池化层和全连接层，其中卷积层与池化层往往组合使用，并多次堆叠于隐藏层中。




图 2.3 卷积神经网络

Figure 2.3 Convolutional neural network

（1）卷积层

卷积层是 CNN 的核心组件之一，主要负责利用一组可学习的卷积核从输入图像上学习并提取局部特征。卷积核在整张图像上滑动采样，滑动过程使用同一组权重，能够降低过拟合风险并且减少计算成本。通过将卷积核按固定步长沿输入图像的宽度和高度移动，每次处理固定大小的感受野，可以有效捕获图像的局部特征。在卷积核采样结束后，通常会连接池化层与激活函数（如 sigmoid、ReLU 等），以增加网络的表达能力。总体而言，卷积层能够通过滑动卷积操作提取并转换图像局部特征，生成新的特征输出并保留原始输入信息，为后续层提供更高级别的抽象特征表达。

（2）池化层

池化层通常跟随在卷积层之后，承担缩减输入特征图空间维度的功能，旨在有效控制模型的计算复杂度以及参数规模，防止过拟合并加速训练过程。常见的池化函数通常为最大池化和平均池化，分别保留窗口中最大值和所有数值的平均值作为该窗口的输出值。通过池化操作，能够对输入特征进行下采样的同时保留住重要的空间特征，为后续层提供更为紧凑和抽象的特征表示。

（3）全连接层

全连接层位于卷积层和池化层之后，类似前馈神经网络，该层中的每个神经元与前一层中所有神经元均有连接。全连接层将前面提取到的特征图展平后连接到每个神经元，之后进行分类或回归任务。全连接层的作用是对前面提取的特征进行综合分析，实现从局部特征到全局特征的转换，并给出最终的预测结果。

2.1.3 残差神经网络

深度神经网络之所以得名于此是由于其神经网络往往具有很多层数（卷积层或全连接层），基于神经网络的机器学习算法因此也被称作“深度学习”。原则上，随着神经网络层数的增多，机器学习应该获得更好的结果。然而，随着算力的增强以及网络层数的不断增加，参数不断增多所导致的梯度消失、梯度爆炸以及严重的过拟合问题使得层数越多的神经网络训练效果不一定越好。以上梯度消失/梯度爆炸及过拟合等问题被称作退化问题，即随着神经网络层数的增加，预测效果反而退化越来越差。

残差神经网络（ResNet）^[70]被提出用以解决退化问题，通过设计“残差块”通过恒等映射的方式保证新层的增加至少应与少层时性能保持一致。在残差结构中，输入信息能够经由跨层链路以更快的速度直达后续层，而且在某些情况下能够避免深层网络层的不利影响。残差神经网络结构如图 2.4 所示。




图 2.4 残差神经网络

Figure 2.4 Residual neural network

在 ResNet 中，每个残差块引入了“快捷连接”（Shortcut Connection），它允许信息以跳跃的方式从较浅层直接到达较深层，而不仅仅是通过逐层计算得到。这种设计使得网络可以直接学习输入与输出之间的残差映射，而非原始的端到端映射。ResNet 在 ImageNet 图像识别竞赛中取得了巨大成功，不仅显著提高了分类准确率，还推动了深度学习和计算机视觉领域研究的进展。后续许多网络结构都借鉴了 ResNet 的残差学习思想，成为现代深度神经网络设计标准组件之一。

2.1.4 VGG 神经网络

VGG^[71]是牛津的 Visual Geometry Group 组提出的图像识别神经网络模型，其主要有两种结构，分别是 VGG16 和 VGG19。区别于传统的图像网络模型如 AlexNet 中较大的 11×11 、 5×5 卷积核，其采用几个较小的 3×3 卷积核堆叠替代。采用多个较小卷积核的堆叠，一方面能通过多层的非线性特性增强模型的学习能力（卷积+ReLU 为一个组合），同时能进一步减少模型的参数。

VGG 具有小卷积核、多层堆叠（例如 VGG16、VGG19）、固定步长、参数降维等特点，其深层次的网络结构允许模型在复杂图像数据集上捕获更丰富的层次特征。它的出现进一步推动了深度学习在计算机视觉领域的研究和发展，在语义分割、物体检测及风格迁移领域得到广泛应用，其设计理念对后续的许多深度学习模型如 ResNet 等产生了深远影响。

2.1.5 神经网络模型训练

神经网络通过模仿人类大脑中神经元网络的层次结构来解决复杂的学习问题，尤其是涉及高维度与非线性关系的数据集。其核心是模拟生物神经系统的工作原理并建

立深层神经网络，通过不断训练使预定义的损失函数能够到达最小值点。深度学习模型除输入层与输出层外，通常包含多个隐藏层。在深度学习训练过程中，损失函数扮演着重要角色，其反映了模型预测结果与真值之间的差距。训练神经网络可看作是寻找一组神经网络参数，使得整个网络在训练集上的损失函数最小化。这个寻找网络参数的过程常采用梯度下降法，通过模型的反向传播使模型参数沿着损失函数梯度的反方向进行更新。梯度下降法通过公式（2-2）对神经网络权重进行更新，式中 θ 表示网络权重， $J(\cdot)$ 表示损失函数， η 表示学习率。梯度下降法需要预先求得损失函数的值，这一过程即神经网络的前向传播过程，即将训练样本从神经网络输入层输入并最终得到网络输出层结果。最终，通过预先定义的损失函数计算出输出结果与真值之间的差值，并求得网络各层间参数的梯度用以更新。

$$\theta = \theta - \eta * \nabla J(\theta) \quad (2-2)$$

在实践中，由多种变体的梯度下降法被广泛用于深度学习的训练当中，主要可概括为以下三类：

（1）批量梯度下降（Batch Gradient Descent）：在每次更新前，计算整个训练集上损失函数的梯度，然后一次性更新所有参数。

（2）随机梯度下降（Stochastic Gradient Descent, SGD）：每次仅根据一个训练样本或一个小批量样本计算梯度并更新参数，因其高效性和随机性，成为深度学习中最常用的一种优化算法。

（3）小批量梯度下降（Mini-batch Gradient Descent）：结合了批量和随机梯度下降的特点，每次基于一小部分样本（批量大小一般介于几到几千之间）来更新参数，既保持了一定的随机性以缓解局部最优问题，又减少了计算开销。

除了上述基本类别外，还存在部分改进上述方法的研究，例如动量法与加速梯度等。这些改进方法通过引入额外的机制来加速模型训练过程和收敛结果，如脱离训练中的鞍点等。

总的来说，深度学习的过程就是在选定的目标函数指导下，利用梯度下降及其变种方法不断地迭代调整模型参数，以期在验证集或测试集上获得最优的泛化性能。这种通过模拟生物神经元工作原理的多层非线性模型能够实现复杂数据的高度解释与拟合预测能力，逐步成为人工智能领域的核心支柱之一。

2.2 分布式机器学习

分布式机器学习是指在多台计算机节点组成的网络中，协同训练机器学习模型的方法。这种模式与传统的集中式机器学习相比，在处理大规模数据集、优化计算资源使用以及加快模型训练速度等方面存在显著优势。单一服务器往往难以提供海量的计

算资源与存储资源，即使能够训练，往往也需要很长的训练时间。由此分布式机器学习应运而生，旨在通过多台机器的协同训练以实现联合共同任务。

分布式机器学习的关键理念在于将庞大的机器学习作业分割为多个能够并行执行的小型独立任务单元，并将这些任务单元合理地分配给分布式系统中的各个节点进行运算处理。具体而言，数据集不必统一汇聚于服务器中，而是分散存储在不同的集群节点上，使每个节点都可以独立地在本地数据上进行模型训练。同时，节点之间通过高效的网络通信协议进行协作，集群中节点会定期或按需交换模型参数的更新、梯度信息或其他必要的中间结果。集群中节点的并行化训练不仅解决了集中式机器学习需要将所有训练数据汇聚的数据存储压力，同时也获得了更大的计算能力，提升了模型的训练效率。在分布式环境下的机器学习训练，一般采用分布式随机梯度下降法并进行迭代。

分布式机器学习重点关注如何解决传统集中式机器学习所面临的基本挑战，如数据存储压力、计算资源瓶颈与训练效率等。随着技术发展，分布式机器学习的延伸方向还包括模型并行（如深度学习模型的层间并行）、数据流并行等更复杂的并行策略，以及针对特定场景如隐私保护的解决方案。同时，数据隐私法规的强化和对数据安全的重视使得联邦学习应运而生，作为一种崭新的分布式机器学习模式，联邦学习专注于在保障参与方数据安全的同时实现高效的多方协同训练。

2.3 联邦学习

联邦学习作为分布式机器学习下的一种新兴范式，能够使各参与方在不暴露其私有数据的前提下进行协作训练，保证数据的隐私安全并打破大数据背景下的“数据孤岛”现象。各参与方利用其各自私有数据做本地训练以得到其本地模型，在每轮训练末将其本地模型参数或梯度上传至全局服务区，由全局服务器进行聚合并最终得到该轮的全局模型，并在新一轮训练开始时下发全局模型给各参与方进行次轮训练。以上过程一直持续直到全局模型完成收敛或模型达到预设的推理准确率。从数据隐私保护的角度出发，联邦学习在保证数据隐私安全的同时能够使多方协作训练成为可能，为隐私受限下的分布式应用场景提供了一种新的分布式学习范式。

在一个典型的联邦学习应用场景中，包含一个全局服务器与若干参与方节点，对 N 个参与方的集合用 $C = \{C_1, C_2, C_3, \dots, C_N\}$ 表示，其各自拥有的私有数据的集合用 $D = \{D_1, D_2, D_3, \dots, D_N\}$ 表示。其中，参与方 i 的私有数据 D_i 大小用 $|D_i|$ 表示。传统的集中式机器学习需要将 $D = \{D_1, D_2, D_3, \dots, D_N\}$ 集中汇聚以训练出唯一模型，汇聚后数据分布一致且目标函数唯一。然而，由于数据隐私与数据安全，联邦学习不会在全局服务器中汇聚数据，而仅汇聚各参与方本地训练后的模型参数或梯度。当模型训练任务启动后，全局服务器会进行模型初始化并分发各参与方节点，各参与方利用其私有数据在

本地独立训练器本地模型 $\{M_1, M_2, M_3, \dots, M_N\}$ ，并将更新后的本地模型参数或梯度传回全局服务器，最后由全局服务器进行聚合并得到该轮新的全局模型 G 。上述过程称为联邦学习的一个通信轮次，次轮训练开始时由全局服务器分发上轮得到的全局模型参数，并重复该过程直至全局模型收敛或达到指定通信轮次、目标精度。

在实际联邦学习场景中可能存在大量参与方，如谷歌提出的基于海量用户手机终端的联邦学习。出于网络传输、计算开销等方面考虑，每轮训练中会根据预设的活跃比例随机选取部分参与方进行训练。被选中的参与方 C_i 完成本地训练后，会将其本地模型 M_i 的权重参数 w_i 上传至全局服务器，之后服务器采用特定的聚合策略聚合收到的所有本地模型参数，由此生成下一轮全局模型参数 w_G 并分发给下一轮选中的参与方开始次轮训练。该训练过程重复多轮直至全局模型 G 收敛至预定水平并最终分发给所有联邦学习参与方。

联邦学习通过求解全局目标函数以协调大量参与方共同训练出全局模型，其全局目标函数 $f(w)$ 可以表示为：

$$\min_w f(w) = \sum_{i=1}^N p_i F_i(w) = E_i[F_i(w)] \quad (2-3)$$

其中 N 表示参与方个数， $F_i(w)$ 表示参与方 i 的本地目标函数， $p_i = |D_i| / \sum_{j=1}^N |D_j|$ 则表示其聚合权重，由参与方 i 的本地数据量 $|D_i|$ 决定。且 p_i 满足 $p_i > 0$ ， $\sum_{i=1}^N p_i = 1$ 。在联邦学习框架下，参与方 i 利用自身的私有数据集进行本地模型训练，其核心任务是通过不断迭代训练调整和优化模型参数，以期达到最小化其本地目标函数的目的。本地目标函数定义如下：

$$\min_{\omega} F_i(\omega) = \frac{1}{|D_i|} l_i(\omega, D_i) \quad (2-4)$$

其中 l_i 代表了第 i 个参与方的本地损失函数，通常为交叉熵损失或均方误差损失等。在每一轮通信迭代中，一旦参与方接收到由服务器广播的全局模型参数，就会结合自身的私有数据在本地进行训练以对其私有数据进行拟合，从而得到训练后的本地模型。训练过程中利用梯度下降法按照损失函数梯度下降的方向对模型参数进行更新，从而使得模型参数按照损失函数最小化的方向前进。具体而言对于参与方 i ，其本地参数更新方式为：

$$\omega_{i,t+1} = \omega_{i,t} - \eta * g_i \quad (2-5)$$

其中 $g_i = \nabla f_i(\omega_{i,t})$ 为参与方 i 的损失函数在当前轮次 t 下的梯度， η 作为学习率控制模型更新的幅度。当该轮次所有选中参与方本地训练完毕并将本地模型参数上传至全局服务器后，由全局服务器进行模型融合以得到新一轮的全局模型。

算法 2-1 详细展示了联邦学习的基本算法 FedAvg 在本地训练阶段与全局聚合阶段的具体步骤。服务器端聚合时除了采用权重聚合以外，还可以采用梯度聚合：该轮迭

代所选中参与方将其本地训练后的梯度进行上传，全局服务器在收集完所有梯度后对全局模型参数进行更新操作，方法与权重聚合一致，采用加权聚合方式。全局模型更新方式如下：

$$w_g^{t+1} = w_g^t - \eta \sum_{i=1}^N \frac{|D_i|}{|D|} g_i \quad (2-6)$$

其中， η 代表学习率， g_i 为参与方 i 在该迭代轮次所上传梯度值， w_g^t 与 w_g^{t+1} 分别代表第 t 轮与第 $t+1$ 轮全局模型， $|D|$ 代表所有私有数据总数。

算法 2-1 FedAvg 训练过程

输入： T :训练总轮次; N :参与方数量; C :参与方活跃比例; $D = \{D_1, D_2, D_3, \dots, D_N\}$:参与方本地数据集; η :学习率; E :本地训练轮次

输出：全局模型 w_g

```

1: Initialize  $w$ 
2: ServerExecutes:    # 服务器聚合阶段
3: for each round  $t \in \{1, 2, \dots, T\}$  do
4:    $S_t \leftarrow$  random subset ( $C$  fraction) of the  $N$  clients
5:   for each clients  $i \in S_t$  in parallel do
6:      $w_{g,i}^t \leftarrow$  ClientUpdate ( $i, w_g^t$ )
7:   end for
8:   Server Aggregation:  $w_g^{t+1} = \sum_{i \in S_t} \frac{|D_i|}{|D|} w_{g,i}^t$ 
9: end for
10: ClientUpdate( $i, w_g^t$ ): # 参与方本地训练阶段
11: for each  $e \in \{1, 2, \dots, E\}$  do
12:   for batch  $b = \{x, y\} \in D_i$  do
13:      $w_{g,i}^t \leftarrow w_{g,i}^t - \eta \nabla L_i$ 
14:   end for
15: return  $w_{g,i}^t$ 
16: end for
```

FedAvg 算法是隐私受限下的分布式学习框架的一个重要突破，首次允许分散地训练深度学习模型，并不必将所有数据集中到单一服务器。然而，FedAvg 在处理 Non-IID 数据时会受到性能下降或收敛速度变慢等负面影响，需要进一步扩展与完善。

2.4 联邦学习中的 Non-IID 数据

在联邦学习的实际应用场景中，由于各参与方的私有数据在来源、质量上存在差

异且样本数量、类别各不相同，使得各方数据存在差异。因而在现实应用场景中，联邦学习各方的私有数据往往并不能满足独立同分布的基础统计假设。有研究表明，Non-IID 数据对联邦学习算法的性能及表现有着极大的影响，各方拥有数据的分布差异越大，将导致联邦学习最终全局模型的准确性下降、收敛轮次上升，极大地限制了联邦学习的应用场景。为了解决上述挑战，针对非独立同分布下的联邦学习优化成为了大量联邦学习研究的重点。本节将对非独立同分布数据及其对传统联邦学习框架造成的影响、原因进行分析与介绍。

2.4.1 Non-IID 数据简介

现有主流深度学习计算任务存在一个基本前提，即不同的数据样本间满足独立同分布（IID）条件。独立性指每个数据样本都是独立抽样得到的，其相互之间不会产生干预，不存在相关性。同分布性则指所有数据样本都应当从同一概率分布中抽样得到，能够保证模型学习到真实分布的一般性表达。传统的集中式机器学习能够将数据汇总于服务器用于训练，使这个前提能够得到保证。然而在联邦学习的训练场景下，各参与方出于数据隐私保护不会将其汇总于服务器进行集中式训练，从而不满足该基本前提，产生了数据的 Non-IID 现象。联邦学习中的 Non-IID 类别主要为样本标签分布偏差，即不同参与方数据集的条件分布 $P(x|y)$ 相同，但是其标签分布 $P(y)$ 却因参与方不同而不同。例如医疗领域中不同区域或医院内病人所患疾病类型数一致，但因区域性差异等导致各疾病类别下病人样本数量存在较大差异。在电商领域中因地域不同导致各地不同类别的商品其购买数量存在较大差异等。在联邦学习的实际应用场景中存在大量类似现象，现实中因各参与方所在区域、数据来源等不同所造成的各方数据集差异，即称为 Non-IID 数据。

在联邦学习传统框架下，Non-IID 数据会对其全局模型训练产生较大的负面影响，例如使收敛轮次增加甚至难以收敛、提升通信开销、使模型推理准确率下降等。联邦学习框架与集中式机器学习的区别主要在于联邦学习不会汇总各方数据集中训练，而是令各参与方的本地更新机制，在本地训练一定轮次后统一汇聚成全局模型。如果此时各参与方拥有的是 Non-IID 数据，其本地训练时其本地模型趋向于拟合其本地数据集分布。同时出于降低通信开销等原因，每轮通信中各参与方本地训练往往会进行不止一次，更易导致模型只能学习到基于其本地数据集样本分布的非一般性表达，导致其泛化能力的下降。采用随机梯度下降的方式训练本地模型，由于参与方拥有不同的数据分布，其本地模型的梯度下降方向也各不相同，在聚合全局模型时亦会互相干扰。因此，在 Non-IID 数据的应用场景下，联邦学习中的本地更新机制会彼此拖累，对全局模型保留各方知识产生较大的负面影响。

如图 2.5 所示， w_1^t 代表参与方 1 在第 t 轮的模型参数， w_1^{t+1} 代表参与方 1 在第 $t+1$ 轮

的模型参数，参与方2类似。 w^* 代表聚合后全局最优值， w_1^* 与 w_2^* 则分别代表参与方1、2的局部最优值。从图中可以看出，在数据 IID 场景下各参与方模型更新方向与集中式训练的理论更新方向较为接近，各参与方能够产生较大的协同作用，使得最终聚合后的全局模型参数能够接近于全局最优值。同时，由于各参与方数据分布一致，联邦学习每个通信轮中可以随机选取部分节点参与训练而不影响模型拟合的总体分布，从而在保证模型性能的基础上降低通信开销。然而，在 Non-IID 数据场景下，由于各参与方本地模型所拟合的数据分布不一致，本地训练后只得到了适用于其本地数据分布的模型，这些模型的优化目标因为数据分布的不一致也将产生分歧。在本地训练完成后的全局聚合阶段，由于各方优化目标不一致所带来的参数更新方向不一致，聚合后的全局模型参数将偏离全局最优值，产生较大的方向偏差。




图 2.5 联邦学习的漂移现象

Figure 2.5 Client drift in Federated Learning

2.4.2 Non-IID 数据造成的权重发散

Non-IID 数据会严重影响联邦学习各参与方本地训练的更新优化方向，从而对联邦学习最终的全局模型造成较大的负面影响。然而仅凭上述定性分析很难量化研究不同程度的数据分布对联邦学习所带来的影响程度，难以通过定量分析的方式对现有联邦学习算法进行优化与改进。因此，需要对数据的分布差异性与联邦学习聚合后模型的权重参数偏离程度进行度量，以定量地描述数据的分布差异与联邦学习模型训练后的权重分歧程度。

权重发散（Weight Divergence）^[72]被提出，用来衡量在联邦学习中采用相同的权重初始化情况下，本地模型在训练过程中形成的权重与全局模型的权重之间产生的差异。具体地，权重发散的公式化表达如下：

$$\text{weight divergence} = \frac{\|w^{Fed} - w^{SGD}\|}{\|w^{SGD}\|} \quad (2-7)$$

式中， w^{Fed} 表示联邦学习每轮训练后的全局模型参数， w^{SGD} 则表示数据集中式学习时采用SGD训练获得的模型参数。通过权重发散可以定量分析联邦学习在不同Non-IID数据影响下全局模型权重与集中式学习权重的差异，并一定程度上反映模型受

Non-IID 数据影响的大小。

采用 FedAvg 算法在 CIFAR10 数据集下的不同分布场景进行权重发散实验，以测试 Non-IID 数据对传统联邦学习的影响。数据分布采用同分布、中等倾斜分布与极端倾斜分布（由 β 控制的 Dirichlet 分布产生）。模型为一个 3 层 CNN 与 3 层线性层神经网络，不同分布条件下神经网络各层的权重发散如图 2.6 所示。




图 2.6 FedAvg 在不同分布场景下的权重发散

Figure 2.6 Weight divergence of FedAvg in different distribution scenarios

表 2.1 CIFAR10 数据集下 FedAvg 的权重发散

Table 2.1 Weight divergence of FedAvg in CIFAR10

分布场景	权重发散					
	conv1	conv2	conv3	fc1	fc2	fc3
CIFAR-10 (IID)	0.1258	0.1032	0.0914	0.0329	0.1594	0.3546
CIFAR-10 ($\beta = 0.1$)	0.2637	0.2581	0.3146	0.2237	0.3217	0.8212
CIFAR-10 ($\beta = 0.1$)	0.3924	0.3597	0.4281	0.2874	0.3973	0.9364

表 2.1 定量展示了在两个不同数据集上 FedAvg 不同网络层的权重发散大小。通过对比可以发现，模型权重发散的程度随着数据 Non-IID 程度的增大而增大，同时网络层中每层权重发散程度各异，并且最后一层全连接层差异最大。最后一层全连接层与网络输出结果直接相关，其产生大的权重分歧易使神经网络的推理结果偏离，并最终导致神经网络的推理准确率下降。

2.5 知识蒸馏

近年来基于神经网络的深度学习发展迅速，在神经网络的背景下，一个模型若要取得好的预测效果往往需要大量的神经元参数以保证其知识承载能力。在研究与应用场景中一个好的模型往往具有相当规模的参数体量，需要耗费大量的存储空间，同时在模型推理时亦会消耗大量计算单元并存在较大的推理延迟。为了降低模型部署时的各类开销，Bucilua 等人^[73]提出模型压缩技术以在减少模型参数量的同时尽可能保证模型性能。知识蒸馏作为一种有效的模型压缩技术在 2015 年被 Hinton 等人提出，用以将大模型中的知识转移到较小的模型当中，同时不造成任何模型准确率的重大损失，其示意图如图 2.7 所示。有别于传统的剪枝、量化等依靠对原模型进行修剪的模型压缩技术，知识蒸馏将大模型看作教师，将小型模型看作学生。通过将教师模型中通过大量训练得到的知识提取迁移到学生模型中，以达到模型压缩的目的。其原理是通过将教师模型对数据样本的输出作为“软标签”，在学生模型训练时将其通过 KL 散度引入损失函数，使学生模型不仅关心样本标签，同时也关注其教师“软标签”，以达到教师模型与学生模型间知识迁移的效果。目前知识蒸馏技术通过不断发展，诞生了许多衍生技术，知识蒸馏也逐渐在非模型压缩领域取得成果。




图 2.7 知识蒸馏模型结构

Figure 2.7 Knowledge distillation model structure

知识蒸馏中涉及多种知识表征方式，主要分为三种形式：基于响应的知识，基于关系的知识与基于特征的知识。基于响应的知识是指教师模型神经网络输出层的最终结果，其核心理念在于引导学生模型直接向教师模型的最终预测靠近。基于关系的知识则是将教师模型的多个输出结果整合为特征组的形式，令学生模型学习教师模型输出特征组的结构化知识。基于特征的知识则常指将教师模型的中间层输出特征图作为知识用以指导学生训练。本文主要关注前两者。除此之外，知识蒸馏在蒸馏结构与算法上也发展出多个类别，其中包括多教师蒸馏和协作蒸馏等。

2.5.1 基于响应的知识蒸馏

在知识蒸馏中，基于响应的方法主要关注教师模型输出层的概率分布。如图 2.8 所示，教师模型不仅仅给出最终预测的类别，而是提供一个软化的概率分布，其中包含更多关于各个类别的置信度信息，而不仅仅是硬标签。学生模型的目标是在训练过程中尽可能地模仿这种软化后的概率分布，从而捕获教师模型的决策边界和类别间的相对相似性。响应（logit）通常指的是模型最后一层输出的未归一化向量，在 softmax 激活函数作用下会转化为类别的概率分布，目的在于令学生模型直接模拟教师模型的最终预测结果。




图 2.8 基于响应的知识蒸馏

Figure 2.8 Response-based knowledge distillation

2.5.2 基于关系的知识蒸馏

基于关系的知识蒸馏是一种知识蒸馏技术的变体，与基于响应的知识蒸馏不同，其侧重于挖掘和传输不同数据样本输出空间中的高维结构关系。如图 2.9 所示，通过对教师输出 logits 间高维结构关系的学习，能够令学生模型学习到更加稳定且鲁棒性高的深层次、复杂关系知识，从而在有限的资源条件下，提升模型性能和泛化能力。




图 2.9 基于关系的知识蒸馏

Figure 2.9 Relationship-based knowledge distillation

利用 $\hat{f}_t, \check{f}_t$ 与 $\hat{f}_s, \check{f}_s$ 分别表示教师模型和学生模型的输出 logits 组。 Ψ_t 和 Ψ_s 分别是教师模型和学生模型的关系距离计算公式。 L_{div} 表示计算教师与学生模型关系知识相似性的损失函数，可将其公式化表达如下：

$$L(f_t, f_s) = L_{div}(\Psi_t(\hat{f}_t, \check{f}_t), \Psi_s(\hat{f}_s, \check{f}_s)) \quad (2-8)$$

通过对不同数据样本在教师模型中输出结果的相互关系进行学习，可以使学生模型更好的继承教师模型知识，以高维的视野进一步学习教师模型输出的结构化特征。 L_{div} 通常采用样本间的相对距离、成对相似度等，用以指导学生模型学习得到更好的结果。

2.5.3 基于特征的知识蒸馏

基于特征的知识蒸馏强调的是利用教师模型中间层学习到的特征表达来指导学生模型训练。如图 2.10 所示，对于中间层和最后输出层的输出结果，都可以作为教师模型的知识用以知识蒸馏过程。对中间层输出的特征知识进行学习可以作为响应知识的进一步补充，特别是对于训练窄而深的网络往往有较好的效果。




图 2.10 基于特征的知识蒸馏

Figure 2.10 Feature-based knowledge distillation

基于特征蒸馏的方法允许学生模型不仅学习教师模型的最后一层输出，还能学习到深层的特征层次结构。例如，学生模型可以通过最小化其中间层特征与教师模型对应层特征之间的差异来学习更加丰富的表示能力。

2.6 生成对抗网络

生成对抗网络（Generative Adversarial Networks, GAN）是由 Ian Goodfellow 等人^[74]提出的一种生成式深度学习框架，用于估计复杂数据分布，并从中生成新的、逼真的样本。在 GAN 架构中包含两个核心组件——生成器（Generator）与判别器（Discriminator）。这两个模块各自承担着独特的职责：生成器致力于创造出与真实数据难以区分的新样本，而判别器则负责精确地区分哪些样本源自生成器，哪些样本来自实际的真实数据集。从博弈论的角度解读 GAN 的训练流程，可以将其比拟为一场“猫鼠游戏”，生成器与判别器不断对抗训练，最终获得更好的生成效果。




图 2.11 生成对抗网络模型

Figure 2.11 Generating Adversarial Network

如图 2.11 所示，生成器 G 通常采用一个固定长度的随机向量作为输入 z ， z 通过从简单分布（如高斯分布）随机采样得到。让神经网络直接生成一个数据分布比较困难，这样利用生成器建立简单分布到复杂分布的映射关系较为可行。将生成器生成的数据分布记为 P_G ，将需要生成器需要逼近的真实数据分布记为 P_{data} ，整个生成对抗网络的目标即为使 P_G 尽可能逼近 P_{data} ，生成器网络的优化目标如下：

$$G^* = \underset{G}{\operatorname{argmin}} \operatorname{Div}(P_G, P_{data}) \quad (2-9)$$

Div 是某种计算不同分布之间距离的函数，然而连续分布间的距离通常难以用函数直接计算。GAN 创新性地提出了利用判别器对真假数据进行判别，判别器作为一个二元分类器与生成器对抗训练，可以做到在对抗训练中不用公式显示计算的情况下即可估测其分布间距离。最终生成对抗网络优化过程的损失函数可表示为：

$$G^* = \underset{G}{\operatorname{argmin}} \max_D V(G, D) \quad (2-10)$$

$$V(G, D) = E_{y \sim P_{data}} [\log D(y)] + E_{y \sim P_G} [\log(1 - D(y))] \quad (2-11)$$

除了常规的 GAN 以外，若想让生成器生成指定类别的数据，则需要在生成器端引入额外的条件信息，判别器也需要识别该生成结果与指定的类别是否一致，这种网络模型叫做条件生成对抗网络模型 (Conditional GAN)。此外，GAN 还衍生出了许多变体与改进版本，例如 Wasserstein GAN (WGAN)、循环一致性 GAN (CycleGAN) 等，其应用包括但不限于图像生成、音视频生成、风格迁移以及强化学习等领域。

第3章 基于协作知识蒸馏的本地训练方法

联邦学习的本地训练阶段包含若干步骤，每轮参与训练的各方首先下载上一轮全局模型，之后利用下载好的全局模型在本地数据集上进行训练优化，并最终将训练完成的模型上传给服务器用以进行全局聚合，从而收集所有参与方模型知识以实现各方协作训练。然而，联邦学习中常见的本地训练方式在 IID 场景下表现良好，但在 Non-IID 场景下表现不佳。同时，联邦学习中要求各方必须采用相同的模型结构，阻碍了各参与方针对自身数据及场景特点设计独立的模型结构。

针对上述问题，本章在联邦学习的本地训练阶段提出了一种基于全局模型与本地模型协作知识蒸馏的优化方法。该方法引入协作蒸馏对本地模型与全局模型设计了解耦方案，允许各方独立设计其本地模型结构。更进一步，为了充分挖掘模型输出潜在空间中的优质知识表征，该方法引入关系知识与响应知识相结合以提升正向知识传输，并利用基于信息熵的自适应权重策略更好地传递优质知识。该方法在解耦本地与全局模型结构的同时，加强了知识的传递质量与效率，可以为 Non-IID 场景下的联邦学习应用场景提供更为高效、准确的本地训练方式。

3.1 Non-IID 数据下的知识遗忘

从持续学习的角度来看，联邦学习中由于 Non-IID 数据所导致的权重发散可以视作本地训练结束及全局模型聚合后对各参与方本地训练知识的遗忘。各参与方持有的本地数据在现实中很可能具有不同分布，以至于其与全局数据分布存在偏差，这将导致模型难以正确收集知识并拟合正确的数据分布。与持续学习中存在的问题类似，这种分布间的差异令各参与方在训练过程中对全局知识产生遗忘，进而严重影响了联邦学习的性能表现及收敛速度^[75]。这是因为各方在本地数据上的本地目标与全局目标存在差异，本地训练时的目标是降低本地经验损失，而全局模型则旨在降低全局经验损失，其间在数据 Non-IID 情形下存在差异。类似持续学习^[76,77]中的遗忘现象，联邦学习的各参与方在本地训练时其各自的目标函数也有差异。该现象会导致在本地训练阶段参与方按照其各自目标函数优化方向进行优化，仅降低私有数据交叉熵损失进而过拟合本地数据分布，最终导致知识遗忘。同时，在全局聚合阶段的稀有特征削弱甚至抵消，将导致全局模型产生知识遗忘，泛化性能下降。这类现象在数据非独立同分布场景下尤为严重，将导致全局模型聚合后偏移出“知识留存域”，如图 3.1 所示。




图 3.1 联邦学习的知识遗忘现象

Figure 3.1 Knowledge forgetting in Federated Learning

在 CIFAR-10 数据集下对 FedAvg 算法进行实验，针对联邦学习的训练过程对模型的预测情况随通信轮次的增长变化进行分析。图 3.2 (a) 对一个通信轮次内，本地训练后产生的知识遗忘进行了实验，可以看到全局模型中高精度的类别知识在本地训练后出现了下降，由于模型学习目标仅为降低本地数据集上交叉熵损失，对本地数据分布的过度拟合和负向知识传递导致知识遗忘，泛化能力下降。图 3.2 (b) 中进行了 100 个通信轮次的实验，并记录了每轮全局模型对各类别的预测精度。结果表明在 IID 场景下，本地模型和全局模型的学习十分连贯，积累知识均匀。相反在 Non-IID 场景下，全局模型在不同轮次对样本各类别的预测精度变化较大，先前精度较高的部分类别往往在随后伴随着精度明显下降。以上实验分析说明与持续学习中由于数据分布不同存在的遗忘现象类似，联邦学习也存在知识遗忘。




图 3.2 本地训练及全局聚合阶段的遗忘现象

Figure 3.2 Forgetting phenomena in local training and global aggregation phases

3.1.1 基于 Dirichlet 分布生成的 Non-IID 数据

Dirichlet 分布又称为多元 Beta 分布，是一种在多变量概率分布中广泛应用的概率分布。通常又将 Dirichlet 分布称为“分布的分布”，即是对一种概率分布的分布进行建模。具体的分布方式由参数 β 确定，记为 $Dir(\beta)$ 。其中， β 表示其分布参数，控制分布是倾向均匀还是集中。

Dirichlet 分布的定义可以被描述如下：假设存在一个 K 维向量，将该向量记作 $x = (x_1, x_2, \dots, x_K)$ 。该向量属于 $K - 1$ 阶单纯形， $K - 1$ 阶单纯形满足 $\sum_{i=1}^K x_i = 1$ 且 $x_i \geq 0$ ， $i \in \{1, \dots, K\}$ 。其中每个 x_i 对应一个参数 β_i ，记作 $\beta = (\beta_1, \dots, \beta_K)$ 。通过以上定义，Dirichlet 分布的概率密度函数可表示为：

$$f(x_1, \dots, x_K; \beta_1, \dots, \beta_K) = \frac{1}{B(\beta)} \prod_{i=1}^K x_i^{\beta_i-1} \quad (3-1)$$

其中，概率密度函数上的分母为用于归一化的多元 Beta 函数，可以通过含有 Gamma 函数表示：

$$B(\beta) = \frac{\prod_{i=1}^K \Gamma(\beta_i)}{\Gamma(\sum_{i=1}^K \beta_i)}, \beta = (\beta_1, \dots, \beta_K) \quad (3-2)$$

在联邦学习实验中，数据通常分散在多个参与方，并且由于隐私保护、地域差异等因素，各个参与方的数据通常不满足 IID 假设。然而，现阶段还没有一个通用的 Non-IID 数据集供学术界进行研究分析，因而针对联邦学习的研究中常采用 IID 数据集与 Dirichlet 分布来手动划分 Non-IID 数据。为了模拟这种场景并评估联邦学习算法在数据 Non-IID 场景下的性能，可通过 Dirichlet 分布来生成具有不同数据分布特性的参与方数据集，其公式化表达如下：

$$q \sim Dir(\beta p) \quad (3-3)$$

利用 Dirichlet 分布来模拟 Non-IID 数据时，可以设定不同的 β 参数来控制各个参与方本地数据集中的类别分布不均匀性。简单来说，当采用 IID 数据集划分时，若 $\beta \rightarrow \infty$ ，则所生成的参与方上数据分布趋向于均匀分布。反之，当 $\beta \rightarrow 0$ 时，每个参与方的样本数据将会获得高度倾斜的数据分布，不同参与方之间的数据分布差异也越大。在联邦学习研究中，Dirichlet 分布能够通过调整其参数 β 来控制模拟参与方数据的类别分布差异，从而有效模拟真实环境中可能出现的各种 Non-IID 现象。

3.2 协作与关系蒸馏模式

针对联邦学习中的知识遗忘所带来的学习不一致性和由此导致的性能下降问题，在本地训练阶段从拓展蒸馏知识维度的角度提出一种新型联邦学习方法：FedCRD (Federated Co-Rational Distillation)。在每一轮通信中，FedCRD 随机选择一组参与方

并将全局模型广播给他们。每个参与方首先初始化本地模型，在每轮通信中将接收到的全局模型与本地模型以协作蒸馏的方式利用本地数据进行训练。具体来说，将预测知识的高维空间关系作为补充约束对模型进行训练，从而更有效地挖掘全局模型的优质知识表征用于指导本地模型，提升正向知识传输同时缓解知识遗忘。并且在本地模型的训练过程中，为了提升正向可靠的蒸馏知识传输，本文提出一种基于熵的自适应权重策略自动调整响应知识与关系知识的学习比例。其整体流程如算法 3-1 所示。

算法 3-1 FedCRD 训练过程

输入: T : 训练总轮次; N : 参与方数量; C : 每轮训练中活跃参与方数量; $\{D_i\}_{i \in \{1, \dots, N\}}$: 参与方本地数据; $p_g(x), p_n(x)$: 全局模型和本地模型的预测输出; η : 学习率; E : 本地轮次

输出: $w = [w_1, \dots, w_N] \cup w_g$

```

1: Initialize  $w$ 
2: ServerExecutes:    # 服务器聚合阶段
3: for each round  $t \in \{1, 2, \dots, T\}$  do
4:    $S_t \leftarrow$  random subset ( $C$  fraction) of the  $N$  clients
5:   for each clients  $i \in S_t$  in parallel do
6:      $w_{g,i}^t \leftarrow$  ClientUpdate ( $i, w_g^t$ )
7:   end for
8:   Server Aggregation:  $w_g^{t+1} = \frac{1}{|S_t|} \sum_{i \in S_t} w_{g,i}^t$ 
9: end for
10: ClientUpdate( $i, w_g^t$ ):    # 参与方本地训练阶段
11: for each  $e \in \{1, 2, \dots, E\}$  do
12:   for batch  $b = \{x, y\} \in D_i$  do
13:      $L_{local} = \alpha L_{CE} + (1 - \alpha) \left[ \lambda \mathcal{D}_{KL} (p_g(x) \parallel p_n(x)) + (1 - \lambda) L_{RKD} \right]$ 
14:      $L_{global} = \alpha L_{CE} + (1 - \alpha) \left[ \mathcal{D}_{KL} (p_n(x) \parallel p_g(x)) + L_{RKD} \right]$ 
15:      $w_i^t \leftarrow w_i^t - \eta \nabla L_{local}$ 
16:      $w_{g,i}^t \leftarrow w_{g,i}^t - \eta \nabla L_{global}$ 
17:   end for
18: end for

```

3.2.1 联邦学习问题定义

联邦学习的目标是在不需将每个参与方数据集中进行训练的情况下，各方协同训练出一个图像分类模型。假设其中包含 N 个参与方和 1 个服务器，其中参与方 n 包含其私有数据 $D_n := \{x_i, y_i\}$ ， x_i 代表数据集中的第 i 个样本， y_i 为该样本对应的类别标签， $y_i \in \{1, 2, \dots, K\}$ 。经典联邦学习可以被描述为解决如下优化问题：

$$\min_w \mathcal{L}(w) := \sum_{n=1}^N \frac{|D_n|}{|D|} \mathcal{L}_n(w), \text{ where } \mathcal{L}_n(w) = \frac{1}{|D_n|} \sum_{i=1}^{|D_n|} \mathcal{L}_{CE}(w; x_i, y_i) \quad (3-4)$$

全局目标函数 $\mathcal{L}(w)$ 由 N 个参与方的本地目标函数加权平均得到，参与方 n 的权值通常正比于其私有数据量 $|D_n|$ 。为了求解公式(3-4)，每个通信轮 t ，服务器将上轮聚合得到的全局模型参数分发给该轮被选中的参与方，不同参与方在各自数据集 D_n 上用本地目标函数 $\mathcal{L}_{CE}$ 进行本地更新。之后，服务器将收集到的本地模型参数进行聚合并生成下一轮的全局模型。

这类传统 FL 算法（以 FedAvg 为代表）在数据同分布场景下能够实现不同设备间隐私受限下的协同学习，并取得较为不错的性能。然而，现实应用中由于用户偏好与特征的不同以及设备采集信息场景的不同，实际场景下的数据分布通常表现出显著的 Non-IID 特性，这会使得传统 FL 的模型性能明显下降。由于每个参与方的本地目标函数拟合的分布与全局目标函数并不一致，采取上述优化目标容易导致知识遗忘从而造成模型性能下降。




图 3.3 FedCRD 整体结构

Figure 3.3 Overall structure of FedCRD

3.2.2 本地训练的协作蒸馏方式

FedCRD 的整体结构以及关键损失与模块如图 3.3 所示。在每轮通信 t 中，被服务器选中的参与方获取来自服务器的全局模型，同时在整个联邦学习过程中保留其本地模型。本地训练阶段，本地模型和全局模型的损失由分类交叉熵损失和蒸馏损失，即

响应蒸馏损失和关系蒸馏损失组成。双方进行协作蒸馏使得不同模型交替扮演教师与学生，以获取来自对方模型的响应知识和关系知识，从输出嵌入空间学习高维结构知识并提升正向知识传输，加快知识获取效率。同时，降低硬性约束造成的模型过拟合及知识遗忘。最后各参与方将更新后的全局模型上传至服务器，由服务器聚合形成次轮新的全局模型并重复上述过程直至收敛。本地模型和全局模型的损失函数定义为：

$$\mathcal{L}_{local} = \alpha \mathcal{L}_{CE} + (1 - \alpha) \left[\lambda D_{KL} \left(p_g(x_i) \parallel p_n(x_i) \right) + (1 - \lambda) \mathcal{L}_{RKD} \right] \quad (3-5)$$

$$\mathcal{L}_{global} = \alpha \mathcal{L}_{CE} + (1 - \alpha) \left[D_{KL} \left(p_n(x_i) \parallel p_g(x_i) \right) + \mathcal{L}_{RKD} \right] \quad (3-6)$$

其中， α 为超参数，控制本地数据集知识与模型间蒸馏知识的权重比例。在初始训练阶段可以设置偏大以充分学习本地数据集知识。随着训练轮次的增加，对 α 采用指数动态衰减（Exponential auto decay, eda）可以充分交换本地模型与全局模型的知识以加强协作蒸馏效果。本地损失中的 λ 则为自适应权重系数，从预测信息熵的角度，用以在每个数据 batch 间自动权衡该轮响应知识和关系知识的比例，提升教师知识质量，详细过程在 3.2.4 节阐述。处于本地的全局模型以相同比例吸收来自本地模型的响应知识和关系知识，取代传统方法中仅采用交叉熵损失的训练方式，进而避免模型对私有数据的过度拟合，全局知识遗忘以及泛化性能下降。最后，将全局模型参数进行上传。

分类损失采用交叉熵计算，以参与方 n 的训练为例，以 z^n, z^g 分别代表客户 n 的本地模型和全局模型的 logit 输出，本地模型的数据集为 $D_n = \{x_i, y_i\}, y \in \{1, 2, \dots, K\}$ ，上标 k 则代表 logit 中对应的类别。本地训练时全局模型和本地模型的分类损失定义为：

$$\mathcal{L}_{CE} = \sum_{i=1}^{|D_i|} -y_i \log[p(x_i)] \quad (3-7)$$

其中全局模型和本地模型的预测 $p(x)$ 分别为：

$$p_g(x) = \frac{\exp^{z^g/T}}{\sum_{k=1}^K \exp^{z^{g,k}/T}}, \quad p_n(x) = \frac{\exp^{z^n/T}}{\sum_{k=1}^K \exp^{z^{n,k}/T}} \quad (3-8)$$

3.2.3 关系知识蒸馏

模型输出间的高维空间关系往往考虑二元组的距离关系与三元组的角度关系。以距离关系为例，对每一批 mini-batch 数据中一对给定的样本 (x_i, x_j) ，用欧氏距离度量其距离关系：

$$\psi_D(z_i, z_j) = \frac{1}{\mu} \|z_i - z_j\|_2, \mu = \frac{1}{|D^2|} \sum_{x_i, x_j \in D, i \neq j} \|z_i - z_j\|_2 \quad (3-9)$$

其中， D 代表一个 mini-batch 数据集， μ 为一批 mini-batch 数据中所有样本对输出的平均距离。以 μ 作为标准化系数缩放距离大小以考虑输出间的相对距离。整体的关

系知识损失 $\mathcal{L}_{\text{RKD}}$ 定义如下：

$$\mathcal{L}_{\text{RKD}} = \sum_{x_i, x_j \in \mathcal{D}_i, i \neq j} l_{\delta} \left(\psi_D(z_i^g, z_j^g), \psi_D(z_i^n, z_j^n) \right) \quad (3-10)$$

l_{δ} 选用 huber loss，该损失函数将 MSE 与 MAE 结合，减小了 MSE 对离群点的高惩罚倾向及 MAE 对小损失点的过高梯度，是一种更加鲁棒的损失函数。对角度关系而言， $\mathcal{L}_{\text{RKD}}$ 中改以三元组计算关系损失，这里不再赘述。对于一个给定的样本三元组 (x_i, x_j, x_k) ，其空间角度结构可用该三元组在输出嵌入空间中构成的三角函数度量：

$$\psi_A(x_i, x_j, x_k) = \cos \angle x_i x_j x_k = \left\langle \frac{x_i - x_j}{\|x_i - x_j\|_2}, \frac{x_j - x_k}{\|x_j - x_k\|_2} \right\rangle \quad (3-11)$$

3.2.4 蒸馏知识的自适应权重调节

为了更好地权衡传统知识蒸馏与关系知识蒸馏的惩罚权重，本文进一步提出了一种基于熵的自适应权重策略（entropy-wise adaptive weight, ewaw），帮助本地模型根据全局模型对于不同样本的预测能力自适应地控制不同蒸馏知识的影响，防止负面知识的过度转移。当全局模型对样本类别的预测可信时，本地模型对响应知识和关系知识进行均衡学习。否则，本地模型将更多地关注关系知识。以距离关系为例，如图 3.4 所示，当全局模型对样本类别预测错误的情况下，输出 logit 间其余类别的关系知识更加可信，通过自适应系数调整不同蒸馏知识对损失的贡献以向本地模型传递优质知识。




图 3.4 蒸馏知识的自适应调整过程

Figure 3.4 Adaptive adjustment process for distillation knowledge

利用信息量与信息熵可以评估模型输出结果的置信程度^[78,79]，如果一个事件的不确定性越大，则其发生后所传递的信息量就越大。相反若一个事件的不确定性越小，其发生后所传递的信息量则越小。信息量即随机变量取某个特定值时，对其概率 $p(x)$ 的倒数取对数，记为 $-\log_2 p(x)$ 。

信息熵则是用于衡量整个事件空间中包含的平均信息量，即信息量的平均期望。只需要将事件空间中所有事件发生的概率，乘以该事件的信息量，即可得到信息熵：

$$H_p(X) = \sum_x p(x) \cdot \log_2 \frac{1}{p(x)} = - \sum_x p(x) \cdot \log_2 p(x) \quad (3-12)$$

信息熵可以表征一个概率系统的不确定性程度，其值越大则一个系统的不确定性就越大。一个样本 (x_i, y) 经过下载的全局模型后得到预测输出 $p_g(x_i)$ ，对每个 mini-batch 中的 M 个样本输出计算其熵，以评估该 batch 下全局模型的预测表现：

$$H(p_{batch}) = -\frac{1}{|M|} \sum_{i=1}^M \sum_{k=1}^K p_g(x_i) \log p_g(x_i) \quad (3-13)$$

其中 K 代表预测输出的总类别数， k 表示具体类别。越小的信息熵代表越高的置信度，反之亦然。利用一个映射函数控制其权重系数， λ 最终定义为：

$$\lambda = \frac{\eta}{(e^{H(p_{batch})} + 1)} \quad (3-14)$$

超参数 η 选用 1.6 以将结果映射到对应区间，经后续实验表明是一个合适的比例区间（见 3.3.4.3 节超参数实验部分）。由此，根据熵的大小自适应地确定该批次数据响应知识与关系知识的权重比例，在该轮全局输出对本地数据预测可信度不足时，加大高维空间更为鲁棒的关系知识权重，反之则适当增大模型输出的响应知识权重。

综上，FedCRD 通过本地端协作蒸馏的方式解耦模型，避免全局模型过拟合本地数据分布以减少知识遗忘。同时添加关系知识对模型进行损失约束，从高维的视野更有效地学习优质知识表征用于本地模型训练，提升知识质量。并且对不同蒸馏知识添加基于熵的自适应权重策略，从全局模型预测熵的角度自动权衡响应知识与关系知识的约束能力强弱，在预测可信度较低时（即预测熵较低时）自动放大关系知识权重，使算法更加健壮可靠。

3.3 实验与分析

3.3.1 实验环境

本章所提出 FedCRD 算法基于 PyTorch 搭建其中的神经网络模型并采用 Python 编程语言编写。具体软件与硬件配置信息如表 3.1 所示。

表 3.1 实验环境配置信息

Table 3.1 Experimental environment configuration information

环境项	配置信息
操作系统	Ubuntu 18.04.5 LTS
CPU	12 vCPU Intel (R) Xeon (R) Silver 4214R CPU @ 2.40GHz
GPU	NVIDIA GeForce RTX 3080 Ti
内存	32GB
硬盘	1T
PyTorch 版本	1.11.0
Python 版本	3.8 (ubuntu20.04)
Cuda 版本	11.3

3.3.2 数据集选取与划分方式

为了评估所提出算法 FedCRD 的有效性，本节分别在 Fashion-MNIST（简称 FMNIST）、CIFAR-10、CIFAR-100 三个联邦学习研究广泛采用的数据集上进行了实验。FMNIST 是一个包含 60000 张有标签图片的商品数据集，其分为 T 恤、裤子、连衣裙、外套、桑巴鞋、衬衫、运动鞋、手提包、高跟鞋共十个商品类别，每类包含 6000 张 28×28 大小的单通道图片。CIFAR-10 是一个常用的视觉领域深度学习性能评估数据集，其中包含了 10 个标签类别，这 10 个类别分别为飞机、汽车、鸟类、猫、鹿、狗、青蛙、船、卡车和客车，每个类别有 6000 张 32×32 大小的图片。CIFAR-100 数据集是 CIFAR-10 的扩展版，其同样包含 60000 张 32×32 大小的图片，但其类别数量由 10 类增加到了 100 类。CIFAR-100 除了 100 个细粒度类别外，还额外将这 100 个类别组织成了 20 个“超类”，每个超类中包含 5 个细粒度类别，本节实验仅采用细粒度类别进行模型评估。具体的数据集信息由表 3.2 所示。

表 3.2 数据集信息

Table 3.2 Datasets information

数据集	训练集数量	测试集数量	类别数量	图像类型
FMNIST	6 万	1 万	10	28×28 灰度图像
CIFAR-10	5 万	1 万	10	32×32 RGB 图像
CIFAR-100	5 万	1 万	100	32×32 RGB 图像

在 Non-IID 数据划分方面，实验采用 Dirichlet 分布模拟样本类别不均衡的数据分

布场景，通过 β 控制数据 Non-IID 的程度， β 越小代表数据的分布差异程度越大。将 Dirichlet 随机划分的数据分给 10 个参与方，在 $[100, 0.1, 0.01]$ 范围调整 β 大小以分别模拟 IID 场景和不同程度的 Non-IID 场景，当 $\beta = 100$ 时各参与方拥有数据的数量与类别几乎一致，模拟数据同分布的场景。当 $\beta = 0.01$ 时则代表每个参与方数据分布高度不一致，模拟数据分布倾斜严重的场景。

图 3.5 展示了 CIFAR-10、CIFAR-100 数据集和 10 个参与方的场景中，不同 β 取值下各参与方的数据分布情况（FMNIST 数据集与 CIFAR-10 类似）。其中横坐标代表各参与方编号，纵坐标代表数据集中样本标签编号，网格中的气泡大小与该坐标点对应数据量成正比。可以看到，当 $\beta = 100$ 时，数据倾向于均匀分布，随着 β 的减小，各参与方中不同标签下的数据越加倾斜，不同参与方之间的数据分布差异也越大。




图 3.5 不同 β 下数据划分情况

Figure 3.5 Division of data under different β

3.3.3 模型选取与超参数设置

在模型同构的场景下，对于较简单的数据集 FMNIST 与 CIFAR-10 选用六层 CNN 网络模型作为全局模型与本地模型，其包含三层卷积层与三层全连接层，各卷积层后接 relu 激活函数与 maxPooling 层。对于较为复杂的 CIFAR100 数据集，选用 ResNet18 作为全局模型与本地模型。在模型异构场景下，分别选用 CNN、MLP、ResNet18、VGG16 作为参与方本地模型，其中 CNN 模型结构选用表 3.3 所示。全局模型随实验方式不同而改变，具体设置详见后文。

表 3.3 CNN 模型结构

Table 3.3 CNN model structure

网络类型	输入通道	输出通道	卷积核	步长	激活函数
Conv2d	3	32	3	1	ReLU
Conv2d	32	64	3	1	ReLU
Conv2d	64	64	3	1	ReLU
FC	1024	1024	-	-	ReLU
FC	1024	64	-	-	ReLU
FC	64	10	-	-	Softmax

超参数设置方面，若无特别说明则所有方法都将本地训练 epoch 设置为 5，通信轮次根据训练收敛情况设置为 100 或 200，同时联邦学习参与方数量设置为 10（活跃比例设置为 1，即每轮所有参与方都将参与训练）。对于算法中所涉及的蒸馏温度 T 统一设置为 1。在本地训练阶段，批处理大小（BatchSize）设置为 64，优化器选用随机梯度下降（SGD），学习率（lr）设置为 0.01 并采用衰减因子为 0.99 的指数衰减算法， α 设置为 0.5。采用固定初始化的方式进行模型初始化，以保证不同方法的初始模型位于同一起点。

在下一节实验结果中，首先将所提出的 FedCRD 算法的几种变体，即仅考虑距离关系的 FedCRD-dist、仅考虑角度关系的 FedCRD-angle 与同时考虑距离与角度关系的 FedCRD-dist&angle 同经典联邦平均算法 FedAvg 进行 IID 及不同 Non-IID 场景下的性能对比，然后在各参与方模型异构的场景下验证 FedCRD 的性能表现。最后，针对 FedCRD 算法的超参数选取进行实验并对不同模块进行消融实验，探索关系知识、基于熵的自适应权重调节及映射超参数等对所提出算法的影响。实验中均固定随机数种子以避免数据集加载顺序等对实验结果产生影响。

3.3.4 实验结果

3.3.4.1 IID 场景中算法性能对比

针对 Non-IID 场景下对本地训练的调整可能影响到模型在 IID 场景的表现，因此实验以 FedCRD-dist 为例，首先验证数据 IID 场景下 FedCRD 不会对模型最终测试准确率造成负面效果。在表 3.4 中，展示了 FedCRD-dist 与 FedAvg 两种方法在 FMNIST，CIFAR-10 和 CIFAR-100 三个数据集中 IID 数据划分下的模型测试准确率对比实验。网络模型选用 CNN、ResNet-18 以及 VGG-16 在内的三种基础网络架构，目的在于检验 FedCRD 方法在数据 IID 场景下相较于 FedAvg 是否会产生负面影响。从实验数据显示，在共计 9 个不同的模型与数据集组合场景中，FedCRD-dist 在 7 个场景中取得了更好的

性能。例如，在 CIFAR-100 数据集和 CNN 模型的组合场景下，FedCRD-dist 取得了 72.39% 的准确率，对比 FedAvg 提升了 0.08%。实验结果表明在 IID 场景下 FedCRD-dist 不会对模型推理准确率造成负面影响，甚至在部分场景下准确率能够略有提升。

表 3.4 各算法在 IID 场景下的性能对比

Table 3.4 Performance comparison of algorithms in IID scenarios

算法	模型	不同数据集准确率(%)		
		FMNIST	CIFAR-10	CIFAR-100
FedCRD-dist	CNN	91.23	88.81	72.39
	ResNet-18	92.61	89.98	76.14
	VGG-16	92.14	89.14	75.29
FedAvg	CNN	91.29	88.73	72.31
	ResNet-18	92.59	89.99	76.12
	VGG-16	92.08	89.12	75.24

3.3.4.2 Non-IID 场景中算法性能对比

本节在三个数据集（即 FMNIST, CIFAR-10, CIFAR-100）上按 Dirichlet 划分方式对不同方法在 Non-IID 场景下进行了实验对比，三个数据集均按照 3.3.2 节中提供的 Non-IID 场景划分进行设置，并在之后进行了模型异构场景下的实验验证。图 3.6 展示了在 CIFAR-10 数据集上，按照 Dirichlet 划分 $\beta = 0.1$ 及 $\beta = 0.01$ 时不同算法的性能表现。




图 3.6 CIFAR-10 不同 Non-IID 场景下各算法性能对比

Figure 3.6 Algorithms performance under Different Non-IID scenarios in CIFAR-10

在每个独立的子图中，横轴表示联邦学习训练过程中的通信轮数，纵轴则表示模型的测试准确率。可以看到，在图 3.6 (a) 中 FedCRD 的三种形式均取得了高于

FedAvg 的测试准确率，分别为 81.34%、80.68%与 78.23%，而 FedAvg 的测试准确率为 78.04%。由此可以看出，FedCRD 通过使参与方本地模型维持持续训练状态，并通过协作蒸馏的形式传递本地模型与全局模型间保存的知识，能够使模型准确率得到提高。图 3.6 (b) 展示了类似的结果，对比 FedAvg，FedCRD 的三种形式分别取得了 5.24%、4.58%与 3.41%的准确率提升。同时可以看到，FedCRD-dist 取得了最高的测试准确率，FedCRD-dist&angle 相比 FedCRD-dist 准确率有所下降，FedCRD-angle 则相较 FedAvg 提升并不明显。据此可以推断在联邦学习的协作蒸馏中，模型输出间的距离损失作为蒸馏知识效果好于角度损失。由于角度损失是比距离损失更高阶的属性，在训练过程中学生模型将拥有更大的灵活性，在数据 Non-IID 场景下的协作蒸馏中表现不佳。因此，为了简化书写，在本小节之后的实验中，默认采用 FedCRD-dist 作为联邦学习的本地训练方式，并称其为 FedCRD。





图 3.7 CIFAR-100 不同数据分布场景下各算法性能对比

Figure 3.7 Algorithms performance under Different Data Distribution in CIFAR-10

CIFAR-100 数据集上各算法的性能表现如图 3.7 所示，图 3.7 (a) 与 (b) 分别代表了 Dirichlet 划分 $\beta = 0.1$ 及 $\beta = 0.01$ 时算法的性能。与 CIFAR-10 中类似，随着数据分布倾斜的增加，所有算法的准确率都有所下降。在 $\beta = 0.1$ 场景下，FedCRD-dist 取得了最高 47.15% 的测试准确率，对比相同场景下的 FedAvg 算法准确率提升了 3.83%，同时 FedCRD-dist 同样取得了比 FedCRD-angle 与 FedCRD-dist&angle 更高的准确率。在 $\beta = 0.01$ 场景下，FedCRD-dist 取得了最高 34.86% 的推理准确率，而 FedAvg 算法在相同场景下取得了 30.78% 的推理准确率。实验结果说明，通过协作蒸馏解耦全局模型与本地模型能够使双方更为平稳地学习本地数据知识，缓解全局模型过拟合本地数据分布的现象。同时通过自适应权重调节在不同场景下交换优质知识，提升模型训练效果。图 3.8 展示了不同算法在 FMNIST 数据集 $\beta = 0.01$ 划分下的性能表现，结论与前文类似。

图 3.8 FMNIST 在 $\beta = 0.01$ 场景下各算法性能对比Figure 3.8 Algorithms performance under $\beta = 0.01$ in FMNIST

作为个性化联邦学习优化方法，FedCRD 允许各参与方根据自身情况独立设计其本地模型结构。通过将参与方本地模型与下载后的全局模型进行协作蒸馏，可以在解耦本地模型与全局模型的同时，充分学习本地模型个性化训练所得知识，并获得全局模型中来自其余参与方数据的协作知识。并且，通过协作蒸馏交换双方响应知识与关系知识，可以准确并高效地完成模型训练。实验中，将全局模型设置为 VGG 模型，并设置 4 个联邦学习参与方，其本地模型分别设置为：CNN、MLP、VGG16、Resnet18。图 3.9 展示了各参与方采用不同本地模型在 CIFAR10 数据集上进行训练时，各本地模型的测试准确率。图中不同颜色的曲线代表各参与方进行联邦学习后模型的推理准确率变化，颜色与之对应的虚线则代表各方仅在本地上独立训练而不参与联邦学习时的准确率上限。由图 3.9 (a) 可以看到，FedCRD 在 IID 数据场景下进行训练时，可通过全局模型共享所有参与方的数据知识进行协作训练。对于不同的本地模型，相比仅利用本地私有数据单独训练，FedCRD 下各模型准确率分别有 3.8%~10.2% 的提升。同时，由图 3.9 (b) 所示，在 Non-IID 数据且各参与方本地模型异构的情况下，FedCRD 仍能够捕获不同参与方特有的本地数据知识并通过特定的蒸馏方式共享给其余参与方，以提升各参与方本地模型的性能。可以看到，在 Non-IID 数据场景下，不同复杂程度的模型所取得的推理准确率提升各不相同，总体来看越复杂的模型结构在该场景下的推理准确率提升越大，其中 Resnet 达到了 46.89%，说明复杂模型在极端异构场景下所能捕获的全局知识较多，对比仅在参与方本地端利用私有数据欠训练的情况下，能够得到进一步的性能提升。




图 3.9 模型异构场景下各参与方模型推准确率

Figure 3.9 Testing accuracy of each participant in model heterogeneous scenarios

通信开销方面，FedCRD 的通信开销在每个通信轮次内只涉及全局模型的下发和本地训练完成后的梯度上传。与 FedAvg 相比，FedCRD 引入特定蒸馏过程的本地训练方法并不会在每轮通信中带来额外的通信开销。同时，由于 FedCRD 能够解耦本地模型与全局模型，使全局模型可以在保证模型推理准确率的前提下选择较为简单的模型结构，减少每轮传递模型产生的开销，在实际运用时可以根据需求权衡模型准确率与通信开销，选择合适的全局模型结构。最后，相比于 FedAvg，本节所提出的 FedCRD 收敛速度更快，因此其达到目标准确率所需要的总通信轮次也将更少。

3.3.4.3 超参数选取

为了评估 FedCRD 在各程度数据分布倾斜下的鲁棒性，本节测试了 FedCRD 在不同的数据分布情景下（调整 Dirichlet 分布的超参数 β ）的测试精度。图 3.10（a）展示了 FedCRD 在 CIFAR10 数据集中，不同 β 划分下的测试准确率。可以看到，FedCRD 在各种不同分布场景下均优于 FedAvg。随着数据分布差异程度的降低（即 β 增加），两种算法的精度都趋于提高。注意到在 Non-IID 程度较高的情况下，FedCRD 比 FedAvg 有更大的改进，进一步验证了随着 Non-IID 程度的增加，FedCRD 通过改善本地模型训练的知识遗忘与传输质量，能够取得更大的改进效果，使模型推理准确率进一步提升。

为了评估 FedCRD 的适应性，在 CIFAR10 上针对参与每轮学习不同客户数量进行实验。具体来说，本文将 CIFAR10 数据集的训练样本按 $\beta = 0.1$ 场景分配给 100 个参与方，同时选取活跃比例 C 选取为 $[0.05, 0.1, 0.15, 0.2, 0.25]$ 。表 3.5 展示了在每轮学习中不同活跃参与方比例 C 下的测试准确率，同时图 3.10（b）对不同 C 上的测试准确率进

行了可视化展示。可以看出 FedCRD 在各情形下均取得了最好表现。同时可以发现，随着每轮学习中参与客户的增多，各算法的表现会越来越好。




图 3.10 不同 Non-IID 程度 β 及活跃比例 C 下测试准确率


Figure 3.10 Test Accuracy with Different β and active ratio C

表 3.5 不同活跃比例 C 对各算法性能的影响

Table 3.5 Effect of different active ratios C on the performance of each algorithm

FL 算法	测试准确率(%)				
	$C = 0.05$	$C = 0.1$	$C = 0.15$	$C = 0.2$	$C = 0.25$
FedAvg	68.84	72.51	73.26	74.02	74.29
FedCRD	75.34	77.54	78.89	79.11	78.94

超参数 η 作为将预测熵映射到对应系数区间关键参数，决定了不同样本预测下响应蒸馏损失与关系蒸馏损失的惩罚权重。为了评估关键超参数 η 对 FedCRD 的影响，从 $[1.0, 1.2, 1.4, 1.6, 1.8, 2.0]$ 中选取 η 并在 CIFAR10 ($\beta = 0.1$) 及 10 个参与方（活跃比例 $C = 1$ ）场景下实验。当 $\eta = 1$ 时，预测熵即使很小，即预测确定性很高时，响应知识损失仍只能获取 1/2 的权重系数。相反当 $\eta = 2$ 情形下最高则能获取 1 的权重系数（代表该完全舍弃关系知识）。图 3.11 用箱线图展示了不同超参数 η 选择下多次实验的准确率，结果表明 $\eta = 1.6$ 时 FedCRD 能更加合理地利用模型内响应知识与关系知识，并获得最佳表现。同时图中结果也说明了 FedCRD 的健壮性，随着 η 的取值变化，模型准确率大量集中于 0.805 至 0.815 之间，在 $\eta = 1.6$ 时达到最优。

图 3.11 超参数 η 对算法准确率的影响Figure 3.11 Impact of η on the accuracy of the algorithm

3.3.4.4 FedCRD 消融实验

表 3.6 显示了 FedCRD 在 CIFAR10 ($\beta = 0.1$) 上经过 100 轮训练后的准确率, 删除了一些关键模块进行对比。其中 $\mathcal{L}_{\text{RKD}}$ 代表关系知识蒸馏模块, ewaw 代表熵自适应权重模块, eda 代表交叉熵损失权重 α 的指数衰减。去掉 $\mathcal{L}_{\text{RKD}}$ 表示公式(3-5)和公式(3-6)中的协作蒸馏只蒸馏响应知识, ewaw 自然也不存在。在早期训练阶段, 较大的 α 可以让模型从各方私有数据集中初步学习知识。随着训练轮数的增加, α 会随着 eda 以指数形式衰减, 从而扩大知识蒸馏的学习比例。可以看出, 去掉任何一部分都会对最终的测试准确率产生一定影响, 尤其是去掉关系知识与自适应系数调整 ewaw 时, 准确率分别下降 2.09% 与 1.28%。这说明在联邦学习中, 传递嵌入空间关系知识且通过预测熵以自适应调节蒸馏知识的惩罚权重十分重要, 能够更好地传输和保留优质知识并减少模型的知识遗忘。

表 3.6 不同算法模块对 FedCRD 的影响

Table 3.6 Impact of different modules on FedCRD

	方法/模块	推理准确率(%)
基线	FedCRD	81.34
	w/o $\mathcal{L}_{\text{RKD}}$	79.25
对比方法	w/o ewaw	80.06
	w/o eda	80.47
	w/o ewaw+eda	79.72

3.4 小结

本章从联邦学习训练阶段的知识遗忘现象出发，提出了一种基于协作蒸馏的本地训练优化方法 FedCRD，通过将响应知识和关系知识纳入本地训练的协作蒸馏，使模型能够从更高维度的输出空间中相互学习知识的可靠表征，减少知识遗忘。此外，引入了基于熵的自适应权重调节模块，以动态权衡各分布场景下不同蒸馏知识对目标函数的损失约束，提升正向知识传输。在 FMNIST、CIFAR10 和 CIFAR100 三个基准数据集上的实验表明，与 FedAvg 算法相比，FedCRD 在测试精度和收敛速度方面都具有优势。最后，在不同 Non-IID 程度和不同参与方活跃比例的应用场景下进行实验，进一步验证了 FedCRD 相比 FedAvg 的优越性。

第4章 基于生成对抗网络的全局聚合方法

联邦学习的本地训练阶段完成后，会将模型参数或梯度上传至全局服务器并聚合生成新一轮全局模型。然而在 Non-IID 数据场景下，尽管各个模型在本地训练阶段已学习到了高质量知识，但由于各参与方节点间数据分布差异较大，传统联邦学习算法简单的加权平均聚合方式会导致某些学到的特定模式或关键特征在全局聚合过程中被“遗忘”。因为那些仅存在于少量参与方上的数据特征，其对应的模型参数在聚合过程中会受到其他参与方模型参数的影响，进而被削弱甚至抵消，并导致最终无法在全局模型中有效保留与表达。基于此，利用生成对抗网络对遗忘知识进行挖掘，并对全局模型进行调优是一种可行的方案。本章提出一种基于生成器对抗训练的全局聚合方法 FedGA，通过在联邦学习的全局聚合阶段，对聚合过程中被遗忘的样本知识进行挖掘生成，以增强全局模型的泛化性能，减少聚合后模型的知识遗忘。

4.1 Non-IID 数据下全局聚合问题分析

Non-IID 数据场景下，某些特定模式或特征可能仅存在于少量参与方的数据当中。在全局聚合阶段，这些稀有特征对应的模型参数由于权重不足或与其他参与方的参数相抵，可能在聚合过程中被削弱甚至完全消除。这种现象最终导致知识遗忘，意味着全局模型未能充分汲取所有参与方的有价值信息，降低了模型的泛化能力与性能表现。

传统联邦学习的服务器聚合方案是以 FedAvg 为代表的定期聚合每轮服务器中的本地模型。FedProx 在本地训练阶段给本地模型添加一个近端项，以限制本地模型更新方向使其更接近上一轮的全局模型。SCAFFOLD 使用方差减少技术来纠正漂移的局部更新。FedDyn^[80]使用线性和二次惩罚项修改客户端的目标，以使全局和局部目标保持一致。然而，这些方法都集中在促使局部和全局模型的对齐上，以缩小局部训练期间的分布漂移，并不是在聚合阶段直接优化全局模型的泛化能力并减少其知识遗忘。

在全局聚合阶段优化方面，大部分联邦学习方法常用到知识蒸馏。在未标记数据集的帮助下，FedDF 提出了用于模型融合的集成蒸馏，使用局部模型的平均 logits 训练全局模型。FedAUX^[81]为局部模型找到一个模型初始化，并使用 (ϵ, δ) 差分隐私确定性评分对局部模型的 logits 进行加权。FedBE^[82]使用局部模型从贝叶斯角度生成一系列全局模型，然后通过集成知识蒸馏将这些模型总结为一个全局模型。然而，所有这些方法都依赖于服务器中一个未标记的公共数据集，公共数据集在实际应用场景中由于隐私限制很难获取。同时高质量的公共数据集是性能提升的关键，即便能够获取到公共数据集，其数据特征往往与参与方本地数据集有一定差异，会直接影响训练质量。

FedGA 从全局聚合阶段的知识遗忘入手，在全局服务器中学习一个轻量级生成器，通过降低特定损失函数的方式拟合各参与方的私有数据分布。同时针对该生成器设计了多样化损失和动态权重系数，使生成数据能够避免“模式坍塌”并且有效地生成全局模型遗忘的知识，不受公共数据集的限制。由于全局服务器一般具备高算力与高性能，部署于全局服务器的生成器训练与推理不会受制于机器的算力性能。

4.2 基于生成器对抗训练的聚合调优策略

本节描述了提出的联邦学习全局聚合方法 FedGA。在每轮通信中，FedGA 随机选择一组参与方并向它们广播全局模型。每个参与方使用全局模型初始化其本地模型，并各自进行本地训练。服务器收集训练后上传的模型并将其聚合为一个初始的全局模型。FedGA 使用生成器从本地模型中拟合数据分布并在服务器中通过知识蒸馏调整聚合后的全局模型，而不是直接将聚合模型广播给下一轮的参与方。具体而言，FedGA 结合了一种具有遗忘样本生成的无数据知识蒸馏方法，有效地探索并将知识转移到全局模型中。同时考虑到参与方的标签分布存在差异，FedGA 采用了动态权重系数计算不同参与方的知识贡献比例，以促进更有效的知识利用。通过对抗训练，令全局模型增强知识获取，同时令生成器倾向生成全局模型学习困难的知识以供训练。图 4.1 展示了服务器上的训练过程与核心损失项。




图 4.1 FedGA 聚合训练过程

Figure 4.1 The process of FedGA aggregation training

FedGA 在服务器端的训练过程分为三个部分。FedGA 在第 t 轮接收局部模型并对其聚合后，对抗性地生成困难样本，并通过 $\mathcal{L}_{ad}$ 将知识传递给聚合的全局模型。利用 $\mathcal{L}_G$ 和 $\mathcal{L}_{dis}$ 来提高困难样本的保真度和多样性。此外，FedGA 使用定制标签采样和类级集成来获得最大的本地模型知识利用率。服务器部分的聚合过程如算法 4-1 所示。

算法 4-1 FedGA 服务器训练过程

输入: T : 服务器训练总轮次; T_g, T_d : 生成器与服务器模型训练轮次; η_g : 服务器全局模型学习率

输出: ω, θ

```

1: Initialize Generator  $\theta$ 
2: ServerExecutes and Aggreagations:
3: for each round  $t \in \{1, 2, \dots, T\}$  do
4:  $(Z, Y) \leftarrow$  random sample noise  $z \sim \mathcal{N}(\mathbf{0}, \mathbf{1})$  and sample  $y \sim [U(0, Y)]$ 
5:   Calulate  $\alpha_j^{k, \tilde{x}}, k \in S_t$ 
6:   for each epoch  $t \in \{1, 2, \dots, T_g\}$  do
7:     Update Generator  $\theta$  while fixing  $\omega$ 
8:   end for
9:   for each epoch  $t \in \{1, 2, \dots, T_d\}$  do
10:    train  $\omega$  inorder to pick up forgotten knowledge while fixing  $\theta$ 
11:   end for
12: end for

```

4.2.1 生成器挖掘数据与蒸馏学习

用 w 表示服务器聚合模型和本地模型的模型参数, 假设联邦学习的参与方一共为 N 个, 同时 $\mathcal{D}_k = \{(x_{k,i}, y_{k,i})\}_{i=1}^{N_k}$ 表示第 k 个参与方上的私有数据集, N_k 则为其数据集样本个数。这里将传统联邦学习简化描述如下:

$$\min_{\omega} \frac{1}{K} \sum_{k=1}^K \mathcal{L}_k(\omega), \mathcal{L}_k(\omega) = \frac{1}{N_k} \sum_{i=1}^{N_k} \mathcal{L}_{CE}(x_k^i, y_k^i; \omega) \quad (4-1)$$

其中, $\mathcal{L}$ 是本地训练阶段的损失函数, 同时对于每个参与方私有数据 $\mathcal{D}_k, k \in [1, 2, \dots, K]$ 可能具备不同分布。同时, 由于隐私保护所限联邦学习算法不能直接求解公式 (4-1)。在每个通信轮 t 中, 被选中的参与方集合 S_t 将其训练后的本地模型发送给服务器, 服务器收集所有该轮选中的本地模型 $\{\omega_k\}_{k \in S_t}$ 并通过平均其梯度或模型参数的方式聚合得到全局模型 ω 。

然而在各参与方数据 Non-IID 的情景下, 本地模型之间往往存在较大偏差, 即产生漂移与遗忘现象。传统的梯度或参数平均聚合的方式会丢失本地模型的知识与信息, 导致聚合后的全局模型在某些样本标签上的预测能力极大地弱于一部分聚合前的模型。针对聚合阶段的知识丢失与遗忘, 本文采用了一种基于生成对抗网络与知识蒸馏的方式对聚合后的全局模型进行进一步调整优化, 以使全局模型尽可能保留聚合前本地模型中保有的知识, 提升全局模型在每轮聚合后的性能表现。

具体地, 在服务器端保有一个生成器 G 用于生成样本辅助训练, 该生成样本用以

捕获各参与方数据集的分布情况，生成器模型如公式（4-2）所示。

$$\tilde{x} = G(z, y; \theta) \quad (4-2)$$

其中， θ 是生成器 G 的模型参数， $z \sim \mathcal{N}(0,1)$ 是采样于标准高斯分布的噪声， y 是生成数据 $\tilde{x}$ 的标签，其采样于均匀分布 $[U(0,Y)]$ ， Y 表示数据集的样本类别最大值。将生成后的数据 $\tilde{x}$ 输入给全局模型并解决公式（4-3）的优化问题：

$$\min_{\omega} \mathbb{E}_{z \sim \mathcal{N}(0,1)} [\mathcal{L}_{ad}] = \min_{\omega} \mathbb{E}_{z \sim \mathcal{N}(0,1)} \sum_{y \sim [U(0,Y)]} \sum_{k \in S_t} \alpha_j^{k,\tilde{x}} \mathcal{L}_{ad}^k \quad (4-3)$$

公式中 $\mathcal{L}_{ad}^j$ 用KL散度衡量全局模型 ω 和本地模型 ω_j ，由公式（4-4）具体表示：

$$\mathcal{L}_{ad}^k = D_{KL}(\sigma(D(\tilde{x}; \omega)) || \sigma(D(\tilde{x}; \omega_k))) \quad (4-4)$$

其中， D 作为分类器用于对抗训练，在联邦学习中代表各本地模型与全局模型。 σ 表示 softmax 函数用以输出关于输入 $\tilde{x}$ 的预测。 D_{KL} 作为 KL 散度衡量模型输出分布差异。权重系数 $\alpha_j^{k,\tilde{x}}$ 用以控制不同本地模型在不同生成数据下的蒸馏知识贡献。通过最小化 $\mathcal{L}_{ad}$ 可以将每轮被选中的本地模型集群 S_t 中的知识传递给全局模型。

为了迫使生成数据 $\tilde{x}$ 能够适配本地模型私有数据的样本空间，本文通过最小化 $\mathcal{L}_G$ 损失训练生成器 G （公式 4-5），其中 $\mathcal{L}_G^k$ 表示第 k 个被选中的本地模型在输入为 $\tilde{x}$ 下其输出与真标签 y 的交叉熵损失，具体定义为公式（4-6）。通过最小化 $\mathcal{L}_G$ ，可以迫使生成器 G 生成符合标签 y 分布的样本空间内数据 $\tilde{x}$ ，并结合后文针对遗忘样本生成数据促进全局模型吸收本地模型知识。

$$\min_{\theta} \mathbb{E}_{z \sim \mathcal{N}(0,1)} [\mathcal{L}_G] = \min_{\theta} \mathbb{E}_{z \sim \mathcal{N}(0,1)} \frac{1}{|S_t|} \sum_{y \sim [U(0,Y)]} \sum_{k \in S_t} \mathcal{L}_G^k \quad (4-5)$$

$$\mathcal{L}_G^k = \mathcal{L}_{CE}(\sigma(D(\tilde{x}; \omega_k)), y) \quad (4-6)$$

4.2.2 生成数据多样性

在条件对抗生成网络中，单纯通过降低 $\mathcal{L}_G$ 损失的方式训练生成器，容易造成生成器倾向于针对每个标签生成相同或类似的数据，因为这样已经足够满足其标签对应的数据样本空间。生成器不必再强迫自己生成不同的数据，这样会造成对每个标签类别而言所生成的数据多样性较差，缺乏真正的内在变异性，该现象被称作生成器的“模式坍缩”。如果生成器在训练过程中发生模式坍缩，其所提供的生成数据将难以充分表征全局模型因聚合所丢失的知识特征，影响后续全局模型的训练质量。

一种符合直觉且有效的方式是通过构造合适的多样性正则损失以限制生成器发散模式坍缩。通过限制不同噪声输入下生成器生成的样本在潜在空间中的距离，鼓励生成器探索空间中更多可能的输出。具体的损失公式化表达如下：

$$\mathcal{L}_{div} = -\frac{1}{|batch|^2} \sum_{z_1, z_2 \in batch} \left(\frac{L_2(G(y, z_1), G(y, z_2))}{L_2(z_1, z_2)} \right) \quad (4-7)$$

其中, $\mathcal{L}_{div}$ 表示生成器的多样性损失, L_2 表示欧几里德范数, $batch$ 表示采样噪声的一个 mini-batch。通过最小化 $\mathcal{L}_{div}$ 可令生成器生成数据多样化, 避免陷入模式坍塌。

4.2.3 整体损失函数

通过对公式 (4-3) 中的 $\mathcal{L}_{ad}$ 进行对抗训练, 实现对遗忘知识的挖掘。对于生成器而言, 利用公式 (4-5) 中 $\mathcal{L}_G$ 仅能让其尽可能生成符合当前标签下样本空间的生成数据, 而这类数据往往是具备鲜明特征的, 意味着更容易被全局模型学习并获得其知识。类似样本往往已经被全局模型正确分类, 单纯利用这类数据进行训练会导致全局模型继续学习其本就掌握良好的样本知识, 不足以推动其捕获样本空间中的遗忘样本知识。

为了有效地利用局部模型中的知识并将其转移到全局模型中, 本文探索了导致局部模型和全局模型之间预测分歧的数据分布中的遗忘样本。通过利用 $\mathcal{L}_{ad}$ 对生成器和全局模型进行对抗性训练以达到使全局模型学习其尚未捕获的遗忘样本知识: 强制生成器最大化 $\mathcal{L}_{ad}$ 以生成困难样本, 同时使用遗忘样本训练全局模型以最小化 $\mathcal{L}_{ad}$, 即利用知识蒸馏迫使全局模型输出与本地模型接近, 学习其本地模型知识。使用 $\mathcal{L}_{div}$ 防止生成器产生模型坍塌, 保证知识多样性。如图 4.2 所示, 生成器产生的遗忘样本帮助模型正确拟合。




图 4.2 生成遗忘样本纠正全局模型拟合

Figure 4.2 Generating forgetting samples to correct global model fitting

最终的目标函数如下：

$$\min_{\omega} \max_{\theta} \mathbb{E}_{z \sim \mathcal{N}(0, \mathbf{I}), y \sim [U(0, Y)]} [\mathcal{L}_{ad} - \lambda_G \mathcal{L}_G - \mathcal{L}_{div}] \quad (4-8)$$

其中，生成器最大化该目标函数以生成困难样本，而全局模型最小化该目标函数以尽可能减少其与各本地模型间的输出分布差异，从而学习各本地模型所保有的模型知识。

4.2.4 动态权重系数

在数据非独立同分布场景下，各参与方本地模型所学到的知识是不等价的，因为不同本地模型所拥有的私有数据存在分布上的天然差异。对于同一个生成数据 $\tilde{x}$ ，不同本地模型对其的预测知识掌握程度不同，因此需要对不同本地模型产生的损失进行不同的权重划分，以正确衡量其在 $\tilde{x}$ 下的知识贡献。

具体而言，首先在该轮被选中参与的联邦学习的参与方集合 $\mathcal{S}_t$ 中排除掉错误预测 $\tilde{x}$ 的模型，认为其在 $\tilde{x}$ 的预测上不可信赖，并将其权重置为 0。对于剩余的能够正确预测 $\tilde{x}$ 标签的参与方，则认为其可以信赖并计算其贡献权重。与第三章中确定不同蒸馏机制的自适应系数类似，可以采用模型预测的信息熵作为权重确定标准，越高的信息熵代表输出的不确定性越大，需要给与其较小的权重参数。将参与方 j 关于生成数据 $\tilde{x}$ 的输出定义为，则其信息熵可表示为：

$$H_j(\tilde{x}) = \sum_{y=1}^Y -p^j(\tilde{x}) \log[p^j(\tilde{x})] \quad (4-9)$$

其中， $y = [1, 2, \dots, Y]$ 表示不同标签类别上参与方 j 输出的类别概率。最终的权重计算公式如式（4-10）所示，其中 $\mathcal{C}_{\text{错误}}$ 代表预测 $\tilde{x}$ 标签错误的参与方集合， $\mathcal{C}_{\text{正确}}$ 则代表预测 $\tilde{x}$ 标签正确的参与方集合。最终的动态系数可公式化表达如下：

$$\alpha_j^{k, \tilde{x}} = \begin{cases} 0, & j \in \mathcal{C}_{\text{错误}} \\ \text{softmax}(\frac{1}{H_j(\tilde{x})}), & j \in \mathcal{C}_{\text{正确}} \end{cases} \quad (4-10)$$

4.3 实验与分析

4.3.1 实验设置

为了评估所提出算法在全局模型聚合阶段的有效性，本节分别在 CIFAR-10、CIFAR-100 和 FMNIST 三个知名数据集上进行了实验。同第三章实验设置一样，采用 Dirichlet 分布划分数据集。Dirichlet 分布中的参数 β 取值越大，划分所得数据集越趋于均匀分布。相反参数 β 取值越小，基于该划分构造的数据分布差异越大。本节实验环

境与 3.3.1 节保持一致。为了方便对比，本节将联邦学习参与方数量设置为 100（活跃比例设置为 0.1）。除特殊说明外，基础模型和其余超参数设置与 3.3.3 节保持一致。

生成器选择方面，FedGA 采用条件生成对抗网络（CGAN）以生成给定标签下的所上传数据。与原始 GAN 相比，CGAN 将监督学习的思想引入生成模型领域，其输入除了噪声 z 之外还包含指定的类别标签 y 。生成模型的图像上采样方式通常包含反卷积与插值，其中反卷积操作能够将低维度的潜在空间向量映射为高分辨率的图像。通过一系列的反卷积操作，生成器能够增加特征图的空间维度，直至得到与目标图像尺寸一致的输出。插值则是通过数学计算对图像进行上采样操作，常见的插值方式包含双线性插值、最近邻插值等。在本节实验中，生成器采用双线性插值的方式进行上采样操作。生成器模型结构如表 4.1 所示，其中噪声 $z \in \mathbb{R}^d \sim \mathcal{N}(0,1)$ 从标准正态分布中采样得到，维度 d 为 100（FMNIST、CIFAR-10）或 256（CIFAR-100）。 $y \in \mathbb{R}^M$ 则是给定标签的 onehot 形式，大小与该数据集标签总类别数 M 一致。

表 4.1 生成器 CGAN 模型结构

Table 4.1 Generator CGAN model structure

网络层	网络/函数类型	输出维度（CIFAR）	输出维度（FMNIST）
输入层	Linear(z)	4096	4096
	Linear(y)	4096	4096
	concat	8192	8192
	Reshape+BN	128×8×8	128×7×7
Block1	Conv2D+BN+relu	128×8×8	128×7×7
	interpolate	128×16×16	128×14×14
Block2	Conv2D+BN+relu	64×16×16	64×14×14
	interpolate	64×32×32	64×28×28
输出层	Conv2D+BN+tanh	3×32×32	1×28×28

4.3.2 实验结果

4.3.2.1 不同 Non-IID 场景下性能对比

本节在三种数据集的不同 Non-IID 程度场景下进行了实验，对比了提出的 FedGA 算法和 FedAvg 算法在不同场景下的性能表现。对于 CIFAR-10 与 CIFAR-100 数据集，100 个参与方平均每个能划分约 500 份数据样本，而 FMNIST 数据集下各参与方平均能划分 600 份数据样本。参与方活跃比例设置为 0.1，表示每个通信轮随机选取 10% 的参

与方进行本轮学习，并测试算法的准确率大小。




图 4.3 CIFAR-10 数据集在不同分布场景下的算法性能对比

Figure 4.3 Algorithms performance under different data distribution in CIFAR-10

图 4.3 展示了不同算法在 CIFAR-10 数据集上的测试精度对比，其中横坐标代表联邦学习通信轮次，纵坐标代表算法准确率。图 4.3 (a)、(b) 分别对应 $\beta = 0.1$ 与 $\beta = 0.01$ 的 Non-IID 场景。如图 4.3 (a) 可以看到，当处于数据分布偏差适中的场景时，FedGA 通过在服务器利用生成器挖掘困难样本并学习其蒸馏知识，取得了优于 FedAvg 算法的性能表现。FedGA 算法的准确率达到 77.66%，较 FedAvg 算法高出了 4.15%。同时由于其模型聚合阶段能够迅速学习并掌握各参与方的本地模型蒸馏知识，使全局模型在聚合后能够最大限度地保留各方知识，其在早期训练阶段的准确率增长速率也高于 FedAvg 算法。图 4.3 (b) 中展示了数据分布偏差较大场景下的算法性能对比，可以看到 FedAvg 算法的全局模型的训练过程中其准确率曲线不再稳定平滑，这是由于在高度 Non-IID 场景下各参与方每轮的梯度更新方向差异较大，在简单的加权聚合后全局模型不能够很好地整合各模型知识所致，同时 FedAvg 算法全局模型的测试精度仅为 37.32%。FedGA 则通过有效挖掘困难样本并通过蒸馏损失有效调节全局模型，准确率最终达到了 41.82%。





图 4.4 CIFAR-100 数据集在不同分布场景下的算法性能对比

Figure 4.4 Algorithms performance under different data distribution in CIFAR-100

CIFAR-100 数据集下各算法性能如图 4.4 所示。图 4.4 (a) 和图 4.4 (b) 分别对应了 $\beta = 0.1$ 和 $\beta = 0.01$ 时的算法性能。同 CIFAR-10 数据集类似，随着数据 Non-IID 程度的提高，各算法在极端场景下准确率有所下降。图 4.4 (a) 中，FedGA 的准确率为 34.97%，较 FedAvg 的 29.83% 提升了 5.14%；图 4.4 (b) 中，FedGA 的准确率为 21.67%，较 FedAvg 的 17.18% 提升了 4.49%。同时可以看到，在较为复杂的数据集训练任务下，通过生成器与知识蒸馏能够高效转移本地模型知识至全局模型，所以 FedGA 算法的准确率提升速率高于 FedAvg 算法。同样，由于 FedGA 能够高效地积累各模型知识，因此在达到相同的预设准确率所需要的通信轮次上 FedGA 优于 FedAvg。图 4.5 展示了 FMNIST 数据集在 $\beta = 0.01$ 场景下的算法性能对比，结论与前文类似。

图 4.5 FMNIST 数据集 $\beta = 0.01$ 分布场景下算法性能Figure 4.5 Algorithms performance under $\beta = 0.01$ in FMNIST

4.3.2.2 超参数选取

为了评估 FedGA 在不同 Non-IID 数据场景下的鲁棒性，本节测试了 FedGA 在不同分布场景下（调整 Dirichlet 分布的超参数 β ）的准确性，并沿用了前文相关设置，将参与方设定为 100，同时将参与方活跃比例 C 设置为 0.1。图 4.6（a）展示了不同算法在 CIFAR-10 数据集中，不同 β 划分下的测试准确率。随着数据分布差异的逐渐增大，各算法测试准确率也逐渐提高，并在数据分布达到某个临界点时（该场景下为 $\beta = 0.4$ ）逐渐平缓。可以看到在不同数据分布场景下 FedGA 算法性能均优于 FedAvg，其内部的遗忘知识挖掘生成与蒸馏学习优化能够在不同场景下合理指导全局模型训练，使全局模型取得更好的性能表现。





图 4.6 不同分布场景 β 及系数 λ_G 对 FedGA 的影响

Figure 4.6 Effect of different distribution scenarios β and coefficients λ_G on FedGA

系数 λ_G 用以控制生成的数据 $\tilde{x}$ 符合参与方数据分布的程度，为了评估 λ_G 对 FedGA 算法性能的影响，在 100 个参与方（活跃比例 0.1）、CIFAR-10 ($\beta = 0.1$ 与 0.01) 场景下进行实验，其中 λ_{cls} 从 [0.05, 0.5, 1, 5, 10] 中选取。从图 4.6 (b) 可以看到，在 $\beta = 0.1$ 与 0.01 两种数据分布场景下， $\lambda_{cls} = 1$ 取得了最好的测试准确率，表明该取值能够合理权衡不同损失之间贡献大小，提升模型训练质量。若 λ_{cls} 过小，则生成器生成的数据不能正确拟合给定标签下的真实数据情况， λ_{cls} 过大则会导致对抗损失的占比过小，降低全局模型蒸馏训练质量。

此外，在相同实验参数及场景的设定下，实验比较了本地训练轮数 E 的取值对不同算法准确率的影响。实验结果如图 4.7 所示，当本地训练轮数 $E = 5$ 时，FedGA 与 FedAvg 都能取得最好的准确率。当 E 取过小时，由于未能在本地进行充分训练，所以上传的全局模型不能有效捕获本地数据知识。当 E 取过大时，则会使模型过度拟合当前本地数据集分布情况，加剧模型梯度分歧从而对模型准确率造成影响。同时可以看到，在不同 E 取值下，FedGA 算法准确率均优于 FedAvg，分别领先 1.96%-4.79%。

图 4.7 不同本地训练轮数 E 对算法准确率的影响Figure 4.7 Effect of different local training rounds E on the accuracy of each algorithm

4.3.2.3 FedGA 消融实验

在 100 个参与方（活跃比例 0.1）、CIFAR-10 ($\beta = 0.1$) 场景下对 FedGA 不同模块进行消融实验，以判断不同模块对算法准确率的作用，结果如表 4.2 所示。可以看到，每个模块都对 FedGA 起到了正向作用，移除任意模块将导致 FedGA 性能下降 1.77% 和 2.12%。同时减少多个模块将导致算法性能进一步降低，准确率下降 2.85%。

表 4.2 不同算法模块对 FedGA 的影响

Table 4.2 Impact of different modules on FedGA

	方法/模块	推理准确率(%)
基线	FedGA	77.66
对比方法	w/o $\alpha_j^{\tilde{x}}$	75.89
	w/o $\mathcal{L}_{div}$	75.54
	w/o $\alpha_j^{\tilde{x}} + \mathcal{L}_{div}$	74.81

4.4 小结

本章针对 Non-IID 数据下联邦学习在全局聚合阶段产生的知识遗忘，提出了 FedGA 算法。该算法在全局聚合阶段，将聚合后得到的全局模型与生成器针对特定损失进行对抗训练以挖掘遗忘知识，并利用生成知识重新指导全局模型训练，提升模型泛化性能。同时，针对生成器的生成数据多样化设计了距离损失，避免生成数据单一造成的知识固化。此外，基于预测归类和信息熵进行动态权重调节，以更好地权衡不同参与方在知识蒸馏中作为教师的知识贡献比例。最后，在不同数据集及分布场景下

的实验表明，相比 FedAvg，FedGA 能够有效提升模型测试精度并缩短收敛轮次。

第5章 FedCGA 算法集成与验证

本章节将系统地整合前文所提出的针对联邦学习本地训练与全局聚合两个阶段的优化方法。在本地训练中实施协作蒸馏过程，同时纳入关系知识旨在促使模型充分挖掘并学习私有数据中的优质知识结构，之后将本地更新完成后的模型参数上传至全局服务器。在全局聚合阶段，采用生成器对抗训练机制，以期在模型聚合后能有效地保持和巩固已习得的知识，从而减少知识遗忘。这两个互补性的方法共同组成了一个协同工作算法，集成后的联邦学习算法命名为：基于协作关系蒸馏和生成器增强聚合的联邦学习算法（Federated Co-rational distillation and GAN-based assemble Algorithm，FedCGA）。最后在不同场景下进行实验，验证了 FedCGA 的有效性和优越性。

5.1 本地训练与全局聚合优化方法集成

在联邦学习框架中，统计学意义上的 Non-IID 特性以及参与方无法独立设计本地模型结构的限制阻碍了个性化联邦学习的发展。针对各参与方数据在分布上存在的天然倾斜，本文采用协作与关系蒸馏的本地训练方法，提升模型对于不同分布和差异化私有数据的知识获取能力。同时，仅依赖本地训练无法消除 Non-IID 数据在全局聚合阶段对模型造成的影响，为此本文在全局聚合阶段引入生成器与全局模型对抗训练，以期在全局聚合阶段进一步降低知识遗忘带来的影响，进而确保联邦学习算法整体性能的提升。FedCGA 整体集成框架及两阶段的关键损失项在图 5.1 中详细展示。




图 5.1 FedCGA 算法集成框架

Figure 5.1 Integrated framework for FedCGA

具体地，联邦学习系统初始化时根据需要设置相同或不同的初始化模型结构，其中全局模型与不同参与方的本地模型网络结构可以不同。如图 5.2 所示，训练开始后的每个通信轮次内，首先进行步骤 1，令全局服务器下发本轮全局模型至所有被选中的参与方本地，参与方收到全局模型后进行步骤 2，在本地训练采用协作蒸馏机制并结合关系知识获取知识、拟合私有数据分布，在训练完成后上传模型至全局服务器。最后，全局服务器执行步骤 3，利用生成器与聚合后的全局模型进行对抗训练，生成聚合后遗忘的样本知识并在无公共数据的知识蒸馏下，对全局模型进行调优并得到该轮最终的全局模型。后续循环重复该过程直至模型收敛或达到预设性能标准。




图 5.2 FedCGA 关键步骤

Figure 5.2 Key steps in FedCGA

通过在联邦学习两个阶段中关键步骤上的优化训练方式，缓解了联邦学习训练阶段的知识遗忘并提升了训练时传输的知识质量，提升模型性能。具体地，算法 5-1 展示了 FedCGA 的训练流程。

算法 5-1 基于关系知识蒸馏和数据增强的联邦学习算法——FedCGA

输入: T : 训练总轮次; N : 参与方数量; C : 每轮训练中活跃参与方数量; $\{D_i\}_{i \in \{1, \dots, N\}}$: 参与方本地数据; $p_g(x), p_n(x)$: 全局模型和本地模型的预测输出; η : 学习率; E : 本地轮次

输出: $w = [w_1, \dots, w_N] \cup w_g$

```

1: Initialize  $w$ 
2: ServerExecutes:
3: for each round  $t \in \{1, 2, \dots, T\}$  do
4:    $S_t \leftarrow$  random subset ( $C$  fraction) of the  $N$  clients
5:   for each clients  $i \in S_t$  in parallel do
6:      $w_{g,i}^t \leftarrow \text{ClientUpdate}(i, w_g^t)$ 
7:   end for
8:   ServerAggregation:  $w_g^{t+1} = \frac{1}{|S_t|} \sum_{i \in S_t} w_{g,i}^t$ 
9:   生成器挖掘样本数据增强全局模型      # 细节见算法 4-1
10: end for
11: ClientUpdate( $i, w_g^t$ ):
12: for each  $e \in \{1, 2, \dots, E\}$  do
13:   for batch  $b = \{x, y\} \in D_i$  do
14:     各参与方接收该轮全局模型  $w_g^t$ 
15:     本地模型进行更新与知识蒸馏      # 细节见算法 3-1
16:   end for
17: end for

```

本文所提出的基于协作蒸馏机制的本地训练方法与基于生成器对抗训练的全局聚合方法，能够有效减少 Non-IID 数据场景下联邦学习在不同训练阶段造成的知识遗忘，同时允许各参与方独立定制其需要的模型结构。在 Non-IID 场景下，通过改进后的本地训练过程，FedCGA 能够借助不同蒸馏知识有效学习并整合私有数据中的内在知识，并将其高效汇集至中心服务器。与此同时，在服务器全局聚合阶段，通过引入生成器对抗生成针对遗忘知识的补充生成数据，以充分聚合并利用所得到的各方本地知识，减少全局聚合阶段由于各方分歧导致的知识遗忘。

5.2 实验与分析

5.2.1 推理准确率对比

为了验证集成后 FedCGA 算法的性能表现，本文对 FedCGA 算法进行不同场景下的实验测试，在 FMNIST、CIFAR-10 与 CIFAR-100 数据集上进行 FedCGA 算法与其余

基线算法的对比实验，并采用不同 Dirichlet 分布 ($\beta = 0.1$ 与 $\beta = 0.01$) 划分数据集，参与方个数设置为 100 (活跃比例 0.1)。除特殊说明外，本节实验环境、基础模型与其余超参数设置与 4.3.1 节保持一致。基线算法分别选取了经典的 FedAvg 算法、使用本地正则化约束的 FedProx^[39]算法、基于控制变量纠正个性化更新方向的 SCAFFOLD^[43]算法以及基于生成器的 FedGen^[34]算法。




图 5.3 FedCGA 及基线算法在不同场景下的模型性能

Figure 5.3 Performance of FedCGA and baselines in different scenarios

图 5.3 展示了不同数据集上各算法在不同 Non-IID 场景下的测试性能。具体而言，图中三行分别表示了各联邦学习算法在 FMNIST、CIFAR-10、CIFAR-100 与上的训练过程，其中每行的子图从左到右，其数据 Non-IID 程度分别为 $\beta = 0.1$ 与 $\beta = 0.01$ 。各

子图中纵坐标代表模型测试准确率，横坐标代表联邦学习通信轮次，一个完整通信轮次包含全局模型的分发过程、参与方本地训练过程以及模型上传后的聚合过程。从图 5.3 中可以发现，在所有三种数据集的不同 Non-IID 程度下，本章所提出的 FedCGA 算法均取得了领先其它算法的推理精度，并且对比其他基线方法能够更快地收敛到目标准确率。在数据分布极度倾斜（ $\beta = 0.01$ ）的场景中，FedCGA 在 FMNIST 中取得了 88.93% 的推理精度，由于 FMNIST 数据集相对简单，本地训练较易捕获其私有数据知识，因此各算法在 $\beta = 0.01$ 场景下表现差距并不明显，都接近集中式机器学习的上限。在 CIFAR-10 与 CIFAR-100 数据集中 $\beta = 0.01$ 分布场景，FedCGA 分别取得了 43.35% 和 23.64% 的准确率，对比其余基线算法提升达 3.31%-6.46%。由此可知，FedCGA 算法能够在各参与方的本地训练过程中，借助知识蒸馏技术捕获更多私有数据所蕴含的知识信息，并在联邦学习全局聚合阶段通过生成器对抗训练，有效地整合并强化这些知识，进一步避免知识在聚合过程中丢失与遗忘。与此同时，FedCGA 算法在联邦学习的不同阶段皆通过设计自适应权重策略合理确定不同质量下知识的贡献程度，使模型训练更加鲁棒，进而提升模型性能。总体而言，图 5.3 充分说明了 FedCGA 算法相较于其余四种对比基线方法所展现出的优越性，它能在最短的时间内达到目标精度，并最终收敛至最高的模型精度。

5.2.2 超参数实验

为了评估 FedCGA 在不同程度的 Non-IID 场景下的适应能力，本节测试了各算法在不同数据分布场景下（调整 Dirichlet 分布的超参数 β ）的测试精度。图 5.4（a）显示了 CIFAR10 数据集中不同 β 取值下每种联邦学习算法的测试精度。FedCGA 在不同分布场景下都取得了最佳性能，优于其他基线算法。同时，随着数据分布倾斜程度的降低（即 β 增加），所有方法的准确性都趋于提高，知识遗忘得到缓解。FedProx 在某些 Non-IID 场景中的表现与 FedAvg 类似，原因之一是它只根据全局模型的模型权重对本地模型施加正则化约束限制其更新方向与速度，而不是从知识蒸馏的角度以更具针对性的约束条件来优化本地模型，提升训练质量。实验中还注意到在数据 Non-IID 程度较高的情况下，FedCGA 比其他方法有更大的改进，而 FedGen 在这种情况下并没有显著改进，这进一步验证了在联邦学习本地训练阶段，通过协作蒸馏及关系知识为全局模型传输高质量知识的必要性。




图 5.4 不同 Non-IID 程度及参与方活跃比例对算法精度的影响

Figure 5.4 Impact of different Non-IID and active ratios on test accuracy

为了评估 FedCGA 针对不同参与方活跃比例的适应性，在 CIFAR10 上针对参与每轮学习不同参与方数量进行实验。具体来说，本文将 CIFAR10 数据集的训练样本分配给 100 个参与方，同时选取活跃比例 C 选取为 $[0.1, 0.2, 0.3, 0.4]$ 。表 5.1 展示了在每轮学习中不同活跃比例 C 下各算法的测试准确率，同时图 5.4 (b) 中也展示了各算法在不同 C 取值下的测试准确率。可以看到 FedCGA 在各情形下均取得了最好表现。同时可以发现，随着联邦学习中参与方的增多，各算法的表现会越来越好。表 5.1 具体展示了不同活跃比例 C 下各算法的推理准确率。

表 5.1 不同活跃比例 C 下各算法性能对比

Table 5.1 Performance comparison of algorithms with different active ratio C

FL 算法	推理准确率(%)			
	$C = 0.1$	$C = 0.2$	$C = 0.3$	$C = 0.4$
FedAvg	72.51	74.02	74.36	75.21
FedProx	73.83	75.85	76.23	75.83
SCAFFOLD	75.68	77.53	77.88	78.15
FedGen	73.17	73.33	75.29	76.09
FedCGA	80.61	82.74	83.41	83.37

5.2.3 模型泛化与个性化能力

接下来研究各算法模型的泛化能力与个性化推理能力。在 CIFAR-10 的统一测试数据集（表 3.2 中划分方式）上评估全局模型和每个本地模型的平均表现，以检查本地训练过程中私有知识的保存情况。从图 5.5 中可以看到，FedCGA 在全局模型上始终保持

最高的推理精度，表明 FedCGA 能够有效通过本地训练捕获知识并在全局聚合时利用生成器避免知识丢失，因此全局模型保留了最好的泛化能力。此外，FedCGA 的本地模型在统一测试数据集上的测试精度也取得最优，表明 FedCGA 在本地模型和全局模型的泛化性能上都是最好的。因为 FedCGA 在参与方本地端利用特定蒸馏方式，实现了本地模型的全局优质知识学习捕获，使本地模型泛化性能得到充分提升。最后，FedCGA 本地模型在各自私有测试集上的平均测试准确率也优于所有基线算法，表明其本地训练阶段通过解耦两端模型，实现了本地模型的持续训练以充分获取本地知识，拟合私有数据分布。可以看到，FedCGA 在全局模型的泛化能力和本地模型的个性化能力上均优于基线算法。




图 5.5 FedCGA 与基线算法的全局/本地模型精度比较

Figure 5.5 Comparison of global/local model accuracy between FedCGA and baselines

5.2.4 权重发散

针对 2.4.2 节所述，权重发散能够衡量在联邦学习中采用相同的权重初始化情况下，本地模型在训练过程中形成的权重与全局模型的权重之间产生的差异，并且在一定程度上反映模型受 Non-IID 数据影响的大小。在 CIFAR10 数据集下的不同数据分布场景对 FedCGA 进行权重发散实验。同 2.4.2 节一样，数据分布采用同分布、中等倾斜分布与极端倾斜分布 ($\beta = 100$, $\beta = 0.1$, $\beta = 0.01$)，模型选用 3 层 CNN 叠加 3 层线性层神经网络。由图 5.6 可以看到，FedCGA 在相同初始化参数设置下取得了远小于 2.4.2 节中 FedAvg 的权重发散，模型受 Non-IID 数据影响较小。需要指出，权重发散并不是确定联邦学习模型性能好坏的绝对标准，通常用作参考可以一定程度从侧面反映出模型对 Non-IID 数据的敏感程度。




图 5.6 FedCGA 权重发散

Figure 5.6 Weight divergence of FedCGA

5.2.5 模型异构场景测试精度

作为个性化联邦学习优化方法，除了优化算法在 Non-IID 数据场景下的性能之外，FedCGA 允许各参与方根据各自具体场景独立设计其本地模型。同 3.3.4.2 节模型异构实验一样，测试各参与方采用不同本地模型在 CIFAR10 数据集上进行训练时，不同本地模型的测试精度。如图 5.7 所示，不同颜色的曲线代表各参与方参与联邦学习后模型的从测试精度变化，对应颜色的虚线则代表模型仅在本地独立训练而不参与联邦学习时的精度上限。图 5.7（a）、（b）分别展示了 IID 与 Non-IID 场景下不同参与方的模型测试精度。可以看到，在 FedCGA 训练下不同参与方均取得了优于其独立训练的模型测试精度，同时由于在全局聚合阶段引入生成器对抗训练缓解知识遗忘，在提升全局模型泛化性能的同时也使各参与方本地模型取得比 FedCRD 算法更高的测试准确率。




图 5.7 FedCGA 在模型异构场景下的推理准确率

Figure 5.7 Accuracy of FedCGA in model heterogeneous scenarios

5.3 小结

本章针对先前章节所提出的两种联邦学习优化方法——FedCRD（针对本地训练优化）与 FedGA（针对全局聚合优化）进行了整合。其中 FedCRD 方法在本地训练阶段通过高效地学习模型间的高质量知识及高维知识结构，确保算法在应对不同数据分布场景时能够准确捕捉并学习更多优质教师知识，提升模型性能，同时解除了模型同构的限制。FedGA 方法在全局聚合阶段利用生成器对抗训练，旨在通过挖掘与生成聚合后遗忘的样本知识并通过知识蒸馏重新指导全局模型学习，使得全局模型能够保留更多模型所携带的知识，提升其泛化能力。整合后的 FedCGA 算法联合了上述两种优化方法的优势，使联邦学习的两个阶段互相协同促进，同时提升了模型的知识获取与留存能力。最后，通过在 FMNIST、CIFAR-10 和 CIFAR-100 三个联邦学习基准数据集上开展的深入实验，验证了 FedCGA 相比于基线算法在测试精度与收敛速度上的优越性。

第6章 结论与展望

6.1 结论

联邦学习是一种新兴分布式机器学习框架，能够在保护数据隐私、确保不暴露各方原始数据的前提下，联合多个数据持有方协同训练，有效地打破了“数据孤岛”的僵局。但联邦学习的效果受数据分布倾斜的影响，Non-IID 数据将极大地降低联邦学习的模型性能。本文主要围绕 Non-IID 场景下联邦学习的推理准确率与收敛速率降低问题进行个性化联邦学习方法研究，同时打破了传统联邦学习方法模型同构的限制。针对联邦学习本地训练和全局聚合两个不同阶段的知识遗忘现象，提出了两种提升 Non-IID 场景下模型性能的改进方法，使得联邦学习在本地训练阶段能够充分学习本地优质知识，同时在全局聚合阶段能够更多地留存已获取知识。最后，在不同数据集及 Non-IID 场景下进行了实验验证，验证了所提出方法的有效性。本文的工作总结如下：

(1) 针对 Non-IID 场景下的联邦学习本地训练存在的知识遗忘现象以及模型整体性能下降的问题，提出了一种个性化联邦学习方法 FedCRD，旨在通过在本地训练阶段将全局模型与本地模型解耦，使各方能够独立定制其私有模型结构的同时，减少本地训练的知识遗忘现象。通过对模型间进行协作蒸馏，并引入关系知识提升训练过程的鲁棒性和知识质量。其次，利用预测信息熵自适应调节关系知识与响应知识权重，以转移优质知识避免模型受负面知识影响。最后，将 FedCRD 与 FedAvg 进行了对比，实验结果表明，FedCRD 在性能上优于 FedAvg，在相对困难的 CIFAR-10、CIFAR-100 场景下，FedCRD 推理准确率先 FedAvg 在 3.3%-5.24% 之间。

(2) 针对联邦学习的全局聚合阶段受 Non-IID 数据影响导致的知识遗忘现象，提出了一种全局聚合优化方法 FedGA。该方法通过结合生成对抗网络与全局模型对抗训练，旨在挖掘聚合后全局模型所遗忘的样本知识，并通过知识蒸馏重新指导全局模型训练巩固。通过引入数据多样化损失以及动态权重系数，使生成器能够生成多样化的样本知识，并合理权衡知识蒸馏中不同生成数据下各参与方作为教师的知识贡献。最后，FedGA 与 FedAvg 在不同分布场景及不同本地更新轮次下的实验结果表明，FedGA 在各场景下表现均优于 FedAvg。尤其在 CIFAR-100 数据集的不同分布场景下，FedGA 的推理准确率提升分别达到了 5.14% 及 4.49%。

(3) 对所提出本地训练和全局聚合优化方法进行整合，提出了 FedCGA 算法，通过在本地训练充分吸收各参与方私有数据知识的同时，在全局聚合阶段进一步保持知识留存避免遗忘，以进一步降低 Non-IID 场景对联邦学习模型性能的影响。最后，FedCGA 与不同基线方法在不同场景下的实验对比结果表明，FedCGA 在模型推理准确

率和模型收敛速度方面均取得最优，在 CIFAR-10 与 CIFAR-100 数据集中相比基线方法分别提升了 3.31%-6.46%，验证了所提算法的有效性。

6.2 展望

本文提出的两个算法能够有效提升数据非独立同分布场景下联邦学习的性能和收敛速度，同时实现联邦学习的本地模型个性化。但是仍然存在一些挑战，未来需要深入研究。本文提出了如下几个需要继续深入研究和解决的问题：

(1) FedCRD 通过解耦本地与全局模型实现联邦学习的本地训练优化，提升知识质量并缓解知识遗忘现象。但该方法需要在本地训练阶段维护两个模型，对算力的需求相对 FedAvg 较高，需要在参与方算力足够的情况下进行，如制造领域或医疗领域的“cross-silo”联邦学习场景，在边缘计算的多设备“cross-device”联邦学习场景会受到算力瓶颈限制。因此，今后的研究可以结合拆分学习的思想，将全局模型与本地模型拆分，仅维持关键层的协作蒸馏以提升算法效率并降低算力消耗。

(2) FedGA 在联邦学习的全局聚合阶段通过结合生成器对抗训练，帮助全局模型学习并重新捕获遗忘知识。生成器的训练需要依赖多项损失，不同损失的权重将极大程度影响生成器的性能，进而影响全局模型的训练效果。因此，如何更加精准且智能地控制不同损失间的贡献比例非常关键，这也将是我们后续会进一步深入研究的问题。

参考文献

- [1] 许宪春,任雪,常子豪.大数据与绿色发展[J].中国工业经济,2019,4(5): 22.
- [2] 王灏晨. 欧盟《通用数据保护条例》对人工智能发展的影响及启示[J]. 中国经贸导刊, 2018(17): 20-22.
- [3] 叶明,王岩. 人工智能时代数据孤岛破解法律制度研究[J]. 大连理工大学学报: 社会科学版, 2019, 40(5): 69-77.
- [4] Li S, Xu L D, Zhao S. The internet of things: a survey[J]. Information systems frontiers, 2015, 17: 243-259.
- [5] 吴吉义,文娟,曹健,等. 智能物联网 AIoT 研究综述[J]. 电信科学, 2021, 37(8): 1-17.
- [6] 张锋军,杨永刚,庆华,等. 大数据安全研究综述[J]. 通信技术, 2020, 53(5): 1063-1076.
- [7] 杨奔. 人工智能与大数据,云计算的融合发展[J]. 无线互联科技, 2021, 17(10): 30-31.
- [8] 王玥,田燕军,王莉.云计算技术应用与发展[J].山西电子技术,2022(06):69-71.
- [9] 吴伟,杨以兵,王清,等.基于云计算的工业数字化转型研究[J].科技与创新,2023(24):26-28+31.
- [10] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017: 1273-1282.
- [11] Wu Y, Cai S, Xiao X, et al. Privacy preserving vertical federated learning for tree-based models[J]. arXiv preprint arXiv:2008.06170, 2020.
- [12] Kairouz P, McMahan H B, Avent B, et al. Advances and open problems in federated learning[J]. Foundations and trends® in machine learning, 2021, 14(1-2): 1-210.
- [13] 许晶华. 我国智慧城市建设的现状和类型比较研究[J]. 城市观察, 2012, 4(5).
- [14] Zheng Z, Zhou Y, Sun Y, et al. Applications of federated learning in smart cities: recent advances, taxonomy, and open challenges[J]. Connection Science, 2022, 34(1): 1-28.
- [15] 杨强,童咏昕,王晏晟,等. 群体智能中的联邦学习算法综述[J]. 智能科学与技术学报, 2022, 4(1): 29-44.
- [16] Liu Q, Chen C, Qin J, et al. Feddg: Federated domain generalization on medical image segmentation via episodic learning in continuous frequency space[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 1013-1023.
- [17] Vaid A, Jaladanki S K, Xu J, et al. Federated learning of electronic health records to improve mortality prediction in hospitalized patients with COVID-19: machine learning approach[J]. JMIR medical informatics, 2021, 9(1): e24207.
- [18] 简兆权,谭艳霞,刘念.数字化驱动下智慧医疗服务平台价值共创的演化过程——基于服务生态系统和知识整合视角的案例研究[J].管理评论,2022,34(12):322-339.
- [19] 计虹.大数据在智慧医院建设中的应用实践[J].中国卫生信息管理杂志,2020,17(06):706-709+743.
- [20] 徐婷婷,徐玲玲.大数据背景下智慧医疗发展浅析[J].智能计算机与应用,2020,10(01):281-284.
- [21] Byrd D, Polychroniadou A. Differentially private secure multi-party computation for federated learning in financial applications[C]//Proceedings of the First ACM International Conference on AI in Finance. 2020: 1-9.
- [22] Long G, Tan Y, Jiang J, et al. Federated learning for open banking[M]//Federated Learning: Privacy and Incentive. Cham: Springer International Publishing, 2020: 240-254.
- [23] 巩世广,郭继涛.基于区块链的科技金融模式创新研究[J].科学管理研究,2016,34(04):110-113.

- [24] 陈振云.数据驱动科技金融的监管挑战与法律应对[J].佛山科学技术学院学报:社会科学版, 2022, 40(4):8.
- [25] Yao A C C. How to generate and exchange secrets[C]//27th annual symposium on foundations of computer science (Sfcs 1986) . IEEE, 1986: 162-167.
- [26] Yao A C. Protocols for secure computations[C]//23rd annual symposium on foundations of computer science (sfcs 1982) . IEEE, 1982: 160-164.
- [27] Li T, Sahu A K, Talwalkar A, et al. Federated learning: Challenges, methods, and future directions[J]. IEEE signal processing magazine, 2020, 37(3): 50-60.
- [28] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.
- [29] Li D, W J. Fedmd.Heterogenous federated learning via model distillation[C]//Proceedings of the NeurIPS Workshop Feder. Learn. Data Privacy Confidentiality. 2019, 1: 8.
- [30] Lin T, Kong L, Stich S U, et al. Ensemble distillation for robust model fusion in federated learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 2351-2363.
- [31] Cheng S, Wu J, Xiao Y, et al. Fedgems: Federated learning of larger server models via selective knowledge fusion[J]. arXiv preprint arXiv:2110.11027, 2021.
- [32] Jeong E, Oh S, Kim H, et al. Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data[J]. arXiv preprint arXiv:1811.11479, 2018.
- [33] He C, Annavaram M, Avestimehr S. Group knowledge transfer: Federated learning of large cnns at the edge[J]. Advances in Neural Information Processing Systems, 2020, 33: 14068-14080.
- [34] Zhu Z, Hong J, Zhou J. Data-free knowledge distillation for heterogeneous federated learning[C]//International conference on machine learning. PMLR, 2021: 12878-12889.
- [35] Zhang L, Wu D, Yuan X. Fedzkt: Zero-shot knowledge transfer towards resource-constrained federated learning with heterogeneous on-device models[C]//2022 IEEE 42nd International Conference on Distributed Computing Systems (ICDCS). IEEE, 2022: 928-938.
- [36] Sattler F, Müller K R, Samek W. Clustered federated learning: Model-agnostic distributed multitask optimization under privacy constraints[J]. IEEE transactions on neural networks and learning systems, 2020, 32(8): 3710-3722.
- [37] K. Kopparapu, E. Lin. FedFMC: Sequential Efficient Federated Learning on Non-iid Data[J]. arXiv preprint arXiv:2006.10937, 2020
- [38] Ghosh A, Chung J, Yin D, et al. An efficient framework for clustered federated learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 19586-19597.
- [39] Li T, Sahu A K, Zaheer M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine learning and systems, 2020, 2: 429-450.
- [40] Hanzely F, Richtárik P. Federated learning of a mixture of global and local models[J]. arXiv preprint arXiv:2002.05516, 2020.
- [41] T Dinh C, Tran N, Nguyen J. Personalized federated learning with moreau envelopes[J]. Advances in Neural Information Processing Systems, 2020, 33: 21394-21405.
- [42] Yao X, Sun L. Continual local training for better initialization of federated models[C]. 2020 IEEE International Conference on Image Processing (ICIP), Nanjing: IEEE, 2020: 1736-1740.
- [43] Karimireddy S P, Kale S, Mohri M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]. International Conference on Machine Learning, Cambridge: JMLR, 2020: 5132-5143.
- [44] Tan Y, Long G, Liu L, et al. Fedproto: Federated prototype learning across heterogeneous

- clients[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022, 36(8): 8432-8440.
- [45] 张传尧, 司世景, 王健宗, 等. 联邦元学习综述[J]. 大数据, 2023, 9(2): 122-146.
- [46] 杨仕成, 陈保罗, 陈铁明, 等. 基于联邦元学习的安全移动边缘计算卸载框架[J]. 高技术通讯, 2023, 33(12): 1265-1275.
- [47] Fallah A, Mokhtari A, Ozdaglar A. Personalized federated learning with theoretical guarantees: A model-agnostic meta-learning approach[J]. Advances in Neural Information Processing Systems, 2020, 33: 3557-3568.
- [48] 李少波, 杨磊, 李传江, 等. 联邦学习概述: 技术, 应用及未来[J]. 计算机集成制造系统, 2022, 28(7): 2119.
- [49] Saha S, Ahmad T. Federated transfer learning: concept and applications[J]. Intelligenza Artificiale, 2021, 15(1): 35-44.
- [50] Kevin I, Wang K, Zhou X, et al. Federated transfer learning based cross-domain prediction for smart manufacturing[J]. IEEE Transactions on Industrial Informatics, 2021, 18(6): 4088-4096.
- [51] 李响, 付春霖, 雷亚国, 等. 保证数据隐私的装备协同智能故障诊断联邦迁移学习方法[J]. 机械工程学报, 2023, 59(06): 1-9.
- [52] Peterson D, Kanani P, Marathe V J. Private federated learning with domain adaptation[J]. arXiv preprint arXiv:1912.06733, 2019.
- [53] Shenaj D, Fanì E, Toldo M, et al. Learning across domains and devices: Style-driven source-free domain adaptation in clustered federated learning[C]//Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2023: 444-454.
- [54] Yao C H, Gong B, Qi H, et al. Federated multi-target domain adaptation[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2022: 1424-1433.
- [55] W. Y. B. Lim, N. C. Luong, D. T. Hoang, et al. Federated learning in mobile edge networks: A comprehensive survey[J]. IEEE Communications Surveys & Tutorials, 2020, 22(3): 2031-2063
- [56] 张燕, 胡明星. 边缘计算下的联邦学习挑战及进展[J]. 数字技术与应用, 2023, 41(10): 160-162.
- [57] Duan Q, Huang J, Hu S, et al. Combining federated learning and edge computing toward ubiquitous intelligence in 6G network: Challenges, recent advances, and future directions[J]. IEEE Communications Surveys & Tutorials, 2023.
- [58] Lu R, Zhang W, Wang Y, et al. Auction-based cluster federated learning in mobile edge computing systems[J]. IEEE Transactions on Parallel and Distributed Systems, 2023, 34(4): 1145-1158.
- [59] Nishio T, Yonetani R. Client selection for federated learning with heterogeneous resources in mobile edge[C]//ICC 2019-2019 IEEE international conference on communications (ICC). IEEE, 2019: 1-7.
- [60] P. Richtárik, M. Takáč. Distributed coordinate descent method for learning with big data[J]. The Journal of Machine Learning Research, 2016, 17(1): 2657-2681
- [61] O. Shamir, N. Srebro. Distributed stochastic optimization and learning[C]. 52nd Annual Allerton Conference on Communication, Control, and Computing, Monticello, IL, USA, 2014, 850-857
- [62] V. Smith, S. Forte, M. Chenxin, et al. Cocoa: A general framework for communication-efficient distributed optimization[J]. Journal of Machine Learning Research, 2018, 18(230): 1-49
- [63] S. U. Stich. Local SGD Converges Fast and Communicates Little[C]//In Proceedings of the 7th International Conference on Learning Representations, ICLR, New Orleans, LA, USA, May 6–9, 2019.
- [64] Yang Q, Liu Y, Chen T, et al. Federated machine learning: Concept and applications[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2019, 10(2): 1-19.
- [65] Zeng R, Zhang S, Wang J, et al. Fmore: An incentive scheme of multi-dimensional auction for federated

- learning in mec[C]//2020 IEEE 40th international conference on distributed computing systems (ICDCS). IEEE, 2020: 278-288.
- [66] Deng Y, Lyu F, Ren J, et al. Fair: Quality-aware federated learning with precise user incentive and model aggregation[C]//IEEE INFOCOM 2021-IEEE Conference on Computer Communications. IEEE, 2021: 1-10.
- [67] Kang J, Xiong Z, Niyato D, et al. Incentive design for efficient federated learning in mobile networks: A contract theory approach[C]//2019 IEEE VTS Asia Pacific Wireless Communications Symposium (APWCS). IEEE, 2019: 1-5.
- [68] Zhan Y, Li P, Qu Z, et al. A learning-based incentive mechanism for federated learning[J]. IEEE Internet of Things Journal, 2020, 7(7): 6360-6368.
- [69] Anil R, Pereyra G, Passos A, et al. Large scale distributed neural network training through online distillation[C]//In Proceedings of the 6th International Conference on Learning Representations, ICLR 2018.
- [70] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [71] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]//Proceedings of the 3rd International Conference on Learning Representations, ICLR, San Diego, CA, USA, May 7–9, 2015.
- [72] Zhao Y, Li M, Lai L, et al. Federated learning with non-iid data[J]. arXiv preprint arXiv:1806.00582, 2018.
- [73] Buciluă C, Caruana R, Niculescu-Mizil A. Model compression[C]//Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining. 2006: 535-541.
- [74] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks[J]. Communications of the ACM, 2020, 63(11): 139-144.
- [75] Zhu H, Xu J, Liu S, et al. Federated learning on non-IID data: A survey[J]. Neurocomputing, 2021, 465: 371-390.
- [76] Mermillod M, Bugaiska A, Bonin P. The stability-plasticity dilemma: Investigating the continuum from catastrophic forgetting to age-limited learning effects[J]. Frontiers in psychology, 2013, 4: 54654.
- [77] Serra J, Suris D, Miron M, et al. Overcoming catastrophic forgetting with hard attention to the task[C]//International conference on machine learning. PMLR, 2018: 4548-4557.
- [78] Li Z, Wang X, Hu D, et al. Not all knowledge is created equal: Mutual distillation of confident knowledge[J]. arXiv preprint arXiv:2106.01489, 2021.
- [79] Pereyra G, Tucker G, Chorowski J, et al. Regularizing Neural Networks by Penalizing Confident Output Distributions[C]//In Proceedings of the 5th International Conference on Learning Representations, ICLR, Toulon, France, April 24–26, 2017.
- [80] Acar D A E, Zhao Y, Navarro R M, et al. Federated Learning Based on Dynamic Regularization[C]//In Proceedings of the 9th International Conference on Learning Representations, ICLR, Austria, May 3–7, 2021.
- [81] Sattler F, Korjakow T, Rischke R, et al. Fedaux: Leveraging unlabeled auxiliary data in federated learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 34(9): 5531-5543.
- [82] Chen H Y, Chao W L. FedBE: Making Bayesian Model Ensemble Applicable to Federated Learning[C] // In Proceedings of the 9th International Conference on Learning Representations, ICLR, Austria, May 3–7, 2021.