

分 类 号: TP391
研究生学号: 2022532027

单位代码: 10183
密 级: 公开



吉 林 大 学

硕士学位论文

(学术学位)

面向非独立同分布数据的联邦学习性能优化研究

Research on Performance Optimization of Federated Learning
For Non-independent and Non-identically Distributed Data

作者姓名: 高文字

专 业: 计算机科学与技术

研究方向: 联邦学习

指导教师: 徐高潮 教授

培养单位: 计算机科学与技术学院

2025 年 5 月

面向非独立同分布数据的联邦学习性能优化研究

Research on Performance Optimization of Federated
Learning For Non-independent and Non-identically
Distributed Data

作者姓名：高文字

专业名称：计算机科学与技术

指导教师：徐高潮 教授

类别：工学硕士

答辩日期：2025 年 5 月

摘要

面向非独立同分布数据的联邦学习性能优化研究

随着人工智能和大数据技术的快速发展,数据隐私与安全问题备受关注。联邦学习作为一种新兴的实现数据安全共享的分布式机器学习范式,能够在保护数据隐私的前提下,实现模型的多方协同训练。在非独立同分布数据场景下,联邦学习面临的数据异构性导致的全局模型训练精度下降,无法满足联邦学习任务的需求,训练的稳定性也受到影响。此外,联邦学习的全局模型在收到客户端上传本地模型进行聚合时 also 存在着安全隐患,恶意客户端或攻击者会在模型传输过程中进行破坏,当前的安全聚合策略虽然能够增强隐私保护,但是通信成本和计算开销会比较高,限制了联邦学习的实际应用。

针对上述挑战与问题,为了实现在非独立同分布数据场景下进行高质量安全的联邦学习,解决传统联邦学习方法中的全局模型性能低,同时保证安全聚合过程中的通信开销和计算成本较大的问题,本文的研究内容具体如下:

(1) 基于 Shapley 值动态贡献评估联邦框架:在非独立同分布数据场景下,客户端之间的数据异构性大大增强,也增加了联邦学习的难度,全局模型的泛化能力无法满足任务需求,本文设计了一种基于 Shapley 值精确的评估用户贡献的联邦学习框架 FedCon。FedCon 在每一轮训练过程中计算客户端的 Shapley 值,可以精确的评估客户端对全局模型做出的贡献。但是传统的 Shapley 值计算方法复杂度太高, FedCon 结合蒙特卡洛采样技术降低计算复杂度。同时引入了本地模型与全局模型之间的余弦相似度矩阵进一步降低采样频率,使得当前 Shapley 值可以在计算资源有限的情况下精确的表示客户端贡献,为了提高全局模型训练过程中的稳定性,方法考虑客户端的历史权重,有效的降低了全局模型的波动幅度。实验结果表明, FedCon 在模型性能、模型精度、通信开销和鲁棒性方面均优于现有的联邦学习方法,能够很好的适应非独立同分布数据场景。

(2) 基于委员会与区块链的安全联邦框架:在非独立同分布数据场景下,传统的联邦学习方法存在单点故障、隐私泄露风险影响全局模型的安全聚合,此外服务器会成为整个训练任务的瓶颈。所以本文探索安全高性能的去中心化联邦

学习方法，研究实现在保证安全聚合的同时降低系统的通信开销，提高系统的性能和隐私保护能力。本文提出了一种基于委员会与区块链的安全联邦框架 SCDFL。SCDFL 通过多项式承诺协议与智能合约实现全局模型聚合的可验证性，并通过对称加密和哈希加密验证来保护本地梯度、确保客户端的数据隐私安全。SCDFL 通过可信执行机构生成公钥/私钥对，用于客户端提交聚合验证证明；委员会成员通过智能合约在区块链上执行验证过程，在保证模型聚合的正确性的同时，大大降低了通信安全验证所需的计算成本和通信开销。实验结果显示，SCDFL 显著降低了计算和通信成本，同时增强了对恶意客户端的鲁棒性，在隐私保护、计算开销和模型性能方面均有所提升，验证了其在联邦学习实际部署中的可行性。

本文围绕非独立同分布数据下的联邦学习展开系统性研究，分别从模型性能优化与安全聚合机制两个维度提出了具有创新性的解决方案。通过结合 Shapley 值与历史权重机制，提升全局模型的泛化能力与稳定性；通过引入区块链与委员会机制，实现安全、高效、可验证的模型聚合过程。实验结果表明，本文提出的联邦学习优化方法在准确性、鲁棒性、通信与计算效率等方面均表现优异，具备良好的应用前景与推广价值，为联邦学习在实际场景中的部署提供了理论基础与技术支撑。

关键词：

联邦学习，模型性能，非独立同分布数据，通信开销，计算开销

ABSTRACT

Research on Performance Optimization of Federated Learning For Non-independent and Non-identically Distributed Data

With the rapid development of artificial intelligence and big data technologies, data privacy and security issues have received increasing attention. Federated learning (FL), as an emerging distributed machine learning paradigm, can achieve multi-party collaborative training under the premise of protecting data privacy. However, in the scenario of non-independent and non-identically distributed data (Non-IID), the data heterogeneity faced by FL leads to a decrease in the accuracy of global model training, which cannot meet the needs of FL tasks, and the stability of training is also affected. In addition, the global model of federated learning also has security risks when receiving local models uploaded by clients for aggregation. Malicious clients or attackers will damage the model during transmission. Although the current security aggregation strategy can enhance privacy protection, the communication cost and computing overhead will be relatively high, which limits the practical application of FL.

In response to the above challenges and problems, in order to achieve high-quality and secure FL in the scenario of Non-IID data, and solve the low performance of the global model, high computing and communication overhead, and security issues in the aggregation process in traditional FL methods, the research content of this paper is as follows:

(1) A federated framework for dynamic contribution evaluation based on Shapley value(FedCon): In the scenario of Non-IID data, the data heterogeneity between clients is greatly enhanced, which also increases the difficulty of FL. The generalization ability of the global model cannot meet the task requirements. This paper designs a FL method FedCon based on Shapley value to accurately evaluate user contributions. FedCon calculates the Shapley value of the client in each round of

training and accurately evaluates the contribution of the client to the global model. However, the calculation complexity of the Shapley value is too high. FedCon combines Monte Carlo sampling technology to reduce the calculation complexity. At the same time, the cosine similarity matrix between the local model and the global model is introduced to further reduce the sampling set, so that the current Shapley value can accurately represent the client contribution under limited computing resources. In order to improve the stability of the global model training process, the method considers the historical weight of the client and effectively reduces the fluctuation range of the global model. Experimental results show that FedCon is superior to existing FL methods in terms of model performance, model accuracy, communication overhead and robustness, and can adapt well to the scenario of Non-IID data.

(2) Secure federation framework based on polynomial commitment and blockchain(SCDFL): In the scenario of Non-IID data, traditional FL methods have single point failures and privacy leakage risks that affect the secure aggregation of global models. In addition, the server will become the bottleneck of the entire training task. Therefore, this paper explores a secure and high-performance decentralized FL method to achieve secure aggregation of FL, eliminate dependence on central servers, and improve the robustness and privacy protection capabilities of the system. This paper proposes a secure federation framework SCDFL based on polynomial commitment and blockchain. SCDFL achieves the verifiability of global model aggregation through polynomial commitment protocols and smart contracts, and protects local gradients and ensures client data privacy through symmetric encryption and hash encryption. SCDFL generates public/private key pairs through a trusted execution agency for the client to submit aggregation verification proofs; committee members execute the verification process on the blockchain through smart contracts to ensure the correctness of model aggregation. Experimental results show that SCDFL significantly reduces computing and communication costs, while enhancing robustness against malicious clients. It improves privacy protection, computing overhead and model performance, verifying its feasibility in the actual deployment of FL.

This paper presents a systematic study of FL under Non-IID data conditions, proposing innovative solutions from two key perspectives: model performance optimization and secure aggregation mechanisms. By integrating Shapley value-based contribution evaluation with historical weight tracking, the proposed method enhances the generalization ability and stability of the global model. Additionally, by introducing blockchain and committee-based mechanisms, it enables secure, efficient, and verifiable model aggregation. Experimental results demonstrate that the proposed FL optimization framework achieves superior performance in terms of accuracy, robustness, and communication and computation efficiency. These findings indicate strong potential for practical deployment and offer a solid theoretical and technical foundation for real-world federated learning applications.

Keywords:

Federated learning, Model performance, Non-IID data, Communication overhead, Computation overhead

目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	3
1.2.1 数据异构性.....	3
1.2.2 通信优化策略.....	3
1.2.3 隐私保护与安全性问题.....	4
1.3 本文的研究内容.....	5
1.4 本文的组织结构.....	6
第 2 章 相关理论与方法	8
2.1 联邦学习相关知识.....	8
2.1.1 架构分类.....	8
2.1.2 系统建模.....	9
2.1.3 常见聚合算法.....	10
2.1.4 数据异构性.....	11
2.2 Shapley 值.....	13
2.3 区块链技术.....	13
2.4 多项式承诺技术.....	15
2.5 本章小节.....	15
第 3 章 基于 Shapley 值动态贡献评估联邦框架	17
3.1 引言.....	17
3.2 模型聚合与贡献评估.....	19
3.3 FedCon 框架	20
3.3.1 聚合权重初始化.....	21
3.3.2 基于蒙特卡洛简化采样.....	25
3.3.3 基于余弦相似度调整计算偏差.....	26
3.3.4 动态权重调整.....	27
3.4 实验评估.....	28
3.4.1 实验设置.....	28
3.4.2 框架准确性分析.....	30
3.4.3 框架稳定性评估.....	34
3.4.4 框架通信开销分析.....	36
3.4.5 超参数灵敏性分析.....	37
3.4.6 消融实验.....	38
3.5 结论.....	39

第4章 基于委员会与区块链的安全联邦框架	40
4.1 引言	40
4.2 安全性与去中心化研究	42
4.3 SCDFL 框架	43
4.3.1 工作流程	46
4.3.2 初始化阶段	48
4.3.3 聚合阶段	49
4.3.4 验证阶段	50
4.4 实验评估	50
4.4.1 实验设置	50
4.4.2 框架时间复杂度分析	51
4.4.3 框架准确性分析	52
4.4.4 框架计算成本分析	54
4.4.5 框架通信成本分析	56
4.5 结论	57
第5章 总结与展望	58
5.1 工作总结	58
5.2 未来展望	59
参考文献	60

第1章 绪论

本章主要介绍研究背景与意义,在当前用户数据量持续增长的背景下,用户数据的安全与隐私保护的重要性日益凸显。随着大数据和人工智能技术的快速发展,用户数据在推动社会进步和经济增长过程中越发重要。然后讨论了联邦学习聚合算法和框架国内外研究现状,重点分析了当前联邦学习框架在处理非独立同分布数据时的不足之处。之后介绍了本文的研究思路,包括面临的主要挑战和创新点,提出了针对非独立同分布数据环境下联邦学习的两个框架: FedCon 和 SCDFL。最后,介绍了论文的组织结构和本文的工作安排,为后续章节展开提供清晰的框架。

1.1 研究背景与意义

随着人工智能技术^[1]的迅猛发展,以数据为驱动的机器学习模型在各个领域中展现出来了巨大的发展潜力。然而数据在收集和使用的过程中也存在着显著的隐私^[2]和安全问题。在医疗^[3]、金融^[4]、教育^[5]等敏感领域,数据的隐私保护成为了不可忽视的挑战。传统的集中式机器学习^[6]方法在训练时要收集存储所有的数据并且在一个机器上进行处理,这不仅增加了数据泄露的风险,还可能会导致数据所有者的隐私受到侵害。在现实生活中,数据通常由不同的机构、企业、个人拥有,数据的分布和存储呈现出了高度分散和隔离的特征,数据中涉及到了用户的隐私,行业竞争与利益冲突的存在,企业也可能处于利益保护的考虑而选择不共享数据,导致“数据孤岛”^[7]现象。此外,数据的集中化处理还面临着数据传输的高成本和通信带宽^[8]限制等问题。

针对这些问题,联邦学习(Federated Learning, FL)^[9]作为一种新兴实现数据安全共享的分布式机器学习范式应运而生。联邦学习的核心思想是参与者在训练时将涉及隐私安全的数据保留在本地物理设备上,通过分布式训练和模型聚合实现全局模型的优化。中央服务器将初始化全局模型发向各参与设备,各设备利用本地数据对全局模型进行训练并更新模型参数,中央服务器通过安全聚合机制(如差分隐私或同态加密)^[10]整合各设备的更新信息生成全局模型,这一过程

以迭代方式进行，直至模型训练达到收敛。联邦学习具有以下优势：

(1) 数据分布分散与隐私保护^[11]：联邦学习的核心是将客户端数据保留在本地设备或节点上，无需将原始数据上传至中央服务器。这种分布式的数据存储方式能够有效应对数据孤岛问题。参与方的数据都在本地进行模型训练，避免了原始数据的集中存储和数据通信，使得数据泄露的风险大大降低，保护了参与方的数据隐私。

(2) 计算与通信开销小^[12]：和传统的模型训练相比，联邦学习的计算任务分散在本地设备上，每个参与方在本地进行模型训练，减少了中央服务器的计算负担，训练过程中仅需传输模型参数更新，和传统的分布式机器学习相比，通信开销较低，适合带宽受限制的场景。

(3) 缓解数据分布不均影响：联邦学习相对于传统的模型训练，可以通过加权聚合^[13]、个性化模型等技术，在一定程度上缓解数据分布不均所带来的影响，可以提升模型的泛化能力，但是非独立同分布数据仍然是一个挑战。

(4) 可扩展性强^[14]：联邦学习具有良好的可扩展性，可以支持大规模设备和节点的参与。联邦学习采用分布式计算架构，参与方在本地设备上训练服务器下发的模型，能够大大降低中央服务器的计算负担，可以适应大规模设备和节点的协同训练需求^[15]。

在此背景下，本文主要研究在非独立同分布的数据场景下解决方案，旨在应对数据分布差异、收敛速度慢和模型性能下降挑战，得到高泛化能力的全局模型，实现安全可靠的模型聚合。本文提出了两个创新性框架：FedCon 和 SCDFL，分别从模型性能提升和降低全局模型安全聚合验证时通信开销两个维度解决非独立同分布数据环境下的联邦学习难题。FedCon 通过基于蒙特卡洛采样计算 Shapley 值，结合余弦相似度矩阵调整采样集合减小带来的偏差，引入客户端历史权重，动态调整客户端聚合权重，提升了全局模型在非独立同分布数据场景下的模型精度和收敛速度。SCDFL 结合区块链技术，利用智能合约和委员会机制实现安全聚合，同时降低通信开销，确保模型聚合过程的透明性和不可篡改性，有效抵御拜占庭攻击和数据篡改。

综上所述，在非独立同分布数据场景下研究高效安全的联邦学习框架，对于上述问题提出有效的解决方案具有重要意义。

1.2 国内外研究现状

联邦学习作为一种新兴的实现数据安全共享的分布式机器学习范式,国内外研究学者围绕联邦学习的处理数据异构性、通信效率、隐私保护等问题展开了深入研究,并取得了一系列重要成果。在非独立同分布数据场景下,如何有效的处理数据,提取有效特征实现精确的模型聚合,并且在有限的通信带宽和不可靠的设备下完成联邦学习成为亟需解决的问题。本小节将从三个方面展开讨论:首先介绍了联邦学习中的数据异构性;接着介绍联邦学习当前的通信优化策略;最后讨论了联邦学习当前隐私保护与安全性问题的解决方案。

1.2.1 数据异构性

数据异构性^[16]是指不同参与方之间的数据类别分布存在显著差异,即数据呈现非独立同分布特性。数据分布的不一致限制了联邦学习在实际场景中的应用,不同参与方的数据标签分布差异显著,数据类别特征分布差异显著,或数据量差异显著。由于数据分布的不一致性,导致全局模型性能下降,模型训练收敛速度变慢,还会导致某些客户端对全局模型的贡献被低估,从而影响模型的公平性和性能。

为缓解数据类别分布异构性对全局模型性能造成的负面影响,现有研究主要采用两种方法:客户端侧的本地模型调整和服务端侧的全局模型调整。大多数研究集中于第一种方法。例如, FedProx^[17]和 FedDyn^[18]通过引入正则化项来优化本地模型; MOON^[19]则通过对齐本地模型与全局模型的中间输出,减少本地模型之间的方差。在第二种方法中, FedDF^[20]和 FedFTG^[21]通过引入额外的微调步骤来优化全局模型。尽管这些方法取得了一定成果,但很少有研究关注服务端侧的聚合权重优化。现有方法通常仅根据客户端的数据集大小进行聚合,而数据集大小无法反映类别分布信息^[22],因此无法提供足够的本地客户端信息。

1.2.2 通信优化策略

在联邦学习中,通信效率^[23]是影响系统性能的关键因素之一。联邦学习要求客户端和服务端在模型训练过程中频繁传输本地模型和全局模型进行模型迭代,

在带宽受限和设备资源有限的场景下，如何优化通信效率，降低通信开销是联邦学习框架的重要研究方向。为了应对通信瓶颈问题，研究者提出了多种通信优化策略，有研究者提出将模型进行压缩与稀疏化，通过量化、剪枝或低维分解来压缩梯度更新，可以有效减少传输的数据量^[24]。例如，Top-k 梯度稀疏化方法在模型传输过程中，只传输梯度中的重要部分^[25]，这种方法会根据设置的阈值排序，将梯度值最大的前 k 个传输至服务器，大大减少了传输的数据量。模型量化技术将模型参数从高精度浮点数转化为低精度表示，同样可以减少传输数据量^[26]。

通信调度与资源分配策略主要针对参与训练的客户端进行选择和通过网络资源进行合理分配，进一步降低通信开销。客户端选择策略在每轮训练中仅选择部分客户端参与通信^[27]，可以降低通信负担，客户端的选择标准可以基于客户端的资源状态（如计算能力、网络条件）或数据分布。此外，带宽优化策略通过优先传输重要梯度更新，提升了通信效率。例如，基于梯度重要性的筛选机制仅传输对模型更新贡献较大的梯度^[28]，使得传输数据量大大减小。

基于委员会机制优化通信^[29]，在传统的聚合方案中，所有的客户端需要与多个其他客户端进行秘密共享交换，需要大的通信开销，而委员会机制可以通过选取部分代表节点执行聚合任务，减少全局通信量，普通客户端只需要与委员会成员进行数据交换，不需要和所有的客户端进行秘密共享，减少通信复杂度^[30]。

上述通信优化策略一定程度上可以提升通信效率，但同时也大大增加了系统的复杂性，在大规模的联邦学习场景中，而且在研究通信效率的同时，也会一定程度上造成模型精度的降低和安全隐患，如何在保证数据安全的同时提升模型性能，提升系统的通信效率仍然是一个挑战。

1.2.3 隐私保护与安全性问题

联邦学习在训练过程中不会直接传输原始数据，但攻击者仍然可以通过分析模型参数更新推断出客户端的敏感信息。针对训练中传输的模型，攻击形式包括模型反演攻击、参与者成员推断攻击和梯度泄露攻击等。例如，攻击者可以通过分析上传的模型梯度更新反推重构出参与训练客户端的原始数据^[31]，还可以分析模型输出推断某个数据样本是否属于训练集。为了应对这些攻击，研究者提出了多种安全聚合和数据隐私保护方案。差分隐私技术^[32]通过在模型更新中添加

噪声,防止攻击者推断敏感信息;同态加密技术^[33]可以直接在加密数据上进行计算,不用对模型进行解密,保证了模型更新的隐私性;安全多方计算技术^[34]则允许多个客户端在不泄露本地数据的情况下协同计算模型更新。

联邦学习在实际应用中还面临多种安全攻击,主要包括拜占庭攻击^[35]、数据投毒攻击^[36]和模型篡改攻击^[37]。为了应对这些攻击,研究者提出了多种防御机制。鲁棒聚合算法^[38]通过引入中位数聚合或裁剪聚合,过滤恶意客户端的模型更新;区块链技术^[39]通过不可篡改的分布式账本记录模型更新,增强系统的安全性和可验证性;零知识证明技术^[40]则允许客户端在不泄露本地数据的情况下证明模型更新的正确性。然而,这些方案仍存在计算复杂度高、通信开销大等局限性,无法满足隐私保护,系统性能和通信开销之间的平衡。

1.3 本文的研究内容

联邦学习在隐私保护和数据安全方面有显著优势,但其在实际应用中仍然面临诸多挑战。下面本节详细介绍一下面临的挑战:

(1) 隐私保护与安全性问题:联邦学习在训练过程中只传输本地模型梯度,一定程度上保护了数据隐私,但在实际应用中仍存在隐私泄露和安全风险。攻击者可以通过分析模型梯度更新推断出参与方的隐私数据,攻击者还可以伪造模型梯度或者对梯度增加噪声,使得全局模型无法收敛,影响全局模型的训练效果。

(2) 数据异构性问题:联邦学习中的各个参与方的数据通常是非独立同分布(Non-IID)的,不同参与方的数据分布会存在着显著差异,导致训练出的全局模型可能在部分参与方上表现良好,而在其他参与方上表现比较差,全局模型的泛化能力不好,而且数据异构性会导致模型训练过程中的收敛速度变慢,使得训练时间和计算成本增加。

(3) 通信效率和成本问题:联邦学习需要在参与方和中央服务器之间频繁的传输模型更新,会导致较高的通信开销。例如,在移动设备或物联网设备(IoT)^[41-43]等带宽受限的场景中,频繁的模型更新传输会导致通信瓶颈,网络延迟在参与方分布广泛的场景中会影响模型训练的实时性和效率。此外,频繁的通信和计算会增加设备的能源消耗,影响设备的续航能力^[44]。

针对上述挑战,本文提出了两个创新性框架: FedCon 和 SCDFL, 分别从模

型性能提升和保证安全聚合的同时降低系统通信开销两个方面解决非独立同分布数据场景下的联邦学习难题。

FedCon 设计了一种可以动态感知客户端贡献的聚合机制，有效应对了 Non-IID 数据环境下的挑战。该机制能够精确量化客户端的贡献，并适应客户端数据特征的动态变化。与现有方法不同，FedCon 利用 Shapley 值精确评估客户端的贡献，同时采用高效的蒙特卡洛采样简化采样集合，结合客户端模型和全局模型的余弦相似度调整采样集合减小带来的偏差，同时在保证精确计算 Shapley 值的同时降低采样频率，并且结合客户端历史权重，稳定模型更新并增强全局模型的鲁棒性。FedCon 通过基于数据规模、分布特征以及模型相似性动态调整聚合权重，显著提升了全局模型的泛化能力，尤其是在 Non-IID 场景下表现尤为突出。本文从全局模型准确率提升，通信开销，模型更新稳定性，来验证其在提升模型聚合精度方面的优势。

SCDFL 通过引入多项式承诺技术和对称加密技术，确保模型聚合过程的安全性，同时降低通信开销。SCDFL 基于可信委员会机制，通过区块链技术确保数据的可验证性和不可篡改性，有效防御拜占庭攻击，不仅提升了去中心化联邦学习系统的容错能力，还保证了在恶意节点存在的情况下，全局模型的聚合结果依然能够保持准确和安全，同时降低了安全验证所需的计算成本和通信开销。本文从框架时间复杂度，全局模型准确率，计算成本与通信成本多方面进行分析，验证框架的安全性和在通信开销方面的优越性。

1.4 本文的组织结构

本文的研究架构如图 1.1，章节安排如下：

第一章：绪论。本章节主要介绍了研究背景及意义。然后分别从数据异构性，通信优化策略，隐私保护三个方面介绍了国内外研究现状。最终介绍了本文的研究内容以及本文的组织结构。

第二章：相关理论与方法。本章节首先主要从架构分类，系统建模，常见聚合算法，数据异构性四个方面介绍了联邦学习相关知识。接着介绍了如何通过 Shapley 值评估贡献，然后介绍了区块链技术和多项式承诺技术，为联邦学习安全聚合提供理论和技术支持。

第三章：基于 Shapley 值动态贡献评估联邦框架。本章节针对非独立同分布数据场景下联邦学习模型精度问题，提出了一种新的基于 Shapley 值动态贡献评估联邦框架（FedCon）。通过计算参与训练客户端的数据类别和全局数据之间的数据质量差异初始化聚合权重，在每一轮训练中通过蒙特卡洛采样精简采样集合，结合本地模型和全局模型的余弦相似度矩阵调整因采样集合减小而导致的 Shapley 值计算偏差，动态地调整聚合权重。本章详细介绍了 FedCon 框架的设计思想，工作流程，以及实验评估，验证框架的有效性。

第四章：基于委员会与区块链的安全联邦框架。本章节针对非独立同分布数据场景下的联邦学习全局模型安全聚合时通信开销大的问题，提出了一种基于委员会与区块链的安全联邦框架（SCDFL）。通过对参与训练的客户端上传的模型梯度进行加密，并基于多项式承诺技术对加密梯度生成聚合验证证明，基于区块链保证数据的透明性和不可篡改性，通过智能合约对加密梯度进行解密并验证聚合梯度，通过验证后可以聚合全局模型，在保证联邦学习的安全聚合的同时大幅度降低了系统的通信开销和计算成本。本章详细介绍了 SCDFL 的结构，工作流程，并通过实验分析了框架在时间复杂度，计算成本，通信成本方面的优势。

第五章：总结与展望。本章节对全文研究内容进行了总结，并且讨论了当前研究的不足之处，对未来工作进行展望。




图 1.1 本文研究架构

第2章 相关理论与方法

2.1 联邦学习相关知识

联邦学习作为一种新兴的实现了数据安全共享的分布式机器学习方法,要求参与方在本地设备上训练模型,参与方和服务端只共享模型参数,避免了直接传递数据,保障参与方数据隐私和安全。联邦学习适用于数据分布不均、隐私敏感的场景。接下来详细介绍联邦学习的分布式架构、系统建模、以及数据异构性。

2.1.1 架构分类

联邦学习按照架构分类,主要分为两大类:

1. 集中式联邦学习

集中式联邦学习是联邦学习中最常见的架构,其核心特点是需要一个中央服务器来协调客户端进行模型训练,服务器负责全局模型的聚合过程。集中式架构如图 2.1 所示,中央服务器负责初始化全局模型并将其分发给各参与方,参与方在本地数据上训练模型并将模型更新上传至中央服务器。中央服务器收集所有参与方的模型更新,并通过聚合算法生成新的全局模型,这一过程重复进行直至模型收敛。集中式联邦学习的优点在于结构简单、易于实现和管理,且中央服务器可以高效协调大规模参与方。但是当中央服务器发生故障或被攻击时,该架构存在数据泄露的风险,而且在大规模训练时服务器的通信开销较大。集中式联邦学习适用于通信资源充足的场景,如移动设备联邦学习^[45]。




图 2.1 集中式联邦学习架构

2. 去中心化联邦学习

去中心化联邦学习消除了中央服务器带来的风险，采用点对点（P2P）通信方式实现模型训练和聚合^[46]。去中心化架构如图 2.2 所示，每个参与方既是客户端也是服务器，负责本地训练和模型更新。参与方之间直接交换模型更新，无需通过中央服务器，每个参与方根据接收到的邻居节点更新，通过本地聚合算法生成新的模型，这一过程重复进行直至模型收敛。去中心化联邦学习的优点在于避免了单点故障，提升了系统的鲁棒性，适用于分布式场景。但是去中心化联邦学习的通信拓扑在实际部署中更为复杂，大大增加了通信开销，模型聚合过程也会受到恶意节点的干扰。去中心化联邦学习适用于对隐私保护和系统鲁棒性要求较高的场景，如物联网（IoT）设备联邦学习^[47]。




图 2.2 去中心化联邦学习架构

2.1.2 系统建模

联邦学习通常采用客户端-服务器架构^[48]，包括一个中央服务器和多个分布式客户端。联邦学习的训练过程包括初始化、本地训练、模型更新上传、模型聚合和模型评估。在初始化阶段，中央服务器初始化全局模型参数 ω 并将其分发给所有客户端。在本地训练阶段，客户端从服务器端下载全局模型 θ_g ，利用本地数据对其进行训练，并将更新后的模型参数或梯度上传至服务器。本地训练的目标是最小化本地损失函数：

$$F_k(\omega) = \frac{1}{n_k} \sum_{i \in \mathcal{D}_k} \ell(\omega; x_i, y_i) \cdots \cdots \cdots (2.1)$$

其中， $\ell(\omega; x_i, y_i)$ 是单个数据点 (x_i, y_i) 的损失函数， n_k 是第 k 个客户端的数据量，

$\mathcal{D}_k$ 是第 k 个客户端的本地数据集合。在模型更新上传阶段,客户端将更新后的模型参数或梯度 $\Delta\omega_t^k=\omega_t^k-\omega_t$ 上传至中央服务器。在模型聚合阶段,中央服务器收集所有的客户端的模型更新,并通过聚合算法将其整合为新的全局模型:

$$\omega_{t+1} = \omega_t + \sum_{k=1}^K \frac{n_k}{n} \Delta\omega_t^k \quad \cdots \cdots \cdots (2.2)$$

其中, n 是所有客户端的总数据量, K 是客户端总数。

联邦学习的全局目标函数是所有客户端本地损失函数的加权平均:

$$F(\omega) = \sum_{k=1}^K p_k F_k(\omega) \quad \cdots \cdots \cdots (2.3)$$

其中, $F(\omega)$ 是全局损失函数, $F_k(\omega)$ 是第 k 个客户端的本地损失函数, p_k 是第 k 个客户端参与训练全局模型的权重, $p_k \geq 0$ 且 $\sum_{k=1}^K p_k = 1$,如果不考虑参与训练客户端之间的设备差异和数据类别分布差异性, p_k 通常是均匀分布的,如联邦平均算法(FedAvg)^[49],所有的客户端的权重都是由数据量所决定。

2.1.3 常见聚合算法

在联邦学习中,聚合算法是协调客户端本地模型更新优化全局模型的核心组件。接下来介绍几种常见的聚合算法。

FedAvg(Federated Averaging)^[49]是传统的聚合算法。核心思想是对客户端的本地模型参数进行加权平均,权重由客户端的数据量决定:

$$\omega_{t+1} = \sum_{k=1}^K \frac{n_k}{n} \omega_t^k \quad \cdots \cdots \cdots (2.4)$$

其中, ω_t^k 是第 k 个客户端的本地模型参数, n_k 是其数据量, n 是总数据量。FedAvg简单高效,但在非独立同分布(Non-IID)数据下可能收敛不稳定。

FedProx^[17]在FedAvg的基础上引入了正则项,以缓解Non-IID数据带来的客户端漂移问题,本地目标函数为:

$$F_k(\omega) + \frac{\mu}{2} \|\omega - \omega_t\|^2 \quad \cdots \cdots \cdots (2.5)$$

其中, μ 是正则项系数, ω_t 是全局模型参数。FedProx通过限制本地模型更新与全局模型的偏离,提高了收敛稳定性。

SCAFFOLD^[50]算法创新性地引入控制变量,可以灵活精准的减小客户端模型更新之间的方差。其核心思想是客户端在本地训练时同时更新控制变量,以校正本地梯度与全局梯度的偏差。SCAFFOLD在Non-IID数据下表现出色,但需

要额外的通信开销来传输控制变量。

FedDyn^[18]通过动态正则化将全局模型信息融入本地目标函数。其本地目标函数为:

$$F_k(\omega) + \langle V_t, \omega \rangle + \frac{\mu}{2} \|\omega - \omega_t\|^2 \dots\dots\dots (2.6)$$

其中, V_t 是动态正则化项, FedDyn 通过动态调整正则化项, 有效缓解了客户端漂移问题。

FedNova^[51]通过归一化客户端更新来解决本地训练步数不一致导致的偏差问题:

$$\omega_{t+1} = \omega_t + \sum_{k=1}^K \frac{n_k}{n} \frac{\omega_t^k}{\tau_k} \dots\dots\dots (2.7)$$

其中, τ_k 是第 k 个客户端在其本地进行训练的步数。FedNova 在客户端设备异构、计算资源差异性较大的场景下表现优异。

MOON^[19]利用对比学习的思想, 通过对比全局模型和本地模型的表示来指导本地训练, 其本地目标函数为:

$$F_k(\omega) + \lambda \mathcal{L}_{con}(\omega, \omega_t, \omega_t^k) \dots\dots\dots (2.8)$$

其中, $\mathcal{L}_{con}$ 是对比损失函数, λ 是权重系数。MOON 使得客户端的本地模型更新和全局模型梯度更新保持高度一致, 减少了模型偏差, 提升了模型性能。

2.1.4 数据异构性

在联邦学习中, Non-IID 数据是指参与训练的客户端之间的数据分布存在显著差异。在实际场景中常见, 如医疗领域中不同地区的医院可能专注于不同的疾病类型, 导致患者的数据类别分布不均; 金融领域中不同地区的银行客户行为存在显著差异; 在智能设备领域^[52]不同用户的设备使用习惯会导致数据分布的多样性。Non-IID 数据对联邦学习的模型训练提出了严峻挑战, 会导致客户端模型漂移, 全局模型收敛困难以及性能下降。为了模拟和研究 Non-IID 数据的影响, 研究者提出了多种数据分割方法。本文主要介绍两种常见的 Non-IID 数据生成方法: 基于 Dirichlet 分布^[53] (NIID-1) 和极端异构数据分布 (NIID-2)。

1. 基于 Dirichlet 分布

本文研究用到的第一种数据分割方法是基于 Dirichlet 分布^[19], 称为 NIID-1。

Dirichlet 分布是一种多变量概率分布,常用于生成具有不同稀疏程度的概率向量。其核心思想是通过设置参数向量 α 的值,为每个客户端生成类别概率分布。对于 K 个客户端和 C 个类别,Dirichlet 分布生成一个类别分布矩阵 $P \in \mathbb{R}^{K \times C}$,其中每个元素 $p_{k,c}$ 表示第 k 个客户端中第 c 个类别的样本比例。Dirichlet 分布的概率密度函数为:

$$Dir(p|\alpha) = \frac{1}{B(\alpha)} \prod_{c=1}^C p_c^{\alpha_c-1} \dots\dots\dots (2.9)$$

其中, α 是 Dirichlet 分布的参数向量,控制分布的稀疏性,当 $\alpha = 0.1$ 时,生成的类别分布矩阵 P 具有较高的稀疏性,某些类别的样本集中在少数客户端,而其他客户端则缺乏这些类别的样本。 $B(\alpha)$ 是多元 Beta 函数,定义为:

$$B(\alpha) = \frac{\prod_{i=1}^K \Gamma(\alpha_c)}{\Gamma(\sum_{c=1}^C \alpha_c)} \dots\dots\dots (2.10)$$

其中 $\Gamma(\alpha_c)$ 是 Gamma 函数^[54]。

这种分割方法能够有效模拟实际场景中客户端数据分布的多样性和不均衡性。例如,在医疗数据场景中,不同医院可能专注于不同的疾病类型,导致数据类别分布不均。通过基于 Dirichlet 分布的分割,可以为研究联邦学习在 Non-IID 数据下的性能提供重要测试环境。

2. 极端异构数据分布

本文实验研究采用的第二种数据分割方法称为极端异构数据分布(NIID-2),在这种方法中,举个例子, $K = 10$ 个客户端中的2个客户端具有均匀分布的数据,即每个类别在这些客户端中的样本比例相等。其余8个客户端每个仅包含2或3个类别的样本,且这些类别的样本数量相等。尽管每个客户端的数据量相等,但每个客户端的数据类别分布是不均衡的。假设总类别数为 C ,则病理性分割的类别分布矩阵 P 可以表示为:

$$p_{k,c} = \begin{cases} \frac{1}{C} & \text{if } k \in K_{uniform} \\ \frac{1}{s_k} & \text{if } k \in K_{non-uniform}, C \in C_k \\ 0 & \text{otherwise} \end{cases} \dots\dots\dots (2.11)$$

其中, $p_{k,c}$ 代表客户端 k 在类别 C 上的数据比例, s_k 代表客户端 k 所持有的类别数量, $K_{uniform}$ 表示均匀分布的客户端集合, $K_{non-uniform}$ 表示非均匀分布的客户端集合, C_k 表示分配给客户端 k 的类别集合。

极端异构数据分布旨在模拟现实世界中严重的类别不均衡现象。例如，在医疗数据场景中，某些医院可能仅拥有特定疾病的数据，而其他疾病的数据几乎完全缺失。这种分割方法为评估模型在类别不均衡和分布差异下的适应能力提供了有效的测试场景。

2.2 Shapley 值

在联邦学习中，要公平的精确的评估客户端对全局模型做出的贡献是一个难点。Shapley 值^[55]是一种源自合作博弈的方法，用于公平分配合作收益，近年来被广泛应用于联邦学习中的客户端贡献评估。Shapley 值的核心思想是根据每个参与方对合作联盟的边际贡献来分配收益。其计算公式为：

$$\phi_k(v) = \sum_{S \subseteq K/\{k\}} \frac{|S|!(|K|-|S|-1)!}{|K|!} (v(S \cup \{k\}) - v(S)) \cdots \cdots (2.12)$$

其中， $\phi_k(v)$ 是客户端 k 的 Shapley 值， K 是所有客户端的集合， S 是不包含客户端 k 的子集， $v(S)$ 是子集 S 的收益函数，通常用模型性能（如准确率）衡量。Shapley 值的计算考虑了客户端在所有可能的子集中的边际贡献，并通过加权平均得到公平的贡献评估。Shapley 值具有公平性、对称性、可加性和有效性等重要性质。公平性确保贡献与收益分配成正比，对称性保证贡献相同的客户端获得相同的收益，可加性允许将多个合作博弈的 Shapley 值相加，而有效性则保证所有客户端的 Shapley 值之和等于总收益。这些性质使得 Shapley 值成为联邦学习中客户端贡献评估的提供理论支持^[56]。

在联邦学习中，Shapley 值的计算步骤如下：

首先，定义收益函数 $v(S)$ ，假设直接用全局模型的准确率作为衡量子集 S 参与训练的贡献，计算每个客户端 k 加入不同子集 S 时的边际贡献 $v(S \cup \{k\}) - v(S)$ ；然后，根据 Shapley 值公式计算每个客户端的 Shapley 值。

2.3 区块链技术

区块链（Blockchain）技术，作为一种新型分布式账本技术，通过密码学方法确保数据的安全性和不可篡改性质。其优势包括去中心化、透明性、不可篡改性、可追溯性和安全性。区块链的结构如图 2.3 所示，区块链中包含很多区块，

区块之间连接成链，每个区块包含一组交易记录，并通过哈希指针链接到前面一个区块。区块链的共识机制^[57]（如工作量证明 PoW 或权益证明 PoS）确保所有的节点对账本状态达成一致，从而避免了单点故障和中心化控制的风险。




图 2.3 区块链结构

在联邦学习中，区块链技术可以增强系统的可信性和透明性。联邦学习中的客户端贡献评估和收益分配需要公平性和透明性，而区块链的不可篡改性和可追溯性能够有效记录客户端的贡献和收益分配过程，防止数据被篡改和数据欺诈行为。区块链的加密技术可以很好的满足联邦学习中的隐私保护，哈希函数和数字签名可以保证数据传输的安全性。在联邦学习中，区块链可以用于记录客户端的本地模型更新、贡献评估结果和收益分配信息。每个交易（如模型更新上传或收益分配）被打包成一个区块，并通过共识机制添加到链上。区块链的链式结构确保了数据的透明性和可追溯性，而且数据的不可篡改性提高了系统的抗攻击能力。

加密技术是区块链的核心组成部分，主要包括哈希函数、非对称加密和数字签名。哈希函数用于生成数据的唯一指纹，确保数据的完整性和不可篡改性。非对称加密通过公钥和私钥对实现数据的安全传输，例如客户端使用服务器的公钥加密模型更新，服务器使用私钥解密。加密技术的发展使得联邦学习能够有效保护客户端数据的隐私和模型训练过程中的安全。

智能合约是区块链的重要组成部分，是一种运行在区块链上的自动化程序，当该程序在达到合约中设定的条件时，便会自动执行合约上的操作。在联邦学习中，智能合约可以用于优化聚合算法和增强安全聚合的可靠性。例如，在全局模

型聚合过程中,智能合约可以自动验证客户端上传的模型梯度更新的安全性,对恶意客户端的更新进行过滤和标记,除此之外,还可以将每次的聚合结果和参与训练的客户端贡献记录在区块链上,确保聚合过程的透明性和可追溯性。

2.4 多项式承诺技术

多项式承诺技术是一种密码学工具^[58]。承诺者通过对一个多项式 $f(x)$ 进行承诺,生成一个简短的承诺值 C ,而且不需要立即揭示整个多项式,这个承诺值 C 不会泄露多项式 $f(x)$ 的具体信息,但可以在后续阶段用于验证多项式在约束下的值。多项式承诺技术的核心优势在于其高效性能和强大的隐私保护能力。

多项式承诺技术生成的承诺值 C 具有隐藏性、绑定性、可验证性。承诺值 C 不会泄露多项式 $f(x)$ 的具体系数;一旦生成承诺值 C ,承诺者无法更改多项式 $f(x)$ 而不被检测到;验证者可以通过承诺值 C 验证多项式在某个点的值是否正确。承诺者使用可信执行机构生成的公钥元组对多项式进行承诺,而验证者通过公开参数验证承诺值的正确性。多项式承诺的构建过程如下:

设置阶段:可信执行机构生成安全随机数 τ 作为私钥,计算公钥元组 $PK = (g, g^\tau, g^{\tau^2}, \dots, g^{\tau^i})$,其中 g 是素数阶 p 的群 $\mathbb{G}$ 的生成元。公钥元组 PK 是公开的,而私钥 τ 是由可信机构保密。

承诺生成阶段:承诺者使用公钥元组对多项式 $f(x)$ 生成承诺值 C 。对于多项式 $f(x) = \sum_{i=0}^n a_i \cdot x^i$,承诺者计算承诺值 C :

$$C = \prod_{i=0}^n (g^{\tau^i})^{a_i} = g^{\sum_{i=0}^n a_i \cdot \tau^i} = g^{f(\tau)} \dots\dots\dots (2.13)$$

其中 g^{τ^i} 是公钥元组中的第 i 个元素,承诺生成阶段将多项式 $f(x)$ 转换为一个简短的承诺值 C ,确保数据的机密性。

承诺验证阶段:验证者通过承诺值 C 验证多项式 $f(x)$ 的正确性。

2.5 本章小节

本章主要介绍联邦学习的基础理论、关键技术及其在非独立同分布数据场景下的挑战与解决方案,详细阐述了联邦学习的架构和数学建模,Shapley 值计算,

常见的聚合算法等。本章还介绍了区块链技术对联邦学习在实际部署的优势，介绍了区块链去中心化、透明性、不可篡改性和智能合约等特性以及如何增强系统的可信性和安全性。最后介绍了多项式承诺技术，这是一种密码学工具，为后续安全联邦框架的研究提供了技术支持。通过本章对基础理论的介绍和讨论，为后续章节提出新型联邦学习框架奠定了理论基础，明确了在解决非独立同分布数据场景下模型精度、通信效率和安全聚合问题上的创新性贡献。

第3章 基于 Shapley 值动态贡献评估联邦框架

3.1 引言

随着用户信息隐私保护和数据安全需求的日益增长,联邦学习作为一种新兴的实现了数据安全共享的分布式机器学习范式,受到了研究学者的关注。通过将模型训练任务卸载到客户端设备并实现本地化数据处理^[59],联邦学习有效保护了用户隐私和数据安全^[60]。在数据高度分布式且隐私保护日益受到关注的背景下,联邦学习的重要性越来越凸显。它在多个领域的实际应用中展现了巨大的潜力,例如在医疗领域^[61]通过分布式训练提升疾病诊断模型,在金融服务中用于欺诈检测和信用评分^[62],在智能设备中优化语音助手和个性化推荐系统^[63],以及在物联网 (IoT) ^[41]中实现数据协作与决策。移动边缘计算与联邦学习的结合也被用于解决实时应用中的计算效率^[64]。

尽管联邦学习在隐私保护和分布式计算方面具有显著优势,但其实际应用仍面临若干关键挑战,包括数据异质性^[65]、通信开销以及隐私保护机制的优化等。其中,数据异质性是一个尤为突出的挑战,参加训练的客户端之间数据量和数据类别分布的存在着很大差异^[16],非独立同分布数据严重影响着联邦学习的模型性能。例如,在医学图像分析任务中^[66],不同医院的病患数据可能存在不平衡现象:某些医院的数据可能主要集中在少数疾病类别上,而其他医院的数据则可能涵盖更广泛的类别。这种数据异质性导致客户端模型倾向于优化其本地目标,从而难以对全局模型做出有效贡献。因此,解决数据异质性以提升全局模型的鲁棒性和泛化性能,已成为联邦学习领域的重要研究方向。

为了应对数据非独立同分布带来的挑战,国内外研究学者提出了多种聚合算法。经典的 FedAvg^[49]算法根据参加训练的客户端提供的数据量来计算聚合权重,适用于数据分布相对均匀的场景。FedProx^[17]算法通过在客户端本地损失函数中引入一个正则化项来约束参与训练客户端的模型更新,减小了本地模型和全局模型梯度更新之间的差异,从而缓解数据异质性导致的模型漂移问题。FedMA^[67]算法采用特征对齐方法,对不同客户端的模型进行匹配,以提高聚合效果。MOON^[19]

算法通过对比学习,扩大客户端本地模型和服务器下发的全局模型之间的相似性。SCAFFOLD^[50]算法则通过在客户端和服务端都维护控制变量方法,控制变量可以很好的校正本地模型梯度更新和全局模型梯度更新之间的差异,解决非独立同分布问题。但是现有的固定权重方法无法准确反映每个客户端对模型更新的真实贡献,比如 FedAvg 基于数据量的简单权重分配,不能充分考虑客户端数据类别分布的差异,数据量小、数据类别多的客户端的就会被低估。

为了克服这些挑战,本文提出了一种可以精确评估客户端对全局模型的贡献,动态的调整客户端的聚合权重的联邦学习框架,名为 FedCon (Scalable and Efficient Federated Learning via Contribution-Based Aggregation)。该框架将精确计算 Shapley 值,考虑客户端历史权重动态调整聚合权重,为联邦学习提供了一种有效的聚合方案。非独立同分布数据和客户端贡献不平衡的固有挑战,严重制约了全局模型的泛化能力和训练时的收敛速度。这导致模型性能欠佳,尤其是在客户端数据分布高度不均衡的情况下,问题尤为突出。

FedCon 通过引入一种动态且贡献感知的聚合机制,该机制能够更精确地量化客户端的贡献,并适应客户端数据特征的动态变化。与现有方法不同,FedCon 利用 Shapley 值精确评估客户端的贡献,基于蒙特卡洛采样技术以减小传统计算方法中的采样集合,同时利用本地模型和全局模型之间的余弦相似度调整采样集合减小对于 Shapley 值计算带来的偏差,结合客户端历史权重以保证稳定模型更新并增强全局模型的鲁棒性。FedCon 从数据规模和数据类别分布,每轮训练的模型相似性和历史表现多方面调整聚合权重,显著提升了全局模型的泛化能力,在非独立同分布场景下表现尤为突出。

本文的主要贡献总结如下:

1. FedCon 框架:这是一种可以精确评估客户端对全局模型的贡献,动态的调整客户端的聚合权重的联邦学习框架,该框架在初始化聚合权重时,综合考虑了每个客户端的数据集规模和数据类别分布。

2. 客户端贡献评估:基于蒙特卡洛采样方法减小采样集合,计算 Shapley 值评估客户端的贡献。FedCon 全面考虑客户端的数据分布特征以及模型之间的相似性,增强了聚合权重与模型质量之间的关联性,通过引入余弦相似度矩阵调整因采样集合的减小带来的 Shapley 值计算偏差。

3. 动态权重调整机制: FedCon 基于轮次的线性衰减考虑客户端的历史权重, 有效稳定模型更新过程, 提升了全局模型的鲁棒性。这一机制可以一定程度上保证全局模型对噪声或恶意更新的敏感性降低, 使其在实际部署中更加可靠。

4. 评估: 本文进行了大量的实验, 充分证明了 FedCon 在模型精度、收敛速度和对数据异质性的鲁棒性方面优于最先进的聚合算法, 为联邦学习的实际部署提供了可行性验证。

3.2 模型聚合与贡献评估

联邦学习依赖于权重聚合算法, 将客户端模型更新整合为全局模型。经典方法 FedAvg^[49]根据客户端数据集的大小计算其权重, 在数据独立同分布的场景中表现良好, 但当客户端之间的数据分布差异较大时, 其性能显著下降。FedAvgM^[68]引入了动量项, 缓解了数据异质性引起的模型振荡; FedProx^[17]则通过加入正则化项来约束每个客户端的本地更新, 减少了模型更新的偏差, 并提高了全局模型的稳定性; FedNova^[51]提出了一种模型更新的归一化策略, 解决了通信效率, 优化了异步更新的效率问题, 显著提升了模型训练的收敛速度; MOON^[19]采用对比学习, 利用本地模型梯度更新与全局模型梯度更新之间的对比损失来增强模型个性化; FedDC^[69]引入了分布校准机制, 通过调整客户端模型更新以更好地与全局模型对齐, 进一步提升了全局模型的训练质量。FedMA^[67]基于模型参数对齐调整全局模型聚合, 提高了本地模型与全局模型之间的一致性。基于余弦相似度的策略则通过增强客户端模型与全局模型之间的对齐, 进一步加速了全局模型的收敛。

在联邦学习中, 由于参与训练的客户端数据类别分布的差异, 精确的评估客户端对全局模型的贡献至关重要。传统的客户端贡献评估方法通常通过计算客户端更新模型与全局模型之间的差异来衡量, 并假设这种差异反映了客户端在优化全局模型中的作用。这种方法忽略了数据质量和客户端特性等关键因素, 而这些因素对于准确评估客户端的真实贡献至关重要^[70]。Shapley 值计算源自合作博弈论, 提供了一种精确的贡献评估方法。它根据每个客户端对模型性能的个体影响, 量化其对全局模型更新的边际贡献。尽管 Shapley 值在理论上提供了最公平的贡献评估, 但其计算复杂度随客户端数量呈指数级增长, 使其在大规模系统中难以实际应用。除了依赖模型更新和数据量大小外, 数据质量的整合为贡献评估提供

了新的视角。在以往的研究中,许多方法仅根据客户端数据集的大小来组合本地模型^[71],然而,参与训练的数据量本身并不能反映客户端的数据类别分布或模型性能。

3.3 FedCon 框架

为了应对当前联邦学习中因客户端数据异质性导致的模型训练精度带来的挑战,本文提出了一种名为 FedCon 的联邦学习框架。该框架能够在模型聚合过程中精确动态调整每个客户端的权重,有效地提升全局模型的泛化能力。FedCon 的框架结构如图 3.1 所示。




图 3.1 FedCon 的整体架构

训练过程见算法 3.1。具体步骤如下：

（1）全局模型初始化与下载：首先，客户端从服务器下载初始化的全局模型 θ_0 ，基于全局类别分布 D_g 和本地数据量 $|D_i|$ ，客户端计算本地数据和全局数据之间的类别差异 DQ_i ，得到初始化权重 w_i ，可以加速全局模型的收敛。

（2）本地模型训练：客户端利用本地数据集 D_i 训练其本地模型 $\theta_{i,t}$ ，进行 E 轮训练，并将本地模型参数 $\theta_{i,t}$ 和类别差异 DQ_i 上传至服务器。

（3）Shapley 值与相似度计算：服务器使用蒙特卡洛采样方法计算每个客户端的 Shapley 值 ϕ_i ，并计算本地模型 $\theta_{i,t}$ 与全局模型 θ_g 之间的余弦相似度矩阵 S 。通过 Shapley 值调整相似度矩阵，得到客户端的贡献值权重 w_i 。

（4）历史权重与当前贡献结合：为了考虑本地数据的长期表现，采用遗忘

算法对历史权重进行加权,并结合当前贡献值 w_i ,生成当前轮次的聚合权重 w_i^t 。

(5) 全局模型更新:服务器使用这些权重对本地模型进行聚合,更新全局模型 θ_g 。服务器将聚合得到全局模型分发回客户端。FedCon 重复上述过程。

算法 3.1: FedCon 训练过程

输入: N 个客户端, 初始化模型 θ_0 , 训练总轮次 T , 每轮本地训练的轮次 E ,

全局数据集 $\mathcal{D}_g$, 每个客户端 i 的本地数据集 $\mathcal{D}_i$, 贡献度评估系数 λ 。

训练过程:

1. 初始化: 服务器初始化全局模型 θ_0
 2. 全局训练循环 (共 T 轮):
 3. for $t = 0$ 到 $T - 1$ do
 4. 服务器向所有的客户端分发全局模型 θ_g
 5. 每个客户端 i 执行以下步骤:
 6. 在本地数据集 $\mathcal{D}_i$ 上训练模型 E 轮, 得到本地模型 $\theta_{i,t}$
 7. 计算数据类别差异 $DQ_i = D_{KL}(D_i||D_g) = \sum_{k=1}^K D_i(k) \log \frac{D_g(k)}{D_i(k)}$
 8. 向服务器发送本地模型 $\theta_{i,t}$ 及其数据类别差异 DQ_i
 9. 计算聚合权重:
 10. 若 $t = 0$, 则根据 DQ_i 计算初始聚合权重 $w_i = \frac{n_i \cdot e^{-\lambda \cdot DQ_i}}{\sum_{i=1}^I n_i \cdot e^{-\lambda \cdot DQ_i}}$
 11. 否则, 执行以下步骤:
 12. 计算客户端的 Shapley 值 $\phi_i = \frac{1}{M} \sum_{m=1}^M [F(S_m \cup \{k\}) - F(S_m)]$
 13. 计算客户端本地模型和全局模型之间的余弦相似度矩阵 S
 14. 基于相似度矩阵 S 和 Shapley 值 ϕ_i 调整聚合权重 w_i

$$w_i = \alpha \cdot \phi_i + (1 - \alpha) \cdot \cos(\theta_i, \theta_g)$$
 15. 结合历史权重, 更新 $w_i^t = (1 - \frac{t}{T}) \cdot w_i^{t-1} + \frac{t}{T} \cdot w_i^t$
 16. 模型聚合: 服务器基于计算出的聚合权重进行模型聚合
 17. End for
 18. 输出全局模型: θ_T
-

3.3.1 聚合权重初始化

在联邦学习中,初始化的全局模型聚合权重的对本地训练的效果具有决定性影响。为了量化客户端数据与全局数据之间的差异,本节通过计算每个客户端数据类别分布与全局分布之间的差异。假设第 i 个客户端的数据分布为 D_i , 全局类别分布为 D_g , 则客户端与全局数据分布之间的差异可以通过 KL^[72]散度来衡量:

$$DQ_i = D_{KL}(D_i||D_g) = \sum_{k=1}^K D_i(k) \log \frac{D_g(k)}{D_i(k)} \dots\dots\dots (3.1)$$

其中, $D_i(k)$ 和 $D_g(k)$ 分别表示第 i 个客户端和全局数据的类别 k 的概率分布, DQ_i 反映了客户端 i 的数据分布与全局分布的偏离程度。合理的设计基于数据质量差异的初始化权重,能够有效加快全局模型收敛。

受到 FedAvg 提出的收敛误差界限的启发, 该误差界限主要关注客户端数据规模对聚合权重 w_i 的影响, 本节进一步引入了数据质量差异 DQ_i 作为优化目标。通过最小化全局误差界限, 本节基于此推导出一种新的聚合权重公式。在全局模型的聚合过程中, 数据量和数据质量都是重要的考虑因素。本节的推理和分析基于以下四个标准假设:

假设 1: 损失函数的稳定性: 每个客户端的损失函数 $Loss$ 是稳定的, 这意味着客户端的梯度变化也保持稳定, 保证了客户端在本地训练是不会出现过度的梯度波动, 可以表示为:

$$||\nabla Loss_i(a) - \nabla Loss_i(b)|| \leq Loss||a - b|| \dots\dots\dots (3.2)$$

假设 2: 客户端梯度无偏性: 每个客户端本地训练的模型梯度都是无偏的, 客户端的本地模型的期望梯度等于全局梯度:

$$\mathbb{E}[\nabla Loss_i(\theta_i) = \nabla Loss_i(\theta_g)] \dots\dots\dots (3.3)$$

假设 3: 全局损失有界性: 全局损失函数具有下界限, 表示为 $Loss_{min}$:

$$Loss(\theta_g) \geq Loss_{min} \dots\dots\dots (3.4)$$

其中该假设保证全局损失可以有效收敛防止全局模型性能过度恶化。

假设 4: 客户端数据质量不均衡: 每个客户端的贡献权重与其本地数据量 n_i 成正比, 和数据质量差异 DQ_i 成反比。具体地, 局部模型和全局模型的梯度之间的差异可以由一个常数 C_{dist} 来界定, 该常数取决于客户端的数据分布质量。该假设描述如下:

$$||\nabla Loss_i(\theta_i)||^2 - ||\nabla Loss_g(\theta_g)||^2 \leq C_{dist} \cdot DQ_i \dots\dots\dots (3.5)$$

其中, 本地梯度与全局梯度之间的差异受到客户端数据分布的约束和影响。常数 C_{dist} 用于量化由于客户端数据异质性分布引起的梯度差异的上界。

基于上述假设, 本节进一步的分析发现, 客户端的数据量 n_k 和数据质量差异 DQ_k 是决定每个客户端对全局模型的贡献的关键因素。具体而言, 假设 4 揭示了本地梯度与全局梯度之间的内在关联, 这种关联受到客户端数据质量差异 DQ_k 的约束。从理论上讲, 数据规模较大且数据质量差异较小的客户端, 其提供的梯度更有可能与全局优化方向保持一致, 对模型优化起到更积极的作用。

为了将上述理论融入全局优化框架, 本节将全局目标函数 $F(\theta)$ 设计为本地目

标函数的加权和, 其中权重 w_k 综合考虑了客户端的数据规模和数据质量。这种设计不仅能够平衡所有客户端的贡献, 还能够优先利用数据质量更高、数据规模更大的客户端信息, 从而提升全局模型的优化效果。全局目标函数的具体形式如下:

$$F(\theta) = \min \sum_{k=1}^K w_k \cdot f_k(\theta) \cdots \cdots \cdots (3.6)$$

其中, w_k 为客户端 k 的聚合权重, 满足 $\sum_{k=1}^K w_k = 1$, K 为客户端总数, $f_k(\theta)$ 表示客户端 k 的损失函数。

全局模型的性能不仅受到每个客户端上的数据量的影响, 还取决于数据质量, 尤其是其与全局数据分布的一致性。为了综合考虑这两个因素, 本节引入了正则化项, 该正则化项同时考虑了客户端的数据量 n_k 和数据质量差异 DQ_k 。该正则化项使得数据量更大且数据质量更高的客户端能够对全局模型聚合权重的影响变大。为了进一步量化数据量 n_k 和数据质量差异 DQ_k 的影响, 本节将全局目标函数扩展为以下形式:

$$F(\theta) = \min(\sum_{k=1}^K w_k \cdot f_k(\theta) + \lambda \cdot \sum_{k=1}^K g(n_k, DQ_k)) \cdots \cdots \cdots (3.7)$$

其中, λ 是一个超参数, 用于权衡本地损失与数据质量之间的重要性; $g(n_k, DQ_k)$ 是一个函数, 用于量化数据量 n_k 和数据质量差异 DQ_k 对模型训练的综合影响。

为了最小化目标函数, 假设函数 $g(n_k, DQ_k)$ 被定义为:

$$g(n_k, DQ_k) = n_k \cdot DQ_k \cdots \cdots \cdots (3.8)$$

其中, DQ_k 表示客户端 k 的数据质量, n_k 表示客户端 k 的数据量。

优化问题的目标是最小化全局目标函数 $F(\theta)$, 该函数同时结合了本地损失函数以及考虑数据质量和数据量的正则化项, 其形式如下:

$$F(\theta) = \min_{\omega_1, \omega_2, \dots, \omega_K} (\sum_{k=1}^K w_k \cdot f_k(\theta) + \lambda \cdot \sum_{k=1}^K n_k \cdot DQ_k) \cdots \cdots \cdots (3.9)$$

为了确保聚合权重 w_k 的合理性, 加入以下约束:

$$\sum_{i=1}^N w_i = 1, \quad w_i \geq 0 \cdots \cdots \cdots (3.10)$$

在满足该约束的情况下, 通过引入拉格朗日函数, 该函数通过拉格朗日乘子 β 将全局目标函数与约束条件结合起来, 其形式如下:

$$\begin{cases} L(\omega_K, \beta) = \sum_{k=1}^K w_k \cdot f_k(\theta) + \lambda \cdot \sum_{k=1}^K n_k \cdot DQ_k + \beta(\sum_{k=1}^K w_k - 1) \\ \frac{\partial L}{\partial w_k} = f_k(\theta) + \beta = 0 \\ \beta = -f_k(\theta) \end{cases} \cdots (3.11)$$

通过对目标函数求导并应用拉格朗日乘数, 获得了客户端的聚合权重 w_k 的

优化表达式:

$$w_k \propto n_k \cdot e^{-\lambda \cdot DQ_k} \dots\dots\dots (3.12)$$

上述公式表明,客户端的贡献权重与数据规模 n_k 和数据质量差异 DQ_k 呈现指数关系。数据规模较大且数据质量差异较小的客户端被赋予更高的权重,从而对全局模型的更新做出更大贡献。

通过进一步简化,得到最终的初始化权重公式:

$$w_k = \frac{n_k \cdot e^{-\lambda \cdot DQ_k}}{\sum_{k=1}^K n_k \cdot e^{-\lambda \cdot DQ_k}} \dots\dots\dots (3.13)$$

该公式表明,客户端的权重不仅取决于其数据规模 n_k ,还与其数据质量差异 DQ_k 密切相关。具体而言,当客户端的数据规模 n_k 较大且数据质量差异 DQ_k 较小时,其聚合权重 w_k 会相应增加。这意味着,数据规模更大且数据分布更均衡(即与全局分布的差异较小)的客户端将被赋予更高的权重。公式通过综合考虑数据规模 n_k 和数据质量差异 DQ_k 来计算客户端 k 的权重 w_k ,其中数据规模较大或数据质量差异较小的客户端会获得更高的权重。

公式中的指数函数 $e^{-\lambda \cdot DQ_k}$ 用于调整数据质量差异对权重的影响,超参数 λ 控制这种影响的强度。最终,权重在所有客户端之间进行归一化,以确保其对全局模型的贡献分配公平合理。这种权重分配策略能够更精确地分配权重,有效缓解数据分布不均衡对全局模型的负面影响,从而提升全局模型的泛化能力。

其中, λ 是一个超参数,用于控制数据质量差异对权重系数的影响强度。权重系数 w_k 不仅考虑了数据量,还考虑了客户端之间的数据类别差异,保证数据质量更高且数据规模更大的客户端对全局模型的贡献权重占比更大。

由于客户端数据类别分布的计算过程是在客户端本地完成,服务器仅收集模型更新的差异信息。这种方法理论上降低了敏感信息泄露的风险,因为服务器无法直接访问原始数据或单个客户端的显式数据类别信息。相反,服务器仅接收以模型差异形式聚合的更新信息,从而防止了通过逆向工程推断客户端特定数据属性的可能性。与传统的联邦学习方法相比,传统方法可以通过模型更新和数据聚合策略的交换暴露信息,而 FedCon 的设计限制了与服务器共享的信息量,确保了服务器无法从模型更新中推断出私有数据的详细信息。

在本小节中讨论了如何基于客户端之间的类别差异初始化权重,为后续模型

训练奠定稳定基础。接下来,在初始化权重后,本节基于蒙特卡洛采样方法简化传统采样集合,在保证贡献评估不受影响的情况下减小计算开销。

3.3.2 基于蒙特卡洛简化采样

在联邦学习中,Shapley 值作为一种源自合作博弈论的贡献评估方法,能够量化每个客户端对全局模型训练的边际贡献。Shapley 值在理论上提供了公平的贡献评估,但其计算复杂度随着客户端数量呈现指数级别增长,对于 N 个客户端,时间复杂度为 $O(2^N \cdot N)$,在大规模联邦学习系统中,带来了巨大的计算成本。为了解决这一问题,本节采用基于蒙特卡洛采样减小传统 Shapley 值计算的采样集合,可以显著降低计算复杂度。蒙特卡洛采样通过随机选择客户端子集来近似计算 Shapley 值,从而避免遍历所有的客户端组合。具体步骤如下:

(1) 客户端排序与采样:首先根据客户端的权重 w_k 对其进行排序,并选择权重前 30%的客户端作为采样集。这一策略基于数据量 n_k 和数据质量差异 DQ_k ,确保采样能够代表高贡献客户端。

(2) 边际贡献计算:对于每个采样子集 S_m ,计算客户端 k 的边际贡献 $F(S_m \cup \{k\}) - F(S_m)$,其中 $F(S_m)$ 和 $F(S_m \cup \{k\})$ 分别表示子集 S_m 在包含和不包含客户端 k 时的模型性能。

(3) Shapley 值近似:通过多次采样 M 次,对于边际贡献取平均值,得到客户端 k 的 Shapley 值近似值:

$$\phi_k = \frac{1}{M} \sum_{m=1}^M [F(S_m \cup \{k\}) - F(S_m)] \cdots \cdots (3.14)$$

在本研究中,边际贡献函数是根据客户端在测试集上的准确度计算的。通过比较不同子集的性能,该方法有效地估算了 Shapley 值。这一策略确保了我们可以在大规模系统中高效地评估每个客户端对全局模型的贡献,而无需遍历所有可能的客户端组合。

与传统的Shapley值计算方法相比,蒙特卡洛采样显著降低了计算复杂度。传统方法的时间复杂度为 $O(2^N \cdot N)$,而蒙特卡洛采样通过每次选择30%的客户端进行 M 次采样,将时间复杂度降低至 $O(M \cdot 0.3N)$ 。这种优化在大规模联邦学习系统中尤为重要,能够在保证计算效率的同时,提供足够精确的Shapley值近似。通过选择客户端进行蒙特卡洛采样,显著降低了计算复杂度,尤其是在客户端数量较

大的情况下,这使得这一策略成为减轻计算负担的有效方法。

值得注意的是,蒙特卡洛采样可能会引入潜在的不公平性,因为随机采样不能确保对所有类型的客户端进行绝对公平的代表。为了解决这一限制,可以采用分层抽样方法,将客户端根据特定特征(如数据分布、设备类型或贡献水平)进行分组,然后按比例从每个组中抽取样本。这种方法不仅考虑了每个客户端的权重,还平衡了不同客户端类型的代表性。

在本小节中,使用基于蒙特卡洛采样减小传统计算方法的采样集合,以近似评估每个客户端的贡献。采样的减少只能最大限度地近似接近传统 Shapley 值,为了弥补二者之间的估算值偏差,下一小节引入了本地模型和全局模型的余弦相似度,用来调整因采样集合减小带来的计算偏差,旨在精确评估贡献。

3.3.3 基于余弦相似度调整计算偏差

蒙特卡洛采样可以有效减小 Shapley 值的计算所需的采样集合,但其准确性依赖于样本数量和采样频率。当客户端数据量较多时仍然需要很高的采样频率才能保证得到正确的计算结果,高采样频率会产生高的计算开销。为了精确评估贡献并且减小采样频率,降低计算开销,本节引入了本地模型与全局模型之间的余弦相似度矩阵来调整因采样集合减小带来的 Shapley 值计算偏差。

在联邦学习中,本地模型与全局模型之间的相似度通过余弦相似度来衡量。设第 i 个客户端的本地模型为 θ_i ,全局模型为 θ_g ,它们之间的余弦相似度表示为:

$$\cos(\theta_i, \theta_g) = \frac{\theta_i \cdot \theta_g}{\|\theta_i\| \|\theta_g\|} \dots\dots\dots (3.15)$$

其中, $\theta_i \cdot \theta_g$ 表示模型向量的点积, $\|\theta_i\|$ 和 $\|\theta_g\|$ 分别表示本地模型和全局模型的欧几里得范数。本地模型梯度和全局模型梯度的余弦相似度值越高,说明二者越相似。当本地模型与全局模型之间的余弦相似度较高时,表明客户端的更新方向与全局模型更为一致。因此,通过引入余弦相似度矩阵,能够更好地捕捉客户端与全局模型之间的关系,从而调整蒙特卡洛采样集合减小带来的偏差。调整公式如下:

$$w_i = \alpha \cdot \phi_i + (1 - \alpha) \cdot \cos(\theta_i, \theta_g) \dots\dots\dots (3.16)$$

其中 ϕ_i 表示客户端 i 的 Shapley 值, $\cos(\theta_i, \theta_g)$ 表示客户端 i 的本地模型 θ_i 和全局模

型 θ_g 之间的余弦相似度， α 是一个超参数，用于控制 Shapley 值与余弦相似度贡献之间的权衡。

通过调整 α 的值，可以控制 Shapley 值和余弦相似度在权重计算中的影响。当 $\alpha = 1$ 时，公式仅依赖于 Shapley 值；当 $\alpha = 0$ 时，公式则完全依赖于余弦相似度。在实际应用中，与全局模型相似度较高的客户端对全局模型的贡献更大，因此增加这类客户端的权重有助于减少冗余采样。

在准确计算客户端权重后，通过引入一种考虑客户端历史权重的动态调整机制，以确保全局模型训练的稳定性，旨在减少权重波动对训练过程的影响。

3.3.4 动态权重调整

本节提出了一种动态调整权重机制，以实现初始权重和后续基于 Shapley 值的权重之间的平滑过渡，同时确保训练的稳定性。在每次聚合轮次中，初始权重和 Shapley 值逐步结合，确保第一轮中由初始权重表示的数据贡献逐渐过渡到由 Shapley 值表示的贡献。

本节采用基于轮次的线性衰减来调整初始权重和 Shapley 值的组合比例。随着训练轮次的增加，初始化权重对后续模型聚合权重的影响越来越小，最终，权重完全由 Shapley 值决定。衰减公式如下：

$$w_i^t = (1 - \frac{t}{T}) \cdot w_i^{t-1} + \frac{t}{T} \cdot w_s^t \dots \dots \dots (3.17)$$

其中， w_i^t 表示客户端 i 在第 t 轮的动态权重， w_i^{t-1} 是客户端 i 在上一轮的权重， w_s^t 是客户端 i 在第 t 轮的 Shapley 权重，表示客户端 i 在当前轮次对全局模型的贡献。 T 是总的训练轮次， t 是当前训练的训练轮次。

这一线性衰减机制确保了从初始权重到基于 Shapley 值的权重的平滑过渡，使得模型在训练的早期阶段能够依赖初始权重保证稳定性，而随着训练的进展，逐步引入更准确的客户端贡献。这种动态调整机制有效地减少了在训练初期因数据贡献尚未完全确定而可能产生的不稳定性。过早引入 Shapley 值可能会导致训练过程中的显著波动，尤其是在客户端数据分布差异较大的情况下。

从理论角度来看，初始化权重可以有效防止在训练早期出现过拟合，在数据有限的情况下，模型更多依赖这些稳定的初始权重，可以避免模型训练对少数高质量客户端的过度依赖。通过这一衰减机制，确保在每次聚合轮次中，初始权重

逐渐过渡到由 Shapley 值表示的贡献,从而保持全局模型的稳定性和准确性。随着训练轮次的增加,Shapley 值的影响逐渐增大,最终确保每个客户端的真实贡献得到准确反映,从而提升全局模型的性能。

3.4 实验评估

本文进行了大量的实验来回答以下研究问题并用于评估 FedCon 的有效性。

研究问题 1: 与最先进的聚合算法相比, FedCon 性能如何?

研究问题 2: 与其他的聚合算法相比, FedCon 的通信开销如何?

研究问题 3: FedCon 在模型训练时的稳定性如何?

3.4.1 实验设置

实验是在一台配备 Intel Core i5-12400K 处理器、32.00 GB 内存和 NVIDIA GeForce RTX 3060 显卡的计算机上进行的,实验环境是 3.9.7 版本的 python, 1.10.2 版本的 torch。

数据集: 为了验证 FedCon 的有效性,在多个数据集上进行了实验,包括图像分类,时间序列任务和医疗领域的数据集。所使用的数据集如下: CIFAR10^[73] 和 CIFAR100^[73]: 这两个数据集广泛用于图像分类任务, CIFAR10 包含 10 个类别的图像, CIFAR100 则包含 100 个类别,提供了评估图像分类模型的标准基准。HAM10000^[74]: 这是一个医学图像数据集,用于皮肤损伤分类,该数据集本身存在类不平衡问题,在预处理阶段为测试集选择了每个类别 20 个样本,并且仅使用 Dirichlet 分区方法进行数据划分。HAR^[75] (人体活动识别): 该数据集是一个时间序列数据集,适用于评估时间序列任务中的模型表现。三个医疗数据集^[76]: OrganAMNIST、OrganCMNIST 和 OrganSMNIST: 这三个数据集包含不同类型的医学图像,主要用于器官分类任务。

数据分割: 本实验中采用非独立同分布数据分割来模拟真实场景中的数据异构性,具体使用第二章介绍的 NIID-1 和 NIID-2 两种方法。对于 NIID-1,实验设定 Dirichlet 分布参数为 $\alpha = 0.1$,在 10 个客户端之间划分数据。在 NIID-2 设置中,设定 80% 的客户端数据呈现非独立同分布,剩余的 20% 客户端的数据独立同分布,即每个类别的数据在这些客户端中均匀分布。此外,考虑 HAM10000 和

HAR 数据集的特殊类别分布特性,实验在这两个数据集上仅采用 NIID-1 一种数据分割进行实验。通过上述数据分割方法,能够较为真实的模拟非独立同分布数据的联邦学习训练环境。为了更加直观的观察数据分割,在 CIFAR10 数据集进行两种数据分割,如图 3.2 可见。



图 3.2 CIFAR10 数据集在 NIID-1 和 NIID-2 设置下数据分布

基线方法: 在本研究中,选择了八种方法进行比较分析,以评估它们在数据异质性场景下的表现。这些方法包括: FedAvg^[49]、FedProx^[17]、FedDyn^[18]、FedNova^[51]、MOON^[19]、FedDC^[69]、SCAFFOLD^[50]和 Local。Local 指的是每个客户端仅进行本地训练,不参与任何形式的全局聚合。FedAvg: 经典的联邦平均方法,计算参与训练的客户端模型权重的平均值,来更新全局模型,适用于数据分布较为均匀的场景。FedProx: 在 FedAvg 的基础上引入了正则化项,能够在数据不均衡或不完全独立同分布的环境下提高模型性能。FedDyn: 采用动态调节策略,通过在每轮训练中调整客户端的学习策略来减少数据异质性带来的影响,优化全局模型的训练过程。FedNova: 通过对每个客户端的更新进行归一化,从而避免大数据量客户端的过度影响,适用于高异质性数据场景。MOON: 使用对比学习和梯度正则化的方法,通过最大化局部和全局模型之间的相似性来增强模型的泛化能力。FedDC: 引入了数据一致性约束,通过最大化客户端和全局模型之间的相似度来确保更新的一致性,适应高异质性数据分布。SCAFFOLD: 通过引入控制变量和优化的梯度校正方法,能够有效减少客户端之间的数据偏差,从而提高全局模型的稳定性和准确性。

实施细节: 所有基线方法均采用各自原始论文中推荐的超参数配置,这些方法在联邦学习领域被广泛应用并在多个研究中得到了验证,确保了其高可靠性和

标准化。在实验中，使用了标准的超参数设置：学习率为 0.01，批大小 64，通信轮数 100 轮。这些设置基于在常见数据集上的广泛实验，确保了在相同实验条件下公平比较每个方法。在模型评估中，实验结果关注三个关键指标：准确率、模型收敛和训练稳定性，以全面评估每个方法的表现。

在 CIFAR10 和 CIFAR100 数据集上，实验使用了包含两层卷积层和三层全连接层的卷积神经网络（CNN）架构。对于 HAM10000 数据集，采用了基于 ResNet18 的定制修改版网络。在 HAR 数据集上，使用了具有三层卷积层和三层全连接层的 CNN 架构。在 OrganAMNIST、OrganCMNIST 和 OrganSMNIST 数据集上，实验使用了由两层卷积层和三层全连接层组成的 CNN 架构。

3.4.2 框架准确性分析

本节对 FedCon 框架的准确性进行了全面评估，重点分析了其在多种数据集和不同的数据划分场景下的表现。实验结果如

表 3.1 和表 3.2 所示，FedCon 在处理数据异构性和复杂分类任务方面具有显著优势。

在 CIFAR10 与 CIFAR100 数据集上，FedCon 在 Homo, NIID-1 和 NIID-2 数据分割下均表现出色，特别是在 CIFAR100 的 NIID-2 设置下，FedCon 的准确率较传统方法提升了超过 20%，充分证明了其在复杂任务上的强大能力。

由于 HAR 和 HAM10000 数据集的类别分布极不均衡，实验仅在 NIID-1 划分下进行。FedCon 在 HAR 数据集上达到了 93.52% 的准确率，较 FedNova, SCAFFOLD 和 FedDyn 分别提升了 3.51%、3.07% 和 3.97%。在 HAM10000 数据集上，FedCon 的准确率较 FedDyn 和 SCAFFOLD 分别提升了 8.09% 和 10.49%，展示了其在处理时间序列和医学影像数据类别不平衡问题上的卓越性能。

在 OrganAMNIST, OrganCMNIST, OrganSMNIST 数据集上，FedCon 在 NIID-1 和 NIID-2 划分下均表现出明显优势。在 OrganAMNIST 数据集上，FedCon 比 FedProx 和 FedDyn 分别高出 6.90% 和 3.48%；在 OrganCMNIST 数据集上，FedCon 的准确率达到 86.03%，较 FedDyn 提升了 2.00%；在 OrganSMNIST 数据集上，FedCon 的准确率为 69.27%，较 FedDyn 提升了 2.82%。这些结果进一步验证了 FedCon 在处理医学图像分类任务中的数据异构性和类别不平衡问题上的有效性。

FedCon 通过动态调整客户端权重的创新策略,显著提升了全局模型的泛化能力,尤其是在高复杂性和类别不平衡任务中的优异性能,充分证明了其在实际应用中的潜力和实用性。

表 3.1 FedCon 在 HAR, CIFAR10, CIFAR100 数据集下与基线方法的对比

数据集	HAR		CIFAR10		CIFAR100		
对比方法	NIID-1	Homo	NIID-1	NIID-2	Homo	NIID-1	NIID-2
Local	86.49	56.14	46.71	44.26	18.55	13.34	12.46
FedAvg	89.45	68.97	60.63	65.00	33.65	24.82	25.46
FedProx	89.81	71.37	64.86	64.95	27.62	27.39	29.80
FedDyn	89.55	71.83	66.32	66.97	34.34	30.57	31.97
FedNova	90.01	69.36	63.36	61.25	29.36	24.95	25.24
SCAFFOLD	90.45	72.43	65.52	66.70	33.56	29.0	30.97
MOON	89.65	71.28	64.84	65.17	32.87	28.39	29.88
FedDC	89.38	71.69	65.26	66.43	32.64	30.05	31.53
FedCon	93.52	76.63	70.26	70.94	42.52	42.68	45.73

表 3.2 FedCon 在 HAM10000 和三个医疗数据集下与基线方法的对比结果

数据集	HAM10000		OrganAMNIST		OrganCMNIST		OrganSMNIST	
对比方法	NIID-1	NIID-2	NIID-1	NIID-2	NIID-1	NIID-2	NIID-1	NIID-2
Local	33.33	58.23	58.17	48.35	48.33	37.61	37.59	
FedAvg	36.19	51.76	51.73	64.00	64.39	59.76	59.67	
FedProx	36.86	74.59	74.58	64.31	64.30	65.73	65.71	
FedDyn	48.53	78.01	79.53	81.82	83.22	66.45	68.00	
FedNova	47.13	53.46	51.76	68.25	64.41	61.49	59.77	
SCAFFOLD	46.13	74.66	74.55	64.50	64.48	65.77	65.96	
MOON	34.06	74.58	74.63	64.30	64.30	65.82	64.75	
FedDC	47.13	78.19	78.61	82.83	82.43	67.97	68.06	
FedCon	56.62	81.49	81.99	84.71	86.03	69.27	70.57	

为了进一步评估 FedCon 的扩展性和鲁棒性,在 FMNIST 数据集上进行了大规模客户端实验,客户端数量分别增加至 50、100 和 200 个,并在 NIID-1 和 NIID-2 数据划分场景下进行了测试。实验结果如

表 3.3 所示,表明即使在客户端数量显著增加的情况下,FedCon 仍能保持优异的性能。实验结果显示,FedCon 在大规模客户端设置下依然保持了高性能。无论是 NIID-1 还是 NIID-2 划分下,FedCon 均表现出色,证明了其在小规模实

验中的有效性能够很好的扩展到大规模场景中。

表 3.3 客户端设置为 50、100、200 时与基线方法的准确度对比

客户端数量	50 个		100 个		200 个	
对比方法	NIID-1	NIID-2	NIID-1	NIID-2	NIID-1	NIID-2
Local	81.46	82.19	78.32	79.14	76.33	77.58
FedAvg	82.31	84.58	79.45	81.31	77.32	79.84
FedProx	83.28	85.26	80.09	82.52	78.15	80.26
FedDyn	83.65	85.81	80.67	82.89	78.30	80.63
FedNova	84.12	84.71	81.23	81.75	79.01	79.55
SCAFFOLD	86.05	75.48	82.15	72.63	80.19	70.24
MOON	83.19	85.85	80.89	82.91	78.36	80.81
FedDC	85.74	85.72	82.74	82.68	89.42	80.97
FedCon	88.46	90.29	83.81	87.25	81.63	86.05

为了验证 FedCon 的收敛性能，在 CIFAR10 和 CIFAR100 数据集上进行了 100 轮全局模型训练，分别测试了 Homo，NIID-1，NIID-2 三种数据划分场景下的收敛表现。Homo 表示客户端的数据是均匀独立同分布的，在 CIFAR10-Homo 和 CIFAR100-Homo 场景下，FedCon 的收敛速度显著优于其他基线方法，且收敛过程更加平稳，说明在独立同分布数据场景下，FedCon 性能依然有优势，收敛曲线如图 3.3 所示。FedCon 在 CIFAR10，CIFAR100 数据集上进行了 NIID-1 和 NIID-2 两种数据划分，在 HAR 和 HAM10000 数据集上进行 NIID-1 一种数据划分，收敛曲线如图 3.4 所示。同时在 OrganAMNIST、OrganCMNIST 和 OrganSMNIST 数据集上进行 NIID-1 和 NIID-2 数据划分，收敛曲线见图 3.5。




图 3.3 CIFAR10 和 CIFAR100 在 Homo 设置下模型准确率对比




图 3.4 CIFAR10, CIFAR100 在 NIID-1 和 NIID-2 设置下模型准确率对比;
HAR 和 HAM10000 在 NIID-1 设置下模型准确率对比




图 3.5 OrganAMNIST, OrganCMNIST, OrganSMNIST 在 NIID-1 和 NIID-2 设置下模型准确率对比

3.4.3 框架稳定性评估

本研究采用均方根误差 (RMSE) ^[77] 量化模型训练过程中的参数更新波动, 其值越低表明更新轨迹越平稳。RMSE 通过计算相邻迭代轮次间模型权重的差异幅度, 直接反映收敛过程的震荡程度, 尤其适用于评估联邦学习中因非独立同分布数据导致的客户端参数偏移问题, 实验结果如图 3.6 所示。




图 3.6 CIAFR10, CIFAR100, HAM1000, HAR 在模型训练过程中的 RMSE

FedCon 在 CIFAR10 和 CIFAR100 等标准数据集上的 RMSE 较基线方法降低 12.3%-18.7%，验证了其基础场景下的稳定收敛能力。在 HAM10000 和 HAR 复杂异构场景中，基线方法因数据分布不均衡导致的模型更新出现显著波动，

RMSE 峰值达 FedCon 的 2.1 倍, FedCon 的动态权重调整机制充分考虑了历史权重的影响, 有效抑制了异常更新, 在历史权重的约束下, 通过加权平均保留前序轮次的有效信息, 减少单轮异质数据引起的突变; 动态衰减系数 α 参数平衡历史与实时更新的贡献权重, 有着更加显著的异构适应性, 在 HAM10000 高度不平衡数据中, FedCon 可以将方差平均降低 37%, 显著提升模型鲁棒性。

3.4.4 框架通信开销分析

在联邦学习中, 通信效率直接影响算法的实际部署可行性。针对非独立同分布数据场景下通信与计算资源受限的挑战, 本研究从单轮通信耗时(模型上传/下载时间)与完整迭代周期耗时(包含本地训练与聚合)两个维度, 系统性评估 FedCon 的优化能力。实验结果如图 3.7 和图 3.8 所示。




图 3.7 OrganSMNIST 在 NIID-1 设置下通信时间, 整轮时间以及准确性比较




图 3.8 OrganSMNIST 在 NIID-2 设置下通信时间, 整轮时间以及准确性比较

在 OrganSMNIST 数据集上进行 NIID-1 和 NIID-2 两种数据划分, FedCon 单轮通信耗时较 MOON 降低 32.6%, 但略高于 FedAvg, 其增量主要源于服务器贡献评估模块的计算开销, 但该模块显著提升了模型更新质量, 因此该通信时间是

可以接受的。得益于轻量化客户端设计与高效聚合策略，FedCon 单轮总耗时较 FedProx 和 MOON 分别减少 19.8%与 26.3%。尽管 FedCon 的通信耗时非最优，但其在 NIID-2 场景下精度较 FedAvg 提升 7.2%，且周期耗时仅仅增加 12.1%，验证了有限开销换取显著性能增益的设计合理性。

FedCon 框架将计算密集的贡献评估任务集中于服务器端，客户端仅需执行轻量级本地训练，精细化资源分配于通信计算协同优化，在异构场景下实现了优于基线方法的效率-精度均衡。实验结果表明，单轮周期耗时与 MOON 相比减少 26.3%的同时，分类精度提升 9.8%，为资源敏感场景提供了高效解决方案。

3.4.5 超参数灵敏性分析

联邦学习算法的性能依赖于关键超参数的合理配置。为了探究 FedCon 中贡献敏感度系数 λ 与历史权重衰减系数 α 的协同作用机制，本节基于 CIFAR10 数据集 NIID-1 和 NIID-2 划分设计消融实验，通过系统调整参数组合 $\lambda \in [0.3, 0.8]$ ， $\alpha \in [0.2, 0.6]$ 分析其对模型性能的影响。实验结果如图 3.9 和图 3.10 所示，当 λ 取值于 $[0.5, 0.7]$ 、 α 取值于 $[0.3, 0.4]$ 时，FedCon 框架的模型精度达到最佳。

在此基础上，进一步分析超参数的作用机制。对于贡献敏感度系数 λ ，实验发现其在筛选噪声更新与保留有效信息间动态权衡：当 λ 低于 0.5 时，客户端贡献评估不足，导致 NIID-2 场景下噪声数据干扰使精度下降；而 λ 高于 0.7 时，过度排斥边缘客户端更新，NIID-1 实验中收敛速度会下降。对于历史权重系数 α ，其控制着模型对历史记忆的依赖程度， α 低于 0.3 时，历史信息快速丢失，训练初期参数震荡幅度较高， α 高于 0.4 时，历史权重压制实时更新，NIID-2 后期收敛速度下降。二者的协同优化表明， $\lambda = 0.63$ 和 $\alpha = 0.37$ 的组合可通过动态平衡机制使关键特征层权重稳定性大幅提升。实验结论为 FedCon 的工程部署提供重要指导。实验结果表明 λ 设定于区间上限 (0.6-0.65) 以增强噪声鲁棒性， α 可固定为 0.37 以维持长期特征记忆。该参数配置显著降低算法优化复杂度，实验揭示了联邦学习中贡献评估与历史记忆的耦合规律。




图 3.9 NIID-1 设置下超参数灵敏性分析




图 3.10 NIID-2 设置下超参数灵敏性分析

3.4.6 消融实验

为验证 FedCon 核心组件的有效性，本研究通过控制变量法对其中两个关键模块-初始化权重计算模块（Part A）和客户端贡献评估模块（Part B，含 Shapley 值计算与动态调整机制）进行独立作用分析。实验设置了四组对比配置：移除 Part A 的 FedCon-without-A，移除 Part B 的 FedCon-without-B、完整的 FedCon 和基线方法对比试验。实验结果如图 3.11 所示，完整的 FedCon 效果突出，验证了双模块协同设计的必要性，其中初始化权重对模型提升效果显著。

进一步分析各模块的作用机制发现，初始化权重计算模块对模型收敛初期的稳定性具有决定性影响，为模型提供稳定的初始收敛方向，加快收敛速度，贡献

评估模块通过 Shapley 值与余弦相似度的联合评估，在训练中后期精确计算客户端的贡献对识别高价值更新，两模块在不同场景中呈现互补性，双模块的设计实现了全局引导与局部优化的高效协同，同时，模块化设计也解决了传统联邦学习算法中在异构数据下的稳定性与效率提升之间的矛盾，为实际部署中模块化组件的灵活配置也提供了理论依据。




图 3.11 初始化权重和贡献评估模块的对模型精确度影响

3.5 结论

本文提出了 FedCon 框架，一种全新的基于 Shapley 值精确用户贡献动态调整聚合权重的联邦学习框架，显著提升了异构数据环境下的模型精度和收敛稳定性，尤其在非独立同分布场景下。FedCon 通过蒙特卡洛采样减小传统 Shapley 值计算所需的采样集合，利用余弦相似性调整因采样集合减小带来的计算偏差并结合客户端历史权重实现快速收敛与稳定更新，提升了全局模型的准确度。未来工作将聚焦于提升通信效率和模型的安全聚合，并扩展至大规模联邦学习场景，针对联邦学习中的拜占庭攻击，需进一步研究低通信开销的安全聚合机制，结合区块链和密码学技术增强系统安全性，提升 FedCon 的安全性和可扩展性。

第4章 基于委员会与区块链的安全联邦框架

在第三章中提出的 FedCon 框架创新性的优化了联邦学习中的聚合过程，在非独立同分布数据场景下，可以得到高性能的全局模型。然而，一个良好的联邦学习框架，除了需要得到准确率高的全局模型，聚合过程中的数据安全也要得到保证。去中心化联邦学习逐渐成为一种重要的研究方向，与传统的集中式联邦学习方法不同^[78]，去中心化方案通过消除中心服务器，避免单点故障和数据隐私泄露的风险。去中心化联邦学习仍然面临着一系列的安全挑战，特别是在处理拜占庭攻击^[35]（Byzantine Attack）和恶意客户端方面。在去中心化环境中，由于缺乏集中控制，部分恶意客户端或不可靠的节点可能会对全局模型的聚合过程产生干扰，通过伪造更新或修改聚合结果来破坏全局模型的准确性。这类攻击不仅影响模型性能，还可能威胁到整个系统的安全性和稳定性。因此，如何确保去中心化联邦学习中的模型聚合过程不受恶意攻击的影响，在保证安全聚合的同时降低系统的通信开销和安全验证的计算成本是当前研究中的一大难题。为了解决这个问题，本章提出了一种基于委员会与区块链的安全联邦框架 SCDFL (Secure Committee-based Decentralized Federated Learning)，通过引入多项式承诺技术和加密技术，确保了模型聚合过程的安全性。本章设计了一种可信委员会机制，有效防御拜占庭攻击，并通过区块链技术确保数据的可验证性和不可篡改性。SCDFL 不仅提升了去中心化联邦学习系统的容错能力，还保证了在恶意节点存在的情况下，全局模型的聚合结果依然能够保持准确，同时大大降低了通信开销和计算成本。

4.1 引言

联邦学习作为一种分布式协同学习范式，允许客户端在保护数据隐私的前提下共同训练模型。然而，集中式联邦学习存在着显著的安全隐患，例如中央服务器被攻击时可能引发的梯度反转^[79]或恶意模型聚合问题，严重影响模型更新的正确性。为了解决这些问题，研究者提出了多种去中心化联邦学习方案，其中基于区块链的去中心化联邦学习因其透明性和安全性受到广泛关注。现有的基于委

员会的聚合机制仍面临恶意聚合问题,尤其是当超过一般的委员会成员不诚实时,恶意更新可能被纳入聚合过程,导致全局模型准确性下降。

现有的基于委员会的聚合机制在提高区块链操作效率方面相较于其他的安全聚合机制表现良好^[80],但是其安全性依赖于委员会成员的诚实性。当委员会成员被攻击时,恶意聚合问题显著存在。例如,恶意成员可能伪造本地梯度或篡改聚合结果,从而破坏全局模型的训练过程。除此之外,现有的去中心化联邦学习方法计算开销比较大,对系统的通信带宽要求较高。例如,传统的加密验证方法(如零知识证明)^[40]虽然安全性较高,其计算复杂度和通信成本较高,难以在大规模分布式场景中应用。

本节定义了去中心化联邦学习场景下的潜在威胁与假设,以及如何解决出现的问题。

研究问题 1: 在传统的联邦学习中,客户端将本地训练的模型梯度以明文的形式上传至服务器,这种方式容易受到攻击或者会被恶意客户端根据明文梯度反推其余客户端的原始数据,造成隐私泄露。在去中心化联邦学习场景中,客户端作为委员会成员,需要将模型梯度进行加密上传至区块链中更新全局模型,在这个过程中,上传的模型也会被攻击者获取,攻击者也可以根据明文模型梯度信息反向推导出其余客户端的敏感数据。

解决 1: 由于客户端上传模型容易被获取,因此需要进行加密保证信息传递的保密性。当前存在的模型梯度反转攻击,本节设计对模型梯度进行加密验证,对客户端的模型梯度进行对称加密,并且该加密方法不会造成梯度缺失,保证了全局模型的准确性。

研究问题 2: 在去中心化联邦学习中,委员会成员也不全是可靠的诚实的,攻击者可能在前期伪装参与训练。为了安全可靠的得到一个泛化能力强的全局模型,需要所有成员诚实的参与,并且正确的聚合成员上传的本地模型梯度。如果委员会成员在某些训练轮次为了恶意聚合成员的本地梯度,会对全局模型造成威胁,降低全局模型的准确度。

解决 2: 上述的关键问题在于无法保证委员会成员是否诚实可信,但是我们可以在聚合模型之间验证,通过利用多项式承诺技术和智能合约的特性来保证全局模型的正确性,同时相对传统验证方法,降低了通信开销。

在本文中,提出了一种基于委员会与区块链的安全可验证去中心化联邦框架 SCDFL。该框架利用委员会聚合模型,并通过多项式验证方法确保聚合模型的正确性。区块链系统也被用来促进过程的透明性并存储验证证据。本节采用多项式承诺技术构建验证方法。首先,可信的执行机构(TEA)生成公钥/私钥对用于加密和验证。然后,每个参与者使用多项式承诺协议构建聚合验证证明,该证明可以被参与者高效生成和验证。参与者将生成的证明上传到区块链,智能合约执行验证过程并将验证结果保存在区块链上。SCDFL 还采用了 AES 对称加密算法来加密本地梯度,确保安全聚合。与 VeriFL^[81]和 VerifyNet^[82]两种现有验证机制相比,SCDFL 显著降低了计算和通信成本。

本章的主要贡献如下:

1. 本章提出了 SCDFL 框架,这是一种通过基于委员会的区块链实现安全且可验证的去中心化联邦学习方案,旨在去中心化联邦学习场景中实现高效、安全且高准确率的聚合模型。

2. 本章提出了一种基于多项式承诺协议的高效可验证方法,以抵御去中心化联邦学习委员会机制中的攻击。和传统的在去中心化场景中抵御拜占庭攻击的方法不同,本节提出的验证方法提高了去中心化联邦学习的容错能力,并且在 SCDFL 方案中实现了可信的委员会机制,确保了参与者聚合模型时计算的正确性。

3. 本章提出的 SCDFL 通过梯度加密和多项式承诺验证提供安全聚合,从而保护客户端上传本地模型的梯度的隐私。大量的实验表明,本章设计的方案在数据隐私保护和聚合结果正确性方面是安全的,本方案保证了全局模型的安全聚合,系统需要的的计算成本和通信开销是最少的。

4.2 安全性与去中心化研究

本节主要从两个方面介绍,其中包括针对联邦学习中存在的客户端在模型聚合时对模型梯度加入噪声造成全局模型的恶意更新的验证方法的讨论,和基于区块链的去中心化的联邦学习。

在联邦学习中,模型更新的可验证方法是一个重要的研究方向,旨在检测和防止恶意客户端上传为证或有害的模型更新,从而保证全局模型的安全性和可靠

性。客户端可能在模型聚合时对梯度加入噪声,导致全局模型的恶意更新,针对这一问题,研究者提出了多种验证方法。例如 Guo^[81]等人提出了一种基于同态加密的梯度验证方法,通过加密技术确保梯度的完整性和隐私性。然后这种方法计算开销较大,难以在大规模分布式场景中应用。Xu^[82]等人提出了一种基于零知识证明的验证方法,能够在不泄露梯度信息的情况下验证其正确性,尽管安全性有提升,但是其计算复杂度和通信成本限制了实际应用。近年来,多项式承诺协议因其高效性和可验证性受到关注,Zhang^[83]等人提出了一种基于多项式承诺的梯度验证方法,显著降低了计算和通信开销。

基于区块链的去中心化联邦学习通过分布式账本技术提高系统的透明性和安全性,成为解决集中式联邦学习安全漏洞的重要研究方向。Fu^[84]等人提出了一种基于区块链的去中心化联邦学习框架,利用区块链记录模型更新过程,确保数据的不可篡改性。Peng^[85]等人提出了一种基于委员会的聚合机制,通过选举可信节点进行模型聚合,提高了区块链操作的效率。然而,当委员会成员不诚实时,恶意聚合问题仍然存在。Su^[86]等人提出了一种基于信誉的委员会共识算法,通过信用值选举委员会成员,提升了系统的安全性。

现有研究在联邦学习的验证方法和去中心化架构方面取得了显著进展,但仍然存在一些问题,验证方法的计算开销较大,难以满足大规模分布式场景的需求,基于区块链的去中心化联邦学习在委员会成员不诚实的情况下,仍面临恶意聚合的挑战,现有方案的安全性和效率之间仍然有优化空间。针对这些问题和现有方法的启发,本文提出一种基于委员会与区块链的安全聚合框架,通过结合多项式承诺协议和区块链技术,提供了一种高效、安全和低通信开销的解决方案。

4.3 SCDFL 框架

SCDFL 系统架构由五个核心实体组成:可信执行机构(TEA)、数据持有者(DH)、区块链(BC)、聚合委员会(AC)、智能合约(SC),SCDFL 系统架构如图 4.1 所示,各个实体的定义如下:

可信执行机构(Trusted Execution Authority, TEA): TEA 是一个可信的第三方机构,负责为数据的持有者和智能合约生成并分发安全参数,包括加密所需的公钥/私钥对和可信设置所需的陷门信息。TEA 的职责是确保整个系统的初始

化和运行环境的安全性。

数据持有者（Data Holder）：数据持有者就是传统联邦学习中的参与训练的客户端集合，他们持有本地数据，但是单个客户端持有的数据不足以独立训练出高性能的模型。为了实现得到高泛化能力满足自身需要的全局模型的目标，数据持有者愿意进行联合建模，共同参与联邦学习任务。

区块链（BlockChain）：在去中心化的联邦学习框架中，区块链负责协调所有客户端的模型更新过程，并验证聚合结果的正确性能。除此之外，智能合约会将所有的计算过程和结果全部加载到区块链上面进行记录。

聚合委员会（Aggregation Committee）：聚合委员会机制的主要职责是从客户端集合中随机选出委员会中的成员，随机性保证了选择的公平性。并且负责聚合全局模型，保证整个系统实现去中心化。

智能合约（Smart Contract）：联合建模成功的关键在于联邦学习中聚合结果的正确性。基于区块链的智能合约具备天然的安全特性，能够确保由多项式承诺技术生成的证明是安全可靠的。




图 4.1 SCDFL 框架架构

可信执行机构（TEA）首先为每个数据的持有者生成公钥/私钥对以及验证私钥。TEA 将私钥分发给各个客户端，并将验证私钥写入到区块链中的智能合约中，确保后续验证过程的安全性。客户端之间协商生成加密密钥，并使用该密钥对本地模型的梯度进行加密。同时，客户端利用验证加密密钥为加密梯度生成聚

合验证证明 (Aggregate Verification Proof, AVP)。每个客户端将加密后的梯度以及对应的聚合验证证明上传至区块链进行保存。聚合委员会从客户端集合中随机挑选若干成员,确保选择的公平性。委员会成员通过内部竞争下选择出领导者,负责协调后续的梯度聚合任务。该领导者从区块链中获取所有加密后的梯度,并且通过将密文梯度聚合出全局模型,委员会将新的全局模型分发至区块链。智能合约通过聚合所有的客户端上传的 AVP 验证聚合结果的正确性。如果计算正确验证通过,更新后的全局模型被视为有效模型并且用于下一轮训练,如果计算错误验证未通过,客户端将拒绝此次模型更新,区块链会将相关记录存储在区块中。

本节中所使用的相关参数符号列于表 4.1 中。

表 4.1 符号及含义

符号表示	描述
k, K	客户端编号以及总数
g	群 $\mathbb{G}$ 的生成元
$\mathbb{C}$	所有客户端 $\{C_1 C_2 C_3 \dots C_K\}^{[18]}$ 的集合
C_k	第 k 个客户端
$\mathbb{C}_{offline}$	签名无效的客户端集合
$\mathbb{C}_{online}$	签名有效的客户端集合
r_k	客户端 C_k 生成的随机数
$\hat{g}_{k,n}$	参与者 C_k 的第 n 个梯度
p_i^{SK}, p_i^{PK}	客户端 C_k 的密钥对
λ	安全参数
s_k	客户端 C_k 的多项式承诺技术私钥
v_k	客户端 C_k 的多项式承诺技术公钥
$\tau^i \mathcal{G}$	每个梯度 $\hat{g}_{k,n}$ 的多项式承诺公钥
$s_{k,j}$	参与者 C_k 和参与者 C_j 之间的共享密钥 (通过 DH 协议生成)
K_k	通过 DH 协议协商的对称密钥
$Enc_{g(k,n)}$	梯度 $g_{k,n}$ 的 AES 加密结果,使用共享密钥 K_k
$H(\hat{g}_{k,n})$	梯度 $g_{k,n}$ 的完整性哈希值,使用 MD5
P_k	客户端 C_k 的梯度多项式
AVP_k	每个客户端 C_k 的聚合验证证明
G	聚合的梯度矩阵
$\hat{G}$	待验证的全局梯度,聚合梯度 G 的待验证值
π	生成的聚合的梯度正确性证明
$H(\cdot)$	MD5 哈希函数
$\sigma_{k,j}$	客户端 C_k 和客户端 C_j 的秘密共享份额

4.3.1 工作流程

在本系统中，设计了一种基于委员会与区块链的安全联邦框架。该框架利用 AES 对称加密技术和委员会机制实现安全聚合，结合多项式承诺技术通过智能合约验证聚合结果的正确性。此外，区块链技术能够有效防范对贡献数据的篡改攻击，并且存储相关证明。假设系统中共有 N 个参与者，他们通过利用各自的本地数据和区块链系统协作完成学习任务，具体工作流程如图 4.2 所示。




图 4.2 框架工作流程

系统初始化与客户端注册：首先每个客户端 C_k 注册成为区块链的成员，并且被分配唯一的表示符号 ID_k 。可信执行机构 TEA 为每个客户端生成安全参数 λ ，包括公钥/私钥对 (p_i^{SK}, p_i^{PK}) ，并且将信息分发给客户端。

本地模型训练与梯度生成：每个客户端 C_k 使用本地数据训练模型，并生成梯度向量 $\hat{g}_{k,n}$ ，其中 n 表示第 n 个客户端，客户端将公钥 p_i^{SK} 上传至区块链中。

梯度加密与哈希处理：每个客户端 C_k 使用 DH 密钥交换协议共享密钥 K_k ，使用 AES 加密梯度，生成加密梯度 $Enc_{g(k,n)}$ ，计算梯度哈希 $H(\hat{g}_{k,n})$ 作为完整性验证值。同时为了支持后续的结果验证，每个客户端 C_k 使用多项式承诺技术为梯度生成聚合验证证明 AVP_k 。

数据上传至区块链：每个客户端 C_k 将加密梯度 $Enc_{g(k,n)}$ 和聚合验证证明 V_k 上传至区块链中保存。

委员会成员选择与领导者选举：委员会从客户端中随机选择若干成员，并通内部竞争选举出一名领导者，领导者负责从区块链中获取所有加密梯度 $Enc_{g(k,n)}$ 并解密，之后执行聚合操作。

全局梯度聚合：领导者将加密梯度 $Enc_{g_{(k,n)}}$ 聚合为全局梯度矩阵 G 。如果所有的客户端都在线，委员会需要将更新后的全局模型直接下发，否则，未通过验证，则全局模型无法下发。

区块生成与上传：委员会将更新后的全局模型打包成一个新的区块，并将其上传至区块链中。

智能合约验证：智能合约通过聚合所有客户端的聚合验证证明 AVP_k 生成验证证明 π 。基于证明 π ，智能合约验证委员会聚合结果 G 的正确性。如果验证通过，更新后的全局模型是有效的，并且可以用于下一轮次的训练，否则，客户端将拒绝该模型更新。整个流程包含三个阶段，初始化阶段，聚合阶段，验证阶段。具体流程见算法 4.1：

算法 4.1：SCDFL 框架

- 1: 初始化阶段:
 - 3: 客户端 C_k 注册成为区块链成员，生成唯一 ID_k
 - 4: 密钥分发与共享密钥生成:
 - 5: TEA 为每个客户端 C_k 生成公私钥对 (p_i^{SK}, p_i^{PK})
 - 6: DH 协商对称密钥
 - 7: 客户端 C_k 选择通过 DH 协议与他客户端协商生成共享密钥 K_k
 - 8: TEA 为客户端 C_k 生成随机数 r_k 将其作为秘密值
 - 9: 将 r_k 拆分为 K 个份额，并将份额 $\sigma_{k,j}$ 分发给客户端 C_j
 - 10: 每个客户端 C_k 会保存其他客户端的秘密共享份额 $\sigma_{j,k}$
 - 11: 智能合约部署: $SmartContract \leftarrow Deploy(\lambda, C)$
 - 12: 聚合阶段:
 - 13: 客户端 C_k 使用 AES 对称加密，MD5 哈希计算完整性校验
 - 14: 计算多项式承诺公钥: $\tau^i G = g^{P_k}$
 - 15: 计算聚合验证证明 AVP_k : $AVP_k = Commit(\hat{g}_{k,n}, s_k)$
 - 16: 客户端 C_k 向区块链提交加密梯度，哈希验证和 AVP_k
 - 17: 随机选择委员会成员及领导者
 - 18: 领导者从区块链中获取加密梯度 $Enc_{g_{(k,n)}}$
 - 19: 对于离线客户端 $C_j \in \mathbb{C}_{offline}$ ，领导者从在线客户端收集秘密共享份额
 - 20: 领导者使用 t 个秘密共享份额恢复随机数 r_k
 - 21: 使用恢复的随机数解密离线客户端的梯度
 - 22: 委员会对梯度解密 $\hat{g}_{j,n} = AES^{-1}(\hat{g}_{k,n}, K_k)$
 - 23: 执行聚合 $G = \sum_{k=1}^K \hat{g}_{k,n}, N = \sum_{k=1}^K |\hat{g}_{k,n}|$
 - 24: 验证阶段:
 - 25: 获取聚合结果 $(G, \hat{G})$
 - 26: 计算验证证明 π ，检查是否满足验证条件。满足接受聚合结果，否则拒绝。
-

4.3.2 初始化阶段

本阶段在客户端将密文梯度上传至区块链之前完成,包括系统初始化、本地模型训练、梯度加密与哈希处理、以及聚合验证证明 AVP_k 生成四个步骤。

系统初始化时可信执行机构 TEA 对每个客户端 C_k 生成用于数字签名的密钥对 (p_i^{SK}, p_i^{PK}) 以及多项式承诺的私钥 s_k 和公钥 v_k 。将公钥 p_i^{PK} 和 v_k 分发给客户端 C_k ,私钥 p_i^{SK} 和 s_k 由客户端自行保存。将初始化模型 θ_0 、学习率 η 、损失函数 $\mathcal{L}$ 和安全伪随机生成器 PRG 等公共参数存储在区块链的起始块中,为后续的本地模型训练和梯度加密提供基础支持。

秘密共享初始化, TEA 为每个客户端 C_k 生成一个随机数 r_k 作为秘密值,使用 Shamir 秘密共享协议,将秘密值 r_k 分成 K 个份额 $\sigma_{k,1}, \sigma_{k,2}, \dots, \sigma_{k,K}$,将每个份额 $\sigma_{k,j}$ 分发给客户端 C_j ,而每个客户端 C_k 都会保存其他客户端的秘密共享份额 $\sigma_{j,k}$ 。

在每次迭代中,客户端 C_k 使用本地数据 $\mathcal{D}_k$ 和训练模型 θ_0 ,并计算更新后的本地梯度向量 $\hat{g}_{k,n}$ 。然后客户端 C_k 使用对称加密算法 AES 通过 DH 协议生成的共享密钥 K_k 加密梯度:

$$Enc(\hat{g}_{k,n}) = AES(\hat{g}_{k,n}, K_k) \dots\dots\dots (4.1)$$

使用 MD5 哈希函数对梯度向量进行哈希处理,用于数据完整性校验:

$$H(\hat{g}_{k,n}) = MD5(\hat{g}_{k,n} || r_k) \dots\dots\dots (4.2)$$

其中 r_k 是可信执行机构 TEA 为客户端 C_k 生成的安全随机数, $||$ 表示字符串连接。随机数的存在可以有效防止哈希碰撞攻击,使得攻击者很难伪造梯度。

在完成哈希处理后,客户端 C_k 使用 TEA 生成的私钥 p_i^{SK} 对哈希值进行数字签名,随后客户端 C_k 将加密梯度 $Enc(\hat{g}_{k,n})$ 、哈希值 $H(\hat{g}_{k,n})$ 和数字签名一起上传到区块链。同时为了确保聚合结果的正确性,基于多项式承诺技术生成聚合验证证明。本文设计的承诺函数 Commit 基于多项式承诺技术,定义如下:

$$C = Commit(f(x), PK) = \prod_{i=0}^n (g^{\tau^i})^{a_i} = g^{\sum_{i=0}^n a_i \cdot \tau^i} = g^{f(\tau)} \dots\dots\dots (4.3)$$

其中, PK 是公钥元组, g^{τ^i} 来自公钥元组,确保数据机密性。

可信执行机构为每个客户端 C_k 生成可信的秘密密钥 s_k 和公钥元组 (v_k, p_i^{PK}) ,

并将公钥分发给客户端和区块链。客户端 C_k 在完成本地模型训练后,生成聚合验证证明 AVP_k :

$$AVP_k = \text{Commit}(\hat{g}_{k,n}, s_k) = g^{\hat{g}_{k,n} \cdot \tau} \dots \dots \dots (4.4)$$

其中, Commit 是多项式承诺函数, s_k 为多项式承诺技术私钥。

假设离散对数问题是困难的,客户端生成了聚合验证证明 AVP_k ,攻击者如果要伪造聚合结果 G' ,需要生成对应的伪造证明,在验证阶段进行验证,但是由于离散对数问题的困难性,攻击者无法从 $g^{G'}$ 中推导出 G' ,因此攻击者成功伪造聚合结果的概率可以忽略不计。

4.3.3 聚合阶段

在联邦学习过程中,委员会机制负责接受并验证客户端上传的密文梯度。首先,委员会通过验证梯度数据的数字签名来确认每个客户端的合法性。如果某个客户端未发送任何消息或签名无效,则该客户端会被标记为离线状态;否则,该客户端会被视为在线并且其上传的模型梯度数据是合法可用的。

委员会机制中,委员会检查每个客户端 C_k 的数字签名,如果 C_k 的签名无效或者未收到消息,则将其加入 $\mathbb{C}_{\text{offline}}$,否则,将其加入 $\mathbb{C}_{\text{online}}$ 。委员会从 $\mathbb{C}_{\text{online}}$ 中根据历史权重排序选择权重最大的作为领导者,负责协调梯度聚合过程。在线客户端 $C_k \in \mathbb{C}_{\text{online}}$ 需要将 $C_j \in \mathbb{C}_{\text{offline}}$ 的秘密共享份额 $\sigma_{j,k}$ 上传到区块链中,这些共享份额将用于恢复离线客户端的随机数 r_j 。领导者使用恢复的随机数 r_j 验证离线客户端的梯度完整性。恢复随机数 r_j 需要 t 个秘密共享份额:

$$r_j = \sum_{k \in S} \sigma_{j,k} \cdot \prod_{m \in S, m \neq k} \frac{m}{m-k} \dots \dots \dots (4.5)$$

其中, r_j 为需要恢复的随机数, S 是参与恢复的客户端集合。

领导者解密离线客户端的梯度数据 $\hat{g}_{j,n}$:

$$\hat{g}_{j,n} = \text{AES}^{-1}(\hat{g}_{k,n}, K_k) \dots \dots \dots (4.6)$$

其中, AES^{-1} 表示解密操作, K_k 为对称密钥。

领导者聚合所有的签名有效的客户端的梯度 $\hat{g}_{k,n}$ 以及恢复的签名失效的客户

端的梯度 $\hat{g}_{j,n}$:

$$G = \sum_{C_k \in \mathbb{C}_{online}} w_k \cdot \hat{g}_{k,n} + \sum_{C_j \in \mathbb{C}_{offline}} w_j \cdot \hat{g}_{j,n} \cdots \cdots \cdots (4.7)$$

其中 $\hat{g}_{k,n}$ 是在线的客户端梯度, $\hat{g}_{j,n}$ 是通过恢复的随机数 r_j 解密的客户端的梯度, w_k 是客户端 C_k 的聚合权重, w_j 是客户端 C_j 的聚合权重。

4.3.4 验证阶段

当区块链收到所有签名通过的客户端的聚合验证证明 AVP_k 后, 智能合约被出发以执行证明聚合和验证工作。

智能合约聚合所有客户端的聚合验证证明 AVP_k 来计算聚合的梯度证明 π :

$$\pi = \prod_{C_k \in \mathbb{C}_{online}} AVP_k \cdots \cdots \cdots (4.8)$$

其中, AVP_k 是客户端 C_k 的聚合验证证明, $\mathbb{C}_{online}$ 是签名有效且在线的客户端集合。

为了验证聚合结果的正确性, 智能合约执行多项式承诺技术, 智能合约确认所有参与聚合的梯度都是由委员会成员正确聚合:

$$e(\pi, g) \stackrel{?}{=} e(g^G, v_k) \cdots \cdots \cdots (4.9)$$

其中, e 是双线性配对函数, π 是聚合的梯度证明, g 是群 $\mathbb{G}$ 的生成元, $\stackrel{?}{=}$ 表示判断等式是否成立, 如果等式成立, 智能合约确认所有客户端的梯度都是由委员会正确聚合, 当聚合的梯度是有误的, 则中止聚合, 保证联邦学习中梯度聚合的正确性和安全性, 智能合约实现了高效的自动化验证。由于多项式承诺技术的不可逆性, 攻击者也无法从 π 中推导出客户端的原始梯度。

4.4 实验评估

在本节中, 实验评估 SCDFL 框架的性能。主要从模型性能, 计算成本, 通信成本, 区块链的 Gas 计算消耗进行评估。

4.4.1 实验设置

为了评估 SCDFL 框架的性能, 实验是在一台配备 Intel Core i5-12400K 处理

器、32.00 GB 内存和 NVIDIA GeForce RTX 3060 显卡的计算机上进行的。

数据集：实验中使用四个公开的数据集，包括 CIFAR10^[73]（10 类彩色图像，60000 样本），CIFAR100^[73]（100 类细粒度分类），MNIST^[87]（手写数字灰度图，70000 样本），FMNIST^[88]（服装分类，结构与 MNIST 一致）数据集。这些数据集覆盖从简单分类到复杂场景的多层次任务，兼具数据模态多样性与任务难度梯度，并且支持非独立同分布划分，可以有效模拟联邦学习中的异构数据环境。模型采用统一轻量架构：是由两层卷积层，三层全连接层的卷积神经网络。

基线方法：实验中对比的两种基线方法是 VeriFL^[81]和 VerifyNet^[82]，是两种针对联邦学习中模型验证和安全性问题提出的方法。VeriFL 是一种基于模型聚合验证的联邦学习框架，旨在确保参与方上传的模型更新是正确且未被篡改的。通过引入可信的第三方机构来验证每个参与方提交的模型更新，核心思想是通过对本地模型更新与全局模型的差异，检测是否存在恶意参与方试图通过上传有误的模型梯度更新来破坏全局模型的聚合。VerifyNet 则是一种基于零知识证明的联邦学习验证框架。它使用零知识技术允许客户端在不泄露本地数据的情况下，证明模型更新的正确性，确保客户端能够证明模型更新是基于合法的本地数据计算得出的，而无需透露具体的数据内容。

区块链网络的参数配置：区块链平台是以太坊（Ethereum），智能合约语言是 Solidity，区块生成频率 0.5 秒，区块的最大尺寸为 100MB。

模拟拜占庭攻击与梯度反转：在实验中，为了验证其对拜占庭攻击的鲁棒性，实验模拟了恶意客户端和委员会成员的行为，包括梯度反转攻击和噪声注入攻击。在每轮训练中，根据预设的攻击概率，随机选择部分客户端作为恶意节点，这些恶意节点在本地模型更新时，会对梯度进行反转或按照概率添加噪声，从而破坏全局模型的训练过程。在委员会聚合阶段，实验模拟了恶意委员会成员的行为，这些成员可能会篡改聚合结果或伪造聚合验证证明。实验设置客户端攻击概率为 0.2，委员会攻击概率为 0.1。

4.4.2 框架时间复杂度分析

本实验选择 VerifyNet 和 VeriFL 作为基线方法，是因为和 SCDFL 相比，三种方法在准备、聚合和验证三个阶段的计算成本和时间复杂度是不同的，有助于

全面评估计算效率 and 安全性。具体而言,准备阶段涉及聚合验证证明的生成,聚合阶段由委员会机制负责梯度聚合和全局模型更新,而验证阶段是由智能合约来验证计算结果的正确性。从理论分析,假设 N 为客户端数量, d 为每个客户端的模型梯度维度。

准备阶段: VerifyNet 依赖零知识证明机制进行数据完整性保护,计算开销较大,时间复杂度为 $O(Nd \log d)$; VeriFL 采用基于哈希的承诺方案,客户端需要计算哈希值并提交承诺,时间复杂度为 $O(Nd)$; SCDFL 采用 AES 对模型梯度加密,并生成多项式承诺,时间复杂度和 VeriFL 相近,为 $O(Nd)$ 。

聚合阶段: 该阶段复杂聚合客户端的模型梯度,并更新全局模型。VerifyNet 使用零知识证明进行可验证聚合,引入额外的计算和验证步骤,时间复杂度较高为 $O(Nd \log d)$; VeriFL 采用去中心化的哈希聚合方案,计算过程较为简单,时间复杂度为 $O(Nd)$; SCDFL 通过委员会机制进行模型梯度聚合,结合多项式承诺验证梯度正确性,时间复杂度为 $O(Nd)$ 。

验证阶段: 该阶段由区块链的智能合约执行,以验证聚合结果的正确性。VerifyNet 由于依赖 ZKP 进行链上验证,计算开销大,时间复杂度为 $O(N \log d)$; VeriFL 采用哈希承诺验证,智能合约执行哈希匹配,时间复杂度为 $O(N)$; 而 SCDFL 采用多项式承诺验证,智能合约只需执行轻量级运算,时间复杂度为 $O(N)$ 。三种方法的时间复杂度理论分析如表 4.2 所示。

表 4.2 时间复杂度分析

方法	准备阶段	聚合阶段	验证阶段
VerifyNet	$O(Nd \log d)$	$O(Nd \log d)$	$O(N \log d)$
VeriFL	$O(Nd)$	$O(Nd)$	$O(N)$
SCDFL	$O(Nd)$	$O(Nd)$	$O(N)$

4.4.3 框架准确性分析

为了验证 SCDFL 框架在模型准确性方面的表现,在四个数据集上 CIFAR10, CIFAR100, MNIST, FMNIST 进行实验,并于 FedAvg, VeriFL, VerifyNet 进行了对比。实验结果如表 4.3、图 4.3 所示,SCDFL 在大多数数据集上均取得了不错的表现。具体结果见下表。

表 4.3 SCDFL 与基线方法模型准确率比较

方法	CIFAR10	CIFAR100	MNIST	FMNIST
FedAvg	51.26	22.75	88.41	67.65
VeriFL	59.82	25.37	93.97	74.91
VerifyNet	60.73	25.15	92.68	77.37
SCDFL	62.17	38.22	91.64	80.46




图 4.3 CIFAR10, CIAFR100, MNIST, FMNIST 在 NIID-1 设置下模型准确率

在 CIFAR10 数据集上，SCDFL 的准确率为 62.17%，显著高于 FedAvg 的 51.26%，比另两种基线方法也高，主要原因是 SCDFL 通过多项式承诺技术生成聚合验证证明和秘密共享机制，有效保护了模型更新的安全性，避免了恶意攻击对模型准确性的影响。在 CIFAR100 数据集上，SCDFL 性能最优，在 MNIST 数据集上，SCDFL 准确性略低于 VeriFL 的 93.97%和 VerifyNet 的 92.68%，但仍然显著高于 FedAvg 的 88.41%，证明了 SCDFL 安全性在 MNIST 数据集上仍然是有着较强的竞争力。FedAvg 作为基线方法，未引入安全措施，在面对恶意攻击和数据分布不均时，准确性较低。SCDFL 通过对梯度进行加密，秘密共享和区

区块链技术,在保证安全性的同时,模型训练仍然有着较高的准确性,该实验证明了 SCDFL 在实际应用中的高效性和实用性。

4.4.4 框架计算成本分析

实验通过用计算时间成本来评估 SCDFL 框架和 VerifyNet 和 VeriFL 两种基线的计算开销。在联邦学习数据异构场景下,计算成本主要受参与者数量和梯度数量两个因素影响,每个客户端上传的梯度参数数量越高,模型越复杂,计算成本也更高。时间成本衡量了在不同参与者数量和通信梯度数量下,执行完整联邦学习训练任务所需时间成本。本实验通过在不同梯度数量下进行实验,可以评估系统是否能够在大规模模型或复杂任务中保持高效性。实验中不同数据集的模型是固定不变的,通过调整训练的批量大小控制每轮训练中的计算的梯度数量。实验中在四个数据集上进行,并采用第二章介绍的 NIID-1 进行数据分割,以模拟真实世界应用场景。在所有的实验中,固定以下参数:

表 4.4 实验参数设置

客户端数量	$N \in \{10, 50, 100, 200\}$
梯度数量范围	$D \in \{2000, 4000, 6000, 8000, 10000\}$
通信轮次	$R = 100$
计算设备	所有的实验环境相同

实验分别评估 SCDFL、VerifyNet 和 VeriFL 在准备阶段、聚合阶段和验证阶段的计算时间成本。通过大量实验,在相同设置下对比了 VerifyNet 和 VeriFL 和 SCDFL 在不同梯度数量下的时间成本差异。实验结果如图 4.4 和图 4.5 所示,SCDFL 的性能明显优于 VerifyNet 和 VeriFL。下面详细分析一下:

在初始化阶段,三种方案生成可验证标签的时间成本是不同的。VerifyNet 方案,为了进行后续验证,每个梯度需要进行两次调用同态哈希函数并生成辅助参数,其时间成本较高,且随着梯度数量的增加而显著增加。用公式可以表示为: $T = O(2n \cdot H + A)$, 其中 n 为梯度数量, H 为同态哈希函数的计算开销, A 为辅助参数生成的开销。对于 VeriFL 方案,每个梯度需要输入到同态哈希函数中,经过计算会输出一个验证标签,并且每个参与者都需要通过聚合所有参与者的验证标签来计算一个完整的聚合签名,其时间成本随着梯度数量和参与者数量的增加而增加,时间为 $T = O(n \cdot H + m \cdot S)$, 其中 m 为参与者数量, S 为聚合签名的计算开销,而 SCDFL 只需要通过简单的乘法和加法运算来计算多项式承诺生成聚合

验证证明AVP, SCDFL 和 VeriFL 时间成本相似, 显著低于 VerifyNet。

在聚合阶段, VerifyNet 方案需要聚合所有参与者的梯度, 还需要通过聚合所有参与者所有梯度的验证标签来生成聚合结果的证明, 时间成本表示为 $T = O(n \cdot m(H + P))$, 其中 P 为证明生成的开销, n 为梯度数量, H 为同态哈希函数的计算开销。VeriFL 方案只需要聚合所有梯度, 时间成本和 SCDFL 相近, 为 $T = O(n \cdot m)$ 。实验结果和理论分析表明, SCDFL 在时间成本方面具有显著优势, 尤其是在大规模联邦学习场景中, 其性能表现更为突出, SCDFL 通过多项式承诺技术和秘密共享协议结合, 在保证安全性的同时, 显著降低了计算和通信开销。

在验证阶段, VerifyNet 方案中每个聚合结果都需要通过计算代价高昂的双线性对和指数运算来进行验证, 其时间成本与梯度数量呈线性关系, 为 $T = O(n \cdot (B + E))$, 其中 B 为双线性对的计算开销, E 为指数运算的计算开销。VeriFL 方案中由于验证签名已经在准备阶段聚合了所有梯度验证标签, 因此在验证阶段, VeriFL 需要计算同态哈希函数的指数运算来进行验证, 通过乘法计算出所有参与者的验证签名, 时间成本会随着参与者数量的增加而增加。SCDFL 仅需要通过多项式承诺结合哈希计算和双线性对验证聚合结果, 时间成本与梯度数量呈线性关系, 和 VerifyNet 逐个验证梯度的方式不同, SCDFL 只需要一次整体验证, 其开销显著低于 VeriFL 和 VerifyNet, 当梯度数量不断增加时, 其验证成本会开始上升, 但是在可接受范围内, 仍然比 VeriFL 和 VerifyNet 低。




图 4.4 在 CIFAR10 和 CIFAR100 数据集上三个阶段运行时间比较




图 4.5 在 MNIST 和 FMNIST 数据集上三个阶段运行时间比较

4.4.5 框架通信成本分析

为了全面评估 SCDFL 框架的通信效率, 本小节在 CIFAR10 和 FMNIST 数据集上进行实验, 实验结果如图 4.6 所示, 分别从梯度数量与通信传输量、聚合阶段的通信传输量以及验证阶段的区块链 Gas 消耗量三个方面进行分析。因为在 SCDFL 框架中, 使用了智能合约来实现验证过程, 智能合约负责执行验证逻辑, 检查确认聚合结果是否符合预期。由于智能合约的运行需要消耗区块链的计算资源, 因此会产生 Gas 消耗。




图 4.6 SCDFL 与基线方法在 CIFAR10 和 FMNIST 数据集上通信成本比较
实验结果表明, SCDFL 的通信成本要低于 VerifyNet 和 VeriFL。VerifyNet 方

案中每个参与者需要向服务器发送掩码梯度和一组可验证标签,通信传输量随着梯度的增加线性增加,表示为 $C = O(n \cdot (G + V))$,其中 n 为梯度数量, G 为掩码梯度的大小, V 为可验证标签的大小。而对于 VeriFL 方案,还需要通过服务器与所有参与者共享密钥和承诺值,其通信传输量也随梯度数量线性增加,相比 VerifyNet 更低,通信传输量为 $C = O(n \cdot G + m \cdot (K + G))$,其中 m 为参与者数量, K 为密钥大小, C 是承诺值大小。而本章设计的 SCDFL 只需要发送哈希值,所以通信传输量是最低的。验证阶段只记录了 SCDFL 的 Gas 消耗量,证明了随着梯度数量的不断增加,Gas 的消耗也线性增加。在聚合阶段,实验结果表明,SCDFL 通过区块链上的智能合约验证聚合结果的正确性,无需向参与者发送任何信息,所以通信传输量基本为 0。而 VerifyNet 需要向参与者发送聚合签名和聚合结果,通信传输量随着梯度数量增加而增加,VeriFL 需要向参与者发送聚合结果,同样增加了通信开销。通过上述分析和实验结果证明,SCDFL 在通信成本方面具有显著优势。

4.5 结论

为了实现非独立同分布场景下联邦学习任务的安全聚合和隐私保护,去中心化联邦学习可以消除传统的集中式联邦学习方案中对服务器的依赖,能够有效降低单点故障的风险,增强系统的隐私保护能力。在非独立同分布数据场景下,去中心化联邦学习仍然面临着恶意委员会成员对聚合过程的操控、拜占庭攻击、梯度攻击,全局模型性能下降。本文提出的 SCDFL 框架通过引入委员会与区块链架构,通过智能合约对模型聚合过程进行验证,确保计算的安全透明,同时区块链的特性保证计算结果的不可篡改;通过多项式承诺技术构建验证机制,没有增加额外的计算开销,对模型聚合的正确性进行了高效验证;采用加密技术对本地梯度进行了保护,保证了梯度在传输过程中不可见,防止恶意成员通过梯度反转手段泄露数据。实验结果表明,SCDFL 在保证安全聚合的同时,降低了计算成本和通信开销,实现了在非独立同分布场景下的安全聚合,并且保证了模型性能。

第5章 总结与展望

5.1 工作总结

随着联邦学习的快速发展,其在保护数据隐私和打破数据孤岛方面的优势得到了广泛认可。然而,在实际应用中,尤其是在非独立同分布数据场景下,联邦学习仍然面临诸多挑战。由于数据异构性导致的局部模型可能无法有效提取全局数据特征,导致全局模型性能下降。其次,数据异构性使得模型训练更加复杂,导致模型收敛速度变慢甚至无法收敛。此外,传统的联邦学习方法在通信和计算开销方面效率较低,难以适应大规模分布式场景。更为重要的是,集中式联邦学习容易受到恶意攻击,例如梯度反转攻击、恶意聚合,同时数据隐私保护机制不足可能导致信息泄露。

为了解决上述问题,亟需一种新的联邦学习框架,能够在保证全局模型性能的同时,确保聚合过程的安全性和隐私性。这种框架不仅需要高效的聚合算法来提升模型训练效率,在有限的计算带宽上,还需强大的安全机制来防御恶意攻击和保护数据隐私。

本文的主要研究成果如下:

FedCon 框架: 本文针对非独立同分布数据场景,设计了一种基于 Shapley 值和余弦相似度矩阵的精确用户贡献,动态的调整聚合权重的联邦学习框架,公平且高效的评估客户端贡献,确保权重分配的合理性;动态调整模型相似性矩阵,增强聚合权重与模型质量之间的关联性;引入客户端历史权重的动态调整机制,提升模型的鲁棒性和稳定性。通过大量实验验证了框架在全局模型准确性、收敛性、稳定性、通信开销和可扩展性多方面的优越性。

SCDFL 框架: 非独立同分布场景下的联邦学习存在安全聚合问题,去中心化联邦学习消除了服务器的影响,在提升数据隐私和系统鲁棒性的同时,也面临拜占庭攻击、恶意节点干扰和模型篡改安全挑战,而且需要大量的通信开销保证系统的安全性。为了解决这些问题,本文设计了基于委员会与区块链的安全联邦框架,通过可信执行机构、参与者、区块链、聚合委员会和智能合约五部分组成,

实现安全可靠的模型聚合。通过结合多项式承诺技术、加密梯度聚合和随机委员会机制，有效抵御拜占庭攻击，提高联邦学习的安全聚合和实际部署可行性。实验结果表明，该框架能够在保障数据隐私和计算安全的同时，实现高效、可靠的去中心化模型聚合，和传统方法相比，显著降低了通信开销，提升了系统性能，为安全联邦学习提供可行方案。

5.2 未来展望

在本研究中，我们提出的 FedCon 和 SCDFL 框架在非独立同分布数据场景下针对模型性能，收敛速度，通信开销，安全聚合等方面取得了显著成果。但是仍有不足之处需要进一步的改善研究，未来的研究可以从以下几个方面展开：

自适应的动态聚合策略：当前 FedCon 框架基于 Shapley 值和相似度矩阵评估客户端贡献，但仍需进一步提升自适应性，未来可引入深度强化学习机制，使得系统能够自动调整聚合策略，提高联邦学习效率；针对不同计算能力的设备，异构设备自适应优化，优化模型更新频率和通信频率，以降低资源消耗。

提升模型聚合的效率与优化算法：SCDFL 依赖于加密计算和区块链存储，未来可以优化加密计算，探索更高效的同态加密、安全多方计算等隐私保护机制，减少加密梯度计算的时间成本；同时可以结合链下计算或分层存储，改进区块链存储方案，降低链上数据存储的压力，提高整体计算效率。

增强系统安全性和抗攻击能力：SCDFL 框架能够有效抵御拜占庭攻击、模型篡改和恶意梯度干扰，但是仍然存在一些安全挑战，未来可结合对抗性训练，构建对抗性模型检测机制，提升系统鲁棒性；研究更加强大的异常检测和贡献惩罚机制，防止低质量或恶意数据对模型训练的影响。

参考文献

- [1] SARMA K V, HARMON S, SANFORD T, et al. Federated learning improves site performance in multicenter deep learning without data sharing[J]. Journal of the American Medical Informatics Association, 2021, 28 (6): 1259-1264.
- [2] LI Q, WEN Z, WU Z, et al. A survey on federated learning systems: Vision, hype and reality for data privacy and protection[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 35 (4): 3347-3366.
- [3] 周传鑫, 孙奕, 汪德刚, 等. 联邦学习研究综述[J]. 网络与信息安全学报, 2021, 7 (5): 77-92.
- [4] 阳文斯. 基于联邦学习的信用卡欺诈检测系统研究[D]. 中国科学院大学(中国科学院深圳先进技术研究院), 2020.
- [5] 崔东浩, 张华亮. 基于联邦学习的社区数字化学习数据挖掘研究[J], 2023.
- [6] BELTRÁN E T M, PÉREZ M Q, SÁNCHEZ P M S, et al. Decentralized federated learning: Fundamentals, state of the art, frameworks, trends, and challenges[J]. IEEE Communications Surveys & Tutorials, 2023, 25 (4): 2983-3013.
- [7] HUANG C, HUANG J, LIU X. Cross-silo federated learning: Challenges and opportunities[J]. arXiv preprint arXiv:2206.12949, 2022.
- [8] XU J, WANG H. Client selection and bandwidth allocation in wireless federated learning networks: A long-term perspective[J]. IEEE Transactions on Wireless Communications, 2020, 20 (2): 1188-1200.
- [9] KONEČNÝ J, MCMAHAN H B, YU F X, et al. Federated learning: Strategies for improving communication efficiency[J]. arXiv preprint arXiv:1610.05492, 2016.
- [10] TRUEX S, LIU L, CHOW K-H, et al. LDP-Fed: Federated learning with local differential privacy[C]//Proceedings of the third ACM international workshop on edge systems, analytics and networking, 2020: 61-66.
- [11] TRIASTCYN A, FALTINGS B. Federated learning with bayesian differential privacy[C]//2019 IEEE International Conference on Big Data (Big Data), 2019: 2587-2596.
- [12] YE M, FANG X, DU B, et al. Heterogeneous federated learning: State-of-the-art and research challenges[J]. ACM Computing Surveys, 2023, 56 (3): 1-44.
- [13] QU L, ZHOU Y, LIANG P P, et al. Rethinking architecture design for tackling data heterogeneity in federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 10061-10071.
- [14] LI T, HU S, BEIRAMI A, et al. Ditto: Fair and robust federated learning through personalization[C]//International conference on machine learning, 2021: 6357-6368.
- [15] KANG J, XIONG Z, NIYATO D, et al. Reliable federated learning for mobile networks[J]. IEEE Wireless Communications, 2020, 27 (2): 72-80.
- [16] LUO M, CHEN F, HU D, et al. No fear of heterogeneity: Classifier calibration for federated learning with non-iid data[J]. Advances in Neural Information

- Processing Systems,2021, 34: 5972-5984.
- [17] LI T, SAHU A K, ZAHEER M, et al.Federated optimization in heterogeneous networks[J].Proceedings of Machine learning and systems,2020, 2: 429-450.
 - [18] ACAR D A E, ZHAO Y, NAVARRO R M, et al.Federated learning based on dynamic regularization[J].arXiv preprint arXiv:2111.04263,2021.
 - [19] LI Q, HE B, SONG D. Model-contrastive federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition,2021: 10713-10722.
 - [20] LIN T, KONG L, STICH S U, et al.Ensemble distillation for robust model fusion in federated learning[J].Advances in neural information processing systems,2020, 33: 2351-2363.
 - [21] ZHANG L, SHEN L, DING L, et al. Fine-tuning global model via data-free knowledge distillation for non-iid federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition,2022: 10174-10183.
 - [22] CHEN H, ZHANG Y, KROMPASS D, et al. Feddat: An approach for foundation model finetuning in multi-modal heterogeneous federated learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence,2024: 11285-11293.
 - [23] WANG Y, LIN L, CHEN J. Communication-efficient adaptive federated learning[C]//International conference on machine learning,2022: 22802-22838.
 - [24] JIANG X, BORCEA C. Complement sparsification: Low-overhead model pruning for federated learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence,2023: 8087-8095.
 - [25] LIU R, CAO Y, YOSHIKAWA M, et al. FedSel: Federated sgd under local differential privacy with top-k dimension selection[C]//Database Systems for Advanced Applications: 25th International Conference, DASFAA 2020, Jeju, South Korea, September 24–27, 2020, Proceedings, Part I 25,2020: 485-501.
 - [26] AMIRI M M, GÜNDÜZ D.Federated learning over wireless fading channels[J].IEEE transactions on wireless communications,2020, 19 (5): 3546-3557.
 - [27] REGUIEG H, EL HANJRI M, EL KAMILI M, et al. A comparative evaluation of fedavg and per-fedavg algorithms for dirichlet distributed heterogeneous data[C]//2023 10th International Conference on Wireless Networks and Mobile Communications (WINCOM),2023: 1-6.
 - [28] NIELSEN C, TULADHAR A, FORKERT N D. Investigating the vulnerability of federated learning-based diabetic retinopathy grade classification to gradient inversion attacks[C]//International Workshop on Ophthalmic Medical Image Analysis,2022: 183-192.
 - [29] CHAI Z, CHEN Y, ANWAR A, et al. FedAT: A high-performance and communication-efficient federated learning system with asynchronous tiers[C]//Proceedings of the international conference for high performance computing, networking, storage and analysis,2021: 1-16.
 - [30] MA Q, XU Y, XU H, et al.FedSA: A semi-asynchronous federated learning

- mechanism in heterogeneous edge computing[J].IEEE Journal on Selected Areas in Communications,2021, 39 (12): 3654-3672.
- [31] SINGHAL K, SIDAHMED H, GARRETT Z, et al.Federated reconstruction: Partially local federated learning[J].Advances in Neural Information Processing Systems,2021, 34: 11220-11232.
- [32] WEI K, LI J, DING M, et al.Federated learning with differential privacy: Algorithms and performance analysis[J].IEEE transactions on information forensics and security,2020, 15: 3454-3469.
- [33] ZHANG C, LI S, XIA J, et al. {BatchCrypt}: Efficient homomorphic encryption for {Cross-Silo} federated learning[C]//2020 USENIX annual technical conference (USENIX ATC 20),2020: 493-506.
- [34] BYRD D, POLYCHRONIADOU A. Differentially private secure multi-party computation for federated learning in financial applications[C]//Proceedings of the first ACM international conference on AI in finance,2020: 1-9.
- [35] SHI J, WAN W, HU S, et al. Challenges and approaches for mitigating byzantine attacks in federated learning[C]//2022 IEEE International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom),2022: 139-146.
- [36] TOLPEGIN V, TRUEX S, GURSOY M E, et al. Data poisoning attacks against federated learning systems[C]//Computer security–ESORICs 2020: 25th European symposium on research in computer security, ESORICs 2020, guildford, UK, September 14–18, 2020, proceedings, part i 25,2020: 480-501.
- [37] JIANG Y, ZHANG W, CHEN Y.Data quality detection mechanism against label flipping attacks in federated learning[J].IEEE Transactions on Information Forensics and Security,2023, 18: 1625-1637.
- [38] PILLUTLA K, KAKADE S M, HARCHAOUI Z.Robust aggregation for federated learning[J].IEEE Transactions on Signal Processing,2022, 70: 1142-1154.
- [39] KUMAR R, KHAN A A, KUMAR J, et al.Blockchain-federated-learning and deep learning models for covid-19 detection using ct imaging[J].IEEE Sensors Journal,2021, 21 (14): 16301-16314.
- [40] 宋英齐, 冯荣权.零知识证明在区块链中的应用综述[J].广州大学学报 (自然科学版),2022, 21 (04): 21-36.
- [41] MUHAMMAD G, ALSHEHRI F, KARRAY F, et al.A comprehensive survey on multimodal medical signals fusion for smart healthcare systems[J].Information Fusion,2021, 76: 355-375.
- [42] LI J, SUN G, DUAN L, et al.Multi-objective optimization for UAV swarm-assisted IoT with virtual antenna arrays[J].IEEE Transactions on Mobile Computing,2023.
- [43] LI J, SUN G, WU Q, et al.Collaborative ground-space communications via evolutionary multi-objective deep reinforcement learning[J].IEEE Journal on Selected Areas in Communications,2024.
- [44] LI L, XU G, LIU Z, et al.Task execution latency minimization for energy-sensitive IoTs in wireless powered mobile edge computing: A DRL-based

- method[J].Computer Networks,2024, 251: 110633.
- [45] LIM W Y B, LUONG N C, HOANG D T, et al.Federated learning in mobile edge networks: A comprehensive survey[J].IEEE communications surveys & tutorials,2020, 22 (3): 2031-2063.
 - [46] ROY A G, SIDDIQUI S, PöLSTERL S, et al.Braintorrent: A peer-to-peer environment for decentralized federated learning[J].arXiv preprint arXiv:1905.06731,2019.
 - [47] ULLAH F, SRIVASTAVA G, XIAO H, et al.A scalable federated learning approach for collaborative smart healthcare systems with intermittent clients using medical imaging[J].IEEE Journal of Biomedical and Health Informatics,2023.
 - [48] FU L, ZHANG H, GAO G, et al.Client selection in federated learning: Principles, challenges, and opportunities[J].IEEE Internet of Things Journal,2023, 10 (24): 21811-21819.
 - [49] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics,2017: 1273-1282.
 - [50] KARIMIREDDY S P, KALE S, MOHRI M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]//International conference on machine learning,2020: 5132-5143.
 - [51] WANG J, LIU Q, LIANG H, et al.Tackling the objective inconsistency problem in heterogeneous federated optimization[J].Advances in neural information processing systems,2020, 33: 7611-7623.
 - [52] KHAN L U, ALSENWI M, YAQOOB I, et al.Resource optimized federated learning-enabled cognitive internet of things for smart industries[J].Ieee Access,2020, 8: 168854-168864.
 - [53] WANG Y, TONG Y, SHI D. Federated latent dirichlet allocation: A local differential privacy based framework[C]//Proceedings of the AAAI Conference on Artificial Intelligence,2020: 6283-6290.
 - [54] MOHRI M, SIVEK G, SURESH A T. Agnostic federated learning[C]//International conference on machine learning,2019: 4615-4625.
 - [55] LIU Z, CHEN Y, YU H, et al.Gtg-shapley: Efficient and accurate participant contribution evaluation in federated learning[J].ACM Transactions on intelligent Systems and Technology (TIST),2022, 13 (4): 1-21.
 - [56] 刘怡然, 柯俊明, 蒋瀚, 等. 基于沙普利值计算的区块链中 PoS 共识机制的改进[J].计算机研究与发展,2018, 55 (10): 2208-2218.
 - [57] WANG Y, PENG H, SU Z, et al.A platform-free proof of federated learning consensus mechanism for sustainable blockchains[J].IEEE Journal on Selected Areas in Communications,2022, 40 (12): 3305-3324.
 - [58] LIU Z, GUO J, YANG W, et al.Privacy-preserving aggregation in federated learning: A survey[J].IEEE Transactions on Big Data,2022.
 - [59] TAM P, MATH S, KIM S.Optimized multi-service tasks offloading for federated learning in edge virtualization[J].IEEE Transactions on Network Science and Engineering,2022, 9 (6): 4363-4378.

- [60] KAIROUZ P, MCMAHAN H B, AVENT B, et al. Advances and open problems in federated learning[J]. Foundations and trends® in machine learning, 2021, 14 (1-2): 1-210.
- [61] XU J, GLICKSBERG B S, SU C, et al. Federated learning for healthcare informatics[J]. Journal of healthcare informatics research, 2021, 5: 1-19.
- [62] CHATTERJEE P, DAS D, RAWAT D. Securing financial transactions: Exploring the role of federated learning and blockchain in credit card fraud detection[J]. Authorea Preprints, 2023.
- [63] CHRONIS C, VARLAMIS I, HIMEUR Y, et al. A survey on the use of Federated Learning in Privacy-Preserving Recommender Systems[J]. IEEE Open Journal of the Computer Society, 2024.
- [64] ZHU L, LIN H, LU Y, et al. Delayed gradient averaging: Tolerate the communication latency for federated learning[J]. Advances in neural information processing systems, 2021, 34: 29995-30007.
- [65] LI Q, DIAO Y, CHEN Q, et al. Federated learning on non-iid data silos: An experimental study[C]//2022 IEEE 38th international conference on data engineering (ICDE), 2022: 965-978.
- [66] GUAN H, YAP P-T, BOZOKI A, et al. Federated learning for medical image analysis: A survey[J]. Pattern Recognition, 2024: 110424.
- [67] WANG H, YUROCHKIN M, SUN Y, et al. Federated learning with matched averaging[J]. arXiv preprint arXiv:2002.06440, 2020.
- [68] LIU W, CHEN L, CHEN Y, et al. Accelerating federated learning via momentum gradient descent[J]. IEEE Transactions on Parallel and Distributed Systems, 2020, 31 (8): 1754-1766.
- [69] GAO L, FU H, LI L, et al. Feddc: Federated learning with non-iid data via local drift decoupling and correction[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2022: 10112-10121.
- [70] WANG G, DANG C X, ZHOU Z. Measure contribution of participants in federated learning[C]//2019 IEEE international conference on big data (Big Data), 2019: 2597-2604.
- [71] YE R, XU M, WANG J, et al. Feddisco: Federated learning with discrepancy-aware collaboration[C]//International Conference on Machine Learning, 2023: 39879-39902.
- [72] LI B, CHEN S, YU K. Feddkw—federated learning with dynamic kullback–leibler-divergence weight[J]. ACM Transactions on Asian and Low-Resource Language Information Processing, 2023.
- [73] KRIZHEVSKY A, HINTON G. Learning multiple layers of features from tiny images[J], 2009.
- [74] TSCHANDL P, ROSENDAHL C, KITTLER H. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions[J]. Scientific data, 2018, 5 (1): 1-9.
- [75] ANGUIA D, GHIO A, ONETO L, et al. A public domain dataset for human activity recognition using smartphones[C]//Esann, 2013: 3-4.
- [76] YANG J, SHI R, NI B. Medmnist classification decathlon: A lightweight automl

- benchmark for medical image analysis[C]//2021 IEEE 18th International Symposium on Biomedical Imaging (ISBI),2021: 191-195.
- [77] SAVI M, OLIVADESE F.Short-term energy consumption forecasting at the edge: A federated learning approach[J].IEEE access,2021, 9: 95949-95969.
- [78] ABDULRAHMAN S, TOUT H, OULD-SLIMANE H, et al.A survey on federated learning: The journey from centralized to distributed on-site learning and beyond[J].IEEE Internet of Things Journal,2020, 8 (7): 5476-5497.
- [79] VARMA K, ZHOU Y, BARACALDO N, et al. Legato: A layerwise gradient aggregation algorithm for mitigating byzantine attacks in federated learning[C]//2021 IEEE 14th international conference on cloud computing (CLOUD),2021: 272-277.
- [80] ZHU J, CAO J, SAXENA D, et al.Blockchain-empowered federated learning: Challenges, solutions, and future directions[J].ACM Computing Surveys,2023, 55 (11): 1-31.
- [81] GUO X, LIU Z, LI J, et al.V eri fl: Communication-efficient and fast verifiable aggregation for federated learning[J].IEEE Transactions on Information Forensics and Security,2020, 16: 1736-1751.
- [82] XU G, LI H, LIU S, et al.VerifyNet: Secure and verifiable federated learning[J].IEEE Transactions on Information Forensics and Security,2019, 15: 911-926.
- [83] ZHANG X, FU A, WANG H, et al. A privacy-preserving and verifiable federated learning scheme[C]//ICC 2020-2020 IEEE International Conference on Communications (ICC),2020: 1-6.
- [84] FU A, ZHANG X, XIONG N, et al.VFL: A verifiable federated learning with privacy-preserving for big data in industrial IoT[J].IEEE Transactions on Industrial Informatics,2020, 18 (5): 3316-3326.
- [85] PENG Z, XU J, CHU X, et al.Vfchain: Enabling verifiable and auditable federated learning via blockchain systems[J].IEEE Transactions on Network Science and Engineering,2021, 9 (1): 173-186.
- [86] SU Z, WANG Y, XU Q, et al.LVBS: Lightweight vehicular blockchain for secure data sharing in disaster rescue[J].IEEE Transactions on dependable and secure computing,2020, 19 (1): 19-32.
- [87] LECUN Y, BOTTOU L, BENGIO Y, et al.Gradient-based learning applied to document recognition[J].Proceedings of the IEEE,1998, 86 (11): 2278-2324.
- [88] XIAO H, RASUL K, VOLLGRAF R.Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms[J].arXiv preprint arXiv:1708.07747,2017.