

硕士学位论文

面向非独立同分布数据的联邦学习方法研究

Research on Federated Learning Methods for Non-IID Data

作者姓名: 李卫超

学号: 22209067

指导教师: 郭艳卿教授

学科、专业: 信息与通信工程

答辩日期: 2025 年 5 月 28 日

大连理工大学

Dalian University of Technology

硕士学位论文答辩委员会

答辩人：李卫超

答辩委员会委员：

大连理工大学教授： 孙怡 (注：主席)

大连理工大学教授： 马晓红

大连理工大学教授： 龚晓峰

大连理工大学副教授： 戚金清

大连理工大学副教授： 朴永日

大连理工大学助理教授： 宋瑞

答辩日期：2023 年 05 月 28 日

答辩地点：大连理工大学海山楼 A331 室

摘要

在数字化时代，数据隐私和安全问题日益严峻，传统的集中式机器学习方法因涉及集中存储数据而容易引发隐私泄露。为了解决这一问题，联邦学习应运而生，它允许多个参与方在保护数据隐私的前提下共同训练模型，而无需集中存储数据。然而，联邦学习的有效性依赖于数据独立同分布（Independent and Identically Distributed, IID）假设，而现实中的数据通常呈现非独立同分布（Non-Independent and Identically Distributed, Non-IID），这给模型的收敛性、预测性能和泛化能力带来了显著挑战。

为应对这一挑战，本文提出了两种算法以处理不同的 Non-IID 场景。在一般的 Non-IID 场景中，参与训练的客户端在样本类别上基本一致，但不同客户端之间不同类别样本数量差异较大。对比学习可以充分利用样本之间的互信息，弥补本地样本类别不均衡带来的挑战，然而无监督学习导致的特征旋转使得对比学习难以在联邦学习中聚合。本文提出了一种分类器辅助的联邦对比学习算法以解决一般的 Non-IID 问题。该算法通过分类器帮助在客户端之间建立统一的特征空间，并利用对比学习使局部优化目标趋近于全局优化目标。此外，本文还设计了一种双分支网络架构，其中一个分支作为线性分类器头部，帮助在客户端之间建立一致的特征空间；另一个分支作为投影头部用于对比学习，增强样本间差异，从而提升模型的泛化能力。

长尾分布是联邦学习中 Non-IID 问题的一个特殊场景，在这一场景中，不仅跨客户端的数据分布差异显著，而且所有客户端的各类别数据总量差异也极为突出，这更符合实际应用中的数据分布。在长尾分布中，部分类别的缺失导致少量类别的分类器参数互相收敛。本文提出了一种使用固定分类器的联邦学习算法以减少长尾分布对分类器的影响。该算法通过借鉴在平衡数据集上的零分类误差阶段经验，建立了基于等角紧框架（Equiangular Tight Frame, ETF）的固定平衡分类器。为充分发挥固定分类器的作用，本文还设计了与其对齐的特征提取器、正交旋转矩阵以及多种归一化模块等结构，以解决长尾分布带来的挑战。为确保系统的稳定性并避免梯度更新的偏斜，本文提出了一种基于样本数量的预测概率调整的平衡损失，并通过实验验证了该方法的有效性。

关键词：联邦学习；非独立同分布；对比学习；固定分类器

ABSTRACT

In the digital era, data privacy and security have become increasingly critical. Traditional centralized machine learning methods, which require aggregating data in a central server, pose a high risk of privacy leakage. Federated learning emerges as a promising solution by enabling multiple clients to collaboratively train models without sharing raw data. However, the effectiveness of federated learning often relies on the assumption of Independent and Identically Distributed (IID) data, whereas real-world data are typically Non-IID, posing significant challenges to model convergence, predictive performance, and generalization.

To address this issue, this paper proposes two algorithms tailored for different Non-IID scenarios. In general Non-IID settings, clients have similar data categories, but the number of samples per class varies significantly. Contrastive learning can leverage mutual information between samples to mitigate the challenges of class imbalance, yet unsupervised learning often induces feature misalignment, making model aggregation difficult. To overcome this, we propose a classifier-assisted federated contrastive learning algorithm. This method utilizes a classifier to align feature spaces across clients and leverages contrastive learning to narrow the gap between local and global optimization objectives. A dual-branch network is designed: one branch acts as a linear classifier head to unify feature representations, while the other serves as a projection head to enhance inter-sample discrimination, improving generalization.

Long-tailed distribution represents a special Non-IID scenario in federated learning, where both inter-client and intra-client class imbalances are severe, resembling practical data distributions. In such cases, the scarcity of certain classes leads to convergence of classifier weights across minority classes. To tackle this, we propose a fixed-classifier federated learning algorithm that mitigates the influence of class imbalance. Inspired by the zero classification error phase on balanced datasets, we adopt an Equiangular Tight Frame (ETF)-based fixed classifier. To fully exploit this design, we align the feature extractor with the fixed classifier using orthogonal rotation matrices and normalization modules. Additionally, we propose a balanced loss function based on sample-aware prediction adjustment to prevent biased gradient updates. Experimental results demonstrate the effectiveness of the proposed methods.

Key Words: Federated Learning; Non-IID; Contrastive Learning; Fixed Classifier

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 联邦学习研究现状.....	2
1.2.1 通信开销问题.....	2
1.2.2 隐私安全问题.....	3
1.2.3 异质性问题.....	3
1.3 论文研究内容与结构.....	5
1.3.1 主要研究内容.....	5
1.3.2 论文结构安排.....	6
2 相关理论与技术基础	9
2.1 联邦学习框架.....	9
2.2 联邦学习的非独立同分布问题	11
2.2.1 非独立同分布数据划分方法.....	13
2.2.2 解决非独立同分布问题的联邦学习算法	14
2.3 对比学习算法.....	15
2.4 等角紧框架分类器理论.....	18
2.5 本章小结.....	19
3 基于对比学习的联邦学习算法	20
3.1 算法介绍及适用场景.....	20
3.1.1 适用场景.....	20
3.1.2 算法介绍.....	21
3.2 算法框架.....	24
3.2.1 双分支网络.....	24
3.2.2 客户端损失函数.....	27
3.3 实验与分析.....	29
3.3.1 数据集及数据预处理.....	29
3.3.2 实验设置与指标.....	30
3.3.3 对比实验与分析.....	31
3.3.4 消融实验与性能分析.....	34
3.4 本章小结.....	35
4 基于固定分类器的联邦学习算法	37
4.1 算法介绍及适用场景.....	37
4.1.1 适用场景.....	37
4.1.2 算法介绍.....	39

4.2 算法框架.....	41
4.2.1 固定分类器的卷积网络模型.....	41
4.2.2 混合温度系数平衡损失.....	43
4.3 实验与分析.....	46
4.3.1 数据集及数据预处理.....	46
4.3.2 实验设置与指标.....	47
4.3.3 对比实验与分析.....	48
4.3.4 消融实验与性能分析.....	51
4.4 本章小结.....	54
5 结论与展望.....	56
5.1 结论.....	56
5.2 创新点.....	57
5.3 展望.....	57
参考文献.....	59

图 目 录

图 1.1 论文结构框架	7
图 2.1 FedAvg 算法框架	9
图 3.1 一般 Non-IID 分布情况	20
图 3.2 不同模型特征空间旋转示意	23
图 3.3 使用分类器辅助的联邦对比学习算法本地梯度更新流程	25
图 3.4 CNN 和 ResNet 基本模块对比	26
图 3.5 在相同数据增强条件下 CAFedCon 与 FedProc 的准确率对比	32
图 4.1 联邦长尾分布中不同客户端数据分布	37
图 4.2 CIFAR10-LT 上单机训练结果	38
图 4.3 固定分类器的联邦学习框架	41
图 4.4 不同预测结果下损失值与温度系数的关系	44
图 4.5 训练过程中类向量与分类器之间余弦相似度的变化趋势	52

表 目 录

表 3.1 测试集上的 Top-1 准确率 (%)	31
表 3.2 采用相同数据增广算法的 Top-1 准确率 (%)	31
表 3.3 在不同 Non-IID 条件下的 CIFAR-100 测试准确率 (%)	33
表 3.4 不同损失的影响	34
表 3.5 不同损失的影响 (无 MLP 投影头)	34
表 3.6 占用存储空间对比	35
表 4.1 CIFAR10-LT 数据集上对比的联邦学习方法的 Top-1 测试准确率 (%)	48
表 4.2 CIFAR100-LT 数据集上对比的联邦学习方法的 Top-1 测试准确率 (%)	49
表 4.3 Imagenet-LT 数据集上对比的联邦学习方法的 Top-1 测试准确率 (%)	49
表 4.4 消融实验	53
表 4.5 温度系数敏感性质验证	53

主要符号表

符号	代表意义	单位或定义
英文字母		
T	全局通信轮次	
E	本地更新轮次	
x	样本数据	
J	全一矩阵	
I	单位矩阵	
$\mathbb{E}$	期望值	
exp	自然数底数	
$\arg \min$	最小化目标函数	
希腊字母		
$\mathcal{L}$	损失函数	
η	学习率	
φ	偏置项	
τ	温度系数	
缩写		
Non-IID	非独立同分布	
IID	独立同分布	
ETF	等角紧框架	

注：如文中对符号另有说明，以文中对应位置说明为准。

1 绪论

1.1 研究背景与意义

随着神经网络的不断发展,深度学习越来越广泛的应用于各领域并提高了不同领域的生产效率,促进了社会生产方式的进步。然而,在传统的深度学习中,模型的训练需要在本地服务器中获得大量的已标记数据,大量数据的收集在某些领域,尤其医疗领域、金融领域等,被完全信任的开放给模型训练的相关技术人员以及第三方企业。这种训练方式极大的影响了数据提供者的隐私安全。此外,受限于严格的政策法规,许多领域难以收集到大规模且高质量的数据集,这进一步限制了特定领域中模型训练的效果和应用范围。为了解决这些问题,联邦学习应运而生。联邦学习重新组织了数据结构,将数据分散存储在参与方中,并通过加密等手段保障数据隐私。同时,联邦学习也能够保证各参与方的数据隐私安全的前提下,实现更好的训练效果。

在 2016 年,McMahan^[1]团队首次提出了联邦学习的概念。联邦学习的关键特征是保证各参与方中与单个样本相关的关键特征不会暴露给其他参与方。通常情况下,联邦学习是分布式协作,其包括一个中心服务器和若干客户端参与。数据持有方作为客户端,由于其自身数据量不足、数据质量差等因素的影响,无法单独训练出高效的机器学习模型。中央服务器则负责模型的下发、收集和聚合,通过使用不同策略对来自本地的模型进行聚合来改善模型的性能。通过这种方式,联邦学习可以在保护数据隐私的前提下,实现多方参与模型训练并获得更好的训练效果。联邦学习通过模型梯度等非隐私数据的跨设备传输与聚合,实现了在保护用户隐私数据的前提下,聚合产生一个良好的媲美集中学习的全局模型。然而,随着隐私计算的发展和广泛应用,联邦学习被应用与越来越多的领域,也提出了一些挑战。

联邦学习通常聚合所有选定的客户端模型参数或梯度,以构建一个通用的联邦全局模型。传统的联邦学习往往是利用各客户端的本地模型进行加权聚合以共同构建一个全局模型。然而在实际应用中,由于不同客户端的设备差异,地缘差异以及各种其他因素等,不同的客户端往往呈现出很大的差异性^[2],比如不同客户端之间性能差异导致很难部署相同规模的网络模型,可能在模型结构及模型参数上存在较大差异;此外还有数据上的差异,不同客户端的本地数据分布不同,其中包括不同客户端有相同的样本类别,但是样本数量不同、客户端之间相同类别的样本的特征不同、以及某些少数类在模型中十分重要但是在整个样本集中缺失严重等,各种复杂的数据分布情况使得联邦学习很难使用一个简单的框架在所有场景中都达到不错的收敛效果。

为了解决多样化的 Non-IID 场景对联邦学习训练过程和收敛精度等的影响,本文提出多种算法以在不同的 Non-IID 场景中根据数据分布特点,选择合适的策略来解决

联邦学习的 Non-IID 问题。具体来说，在一般的数量不均衡的 Non-IID 场景中，本文创新性的使用双分支网络来将对对比学习应用于联邦学习中，以防止在无监督对比学习中由于模型特征空间的旋转导致的不同本地模型样本空间不对齐的现象。在更进一步的某些类别样本在所有客户端中都数量稀少的较为极端的长尾设置下的 Non-IID 环境中，本文提出使用预设的固定的分类器来进行联邦学习，以迁移来自样本数量多的特征识别罕见类别的特征，同时防止罕见类别样本数量稀少导致的分类器在少样本类别上的少数崩溃现象^[3]，从而提高模型在长尾学习场景中的训练精度。

1.2 联邦学习研究现状

联邦学习作为一种保护用户隐私的分布式学习框架，当前阶段主要面临三个主要挑战：客户端与服务器之间的通信效率影响其训练的速度，隐私安全问题受当前越来越多样的攻击手段的影响需要进一步加强，数据异质性问题导致全局模型不收敛从而影响联邦学习训练后的预测性能。本章将在研究提高联邦学习在多种 Non-IID 场景下的预测性能的同时，尽量保证算法的通信开销不会增加并且不增加隐私安全风险。本小节将简要介绍通信开销和隐私安全问题并着重介绍数据 Non-IID 问题。

1.2.1 通信开销问题

客户端和中央服务器之间的通信是联邦学习的关键步骤。在一般的联邦学习，如 FedAvg 算法中，中央服务器通过网络共享全局模型到参与的所有设备。参与此联邦学习的设备总数有时可能为数百万，设备进行通信使用的网络带宽可能相对较慢或不稳定的。受限于客户端的带宽限制，设备功率以及设备的 CPU 以及 GPU 处理信息的能力的限制等，这些通信可能会很慢^[4,5]。

减少通信开销的一个有用方法是通过提高本地训练的效率和性能来降低通信频率。例如，FedKD^[6] 利用互知识蒸馏和动态梯度压缩来减少通信开销，提高训练效率。FedDM^[7] 则使用更创新的本地更新策略，该算法中通过分布匹配在本地生成合成数据，并在服务器上利用这些合成数据重构全局模型。与参数聚合的算法比较，该算法可以利用空间更少且信息更大的合成数据确保在更少通信次数下得到收敛的全局模型。

客户端选择是一种可以通过限制参与设备的数量来降低通信成本的方法，在每一轮通信中只选择性更新一小部分客户端^[8]。在联邦学习应用中，使用合适的客户端选择方案将直接影响联邦模型的效率和性能。Chen^[9] 等人设计了一种客户端选择策略，在每轮中对模型收敛性提升显著的并且损失具有较大下降的客户端模型设置更大的选中概率从而促进全局收敛，此外，该算法还设计了一种高效的量化策略减少模型参数，从而提高通信和计算效率。Deng 等人^[10] 提出了一个基于自动化质量意识的客户端选择框架，该框架考虑了影响学习表现的各种因素，采用了强化学习方法^[11]。并

且它自动评估客户端的模型质量，并在有限的预算内自动为联邦任务选择高质量的客户端，显著提高了学习效率。

压缩模型或者减少本地模型更新参数与次数是降低通信成本的又一种策略。Zhu 等人^[12] 尝试使用多目标进化算法 (Multi-Objective Evolutionary Algorithm, MOEA) 优化联邦学习神经网络模型的结构，并实现网络模型参数的最优压缩，从而同步实现较小的通信成本和良好的全局模型性能。Sattler 等人^[13] 提出了一种稀疏三元压缩 (Sparse Ternary Compression, STC) 方法，该方法不仅遵守联邦学习设置和环境的压缩要求，而且还为上游和下游通信进行压缩。通过这些压缩技术可以在一定程度上减少联邦学习中的通信压力。

1.2.2 隐私安全问题

联邦学习是一种用于保护用户隐私安全的分布式计算方法，其通过传输模型梯度等信息来聚合全局模型，不会直接暴露用户隐私信息。然而，这种传输模型参数相关信息的方法并不是绝对安全的，现有一些攻击方法如中毒攻击和推理攻击^[14] 等可以泄露用户的隐私信息。为了保护用户隐私，常常采用的方法包括在数据传输过程中进行加密以及应用差分隐私等。

常用的加密手段有安全多方计算和同态加密^[15] 等手段。同态加密算法可以在对数据进行加密的情况下进行运算，不需要在中央服务器进行解密；安全多方计算则可以通过一组协议在不泄露输入的前提下多个参与方之间协同计算。这两种算法会大幅增加联邦学习的隐私安全性能，但是同时由于其复杂的加密方法，往往会对设备产生较大的计算压力。

差分隐私^[16] 是不同于以上加密算法的另一种保护用户隐私安全的方法。差分隐私通过添加扰动使得单条数据的变化不会引起查询结果的变化，从而防止通过对数据的查询泄露用户隐私信息。然而，由于添加噪声会造成数据失真，该方法往往会导致模型的性能下降，所以需要在隐私安全与模型性能之间进行取舍。

这几种方法可以互相独立的运行在联邦学习框架中保护用户隐私安全。本文算法没有涉及到相关加密算法的创新性，所以在实验中没有应用加密算法。但是本文所提出的两种算法在全局通信过程中与 FedAvg 算法基本相同，也是传输模型参数，因此在应用过程中与 FedAvg 算法具有相同的隐私安全性能。

1.2.3 异质性问题

传统联邦学习通常聚合所有选定的客户端模型参数或梯度，以构建一个通用的联邦全局模型。如公式1.1所示，联邦学习的优化目标是最小化不同本地优化函数的加权均值。其中 p_k 是客户端 k 的权重系数， $F_k(\mathbf{w})$ 是客户端 k 的优化目标， N 为所有参与客户端数量。在聚合的过程中，由于每个客户端数据的 Non-IID，以及由于不同的设

备资源约束和个性化任务而导致的每个客户端模型结构大小不同的模型异构性问题, 导致全局目标难以收敛或收敛于有偏的最优值, 这些问题会降低全局模型的性能或使其难以收敛到全局最优解^[2]。

$$\min_{\mathbf{w}} f(\mathbf{w}) = \sum_{k=1}^N p_k F_k(\mathbf{w}) = \mathbb{E}_k[F_k(\mathbf{w})] \quad (1.1)$$

对于联邦学习中由于数据分布的 Non-IID 导致的统计异质性问题, 已经有许多理论分析与研究。Li 等人^[17] 证明了 FedAvg 算法在现实环境中收敛不佳的理论依据。该文分析了 FedAvg 在 Non-IID 数据上的收敛性, 并给出了在强凸且光滑条件下的收敛率。研究表明, 数据异质性会降低收敛速度, 而通信效率和收敛速度之间需要权衡考虑。此外, 作者还证明了对于 Non-IID 数据进行 FedAvg 的一个必要条件: 即使所有的本地系统参与训练, 学习率也必须不断衰减, 否则将偏离全局最优解。这些结果揭示了在非独立同分布数据上使用联邦平均算法的一些局限性, 同时也为研究人员提供了改进这种算法的思路。FedProx^[4] 在损失函数中引入了近端项, 限制了因为数据异质性导致的模型偏离。同时, 为了统筹各客户端的计算性能, 该算法不再固定每个客户端的轮次, 而是引入了不精确解, 各个客户端只需要得到一个与全局模型相近的本地优化目的的不精确解, 以防止各客户端的参数偏离全局参数过多, 同时这也有效缓解了某些设备的计算压力。Wang 等人^[18] 提出了一种有效的多项式时间算法来调度不同客户端的工作负载。针对异构数据问题, 他们将其转化为平均成本最小化优化问题, 并使用贪婪算法在计算时间和计算准确性之间寻求平衡。此外, 对于具有噪声的 Non-IID 数据, Hu 等人^[19] 提出了一种基于联邦卡尔曼滤波 (Federated Kalman Filters, FKF) 置信度的联邦学习框架。它使用具有高级辅助分类器的卷积对抗生成网络作为特征提取来预训练数据, 然后通过 FKF 生成每个客户端的置信度参数, 克服了数据异构性的挑战, 实现了联邦学习的高效聚合。这些方法极大地缓解了联邦学习中客户端之间数据的异质性, 但很明显, 这些方法的优化针对于不同的 Non-IID 场景, 根据不同的数据分布特点采用了不同的方法。数据异构性问题会影响联邦学习训练过程的不同阶段, 如客户端选择阶段、模型传输阶段和聚合阶段。需要深入分析异质性挑战对联邦学习模型训练的影响, 针对不同的数据分布特点进行约束或者优化可以促进全局模型的收敛, 从而在 Non-IID 场景下得到预测精度较高的全局模型。

个性化本地模型是解决联邦学习数据异质性的另一类有效策略。在传统联邦学习中, 全局模型是通过客户端的协同训练构建的, 而客户端本地训练得到的模型本质上是为本地图任务服务的, 所以在实际场景中, 统一的模型结构会限制本地任务执行的性能, 因此客户端的本地模型可以基于本地任务和本地服务器的性能差异进行个性化^[20]。Mills 等人^[21] 利用多任务处理的思想开发了一种用于个性化联邦模型训

练的多任务联邦学习算法,该算法在联邦深度神经网络中引入了非联邦的批归一化层。所提出的算法允许用户根据自己的本地数据对训练模型进行个性化设置,从而促进本地客户端模型的性能提升和收敛速度。Ni 等人^[22]提出了一种联邦共蒸馏算法,该算法在本地优化目标中添加全局模型输出概率与本地模型输出概率的 KL 散度(Kullback-Leibler Divergence)作为蒸馏损失,以利用全局模型约束本地梯度更新的方向。而且他们提出的算法可以进一步扩展到联邦双向共蒸馏,以个性化每个设备的本地模型。Zhou 等人提出一种利用模型对比学习进行联邦个性化^[23]的方案。该算法在全局模型中基于动态更新的本地模型权重进行聚合,并且将模型解耦为个性化模块和联邦模块。在本地客户端中,他们提出了一种初始化更精确的两阶段迭代聚类算法,以动态更新的多个聚合中心促进个性化全局聚合。此外,他们还基于分层移位窗口注意力机制和新设计的桥接注意力机制,构建了个性化的多模态融合网络。然而,个性化模型往往会降低全局模型的泛化性能,容易对本地数据集过拟合,并且个性化模型通常需要更复杂的算法框架,会带来更多的计算开销和通信压力。

1.3 论文研究内容与结构

1.3.1 主要研究内容

联邦学习作为一种为保护数据隐私而发明的分布式算法框架,能够利用来自多个参与方的独立同分布数据共同训练从而提高模型性能。然而,在实际应用中,由于各客户端的数据分布往往受环境影响而表现出显著的异质性,即客户端之间是 Non-IID 分布的,联邦学习面临模型收敛缓慢、泛化能力弱和性能下降等问题。因此,本文针对联邦学习中的不同 Non-IID 场景展开研究,旨在设计高效鲁棒的算法,以应对复杂的数据分布特性从而提升模型的训练效率和性能表现。

本文的研究内容主要围绕两类典型的 Non-IID 场景:一般 Non-IID 以及长尾分布。在这两种不同的场景下,数据分布的不均衡程度和类别缺失情况逐步增加,对模型的优化过程提出了不同层次的挑战。

数据量的不均衡是 Non-IID 问题中的一种常见情况。在联邦学习中,不同客户端可能拥有不同数量的数据,这种数据量差异会导致客户端在模型训练过程中发挥的作用不均衡。当某些客户端拥有大量数据时,它们的模型更新对全局模型的贡献将远大于那些数据量较少的客户端。这种情况会导致全局模型在训练过程中偏向数据量较大的客户端,忽视了数据量较小客户端的重要性。为了应对这一挑战,FedSKD^[24]算法是一种利用知识蒸馏解决联邦 Non-IID 问题的算法。该算法主要思想是利用上一批次的预测结果作为教师来指导当前的本地训练。同时设计一种动态同步模型来调整本地训练轮次和上传频率以提高训练效率。在这种场景中,还有一些算法通过对联邦学习的本地训练添加修正项等手段,由于这种场景下本地优化目标与全局优化目标差

异不是特别显著,因此可以通过优化本地训练目标,使其接近全局优化目标从而减少 Non-IID 带来的影响。FedNTD^[25] 策略是一种巧妙的解决 Non-IID 问题的联邦蒸馏策略。该策略中在本地训练中仅仅学习全局模型对负标签的预测概率,从而模拟全局模型的预测分布情况,有效地解决了联邦学习中的数据异质性和知识遗忘问题。此外, FedAwS^[26] 框架将分类器与特征提取器的训练进行分离,其核心思想是将输入通过模型得到预测概率和标签放入同一个高维空间,在客户端中使输入和标签距离尽量近,在服务器端使不同类别标签的相互距离尽量远,从而利用其他客户端中的信息来训练模型。然而,以上策略都是通过对算法进行修正,使得本地优化目的逼近全局优化目标,从而减弱 Non-IID 的影响。本文提出基于共享特征提取器的分类器头建立全局的对比学习,从而利用全局数据集中的知识,将全局数据集中的样本互信息引入每一轮本地训练中,从而在不同客户端数据分布 Non-IID 的情况下,建立一个跨客户端的统一的特征空间来进行对比学习,充分提取数据集中的类别特征。

长尾分布也是联邦学习中棘手的 Non-IID 问题之一。在许多实际应用中,某些类别的数据是稀有的,例如医疗数据中的罕见病,然而在模型预测时这种预测结果是十分有意义的。如果使用常用的模型在这种数据总量在不同类别中差异显著的数据集中进行训练,会导致模型在样本数量多的类别上的性能较好,而在样本数量少的类别上的性能较差,而且许多客户端中可能甚至不包含某些稀少的样本,在其他客户端中的该样本数又相对稀少,从而导致全局模型对数量稀少的类别特征忽视,导致其在这些类别上的泛化能力较低。在长尾分布的联邦学习中,为了充分挖掘少样本类别的特征, CLIP2FL^[27] 利用对比语言-图像预训练模型(Contrastive Language- Image Pre-Training, CLIP)中的预训练知识,在本地训练时将 CLIP 作为教师模型学习少样本数据中的特征,在全局服务器中使用 CLIP 生成联邦特征来作为假数据训练全局模型。通过利用来自预训练模型中的知识来弥补少样本类别中缺少的特征。这种方法主要利用来自其他预训练模型的知识来缓解长尾分布中部分类别数据信息量的缺失。本文提出一种利用均衡数据集下神经网络的训练规律,建立规范化的固定的分类器从而防止分类器的有偏优化的联邦学习算法。在本文提出的算法中,主要利用了神经网络训练中,数据有偏影响对神经网络的输出层影响更大的特点,手动设置固定的平衡的分类器参数,并根据分类器设置有效的特征提取器和归一化层以及正交旋转矩阵等,使得模型可以利用多样本数量类别的特征训练特征提取器的同时减少对分类器的有偏优化,从而减少客户端之间的优化目标的分歧,从而提高联邦学习在长尾分布中的训练效率。

1.3.2 论文结构安排

针对以上挑战,本文分别设计了基于对比学习解决一般 Non-IID 问题的联邦学习优化策略和基于固定分类器解决长尾分布的联邦学习优化策略。本文的整体框架如图 1.1:




图 1.1 论文结构框架

Fig. 1.1 The framework of paper

第一章为绪论，首先介绍本文的研究背景与意义，表明在 Non-IID 场景中解决联邦学习的收敛性问题的必要性和挑战性。然后介绍联邦学习相关的研究现状以及其面对的主要挑战，对联邦学习当前发展情况进行初步介绍，之后详细介绍本文主要的研究内容，根据不同的 Non-IID 场景分别介绍最近的研究并提出本文研究的主要创新点。之后是论文的整体结构介绍，简略表达每一章的主要内容。

第二章为相关理论基础。首先从算法框架上了解联邦学习，清晰介绍联邦学习的算法流程。然后介绍了联邦学习中的 Non-IID 问题。分别介绍了实验中进行 Non-IID 问题划分的不同策略以及常用的解决 Non-IID 问题有哪几种算法。之后介绍了本文涉及到的几种神经网络相关知识，包括对比学习，等角紧框架分类器等。并且在介绍这些知识的时候先介绍基本的原理，然后介绍了这种知识在联邦学习中的应用。

第三章基于一般的 Non-IID 场景提出了一种分类器辅助的联邦对比学习算法 (Classifier-Augmented Federated Contrastive Learning, CAFedCon)。在一般的 Non-IID 场景中各客户端之间虽然共享相同的类别标签，但各类别样本数量分布不均衡。这种分布导致模型在本地训练过程中容易偏向局部最优解，而忽略全局最优目标，进而影响全局模型的收敛速度和准确性。为了解决这一问题，本章提出了 CAFedCon 算法。CAFedCon 算法可以利用对比学习解决数据分布不均衡的问题，同时使用全局分类器约束本地特征空间的旋转问题。具体来说，该算法通过设计双分支网络结构来利用分类器辅助进行联邦对比学习。一方面，通过线性分类器分支在客户端之间建立统一的特征表示，减小不同客户端的特征分布偏差；另一方面，通过投影分支引入对比学习机制，进一步增强样本之间的区分性，提高模型的鲁棒性和泛化能力。本章使用分类

器辅助的对比学习机制有效缓解了 Non-IID 分布导致的梯度方向不一致问题，并使本地模型和全局模型的优化目标更为一致从而提高了全局模型的性能。实验结果进一步表明，该算法在不同程度的 Non-IID 数据条件下，相较于传统联邦学习方法具有更快的收敛速度和更高的分类精度。该研究的目标是在常见 Non-IID 场景下，通过改进模型框架和对比学习方法，为联邦学习提供更稳定且有效的优化框架，并且取得了不错的效果。

第四章进一步聚焦于联邦学习中的长尾分布问题提出了一种使用固定分类器的混合低温系数设置下的归一化特征的联邦学习算法（Federated Learning with Mixed Low-Temperature and Normalized Features, Fed-LTNF）。联邦长尾分布是一类更为复杂的 Non-IID 场景，其中不仅客户端之间的数据分布存在显著差异，而且在所有客户端的全局数据分布中，各类别的样本数量也呈现严重的不均衡特性。长尾分布是许多实际场景中常见的数据分布模式，如图像分类任务中的少样本类别问题和语音识别中的稀有音素问题。由于长尾分布会导致模型在训练过程中对多数类别表现出较高的精度，而对少数类别则表现较差，因此解决这一问题对于提升模型的整体性能至关重要。针对长尾分布场景，本章提出了 Fed-LTNF 算法。该算法通过引入一种基于简单等角紧框架的固定平衡分类器，以平衡数据类别的表示能力，减轻长尾分布对特征空间中少数类别互相收敛的影响。具体而言，本文设计了一个与固定分类器对齐的特征提取器，通过几何约束和特征空间对齐机制，引导模型在长尾数据分布下学习更均衡的特征表示。同时，为了进一步优化类别不均衡条件下的损失计算，本文引入了混合低温设置下的预测概率调整损失函数，以降低少数类别在训练过程中被忽略的风险，并防止梯度更新过程中出现偏差。此外，本文还结合批归一化、样本标准化和正交矩阵映射等技术，进一步增强模型的鲁棒性和泛化能力。实验结果表明，该算法在长尾分布场景下能够有效缓解类别不均衡问题，同时提高模型对少数类别的识别精度。理论分析和实验验证共同证明，该方法在面对实际长尾数据时具有较高的应用价值。该研究的目标是在长尾分布条件下，通过固定分类器设计和平衡特征提取机制，提升模型对不均衡数据的适应性与分类性能，为联邦学习在复杂现实场景中的应用提供一定的启发，从而提高联邦学习的广泛适用性。

最后是结论与展望部分。对以上几种场景提出的算法进行分别总结叙述并且分析了每个算法的优缺点。对未来联邦 Non-IID 相关领域的发展进行展望并对本文研究课题及本文算法提出了有可能的发展方向。

2 相关理论与技术基础

本章将介绍本文提出的算法所涉及的相关理论基础，根据研究问题与算法需求，本章将主要介绍联邦学习以及联邦学习中的数据非独立同分布问题。此外，本文将介绍对比学习以及等角紧框架等理论基础。这些技术基础为后面的算法提供理论支持和技术基础。

2.1 联邦学习框架

在实际应用场景^[28]中，假设 n 个用户 $U_1, U_2, \dots, U_n$ 拥有私有数据库 $D_1, D_2, \dots, D_n$ ，并且他们每个人都无法直接访问其他人的数据来扩展自己的数据。在这样的场景中，联邦学习通过从分布式设备中收集非隐私敏感的训练信息来学习模型。该算法一般包含三个基本步骤^[1]：（1）服务器将初始模型发送到每个选定客户端。每个客户端设备不可以共享自己的原始数据，但可以使用本地数据训练自己的本地模型。（2）本地模型更新完成后上传到服务器，服务器对收集到的本地模型进行聚合。（3）全局模型下载到选定的本地客户端，然后更新以替换每个用户的本地模型并继续进行步骤（2），依次循环下去。基于以上联邦学习的适用场景的设想以及定义，一种被广泛应用的联邦平均算法被提出并且成为联邦学习领域的基本算法框架。




图 2.1 FedAvg 算法框架

Fig. 2.1 The framework of FedAvg algorithm

McMahan^[29]等人提出了联邦平均算法(FedAvg)。其框架结构如图2.1所示。在该方法中包括一个中央服务器以及若干个本地客户端,中央服务器中不含有隐私数据,其作用仅仅是聚合各本地客户端的模型更新并生成用于所有客户端的全局模型,本地客户端一般为 $n(n > 1)$ 个,每个本地客户端有其隐私数据,并且隐私数据不能传递给其他参与方,该算法中首先中央服务器初始化模型并将模型下发给指定客户端,收到初始化模型的客户端在本地通过随机梯度下降执行多次更新计算,对模型进行迭代优化。然后将更新的模型上传到中央服务器,中央服务器将本轮获得的所有更新的模型使用公式2.1进行加权求和。其中, $\mathbf{w}_{t+1}$ 是更新后的全局模型,用于下一轮下发给指定客户端作为初始模型, n_k 是第 k 个客户端的本地数据集中的样本数量, n 是本轮更新选中的所有客户端所包含的总的样本数量, $\mathbf{w}_{t+1}^k$ 是第 k 个客户端在第 t 轮更新之后上传到服务器的模型。不断循环上述过程,优化模型训练效果,直至模型收敛为止,其算法框架如算法2.1所示。

$$\mathbf{w}_{t+1} \leftarrow \sum_{k=1}^K \frac{n_k}{n} \mathbf{w}_{t+1}^k \quad (2.1)$$

算法 2.1 FedAvg 算法框架

Input: 客户端数据集 $D_1, D_2, \dots, D_n$;

Output: 全局模型 $\mathbf{w}$;

- 1: 初始化全局模型参数 $\mathbf{w}$
 - 2: **for** 全局通信轮次 $t = 1$ to T **do**
 - 3: $\mathbf{m} \leftarrow$ 随机选定一定比例的客户端 C
 - 4: **for** 每一个客户端 $i \in \mathbf{m}$ **do**
 - 5: $\mathbf{w}_i \leftarrow$ 使用客户端 i 的本地数据集 D_i 进行本地模型更新
 - 6: **end for**
 - 7: $\mathbf{w} \leftarrow \sum_{i \in \mathbf{m}} \frac{|D_i|}{\sum_{k=1}^m |D_k|} \mathbf{w}_i$
 - 8: **end for**
-

根据数据样本空间和特征空间的分布模式不同,联邦学习可以分为横向联邦学习(Horizontal Federated Learning, HFL),纵向联邦学习(Vertical Federated Learning, VFL)以及联邦迁移学习(Federated Transfer Learning, FTL)。横向联邦学习^[30]指不同的参与方在样本特征上是基本一致的,但是不同参与方的样本来源以及样本个体是完全不同的。横向联邦学习是集中数据集按样本为基本单位的分布式划分,每个部分仅含有一部分的样本数量,所以也被称为按用户特征的对齐。例如,两个不同地域的相同类型的机构,他们由于地域差异,其用户互相之间基本是无重复的;但是由于其提供相似的业务,所以不同用户提供的特征基本是一致的。在这种特征对齐的分布式数据集中,可以使用横向联邦学习来进行分布式深度学习以获得性能良好的全局模型,这不仅可以在全局样本上优化全局目标,获得比本地训练时更性能优秀的模型参

数,而且在大数据集中更容易实现模型收敛,使得全局优化获得更稳定的低损失值。在横向联邦学习中,各方通常都会在客户端设备中基于本地样本设置优化函数更新本地模型并上传本地更新的梯度,以便中央服务器可以将它们聚合到一个全局模型中。

垂直联邦学习^[31]是对集中场景下的数据集根据数据的维度使不同参与方仅仅获得全部样本数量的部分数据维度的一种场景,所以也被称为基于特征的联邦学习,通常用于两个或更多客户端数据集共享相似样本 ID 空间但具有不同输入特征空间的场景。这种类型的学习允许客户端通过使用第三方来聚合他们针对特定样本 ID 所拥有的特征信息,该第三方能够确保在特征共享过程中不泄露独特的样本 ID 信息。因此,垂直联邦学习在确保每一个参与方的数据集中的独特样本 ID 数据隐私不被攻击的同时,协作共享不同客户端收集的样本的不同的特征,从而利用来自各参与方的不同信息协作计算全局模型模型的损失函数并更新全局模型梯度。

当不同参与方的数据集在用户和特征上均缺乏重叠时,传统的联邦学习方法可能无法有效发挥作用。为应对这一挑战,引入迁移学习以弥补数据或标签的缺失,从而利用其他参与方的信息,这种方法被称为联邦迁移学习^[32]。例如,考虑两家机构:一家是位于某地市的银行,另一家是位于另一地市的金融证券机构。由于地域不同,这两地生活的人群有很大差异,这两家机构的用户群体几乎完全互质。此外,由于业务性质不同,它们的数据特征也仅有小部分重合,相似度不高。在这种情况下,为了有效地进行联邦学习,需要引入迁移学习通过对方的知识训练全局模型来解决各参与方数据量不足的问题,从而提升模型的性能。迁移学习可以在不同任务间提取到相似的有用信息,从而有利于不相关任务的模型优化。

本文主要研究的是横向联邦学习的场景。即各参与方共享相同的样本空间的场景。在这种场景中,由于各参与方的数据特征之间是相似的,但是不同参与方的样本 ID 空间不同,所以不同的本地模型趋向于适应本地的数据分布。理想场景中是各参与方的数据分布趋于一致的,即呈现出独立同分布的特征。然而在实际场景中,由于各参与方的各种差异,往往互相之间的数据分布呈现出很大的差异,从而导致本地模型收敛向本地的目标空间,这种客户端之间优化方向的差异会极大影响联邦学习的全局模型的收敛性。本文主要研究在这种场景下针对各参与方之间数据分布的差异特点提出针对性的解决策略。

2.2 联邦学习的非独立同分布问题

联邦学习作为一种分布式深度学习算法,可以在不共享用户数据的情况下训练全局模型,这在近年来引起了隐私安全领域的广泛关注。但是,在联邦学习的实际应用中,确保边缘设备中的数据独立同分布是不现实的。因此,Non-IID 分布问题成为影响联邦学习发展的挑战之一。

假设联邦学习中有两个参与方 P_i 和 P_j 分别有各自的本地数据 D_i 和 D_j ，其中 D_i 和 D_j 分别有不同的数据分布特征。那么对于客户端 P_i 和 P_j 来说数据分布是统计异质性的，也即 Non-IID 分布。在联邦学习中进行有监督学习时，每一个样本特征 $\mathbf{x}$ 都有对应的标签 y ，在选定客户端中，对于带标签样本 $(\mathbf{x}, y)$ 的有监督数据集，其分布表示为 $P_i(\mathbf{x}, y)$ 。根据不同客户端之间样本分布的差异，联邦学习中的数据 Non-IID 可以分为特征分布偏斜、标签分布偏斜、同标签不同特征、同特征不同标签和数量偏斜等五种情况。

特征分布偏斜是指不同客户端之间的特征分布 $P_i(\mathbf{x})$ 存在差异，而条件分布 $P_i(y|\mathbf{x})$ 在不同客户端之间是相同的。也就是说，尽管各个客户端的数据在特征层面的分布不一致，但给定特征 $\mathbf{x}$ 时，标签 y 的条件分布是相同的。例如，在手写识别领域中，不同用户写相同单词可能有不同的笔锋特点、字体胖瘦等特征表现形式。这种特征分布的差异会导致不同客户端的数据在特征层面呈现出异构性，从而给联邦学习模型的训练带来挑战。

标签分布偏斜是指不同客户端之间的标签分布 $P_i(y)$ 存在显著差异。这意味着每个客户端的数据集中，不同类别的样本数量分布不均衡。例如，在一个图像分类任务中，一个客户端可能大部分是飞机的图片，而另一个客户端则大部分是麻雀的图片。这种标签分布的不均衡会导致全局模型在训练时难以平衡不同客户端的数据特性，从而影响模型的整体性能。标签分布偏斜是联邦学习中 Non-IID 数据的一种常见形式，它会给模型训练带来诸多挑战，如模型收敛困难、性能不稳定等。为了应对标签分布偏斜问题，研究者们提出了多种方法，例如 FedConcat^[33] 算法，通过模型连接而非传统的平均方法来聚合本地模型，从而更好地利用不同客户端的标签分布信息。

同标签不同特征可以理解作为一种特殊的特征条件偏斜，即 $P_i(\mathbf{x} | y)$ 对于不同的客户端是不同的，并且 $P_i(y)$ 是相同的。例如，相同的建筑物，东方国家和西方国家具有不同的建筑风格。在东西方国家，居民建筑和商业建筑的类型和比例大概是相同的，但是东西方居民楼的建筑特点差异显著。这种特征偏斜会使不同客户端训练时关注不同的特征，从而影响全局模型的聚合效果。

具有相同特征的不同标签意味着 $P_i(y | \mathbf{x})$ 对于不同的客户端是不同的，并且 $P_i(\mathbf{x})$ 是相同的。也就是说，在不同客户端的数据集中，相同的特征可能被不同的标签标记。例如，某些植物在不同地区可能被不同的名称标记。这种情况下，由于相同的特征对应不同的标签，模型难以在不同标签分布之间找到一致的规律，模型可能会在训练过程中产生混淆，导致性能下降，限制模型在不同客户端上的泛化能力。

数量偏斜是指不同客户端数据的数量差异很大。例如在物联网中，不同地区的传感器数据量可能不同，某些地区的传感器可能更密集，数据量更大；其他一些地方的传感器可能数据比较少，使用频率更低。这种数据量不均衡可能导致模型在不同客户

端上的性能差异较大,数据量少的客户端对全局模型的贡献较小甚至会造成负向影响,最终影响全局模型性能。

2.2.1 非独立同分布数据划分方法

Hsieh^[34]指出,解决 Non-IID 数据问题的难易程度取决于其偏差程度。在实验场景中为构建不同的数据分布需要设置多种不同的 Non-IID 数据划分策略。根据不同的 Non-IID 场景需要,本文将介绍几种常用的联邦学习中划分数据 Non-IID 的方法。

迪利克雷(Dirichlet)分布是研究中最常用的 Non-IID 数据划分方法^[35],它可以被用来模拟多种不同的 Non-IID 场景。迪利克雷分布的公式为公式 2.2。其中, x 需要满足 $\sum_{i=1}^K x_i = 1 (\forall x_i \in \mathbf{X}, x_i > 0)$,表示样本在客户端中的分布。 $B(\alpha)$ 是 α 的函数,迪利克雷分布表达式为公式 2.3。其中浓度参数 α 控制数据异质性的程度,是一个与变量 X 维度数相同的向量。较低的值会产生偏斜程度更大的分布,而较高的值会使数据分布更接近 IID 分布条件。这种方法允许生成一系列真实的 Non-IID 数据集来评估不同程度的数据不平衡。迪利克雷分布可以模拟生成包括 β 分布以及均匀分布。因此,它可以被很好的用于 Non-IID 的数据拆分^[36]。

$$D(\mathbf{X}|\alpha) = \frac{1}{B(\alpha)} \prod_{i=1}^K x_i^{\alpha_i-1} \quad (2.2)$$

$$B(\alpha) = \frac{\prod_{i=1}^K \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^K \alpha_i)} \quad (2.3)$$

部分比例数据 Non-IID 划分^[37]是另一种常用的 Non-IID 划分算法。这种方法通过调整比例系数控制一定比例的数据呈 Non-IID 分布,剩下的数据实施跨客户端的 IID 分布划分。例如,20% 的 Non-IID 表示 20% 的数据集是基于标签进行 Non-IID 划分的,而其余 80% 被随机均匀地划分。通过改变百分比,可以实现数据集分布中的不同程度偏斜,从而允许进行具有不同异质性程度的联邦学习实验。

Sharding 方法^[38]是另外一种创建 Non-IID 数据的算法,该方法创建的数据分布中不同客户端中极少含有重复的类别标签,可以用于创建极端 Non-IID 的联邦学习数据分布。它首先获得完整的数据集,然后通过类标签对它们进行排序,之后将它们划分为大小相等的较小数据集(即分片)。这些分片分布在客户端之间,每个客户端接收固定数量的分片。由于每个分片仅包含来自单个类别的数据,因此客户端具有仅表示整体类分布的一小部分的数据。因为客户端主要拥有来自少数类别的样本,并且它们在客户端之间不重叠,这种方法可以创造高度偏斜的 Non-IID 分布。其中,当每个客户端只持有一个类的情况为病理分布^[39]。在本文的具体实验中,主要使用迪利克雷分布和 sharding 方法,以控制不同程度的 Non-IID 数据分布。

2.2.2 解决非独立同分布问题的联邦学习算法

横向联邦学习中, Non-IID 条件下, 不同客户端之间数据的分布差异会极大影响客户端的模型收敛水平, 因此其不同本地模型之间性能差异显著, 然而, FedAvg 等联邦学习算法本身无法处理由 Non-IID 数据引起的模型发散问题。因此一些算法专注于解决不同场景中的联邦 Non-IID 问题。当前常用的解决思路包括从数据角度出发, 从算法角度出发以及从系统角度出发。

在存在 Non-IID 数据的情况下, 联邦学习的性能退化是由异构数据分布引起的, 因此, 最直观的, 基于数据的方法可以通过修改分布从根本上来减轻或者解决这个问题。其中, 数据共享和数据增强是两种最主要的解决方案。

数据共享^[40]是一种简单有效的解决联邦学习 Non-IID 问题的策略。该方法的一般思想为在全局服务器中使用一个均匀分布的共享数据集 G , 并通过训练 G 对全局模型进行预训练。此外, 将全局数据集 G 的随机一部分下载到所有连接的客户端, 以便本地训练数据和来自 G 的共享全局数据作为本地知识更新客户端模型。该算法可以补全本地数据集的部分种类数据缺失, 但是全局数据的获取在某些场景中不易获得并且全局数据集 G 在本地数据中所占的比例也会很大程度影响模型的性能。数据增强最初是一种通过一些随机变换或知识转移来增加训练数据多样性的技术, 在联邦学习中也可以用于丰富可训练的数据集。联邦学习中使用的数据增强方法主要有三种: vanilla 方法、mixup 方法和基于生成对抗网络的方法。Astraea^[41]中首次提出使用 vanilla 数据增强的方法, 其中每个客户端都需要将其标签分布信息, 如不同类别的样本数量发送到服务器。然后服务器可以计算每个类别的平均样本数。如果客户端在该类别中样本数少于平均数量, 则该客户端会生成一定数量的样本进行本地数据的补充。mixup 是处理 Non-IID 数据的另一种数据增强方法。Shin 等人^[42]首先使用 mixup 提出了一个 XorMixFL 框架。核心思想是每个客户端将其编码的种子样本(使用 XOR 算子编码)上传到服务器进行解码, 基础数据样本与服务器中的解码样本一起可以构建一个新的平衡数据集。之后, 根据这些重建的数据训练一个全局模型, 并将其下载到每个客户端, 直到训练收敛。Yoon 等人提出了一种联邦学习策略在客户端与服务器传输平均的本地数据以消除不同客户端的数据异质性差异^[43], 该算法是 mixup 策略在联邦学习中的扩展应用, 并且在不影响模型性能的前提下很好的保护了本地数据隐私。联邦学习中 GAN 算法旨在在 Non-IID 数据的情况下训练生成器。生成器在服务器中进行训练^[44], 使用客户端共享的数据, 最后将其交付给客户端。最终可以使用它来补充缺失的训练数据来获得更平衡的本地数据集。尽管被证明是有效的, 但以上基于数据增强的技术中的大多数都依赖于数据共享, 这可能会增加数据隐私泄露的风险。

通过改变本地更新的算法等手段减少客户端之间差异对全局聚合带来的影响是

另外一类解决 Non-IID 问题的策略。一类算法上的改进是通过构建高性能的初始模型来实现模型微调。Per-FedAvg^[45] 利用与模型无关的元学习来查找初始全局模型,使本地客户端更容易获得良好的性能,而计算成本低。此外,该算法利用二阶导数等改善了本地更新的方式,这些改进使得该算法获得了比 FedAvg 更好的收敛性能。局部和全局信息相结合是另一种改进方法。Hanzely 等人通过添加正则化项来约束本地模型,使得在本地更新时能够与全局模型保持较高相似性,在本地更新使用正则项缩小了不同客户端之间的模型差异^[46]。正则化的目的是最大限度地减少全局模型和本地模型之间的差异,而一般的 FedAvg 可以被视为基于正则化的个性化的特殊情况。Liang 等人提出了一个 LG-FEDAVG^[47] 以利用个性化层解决联邦学习中的 Non-IID 问题,其中个性化层是神经网络的特征提取层,与全局模型共享深层分类器作为共享的基础层。因为只需要在服务器和客户端之间共享基础层而不是整个模型,个性化层不仅能够提高 Non-IID 数据的学习性能,还可以降低通信成本。联邦知识蒸馏是解决 Non-IID 问题的另一有效策略,联邦蒸馏(Federated Distillation, FD)^[48] 是将共蒸馏算法扩展到联邦学习框架的方法。由于在联邦学习中,每个客户端具有的样本不一致,因此无法直接对每个模型进行知识传输。为了解决这个问题,FD 提出了一种基于平均的知识传输方法。该方法将每个客户端上每个类别的预测概率向量进行平均处理,从而得到一个全局的预测概率向量,然后将其发送给每个客户端,作为监督信号来指导模型的学习。这种方法具有显著提高模型精度和鲁棒性、减少计算和通信开销的优点,并适用于联邦学习这种分布式场景。

此外,对联邦学习算法框架进行适当调整是一种有效的解决 Non-IID 问题的策略。一般而言,联邦学习方法都假设整个系统只包含一个全局模型,这很难学习所有客户端信息,尤其是在异构数据环境中。因此,聚类相似的客户端进行联邦学习^[49] 或者将联邦学习聚合成多个不同的全局模型^[49] 是解决 Non-IID 问题的一类重要解决方案。

2.3 对比学习算法

对比学习最初是一种无监督学习算法,它通过使用未标记的数据来学习有用的视觉表示^[50]。学习到的模型为下游的少标签任务的微调提供了良好的初始化,以此利用少量标注数据来充分提取样本的特征。对比学习利用不同类别实例之间特征的差异以及相同类别样本之间特征的相似性,最大限度地提高了同类数据集的特征表示的辨识程度,并最大化了来自不同类别样本的特征表示之间的差异^[51]。

自监督对比学习基本原理是通过对比正样本和负样本,将属于同一个类别或具有相似语义的样本映射到特征空间中更接近的位置,将不同类别或语义无关的样本映射到特征空间中较远的位置。自监督对比学习中通常正样本是同一样本的不同数据增

强，负样本是其他不同样本的数据增强。这种将样本进行多次不同的增强以作为同类标签的技巧可以使模型能够通过对比学习区分不同的数据特征，而无需显式的人工标签，极大地降低了数据标注成本。

自监督中有几种对比学习损失，包括对比损失（Contrastive Loss），信息噪声对比估计损失（Information Noise-Contrastive Estimation Loss, InfoNCE Loss）以及三元组损失（Triplet Loss）等。对比损失作为一种经典的对比学习损失函数，最早由 Hadsell 等人于 2006 年提出^[52]，并广泛应用于人脸识别、图像检索等任务。该损失主要用于训练孪生网络，通过优化样本间的欧几里得距离来学习鲁棒的特征表示。其基本思想是：对于相似样本对，其特征向量之间的距离应尽可能小，而对于非相似样本对，其距离至少应大于一个预定义的边界参数，从而确保类别可分性。

对比损失的定义如公式 2.4 所示：

$$\mathcal{L}_C = \frac{1}{2N} \sum_{i=1}^N (y_i d_i^2 + (1 - y_i) \max(0, m - d_i)^2) \quad (2.4)$$

其中， y_i 为二元标签，表示样本对是否属于同一类别， d_i 为样本对的欧几里得距离， m 为超参数边界参数。在优化过程中，该损失函数通过最小化相似样本之间的距离，同时拉开不同类别样本的距离，使得模型能够学习到有判别力的嵌入空间。

对比损失适用于无类别标签的任务，并能直接优化样本间的距离。然而，该方法仅考虑两两样本的关系，信息利用率较低，容易受到边界参数选择的影响。为了解决这些问题，Schroff 等人^[53]提出了三元组损失，该方法通过锚点（Anchor），正样本（Positive），负样本（Negative）三元组的方式进行优化，使得正样本比负样本更接近锚点，从而增强模型的判别能力。

三元组损失的提出主要来源于人脸识别任务中的度量学习需求，其核心思想是通过优化样本之间的相对距离，使得同类别样本的特征更加紧密，而不同类别样本的特征更加分离。三元组损失的基本原理是基于一个三元组，其中锚点是一个参考样本，正样本是与锚点同类别的样本，负样本是与锚点不同类别的样本。损失函数的优化目标如公式 2.5 所示：

$$d(f(\mathbf{x}_a), f(\mathbf{x}_p)) + \alpha < d(f(\mathbf{x}_a), f(\mathbf{x}_n)) \quad (2.5)$$

其中 $d(\cdot, \cdot)$ 表示样本之间的欧氏距离， α 是预设的间隔。根据以上优化目标，其相应的损失函数定义如公式 2.6 所示：

$$\mathcal{L}_T = \sum_i \max(0, d(f(\mathbf{x}_a^i), f(\mathbf{x}_p^i)) - d(f(\mathbf{x}_a^i), f(\mathbf{x}_n^i)) + \alpha) \quad (2.6)$$

它直接优化样本之间的相对距离，保证了同类别样本之间的距离更小，而不同类

别样本的距离更大, 更适合进行对比学习。此外, 该损失不像 Softmax 损失需要固定类别数, 三元组损失能很好地泛化到新类别, 例如人脸识别和检索任务, 可以适用于更多样化的场景。三元组损失由于梯度极度依赖于特定的负样本, 如果负样本选择不当会导致梯度消失或者梯度爆炸等, 收敛过程中梯度不稳定; 三元组损失仅仅衡量三元组样本之间的相对距离, 而某些时候特地选取的三元组很难代表真正的不同类别之间特征分布情况。为了解决以上挑战, InfoNCE 损失由 Aaron 等人^[54]在 2018 年提出。

InfoNCE 损失可以衡量不同样本特征值之间的方向差异^[55], 由于在特征空间中, 对于样本特征分类时常用线性分类器操作, 其公式为: $\mathbf{y} = \boldsymbol{\omega}^T \mathbf{X} + \mathbf{b}$ 。在神经网络后零误差阶段的研究^[56]表明, 在各类别上保持独立同分布的数据集中提取的特征, 来自不同类别的特征的模值趋于相似长度。在这个前提条件下分析, 影响特征向量分类的条件仅仅依赖于其角度属性, 那么衡量不同的特征之间的角度差异, 并且将相同类别的特征向量角度拉近可以很容易区别不同的类别。InfoNCE 损失的基本形式是基于一个查询 $\mathbf{q}$ 及其对应的一个正样本 $\mathbf{k}^+$ 和 N 个负样本 $\mathbf{K}^-$, 目标是使得 $\mathbf{q}$ 与 $\mathbf{k}^+$ 之间的相似度尽可能高, 而与所有 $\mathbf{K}^-$ 之间的相似度尽可能低。其损失函数定义如下:

$$\mathcal{L}_I = -\log \frac{\exp(\text{sim}(\mathbf{q}, \mathbf{k}^+)/\tau)}{\sum_{k=1}^N \exp(\text{sim}(\mathbf{q}, \mathbf{z}_k)/\tau)} \quad (2.7)$$

其中, $\text{sim}(\mathbf{q}, \mathbf{k})$ 通常表示 $\mathbf{q}$ 和 $\mathbf{k}$ 之间的点积或余弦相似度, τ 是温度参数, 用于控制分布的平滑度。 $\mathbf{z}_k$ 来自正样本 $\mathbf{k}^+$ 和负样本 $\mathbf{K}^-$ 的集合。

相较于其他损失, InfoNCE 损失能有效地学习高质量的表示, 特别是在无监督表示学习中, 如 SimCLR^[57]。它不需要明确的标签信息, 而是通过数据增强等手段构造正负样本对, 使得模型能够在没有人工监督的情况下学习到有用的特征。此外, InfoNCE 通过优化能够提高查询向量和正样本之间的信息量, 最大化利用数据集中的互信息。

对比学习是用来解决联邦学习中 Non-IID 数据问题的一种常用的迁移学习策略。MOON^[58]是第一个将对比学习应用于联邦框架的算法。该算法旨在基于模型对比学习解决 Non-IID 数据问题。与标准的对比算法不同, 它通过将当前本地模型的特征表示与上一轮的本地模型和全局模型的特征表示进行比较, 最大限度地提高了当前本地模型和全局模型之间的特征相似性, 从而防止了对本地缺失数据的全局知识遗忘。然而, 由于需要计算多个对比模型, 该算法具有较高的时间复杂度和内存要求。FedPCL^[59]共享类的原型特征向量而不是模型参数, 利用预先训练的模型来构建针对特定任务定制的联邦模型。然而, 这只是对预训练的模型的微调, 有很大的局限性。FedProc^[60]利用类的原型特征向量作为全局特征表示来校正本地训练。该算法计算类原型与客户端本地数据特征之间的相似性, 确保每个客户端模型的本地特征表示不会偏离全局原型。这将在一定程度上缓解本地模型的优化方向的漂移现象。

2.4 等角紧框架分类器理论

许多研究^[61]表明, 各类数据样本量均衡的训练中, 在神经网络后训练阶段, 神经网络的分类误差可以趋近于零, 并且训练损失也可以趋近于零。在这种零误差训练阶段, 神经网络结构与参数往往呈现出一些数学上的规律, 这个过程可以被称之为神经崩溃 (Neural Collapse, NC)。在神经崩溃阶段, 神经网络的激活函数以及最后一层分类器会呈现以下四种特点^[56]:

- (1) 特征的不可变性崩溃: 随着训练的进行, 来自样本的激活特征逐渐逼近它们的类均值, 来自同一类别的不同样本的激活特征向量的差异变得可以忽略不计。
- (2) 收敛到单纯形等角紧框架: 以全局均值为中心, 每个类别激活特征向量的均值向量, 即类均值, 收敛到相等的模长, 在任何给定类均值对之间形成大小相等的角度, 并且在约束这两个属性的前提下, 互相之间的角度尽可能拉大。这种属性被称为单纯形 ETF。
- (3) 收敛到自对偶性: 类均值和线性分类器在特征空间中相互收敛直至重合, 这意味着神经网络的分类器在决策过程中针对不同的类别完全对称: 不同分类器之间的决策边界通过刚性欧几里得旋转运动与其他不同的类别之间的决策边界是相等的, 也就是说不同类别的决策边界在数学上是完全可以互相替换的; 此外, 类均值都位于它们自己的特定区域内, 因此不存在任何两个类别之间的混淆度高于其他任意两个类别的倾向。
- (4) 简化为最近的类中心 (Nearest Class Center, NCC): 对于给定的深度网络的激活特征向量, 模型的分类器收敛到在标准欧几里得距离中最近的类均值向量中。

在联邦学习中, 客户端需要将本地梯度信息发送给服务器, 将 ETF 结构替换根据梯度更新的分类器可以减少模型的参数量, 减少通信成本, 同时保持模型信息的完整性。并且由于其等角紧框架的特性, ETF 能够提供最优的特征分布, 使得不同客户端的参数分布更加均匀, 从而减少模型训练中的偏差, 所以可以利用 ETF 的数学特点预设联邦学习的分类器参数, 减少数据的 Non-IID 带来的不同本地模型之间的梯度偏移。

为了将 ETF 属性应用于深度学习甚至联邦学习中, 本文首先需要明确 ETF 的相关性质, 方便进行 ETF 分类器的构造。标准的简单 ETF 框架如公式 2.8 所示。

$$\mathbf{M}^* = \sqrt{\frac{C}{C-1}} \left(\mathbf{I} - \frac{1}{C} \mathbf{J} \mathbf{J}^\top \right) \quad (2.8)$$

其中 $\mathbf{I} \in \mathbb{R}^{C \times C}$ 是对角线为 1 的单位阵; $\mathbf{J} \in \mathbb{R}^{C \times C}$ 是全一矩阵; C 是分类器输出的最后一个维度, 表示分类器的分类类别。

基于对平衡数据集中 ETF 的研究成果, Yibo 等人^[62]将 ETF 框架扩展到集中式

学习的长尾分布中，首次利用 ETF 的特性解决数据不平衡问题带来的模型收敛问题。他们发现，在该框架下使用平方损失函数可以实现更快的收敛速度和性能提升。这一发现为长尾学习问题提供了新的视角，通过优化损失函数的方式，能够有效改善模型在类别不平衡数据集上的表现。

受近年来神经崩塌研究突破的启发，2023 年，FEDETF^[63] 首次将等角紧框架策略应用于联邦学习，以应对数据异构性带来的挑战，并通过微调实现了个性化本地模型的优化。该算法的核心思想是引入一个固定的 ETF 分类器，所有客户端在训练过程中使用这一统一的分类器结构，从而避免了因数据分布不均导致的分类器偏差。在训练过程中，FEDETF 只学习和聚合特征提取器和投影层，通过一种新颖的平衡特征损失函数来优化特征表示，减少类别不平衡对模型性能的影响。此外，FEDETF 还设计了本地微调策略，在联邦学习训练结束后，通过微调特征提取器和分类器，进一步提升模型在本地数据上的个性化性能。FEDETF 的主要贡献在于首次从神经崩塌的角度出发，解决了联邦学习中的数据异构性问题，并通过固定 ETF 分类器的框架显著提高了全局模型的泛化能力。然而，他们并未考虑某些类别在任何客户端中几乎不存在的情况。

2.5 本章小结

本章介绍了本文研究算法所涉及的相关理论基础与算法研究，包括联邦学习算法的基本框架及对比学习，等角紧框架分类器等重要理论基础。在联邦学习理论基础部分，介绍了联邦学习的基本框架以及横向联邦学习中 Non-IID 问题的常见分类以及应对 Non-IID 问题的解决策略，系统的分析了解决联邦 Non-IID 问题的策略。在对比学习算法小节中介绍了对比学习的基本原理以及常用的损失，并且介绍了对比学习在联邦学习中的应用，对比学习虽然可以用于解决数据不均衡问题，但是由于其本质是从无监督训练的角度出发，在特征空间中将同类样本聚集，所以在分布式的联邦学习中应用受限，本文算法将从这一角度出发将对比学习应用于解决联邦 Non-IID 问题；在等角紧框架中介绍了神经崩溃下等角紧框架的相关性质和原理，并且介绍了一种利用等角紧框架解决联邦学习个性化任务的应用，然而在个性化之后的模型显然不适合继续进行联邦学习，这不利于联邦学习的持续更新，本文将从建立性能优秀的全局模型角度出发，将 ETF 结构应用于联邦 Non-IID 问题中。这些重要理论为本文的算法的研究提供了坚实的理论基础并且启发了本文中的算法设计。

3 基于对比学习的联邦学习算法

在一般场景的 No-IID 数据集中，不同客户端通常有相同的样本类别，并且样本总量在不同类别中是独立同分布的，也就是不同类别样本对全局模型具有相同的贡献。但是不同客户端的不同类别的样本数量具有较大的差异。在这种 Non-IID 场景中，传统的聚合算法会由于不同客户端之间的 Non-IID 问题导致模型偏移，从而影响全局模型收敛效率。针对这种 Non-IID 问题，本文提出一种使用分类器辅助的联邦对比学习算法（Classifier-Augmented Federated Contrastive Learning, CAFedCon）来进行全局的对比学习，从而利用全局样本之间的互信息促进联邦学习的训练效率。

3.1 算法介绍及适用场景

3.1.1 适用场景

在联邦学习中，由于不同客户端持有的数据通常具有高度倾斜的分布，这种 Non-IID 分布属性通常会损害联邦学习的收敛速度和收敛精度。在一般的 Non-IID 场景中，不同客户端之间的样本类别是相同的，但是不同类别的样本数量有较大差异，如图 3.1所示。研究这种一般的，非极端的联邦学习 Non-IID 场景，可以在一定程度上增加联邦学习的稳健性，对联邦学习在实际场景中的广泛应用具有重要意义。

在现实生活中，假设有两个不同地点的金融参与方：两个不同的金融参与方均承




图 3.1 一般 Non-IID 分布情况

Fig. 3.1 General Non-IID distribution scenarios

担金融借贷, 储蓄, 金融抵押等金融和理财项目。但是由于两个金融参与方的地域文化差异, 可能甲参与方的客户更多偏向于一些政企业务; 而乙参与方可能客户中个人客户占更大比重。然而, 由于两个不同参与方的业务类型基本完全重合, 来自客户的样本分类几乎相同, 只是客户偏好是不同的。这是现实场景中经常会出现的一种 Non-IID 场景。尽管在部署横向联邦学习时, 最理想的状态是来自不同参与方的数据是完全 IID 的, 但是就如世界上没有两片完全一样的树叶一样, 不同的参与方之间的概率分布也会呈现一定的差异。在这种场景中, 可以利用本章算法提高联邦学习的算法精度, 从而扩展联邦学习的适应场景。

对比学习通过学习区分相似和不相似的样本对, 能够生成更具区分性的特征表示。这种表示不仅有助于提高模型在少数类别上的性能, 还能增强模型对不同类别数据的泛化能力, 因此对比学习比使用分类器的监督学习更适合面对各类别样本数量不均衡的场景。然而在联邦学习中, 由于不同客户端往往是本地模型进行优化, 之后将本地模型发送到全局服务器进行聚合, 在本地训练过程中缺少客户端参与方之间的互相沟通。对比学习在训练过程中将相似的样本在特征空间中拉近, 而不相似的样本则推远。具体来说, 对比学习通过数据增强生成正样本对, 并将其特征表示拉近; 同时, 通过负样本对, 将其特征表示推远。对比学习通过最小化某种对比损失函数, 如 InfoNCE 损失, 使得正样本在特征空间中的距离被拉近, 负样本的距离被推远。这个过程实际上是在优化正对图的结构, 使得相似的数据点在特征空间中更紧密地聚集在一起。而在联邦学习中由于不同参与方之间缺乏联系, 不同客户端模型在自由空间中使用无监督的对比学习会很容易导致特征空间的旋转, 从而使得不同本地客户端不能在统一的特征空间中进行相似特征的聚类, 导致聚合后的模型失去了本地模型的有序的特征空间, 这是影响对比学习在联邦学习中部署的关键问题。

为了使用对比学习解决联邦学习中的一般性的 Non-IID 问题, 本章通过利用分类器辅助对比学习, 使得在联邦学习的不同参与方之间建立了同一的投影特征空间, 从而方便不同参与方之间进行对比学习, 防止了对比学习中的特征空间的旋转, 将对比学习的优势应用于联邦学习, 利用样本中的互信息进一步提高模型性能, 从而解决联邦学习中由于 Non-IID 问题导致的不同客户端之间样本数量分布不一致的问题。

3.1.2 算法介绍

假设以下联邦学习场景: 有 m 个客户端 ($P_1, P_2, \dots, P_m$), 每个客户端拥有的数据 ($D^k, k \in (1, m)$) 互不重复且不可互相传递, 另外还有一个中央服务器 *server*。所有客户端共同在 *server* 中维护一个共同的全局模型 M , 并且每一个客户端 i 都有一个本地模型 M_i , 本地模型与全局模型具有相同的结构并且在本地训练时从全局模型开始初始化。

在联邦学习中考虑以下异质性场景: 对于不同的数据参与方, 不同参与方具有相

算法 3.1 CAFedCon 算法整体框架

Input: 客户端数量 n , 全局通信轮次 T , 本地更新轮次 E , 模型参数 M , 本地更新学习率 η , 模型输出样本特征 z , 模型输出样本概率 y , 分类器参数拆分成的向量集合 w , 客户端集合 C

Output: 全局模型 M

```

1: 初始化全局模型参数  $M$ 
2: for  $t = 1, 2, \dots, T$  do
3:   for 对于所有选定的客户端  $c \in C$  do
4:     下载全局模型到本地并使用全局模型初始化本地模型  $M_{local} \leftarrow M$ 
5:     for  $e = 1, 2, \dots, E$  do
6:       本地保存全局模型参数  $M_{global}^{t-1} \leftarrow M_{local}$ 
7:       从全局模型中计算特征  $z_{global} \leftarrow M_{global}^{t-1}$ 
8:       得到全局模型中的分类器参数拆分的向量  $z_{w_{global}} \leftarrow (M_{global}^{t-1}, w)$ 
9:       从本地模型中计算特征  $z_{local} \leftarrow M_{local}^{t-1}$ 
10:      从 Eq. (3.5) 计算损失  $\mathcal{L}_{BCE}$ 
11:      根据 Eq. (3.7) 计算损失  $\mathcal{L}_{Con}$ 
12:      根据 Eq. (3.8) 计算总损失  $\mathcal{L}$ 
13:      根据 Eq. (3.8) 计算梯度更新本地模型  $M_{local}^e \leftarrow M_{local}^{e-1} - \eta \cdot \vec{\nabla} \mathcal{L}$ 
14:    end for
15:  end for
16:  根据公式 Eq. (3.2) 更新全局模型  $M \leftarrow$  使用公式 Eq. (3.2) 聚合模型.
17: end for
18: return 全局模型  $M$ 

```

同的标签类别, 但是标签数量分布并不相同 $P_i(y) \neq P_j(y)$ 。本文希望在这种数据异质性条件下, 实现以下优化目标:

$$\mathcal{L} = \arg \min \sum_{i=1}^K p_i \cdot \mathcal{L}_i \quad (3.1)$$

其中 p_i 是第 i 个客户端的权重, 一般根据其样本数量来确定具体的值, $\mathcal{L}_i$ 是客户端 i 的本地损失函数。本文希望在 m 个参与方的协作下, 共同训练一个全局模型, 这个模型较所有本地数据训练的模型具有准确度优势。另外还有一个中央服务器 *server*, 用于进行聚合以及全局模型的上传和下发工作。

在有监督对比学习上的研究^[51, 64]表明最小化对比学习损失促进了单位超球面上特征的对齐和均匀属性, 这会导致有监督对比学习损失容易获得比交叉熵更好的效果。基于以上先验知识, 许多算法将对对比学习应用于集中数据学习的长尾分布中, 如 Audibert^[65]利用对比学习的队列解决长尾问题数据量差异导致的部分类别正标签的缺失, 从而维护一个平衡的数据分布。然而在联邦学习中^[66], 不同客户端由于数据分布差异导致特征空间不一致; 即使客户端的训练数据是独立同分布的, 并且不同局部模型编码的特征空间是一致的, 然而由于训练过程中的随机性, 不同客户端模型特




图 3.2 不同模型特征空间旋转示意

Fig. 3.2 Illustration of model feature space rotation

征之间仍可能存在错位。例如，对于给定的输入样本集 $\mathbf{X}$ ， A 模型生成的特征表示可能会相当于另一个模型 B 在旋转一定角度时生成的表示，如图 3.2 所示。更重要的是，本地模型之间的旋转位移可能会对聚合模型的性能产生巨大的不利影响。为了减少不同客户端之间的特征空间不一致的问题，本文尝试建立跨客户端统一的特征空间。在集中式深度学习中，BCL^[67] 算法利用分类器辅助对比学习建立平衡的特征空间，防止某些类别样本数量减少对对比学习特征空间的影响。受该算法启发，本算法使用一种双分支网络来利用分类器辅助对比学习建立跨客户端的统一的特征空间，从而将对比学习应用于联邦 Non-IID 空间中。值得注意的是，虽然该算法可以克服不同类别的数量差异影响，但是如果某些类别缺失，将会使得在对比学习中忽略这一类别的特征，从而导致本地特征空间发生较大改变，严重影响全局模型收敛。

本算法总体流程与联邦平均算法相似。在全局服务器首先生成随机的全局模型，然后本地客户端下载全局模型，之后本地客户端进行多轮本地训练并进行梯度更新。在本地训练结束之后将本地模型上传到服务器，之后全局服务器利用公式 3.2 进行加权平均，获得全局模型。其中 $\mathbf{M}$ 是模型参数， k 是客户端编号， t 是全局通信轮次， n_k 为客户端 k 样本数量， n 是所有客户端样本总量。算法流程如算法 3.1 所示。

$$\mathbf{M}_{t+1} \leftarrow \sum_{k=1}^K \frac{n_k}{n} \mathbf{M}_t^k \quad (3.2)$$

本算法的主要创新点在于在本地训练时将对比学习应用于联邦学习以解决联邦学习中的 Non-IID 问题。在本地训练时，本算法的创新点包括建立双分支的网络模型框架以及使用适应 Non-IID 的平衡损失函数。在该模型中，本地模型包括一个特征提取器，一个分类器和一个投影头。其中分类器和投影头被并列连接到特征提取器之后，用于预测特征类别以及进行对比学习。

在本地训练过程中，包括两个模型，分别是本地模型和全局模型，其中本地模型从全局模型开始初始化，本地模型可以进行梯度更新，全局模型不参与梯度更新，其

作用是作为本地训练的参考模型，辅助本地模型建立特征空间，使得本地特征空间不偏离全局模型的特征空间太远的距离。首先本地样本 $\mathbf{x}$ 经过两次不同的数据增强得到两个不同的增强后的样本 $\mathbf{x}_a, \mathbf{x}_b$ ，这里的作用是为了将样本进行数据增强作为同类样本的正样本，增加样本之间的互信息。之后将两个样本 $\mathbf{x}_a, \mathbf{x}_b$ 同时输入特征提取器 $f(\cdot)$ 得到不同的特征 $\mathbf{z}_a, \mathbf{z}_b$ ，将其中一个特征 $\mathbf{z}_a$ 输入分类器 $h_1(\cdot)$ 得到样本的预测概率向量 $\mathbf{y}_{local}$ ，之后利用其标签信息与其输出的预测概率向量 $\mathbf{y}_{local}$ 使用平衡交叉熵损失函数计算基于分类器学习的交叉熵损失。另外一个特征 $\mathbf{z}_b$ 经过投影头 $h_2(\cdot)$ 映射到对比学习的特征空间中去，得到对比学习特征 $\mathbf{z}_{local}$ 。对于全局模型也进行类似的流程，将本地样本 $\mathbf{x}$ 经过数据增强的样本 $\mathbf{x}_b$ 输入全局模型，经过特征提取器之后得到中间特征 $\mathbf{z}_b^{global}$ ，然后将特征输入全局模型的投影头 $h_2(\cdot)$ 将其投影到对比学习的特征空间，得到全局模型的输出特征 $\mathbf{z}_{global}$ 。然后对全局模型的分器 $h_1(\cdot)$ 参数 $\mathbf{w}(\mathbf{w} \in \mathbb{R}^{n \times m})$ 进行拆分，拆成 n 个长度为 m 的向量 $\mathbf{w}_g$ 。其中 n 是类别数量， m 是输出预测概率向量的长度。将分类器向量 $\mathbf{w}_g$ 输入投影头得到辅助对比特征 $\mathbf{z}_{w_global}$ ，然后利用全局模型输出特征 $\mathbf{z}_{global}$ 和来自全局模型的分器的辅助特征向量 $\mathbf{z}_{w_global}$ 作为对比学习的对比特征，与本地模型的输出特征 $\mathbf{z}_{local}$ 进行对比学习，从而保证本地训练时对比学习不会偏离全局模型的特征空间。最后将对比学习和交叉熵损失加权求和，根据损失进行本地模型更新。其本地训练整体结构框架如图 3.3 所示。

3.2 算法框架

3.2.1 双分支网络

为了利用全局模型的分器约束本地对比学习的特征空间，本算法提出一种适用于联邦对比学习的双分支网络模型。该网络模型主要由三个部分组成，分别是共享的特征提取模块，用于对比学习的投影模块以及用于分器训练的分器头。其中，特征提取模块为任意的神经网络，其作用是提取来自样本的特征，特征提取模块的参数对于投影层和分器头来说是共享的。在实验中主要使用卷积神经网络（Convolutional Neural Network, CNN）以及残差网络（Residual Network, ResNet）作为本算法模型的特征提取器。

传统的 CNN 是一种简单的用于解决视觉问题的层级神经网络基本模块。该模块主要结构包括卷积层、池化层和激活函数。其中卷积层是一个可自适应的滤波器，其作用是提取样本中的边缘信息从而获得基础的纹理特征。池化层的作用是对特征进行有效压缩同时尽可能保存其信息量，从而防止过拟合。激活函数是一类非线性函数，用来保证一些复杂映射关系的拟合。这种层次结构使得 CNN 能够有效地学习图像中的层次化特征，从低级的边缘、纹理到高级的形状和物体部分。残差网络是一种深度卷积神经网络，于 2016 年由微软研究院的何凯明等人^[68]提出。ResNet 通过在传统




图 3.3 使用分类器辅助的联邦对比学习算法本地梯度更新流程

Fig. 3.3 Local gradient update process of Classifier-Assisted Federated Contrast Learning algorithm

CNN 中引入残差块解决了深度网络中的梯度消失问题，使得网络可以训练到上百甚至上千层。残差块的核心思想是在网络中引入恒等映射的跨层连接，即通过跳跃连接将前一层的输出直接加到后续层的输出上，这样网络可以更容易地学习残差映射，即输入与输出之间的差异部分。这一机制不仅缓解了梯度消失的问题，还增强了网络的信息传递能力，使得 ResNet 在图像分类任务中取得了显著的性能提升，并成为深度学习中广泛使用的网络结构。ResNet 的架构设计具有很高的灵活性和可扩展性，可以通过调整残差块的数量和结构来适应不同的任务需求。相比较于传统 CNN，ResNet 更容易建立深层网络而无需结构设计，并且能够获得比 CNN 更好的性能，因此往往更加适用于更具有挑战性的分类问题，如图 3.4。在该算法中，传统 CNN 和带残差块的 ResNet 网络均不包括全连接层。

特征提取器之后是两个并列的全连接层模型。其中一个作为分类器，用于最终进行模型预测以及在本地图训时将全局模型的分器参数用于辅助建立本地对比学习的特征空间。另一个全连接层模型作为投影头，用于将特征投影到一个统一的特征空间，以便于进行对比学习，提高模型对不同类别样本的提取能力，从而有助于分类器的训练。所以总的来说，这两个并列的模块是互相促进的。

在特征提取器之后分类器之前有一个批归一化层，其操作可以使用公式 3.3 表示，其作用是把分布分散的数据拉回一个比较小的区间范围，防止部分数据出现在激活函




图 3.4 CNN 和 ResNet 基本模块对比

Fig. 3.4 Comparison of basic modules between CNN and ResNet

数的饱和区间，从而导致模型梯度消失或梯度爆炸，防止对模型的不良影响。批归一化层中包括参数 μ 为这一批数据的均值， σ 为当前批数据的标准差，这两个参数负责将数据归一化到区间范围 $[0, 1]$ 之间，并且调节样本的方差，使互相之间差异保持在一个合适的区间范围。可训练参数 γ 是用于对数据进行重构，将样本区间进行调节， β 调整重构数据的偏置，这两个可训练参数可以共同作用，使得数据在一个合适的区间范围内，从而加速训练过程，提高训练精度。此外，在将分类器拆分成向量时也需要使用公式 3.3 来将向量归一化，以使得对比特征向量的模值在相同的区间内。

$$y = \gamma \cdot \left(\frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} \right) + \beta \quad (3.3)$$

SimCLR^[57] 中验证了在对比学习中使用非线性投影头效果优于线性投影头，使用投影头效果优于不使用投影头。这是因为非线性变换会丢失一部分信息，使得前一层特征提取器更容易保留更多的有效信息加强训练效果，从而促进模型的稳健。DirectCLR^[69] 中通过实验证明低秩的固定投影头可以达到媲美可训练投影头甚至更好的效果。所以根据以上结论，出于减少联邦学习中计算压力和通信压力的考虑，本文考虑使用一种固定参数的低秩的投影头。

本算法投影头由一个多层非线性层网络构成，非线性层包括全连接层以及激活函数，其作用是对输入的特征向量经过投影变成新的特征，从而更容易辨别相应的类别。非线性层的输入输出通常是一组向量而不是二维矩阵。在本算法中，在多层全连接层之间使用了激活函数，通过使用非线性的激活函数，使得神经网络能够得到非线性信息，提高其处理信息的能力。在该模型中，由于投影头最终是不参与样本类别预测的，因此其作用仅仅是在对比学习中，通过多层线性层和非线性的激活函数对特征向量进

行变换,从而将样本特征投影到特征空间,更容易区分不同类别样本之间的差异。所以,投影头的增加的参数量对于模型参数的上传和下载来说是额外的负担。为了尽可能减少模型参数在不同参与方与服务器之间传输的负担,在本算法中,使用 ETF 的结构将线性层结构的权重参数初始化,并且设置为不可梯度更新的固定值,其初始化公式为:

$$\mathbf{w}_T = \sqrt{\frac{k}{k-1}} \mathbf{E}(\mathbf{I} - \frac{1}{k} \mathbf{J}) \quad (3.4)$$

其中 $\mathbf{E}$ 是一个 $\mathbb{R}^{j \times k}$ 大小的矩阵,其中 j 是该层的输入维度, k 是该层的输出维度。 $\mathbf{I}$ 是一个 $\mathbb{R}^{k \times k}$ 的单位矩阵,且 $\mathbf{E}$ 和 $\mathbf{I}$ 满足等式 $\mathbf{E}^T \mathbf{E} = \mathbf{I}$, $\mathbf{J}$ 是一个全 1 的 $\mathbb{R}^{k \times k}$ 的矩阵。通过这一初始化方案,可以使用预设的模型参数模拟被训练了的线性层,从而尽可能不降低对比学习的性能但是会减少模型的通信压力。

分类器部分本算法中是一个单层的线性层,其作用是首先是实现对输入特征的分类任务,利用平衡交叉熵损失训练其本身的参数。另一点是利用分类器辅助对比学习建立跨客户端的特征空间。在分类器中,共包括权重参数 $\mathbf{w}$ 和偏置参数 $\mathbf{b}$,其中参数 $\mathbf{w}$ 用于判决特征向量, $\mathbf{w}$ 中的不同类别的分向量应与该类的特征向量方向相同。因此 $\mathbf{w}$ 可以代表所属类别的类内均值。所以使用单层线性层可以将分类器中的参数提取出来作为对比学习的辅助向量,保持单层分类器模型是设计此算法的重要部分。

3.2.2 客户端损失函数

由于本算法包括分类器和对比学习两个过程,所以本算法中共包括两个部分的损失,分别是交叉熵损失和对比学习损失。在数据集的类别分布不平衡的条件下,由于不同类别之间样本数量差异显著,所以传统的交叉熵损失函数可能会导致模型偏向多数类,而对少数类的分类效果较差,从而影响模型优化方向。Cui 等人^[70]提出了一种使用预测概率偏置的基于样本数量的平衡交叉熵损失,该损失函数通过基于样本量的偏置项,给少数类以较大权重,给多数类较小的权重,从而平衡类别之间的关系。在本算法中也利用了相同的原理,实现本地训练时平衡的交叉熵损失。

在本地训练时,本地的交叉熵损失与本地模型的分器概率输出以及本地样本的标签相关,此外,还需要统计本地样本集中不同类别的样本数量,从而进行交叉熵计算。假设本地模型分类器输出预测概率为 y ,本地样本的标签为 i ,第 i 类样本数量为 n_i ,则可以使用以下损失函数计算基于样本数量的平衡交叉熵损失:

$$\mathcal{L}_{BCE} = -\log \frac{\exp(\frac{y_i}{\tau} + \varphi_i)}{\sum_{j=1}^C \exp(\frac{y_j}{\tau} + \varphi_j)}, \varphi_i = \log \frac{n_i}{\sum_{j=1}^C n_j} \quad (3.5)$$

其中 φ_i 是基于不同类的样本数量计算得到的常数项。 τ 是温度系数,用于控制输出概率的平滑程度,在本算法中温度系数是固定的值并且温度系数的值不大于 1。

对比学习中最常用的损失之一是 InfoNCE 损失，其核心思想来源于噪声对比估计，即将数据分布与噪声分布区分开来。在本算法的适用场景中，由于其本地样本是各类别数量不均衡的，因此简单的应用 InfoNCE 损失可能无法实现较好的效果。Zhu 等人 [67] 提出了一种适用于不均衡数据的对比学习损失。该算法是对有监督对比损失 (Supervised contrastive loss) 的进一步修正。有监督对比损失是 InfoNCE 损失在有标签的数据集上的扩展，其公式为：

$$\mathcal{L}_{\text{SupCon}} = -\frac{1}{N} \sum_{i=1}^N \frac{1}{|\mathbf{P}(i)|} \sum_{p \in \mathbf{P}(i)} \log \frac{\exp(\mathbf{z}_i \cdot \mathbf{z}_p / \tau)}{\sum_{j=1}^K \exp(\mathbf{z}_i \cdot \mathbf{z}_j / \tau)} \quad (3.6)$$

其中， $\mathbf{P}(i)$ 是与 i 同一类的样本的集合， τ 是温度系数， N 是样本集的数量。该样本适用于一般的数据均衡的数据集，然而，当各类别样本数量不同时，负样本对中 $\sum_{j=1}^K \exp(\mathbf{z}_i \cdot \mathbf{z}_j / \tau)$ 是有偏的。所以为了解决 SupCon 损失在类别不均衡的数据集中的有偏优化问题，可以通过对负样本对根据样本数量进行归一化加权，以使得样本数量不同的类别对损失具有相同的影响，因此可对上述损失进行如下修改：

$$\mathcal{L}_{\text{Con}} = -\frac{1}{|\mathbf{D}_y| - 1} \sum_{p \in y} \log \frac{\exp(\frac{\mathbf{z}_i \cdot \mathbf{z}_p}{\tau})}{\sum_{j \in y} \frac{1}{|\mathbf{D}_j|} \sum_{k \in \mathbf{D}_j} \exp(\frac{\mathbf{z}_i \cdot \mathbf{z}_k}{\tau})} \quad (3.7)$$

其主要改进是对负样本对基于负样本的类别进行归一化运算， $\mathbf{D}_j$ 是类别 j 的样本集合， $|\mathbf{D}_j|$ 是 j 类别的样本总量。

在算法模型中该损失的应用为：将样本 X 的一个数据增强样本通过特征提取器后使用投影头 $h_2(\cdot)$ 得到其特征表示 $\mathbf{z}_{\text{local}}$ 。同时将样本 X 的一个数据增强样本利用全局模型的投影头得到 $\mathbf{z}_{\text{global}}$ ，同时将全局模型的分类器的权重 $[\omega_1, \omega_2, \dots, \omega_l]$ 拆分成类向量通过全局模型的投影头得到特征向量 $\mathbf{z}_\omega$ 。然后使用公式 3.7 计算当前本地模型与全局模型之间的对比损失。其中 $\mathbf{z}_i$ 为来自本地模型的特征 $\mathbf{z}_{\text{local}}$ ， $\mathbf{z}_p$ 为来自全局模型的当前批处理大小中所有数据的特征 $\mathbf{z}_{\text{global}}$ 的集合以及分类器参数向量 $\mathbf{z}_\omega$ 的并集。 τ 为一个温度系数，用来控制对比学习对负标签的关注程度，同样是一个不大于 1 的固定超参数。

在本地更新时，其总损失是以上两个损失函数 3.5 和 3.7 的和，其计算过程如公式 3.8。之后根据损失进行梯度更新。

$$\mathcal{L}_{\text{sum}} = \mathcal{L}_{\text{BCE}} + \mathcal{L}_{\text{Con}} \quad (3.8)$$

3.3 实验与分析

3.3.1 数据集及数据预处理

本研究在三个广泛使用的基准数据集上测试了算法的有效性：CIFAR-10、CIFAR-100^[71] 和 Tiny-ImageNet^[72]。这些数据集分别代表了不同规模和复杂度的图像分类任务，能够全面评估本文提出的方法在联邦学习环境中的性能。CIFAR-10 包含 10 个类别的 60000 张 32x32 彩色图像，CIFAR-100 包含 100 个类别的 60000 张图像，而 Tiny-ImageNet 则包含 200 个类别的 100000 张 64x64 彩色图像。这些多样的数据集能够帮助验证算法在不同数据分布和任务复杂度下的鲁棒性。

为了模拟联邦学习中的非独立同分布数据场景，本章采用 Dirichlet 分布来为每个客户端分配类别比例。具体来说，本章实验对每个客户端为其分配一个类别比例向量 p_i^k ，表示客户端 i 中类别 k 的样本比例。Dirichlet 分布的参数 α 是控制数据分布的偏差程度的超参数：当 α 较小时，数据分布高度偏斜，客户端之间的数据差异较大；当 α 较大时，数据分布趋于均匀，客户端之间的数据差异较小。通过调整 α ，能够生成不同程度的 Non-IID 数据分布，从而更真实地模拟联邦学习场景中的数据不平衡问题。在本章中由于考虑的是一般的 Non-IID 场景，所以对 α 设置了一个适中的值。

在对比学习中数据增强是提升模型性能的关键步骤之一。本章采用了多种数据增强技术来生成样本，从而增强模型的泛化能力。对于 CIFAR-10 数据集，实验中采用了以下数据增强方法：包括进行归一化，防止数值进入非线性函数的饱和区间，造成对梯度的不良影响；对图像进行反射填充以保证在后续的随机裁剪中保留更多的图像信息；对图像进行随机颜色抖动，包括亮度、对比度、饱和度和色调的随机变化；对图像进行随机裁剪，以生成多样化的样本，防止对某些样本的过拟合；对图像进行随机翻转来增加样本的多样性。

CIFAR-100 数据集由于类别更多，样本特征更具多样性，也更难以区分，所以本研究在 CIFAR-10 的基础上增加了更多的数据增强方法，包括：对图像进行随机遮挡，通过识别被部分遮挡的样本进一步增强模型的鲁棒性，提高模型对不同类别的特征提取和识别的能力；除此之外还利用 CIFAR10Policy 策略，自动生成数据增强策略，进一步提升模型的性能。CIFAR10Policy 基于 AutoAugment 的思想，通过自动搜索多种数据增强的组合，找到最优的数据增强策略。AutoAugment 的核心思想是通过强化学习或进化算法，在数据增强操作的空间中进行搜索，找到最优的增强策略。其中包含的数据增强策略有：图像旋转、图像剪切、图像颜色调整、图像翻转以及随机添加高斯噪声。

Tiny-ImageNet 是一种更为复杂的分类数据集，所以对于 Tiny-ImageNet 数据集，本章采用了更复杂的数据增强方法，其中有：对图像进行随机调整大小和裁剪，从而

使得原始数据集中大小不同的初始样本能够实现相同大小的样本输入，方便进行模型参数设置。随机应用颜色抖动，包括亮度、对比度、饱和度和色调等，从而避免模型识别类别过程中对颜色的依赖；随机转换为灰度图像；随机应用高斯模糊；对图像进行随机翻转以及对图像进行归一化。

3.3.2 实验设置与指标

为了与现有的联邦学习方法进行比较，本章采用了与其他相似算法相同的基础网络框架，以保证实验的唯一变量。具体而言，CIFAR-10 的特征提取器是一个简单的卷积神经网络，该网络包括两个核大小为 5 的卷积层，每个卷积层后接一个 ReLU 激活函数，之后是核大小为 2 的最大池化层，在该神经网络中，这三种模块的顺序依次为：卷积层，激活函数，最大池化层，之后再依次一组类似的模型。对于 CIFAR-100 和 Tiny-ImageNet，本章实验选择了 ResNet-50 作为基础编码器。对于本章提出的算法，在特征提取器后并列添加了一个投影头和一个分类头。对于所有的数据集，分类头都是一个简单的线性层，其输出特征维度就是数据集的类别数量。CIFAR-10 的投影头是一个包含两层的多层感知机（Multilayer Perceptron, MLP），输出维度为 64，该 MLP 包括两个线性层以及一个批归一化和 ReLU 激活函数，并且线性层分别在该 MLP 的输入和输出，其输出特征为 64 维的向量。对于 CIFAR-100 和 Tiny-ImageNet，投影头也是一个包含两层的 MLP，只是输出维度与 CIFAR-10 不同，为 256 维度的特征。

本章将所提出的方法与五种领先的联邦学习算法进行比较，包括用于对比学习的 FedProc^[60] 和 MOON^[58]，以及作为基准的 FedAvg、FedProx^[4] 和 SCAFFOLD^[73]。SOLO 作为单个客户端的基准。本章将超参数设置与对比算法的参数一致，CIFAR-10 的学习率为 0.01，CIFAR-100 和 Tiny-ImageNet 的学习率为 0.1，所有数据集的批大小为 64。在本章的实验中，共设置 10 个客户端参与了 100 次通信轮次，每个全局通信中本地训练 10 个轮次，Dirichlet 分布的 α 值为 0.5。为了进行对比实验，对于未提及的实验参数，实验中也遵循了 FedProc 的标准设置，以确保比较结果的可靠性。

在实验评估中，本章主要关注模型的预测准确度、模型占用存储空间以及收敛轮次三种评估指标，以全面衡量本章算法的有效性和适用性。

预测准确度是衡量模型性能的核心指标，它反映了全局模型在测试集上的泛化能力。在本实验设置的联邦学习场景中，由于数据具有 Non-IID 属性，不同客户端的数据分布可能存在显著差异，这会导致全局模型的收敛至次优解。因此，本实验比较不同算法的测试准确度，以评估其在异质环境下的鲁棒性。

占用存储空间是衡量联邦学习通信和存储开销的重要因素。由于联邦学习是一种分布式计算框架，在该计算过程中涉及多个客户端与服务器之间的模型传输，模型的大小直接影响通信效率。而且本章算法由于使用了双分支网络，其本身就会引起对模型通信与计算开销的担忧。因此，本章实验中记录了不同算法的模型大小，以评估其

对通信资源的利用是否高效。

收敛轮次反映了联邦学习模型达到稳定性能所需的通信轮次，直接影响整体训练时间和通信成本，是模型计算开销和收敛性能的重要评估指标。在本章实验中由于不同算法的设计不同，其在全局通信时收敛快慢和特点也不同，有些算法可能在开始时就收敛很快而有些算法可能需要多轮之后才逐渐收敛，但是可能这两种算法的准确度差异不大。此时可以通过观测收敛轮次与准确度的收敛曲线，了解模型的收敛效率。

3.3.3 对比实验与分析

表 3.1 测试集上的 Top-1 准确率 (%)
Tab. 3.1 The top-1 accuracy(%) on test datasets.

算法	CIFAR-10	CIFAR-100	Tiny-ImageNet
SOLO*	46.3%	22.3%	8.9%
FedAvg*	66.3%	64.5%	26.2%
SCAFFOLD*	66.6%	52.5%	17.9%
FedProx*	66.9%	64.6%	27.4%
MOON*	49.1%	67.5%	27.5%
FedProc*	70.7%	74.6%	35.4%
CAFedCon	73.3%	79.7%	37.3%

表 3.2 采用相同数据增广算法的 Top-1 准确率 (%)
Tab. 3.2 The top-1 accuracy(%) using the same data augmentation

算法	CIFAR-10	CIFAR-100	Tiny-ImageNet
FedProc	70.7%	78.5%	61.2%
CAFedCon	73.3%	79.3%	64.9%

表 3.1 比较了 CAFedCon 与其他领先的联邦学习方法在多个数据集上的表现。*表示实验结果引用自 FedProc 文献^[60]。相比于单机上的结果本算法有显著提升，这证明了联邦学习是十分有效的。相比于 FedAvg 算法，本算法在各种数据集上均有明显提升，然而本算法仅仅在本地客户端上与 FedAvg 更新方法不同。因此，这一对比也证明了本算法提出的不同结构可以促进模型准确度的提升。此外 SCAFFOLD 在除 CIFAR-10 的数据集中表现还不如 FedAvg 的算法，而在 CIFAR-10 上表现基本与 FedAvg 持平。FedProx 表现略优于 FedAvg，该算法是 FedAvg 算法基于 Non-IID 数据的修正，其算法是 FedAvg 在优化方向中添加修正项后的结果。MOON 算法是联邦学习中最早的对比学习算法，其原理是利用模型对比算法解决联邦学习中 Non-IID 问题。在本实验中，MOON 潘在多种数据集中表现优秀，但较本算法依然有较大差距，

而且 MOON 算法在 CIFAR-10 数据集上表现较差, 仅仅高于单机实验结果。在所有数据集中, CAFedCon 都表现出了优秀的测试准确率, 在 CIFAR-10 上比次优结果提高了 2.6%, 在 CIFAR-100 上比次优结果提高了 5.1%。在 Tiny-ImageNet 上, CAFedCon 比 FedProc 提高了 1.9% 的性能。并且在以上三个数据集上, FedProc 都是结果仅次于 CAFedCon 的次优算法, 而且该算法发表于 2023 年, 是将对比学习应用于联邦学习的较为先进的算法。在 CIFAR 数据集中, 该算法准确度低于本章算法, 这充分说明了使用分类器辅助的算法可以提高对比学习的有效性, 增强对比学习在联邦学习中挖掘跨客户端的互信息的能力。而在 Tiny-ImageNet 数据集中, 由于本身数据难度较大, 而且两者都使用了较为简单的数据增强, 这种简单的数据增强无法适应本章的对比学习算法, 因此 CAFedCon 算法较 FedProc 算法实现了较低水平的预测精度提升。表中的这些结果突显了 CAFedCon 方法的有效性以及其在多个数据集上的广泛适用性。在下文的实验中, 由于 FedProc 作为较为先进的算法, 且是以上算法中唯一使用对比学习进行联邦学习的算法, 所以在实验过程中主要与该算法进行对照, 以确保本章算法的设计合理性。




图 3.5 在相同数据增强条件下 CAFedCon 与 FedProc 的准确率对比

Fig. 3.5 Comparative accuracy(%) of CAFedCon and FedProc under identical data augmentation

此外, 本实验测试了在相同数据增强条件下, CAFedCon 算法和 FedProc 算法在不同数据集上的测试准确率。在进行 100 轮训练之后的准确率见表 3.2, 全局模型准确率变化趋势如图 3.5 所示。从表中可以看出, 在相同的数据增强条件下, CAFedCon 算法仍然达到了较高于 FedProc 的测试准确率, 这进一步证明了 CAFedCon 算法的有效性。其中最主要的是 Tiny-ImageNet 数据集, 其他数据集中的信息可以在表 3.1 中得到相似的结论。在 Tiny-ImageNet 数据集中, CAFedCon 算法与 FedProc 算法同样使用了实验设置中相同的数据增强, 并且设置了相同的超参数。可以看出 CAFedCon 仍然较 FedProc 算法有 3.7% 的精度提升, 这证明了与该算法相比, CAFedCon 算法的精度提升不仅仅在于对比学习中更强的数据增强, 也在于 CAFedCon 算法中的损失设置和双分支网络的模块设计。此外, 如图所示, CAFedCon 算法的收敛速度显著快于 FedProc。在 CIFAR-10 数据集中, CAFedCon 与 FedProc 具有相似的收敛曲线, 但是 CAFedCon 算法的起始阶段收敛速度较快, 所以比 FedProc 更快达到收敛, 而且获得了更好的收敛精度; 在 CIFAR-100 数据集中, CAFedCon 是一个平滑的收敛曲线, 其在初始阶段收敛较快, 在达到收敛轮次后逐渐放缓, 相比之下, FedProc 则收敛速度在进行了几轮全局通信后才突然加快, 在收敛之后又放缓, 最终其收敛精度略低于 CAFedCon 算法; 在 Tiny-ImageNet 数据集上, CAFedCon 算法仍然是平缓的曲线, 在初始阶段收敛较快之后逐渐放缓, 并且 CAFedCon 算法在第 54 轮就达到了收敛, 而 FedProc 则是在开始几轮收敛缓慢, 在经过多轮之后逐渐收敛速度加快, 之后达到收敛轮次精度增长缓慢, 直到第 84 轮才收敛, 收敛速度比 CAFedCon 算法慢了 50%。对于这三个数据集上的收敛曲线可以看出, CAFedCon 算法有一个理想的收敛曲线, 其收敛效果是逐渐放缓的过程; 然而 FedProc 则在复杂数据集中开始阶段不易收敛, 其收敛曲线是由缓慢逐渐增加后达到收敛精度后又放缓的 s 型曲线。以上的实验结果和曲线证明了在训练过程中 CAFedCon 相较于 FedProc 算法的稳定性, 有效性和可靠性。此外, 与其他对比学习算法^[58, 60]相比, CAFedCon 算法没有额外的通信开销 (而 FedProc 算法需要在全局服务器中为辅助类向量设置额外的聚合过程, 这会极大增加参与方与服务器之间的通信开销和服务器上的计算压力), 且本地训练期间的计算负载较低 (与 MOON 相比, CAFedCon 算法只需计算全局模型的对比结果, 而 MOON 算法需要计算多个模型进行模型对比学习, 极大增加计算开销)。这些结果证实了 CAFedCon 算法的优越性。

表 3.3 在不同 Non-IID 条件下的 CIFAR-100 测试准确率 (%)
Tab. 3.3 Test accuracy(%) under different Non-IID conditions on CIFAR-100

算法	$\alpha = 0.1$	$\alpha = 0.5$	$\alpha = 5$
FedProc	65.9%	74.6%	75.6%
CAFedCon	73.4%	79.7%	79.9%

表 3.3展示了在不同非 IID 场景下, CAFedCon 与 FedProc 的对比结果。表中共对比了在不同的 Non-IID 条件下, 在 CAIFAR-100 数据集中算法 CAFedCon 与 FedProc 收敛精度对比。可以看出, 随着 Non-IID 属性逐渐降低, 两算法的训练准确度都在提升, 这证明 Non-IID 分布对联邦学习有不利影响。而且可以看到在不同数据分布中, CAFedCon 算法均优于 FedProc 算法, 这证明了在不同的数据分布场景中, CAFedCon 均比 FedProc 算法实现更好的性能, 证明了算法设计的有效性。随着 Non-IID 程度的加深, CAFedCon 算法与 FedProc 算法精度差异逐渐拉大。其中在 $\alpha = 0.1$ 时 CAFedCon 比 FedProc 提高了 7.5%, 这种精度的差异体现了在面对不同 Non-IID 数据时, CAFedCon 具有更好的稳定性, 在面对不同的 Non-IID 条件时更容易达到较好的收敛精度。

3.3.4 消融实验与性能分析

表 3.4 不同损失的影响
Tab. 3.4 The influence of different loss

条件	CIFAR-10	CIFAR-100
$\mathcal{L}_{BCE}$	69.25%	78.77%
$\mathcal{L}_{sum}:\tau' = 1$ 并且 $\tau = 1$	72.81%	79.72%
$\mathcal{L}_{sum}:\tau' = 0.1$ 并且 $\tau = 0.5$	73.31%	79.34%

表 3.5 不同损失的影响 (无 MLP 投影头)
Tab. 3.5 The influence of different loss(w/o MLP)

条件	CIFAR-10	CIFAR-100
标准交叉熵损失	70.73%	78.77%
$\mathcal{L}_{BCE}$	73.87%	78.05%
$\mathcal{L}_{sum}:\tau' = 0.1$ 且 $\tau = 0.5$	70.77%	79.06%

本文在 CIFAR-10 和 CIFAR-100 上进行了消融实验, 以评估 CAFedCon 的各个组件。无分类器辅助指的是仅使用标准交叉熵损失并且不使用对比学习的情况, 而平衡损失指的是仅使用公式 (3.5) 中的损失的情况。表 3.4和表 3.5详细展示了在有投影头 and 没有投影头的情况下不同损失函数组合的效果。从两个表格中相同条件对比可以看出, 在 CIFAR-10 的低温度系数的对比学习和平衡交叉熵损失的情况下, MLP 投影头有利于模型精度的提升, 这证明了在 CAFedCon 算法中 MLP 对实验结果有一定的促进作用, 并且在使用两个损失的情况下, 在 CIFAR-100 数据集中也达到了相近的预测精度。此外对比标准交叉熵损失和本文提出的平衡交叉熵损失, 如公式 3.5可以看出在部分情况下平衡交叉熵损失实现了更好的结果, 但是即使最差的情况下平衡交叉熵

损失仍然达到了与标准交叉熵损失相似的实验结果。在实验中还对比了不同温度系数对实验结果的影响，实验证明低温系数有利于模型性能的提升。此外 CIFAR-100 中性能变化差异不大，这证明了在应用数据增强等手段后多种损失和参数对模型性能的影响减弱，或许加深网络可以进一步提高模型精度。

与 FedAvg 相比，CAFedCon 由于采用了双分支网络，增加了计算负担和通信成本。然而，CAFedCon 算法也通过一些设计来减少计算和通信开销，例如重用共享特征以及使用 ETF 框架减少不必要的参数更新等。为了讨论本算法的通信开销，实验中还统计了 CAFedCon 算法和最近的联邦对比学习算法 FedProc 的模型大小差异。

表 3.6 占用存储空间对比
Tab. 3.6 Comparison of occupied storage space

数据集	FedProc	CAFedCon
CIFAR10	367k	302k
CIFAR100	109M	109M

表 3.6 中比较了在不同数据集上 CAFedCon 算法与 FedProc 算法使用的模型大小。从表中可以看出，在 CIFAR-10 数据集中，CAFedCon 算法模型大小略低于 FedProc 算法 65kb 大小，这是因为 CAFedCon 在投影头和分类器中使用了单层的分类器和两层的 MLP 投影头，这比 FedProc 的模块略小。在 CIFAR-100 数据集中两者模型大小基本一致，这说明 CAFedCon 算法并没有比其他的联邦对比学习算法更多参数要求。同时由于模型中投影头的设计是固定参数的，其参数不需要参与服务器与客户端之间的参数交流，因此实际传输大小会略小于模型大小。而 FedProc 需要共享的类平均向量辅助建立全局特征空间，因此其实际传输的数据量会大于模型大小。综上所述，CAFedCon 算法并没有显著增加通信开销，甚至较 FedProc 算法减少了通信开销。此外，在计算效率上，从全局通信轮次与全局模型预测精度的曲线，如图 3.5，可以看出：与 2023 年提出的联邦对比学习算法 FedProc 相比，CAFedCon 仅需一半的通信轮数即可达到相似的准确率。这证明了与 FedProc 算法相比，CAFedCon 算法计算效率更高，能够在较短的全局通信轮次内达到较好的收敛结果。

3.4 本章小结

本章提出了一种使用分类器辅助的联邦对比学习算法（CAFedCon）。该算法被用来解决联邦学习中一般场景的 Non-IID 问题，即不同客户端中样本类别相同，但是不同类别的样本数量不同的场景。该算法主要包括全局服务器和多个本地客户端等多个参与方。算法主要是利用分类器帮助客户端建立了统一的跨客户端的特征空间，便于在这个特征空间中使用对比学习，从而防止不同客户端在本地自发建立对比学习的

特征空间导致的本地模型优化方向差异显著,从而影响全局收敛的情况。具体来说:首先全局服务器初始化全局模型,之后将全局模型下发到本地客户端。在客户端中,CAFedCon 算法主要进行了以下改进:首先是创新性使用双分支网络,在这个网络中,包括一个使用卷积神经网络的特征提取器,用于提取样本中与类别相关的特征信息,在特征提取器的最后一层连接了一个批归一化层,用于归一化样本特征,之后并联两个不同的全连接层,其中一个为单层的全连接层,用作模型分类器,预测样本类别,另一个多层感知机作为投影头,用于进行对比学习的特征映射,并且投影头的全连接层参数使用 ETF 模型进行固定,减少计算开销和通信开销;第二个点是使用了多种损失的和作为本地训练的总损失,具体来说包括基于不同类别样本数量的带有偏置项的平衡交叉熵损失以及一个基于 Non-IID 样本进行改进的有监督对比损失。在本地训练中,共有两个模型,一个本地模型以及一个全局模型,本地模型从全局模型初始化参数开始更新,然后使用全局模型作为固定的模型,利用全局模型的分层参数和投影头输出的样本特征作为对比特征,与本地模型投影头输出的样本特征计算有监督对比损失,在本地模型分类器上计算平衡的交叉熵损失。计算两部分损失的和用来更新本地模型。本地更新若干轮次后将本地模型上传到服务器。全局服务器对收到的本地模型进行基于样本数量的加权平均,这就完成了一次全局更新。之后全局模型再次下发到本地,经过若干轮次更新之后,全局模型逐渐收敛,此为完整的联邦学习训练过程。

在实验中,CAFedCon 算法在多个数据集中均表现出了较好的预测精度,比最新的联邦对比学习 FedProc 算法模型精度有明显提升,这证明了本章算法的有效性。并且相比较于 FedProc 算法,CAFedCon 算法减少了全局平均特征向量的传输,这不仅在一定程度上可以减少客户端隐私泄露的风险,而且还可以提高通信效率,减少全局模型的计算开销。

4 基于固定分类器的联邦学习算法

现有的联邦 Non-IID 算法大部分是面向跨客户端所有类别数据总量基本相同，但是不同客户端之间的数据分布呈现 Non-IID 的场景。但是在现实场景中，有许多情况下跨客户端的数据总量也是呈现长尾分布的，这会进一步增大联邦学习中 Non-IID 问题的挑战。面对联邦学习中的长尾分布场景，本章提出了一种基于固定分类器的使用多温度系数损失和特征归一化的联邦学习算法（Federated Learning with Mixed Low-Temperature and Normalized Features, Fed-LTNF）。该算法利用预设的平衡的分类器框架替代可训练的模型分类器，从而解决联邦学习中跨客户端的长尾分布问题。

4.1 算法介绍及适用场景

4.1.1 适用场景

数据异质性是联邦学习中的一个主要挑战。在第三章场景中，由于不同客户端之间的种种性能差异，导致其中一些参与者可能对某些类别拥有大量数据，而另一些参与者可能只有少量甚至几乎没有同类型的样本，从而导致参与者之间的数据分布高度倾斜。这种倾斜可能会使得不同的本地训练优化方向为适用于本地数据集的优化方向，从而导致客户端优化方向偏离全局优化目标，对全局模型的收敛精度和收敛速度带来较大影响。




图 4.1 联邦长尾分布中不同客户端数据分布

Fig. 4.1 Data distribution of different clients in federated long-tail distribution

此外，在现实场景中的 Non-IID 往往会表现出更复杂的特性。例如在医疗领域，不同医院或医疗机构的数据分布往往存在显著差异：某些常见疾病（如感冒或高血压）的影像数据非常丰富，而罕见病（如某些癌症亚型或遗传疾病）的影像数据则极为稀缺，并且即使将几个不同的医疗机构的数据集中来看，这些罕见病的样本往往也是少数的。这种跨客户端是总数据样本数量的不同类别之间的不平衡被称为长尾分布^[74]，即少数“头部”类别拥有大量样本，而许多“尾部”类别则样本稀缺，其各客户端不同类别数据分布如图 4.1 所示。




图 4.2 CIFAR10-LT 上单机训练结果

Fig. 4.2 Solo training results on CIFAR10-LT

在 CIFAR10-LT 长尾分布中，通过简单的卷积神经网络的一百轮单机训练，可以得到其收敛结果如图 4.2 所示。其中左图表示了不同类别的样本数量统计曲线，从第一个类别到最后一个类别样本量逐渐递减，并且最多的类别和最少的类别数量差异显著。右图统计了模型收敛后的不同类别的平均特征向量（类向量）与分类器向量（分类器中用于判别该类别的参数分量）之间的角度差异。其中 $h_c - h_{avg}$ 是类别 c 的平均特征向量与整体样本的平均特征向量的差值； w_c 是分类器中用于判决类别 c 的分量； h_c 是类别 c 的平均特征向量。通过实验结果看出，当样本分布呈现长尾分布时，对于数量稀少的尾部类别，其分类器向量 w_c 与该类别的平均特征向量 h_c 之间的角度差异以及分类器向量 w_c 与该类别的类向量 $h_c - h_{avg}$ 之间的角度差异都会随该类别样本的减少而增大，直到逼近于正交。所以，在长尾分布中，尾部类别的样本更容易被错误地预测到头部类别，从而会影响模型预测。

在联邦学习中，长尾分布不仅导致每个客户端上的数据分布不平衡，还导致所有客户端之间的跨标签分布存在巨大差异，而且这种全局的类别不平衡会严重影响全局模型的收敛，进一步加剧了联邦学习的挑战^[75]。而且，大部分解决一般 Non-IID 问题的算法更倾向于加速模型收敛，而无法解决由于长尾分布导致的分类器角度偏转问

题。因此，解决联邦学习中的长尾分布问题是一项具有挑战性且必要的任务。

在联邦学习中，长尾分布问题不仅导致每个客户端上的本地数据分布呈现显著的不均衡性，还使得不同客户端之间的跨标签分布存在巨大差异。长尾分布使得模型在训练过程中更容易偏向样本数量较多的头部类别，而忽视样本稀少的尾部类别，导致模型的分类性能在尾部类别上显著下降。此外，由于客户端之间的数据分布差异，不同客户端的头部和尾部类别可能完全不同，这使得全局模型在聚合过程中难以有效捕捉所有类别的特征，进一步放大了长尾分布带来的负面影响。这种全局的类别不平衡性会严重阻碍全局模型的收敛，进一步加剧了联邦学习在数据异构性和模型性能优化方面的挑战^[75]。

尽管现有的许多联邦学习算法致力于解决 Non-IID 问题，但这些方法通常更关注如何加速模型的收敛速度或减少通信成本，而未能有效解决由于长尾分布导致的分类器角度偏转问题。在长尾分布场景中，模型在训练过程中倾向于将决策边界偏向样本较多的类别，从而导致对尾部类别的分类性能显著下降。并且在长尾数据集中少数类别分类器互相收敛，导致样本特征与分类器之间夹角较大，因此很难被正确区分。联邦学习中客户端之间的数据分布差异会进一步加剧这一分类器的偏转现象。因此，传统的联邦学习算法在长尾分布场景下往往表现不佳，无法满足实际应用中对模型公平性和鲁棒性的需求。

基于数据分布对模型参数尤其最后一层分类器影响较大的现状，本章提出了一种使用固定分类器的具有混合低温系数的归一化特征的联邦学习策略以解决联邦学习中的长尾分布问题。本算法基于平衡数据集下模型成熟阶段的分类器特点，预设一个具有等角紧框架性质的固定参数分类器，防止长尾分布对分类器的有偏影响。为了使分类器有效，本文设置了包括正交旋转矩阵等多种模块和损失函数。具体来说，本算法采用了带有预测概率调整的平衡损失函数，并证明了其在固定分类器模型中的有效性。本算法提出了一种结合低温固定设置与可训练温度系数的混合方法，以增强系统的稳定性。同时，为了减少特征的离散性，本算法在特征提取器中引入了批量归一化，并采用样本标准化来减轻特征长度的相对差异对预测的影响。此外，本算法还利用可训练的正交矩阵在特征空间中旋转特征提取器，以使其与固定分类器对齐。

4.1.2 算法介绍

由于联邦学习算法是分布式算法，为方便描述算法过程，假设有 m 个参与方 $(P_1, P_2, \dots, P_m)$ ，每个参与方拥有的数据 $(\mathbf{X}^k, k \in (1, m))$ 互不重复，不同的客户端的数据不满足独立同分布条件。算法目标是希望在 m 个参与方的协作下，共同训练一个全局模型，这个模型较所有本地数据训练的模型具有准确度优势。另外还有一个中央服务器 *server*，用于进行聚合以及全局模型的上传和下发工作。

本算法主要创新点是利用固定的预设的等角紧框架分类器解决联邦长尾分布导

致的模型收敛问题，其流程如算法 4.1 所示。整体而言，该算法流程依次包括初始化模型，本地训练，模型上传，全局模型聚合，模型下发五个部分。其中，本地训练，模型上传，全局模型聚合，模型下发四个部分是不断依次迭代的，直至全局模型收敛为止，并且这四个部分每迭代一次被称为一次全局通信；初始化模型的过程在全局服务器中进行，其作用就是产生一个统一的全局模型，以便于各客户端从统一的模型开始训练。在每轮全局通信中，假设选择客户端有 $s(s \leq m)$ 个，则第 t 轮，Fed-LTNF 算法进行如下过程训练。

首先全局模型由 *server* 下发到选定的客户端。之后在客户端中进行训练。在训练过程中，首先将批处理的数据经过两次数据增广，得到同源的两个不同样本，然后经过模型训练，生成两个不同的输出。根据模型输出计算损失并更新模型参数，从而完成一次本地训练，经过若干轮次训练之后，将更新的本地模型上传到全局服务器，在服务器中根据不同的本地模型进行模型聚合。之后再将全局模型下发到本地，依次循环下去。

算法 4.1 Fed-LTNF 训练过程

Input: 客户端集合 C , 全局模型参数 $M = \{f, w\}$, ETF 分类器参数 w , 模型中除分类器的其他部分参数 f , 全局通信轮次 T , 本地更新轮次 E .

Output: 全局模型参数: f_{avg} and w

- 1: **服务器初始化模型:**
 - 2: 随机初始化全局模型: M 并使用公式 Eq.(2.8) 生成固定的 ETF 分类器参数 w 。
 - 3: 将模型参数 f, w 发送到选定客户端。
 - 4: **服务器执行过程:**
 - 5: **for** $t = 1, \dots, T$ **do**
 - 6: 随机选定一组在线客户端: $m^t \in C$
 - 7: **for** 每一个被选定的客户端 $k \in m^t$ **do**
 - 8: $f_k \leftarrow$ 客户端本地更新($\mathcal{D}_k, f_k, w$)。
 - 9: **end for**
 - 10: 计算全局加权平均模型: $f_{\text{avg}} \leftarrow \sum \frac{1}{|\mathcal{D}_k|} f_k$ 。
 - 11: 将全局模型 f_{avg} 发送到下一轮选定客户端 m^{t+1} 。
 - 12: **end for**
 - 13: **客户端本地更新:**
 - 14: 初始化本地模型 $f_k \leftarrow f$ 并且固定分类器参数为不可求导 w 。
 - 15: **for** 本地训练轮次 $e = 1$ to E **do**
 - 16: 使用公式 Eq.(4.4) 计算本地模型损失。
 - 17: $f_k \leftarrow \vec{\nabla} \mathcal{L}(\mathcal{D}_k, f_{k-1}, w)$
 - 18: **end for**
 - 19: 将本地模型 f_k 发送到服务器。
-

图 4.3 固定分类器的联邦学习框架

4.2 算法框架

为了使得固定分类器有效，本文设计了正交旋转矩阵以使得可训练的特征提取器与分类器特征对齐；此外，由于有偏数据中不同类别的特征值具有较大差异，所以本算法设置了批归一化和单个特征向量层面上的归一化。具体来说，该算法的模型可依次拆分为特征提取器，批归一化层，样本归一化层，正交旋转矩阵以及 ETF 分类器五个部分，如图 4.3 所示。其中，由于分类器模块是固定的，所以其参数不需要参与模型的上传和下载；样本归一化部分由于没有可训练参数，所以无需考虑这一模块的参数上传和下载。由于该算法减少了分类器部分的参数传递，所以在一定程度上可以减少联邦学习的通信负担。

下游任务提供了有效可靠的输入。批归一化层通过在每个小批量数据上对输入特征进行标准化处理,能够有效缓解神经网络训练过程中由于环境或者其他因素导致的样本实际像素值的偏大或偏小的问题对预测结果的不良影响。通过归一化可以将同一批样本中的像素转化为相对值,从而使得模型可以应对更多的场景和数据增强的情况。此外,批归一化还具有一定的正则化效果,有助于减少模型的过拟合现象。

将输入特征 $\mathbf{X}$ 通过特征提取器 $f(\cdot)$ 获得特征 $\tilde{\mathbf{z}}$ 后,本算法首先将它们传给批归一化层,以归一化特征的均值和方差。这可以降低特征之间的发散程度,使模型更加稳定。在批归一化层之后,本算法还计算了 $\mathbf{z} = \frac{\tilde{\mathbf{z}}}{\|\tilde{\mathbf{z}}\|_2}$,从而进行样本实例的归一化^[76,77],从而将所有样本的中间特征归一化到 $[0, 1]$ 区间。通过采用样本标准化,本算法可以消除不同样本之间特征长度差异引起的预测偏差。这使得模型主要关注不同样本特征之间的方向差异。此外,该操作可以使得后续模块对输入数据的尺度变化更加鲁棒,有助于提高模型在不同数据分布下的泛化能力,同时防止由于类别不同导致的样本模值差异,从而增加模型对少数类别样本的关注,防止长尾学习中类内均值向量的模长差异引起的对所属类的概率偏差。

此外,与 RBL^[78] 中提出的想法类似,对特征应用适当的刚性旋转可以在一定程度上促进分类器与类向量的角度对齐。因此,该算法使用了一个刚性的旋转矩阵模块作为连接分类器和前面归一化层的桥梁。该模块为一个不改变特征大小,仅仅改变特征的映射角度的特殊矩阵,并且保证所有的特征经过相同的角度变换,从而提高模型训练的效率。在设计该模块时,为了保证在不改变不同样本的特征向量之间的相对位置关系的情况下旋转特征,该算法构造了一个满足公式 4.1 的正交矩阵。

$$SO(n) = \{\mathbf{A} \in \mathbb{R}^{n \times n} \mid \mathbf{A}^T \mathbf{A} = \mathbf{I}, \det(\mathbf{A}) = 1\} \quad (4.1)$$

利用李群 (Lie group) 定理^[79],可以将这个特定矩阵映射到群的单位元素切空间 (tangent space),这个切空间被称为李代数 (Lie algebra)。其李代数可以表示为:

$$\mathfrak{so}(n) = \{\mathbf{A} \in \mathbb{R}^{n \times n} \mid \mathbf{A}^T + \mathbf{A} = 0\} \quad (4.2)$$

此外,李指数 (Lie exponential) 提供了从李代数 $\mathfrak{so}(n)$ 到正交矩阵 $SO(n)$ 的映射关系,如下所示:

$$\exp(\mathbf{A}) := \mathbf{I} + \mathbf{A} + \frac{1}{2}\mathbf{A}^2 + \dots \quad (4.3)$$

所以,可以使用公式 4.3 构造满足条件的矩阵。然而,对于随机初始化的任意矩阵 $\mathbf{A}$ 无法满足 $\mathfrak{so}(n)$ 的条件,因此,为利用上述性质得到一个正交矩阵,可以将 $\mathbf{A}$ 利用 $\mathbf{B}$ 进行构造以满足上述公式: $\mathbf{A} \mapsto \mathbf{B} - \mathbf{B}^T$ 。其中 $\mathbf{B}$ 是可训练的随机初始化的参数,可以参与梯度更新,从而保证该部分结构的刚性旋转属性。为使得正交矩阵可以根据梯

度进行刚性旋转，其初始化过程使用算法 4.2 所示流程。

算法 4.2 正交矩阵训练过程

Input: 随机初始化特定维度的矩阵 $B(B \in \mathbb{R}^{m \times m})$

Output: 正交矩阵 $Q(Q \in \mathbb{R}^{m \times m})$.

- 1: $A = B - B^T$.
 - 2: 计算 A 的矩阵指数以生成正交矩阵:
 - 3: $Q = \text{matrix_exp}(A)$.
-

当用于平衡分类问题的神经网络经过良好训练时，来自同一类的最后一层特征往往非常接近它们的类均值；这些以全局均值为中心的类均值具有相同的长度，并在任何对之间形成最大可能的相等大小的角度；并且最后一层分类器与类均值呈对偶属性，即对于每个类别，类均值和分类器都是固定的比例长度。分类器向量收敛于类均值中。然而在数据不均衡的设置中，数量稀少的类别往往会收敛到单一向量，这会导致少样本的类别更难以被正确分类，而且预测结果更容易偏向数量多的类别，这种现象称为少数崩溃^[3]。由于样本分布主要对模型最后几层尤其是最后一层分类器有较大影响，因此本算法使用预设的固定分类器来解决少样本对模型分类器的不利影响。

模型的最后一部分是使用一个 ETF 结构作为固定的特征分类器。使用公式 2.8 可以得到一个单位长度的 ETF 结构。从而将归一化的特征输入到无偏的分类器中，尽可能减少数据的长尾分布对分类器性能的影响，其初始化流程如算法 4.3 所示。总体来说，该算法对框架的改进包括使用固定的 ETF 结构作为分类器，应用批归一化和样本标准化来约束骨干网络输出激活特征后样本特征的分散。此外，该算法还利用正交矩阵旋转特征向量以匹配固定分类器。

算法 4.3 ETF 参数生成过程

Input: 特征维度 d , 类别数量 n

Output: ETF 分类器参数: $M(M \in \mathbb{R}^{d \times n})$.

- 1: 创造特定维度的单位矩阵: $I \leftarrow E_d$ ▷ $\mathbb{R}^{d \times d}$ 单位矩阵
 - 2: 创造特定维度的全一矩阵: $J \leftarrow \mathbb{1}$ ▷ $\mathbb{R}^{d \times d}$ 全 1 矩阵
 - 3: 对全一向量 J 基于维度标准化: $O \leftarrow \frac{1}{d} \cdot J$
 - 4: $F \leftarrow I - O$
 - 5: 计算 ETF 矩阵参数: $M \leftarrow \sqrt{\left(\frac{d}{d-1}\right)} F[:, : n]$
-

4.2.2 混合温度系数平衡损失

在本地训练中，该算法还设计了一种适用于固定分类器的混合低温系数的平衡损失。温度系数^[80, 81]是一种广泛用于交叉熵和相对熵损失的超参数，这种超参数表现出了一定的敏感性。如图 4.4 绘制了温度系数和损失在预测结果正确和错误时的变化曲线。当预测结果与实际标签匹配时，较低的温度系数将导致较小的损失；相反，当




图 4.4 不同预测结果下损失值与温度系数的关系

Fig. 4.4 Convergence process of FedDS on different datasets

预测不正确时, 较低的温度系数可能会导致更大的损失。因此, 该算法为交叉熵损失设定了一个合适的低温以得到对错误结果的有效惩罚。然而, 过低的温度系数可能会导致损失激增或消失, 由于温度系数是一个相对敏感的超参数, 可调的温度系数可以在一定程度上帮助缓解梯度消失或爆炸的问题。因此, 该算法还设置了一个初始较高的、可学习的温度系数, 以在训练过程中动态调整分布的锐度。此外受一些关于 logit 调整策略的启发, 在训练中也对损失进行了基于类别的样本数量的 logit 调整。总损失函数由公式 4.4 给出。

$$\mathcal{L} = -\left(\log \frac{\exp(\frac{\mathbf{z}_i \mathbf{w}_i}{\tau_1} + \varphi_i)}{\sum_{j=1}^C \exp(\frac{\mathbf{z}_j \mathbf{w}_j}{\tau_1} + \varphi_j)} + \log \frac{\exp(\frac{\mathbf{z}'_i \mathbf{w}_i}{\tau_2} + \varphi_i)}{\sum_{j=1}^C \exp(\frac{\mathbf{z}'_j \mathbf{w}_j}{\tau_2} + \varphi_j)}\right), \varphi_i = \log \frac{n_i}{\sum_{j=1}^C n_j} \quad (4.4)$$

其中 $\mathbf{z}_i$ 是第 i 类样本输入分类器的特征, $\mathbf{w}_i$ 是与类别 i 判决相关的分类器中的参数向量, τ_1 和 τ_2 分别是不同的温度系数, 其中 τ_2 是可学习的参数。 n_j 是类别 j 的样本量。

为证明以上损失函数中基于样本数量的预测概率修正在本章算法中是有效的, 对损失函数 4.4 进行简化, 由于该函数是两个不同温度系数的损失加和, 所以在分析时可分析损失函数 4.5。损失 4.5 是一种简洁而有效的用于解决数据 Non-IID 的基于样本数量对预测概率进行修正的损失函数, 该损失常被应用于由不同类别样本量差异导致的数据分布不均的场景中。然而, 已有的论文的验证^[82, 83]是从对分类器的影响出发, 验证该损失会平衡样本差异对分类器带来的有偏优化。在本文中, 将从对特征的优化方向出发, 论证该损失对于固定的 ETF 结构分类器的模型的有效性。

$$\mathcal{L} = -\log \frac{\exp(\mathbf{z}_i \mathbf{w}_i + \varphi_i)}{\sum_{j=1}^C \exp(\mathbf{z}_j \mathbf{w}_j + \varphi_j)} \quad (4.5)$$

对损失 4.5 求第 i 类样本的导数, 并进一步将偏置项 φ_i 替换为来自类 i 的样本数 n_i , 其他类别也进行 φ_j 的替换, 可得到下列公式:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{z}_i} = -\mathbf{w}_i + \frac{\sum_{j=1}^C \exp(\varphi_j) \cdot \exp(\mathbf{z}_i \mathbf{w}_j) \cdot \mathbf{w}_j}{\sum_{j=1}^C \exp(\varphi_j) \cdot \exp(\mathbf{z}_i \mathbf{w}_j)} = \frac{\sum_{j \neq i} n_j \cdot \exp(\mathbf{z}_i \mathbf{w}_j) \cdot (\mathbf{w}_j - \mathbf{w}_i)}{\sum_{j=1}^C n_j \cdot \exp(\mathbf{z}_i \mathbf{w}_j)} \quad (4.6)$$

对于小批量, 本算法假设其采样概率与整个数据集的分布概率相同。因此, 本文可以分析整个数据集的损失总和, 而不是小批量中的损失来近似估计每一轮更新的优化方向。因此, 可以计算 a 类在所有数据上产生的损失梯度之和, 其公式如 4.7 所示, 其中 b 表示不同于 a 的另一个类别。

$$\begin{aligned} \sum_{i \in a} \frac{\partial \mathcal{L}}{\partial \mathbf{z}_i} &= n_b \cdot (\mathbf{w}_b - \mathbf{w}_a) \cdot \sum_{i \in a} \frac{\exp(\mathbf{z}_i \mathbf{w}_b)}{\sum_{j=1}^C n_j \cdot \exp(\mathbf{z}_i \mathbf{w}_j)} \\ &+ \sum_{i \in a} \frac{\sum_{j \notin a, b} n_j \cdot \exp(\mathbf{z}_i \mathbf{w}_j) \cdot (\mathbf{w}_j - \mathbf{w}_i)}{\sum_{j=1}^C n_j \cdot \exp(\mathbf{z}_i \mathbf{w}_j)} \end{aligned} \quad (4.7)$$

在对梯度的贡献中, 可以近似认为来自同一类的每个样本都遵循相同的概率分布。属于类 a 的样本的特征可以表示为 $\mathbf{z}_a$ 。同时, 为了简化模型, 在下面论证中只考虑两类。因此, 当类 a 和 b 生成的梯度相加时, 可以得到以下公式:

$$\sum_C \frac{\partial \mathcal{L}}{\partial \mathbf{z}} = (\mathbf{w}_a - \mathbf{w}_b) \cdot n_a \cdot n_b \left(\frac{\exp(\tilde{\mathbf{z}}_b \mathbf{w}_a)}{\sum_{j=1}^C n_j \cdot \exp(\tilde{\mathbf{z}}_b \mathbf{w}_j)} - \frac{\exp(\tilde{\mathbf{z}}_a \mathbf{w}_b)}{\sum_{j=1}^C n_j \cdot \exp(\tilde{\mathbf{z}}_a \mathbf{w}_j)} \right) \quad (4.8)$$

这意味着，对于输入分类器的特征，在该损失条件下在每个类方向上获得的梯度不会因每个类中不同数量的样本而产生偏差。这表明该平衡损失也适用于固定分类器的模型，证明了公式 4.4 的有效性。

依照上述推论，可以将该损失函数从两类别的损失推广到多类别中。可以看出在上述公式中，梯度的变化和不同类别的样本数量没有关系，而和该类别与其他类别的分类器的角度差异以及总样本数量和分类器的分类向量的模组有关。具体来说，梯度与数据集总量和分类器的分类向量的大小成正比。分类向量初始时模值设置越大梯度值越大，数据集越大梯度更新值越大。此外，该类别的特征值大小与梯度无关，该类别样本的特征值与所属类别的分类器向量越接近，与其他类别角度越接近正交，则梯度接近为 0；反之，该类别样本特征与所属类别的分类器向量角度越接近正交，则梯度越大。

在本地训练完成之后，本地客户端将本地更新的除样本归一化层和 ETF 分类器之外的模型参数发送至中央服务器。然后中央服务器根据客户端的数据量对客户端的模型参数进行加权平均，更新全局模型参数。具体公式为：

$$\mathbf{f}^{t+1} = \sum_{k=1}^K \frac{n_k}{N} \mathbf{f}_k^t \quad (4.9)$$

其中 $\mathbf{f}_k^t$ 是第 t 轮本地客户端 k 上传的模型参数， n_k 是客户端 k 上的样本总数， N 是所有客户端样本总量。聚合的模型 $\mathbf{f}^{t+1}$ 被下载到下一轮的选定客户端中用于下一次全局通信。

4.3 实验与分析

4.3.1 数据集及数据预处理

本算法在三个数据集上进行了实验：CIFAR10-LT、CIFAR100-LT^[84] 和 ImageNet-LT^[85]。CIFAR10-LT 数据集的构建基于原始 CIFAR-10 数据集，通过引入长尾分布特性，使得每个类别的样本数量呈指数级递减。具体而言，该数据集包含约 60000 张 32x32 像素的彩色图像，分布在 10 个类别中，其中训练集样本数量少于 50000，测试集包含 10000 张图像，每类 1000 张。通过调整类别样本数量，数据集模拟了现实世界中常见的类别不平衡问题。不平衡因素（Imbalance Factor, IF）指最多数量的类

别的样本数与最少数量的类别的样本数的商，并且通过指数函数 $m = m_i \mu^{\frac{i-1}{n-1}}$ 分配不同类别的长尾分布下的数据量。其中 m_i 是第 i 类的原始数据量， n 是总样本类别， $\mu \in (0, 1)$ 是不平衡因子。CIFAR100-LT 数据集是基于 CIFAR-100 数据集构建的长尾分布版本，包含 100 个类别的图像数据集，每个类别有 600 张 32×32 像素的彩色图像，总计 60000 张图像。这些类别被分为 20 个超类，每个超类包含 5 个子类。CIFAR100-LT 数据集通过调整每个类别的样本数量，使其呈现出长尾分布特点。ImageNet-LT 数据集是基于 ImageNet 数据集构建的一个长尾分布版本，专门用于研究类别不平衡问题。ImageNet-LT 数据集由 1000 个类别组成，总共包含约 115,800 张图像。该数据集的特点是类别之间的样本数量分布极不均衡，呈现出长尾分布的特性。

对于 CIFAR10-LT 和 CIFAR100-LT，本实验遵循与 CLIP2FL^[86] 相同的长尾设置 (IF=100、IF=50 和 IF=10，其中 IF 是 $\frac{1}{\mu}$)。由于 ImageNet-LT 本身就是一个长尾数据集，其长尾特性已经确定，因此本实验无需再强加其长尾属性。在客户端数据不平衡的设置中，本章使用迪利克雷分布进行跨客户端数据划分，在数据划分中，将 CIFAR10-LT 和 CIFAR100-LT 的 α 设置为 0.5，对于 ImageNet-LT， α 设置为 0.1。

本实验的对比方案包括七种针对异构性设计的联邦学习方法：FedAvg^[29]、FedAvgM^[87]、FedProx^[4]、FedDF^[88]、FedBE^[70]、CCVR^[89] 和 FedNova^[90]；三种解决不同客户端之间分布不平衡的方法，即 Fed-Focal Loss^[91]、Ratio Loss^[92] 和带有 τ -norm 的 FedAvg^[93]；以及两种针对长尾分布不平衡的方法，分别是 CReFF^[94] 和 CLIP2FL；以及唯一一种将 ETF 应用于联邦学习（但并非针对长尾问题）的算法，FEETF^[63]。

4.3.2 实验设置与指标

对于所有数据集，本实验进行了 200 轮通信，每个本地客户端单次执行 5 个轮次的本地训练。客户端数量设置为 20，在每轮通信中，本实验随机选择 40% 的客户端作为活跃在线客户端。对于 CIFAR10-LT 和 CIFAR100-LT，本实验将批大小设置为 256，学习率设置为 0.1，并在 100 轮后将其降低到 10%。特征提取器使用 ResNet8。对于 ImageNet-LT 数据集，本实验将批大小设置为 64，学习率设置为 0.05，并在每轮中将其降低 0.99 倍。特征提取器采用 ResNet50。

本章使用全局模型的预测准确度以及部分类别的预测准确度还有类向量与分类器之间的余弦相似度作为衡量算法性能的指标。准确率是衡量模型性能的指标，表示模型在测试集上预测正确的样本占总样本的比例。其定义为：

$$\text{准确率} = \frac{\text{预测正确的样本数}}{\text{总样本数}} \times 100\% \quad (4.10)$$

本章算法测量的为全局模型的预测准确度，即所有客户端测试数据的综合准确率，反映的是全局模型的整体性能。除此之外，本章还使用部分类别的预测准确度来描述模

型性能。因为在本章算法中，其解决的问题是联邦长尾分布，在这种场景中，分别评估模型在数量较多的类别中的预测准确度和模型在样本数量较少的类别中的预测准确度，以及比较这两者之间的差异，可以更好地了解该算法的有效性，从而更清晰认识模型的优缺点并且有针对性地进行模型改进。

除此之外，本章还使用类向量与分类器之间的余弦相似度来衡量该算法中 ETF 分类器的有效性。第二章中提到的神经崩溃可以使得分类器的向量分别收敛到相关类别的类中心，并且分类器的分类结果是通过 $y = wx + b$ 来实现的，所以通过观测分类器与平均特征之间的余弦相似度还可以清晰地观察到分类器的有效性。因此，本章主要观测分类器与类向量以及分类器与类的平均特征向量之间的余弦相似度。其中类向量是该类别样本的平均特征减轻全部样本的平均特征。

4.3.3 对比实验与分析

表 4.1 CIFAR10-LT 数据集上对比的联邦学习方法的 Top-1 测试准确率 (%)
Tab. 4.1 Top-1 test accuracy (%) of compared federated learning methods on CIFAR10-LT

IF	100	50	10
FedAvg*	56.17	59.36	77.45
FedAvgM*	52.03	57.11	70.81
FedProx*	56.92	60.89	76.53
FedDF*	55.15	58.74	76.51
FedBE*	55.79	59.55	77.78
CCVR*	69.53	71.89	78.48
FedNova*	57.79	63.91	77.79
Fed-Focal Loss*	53.83	57.42	73.74
Ratio Loss*	59.75	64.77	78.14
FedAvg+ τ -norm*	49.95	51.41	72.08
CReFF*	70.55	73.08	80.71
CLIP2FL*	73.37	75.35	81.18
FEDETF(General)	43.60	48.27	56.60
FEDETF(Personal)	79.70	80.22	79.25
Fed-LTNF	76.21	77.45	84.55

表 4.1和表 4.2展示了 Fed-LTNF 方法与几种最先进的联邦学习方法在 CIFAR10-LT 和 CIFAR100-LT 上解决异构性和不平衡问题的对比结果。其中带有 * 的结果来自 CLIP2FL 论文所记录的数据，该论文与 Fed-LTNF 算法保持相同的实验设置。可以观察到，本文的方法在这两个数据集的各种不平衡设置下均实现了较为优秀的性能。在 CIFAR10-LT 数据集中，FedAvg 算法实现了较好的性能，其结果优于 FedAvgM, FedProx 以及 FedDF 算法，这证明这几类算法虽然是解决联邦异质性问题的常用算法，但是由于其结构设计等原因并不适用于条件更极端的联邦长尾分布，此外，FedBE

表 4.2 CIFAR100-LT 数据集上对比的联邦学习方法的 Top-1 测试准确率 (%)

Tab. 4.2 Top-1 test accuracy (%) of compared federated learning methods on CIFAR100-LT

IF	100	50	10
FedAvg*	30.34	36.35	45.87
FedAvgM*	30.80	35.33	44.66
FedProx*	31.67	36.30	46.10
FedDF*	31.43	36.22	46.19
FedBE*	31.97	36.39	46.25
CCVR*	33.43	36.98	46.88
FedNova*	32.64	36.62	46.75
Fed-Focal Loss*	30.67	35.25	45.52
Ratio Loss*	32.95	36.88	46.79
FedAvg+ τ -norm*	26.22	33.71	43.65
CReFF*	34.67	37.64	47.08
CLIP2FL*	37.56	41.29	48.20
FEDETF(General)	13.68	15.28	19.67
FEDETF(Personal)	39.67	35.58	34.17
Fed-LTNF	39.95	45.54	57.11

表 4.3 Imagenet-LT 数据集上对比的联邦学习方法的 Top-1 测试准确率 (%)

Tab. 4.3 Top-1 test accuracy (%) of compared federated learning methods on Imagenet-LT

样本量	All	Many	Medium	Few
FedAvg*	23.85	34.92	19.18	7.10
FedAvgM*	22.57	33.93	18.55	6.73
FedProx*	22.99	34.25	17.06	6.37
FedDF*	21.63	31.78	15.52	4.48
CCVR*	25.49	36.72	20.24	9.26
Fed-Focal Loss*	21.60	31.74	15.77	5.52
Ratio Loss*	24.31	36.33	18.14	7.41
FedAvg+ τ -norm*	21.58	31.66	15.76	4.33
CReFF*	26.31	37.44	21.87	10.29
CLIP2FL*	27.72	35.06	27.55	24.80
FEDETF(General)	9.19	-	-	-
FEDETF(Personal)	26.32	-	-	-
Fed-LTNF	40.50	58.42	35.30	9.96

和 FedNova 实现了与 FedAvg 相似的实验效果。其中 FedBE 算法通过对全局模型进行采样并且使用贝叶斯模型进行拟合使得本地模型能适应更多的 Non-IID 场景，而 FedNova 通过自适应调节本地训练过程减少本地模型之间的差异，这一结果表现出来了这几种算法的泛用性。此外，CCVR 以及比率损失（Ratio Loss）都实现了较好的预测精度，比例损失根据模型参数衡量本地模型偏移程度，CCVR 基于不平衡数据主

会影响分类器，所以在虚拟表示上进行分类器训练，这与本文算法具有异曲同工之妙。在对比其他两种联邦长尾算法时，这两种算法均实现了较好的实验结果，但是较 Fed-LTNF 算法仍然有一定的差异。CReFF 基于全局模型设置了一组平衡的联邦特征，在这组平衡的特征中训练一个分类器，从而防止长尾分布对分类器的影响，但是这种将分类器和特征提取器分离的方式一定程度上会减少分类器与特征提取器的特征对齐，从而导致效果不太理想。此外，CLIP2FL 则利用 CLIP 中的预训练信息，从而提高模型性能，并且取得了不错的成果。但是这种方案对于预训练中不包含的知识可能会有较大的局限性。FedETF 是另外一种将 ETF 应用于联邦学习的算法。并且在 CIFAR10-LT 的多种设置下实现了最优效果，这种算法一定程度上证明了 ETF 结构对联邦学习长尾分布具有有利影响。同时在类别较少的情况下，对分类器微调是一种很有效的适应本地数据集的策略。

在 CIFAR100-LT 上，随着长尾属性的加剧，由于任务难度增加的不可避免的影响，测试准确率普遍呈现下降趋势。总体而言，本文的算法在长尾设置下优于现有的先进联邦算法。在此设置中，FedAvg 与 FedAvgM 则实现了相似的结果，其他几种解决异质性的算法基本都效果优于这两种算法。解决客户端数据分布不平衡的算法中依然比率损失实现了最好的结果。适用于长尾分布的两种联邦算法效果低于 Fed-LTNF 算法，并且当 IF=10 时，本文的方法相比 CLIP2FL 在准确率上提升了近 8.91%。根据实验结果分析这是因为 CLIP2FL 在更接近平衡分布的环境中未能学习到额外的有益知识。此外，FEDETf 策略在 CIFAR-10 的强长尾分布下表现出具有竞争力的结果，但对数据分布较为敏感。并且 FedETF 更适用于极端的 Non-IID 场景，在相对平衡的数据集上其个性化方法反而效果开始变差。并且个性化之前的效果是明显较低的，根据理论以及实验结果分析，这可能是由于该算法对 ETF 结构与特征提取器进行直接连接，并没有对特征进行处理，使得这两部分模块之间很难对齐。

表 4.3 展示了本文的方法与其他最先进算法在 ImageNet-LT 数据集上测试准确率的对比。其中带有 * 的结果来自 CLIP2FL 论文所记录的数据，该论文与本文算法保持相同的实验设置。该表提供了比 CIFAR 数据集更详细的针对不同类别的信息。在表中，本文将样本数量大于 100 的类别归类为 *many*（多数类），样本数量在 20 到 100 之间的类别归类为 *medium*（中等类），样本数量小于 20 的类别归类为 *few*（少数类）。可以观察到，总体而言，本文的算法相比第二优的方法（CLIP2FL）实现了近 12.78% 的性能提升，这表明了本文的方法的有效性。在 Imagenet-LT 的整体数据集中，Fed-LTNF 较其他算法有显著的性能提升。在处理异构数据的几类算法中，CCVR 性能优于其他算法，这也与 CIFAR 两个数据集上的实验结果相吻合，证明了 CCVR 算法使用虚拟表示训练分类器的有效性。其他几类算法均效果比 FedAvg 差或性能相近，这证明大部分的解决一般场景的异质性问题的算法在长尾分布这一特殊的场景中均

发挥不了效果。在处理不同客户端之间差异的三种算法中，比率损失仍然是效果最显著的，其余两种算法效果比 FedAvg 低。在解决联邦长尾问题的两种算法中，CReFF 效果相对略差，但是相较于其他算法仍然具有明显优势。FedETF 在未个性化时结果明显很低，在个性化之后其效果基本与 CReFF 持平。在总数据集上的对比结果基本与 CIFAR100-LT 中结论一致。然而，对比不同类别的效果，可以看出在多数类中，Fed-LTNF 算法明显优于其他算法，较最优的基线算法（CReFF）精度提高 20.98%，这可能因为本算法中使用了固定分类器可以在更复杂的环境中提高模型的准确度。此外，CLIP2FL 在多数类中性能并不突出，这证明 CLIP 中的知识并不能促进对样本特征的进一步学习。在中等类中 Fed-LTNF 算法较最优基线算法（CLIP2FL）提升了 7.75%，并且 CLIP2FL 较其他算法也有明显性能提升，这表明在样本稀少的类别中，CLIP 中的预训练信息可以帮助模型提取样本特征。在少数类中，CLIP2FL 较本算法有显著的精度提升，并且本算法的精度在所有算法中属于较好的水平。这是因为在少数类中样本数量极其稀少，导致在很多客户端中几乎没有这一类别的信息，因此很难获得有用的分类特征。然而 CLIP 模型本身就包含许多预训练信息，可以弥补客户端中没有样本的缺点，从而在极少数量样本的前提下依然能达到不错的训练效果。

4.3.4 消融实验与性能分析

如图 4.5 所示记录了从初始化模型到第 200 次通信回合期间，在 CIFAR100-LT 数据集上类向量和分类器向量的演化过程，并以每 50 次全局更新进行一次采样的频率进行了记录，并在图中与 FedAvg 进行了比较。其中， $\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \cdot \|\mathbf{b}\|}$ ， $\tilde{\mathbf{H}}_c = \mathbf{h}_c - \mathbf{h}_{avg}$ 。 $\mathbf{h}_c$ 是类别 c 的特征均值向量， $\mathbf{h}_{avg}$ 是所有样本特征的均值向量。将 $\mathbf{H}_c$ 记作类均值，将 $\mathbf{h}_c$ 记为类特征均值。 $\cos(\tilde{\mathbf{H}}_c, \mathbf{w}_c)$ 用于验证公式 4.11，即在平衡数据集下，类均值和类向量会相互收敛直至重合。不同的分类器向量之间是可以旋转对称的，这意味着在特征空间中不同分类器向量之间的角度差异是一致的。而在图中根据收敛结果可以看出，随着模型的优化，FedAvg 在 $\cos(\tilde{\mathbf{H}}_c, \mathbf{w}_c)$ 上表现优于本文的方法。FedAvg 在各类别中倾向于是一致的，然而本文方法随样本数量减少导致类向量与类均值之间角度差异逐渐加大。这是因为，在长尾分布的影响下， $\mathbf{h}_{avg}$ 发生了偏移，从而使得类均值不再平衡，而是偏向头部类别，而此时类向量本身也是在有偏数据中训练出来的，因此也是偏向头部类别。这种分类器向量与类均值互相收敛的属性在有偏数据集中也得到了验证，所以这种同样的有偏优化导致了分类器向量 $\mathbf{w}_c$ 与类均值 $\mathbf{H}_c$ 之间的角度差减小，这种变化符合神经网络的优化经验。而 $\cos(\mathbf{h}_c, \mathbf{w}_c)$ 用于验证分类结果崩溃为选择与样本特征向量在欧氏距离上最接近的类的类内均值的神经崩溃特征的特点，即在公式 $\mathbf{y} = \mathbf{w}\mathbf{x} + \mathbf{b}$ 中，在忽略常量偏置项的影响后，观测类特征均值向量和分类器向量之间的区别。在这一指标中，可以看到 FedAvg 在所有类别上的角度均有较大差异，使得模型对所有类别预测效果均不理想。在本文算法中，类特征均值向量和分类




图 4.5 训练过程中类向量与分类器之间余弦相似度的变化趋势

Fig. 4.5 Trend of cosine similarity between class vectors and classifier during training

器向量之间的角度差异随样本数量的减少而增加，并且即使少数类其角度差异也小于 FedAvg 算法。这也可以解释本文算法在多数类中预测准确度远高于 FedAvg，并且多数类中预测准确度比本算法少数类中预测准确度显著提高。本章算法与 FedAvg 算法在少数类中精度相近。并且分析这是因为在长尾分布中，FedAvg 使用分类器拟合在

特征空间中非对称的类均值,使得分类器学习了较大的先验概率,所以其预测结果整体偏低。反而本章算法使用样本特征拟合固定的对偶的分类器,分类器在各类别上是概率均等的,并且多样本数量类别可以学到更多的特征,而少数量类别即使学习特征不多,也不会导致少数类的类均值崩溃到互相收敛的情况,从而极大地促进了模型的正确分类。同时,可以看到 FedAvg 在这两个指标上的趋势完全不同,相反,本文的方法在两个指标的变化趋势上保持了较高的一致性。

$$\left\| \mathbf{W}^T / \|\mathbf{W}\|_F - \dot{\mathbf{M}} / \|\dot{\mathbf{M}}\|_F \right\|_F \rightarrow 0 \quad (4.11)$$

表 4.4 消融实验
Tab. 4.4 Ablation study

模块			数据集	
批归一化	正交旋转模块	平衡损失	CIFAR100-LT	CIFAR10-LT
✗	✗	✗	36.56	30.99
✗	✗	✓	39.83	52.66
✓	✗	✓	44.14	77.4
✓	✓	✓	45.54	77.45
FedAvg			36.35	59.36

表 4.5 温度系数敏感性质验证
Tab. 4.5 The verification of temperature coefficient sensitive properties

温度系数	是否可迭代	CIFAR100-LT	CIFAR10-LT
1	✗	19.88	52.11
1	✓	45.64	78.48
0.1	✗	44.54	74.88
0.1	✓	46.22	74.58
0.05	✗	42.25	69.11
0.05	✓	40.59	11.27

本文在 CIFAR100-LT 和 CIFAR10-LT 数据集上进行了消融实验如表 4.4所示,以研究不同模块的影响。基线方法为 FedAvg。批归一化表示是否在骨干网络后应用批归一化。正交旋转模块表示是否对最后一层线性层的输入特征应用可训练的正交矩阵。平衡损失表示是否在损失函数中使用 logit 调整。从表 4.4中结果可以看出,未应用除样本归一化的其他模块时,仅仅将 ETF 直接与特征提取器进行连接时,其结果低于 FedAvg 的精度,这是因为如果不对特征进行处理会使得特征分散,无法与分类器进行对齐,从而导致模型性能不佳,在 FedETF 中的实验结果也与这一结果相符合。此外,在应用有偏置项的预测概率后,通过损失修正有偏的梯度更新,可以在一定程度

上减少样本数量倾斜带来的有偏优化,但是依然无法减轻由于数据缺失带来的分类器影响,因此预测精度有了部分提升。采用批归一化可以将样本的均值和方差归一化到一个合适的范围并进行重构数据,使得样本特征类别间差异显著,类内差异减小,促进分类器与样本特征的对齐。此外,正交矩阵可以使得样本特征进行旋转,也会加速模型的收敛,但是正交矩阵终究不会增加网络深度,对模型的提取特征的能力提升有限,因此其效果并没有损失函数与批归一化那样显著。根据实验结果可以得出结论,平衡损失、批归一化和正交矩阵的使用对两个数据集上的模型性能都有正面影响。

本文记录了在不同温度条件下全局模型的测试结果,以研究温度系数的稳定性,具体见表 4.5。表中 τ_1 和 τ_2 条件一致,保持相同的初始值以及是否可学习的属性。从 CIFAR100-LT 和 CIFAR10-LT 数据集的结果中可以观察到,在温度系数设置为不可学习时,当温度系数适当减小时,性能有所提升。这是因为较小的温度系数可以使得损失增加,从而促进模型收敛;当损失过小时,就会使得轻微的噪声扰动会模型的梯度方向与幅度造成较大影响,从而又导致模型梯度爆炸,从而使得模型精度下降。而且,值得注意的是,对于两个数据集,最佳的温度系数参数条件是不同的,这表明温度系数是一个敏感的参数,很难通过手动设置找到其合适的值。当温度系数设置为可以被学习时,适当的较低的温度系数同样可以带来较好的收敛结果,并且温度系数在可学习时其初始化最佳值与不可学习时是不同的。此外,温度系数较高时在可学习的条件下通常能获得更好的效果。因此,结合以上条件,可以分析出来温度系数是一个极其敏感的参数,针对不同的数据集其最优值可能差异很大。虽然无法找到最优结果,但是可以取两种不同设置下的次优结果,以提高模型性能的基础上尽可能抵消温度系数的敏感属性。基于以上观察,本文认为,使用较低的固定温度系数和较高的可训练温度系数相结合,可以减少温度系数的敏感性,并提高模型在不同数据集上的泛化能力。

4.4 本章小结

在联邦长尾分布场景中,所有客户端的总数据集的不同类别之间数量差异较大,这会导致不同本地模型偏移全局优化目标。并且某些少样本数据会在大部分客户端中几乎没有样本。此外,不同客户端之间的数据分布还不满足 IID 条件,这会进一步增加联邦学习 Non-IID 的训练难度。为了解决联邦学习的长尾分布问题,本章提出了一种使用固定分类器的联邦学习算法 (Fed-LTNF)。在本算法中主要贡献是使用固定的 ETF 分类器作为模型分类器。具体来说,在本地训练中,首先使用常用的卷积网络作为模型特征提取器,然后利用批归一化层约束特征的均值和方差,之后使用模长归一化将样本特征归一化到单位球面上。然后使用一个刚性可旋转正交矩阵将特征进行空间旋转,从而将特征对齐到固定的分类器中,在正交矩阵后面是一个使用 ETF 结构的

固定分类器。此外，为了进一步减少样本数量对模型的影响，Fed-LTNF 算法使用了多种温度系数设置下的带有预测概率修正项的交叉熵损失。并且通过实验证明了温度系数的敏感属性，使用理论证明了预测概率修正项可以抵消样本数量对模型的有偏影响。在多种长尾分布数据集中，Fed-LTNF 算法与最先进的算法进行对比实验，并在 CIFAR100-LT 数据集上当不平衡系数 $IF=10$ 时实现了 8.91% 的精度提升，这些对比实验结果证明了本算法总体来说是十分有效的。此外通过消融实验更进一步了解了本算法中不同模块的作用，对 ETF 分类器在联邦学习中的应用提供了宝贵的经验。此外，通过对比特征向量与分类器向量之间的角度差异更进一步理解了 Fed-LTNF 起作用的关键原因。在不同温度系数下的实验结果也充分证明了温度系数的敏感属性，充分解释了本文损失的有效性和合理性。

5 结论与展望

5.1 结论

随着信息技术的快速发展,数据已成为推动人工智能(Artificial Intelligence, AI)和机器学习(Machine Learning, ML)进步的核心资源。然而,数据的集中化存储和处理引发了严重的隐私和安全问题。在此背景下,各国政府纷纷出台严格的数据隐私保护法规,如欧盟的《通用数据保护条例》(General Data Protection Regulation, GDPR)等。这些法规要求企业在处理用户数据时必须确保数据的隐私和安全,禁止未经用户同意的数据共享和滥用,对用户数据的收集、存储和使用提出了严格的要求。为了解决以上问题,联邦学习应运而生。联邦学习通过允许各方在不共享原始数据的情况下协同训练模型,为人工智能的发展提供了新的数据利用方式,解决了集中数据集的隐私安全问题以及迫于商业价值和安全等原因导致的数据孤岛问题,进一步促进了神经网络的发展。

然而,联邦学习中的一个核心挑战是 Non-IID 数据问题,即客户端之间的数据分布可能存在显著差异。在实际应用中,客户端的数据分布往往是高度异质的,如不同用户的手机使用习惯、不同地区的医疗数据分布等。研究 Non-IID 问题有助于提升联邦学习在实际应用中的可行性,使其能够更好地适应真实场景中的数据分布,提高联邦学习在实际环境中的泛化性能。本文针对联邦学习中的 Non-IID 数据问题在不同场景下的分布规律分别提出了两种创新性解决方案。

在一般的 Non-IID 条件下,即不同参与方的样本类别基本相同,但是不同类别的样本数据有较大差异的情况,本文提出了一种分类器辅助的联邦对比学习算法(CAFedCon)。在 CAFedCon 算法中核心思想是使用全局分类器辅助对比学习建立一个统一的特征空间,防止不同客户端本地训练过程中的优化方向的偏差,同时分类器可以进行图像分类的训练,将无监督对比学习扩展于有监督学习中,提高训练效率。在 CAFedCon 算法中首先全局服务器随机初始化全局模型并下发到指定的本地客户端,在本地训练过程中,首先利用全局模型初始化本地模型,并且设置全局模型梯度不可更新。然后将本地样本经过数据增强用以扩充样本数量,之后通过本地模型得到输出的预测类别概率和输出的特征,将样本经过全局模型得到不可参与梯度更新的对比特征和全局模型的预测概率。然后在本地模型的预测概率上进行基于样本数量的有偏置项的平衡的交叉熵损失计算,同时利用本地模型的输出特征和全局模型的输出特征以及全局分类器中各类别相关的分类器参数进行基于不同类别样本数量的平衡对比损失。在进行若干轮次后完成本地更新,之后模型上传服务器,服务器进行基于样本数量的全局聚合,完成全局模型的更新,之后下发全局模型并进行下一轮本地更新。

本算法的创新点在于提出了双分支网络以使用分类器辅助对比学习，并且使用了基于样本不均衡改进的交叉熵损失和有监督对比学习损失。实验证明 CAFedCon 算法在多项数据集中较几种典型的先进算法测试集上的预测精度有明显提升，并且在实验中多项数据集上较最优基线方法提升至少 2.6% 的预测精度。充分的实验结果证明了 CAFedCon 算法的有效性。

长尾分布是一种比一般条件的 Non-IID 更为复杂的数据不均衡场景，在该场景中不仅仅不同客户端之间的数据分布是 Non-IID 的，而且客户端的数据总量是长尾分布的，即不同类别的数据量差异显著，这种情况全局的长尾分布会严重影响少样本类别的识别准确度。针对这种联邦长尾分布场景，本文设计了一种使用固定分类器的联邦学习算法（Fed-LTNF），该算法通过分析分类器与样本的特征向量之间角度规律和长尾分布中数据量的关系，提出使用 ETF 框架预设模型分类器参数并且设置为不可更新。在该算法中，使用了常规的卷积层作为模型的特征提取器，之后使用批归一化和样本归一化用于约束特征的均值和方差，对特征进行重构。然后使用正交旋转矩阵用来实现对特征的刚性旋转，最后连接固定参数的分类器来减少长尾分布对分类器的不利影响。此外，本算法使用了结合两种不同的温度系数的损失，并且对温度系数基于样本数量进行调整，以避免温度系数的不稳定性带来的影响和样本数量对模型的有偏优化。在包括 Imagenet-LT 在内的多种数据集中该算法较比较的十多种基线算法均有显著的训练精度的提升。

5.2 创新点

本文的主要创新点可以总结为以下两个方面：

针对一般 Non-IID 条件，本文提出了一种结合全局分类器的联邦对比学习框架。在该算法中，本文提出了一种双分支网络并且使用有偏置项的交叉熵损失和适用于 Non-IID 数据的对比学习损失来进行本地训练。该算法通过引入全局分类器，使得本地模型能够更好地学习到与全局分布一致的特征表示，从而利用对比学习来缓解客户端数据分布差异带来的性能下降问题。

针对联邦长尾分布场景，本文提出了一种固定分类器的联邦学习算法。通过固定分类器的参数，本地模型能够专注于特征提取，减少长尾分布中类别分布不均衡对分类器的有偏优化，从而增加模型对少样本类别的拟合能力。

5.3 展望

尽管本文提出的方法在多个数据集上取得了显著的效果，但仍有一些值得进一步研究的方向：

- 在本文算法中，适用于各种场景的联邦学习算法都是从图像分类任务考虑的，这

是一种单一的任务场景。然而，在实际场景中，还包括图像分割，目标识别，无监督学习等多种多样的任务场景。将联邦学习 Non-IID 算法扩展到多种不同的任务中，可以使得联邦学习适应更多现实场景，有利于促进联邦学习的广泛应用。

- 在本文提出了多种算法，但是不同的算法都是根据一个较小的 Non-IID 场景而设计的任务，在未来学习和研究中，最终目标是考虑设计一个在多种 Non-IID 场景中都能有良好的泛化性能的算法框架。
- 在联邦学习中，尽管基于样本的聚合算法有一定的合理性，但是样本特征之间的差异可能是衡量不同模型差异的一种更合理的标准。在进一步研究中，本文会考虑基于不同客户端的特征差异对模型参数进行更合理的聚合，从而减少 Non-IID 数据对聚合过程的影响。

总之，本文针对联邦学习中的 Non-IID 问题提出了多种解决方案，并在多个数据集上验证了其有效性。未来，本文将从不同类别样本的特征差异出发继续深入研究联邦 Non-IID 中的关键问题，解决 Non-IID 问题对联邦学习的收敛性的影响。

参 考 文 献

- [1] Konecny J, McMahan H B, Felix X Y, et al. Federated Learning: Strategies for Improving Communication Efficiency [J]. CoRR, 2016.
- [2] Wang Q, Li Q, Wang K, et al. Efficient federated learning for fault diagnosis in industrial cloud-edge computing [J]. Computing, 2021, 103 (10): 2319–2337.
- [3] Fang C, He H, Long Q, et al. Exploring deep neural networks via layer-peeled model: Minority collapse in imbalanced training [J]. National Academy of Sciences, 2021, 118 (43): e2103091118.
- [4] Li T, Sahu A K, Talwalkar A, et al. Federated learning: Challenges, methods, and future directions [J]. IEEE Signal Processing Magazine, 2020, 37 (3): 50–60.
- [5] Mothukuri V, Parizi R M, Pouriyeh S, et al. A survey on security and privacy of federated learning [J]. Future Generation Computer Systems, 2021, 115: 619–640.
- [6] Wu C, Wu F, Lyu L, et al. Communication-efficient federated learning via knowledge distillation [J]. Nature communications, 2022, 13 (1): 2032.
- [7] Xiong Y, Wang R, Cheng M, et al. Feddm: Iterative distribution matching for communication-efficient federated learning [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Vancouver, Canada, 2023: 16323–16332.
- [8] Xu J, Glicksberg B S, Su C, et al. Federated learning for healthcare informatics [J]. Journal of Healthcare Informatics Research, 2021, 5: 1–19.
- [9] Chen M, Shlezinger N, Poor H V, et al. Communication-efficient federated learning [J]. National Academy of Sciences, 2021, 118 (17): e2024789118.
- [10] Deng Y, Lyu F, Ren J, et al. AUCTION: Automated and quality-aware client selection framework for efficient federated learning [J]. IEEE Transactions on Parallel and Distributed Systems, 2021, 33 (8): 1996–2009.
- [11] Luo L, Zhao N, Lodewijks G. Scheduling storage process of shuttle-based storage and retrieval systems based on reinforcement learning [J]. Complex System Modeling and Simulation, 2021, 1 (2): 131–144.
- [12] Zhu H, Jin Y. Multi-objective evolutionary federated learning [J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 31 (4): 1310–1322.
- [13] Sattler F, Wiedemann S, Müller K-R, et al. Robust and communication-efficient federated learning from non-iid data [J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 31 (9): 3400–3413.
- [14] Guo W, Tondi B, Barni M. A temporal chrominance trigger for clean-label backdoor attack against anti-spoof rebroadcast detection [J]. IEEE Transactions on Dependable and Secure Computing, 2023, 20 (6): 4752–4762.
- [15] Çavuşoğlu Ü, Kökçam A H. A new approach to design S-box generation algorithm based on genetic

- algorithm [J]. International Journal of Bio-Inspired Computation, 2021, 17 (1): 52–62.
- [16] Zhao Y, Zhao J, Yang M, et al. Local differential privacy-based federated learning for internet of things [J]. IEEE Internet of Things Journal, 2020, 8 (11): 8836–8853.
- [17] Li X, Huang K, Yang W, et al. On the Convergence of FedAvg on Non-IID Data [C]. International Conference on Learning Representations, Online, 2020.
- [18] Wang C, Yang Y, Zhou P. Towards efficient scheduling of federated mobile devices under computational and statistical heterogeneity [J]. IEEE Transactions on Parallel and Distributed Systems, 2020, 32 (2): 394–410.
- [19] Hu K, Wu J, Weng L, et al. A novel federated learning approach based on the confidence of federated Kalman filters [J]. International Journal of Machine Learning and Cybernetics, 2021, 12: 3607–3627.
- [20] Tan A Z, Yu H, Cui L, et al. Towards personalized federated learning [J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 34 (12): 9587–9603.
- [21] Mills J, Hu J, Min G. Multi-task federated learning for personalised deep neural networks in edge computing [J]. IEEE Transactions on Parallel and Distributed Systems, 2021, 33 (3): 630–641.
- [22] Ni X, Shen X, Zhao H. Federated optimization via knowledge codistillation [J]. Expert Systems with Applications, 2022, 191: 116310.
- [23] Zhou X, Yang Q, Zheng X, et al. Personalized Federated Learning With Model-Contrastive Learning for Multi-Modal User Modeling in Human-Centric Metaverse [J]. IEEE Journal on Selected Areas in Communications, 2024, 42 (4): 817–831.
- [24] 刘松, 罗杨宇, 许佳培, 等. 基于轻量自蒸馏的低成本联邦学习 [J]. 电子学报, 2025.
- [25] Lee G, Jeong M, Shin Y, et al. Preservation of the global knowledge by not-true distillation in federated learning [J]. Advances in Neural Information Processing Systems, 2022, 35: 38461–38474.
- [26] Yu F X, Rawat A S, Menon A K, et al. Federated learning with only positive labels [C]. International Conference on Machine Learning, Online, 2020.
- [27] Shi J, Zheng S, Yin X, et al. Clip-guided federated learning on heterogeneity and long-tailed data [C]. AAAI Conference on Artificial Intelligence, Vancouver, British Columbia, Canada, 2024: 14955–14963.
- [28] Bonawitz K, Ivanov V, Kreuter B, et al. Practical secure aggregation for privacy-preserving machine learning [C]. ACM SIGSAC Conference on Computer and Communications Security, Dallas, USA, 2017: 1175–1191.
- [29] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data [C]. Artificial intelligence and statistics, Amsterdam, Netherlands, 2017: 1273–1282.
- [30] Zhang C, Xie Y, Bai H, et al. A survey on federated learning [J]. Knowledge-Based Systems, 2021, 216: 106775.
- [31] Banabilah S, Aloqaily M, Alsayed E, et al. Federated learning review: Fundamentals, enabling tech-

- nologies, and future applications [J]. *Information processing & management*, 2022, 59 (6): 103061.
- [32] Liu Y, Kang Y, Xing C, et al. A secure federated transfer learning framework [J]. *IEEE Intelligent Systems*, 2020, 35 (4): 70–82.
- [33] Diao Y, Li Q, He B. Exploiting Label Skews in Federated Learning with Model Concatenation [C]. *AAAI Conference on Artificial Intelligence*, Vancouver, British Columbia, 2024: 11784–11792.
- [34] Hsieh K, Phanishayee A, Mutlu O, et al. The non-iid data quagmire of decentralized machine learning [C]. *International Conference on Machine Learning*, Online, 2020: 4387–4398.
- [35] Huang W, Li T, Wang D, et al. Fairness and accuracy in horizontal federated learning [J]. *Information Sciences*, 2022, 589: 170–185.
- [36] Lin J. On the dirichlet distribution [J]. *Department of Mathematics and Statistics, Queens University*, 2016, 40.
- [37] Jimenez G D M, Anagnostopoulos A, Chatzigiannakis I, et al. FedArtML: A Tool to Facilitate the Generation of Non-IID Datasets in a Controlled Way to Support Federated Learning Research [J]. *IEEE Access*, 2024.
- [38] Zakerinia H, Talaie S, Nadiradze G, et al. Communication-efficient federated learning with data and client heterogeneity [C]. *International Conference on Artificial Intelligence and Statistics*, Valencia, Spain, 2024: 3448–3456.
- [39] Wang D, Chen L, Lu X, et al. FedDBO: A Novel Federated Learning Approach for Communication Cost and Data Heterogeneity Using Dung Beetle Optimizer [J]. *IEEE Access*, 2024, 12: 43396–43409.
- [40] Zhao Y, Li M, Lai L, et al. Federated learning with non-iid data [J]. *arXiv preprint arXiv:1806.00582*, 2018.
- [41] Duan M, Liu D, Chen X, et al. Astraea: Self-balancing federated learning for improving classification accuracy of mobile deep learning applications [C]. *IEEE 37th International Conference on Computer Design*, Abu Dhabi, United Arab Emirates, 2019: 246–254.
- [42] Shin M, Hwang C, Kim J, et al. Xor mixup: Privacy-preserving data augmentation for one-shot federated learning [J]. *arXiv preprint arXiv:2006.05148*, 2020.
- [43] Yoon T, Shin S, Hwang S J, et al. FedMix: Approximation of Mixup under Mean Augmented Federated Learning [C]. *International Conference on Learning Representations*, Online, 2021.
- [44] Kortoçi P, Liang Y, Zhou P, et al. Federated split GANs [C]. *ACM Workshop on Data Privacy and Federated Learning Technologies for Mobile Edge Network*, New York, NY, USA, 2022: 25–30.
- [45] Fallah A, Mokhtari A, Ozdaglar A. Personalized federated learning with theoretical guarantees: A model-agnostic meta-learning approach [J]. *Advances in Neural Information Processing Systems*, 2020, 33: 3557–3568.
- [46] Hanzely F, Richtárik P. Federated learning of a mixture of global and local models [J]. *arXiv preprint arXiv:2002.05516*, 2020.

- [47] Liang P P, Liu T, Ziyin L, et al. Think locally, act globally: Federated learning with local and global representations [J]. arXiv preprint arXiv:2001.01523, 2020.
- [48] Jeong E, Oh S, Kim H, et al. Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data [J]. arXiv preprint arXiv:1811.11479, 2018.
- [49] Ghosh A, Chung J, Yin D, et al. An efficient framework for clustered federated learning [J]. Advances in Neural Information Processing Systems, 2020, 33: 19586–19597.
- [50] Misra I, Maaten L v d. Self-supervised learning of pretext-invariant representations [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Online, 2020: 6707–6717.
- [51] Wang T, Isola P. Understanding contrastive representation learning through alignment and uniformity on the hypersphere [C]. International Conference on Machine Learning, Online, 2020: 9929–9939.
- [52] Hadsell R, Chopra S, LeCun Y. Dimensionality reduction by learning an invariant mapping [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, New York, NY, USA, 2006: 1735–1742.
- [53] Schroff F, Kalenichenko D, Philbin J. Facenet: A unified embedding for face recognition and clustering [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Boston, MA, USA, 2015: 815–823.
- [54] Oord A v d, Li Y, Vinyals O. Representation learning with contrastive predictive coding [J]. arXiv preprint arXiv:1807.03748, 2018.
- [55] 史彩娟, 张昆, 赵琳, 等. 基于像素与层级双对比的语义分割 [C]. 第十七届全国信号和智能信息处理与应用学术会议论文集, 重庆, 2023: 403–411.
- [56] Pappayan V, Han X, Donoho D L. Prevalence of neural collapse during the terminal phase of deep learning training [J]. National Academy of Sciences, 2020, 117 (40): 24652–24663.
- [57] Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations [C]. International Conference on Machine Learning, Online, 2020: 1597–1607.
- [58] Li Q, He B, Song D. Model-contrastive federated learning [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Online, 2021: 10713–10722.
- [59] Tan Y, Long G, Ma J, et al. Federated learning from pre-trained models: A contrastive learning approach [J]. Advances in Neural Information Processing Systems, 2022, 35: 19332–19344.
- [60] Mu X, Shen Y, Cheng K, et al. Fedproc: Prototypical contrastive federated learning on non-iid data [J]. Future Generation Computer Systems, 2023, 143: 93–104.
- [61] Belkin M, Hsu D, Ma S, et al. Reconciling modern machine-learning practice and the classical bias–variance trade-off [J]. National Academy of Sciences, 2019, 116 (32): 15849–15854.
- [62] Yang Y, Chen S, Li X, et al. Inducing neural collapse in imbalanced learning: Do we really need a learnable classifier at the end of deep neural network? [J]. Advances in Neural Information Processing Systems, 2022, 35: 37991–38002.
- [63] Li Z, Shang X, He R, et al. No fear of classifier biases: Neural collapse inspired federated learning

- with synthetic and fixed classifier [C]. IEEE/CVF International Conference on Computer Vision, Paris, France, 2023: 5319–5329.
- [64] Graf F, Hofer C, Niethammer M, et al. Dissecting supervised contrastive learning [C]. International Conference on Machine Learning, Online, 2021: 3821–3830.
- [65] Audibert A, Gauffre A, Amini M-R. Exploring contrastive learning for long-tailed multi-label text classification [C]. Joint European Conference on Machine Learning and Knowledge Discovery in Databases, Vilnius, Lithuania, 2024: 245–261.
- [66] Zhang F, Kuang K, Chen L, et al. Federated unsupervised representation learning [J]. Frontiers of Information Technology & Electronic Engineering, 2023, 24 (8): 1181–1193.
- [67] Zhu J, Wang Z, Chen J, et al. Balanced Contrastive Learning for Long-Tailed Visual Recognition [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, LA, USA, 2022: 6898–6907.
- [68] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Las Vegas, NV, USA, 2016: 770–778.
- [69] Jing L, Vincent P, LeCun Y, et al. Understanding Dimensional Collapse in Contrastive Self-supervised Learning [C]. International Conference on Learning Representations, Online, 2022.
- [70] Cui Y, Jia M, Lin T-Y, et al. Class-balanced loss based on effective number of samples [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 2019: 9268–9277.
- [71] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks [J]. Advances in Neural Information Processing Systems, 2012, 25.
- [72] Le Y, Yang X. Tiny imagenet visual recognition challenge [J]. CS 231N, 2015, 7 (7): 3.
- [73] Karimireddy S P, Kale S, Mohri M, et al. Scaffold: Stochastic controlled averaging for federated learning [C]. International Conference on Machine Learning, Online, 2020: 5132–5143.
- [74] Zhang Y, Kang B, Hooi B, et al. Deep long-tailed learning: A survey [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023.
- [75] Shuai X, Shen Y, Jiang S, et al. Balancefl: Addressing class imbalance in long-tail federated learning [C]. ACM/IEEE International Conference on Information Processing in Sensor Networks, Milan, Italy, 2022: 271–284.
- [76] Liu J, Sun Y, Han C, et al. Deep representation learning on long-tailed data: A learnable embedding augmentation perspective [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Online, 2020: 2970–2979.
- [77] Yin X, Yu X, Sohn K, et al. Feature transfer learning for face recognition with under-represented data [C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition, Long Beach, CA, USA, 2019: 5704–5713.
- [78] Peifeng G, Xu Q, Wen P, et al. Feature directions matter: Long-tailed learning via rotated balanced representation [C]. International Conference on Machine Learning, Honolulu, HI, USA, 2023:

27542–27563.

- [79] Lezcano-Casado M, Martinez-Rubio D. Cheap orthogonal constraints in neural networks: A simple parametrization of the orthogonal and unitary group [C]. International Conference on Machine Learning, Los Angeles, CA, USA, 2019: 3794–3803.
- [80] Li Z, Li X, Yang L, et al. Curriculum temperature for knowledge distillation [C]. AAAI Conference on Artificial Intelligence, Washington D.C., USA, 2023: 1504–1512.
- [81] Suh M-K, Seo S-W. Long-tailed recognition by mutual information maximization between latent features and ground-truth labels [C]. International Conference on Machine Learning, Honolulu, HI, USA, 2023: 32770–32782.
- [82] Zhang S, Chen C, Hu X, et al. Balanced knowledge distillation for long-tailed learning [J]. Neurocomputing, 2023, 527: 36–46.
- [83] Ren J, Yu C, Ma X, et al. Balanced meta-softmax for long-tailed visual recognition [J]. Advances in Neural Information Processing Systems, 2020, 33: 4175–4186.
- [84] Cao K, Wei C, Gaidon A, et al. Learning imbalanced datasets with label-distribution-aware margin loss [J]. Advances in Neural Information Processing Systems, 2019, 32.
- [85] Russakovsky O, Deng J, Su H, et al. Imagenet large scale visual recognition challenge [J]. International Journal of Computer Vision, 2015, 115: 211–252.
- [86] Shi J, Zheng S, Yin X, et al. CLIP-Guided Federated Learning on Heterogeneity and Long-Tailed Data [C]. AAAI Conference on Artificial Intelligence, Vancouver, British Columbia, Canada, 2024: 14955–14963.
- [87] Hsu T-M H, Qi H, Brown M. Measuring the effects of non-identical data distribution for federated visual classification [J]. arXiv preprint arXiv:1909.06335, 2019.
- [88] Lin T, Kong L, Stich S U, et al. Ensemble distillation for robust model fusion in federated learning [J]. Advances in Neural Information Processing Systems, 2020, 33: 2351–2363.
- [89] Luo M, Chen F, Hu D, et al. No fear of heterogeneity: Classifier calibration for federated learning with non-iid data [J]. Advances in Neural Information Processing Systems, 2021, 34: 5972–5984.
- [90] Wang J, Liu Q, Liang H, et al. Tackling the objective inconsistency problem in heterogeneous federated optimization [J]. Advances in Neural Information Processing Systems, 2020, 33: 7611–7623.
- [91] Sarkar D, Narang A, Rai S. Fed-focal loss for imbalanced data classification in federated learning [J]. arXiv preprint arXiv:2011.06283, 2020.
- [92] Wang L, Xu S, Wang X, et al. Addressing class imbalance in federated learning [C]. AAAI Conference on Artificial Intelligence, Online, 2021: 10165–10173.
- [93] Kang B, Xie S, Rohrbach M, et al. Decoupling Representation and Classifier for Long-Tailed Recognition [C]. International Conference on Learning Representations, New Orleans, LA, USA, 2019.
- [94] Shang X, Lu Y, Huang G, et al. Federated learning on heterogeneous and long-tailed data via classifier re-training with federated features [J]. arXiv preprint arXiv:2204.13399, 2022.