

学校代码: 10730

分类号: TP3

密级: 公开

兰州大学

硕士学位论文

(专业学位)

论文题目 (中文) 面向非独立同分布数据的联邦学习研究

论文题目 (外文) Research on Federated Learning for Non-Independent and Identically Distributed Data

作者姓名 杨霄

类型领域 电子信息·计算机技术

研究方向 联邦学习

教育类型 学历教育

指导教师 刘刚 副教授

合作导师

论文工作时段 2023 年 9 月至 2025 年 3 月

论文答辩日期 2025 年 5 月

校址: 甘肃省兰州市城关区天水南路 222 号

面向非独立同分布数据的联邦学习研究

中文摘要

随着深度神经网络的快速发展和数据量的激增,深度学习算法模型在目标检测、自然语言处理、图像识别等诸多领域广泛应用,并发挥了重要作用。当前,深度学习模型的训练过程通常采用集中式架构,依赖于强大的计算资源和大量的数据。然而,随着数据规模的不断扩大和模型复杂度的增加,传统的集中式训练方式面临着数据孤岛问题、模型泛化性能低、数据收集成本高昂和隐私保护法规严格等一系列挑战。在这种现实的驱动下,分布式训练逐渐成为解决这些问题的有效手段,应用于移动设备、医疗保健和自动驾驶等领域。

联邦学习作为一种新兴的分布式学习范式,它允许多个客户端参与全局模型的协作训练,而无需访问他们的私人数据,从而在一定程度上保障数据隐私,并有效利用分散的计算资源和数据,受到了各领域学者广泛的关注。尽管取得了显著的成功,但数据异构性仍困扰着联邦学习研究,即客户端的非独立同分布数据。该问题会导致局部模型漂移,造成模型遗忘全局知识,并进一步导致模型性能显著下降和收敛缓慢。这主要归因于在非独立同分布数据条件下,最小化局部经验损失和最小化全局经验损失不一致,局部模型仅使用局部数据进行模型更新,即局部模型最小化局部经验损失。

本文基于联邦学习面临非独立同分布的数据挑战,针对不同的数据异构性的场景,利用生成器和知识蒸馏技术,旨在生成全局数据分布以微调模型,设计了基于生成模型的无监督知识蒸馏方法,主要研究内容如下:

(1) 本文针对标签分布倾斜、数量倾斜的非独立同分布数据场景,考虑到局部设备数据的类不平衡性和全局数据分布的不确定性,在分类模型输入层面,提出了一种无监督的知识蒸馏方法,将服务器中的本地类级伪数据样本方案迁移到全局模型中进行微调。具体来说,首先为每个客户端提供条件变分自编码器,以在服务器中维护一个动态生成器,该生成器集成了客户端数据的异质性特征及类级分布信息。这种灵活的生成器一方面生成表示全局类级分布的辅助数据集,以调节局部模型作为归纳知识偏差。另一方面,它采用无监督知识提炼来增强聚合模型的性能。大量实验表明,该算法明显优于目前最先进的联邦学习算法,并且可以作为灵活的插件集成到现有的联邦优化算法中,以提高模型性能。

(2) 本文针对概念偏移、特征分布倾斜的非独立同分布数据场景，考虑到各客户端特征的不一致性，提出了一种基于生成器和原型增强的双重微调策略。具体而言，该方法首先在服务器端利用轻量级辅助生成器对集成客户端模型的潜在特征空间进行建模，并将生成结果下发至各客户端以指导本地训练；同时，服务器端构建了一个可训练的全局原型网络，通过引入原型自适应边际对比损失函数，最大化客户端特征空间中各类别之间的可分性，并同步参与本地微调。实验结果表明，在概念偏移和特征分布倾斜的非独立同分布数据场景下，提出的方法能够显著提升全局模型的收敛速度和泛化能力。

综上所述，本文针对不同场景下的非独立同分布数据，分别从数据和特征层面提出了相应的联邦学习算法，以在数据异构的场景下，实现高效的联邦学习，实现最佳的模型性能。

关键词：联邦学习，生成模型，非独立同分布数据，知识蒸馏

RESEARCH ON FEDERATED LEARNING FOR NON-INDEPENDENT AND IDENTICALLY DISTRIBUTED DATA

Abstract

With the rapid development of deep neural networks and the surge in data volume, deep learning models have been extensively employed in various domains, such as object detection, natural language processing, and image recognition, playing a pivotal role in these fields. Currently, the training of deep learning models is predominantly conducted under a centralized paradigm, relying on powerful computational resources and massive datasets. However, as data volumes continue to grow and model complexity increases, conventional centralized training faces a range of challenges, including data silos, limited model generalization, high data-collection costs, and strict privacy protection regulations. Driven by these practical concerns, distributed training has gradually emerged as an effective solution and has been widely adopted in applications such as mobile devices, healthcare, and autonomous driving.

Federated learning, as a burgeoning paradigm of distributed learning, enables multiple clients to collaboratively train a global model without accessing their private data. This preserves fundamental privacy while efficiently utilizing dispersed computational resources and data, which has attracted extensive attention across diverse research fields. Despite remarkable progress, data heterogeneity—in other words, non-independent and identically distributed (non-IID) data on clients—continues to pose significant challenges for federated learning. Such heterogeneity can cause local model drift, leading to catastrophic forgetting of global knowledge and ultimately resulting in significant performance degradation and slow convergence. The underlying reason is that when data are not IID, minimizing the local empirical loss is not necessarily aligned with minimizing the global empirical loss, as local models are only updated using local data.

This thesis addresses the challenges posed by non-IID data in federated learning, specifically targeting scenarios with varying data heterogeneity. By leveraging generative models and knowledge distillation techniques, the paper proposes a

framework for generating a global data distribution to fine-tune the model. The key contributions of this research are as follows:

1.Addressing Label Distribution Skew and Quantity Skew in Non-IID Data:

In scenarios where label distribution is skewed and data quantity varies, and considering the statistical heterogeneity present in local models as well as the uncertainty in the global model's data distribution, we propose an unsupervised knowledge distillation method at the model input level. This method transfers local class-level pseudo-data samples from the server to the global model for fine-tuning. Specifically, we introduce a conditional autoencoder for each client to maintain a dynamic generator on the server, which integrates client heterogeneity and class-level information. This flexible generator, on the one hand, generates an auxiliary dataset that reflects the global class-level distribution, which helps adjust the local model as an inductive bias. On the other hand, it employs unsupervised knowledge distillation to enhance the performance of the aggregated model. Extensive experiments demonstrate that our approach significantly outperforms state-of-the-art FL algorithms and can be integrated flexibly as a plugin into existing FL optimization algorithms, thereby improving model performance.

2.Addressing Concept Shift and Feature Distribution Skew in Non-IID Data:

In scenarios characterized by concept shift and feature distribution skew, where client features exhibit noticeable inconsistency, we propose a dual fine-tuning method based on a generator and prototype augmentation. Specifically, our algorithm uses a lightweight auxiliary generator on the server side to model the latent feature space of aggregated client models and then transmits these generated features to the clients to guide local training. In addition, we maintain a lightweight, trainable global prototype network on the server, which leverages a prototype-adaptive margin contrastive loss to maximize class separability across the feature spaces of different clients. This network is subsequently dispatched to the clients for local fine-tuning, thereby significantly boosting model performance while preserving privacy. Experimental results show that, under concept shift and feature distribution skew, the proposed approach not only accelerates convergence but also enhances the generalization performance of the global model, outperforming existing federated learning optimization algorithms.

In conclusion, this thesis proposes federated learning algorithms tailored for different non-IID data scenarios, focusing on both data and feature layers, to achieve

efficient federated learning and optimize model performance in heterogeneous data environments.

Keywords: Federated Learning, Generative Models, Non-IID data, Knowledge Distillation

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.2.1 非独立同分布数据相关研究.....	3
1.2.2 联邦优化策略.....	7
1.2.3 联邦知识蒸馏.....	8
1.2.4 研究成果汇总.....	11
1.3 论文研究内容.....	12
1.4 论文组织结构.....	15
第二章 相关理论和技术研究	17
2.1 联邦学习.....	17
2.1.1 联邦学习框架.....	18
2.1.2 非独立同分布数据.....	19
2.1.3 FedAvg 算法介绍	21
2.2 生成器.....	23
2.2.1 生成对抗网络.....	24
2.2.2 条件生成对抗网络.....	25
2.2.3 条件变分自编码器.....	26
2.3 知识蒸馏.....	27
2.3.1 知识蒸馏的一般形式.....	28
2.3.2 知识蒸馏算法分类.....	28
2.4 本章小结.....	30
第三章 基于生成模型的无监督集成蒸馏联邦学习算法	31
3.1 引言.....	31
3.2 问题分析.....	35
3.3 联邦重采样微调算法.....	36
3.3.1 算法动机.....	37
3.3.2 数据采样.....	39
3.3.3 集成蒸馏.....	41
3.3.4 算法流程.....	43
3.4 与现有研究的异同.....	46
3.4.1 目标不同.....	47
3.4.2 实现不同.....	48
3.5 实验与性能评估.....	49

3.5.1 实验设置.....	49
3.5.2 模型性能与分析.....	51
3.6 本章小结.....	57
第四章 基于生成模型与原型增强的双重微调联邦学习算法	59
4.1 引言.....	59
4.2 问题分析.....	60
4.3 联邦双重微调算法.....	62
4.3.1 算法动机.....	63
4.3.2 生成模型辅助微调.....	65
4.3.3 原型增强对齐.....	68
4.3.4 算法流程.....	71
4.4 与现有研究的异同.....	72
4.4.1 目标不同.....	72
4.4.2 实现不同.....	73
4.5 实验与性能评估.....	73
4.5.1 实验设置.....	73
4.5.2 模型性能与分析.....	75
4.6 本章小结.....	81
第五章 总结与展望	82
5.1 总结.....	82
5.2 展望.....	84
参考文献.....	85

图目录

图 1-1	本文主要研究内容与组织结构	15
图 2-1	集中式联邦学习和分散式联邦学习	18
图 2-2	通过（条件）自动编码器生成	23
图 2-3	通过（条件）对抗生成模型生成	25
图 2-4	通过条件变分自编码器（CVAE）生成	27
图 2-5	基于 logits 的知识蒸馏	29
图 2-6	基于特征的知识蒸馏	30
图 3-1	FedRef 的整体框架	37
图 3-2	CIFAR10 上基于不同来源数据的模型微调性能	38
图 3-3	Fashion MNIST 上基于不同来源数据的模型微调性能	38
图 3-4	集成蒸馏示意图	41
图 3-5	CIFAR10 数据集上不同 α 取值的狄利克雷分布下的可视化	50
图 3-6	CIFAR10 上不同 FL 方法在 1000 轮通信中的学习曲线	52
图 3-7	CIFAR100 上不同 FL 方法在 1000 轮通信中的学习曲线	52
图 3-8	数据异质性影响下的模型测试准确率	55
图 3-9	联邦客户端模型贡献率影响下的模型测试准确率	56
图 3-10	客户端采样率影响下的模型测试准确率	57
图 4-1	FedDualAlign 的整体框架	63
图 4-2	生成数据对决策边界的影响	64
图 4-3	不同模型类别嵌入特征之间的关系	65
图 4-4	CIFAR10 数据集上不同 α 取值的狄利克雷分布下的可视化	74

图 4-5	CIFAR10 数据集上不同通信轮次各算法的准确率.....	76
图 4-6	CIFAR100 数据集上不同通信轮次各算法的准确率.....	77
图 4-7	Fashion MNIST 数据集上不同通信轮次各算法的准确率	79

表目录

表 2-1	非独立同分布数据的分类与示例	20
表 3-1	章节符号说明	34
表 3-2	损失函数说明	35
表 3-3	FedRef 在不同非独立同分设置下的测试准确率	51
表 3-4	目标测试准确率所需的通信轮数	51
表 3-5	FedRef 对现有的 FL 优化器的影响	53
表 3-6	算法达到目标测试准确率的轮数	54
表 3-7	FedRef 在高数据异质性划分下测试准确率	54
表 3-8	FedRef 各模块对测试准确率的影响	56
表 4-1	FedDualAlign 在 CIFAR10 数据集上的试准确率	75
表 4-2	FedDualAlign 在 CIFAR100 数据集上的测试准确率	77
表 4-3	FedDualAlign 在 Fashion MNIST 数据集上的测试准确率	78
表 4-4	在 CIFAR10 上 FedDualAlign 各模块的有效性	80

第一章 绪论

本章节首先对联邦学习的基本概念和现实应用进行介绍,并进一步分析其面临的主要挑战。紧接着讨论了国内外学者对于联邦学习面临的主要挑战提出的各种方法,并进行了对比和总结。随后,分析了现有研究,对本文的主要研究内容和创新点进行了说明。最后,针对论文组织架构进行了简要阐述。

1.1 研究背景及意义

近年来,深度学习技术蓬勃发展,在各领域广泛应用^[1],发挥了重要的作用。深度学习的应用和发展离不开海量高质量标注的数据,根据国家互联网信息办公室发布的《数字中国发展报告(2022年)》显示,2022年,从数据产量方面,我国数据产量达8.1ZB,同比增长22.7%,占全球数据总产量的10.5%;从数据存量方面,数据存储量达724.5EB,同比增长21.1%,占全球数据总存储量的14.4%。数据作为人工智能模型训练的关键,推动着人工智能的发展,也推动着生产力的发展,如智慧城市、智能医疗、智能网联车等产业的发展。同时,在大数据的时代,海量的数据分布在不同的用户、不同的企业中的不同设备之中,在当前的工业界用于训练的模型中,采用的数据往往来自于用户的私人数据,此外,由于隐私保护、行业竞争等因素的存在,不同企业或个体维护用以模型训练的数据集之间有着天然的壁垒,因此数据基本上以孤岛的形式存在。传统的集中式的机器学习^[2,3]的数据处理方式,在分布存储具备隐私性需求的数据上也不再适用。因此,在隐私性需求的情况下,如何有效的利用各方数据、边缘算力是人工智能发展的重要问题之一。

为了在隐私保护的需求下有效利用移动设备的算力和数据,联邦学习(Federated Learning)概念应运而生,应用于移动设备^[4]。联邦学习模型训练涉及多个客户端设备和一个服务器设备,客户端设备作为一个用户基于本地设备通过本地数据来训练模型,实现局部的更新达到学习的效果,客户端的原始数据不会发生交换或者转移,服务器端设备用以指导客户端的模型融合。具体来说,多个客户端经过本地更新、服务器端融合协同训练全局的神经网络模型,完成语义分割任务^[5,6]。在隐私保护的需求下,训练过程中客户端的数据是相互独立的,本地的数据不被其他客户端以及服务器端可见,全局模型通过客户端上传神经网络模型参数,在服务器端实现聚合。联邦学习作为一种去中心化存储和去中心化计算的模型,本地数据被有效保护,部分边缘算力资源也被有效利用,大幅提升了

网络的可扩展性。传统地针对单一数据源的集中式训练^[7]的方式使得模型的泛化能力有限,而联邦学习受益于多方参与,避免了单一数据源导致的模型泛化能力不足的问题,同时推动了多方数据的有效利用。联邦学习作为一个分布式机器学习范式,在满足隐私保护和数据安全的前提下,为构建数据安全的人工智能产业提供了新方向^[8],已成为当前学术界和工业界的关注热点。

数据作为模型训练的关键,高质量的人工智能模型依赖于高质量的数据,然而,联邦学习进行模型训练的数据来自于不同的用户,存在着一个关键的挑战:用户的数据在统计上具有异质性,是非独立同分布(Non-Independent and Identically Distributed, Non-IID)^[9,10]的。这种用户间的非独立同分布的数据会使得模型发散,相比独立同分布的数据会使得模型的泛化性能和收敛速度下降,非独立同分布的数据主要是由于用户之间的差异导致的,比如所处环境场景,数据采集能力和采集偏好等,在统计学习上表现为 Non-IID 数据。在联邦学习中的非独立同分布数据一般分为概念偏移、特征分布倾斜、数量倾斜、标签分布漂移、标签喜好漂移等五类^[10,11]。此外,联邦学习面临的第二个挑战是有限的带宽资源会限制客户端和服务端端的权重参数传递,移动设备与服务器之间的权重传递会消耗大量的带宽资源,造成传输延迟,进而使服务器端模型聚合性能下降^[12,13]。联邦学习面临的第三个挑战是跨域泛化问题,数据收集场景的差异导致模型性能下降,现有的工作在域泛化相关的数据集上进行了深入研究^[14-18]。最后联邦学习面临的第四个挑战是安全问题,如模型的协同训练过程中聚合的正确性和拜占庭鲁棒性问题^[19,20],通过共享的梯度信息分析推断出隐私问题^[21,22]等。针对现有方法存在的不足,在保证数据隐私的条件下,本文使用知识蒸馏和生成器对全局知识进行进一步泛化,来进一步解决联邦学习面临的非独立同分布数据的主要挑战。

非独立同分布的数据主要是不同的客户端之间,在数据的标签、特征和数量三个方面存在一些差异。当前针对联邦学习,为针对数据之间存在的差异,兼容了多种技术,如生成对抗网络、扩散模型、知识蒸馏、超网络、强化学习、元学习等等。知识蒸馏作为其中之一^[23,24],由 Hinton 等人^[25]提出,通过预训练性能优秀的“教师模型”的知识传递给“学生模型”,从而提升学生模型的性能^[26,27]。相较于其他的学习方式,知识蒸馏可以在涉及多个模型异构的情境下,将“知识”传递到指定的模型,也因此,知识蒸馏技术可以用至联邦学习中,联邦学习一般通过权重参数来进行模型聚合^[4]。进一步的,现有的一些联邦学习算法主要针对性地采用了生成器来完成对客户端局部知识或者是全局模型的知识进行提取,而后主要采用知识蒸馏技术或者是二次训练进一步进行模型的微调^[28-35]。值得注意的是,知识蒸馏和生成器在已有的联邦学习工作中^[29,36,37]相比基线模型性能表现出强劲的竞争力。

1.2 国内外研究现状

联邦学习技术由谷歌研究团队于 2016 年提出,旨在保护用户隐私的同时进行模型更新。随后设计了面向现实应用的联邦学习系统,并部署运行了所提出的 FedAvg 算法^[4]。FedAvg 算法作为目前最常用的联邦学习算法,仍然受到学者的广泛关注,并作为诸多研究工作的基准算法。

过去几年,深度神经网络在计算机视觉、推荐系统和大语言模型等领域表现优异而受到广泛关注^[38-40]。然而,深度神经网络优势在于大规模数据的支持,考虑到当下数据量的激增,计算资源和数据收集的难度,从而使得收集各方数据到中央服务器进行训练受到严重的阻碍。联邦学习允许多方参与者在中央服务器的帮助下进行协作训练深度神经网络,由于其轻量级技术方案的优势,联邦学习已经成为解决隐私计算问题的核心方法,有效地打破了数据孤岛的局面。随着联邦学习的应用和发展,在各大顶级会议中多方学者发表了大量的联邦学习研究成果^[41]。

非独立同分布数据作为联邦学习面临的主要挑战,本文将围绕现有的研究成果进行分析。同时,本文将着重解读本研究所采用的生成器和知识蒸馏技术在联邦学习技术上的运用,以及现有研究方案的不足。最后,本文将总结相关研究在解决非独立同分布数据方面的不足和优势。

1.2.1 非独立同分布数据相关研究

非独立同分布数据形成背后的机制是多方面的,包含有不同用户行为差异和偏好的变化,不同的数据的收集过程,如传感器的种类,收集频率等,都进一步促进了数据的非独立同分布特征。具体来说,非独立同分布数据对联邦学习产生了深远的影响,体现在通信效率、模型训练过程、收敛速度和模型整体的性能等四个主要的方面。结合现有的研究成果,本文围绕非独立同分布数据带来的影响,归纳出六个主要的解决方向,分别是服务器端模型聚合策略对全局泛化能力的提升,通过辅助数据集在服务器端进行微调或者对本地数据进行补充的方案,个性化联邦学习根据每个参与者的数据特征提供个性化策略优化模型性能,基于原型的联邦学习算法通过优化类特征一致性进行学习,联邦优化算法通过促进局部客户端的更新方向的一致性而提升模型性能,联邦知识蒸馏通过知识蒸馏技术促进模型之间的知识传递,生成器辅助的联邦学习通过对模型的输入空间或者潜在特征空间进行建模并主要通过知识蒸馏技术进行知识的传递以提升模型的性能。上述技术因为划分比较细,部分现有研究可能包含多个技术来进行优化,下文将展开详细介绍。

1.2.1.1 模型聚合研究

在联邦学习中,模型聚合是指在每一轮通信中对各方的模型参数进行聚合,形成新的全局模型。因此,隐私保护通过聚合模型参数而非原始的训练数据来实现。由于非独立同分布数据的影响,基于不同设备的数据训练的模型相对最优模型存在模型漂移问题,聚合后的全局模型也存在不同客户端模型更新方向不一致而导致的性能下降问题,但是总体而言,模型聚合能够一定程度上获得全局泛化能力优于局部客户端的模型,目前研究主要基于 FedAvg 算法进行优化研究。

FedAvg 算法是最常用的联邦学习算法,也是最早的联邦学习算法,算法流程中每一轮的通信中随机选择随机一组客户端进行聚合,聚合过程中对每个客户端的参数进行加权和平均,从而获得全局模型。一般来说权重因子随着不同设备的数据量比例设置。Deng 等人^[42]发现由于部分设备计算资源有限的原因,不愿参与到联邦学习中,其次,存在训练数据异构型,局部设备更新质量会有很大差异,聚合低质量的模型更新可能会降低全局模型的质量,基于上述发现提出了 FAIR 算法,将模型质量评估纳入到了聚合中,滤除了不理想的局部模型更新。Ma 等人^[43]在个性化联邦学习研究中创新性地提出了分层个性化联邦学习 pFedLA 算法,通过辨别不同客户端每一层的重要性,从而为模型聚合提供了更优的个性化模型聚合策略。Wang 等人^[44]结合传统的支持向量机进行选择式聚合,并对类嵌入上施加最大间隔扩展正则化,从而显著加速了联邦学习模型的收敛,尤其是存在部分客户端更新缓慢的情况下更加有效。Feng 等人^[45]提出了 FedIns 算法,通过实例自适应推理处理数据异构性,FedIns 提出了使用预训练模型和参数高效的微调方法(Scale and Shift Deep Features, SSF),在每个客户端维护一个 SSF 池,并在服务器端进行聚合。Fan 等人^[46]采用了聚类算法,根据客户端能力进行聚类,执行两阶段聚合以更好地利用共享知识。

当前模型聚合策略主要包括模型加权聚合、客户端评估与选择、客户端聚类等方法。这些策略能够在一定程度上提升非独立同分布场景下的联邦学习模型性能,并与一般的个性化联邦学习,联邦优化算法和联邦域泛化等研究方向正交,在特定的配置下能够共同提升模型性能。但值得注意的是上述模型聚合方向仍然主要通过“评估”的方式进行的聚合,会消耗一定的计算资源,缺乏对全局知识的感知。

1.2.1.2 辅助数据集

辅助数据集的关键在于建立一个相关的数据集,或者是评估数据集,此数据集可以被下载,能够用于服务器端模型微调或者构建类平衡的本地数据集,从而提升模型的性能。

Zhao 等人^[9]通过创建一个设备共享的子数据集,从服务器端分发到客户端,旨在通过构建类平衡的子数据集,并使其参与到局部模型更新中,从而减少各客户端数据分布的差异。Jeong 等人^[47]提出了 Faug 算法,通过每个设备共同训练一个生成模型,并在服务器端下发到各个设备,用以生成局部客户端缺失的数据,进而解决非独立同分布场景下客户端数据的异构性。Lin 等人^[37]将客户端未标记的数据集上传到服务器端,将未标记数据上传服务器,通过知识蒸馏技术和辅助数据集降低非独立同分布数据对模型性能的影响。Gong 等人^[48]引入了无标签的外援数据集,供本地设备下载,在本地模型更新完成后通过外援数据集提取模型输出和本地模型的知识,上传至服务器进行聚合获取全局知识,模型通过缩小本地知识和全局知识的差异来实现本地模型的优化。Sattler 等人^[49]提出了 FedAUX 算法,通过对辅助数据无监督预训练获得初始化模型,并根据客户端模型和辅助数据进行预测加权,提升模型性能。

通过采用辅助数据集的方式补充局部设备缺失的数据,能够一定程度上降低局部数据的异构性,提升模型性能。此外,通过局部数据集进行模型的集成蒸馏也能够促进模型之间的知识传递,提升模型的泛化性能。但是在一定程度上,采用辅助数据集会破坏用户的隐私需求,并在实际的应用中,辅助数据集的收集会带来通信成本的增加,而且在面临用户数据分布不可知的场景下或高度个性化的场景下,辅助数据集的提升效果有限。

1.2.1.3 个性化联邦学习

联邦学习作为一种流行的分布式机器学习范式,具有优秀的协作学习能力和隐私保护能力。传统的联邦学习通过局部模型更新和服务器聚合,以迭代的方式学习单一的全局模型。由于数据异构性的存在,在该模式下学习的全局模型存在一般存在表示偏差。为了解决统计异构性,不同于传统的联邦学习,个性化联邦学习被提出,除了学习一个全局模型之外,还能够为局部的客户端维护一个个性化模型,但局部客户端数据相对于全局数据分布仍然存在分布偏差,这种偏差也进一步影响着局部设备的个性化模型的性能。

Arivazhagan 等人^[50]提出了 FedPer 算法,通过将深度神经网络分为“基础层”和“个性化层”进行训练,基础层通过联邦平均 (FedAvg) 共享,个性化层仅在本地设备训练,以应对用户数据的统计异质性。Li 等人^[51]提出了 Ditto 算法,使用了一个超参数 λ 来控制个性化模型与全局模型的偏移,提升模型的准确性、鲁棒性和公平性。Collins 等人^[52]提出了 FedRep 算法,学习全局低维表示,并为每个客户端学习特定的本地分类头,以适应独特标签分布。Chen 等人^[53]提出了 FedRoD 算法,引入了平衡风险最小化用于全局模型的训练,以及基于客户端数

据的经验风险最小化用于个性化模型的训练。FedRoD 将一个共享的特征提取器与两个不同的预测头（分别为全局预测头和个性化预测头）结合起来，从而实现了全局共享和本地定制的平衡。Zhang 等人^[54]提出了 FedCP 算法，通过冻结全局模型头部，仅训练个性化部分，确保全局信息与个性化需求平衡。Yang 等人^[55]提出了 FedAS 算法，通过对齐共享参数与本地数据特征，计算 Fisher 信息矩阵为客户端分配不同权重，减少客户端间不一致性。

面对非独立同分布数据，个性化联邦学习从另一种角度给出了解决方案：面对数据异构性，提供了新的模型能够更好地适应单个数据分布。个性化联邦学习在一定程度上为局部客户端获取高效的人工智能模型降低了数据异构性带来的影响，但是不同于传统的联邦学习获取单一的模型，个性化联邦学习一定程度上在计算和存储资源上对训练设备提出了更高的要求。

1.2.1.4 基于原型的优化

值得注意的是，近期的研究还探索了一种基于原型（prototype）的方法来解决联邦学习中数据异构性带来的问题。这类方法通常通过原型交换、对比学习及知识蒸馏等方式实现高效的信息共享和模型优化。

Tan 等人^[56]提出了一种名为 FedProto 的新型联邦学习框架，该框架通过原型（prototype）进行聚合和通信，以解决 FL 训练中由于客户端异质性导致的优化收敛和泛化问题。核心思想是客户端与服务器交换抽象的类原型，而不是梯度或模型参数，在该方法中证明了原型作为模型知识载体的有效性。Tan 等人^[57]提出了 FedPCL 联邦原型对比学习，该方法通过使用多个预训练模型作为编码器，并融合它们的表示来实现个性化学习，而无需从头开始训练大型模型。核心思想是利用类原型作为信息载体，客户端与服务器之间共享这些原型，采用对比学习方法来对齐本地和全局原型，从而有效地捕获类相关信息并保护隐私。Kim 等人^[58]提出了名为 ProtoFL 的无监督联邦学习方法，结合了原型蒸馏和流式归一化单类分类器。在该方法中，首先使用预训练的模型和数据集生成原型表示，并将其分发给各个客户端，从而避免了频繁的数据共享，并降低了通信成本。然后，在每个客户端上，基于流式归一化模型进行单类分类学习，估计目标类的分布。Zhang 等人^[59]提出 FedTGP 算法，通过在服务器端引入可训练的全局原型和自适应边界增强对比学习，解决了现有原型聚合方法的边界收缩问题。最后，现有部分研究^[60,61]也引入了对比学习来增强模型的泛化性能，获得了有竞争力的性能。

基于原型的联邦学习方法通过抽象的原型表示有效地降低了联邦系统中的通信和计算开销，同时增强了客户端与服务器间的信息共享效率，显著缓解了数据异构性带来的模型性能下降问题。然而，在大规模部署场景下，原型的构建质

量对模型的泛化性能具有显著影响,高质量的原型能够更有效地提升联邦学习的全局优化效果。

1.2.2 联邦优化策略

联邦优化策略的关键在于调整局部设备模型更新的方向和步长^[62-64]。尤其在处理非独立同分布 (Non-IID) 数据时,联邦优化算法通过对局部设备模型的更新方向和步长进行调控,确保不同设备的模型能够有一致的更新方向和步长。联邦优化算法一般根据模型的历史信息和更新梯度的一致性,控制局部模型的梯度变化,确保每个设备的更新步调一致,贡献能够平衡且准确地反映到全局模型中,从而提高模型在跨设备学习中的鲁棒性和准确性。这些优化策略不仅能有效解决数据分布不均的问题,由于一般计算复杂度较低,能够加速模型的收敛速度,并最终实现更优的全局学习效果。

开创性工作 FedAvg 在非独立同分布数据场景下取得了一定的成功,但是并没有完全解决数据异构性带来的潜在挑战。FedAvg 允许局部模型完全执行本地更新,没有作以一定的约束,并且,通常情况下会丢弃没有完全完成局部训练的模型。因此,经常会出现局部模型更新方向和步长的不一致,导致模型存在更新差异,并且 FedAvg 也难以识别局部模型更新的一致性。为了解决以上问题,联邦优化方面研究被广泛的学者关注。Li 等人^[65]提出了 FedProx 算法,旨在解决联邦学习中的系统异质性和统计异质性问题。与传统的 FedAvg 方法相比, FedProx 在每轮训练中允许设备根据其计算能力执行不同数量的本地更新。此外, FedProx 引入了一个“邻近项”到本地优化问题中,从而限制本地更新偏离全局模型的程度,帮助在面对数据分布不一致时保持稳定的收敛性。Acar 等人提出了一种基于动态正则化的联邦学习方法,称为 FedDyn^[66]。该算法通过动态修改每个设备的本地目标函数,加入惩罚项,来确保设备模型与全局最优解一致。Reddi 等人^[67]提出了一种新的适应性联邦优化方法,称为 FEDOPT,通过动态调整学习率来应对数据异质性,客户端使用自适应优化器进行更新。Li 等人^[68]提出了 MOON 算法,MOON 的核心思想是通过模型对比学习来调整各个客户端的局部训练,最大化本地模型表示与全局模型表示之间的一致性,从而纠正局部更新的偏差。该方法通过引入对比损失函数,增强了全局模型和本地模型之间的表示一致性,同时减少了数据分布差异带来的影响。Karimireddy 等人^[69]提出了 SCAFFOLD 算法,它的核心思想是通过估计全局模型和各客户端模型的更新方向差异(即客户端漂移),并利用该差异来校正每个客户端的局部更新。Chen 等人^[70]提出了一种新的聚合方法——弹性聚合。具体来说,弹性聚合根据参数敏感度调整聚合方式,避免服务器模型向某客户端数据分布漂移。参数敏感度是通过计算参数变化对整

体预测结果的影响来测量的。对于敏感的参数，弹性聚合减少其更新的幅度，以避免服务器模型向某一客户端的数据分布漂移；而对于不太敏感的参数，则增加其更新的幅度，从而更好地探索不同客户端的数据分布。

联邦优化策略能够有效提升非独立同分布场景下模型的性能，尤其是在数据具有较大异构性时，通过优化客户端间的协同学习过程，减少了因数据分布差异而导致的性能退化。与传统的集中式训练方法不同，联邦优化策略通过本地更新和全局聚合相结合，不仅能在一定程度上缓解数据隐私和通信成本的问题，还能在异构数据场景下实现更好的泛化能力。然而，从另一种角度看，这种优化方法主要均衡各个模型的更新，在一定程度上对模型的更新带来了限制，面临着模型收敛速度较慢、全局模型的适应性差等挑战，因此在实际应用中，需要通过精细化设计的优化算法，进一步提高模型的训练效率和效果。

1.2.3 联邦知识蒸馏

联邦知识蒸馏是一种结合了联邦学习和知识蒸馏的优化策略，旨在通过不同设备之间的协作，提高全局模型的学习效果，尤其是在数据分布不均或非独立同分布数据的情况下。在这种策略下，局部设备不仅仅根据传统的梯度更新进行训练，还通过与其他设备共享知识（如软标签，潜在特征向量或模型输出）来优化模型的性能。值得注意的是，除了直接利用本地知识以外，联邦知识蒸馏一般会与生成器或者辅助数据集一同使用。具体来说，在联邦知识蒸馏中，每个设备通过蒸馏过程从全局模型或其他设备的知识中提取信息，进而调整本地模型的学习方向和步长。通过这种方式，局部设备可以有效学习到全局知识，并减少由数据不均匀或设备差异引起的学习偏差。蒸馏过程通过控制模型输出的一致性和相似度，确保不同设备的模型朝着相同的目标进行更新，并进行模型知识的传递，从而加速收敛并提高全局模型的准确性以及模型的泛化性能。

联邦知识蒸馏主要针对联邦学习领域的四种问题进行解决，分别是模型异构性问题，数据异构性问题，高通信成本问题和隐私问题。联邦知识蒸馏解决模型异构性问题方面，Li 等人^[36]提出 FedMD 传统的联邦学习要求所有参与方采用相同的模型架构，而 FedMD 允许每个参与者设计自己的独立模型，并通过知识蒸馏进行知识共享。参与方首先使用公共数据集进行预训练，在协作阶段传输分类分数至中央服务器，服务器计算平均值并分发给所有参与者，最终优化本地模型。Lin 等人^[37]提出了一种新的联邦学习模型融合方法，其核心方法基于集成蒸馏。在 FedDF 中，服务器在每轮训练中收集客户端模型，并利用它们的预测结果对无标签数据进行集成蒸馏，从而生成一个全局模型，而不直接平均模型参数。Zhu 等人^[28]提出了一种无数据知识蒸馏算法，该方法通过学习一个轻量级生成器来提

取和融合用户信息,无需依赖额外的代理数据集。生成器利用用户模型的预测规则,在特征空间中生成符合用户数据分布的特征表示,并将其传输给用户,作为归纳偏置来引导本地模型训练。在解决高通信成本问题方面,Jeong 等人^[47]在服务器端通过加权聚合获取类级全局知识,之后将全局知识下发到本地设备,最后本地设备通过蒸馏方式缩小与全局知识的差异,实现模型优化。这种方式,通过小尺寸的知识载体的设计,大幅降低了通信成本。在解决隐私问题方面,Chang 等人^[71]通过在通信轮次中交换模型对未标记的辅助数据集的输出来进行知识的传递,取代了参数平均的过程,能够有效降低隐私泄露的风险。

1.2.3.1 联邦知识蒸馏与数据异构性

联邦知识蒸馏在解决数据异构性方面,主要从以下三方面的研究:以共享的辅助数据集为标杆,进行局部模型和全局模型的知识传递;以本地客户端数据的分布知识为目标,通过引入生成器或者表征转换网络学习局部客户端知识,将引入的网络作为知识的载体结合分类模型进行知识蒸馏;以服务器端引入轻量级生成器学习模型的输入空间或者潜在特征向量,进行模型集成蒸馏或下发至客户端进行本地训练的指导。联邦学习算法中一般引入共享的辅助数据集,经常会通过知识蒸馏的方式进行知识的传递(章节 1.2.1.2),本节主要从后两个方面进行介绍。

基于客户端数据分布的知识为目标,设计本地生成器以捕获数据层面的知识,一般为局部客户端模型的输入空间和潜在空间建模,而后上传局部客户端的生成器到服务器端,并通过知识蒸馏技术进行模型更新。Qi 等人^[72]提出了一种异构联邦学习框架 FedBKD,每个客户端使用其私有数据训练自己的 CVAE 模型,并将训练好的 CVAE 上传到服务器,来生成一个合成数据集,随后 FedBKD 选择将 logits 作为知识载体,通过全局模型和局部模型交叉蒸馏来进行模型更新。Heinbaugh 等人^[31]提出了新的无数据(Data-Free)一次性联邦学习(One-Shot federated learning, FL)方法, FedCVAE-KD,用于应对极高统计异质性的场景。这些方法通过条件变分自编码器(CVAE)来建模局部数据分布,从而减少不同客户端数据分布差异的影响。FedCVAE 要求局部客户端维护一个生成器,并上传至服务器端,在服务器端利用蒸馏后的服务器端解码器来生成合成数据,并用以训练全局模型。Yang 等人^[32]提出了 FedFed 算法,作为一种针对联邦学习中数据异质性和隐私保护问题的新方法,通过在客户端提取原始数据的性能敏感特征和性能稳健特征,实现有效的信息共享与隐私保护。FedFed 使用生成器从原始数据中分离出性能稳健特征并保留在本地,提取出性能敏感特征后加入噪声以保护隐私,再共享给服务器构建全局数据集。各客户端结合本地数据和共享的全局

数据集进行本地训练,最终通过全局模型聚合提升整体性能。这种方式在保障数据隐私的同时,有效增强了模型的准确性与泛化能力。Kang 等人^[73]提出了一种新的生成模型辅助联邦学习 (Generative Model-Aided Federated Learning, GeFL) 框架。GeFL 通过生成器聚合客户端知识并生成合成样本,帮助客户端训练异构目标模型。值得注意的是,上述方法主要通过生成器来捕获模型的本地数据的知识,并主要通过知识蒸馏技术进行模型间知识的传递。该方案在一定程度上能够捕获到客户端数据的局部分布,但对于全局数据集的分布仍然没有有效利用。

基于服务器端的全局模型或者部分局部模型训练生成器,用以模型间的知识传递方法也受到了广泛的关注。Zhu 等人^[28]提出了 FedGen 方法,它在服务器端训练一个轻量级的生成器,该生成器不依赖于任何外部数据,而是利用用户模型的预测规则生成特征表示。具体来说, FedGen 采用一个轻量级的生成器学习模型的潜在特征空间,而后下发至局部设备,用以指导模型训练。Li 等人^[74]提出了 FedKT 算法,通过知识转移技术实现跨数据孤岛的单轮模型训练,减少通信次数。Zhang 等人^[35]提出了一种新的数据无关 (Data-Free) 的一次性联邦学习框架 DENSE,通过生成器生成合成数据,并使用集成模型的知识训练全局模型,支持异构客户端且保持数据隐私。Zhang 等人^[29]提出了 FedFTG 算法,通过生成器学习客户端模型的输入空间,并以此传递本地知识到全局模型。FedFTG 采用数据生成 + 知识蒸馏的方法,在服务器端微调 (fine-tune) 聚合后的全局模型,提高其泛化能力。Wang 等人^[30]提出了一种新的数据无关的鲁棒蒸馏算法 DFRD,通过双生成器策略增强了对分类器的输入空间学习,有效提升了模型性能。Dai 等人^[33]提出了 Co-Boosting 框架,通过数据增强和集成模型优化互相促进来提高服务器端模型的质量。Yang 等人^[75]提出 FedDISC 算法,通过预训练扩散模型生成高质量的合成数据,首先,服务器端从带标签数据中提取原型,并发送给客户端;客户端利用这些原型对本地无标签数据进行伪标注,并计算聚类中心和领域特定表示,以捕捉个体化数据分布;然后,客户端将这些信息(加噪后)上传至服务器,服务器利用预训练生成模型生成符合客户端分布的合成数据;最后,服务器基于合成数据训练全局模型,无需客户端进行本地训练。Chen 等人^[76]提出了公平联邦学习框架 AFed,通过全局数据分布提升公平性,使用双生成器减少偏差。该方法类似于知识蒸馏,但不依赖教师-学生框架。

综上所述,基于知识蒸馏的方式和现有的生成器技术能够有效提升非独立同分布数据场景下的模型性能。值得注意的是,上述研究在进行模型间知识传递时,主要采用了生成器来捕获局部数据的知识,或者是全局数据的知识,对于模型性能提升非常有效,并在一定程度上通过生成器输出作为知识的载体,能够避免隐私泄露,提升对模型对全局数据分布的感知。

1.2.4 研究成果汇总

模型聚合策略在联邦学习中扮演着至关重要的角色。该研究方向的核心目的是通过对多个客户端的模型进行聚合，生成一个全局模型，提升全局泛化能力。然而，这些聚合策略依然面临模型漂移、计算资源的限制以及聚合效率的挑战，尤其是在非独立同分布数据的情况下，聚合过程可能导致性能下降。同时，受设备异构性影响大，模型更新可能不一致。

辅助数据集的主要目标是通过建立高效的共享子数据集来解决客户端数据分布的差异，进而提升模型的训练效果。通过服务器端微调或数据增强，辅助数据集可以帮助减轻数据异构性问题。然而，辅助数据集的引入可能导致隐私泄露问题，且增加了通信开销。在实际应用中，辅助数据集的效果也受限于数据分布的不可预测性。

个性化联邦学习通过为每个客户端提供专门的个性化模型，旨在减轻全局模型与本地数据分布之间的差异。方法如 FedPer、Ditto 和 FedRep 在处理数据异构性方面取得了显著进展，但个性化模型会增加计算和存储负担，且模型的个性化程度与全局模型之间仍然存在一定的偏差，这影响了局部设备的模型更新。

联邦优化策略通过调整局部设备的模型更新方向和步长，确保不同设备在训练过程中具有一致的更新方向。这些优化算法，如 FedProx、FedDyn 和 SCAFFOLD，能够有效提高非独立同分布数据场景下模型的性能，特别是在设备计算能力和数据分布不均的情况下。但这些方法可能在模型收敛速度和全局模型的适应性方面仍然面临挑战。

联邦知识蒸馏结合了联邦学习与知识蒸馏技术，致力于通过设备之间的协作共享知识，从而提高全局模型的准确性和泛化能力。方法如 FedMD 和 FedDF 通过知识蒸馏技术有效提升模型性能，减少了模型异构性和数据不均的问题，并能够结合生成器来更好地捕获全局数据分布或者模型知识。缺点是引入了额外的计算需求，不过这种计算资源主要集中在服务器端计算，传统的联邦学习在服务器端几乎没有额外的计算。部分联邦知识蒸馏算法结合生成器在一定程度上利用了空闲且强大的服务器端算力，加速了模型的收敛速度，增强了模型泛化性能。综合来说，考虑到未来深度神经网络研究面临数据匮乏^[77]，以及生成器在类不平衡模型研究中产生的重要作用，联邦知识蒸馏采用生成器辅助的方法对于解决非独立同分布数据颇具前景。

1.3 论文研究内容

为了提升非独立同分布数据场景下联邦学习模型的性能,即模型泛化能力和加速收敛,在当下已经成为了一个重要的研究方向。面向非独立同分布的挑战,国内外学者在这方面开展了深入的研究,提出了多种优化方法,如模型聚合策略,共享辅助数据集、联邦优化策略、联邦知识蒸馏、个性化联邦学习等。相比之下,联邦知识蒸馏在面向模型异构性问题,数据异构性问题,高通信成本问题和隐私问题等具有独特的优势。由于面临非独立同分布数据的影响和数据隐私保护的需求,以及联邦学习训练过程中模型漂移的问题和通信效率问题,现有的研究成果仍然存在优化空间,如更高效的数据分布生成,模型潜在特征向量对齐等。联邦学习中采用的非独立同分布数据主要表现为两个方面:一是**数据类别数量的分布不均衡**,二是**类间与类内特征差异性**。接下来,本节将对这两个方面进行简要阐述:

数据类别数量的分布不均衡。客户端数据的标签分布差异、数量倾斜和特征分布差异,导致传统的模型聚合策略难以有效整合各客户端信息,严重影响全局模型的性能与适应性。针对这一问题,目前研究多侧重模型参数更新的优化,如FedProx、FedDyn和SCAFFOLD,通过调整局部更新的方向与步长缓解数据异质性影响。然而,这类方法忽略了数据本身的分布特性,导致局部更新难以准确逼近全局最优路径,使模型泛化性能受限。尽管结合知识蒸馏和生成器的方法在缓解数据异构性与保护隐私方面表现出优势,但在充分挖掘本地数据分布特征、精确刻画全局数据结构方面仍存在不足。

类间与类内特征差异性。联邦学习中,特征分布偏移与概念偏移造成的类间与类内特征差异,致使客户端模型更新不一致,严重影响了全局模型的收敛性和泛化性能。这种现象在图像识别、自然语言处理和自动驾驶等领域普遍存在,且违背传统的独立同分布假设。当前通过特征域对齐和生成器驱动特征对齐等方法,可以在一定程度上提升模型泛化能力,但如何有效利用局部数据分布特征,进一步增强全局特征一致性并加速收敛,仍面临诸多挑战。

综上,本论文基于现有研究,主要研究采用**知识蒸馏技术和高效生成器,促进模型输入空间和特征空间的知识传递,解决非独立同分布场景下联邦学习模型性能下降的问题,并在此基础上实现模型的更快收敛**。本研究着力于提升非独立同分布场景下的模型泛化能力,主要研究内容和创新如下:

(1) 针对标签分布倾斜、数量倾斜的非独立同分布数据场景,考虑到局部设备数据的类不平衡性和全局数据分布的不确定性,本文提出了一种名为FedRef的创新方法。该方法结合了条件变分自编码器和知识集成蒸馏技术,旨在拟合模

型输入空间,促进模型间知识均衡传递,进而增强全局模型的性能,克服不同客户端数据分布的挑战。面向数据标签分布倾斜,数量倾斜的非独立同分布数据场景, FedRef 采用了易于收敛的 CVAE 网络,在与客户端的通信中没有直接将全局模型传输到各个客户端。在首轮的通信中, FedRef 接收来自客户端维护的 CVAE 解码器,在后续每一轮通信中,服务器端根据客户端的类分布信息,通过构造输入矩阵,控制 CVAE 解码器生成相应的数据样本,在服务器端以无监督的方式进行全局模型的微调,在保证隐私要求的情况下,有效地将客户端模型地知识转移到全局模型中。CVAE 编码器将输入数据映射到潜在空间,学习了数据的潜在特征,而解码器从数据的潜在空间重构输入数据或者生成新的数据。由于解码器主要负责生成输出数据,而编码器用于从输入中学习潜在特征并建模其隐变量分布,因此两者在模型中的功能相对独立。通过 CVAE 局部化训练,学习局部设备的潜在数据分布,并将解码器上传至服务器端,实际上是将已经学到的潜在空间的生成能力传输到服务器。服务器能够使用这些生成能力来基于独热编码 (One Hot Encoding) 和高斯分布生成伪数据。通过巧妙地利用 CVAE 结构,结合 CVAE 的快速收敛特性,能够减少边缘设备的计算压力,同时利用生成器作为局部设备数据分布的载体,能够有效学习到局部数据的分布,并在服务器端通过蒸馏的方式促进全局模型对局部知识的感知,增强模型的泛化能力和性能。此外,通过实验发现, FedRef 能够有效降低模型所需的通信轮次,加快全局模型的收敛。相比于现有采用辅助数据集的方法^[9,37,47-49], FedRef 具备三个较大的优势,首先是通信资源方面, FedRef 仅有额外的首轮传输模型参数的通信成本,远低于服务器端和客户端共享数据集和伴随模型训练过程进行的生成器更新,但是在一定程度上仍然不及直接通过知识的传递。其次是数据隐私保护方面, FedRef 通过生成器作为载体,能够获得更加有效的隐私保护。最后是收敛速度和模型性能方面, FedRef 不同于对未知的全局数据分布做定义,而通过采用生成器,利用知识集成蒸馏技术来促进模型的更新,在模型的收敛速度和泛化性能方面具有优势。值得注意的是, FedRef 方法与现有的部分联邦优化工作正交,能够在其基础上进一步优化模型性能,并且不同于现有的联邦知识蒸馏方法^[31,32,72,73],他们通过生成器维护稳健特征或者是生成数据直接用以训练, FedRef 通过 CVAE 解码器学习的客户端数据的分布信息,在服务器端进行了集成蒸馏,能够更加有效地促进集成模型向全局模型的知识传递。

(2) 针对概念偏移、特征分布倾斜的非独立同分布数据场景,考虑到各客户端特征的不一致性,本文提出了一种名为 FedDualAlign 的创新方法。该方法结合了生成器与原型增强的双重微调策略,具有多个显著优势。首先, FedDualAlign 通过引入轻量级辅助生成器,在服务器端对客户端的潜在特征空间

进行建模,引导客户端进行特征空间对齐,从而有效减少了客户端间的特征差异,提升了全局模型的泛化能力。与现有方法^[28,29]不同,生成器的训练仅通过一致性损失和简单的多样性损失来进行,导致生成器生成的数据与真实数据的分布存在偏差。因此,本算法针对生成器设计了新的匹配损失、输出差异损失以及增强的多样性损失,并在客户端的局部训练中引入了生成器。这一创新设计使生成器能够更有效地提升模型性能,并加快了模型的收敛速度,从而在保证隐私保护的前提下,大幅优化了联邦学习的训练效率和效果。其次,为了进一步加速模型的收敛速度,本算法引入了全局原型网络^[59],该网络在服务器端通过局部客户端的类原型进行训练。值得注意的是,本文进一步设计了全新的自适应边际对比损失函数,该损失函数能够智能地调整类原型之间的间距,增强模型在不同类别间的快速识别能力。这一设计使得模型能够更高效地捕捉类别之间的差异,提升了分类精度。在客户端局部训练过程中,本算法通过引入原型对比损失和领域重加权损失,进一步促进了同类特征的拉近,确保了各客户端训练过程中数据分布的协调性和一致性,从而加速了模型的收敛。与现有的原型设计相比^[59,56],FedDualAlign在优化收敛速度方面表现更为出色,并在性能和收敛速度之间取得了较好的平衡,显著减少了通信资源的需求。此外,方法通过创新的生成器和原型增强策略,有效地缓解了客户端之间的特征不一致性,确保了全局模型在面对分布倾斜和概念偏移的挑战时,依然能够保持高效的收敛和强大的泛化能力。实验结果表明,FedDualAlign不仅显著提升了全局模型的收敛速度和泛化能力,而且能够有效应对客户端特征不一致的问题,超越了现有的联邦学习优化算法,并为进一步提升联邦学习性能提供了新的思路。值得注意的是,本算法的生成器通过无数据(data free)方式训练,仅从特征层面学习模型的潜在表示,能够有效保护用户数据隐私。

综上所述,本文主要解决标签分布倾斜、数量倾斜以及概念偏移、特征分布倾斜的非独立同分布数据场景中的性能挑战问题。首先,FedRef通过CVAE网络和知识集成蒸馏技术有效解决了数据分布差异问题,提升了全局模型的泛化能力,并加速了模型的收敛速度,特别是在数据隐私保护和通信效率方面表现出显著优势。其次,FedDualAlign通过生成器与原型增强的双重微调策略,在特征空间对齐和模型蒸馏方面发挥了重要作用,优化了全局模型对客户端特征不一致性的适应能力,并提升了收敛速度和模型性能。此外,FedDualAlign还在保证隐私保护的同时,通过创新的无数据训练方式进一步降低了通信成本,提高了联邦学习框架的整体效率。这些方法在实际应用中能够显著提高全局模型的收敛速度、泛化能力和隐私保护水平,超越了现有的联邦学习优化算法,为未来的联邦学习研究和应用提供了新的思路 and 方向。

1.4 论文组织结构




图 1-1 本文主要研究内容与组织结构

本论文共分为五个章节，研究架构如图 1-1 所示，具体章节结构安排如下：

第一章为绪论部分。本章首先概述了联邦学习的背景及其在数据隐私保护和多方协作中的重要意义，并介绍了联邦学习在解决非独立同分布（Non-IID）数据问题中的挑战。随后，详细分析了联邦学习面临的主要问题，包括通信瓶颈、模型性能下降和数据隐私保护的需求，分析了现有研究方向的最新进展，并指出目前研究方法的不足。接着，阐述了本文的主要研究内容和创新点，聚焦于利用生成器和知识蒸馏技术解决非独立同分布数据场景下的性能问题。最后，本章简要介绍了论文的整体框架和各章节安排。

第二章为相关理论与技术研究部分。本章介绍了本文所依赖的基础技术，包括联邦学习的基本原理、针对联邦学习的非独立同分布数据问题的解决方法，知

识蒸馏技术、生成模型技术、对比学习算法以及在联邦学习中应用的优化策略。通过对相关理论和技术的讲解，为后续研究提供理论支持。

第三章为 FedRef 算法的研究。本章针对标签分布倾斜和数量倾斜的非独立同分布数据场景，提出了一种基于条件变分自编码器（CVAE）和知识集成蒸馏技术的创新方法 FedRef。首先，介绍了 FedRef 算法的基本框架，并通过条件变分自编码器（CVAE）生成数据样本的方式有效克服客户端数据分布的挑战。然后，本章详细描述了 CVAE 生成器的训练过程、生成能力的利用以及如何通过集成蒸馏提升模型性能并加速模型的收敛。最后，通过实验验证了 FedRef 在提升泛化能力、收敛速度和隐私保护方面的优势。

第四章为 FedDualAlign 算法的研究。本章针对概念偏移和特征分布倾斜的非独立同分布数据场景，提出了一种结合生成器与原型增强的双重微调策略的创新方法 FedDualAlign。首先，本章介绍了 FedDualAlign 的整体框架，包括轻量级生成器用于潜在特征空间建模和全局原型网络的引入。接着，详细阐述了如何通过生成器进行特征空间对齐，如何设计新的匹配损失和输出差异损失来优化生成器的性能，并介绍了原型对比损失和领域重加权损失的作用。最后，通过实验验证了 FedDualAlign 在提升全局模型的泛化能力和加速收敛速度方面的优势。

第五章为展望部分。本章首先总结了全文的研究工作，回顾了 FedRef 和 FedDualAlign 算法的主要贡献，并分析了其在解决非独立同分布数据问题中的实际效果。随后，针对当前方法的不足和未来研究的方向进行展望，讨论了如何进一步优化生成器与知识蒸馏结合的策略，提升算法的效率和应用范围。最后，展望了联邦学习在多领域应用中的前景，尤其是在数据隐私保护和模型性能优化方面的进一步发展。

第二章 相关理论和技术研究

本章将深入解析所涉及的相关技术和理论背景。首先,介绍联邦学习框架,并阐明其在分布式机器学习中的优势,尤其是在处理非独立同分布(Non-IID)数据时的挑战与应对策略。接着,探讨非独立同分布数据的分类方法,并讨论如何通过 Dirichlet 分布生成这类数据,进一步支持联邦学习中的模型训练。随后,详细解析 FedAvg 算法,作为联邦学习中的经典算法,分析其在多方数据分布下的应用效果。除此之外,本章还介绍生成对抗网络及其变种,包括条件生成对抗网络和条件变分自编码器(CVAE),这些生成模型在本研究中具有重要作用,同时也会探讨 Diffusion 算法的独特优势,以及分析知识蒸馏的基本原理及其不同的实现形式,包括基于模型、特征以及模型集成的蒸馏方法,讨论其在提升深度学习模型性能中的应用。最后,本章简要介绍对比学习方法,作为一种高效的无监督学习技术,它在联邦学习训练中展示了重要价值。通过这些技术的详细分析,为后续的研究提供了坚实的理论基础和技术支持。

2.1 联邦学习

从网络结构角度观察,联邦学习主要可划分为集中式和分散式两种类型。在集中式设置中,系统通常采用星形拓扑设计,由一个中央节点承担整合各客户端训练成果的任务,而各个客户端则依赖本地数据进行独立模型训练,如图 2-1(a)所示。集中式的联邦学习中,服务器是网络的关键组件,用于协调客户端的训练,并且进行模型的聚合分发。这种方法计算和管理简单,但对服务器的可靠性和通信效率要求较高。不同于集中式联邦学习,分散式联邦学习^[78]采用了拓扑结构,如图 2-1(b)所示,在这种结构中没有中央服务器,每个客户端根据私有数据训练模型,并选择与其他客户端进行通信,以点对点(P2P)的方式进行交换本地模型,以网状结构协同训练。这种去中心化的设计增强了系统的鲁棒性,减少了单点故障的风险,并降低了对可信第三方的依赖。分散式联邦学习设计主要用于服务器通信不可用,或者是网络拓扑具备高扩展性,可以局部代表集中式联邦学习或者进行部分替换。分散式联邦学习可以与基于 P2P 的通信技术,如区块链系统,构建出分散的联邦学习系统。集中式联邦学习和分散式联邦学习各具优势,在具体应用场景中应根据系统特性选择合适的联邦学习架构。现有的主要研究聚焦在集中式的联邦学习上^[28-30,51],本文也采用的集中式联邦学习结构进行研究。




图 2-1 集中式联邦学习和分散式联邦学习

2.1.1 联邦学习框架

集中式联邦学习的目标是训练一个全局模型 w ，使得该模型能够在所有客户端的数据上表现良好。首先，联邦学习中定义一个全局目标函数，它是所有客户端的局部目标函数的加权平均。在每个客户端上，假设 D_k 是第 k 个客户端的数据集，且每个客户端 k 的本地目标函数是 $L_k(w)$ 。全局目标函数可以定义为所有客户端的目标函数加权的和：

$$L(w) = \sum_{k=1}^K \frac{n_k}{n} L_k(w) \quad (2-1)$$

其中, $L_k(w)$ 是客户端 k 的损失函数, 表示为:

$$L_k(w) = E_{(x,y) \sim D_k} [\mathcal{L}(f(w; x), y)] \quad (2-2)$$

式中, $\mathcal{L}(f(w; x), y)$ 是损失函数, $f(w; x)$ 是全局模型 w 在输入 x 上的预测, y 是真实标签, D_k 是客户端 k 的数据分布, 且 $E_{(x,y) \sim D_k}$ 表示对客户端 k 的数据集 D_k 上的期望。每个客户端会根据其本地数据集 D_k 对模型参数进行更新, 通常采用梯度下降算法。在客户端 k 的训练中, 模型的更新遵循以下公式:

$$w_k^{t+1} = w_k^t - \eta \nabla_w L_k(w_k^t) \quad (2-3)$$

其中, η 是学习率, $\nabla_w L_k(w_k^t)$ 是客户端 k 在第 t 轮时的损失函数 $L_k(w_k^t)$ 对模型参数 w_k^t 的梯度。客户端 k 在本地计算完梯度后, 上传参数 w_k^{t+1} 至中央服务器。

服务器端将所有客户端的模型更新合并成全局模型。假设每个客户端 k 的本地数据集大小为 n_k , 总的样本数为 n (即 $n = \sum_{k=1}^K n_k$), 服务器使用加权平均的方法来更新全局模型的参数:

$$w^{t+1} = \sum_{k=1}^K \frac{n_k}{n} \cdot w_k^{t+1} \quad (2-4)$$

其中, w^{t+1} 是全局模型在第 $t+1$ 轮的更新, w_k^{t+1} 是客户端 k 在第 t 轮的更新, $\frac{n_k}{n}$ 是客户端 k 对全局模型更新的权重。这个加权平均的方式确保了数据量大的客户端对全局模型的更新贡献更大。

2.1.2 非独立同分布数据

在联邦学习中, 由于数据隐私保护的需求, 每个客户端只能在本地数据上进行训练, 且无法将本地数据上传至中心服务器进行聚合。这使得客户端的数据分布直接影响到模型的训练效果。在实际应用中, 客户端的数据往往无法保证是独立同分布 (IID) 的。相反, 数据的非独立同分布 (NIID) 现象普遍存在, 可以根据不同的偏移类型将其划分为数据层面和特征层面两种不同的情况。本文将重点讨论数据层面的标签分布倾斜和数量倾斜, 以及特征层面的概念偏移和特征分布倾斜, 主要区别如表 2-1 所示。本节将一般地非独立同分布数据划分为数据层面和特征层面进行介绍:

2.1.2.1 数据层面的非独立同分布

数据层面的非独立同分布主要体现在标签分布和数据量的偏斜。不同客户端在训练数据中的标签分布可能存在显著差异, 导致模型的训练效果受到影响。

表 2-1 非独立同分布数据的分类与示例

类别	偏移类型	数学定义	示例说明
数据层面	标签分布倾斜	$P_i(y) \neq P_j(y), \forall i \neq j$	客户端 A 的数据中 90% 为标签 0, 客户端 B 的数据中 95% 为标签 1。
	数量倾斜	$n_i \neq n_j, \forall i \neq j$	客户端 A 拥有 5000 个样本, 客户端 B 仅有 500 个样本。
特征层面	概念偏移	$P_i(x y_k) \neq P_j(x y_k), \forall i \neq j$	不同客户端对同一标签有不同理解, 导致相似特征分布的标签差异。
	特征分布倾斜	$P_i(x) \neq P_j(x), \forall i \neq j$	不同地区语音识别中的口音差异导致语音特征分布显著不同。

标签分布倾斜 (Label Distribution Skew) 是指不同客户端的标签分布具有不同的边缘分布。假设客户端 C_i 的数据集为 $D_i = \{x_i, y_i\}$, 其中 x_i 是特征数据, y_i 是标签数据。标签分布倾斜的情况下, 客户端 C_i 的标签边缘分布 $P_i(y)$ 与其他客户端的标签分布 $P_j(y)$ 不相同, 即

$$P_i(y) \neq P_j(y), \quad \forall i \neq j \quad (2-5)$$

举例来说, 假设客户端 1 的数据集中的标签为 0 的概率为 90%, 标签为其他数字的概率为 10%; 而客户端 2 的数据集中的标签为 1 的概率为 95%, 标签为其他数字的概率为 5%。这种情况下, 客户端 1 和客户端 2 的标签分布 $P_1(y)$ 和 $P_2(y)$ 显然不同。

数量倾斜 (Quantity Skew) 是指不同客户端的数据量存在差异, 导致某些客户端的数据样本量较大, 而其他客户端的样本量较小。假设客户端 C_i 拥有的数据量为 n_i , 那么不同客户端的数据量 n_i 和 n_j 满足:

$$n_i \neq n_j, \quad \forall i \neq j \quad (2-6)$$

这种数据量的差异可能会导致在模型聚合时, 样本量较大的客户端对全局模型的影响更大, 从而使得模型训练结果不够平衡。

2.1.2.2 特征层面的非独立同分布

特征层面的非独立同分布主要体现在特征分布和概念偏移上。特征分布的差异可能会导致相同标签下的特征分布差异, 而概念偏移则反映了在不同客户端之间, 即使标签相同, 特征数据的分布也可能完全不同。

概念偏移 (Concept Shift) 是指不同客户端的数据虽然有相同的标签, 但其条件分布 $P(x|y)$ 却存在差异。假设客户端 C_i 和客户端 C_j 拥有相同的标签集 $Y = \{y_1, y_2, \dots, y_k\}$, 但是对于某个标签 y_k , 其条件分布 $P_i(x|y_k)$ 和 $P_j(x|y_k)$ 是不同的。即:

$$P_i(x|y_k) \neq P_j(x|y_k), \quad \forall i \neq j \quad (2-7)$$

例如, 在图像分类任务中, 不同国家的客户端可能会用不同的视角, 背景和光照条件拍摄相同的物体, 导致相同标签的数据在不同客户端的出现差异。

特征分布倾斜 (Feature Distribution Skew) 是指在不同客户端中, 特征数据的边缘分布 $P_i(x)$ 和 $P_j(x)$ 存在显著差异。假设客户端 C_i 和客户端 C_j 拥有不同的特征分布 $P_i(x)$ 和 $P_j(x)$, 即

$$P_i(x) \neq P_j(x), \quad \forall i \neq j \quad (2-8)$$

例如, 在语音识别任务中, 客户端可能分布在不同地区, 并且说话人的语音特点 (如口音, 音调) 有所不同。这些不同的语音数据特征会影响模型在各客户端的训练效果。

2.1.2.3 非独立同分布数据的影响

数据层面的标签分布倾斜和数量倾斜, 以及特征层面的概念偏移和特征分布倾斜, 都会导致在联邦学习中出现模型聚合困难、性能下降等问题。在标签分布倾斜的情况下, 某些标签可能在训练中被过度代表, 而其他标签则被忽视。在数量倾斜的情况下, 样本量较大的客户端可能会对全局模型的训练起到主导作用, 导致全局模型无法充分学习其他客户端的数据特征。而在特征层面, 概念偏移和特征分布倾斜将使得全局模型的泛化能力受到限制, 特别是在跨客户端任务迁移时, 模型的表现可能会大幅下降。

因此, 理解和处理数据的非独立同分布现象是联邦学习模型优化中的重要研究方向。

2.1.3 FedAvg 算法介绍

FedAvg (Federated Averaging) 是一种广泛应用于联邦学习 (Federated Learning, FL) 中的优化算法。其设计理念是通过在本地设备上进行模型训练, 并周期性地将设备间的模型更新汇总到服务器, 以减少通信负担并保护数据隐私。FedAvg 使得分布在不同设备上的数据能够共同训练一个全局模型, 而无需交换或共享数据, 尤其适合隐私保护要求较高的应用场景。

2.1.3.1 算法流程

FedAvg 算法的基本流程包括两大主要步骤: 局部训练和全局更新。

局部训练: 在每轮训练中, 服务器首先将全局模型 w_t 广播到所有参与的设备 k , 设备 k 根据本地数据集 D_k 执行 E 次局部训练。每次局部训练使用随机梯度下降 (SGD) 更新模型参数:

$$w_k^{t+1} = w_k^t - \eta_t \nabla F_k(w_k^t) \quad (2-9)$$

其中, w_k^t 是设备 k 在第 t 轮的模型参数, η_t 是学习率, $\nabla F_k(w_k^t)$ 是设备 k 上目标函数 $F_k(w)$ 的梯度。

全局更新: 每个设备完成局部更新后, 设备将更新后的模型参数 w_k^{t+E} 发送给服务器。服务器对所有设备的模型更新进行加权平均, 得到新的全局模型:

$$w^{t+E} = \sum_{k=1}^N p_k w_k^{t+E} \quad (2-10)$$

其中 p_k 是设备 k 的权重, 通常是设备 k 上数据的比例。

通过这些步骤, FedAvg 可以在多个设备之间协作训练一个全局模型, 而不需要交换各设备的原始数据。

2.1.3.2 收敛性分析

在 FedAvg 算法中, 收敛性是评价算法性能的一个关键指标。尤其是对于非 IID 数据 (即设备间的数据分布不相同), 其收敛性表现出较强的依赖性。本文基于 FedAvg 算法的目标函数、局部更新和全局平均过程, 结合现有研究^[79]作以简要介绍:

局部更新的误差控制: 每个设备在本地进行的 SGD 更新过程是基于本地数据集 D_k 的, 这会导致设备间的局部模型与全局最优解 w^* 之间的偏差。假设设备 k 在第 t 轮的更新误差 $|w_k^{t+1} - w^*|^2$ 满足如下不等式:

$$|w_k^{t+1} - w^*|^2 \leq (1 - \eta_t \mu) |w_k^t - w^*|^2 + \eta_t^2 G^2 \quad (2-11)$$

其中 μ 是强凸性的常数, G 是梯度的上界。此公式表明, 局部更新的误差随着学习率 η_t 和强凸性常数 μ 逐渐减小。

全局模型更新的误差累积: 当设备的局部模型通过加权平均更新为全局模型时, 非 IID 数据的异质性会导致全局模型的误差累积。通过加权平均更新后, 假设全局模型的误差 $\Delta_t = E|w_t - w^*|^2$ 满足以下递归不等式:

$$\Delta_{t+1} \leq (1 - \eta_t \mu) \Delta_t + \eta_t^2 B \quad (2-12)$$

其中 B 是由设备的梯度方差, 数据异质性以及局部更新次数 E 组成的项, 公式为:

$$B = \sum_{k=1}^N p_k^2 \sigma_k^2 + 6L\Gamma + 8(E-1)^2 G^2 \quad (2-13)$$

其中 $\Gamma = F^* - \sum_{k=1}^N p_k F_k^*$ 表示数据的异质性度量。数据的非 IID 性增加了异质性度量 Γ ，从而增加了收敛的误差。

收敛速率的推导：通过上述递归不等式，结合学习率衰减，可以得出 FedAvg 收敛的速度为：

$$E[F(w_T)] - F^* \leq \frac{2\kappa}{\gamma + T} \left(\frac{B}{\mu} + 2L|w_0 - w^*|^2 \right) \quad (2-14)$$

其中， $\kappa = L/\mu$ 是与目标函数的平滑性和强凸性常数相关的项， T 是总的训练轮数。该公式表明，随着训练轮数 T 增加，模型误差与全局最优值之间的差距以 $O(1/T)$ 的速率收敛。

学习率衰减的必要性：如果学习率保持恒定，模型的最终解 w_T 将与最优解 w^* 之间存在偏差，具体表现为：

$$|w_T - w^*|^2 = \Omega(\eta(E-1)) \cdot |w^*|^2 \quad (2-15)$$

这意味着如果不衰减学习率，最终的模型将会与最优解有一定的偏差。因此，为了确保 FedAvg 收敛到全局最优解，必须对学习率 η 进行适当衰减。

非 IID 数据的影响：综上所述，数据的异质性（由 Γ 度量）导致了 FedAvg 收敛速度的下降。随着设备数据分布差异的增大，收敛速度会变慢。此外，为了确保收敛到最优解，学习率必须逐步衰减。最后，设备参与的数量和局部训练步数 E 对收敛速度有显著影响，合理的策略可以减小收敛的偏差。

2.2 生成器




图 2-2 通过（条件）自动编码器生成

生成模型是计算机视觉领域的研究热点，是无监督学习的经典模型。生成模型的最终目标大都是从倾斜的真实数据分布中提取相似的数据样本，生成新的数据样本。生成模型的研究方向有：基于自动编码器（Autoencoder, AE）的生成模型^[80]，结构如图 2-2 所示，基于变分自动编码器的生成模型^[81]，基于生成对抗

网络的生成模型^[82], 其中还有条件对抗生成网络^[83], 可以作为类别条件图像生成工具, 文本生成图像和图像间的转换等, 基于流的生成模型^[84], 扩散生成模型^[85], 以及最近的可视化自回归建模 (Visual AutoRegressive modeling, VAR)^[86]等。生成器颇具发展前景, 随着用于训练大模型的数据逐渐减少, 以及现实问题中的一些数据长尾分布的场景, 生成模型和强化学习将更加受到重视^[77]。

联邦学习场景中, 高效的通信以及客户端的算力有限问题, 让实验中选择合适的生成模型时显得尤为重要。现有的研究一般采用轻量级的生成器在客户端运行, 或者采用经过预训练的生成器在服务器端辅助训练^[28,30,32]。扩散模型虽然能够生成质量较高的图像, 但是其通过学习噪声和降噪过程决定了其训练算力需求大, 推理速度相对慢, 进而在联邦学习中难以实际应用。

2.2.1 生成对抗网络

生成对抗网络 (Generative Adversarial Network, GAN) 是一种利用博弈论机制实现数据生成的深度模型。其核心架构包含两个主要模块: 生成器和判别器。生成器的职责在于创作出足以混淆判别器的伪造数据, 而判别器则努力辨别输入数据是源自真实分布还是由生成器构造的。通过这种不断交互的对抗性训练, 生成器逐步提升, 最终能够产出与真实数据分布高度相似的高质量样本。

在 GAN 的训练过程中, 生成器和判别器分别进行优化。生成器通过一个潜在变量 (通常是随机噪声) 生成数据, 而判别器则对数据进行分类, 判断其是否为真实数据。生成器和判别器的目标是互相对抗的, 生成器旨在欺骗判别器, 而判别器则致力于分辨真实与生成的数据。最终, GAN 的训练目的是使得生成器生成的数据尽可能无法被判别器区分。GAN 的优化目标通常表示为以下的对抗损失函数:

$$\min_{\theta_g} \max_{\phi} E_{x \sim p_{\text{dt}}(x)} [\log D(x)] + E_{z \sim p_z(z)} \left[\log \left(1 - D(G(z; \theta_g)) \right) \right] \quad (2-16)$$

在这个公式中, $D(x)$ 是判别器对真实数据样本 x 进行分类的输出, 表示 x 属于真实数据的概率; $G(z; \theta_g)$ 是生成器生成的数据样本, z 是输入的随机噪声, θ_g 是生成器的参数。判别器 D 的目标是最大化判别正确的概率, 而生成器 G 的目标是最大化判别器的错误, 从而生成尽可能真实的数据。

在实际的训练过程中, 优化的步骤是交替进行的。生成器通过最小化损失函数来提高生成的样本质量, 而判别器则通过最大化损失函数来提高辨别能力。由于这种博弈式的训练方法, GAN 面临着一些训练不稳定的问题。例如, 生成器和判别器的优化可能会导致梯度消失或梯度爆炸的问题, 甚至可能会出现模式崩溃 (Mode Collapse), 即生成器只生成少数几种类型的样本, 而忽略数据分布的

其他部分。为了解决这些问题，研究者提出了一些改进方法，如 Wasserstein GAN (WGAN)。WGAN 通过引入 Wasserstein 距离来作为损失函数，它能够有效避免传统 GAN 中的梯度消失问题，并提供更稳定的训练过程^[87]。

2.2.2 条件生成对抗网络




图 2-3 通过（条件）对抗生成模型生成

条件生成对抗网络（Conditional Generative Adversarial Networks, CGAN）是在传统的生成对抗网络（GAN）框架的基础上，加入了条件信息的扩展版本，如图 2-3 所示。在 CGAN 中，生成器和判别器都接受条件信息作为输入，并且这种条件信息直接影响到生成过程。生成器不仅依赖于输入的随机噪声（通常是高维的随机向量），还将条件变量（如类别标签、文本描述等）作为额外的输入，生成符合条件要求的样本。判别器的目标是判断生成的样本是否真实，同时它也会接收条件信息，用以判断生成样本是否符合该条件。

生成器在生成样本时，输入包含了条件变量 y 和噪声向量 z ，它的目标是生成与条件信息 y 相关的样本 x 。判别器的目标则是对生成的样本进行判别，判断它是来自真实数据分布 p_{data} 还是生成器分布 p_{θ_g} ，同时判别器需要考虑条件信息 y 进行分类。

生成器 $G(z, y)$ 通过接受噪声向量 z 和条件变量 y 来生成样本。其生成过程可以表示为：

$$x = G(z, y; \theta_g) \quad (2-17)$$

其中， z 是从先验分布 $p_z(z)$ 中抽取的噪声向量， y 是条件变量， θ_g 是生成器的参数， G 表示生成器的生成函数。生成器的目标是尽可能生成接近真实数据分布的样本，且符合给定的条件 y 。

判别器 $D(x, y)$ 需要判断一个给定的样本 x 是否为真实数据，并且条件变量 y 也会被输入到判别器中进行判断。判别器的目标函数可以表示为：

$$L(D) = -E_{p_{\text{dt}}(x|y)}[\log D(x, y)] - E_{p_z(z)} \left[\log \left(1 - D(G(z, y; \theta_g), y) \right) \right] \quad (2-18)$$

其中, $D(x, y)$ 是判别器对输入样本和条件信息的判别输出, 表示样本 x 属于真实数据的概率。判别器通过最大化上述对数似然函数来提高对真假样本的判断能力, 同时, 生成器则通过最小化该损失函数来提高生成样本的质量。

条件生成对抗网络的优化目标: 与标准 GAN 不同, CGAN 的优化目标不仅仅是生成器和判别器之间的博弈。生成器的目标是生成符合条件的假样本, 而判别器的目标则是判断给定样本是否为真实样本, 并且判断其是否符合条件。CGAN 的优化目标可以表示为:

$$\min_{\theta_g} \max_{\theta_d} E_{p_{\text{dt}}(x|y)}[\log D(x, y)] + E_{p_z(z)} \left[\log \left(1 - D(G(z, y; \theta_g), y) \right) \right] \quad (2-19)$$

在这个损失函数中, θ_g 是生成器的参数, θ_d 是判别器的参数。生成器通过最小化该损失函数来生成更加逼真的样本, 而判别器通过最大化损失函数来提高对真假样本的区分能力。

改进的条件生成对抗网络: 在传统的 CGAN 中, 条件信息通常是通过拼接方式与生成器输入的噪声向量进行结合。然而, 拼接方式并没有充分考虑条件信息在生成过程中的结构和作用。为了更好地引入条件信息, 最近的研究提出了基于投影的判别器结构 (Projection Discriminator)。与拼接方式不同, 投影判别器通过将条件信息 y 与生成样本的特征向量进行内积计算, 从而更加有效地引入条件信息。这种方法显著提高了生成样本的质量, 并有效缓解了模式崩溃问题。投影判别器的损失函数可以表示为:

$$L(D) = -E_{q(y)} \left[E_{q(x|y)}[\log D(x, y)] \right] - E_{p(y)} \left[E_{p(x|y)} \left[\log \left(1 - D(G(z, y; \theta_g), y) \right) \right] \right] \quad (2-20)$$

其中: $D(x, y)$ 与传统方法不同的是, 投影判别器通过内积将条件信息 y 与生成样本的特征向量结合, 从而更精确地控制生成过程。 $E_{q(y)} \left[E_{q(x|y)}[\log D(x, y)] \right]$ 表示判别器对真实样本 x 和条件信息 y 的正确判定。投影判别器通过内积精确地处理条件信息, 使得生成样本更符合条件。

2.2.3 条件变分自编码器

条件变分自编码器 (Conditional Variational Autoencoder, CVAE) 是一种深度生成模型, 结合了变分自编码器 (VAE) 和条件生成的思想。其结构如图 2-4 所示, 与传统的 VAE 不同, CVAE 通过引入条件信息 (如观察数据或标签) 来生成与条件相关的数据样本。在条件变分自编码器中, 模型的目标是学习给定条件下数据的潜在表示, 从而生成符合给定条件的新样本。CVAE 已经广泛应用于图像

生成、图像重建和异常检测等领域，特别是在图像重建任务中，能够为重建过程提供不确定性量化的能力，从而为决策提供更可靠的依据。




图 2-4 通过条件变分自编码器 (CVAE) 生成

CVAE 的工作原理主要包括编码器和解码器两个部分。编码器接受输入数据 y ，并通过一个神经网络将其映射到潜在变量空间中。潜在变量 z 反映了数据背后的隐含特征，并且是在给定条件 y 下生成的。解码器则通过对潜在变量 z 进行采样，将其转化为数据的估计值 x ，从而实现数据的重建或生成。

具体来说，CVAE 的目标是学习条件下的后验分布，即 $p(z | y)$ ，并通过解码器生成符合该条件的样本。模型通过最小化以下目标函数进行训练：

$$\mathcal{L}_{\text{CVAE}}(\theta, \phi; x, y) = E_{q_{\theta}(z|x, y)}[\log p_{\phi}(x | y, z)] - D_{\text{KL}}(q_{\theta}(z | x, y) || p_{\phi}(z | y)) \quad (2-21)$$

其中， $q_{\theta}(z | x, y)$ 是编码器输出的后验分布，表示给定 x 和 y 时潜在变量 z 的分布。解码器 $p_{\phi}(x | y, z)$ 用于生成与条件 y 和潜在变量 z 相匹配的样本。KL 散度项用于度量编码器的后验分布与解码器先验分布之间的差异，通过优化这一目标函数，模型能够在给定条件下生成与输入数据相关的样本。

2.3 知识蒸馏

在机器学习中，尤其是深度学习中，模型的复杂度和计算需求往往限制了其在资源受限设备上的应用。为了解决这一问题，知识蒸馏 (Knowledge Distillation, KD) 应运而生，这种方法通过将复杂的“教师模型”的知识传递给较小的“学生模型”，从而在不显著降低性能的情况下，减少模型的计算复杂度和存储需求^[88]。知识蒸馏的核心目标是通过不同的方式将教师模型中包含的丰富知识传递到学生模型中，使得学生模型能够以较低的计算成本达到接近教师模型的表现。

2.3.1 知识蒸馏的一般形式

设定教师模型的输出为 z_t ，学生模型的输出为 z_s ，其中 z_t 和 z_s 都是经过神经网络计算后得到的 *logit*。为了将教师模型的知识传递给学生模型，蒸馏通过最小化学生模型和教师模型之间的差异来实现。常见的损失函数如下：

$$L_{KD} = \alpha \cdot H(y, s(z_s)) + \beta \cdot H(s(z_t, T), s(z_s, T)) \quad (2-22)$$

其中， $H(\cdot)$ 表示交叉熵损失函数； y 是真实标签； $s(\cdot)$ 是 *softmax* 函数； z_s 和 z_t 分别是学生和教师模型的 *logits* 输出； T 是温度参数，用于软化 *softmax* 输出概率分布； α 和 β 是加权系数，用于平衡传统监督损失和蒸馏损失。

在这两项损失中，第一项 $H(y, s(z_s))$ 是学生模型根据真实标签的标准损失，第二项 $H(s(z_t, T), s(z_s, T))$ 是学生和教师之间通过蒸馏传递的知识损失。蒸馏损失通过计算学生模型和教师模型在软标签上的差异来评估其学习的效果。此外，在知识蒸馏中，教师模型的输出通常会经过软化过程（即调整温度参数）。

知识蒸馏的损失函数一般形式：为了让学生模型学习教师模型的“软标签”信息，通常采用混合损失函数来结合学生模型的标准损失和蒸馏损失。常见的损失函数形式为：

$$L_{KD} = \alpha \cdot L_{\text{student}}(z_s, y) + \beta \cdot L_{\text{distill}}(z_s, z_t, T) \quad (2-23)$$

其中： L_{student} 是学生模型与真实标签之间的损失（例如交叉熵损失）； L_{distill} 是学生模型与教师模型输出之间的蒸馏损失； α 和 β 是权重系数，控制两部分损失的重要性； T 是温度参数，控制蒸馏过程中的软标签的平缓程度。

2.3.2 知识蒸馏算法分类

一般来说，知识蒸馏方法可以分为三类：响应式知识蒸馏、特征知识蒸馏和关系知识蒸馏。响应式知识蒸馏通过模仿教师模型的输出层来进行知识转移，帮助学生模型学习教师的决策信息；特征知识蒸馏则通过匹配教师模型和学生模型中间层的特征表示，促进学生模型学习到教师模型的内部表示；关系知识蒸馏则关注层与层、样本与样本之间的关系，帮助学生模型学习到更加复杂的特征依赖关系。

2.3.2.1 基于 logits 的知识蒸馏

基于 *logits* 的知识蒸馏，也即响应型知识蒸馏，结构如图 2-5 所示，通过模仿教师模型的输出进行训练。教师模型的输出是 $\hat{y}_t = \text{softmax}(z_t)$ ，学生模型的输出是 $\hat{y}_s = \text{softmax}(z_s)$ ，其中 z_t 和 z_s 分别是教师和学生模型的 *logits*（激活值）。




图 2-5 基于 logits 的知识蒸馏

为了让学生模型的输出尽可能接近教师模型的输出，蒸馏损失可以使用 Kullback—Leibler (KL) 散度 来衡量教师和学生输出之间的差异。KL 散度定义为：

$$L_D(z_t, z_s) = \text{KL}(p(z_t), p(z_s)) = \sum_i p(z_t)_i \log \frac{p(z_t)_i}{p(z_s)_i} \quad (2-24)$$

其中 $p(z)$ 是通过 *softmax* 函数得到的概率分布：

$$p(z_i) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (2-25)$$

其中， T 是温度因子，用于控制概率分布的平滑度。较高的 T 会使得输出概率分布更加平滑，从而传递更多的类别间关系。

2.3.2.2 基于特征的知识蒸馏

特征型知识蒸馏的目的是让学生模型模仿教师模型的中间层特征，结构如图 2-6 所示。在深度神经网络中，模型的中间层特征包含了输入数据的高层次抽象。通过模仿教师模型的中间层特征，学生模型可以学习到更多有用的特征，从而提高其性能。

给定输入数据 x ，教师模型的中间层特征为 $f_t(x)$ ，学生模型的中间层特征为 $f_s(x)$ 。为了减少学生模型和教师模型之间的特征差异，通常使用以下损失函数来度量两个特征映射之间的差异：

$$L_{\text{Feat}}(f_t(x), f_s(x)) = \mathcal{L}_{\mathcal{F}}(\Phi_t(f_t(x)), \Phi_s(f_s(x))) \quad (2-26)$$




图 2-6 基于特征的知识蒸馏

其中, Φ_t 和 Φ_s 是对教师和学生特征的变换函数, 用来确保它们的形状一致。通常情况下, 这些特征映射的尺寸不同, 需要通过某种变换 (如池化或卷积) 使其匹配。常用的相似度量函数 $\mathcal{L}_F$ 可以是 $L2$ 范数或 $L1$ 范数:

$$\mathcal{L}_F(f_t(x), f_s(x)) = \|\Phi_t(f_t(x)) - \Phi_s(f_s(x))\|_2 \quad (2-27)$$

这种损失函数通过最小化教师模型和学生模型的特征之间的差异, 使学生模型能够学习到与教师模型相似的特征表示。

2.4 本章小结

本章主要介绍了联邦学习的不同架构、数据分布的非独立同分布 (NIID) 特性, 以及几种生成模型的应用。首先, 本章阐述了联邦学习的集中式和分散式两种模式, 重点分析了集中式联邦学习的模型聚合方式和特点, 并进一步探讨了非独立同分布数据在联邦学习中的挑战, 特别是标签分布倾斜、数量倾斜以及特征层面的概念偏移和特征分布倾斜对模型训练的影响。接着, 本章介绍了 FedAvg 算法的流程与收敛性分析, 揭示了在非 IID 数据环境下, 如何通过合理设计和优化策略提高模型的收敛速度与性能。最后, 本章对生成模型, 包括生成对抗网络 (GAN)、条件生成对抗网络 (CGAN)、条件变分自编码器 (CVAE) 等进行了深入讨论, 并分析了它们在联邦学习场景中的潜在应用和挑战。通过这些讨论, 本章为后续章节的模型优化与改进提供了理论支持。

第三章 基于生成模型的无监督集成蒸馏联邦学习算法

3.1 引言

在联邦学习中,由于不同设备上的数据分布存在差异,特别是非独立同分布(Non-IID)数据的影响,导致了局部模型和全局模型之间的适应性差异,进而影响了模型的收敛性和泛化性能表现。在实际应用中,设备上的数据通常具有不同的**标签分布**和**特征分布**,这种异质性使得全局模型难以有效学习到各客户端的特定特征,从而导致全局模型的泛化能力不足。在此背景下,如何有效应对数据的非独立同分布特性,确保联邦学习在多个客户端之间能够充分共享信息,并提升全局模型的泛化能力,成为了联邦学习研究的一个重要挑战。解决非独立同分布数据问题,不仅需要改进模型聚合策略,还需要优化数据和模型传输方式,尤其是在带宽有限、通信资源受限的场景下,如何高效地进行通信和数据同步以加速模型收敛并提高其性能,仍是亟待解决的关键问题。

为了解决客户端数据异构性带来的影响,联邦优化策略成为了一个重要的研究手段。联邦优化策略的提出,旨在通过调整局部设备的模型更新方向和步长,优化客户端之间的协同学习过程。典型方法如 FedProx^[65]引入邻近项以限制本地更新偏离全局模型, FedDyn^[66]采用动态正则化调整本地目标函数, SCAFFOLD^[69]利用控制变量校正客户端更新方向。这些优化策略从模型局部更新的方向和步长一致性方面做出了突出贡献,但令人遗憾的是,为局部模型增加正则项后,模型更新方向可能偏离原有最优路径。同时,由于全局数据分布未知,也难以引导模型朝向全局最优解更新。一般的,联邦优化策略直接或者间接指导着模型更新的步长和方向上,使多个客户端保持一致性更新,但是联邦优化策略主要是从模型角度来指导更新,而全局数据分布是未知的,并且模型主要从数据中获取知识。上述矛盾也是在一定程度上说明,联邦优化算法有时会遇到模型收敛速度慢,全局模型适应性较差等挑战。

在联邦知识蒸馏和生成器方向,结合知识蒸馏技术来优化联邦学习模型的研究也得到了广泛关注。FedGen^[28]通过服务器端轻量生成器建模客户端特征分布以增强模型性能, Dense^[35]算法利用合成数据和集成模型提升全局精度, FedFed^[32]则在客户端提取稳健特征以减少异构性影响。此外, FedBKD^[72]、FedCVAE-KD^[31]等算法以不同方式利用条件变分自编码器,缓解非独立同分布问题,详见 1.2.3.1 节。值得注意的是,部分联邦知识蒸馏方法结合生成器技术,在提升模型收敛速度和泛化能力方面表现突出,并有效降低了通信成本。同时现有的很多算法也均

引入了轻量级的生成器来进行模型微调^[30,33,34,49]，均取得了良好的模型性能。但值得注意的是，这些算法一般从模型角度出发，难以有效利用客户端局部的数据分布，通过引入的生成器也就更加难以从全局数据分布的角度学习分类模型的嵌入空间或者输入空间。

为了解决非独立同分布场景下的联邦学习模型性能和收敛速度上的问题，本文将知识集成蒸馏和生成器进行了结合，提出了一种无数据蒸馏的联邦学习算法 **FedRef (Resampling for fine-tuning in Federated Learning)**。该算法在每个客户端使用条件变分自编码器 (CVAE) 来学习本地数据的分布信息，并仅上传解码器部分至服务器。服务器端利用生成的伪数据，通过集成蒸馏的方式对全局模型进行微调，从而提高全局模型的性能和收敛速度。此外，本算法通过类级加权的方式，在蒸馏过程中平衡各个类别的影响，解决了数据类别不平衡的问题。实验表明，FedRef 在多种基准数据集上均取得了优异的性能，尤其在通信开销和数据隐私保护方面，展现了较为显著的优势。FedRef 不仅能够与现有联邦优化算法兼容，还能在一般的联邦学习框架下，提升模型的泛化能力和鲁棒性。

针对生成器的选择，本算法整合了所提到的基于自动编码器 (AE) 的生成模型^[80]，基于变分自动编码器的生成模型^[81]，基于生成对抗网络的生成模型^[82]，条件对抗生成网络^[83]，基于流的生成模型^[84]，扩散生成模型^[85]，可视化自回归建模 (VAR)^[86]等多种生成器。在生成器的选择上面，同于 FedDF 直接使用简单的 GAN 网络，本算法考虑了生成数据类型平衡的问题，在开始阶段考虑了包含条件扩散模型、条件生成对抗网络和条件变分自编码器在内的三种算法模型，选择条件变分自编码器的原因有以下几点：首先，从训练成本角度看，条件扩散模型和 CGAN 相对较高，参数量较大，相比轻量且收敛速度快的 CVAE，条件扩散模型和 CGAN 会大幅增加通信负担和收敛时间，不利于更新。其次，现有的联邦学习中更多地采用轻量的生成器，这主要考虑到服务器和客户端之间的算力资源差距大，防止因为算力资源导致部分模型更新不及时，造成更加严重的模型性能下降，现有的一些前沿工作也采用了相对轻量的 VAE 网络和其他网络，如工作^[29,32,35,89,90]，这也是 FedRef 算法采用相对更轻量的 CVAE 的原因之一。最后，CVAE 解码器和编码器的结合，给 FedRef 算法在服务器端提供了仅上传解码器通过高斯噪声和独热编码 (One Hot Encoding) 来生成有效的模型输入的可能，这一结构上的特性相比于 CGAN 和条件扩散模型更有利于客户端隐私保护，此外根据工作^[32]可知，FedRef 采用解码器生成的特征具有一定的稳定性。

受到先前研究^[37,91]的启发，本文的集成蒸馏方法建立在一个简单而有效的直观想法之上：在异构数据场景中，全局模型的聚合应该考虑到局部客户端之间数据分布的变化和整体数据的分布。为此，本算法首先通过生成器在每个客户端捕

获局部数据的分布信息,尤其是头类数据的分布,从而确保生成的数据能够充分反映客户端数据分布的特征。在此过程中,生成器通过条件变分自编码器(CVAE)模型生成伪数据,其中潜在变量 z 通过从先验分布 $p(z)$ 中采样获得,随后生成的伪数据 x 根据 $p(x|z)$ 进行建模。这一生成过程使得 FedRef 能够从局部数据中提取出潜在的语义信息,并且保证生成的数据在保留局部特征的同时,避免泄露真实的客户端数据,从而有效保护了隐私。

我们在联邦学习开始前在每个客户端通过头类采样策略维护一个 CAVE 模型学习客户端的数据分布信息,并且仅上传解码器到服务器端,得益于 CAVE 解耦后的 Decoder 部分可以通过高斯噪声和 one-hot 向量来生合成伪数据,在服务器端利用伪数据进行模型的蒸馏,一定程度上既保护了客户端隐私,又通过生成器促进了客户端数据知识向全局模型的转移。初期实验考虑了条件生成网络,条件扩散网络和 CVAE,以及采用原始的部分数据作为辅助蒸馏数据,最后采用了可以解耦的 CVAE 模型,仅在客户端上传 CAVE 解耦后的 Decoder 部分,并在服务器端通过通过高斯噪声和 one-hot 向量作为 Decoder 输入数据来生合成伪数据,用以蒸馏。如果在服务器仅拥有 CVAE 的 Decoder 权重参数,极大增强了隐私安全性。具体来说, FedRef 算法贡献如下:

(1) FedRef 采用生成器对服务器端的全局模型进行了微调,有效利用了服务器端的计算资源,并通过生成器对局部数据分布和全局数据分布的感知学习,提升了全局模型的性能。

(2) FedRef 采用易于收敛的 CVAE 网络,通过服务器端类级分布的定制生成和聚合方案,有效地利用了客户端的数据异构性,并在模型进行知识传递的过程中,采用定制化标签生成和类级继承,最大限度地利用了客户端的统计信息和数据的异构性。

(3) FedRef 与现有的一些联邦优化算法正交,能够有效融入到当前的一些模型中,通过利用服务器算力,提升全局模型的性能。此外,本章节进行了大量的实验,在多个基准数据集上验证了 FedRef 的优越性能,并与现有的几种前沿算法相比,取得了 SOTA 的性能。

本章接下来安排如下:在 3.2 节将形式化地定义 FedRef 在非独立同分布数据环境下的优化目标;在 3.3 节将对 FedRef 算法从设计动机、数据采样机制、条件 CVAE 的构造、集成蒸馏策略、类级加权方案及其整体算法流程等几方面进行详细介绍;在 3.4 节将对比 FedRef 与现有前沿研究在算法目标和算法实现方面的异同;在 3.5 节将通过实验评估 FedRef 算法的性能,并进行分析;在 3.6 节将进行本章节研究内容的总结。

本章所使用的符号如表 3-1 所示:

表 3-1 章节符号说明

符号	含义
ω	全局模型的参数。
θ	局部客户端模型的参数。
D	全局数据。
D_i	客户端 i 的本地数据集，其中包含多个样本。
N_i	客户端 i 的样本数量。
ϕ	CVAE（条件变分自编码器）中的参数，特别是生成器的参数。
P	全局数据分布。
z	标准高斯噪声，用于生成伪数据。
y	类别标签，通常从预定义类别集合中采样。
$\hat{x}$	通过 CVAE 生成的伪数据样本。
C_k	客户端 k 的类级别集合，表示从本地统计信息中派生的类别集合。
$\alpha_t^{k,y}$	知识集成过程中的权重，用于控制来自不同本地模型的学习知识的比重。
σ	用于计算模型的输出概率。
T	知识蒸馏温度参数，用于控制软化的程度。
Φ	全局模型的优化目标。
n_k^y	客户端 k 中类别 y 的样本数量。
$\bar{n}_k$	客户端 k 中所有类别的平均样本数量。
N_k	客户端 k 的总样本数量。
N_t^y	全体客户端中类别 y 的总样本数量。
$q(z x, y)$	条件变分自编码器中给定输入 x 和类别 y 时的后验分布。
$p(z)$	先验分布，通常设置为标准的高斯分布。
μ	均值。
σ^2	方差，通常用于表示潜在变量的方差。
s	学生模型的输出。
t	教师模型的输出。
α_y^k	在集成过程中从客户端 k 中类别 y 的权重。

本章使用到的相关损失如下表：

表 3-2 损失函数说明

损失函数	含义
$L_i(\theta_i)$	客户端 i 的局部损失函数。
L_{Recon}	重构损失，用于衡量生成的数据与输入数据之间的差异。
L_{KL}	KL 散度损失，用于衡量近似后验分布与先验分布之间的差异。
L_{ELBO}	CVAE 的证据下界损失，由重构损失和 KL 散度损失组成。
L_{NLL}^k	负对数似然损失，用于衡量学生模型与教师模型之间的预测分布差异。
L_{KL}^k	KL 散度损失，用于衡量全局模型与集成的本地客户端模型之间的预测分布差异。
$f(x; \theta)$	使用参数 θ 的模型对输入 x 的预测。
$\sigma(s/T)$	使用温度参数 T 对学生模型输出进行软化后的概率分布。
$\sigma(t/T)$	使用温度参数 T 对教师模型输出进行软化后的概率分布。
L_{md}	模型差异损失，用于衡量全局模型与本地模型之间的差异。

3.2 问题分析

FedRef 的设计目标如下：

（1）提高联邦学习（FL）模型在数据异质性下的收敛速度：联邦学习中的一个主要挑战是客户端数据的非独立同分布特性，FedRef 的目标是通过增强聚合和知识转移方法来解决这一问题。

（2）最大化服务器端计算资源的利用：服务器通常拥有比客户端更强大的计算能力，因此一个关键目标是利用这一优势，在服务器端执行复杂的处理（如知识蒸馏），而不是频繁要求客户端进行计算或数据传输。

（3）在最小化数据传输的情况下提升模型性能：设计目标之一是提升全局模型的性能，同时避免违反联邦学习中对隐私的保护要求。方法的核心是通过集

成蒸馏使模型有效感知全局数据分布,进而减少客户端与服务器之间的通信次数来降低通信成本,同时保持高效的模型性能。

FedRef 的不同模块间的优化目标如下:

本地模型优化目标: 每个客户端 i 的目标是最小化自己的本地损失函数,通常表示为:

$$L_i(\theta_i) = E_{(x_{i,j}, y_{i,j}) \in D_i} [l(f(x_{i,j}; \theta_i), y_{i,j})] \quad (3-1)$$

其中 D_i 是客户端 i 的数据集, l 是损失函数,如交叉熵。

全局模型优化目标: 联邦学习的目标是通过聚合各个客户端的本地模型来优化全局模型 ω 。这一目标通常表示为:

$$\operatorname{argmin}_{\omega} \sum_{i=1}^N \frac{|D_i|}{|D|} L_i(\theta_i) \quad (3-2)$$

其中 $|D|$ 是所有客户端数据的总量, $|D_i|$ 是客户端 i 上的数据量。这个公式假设通过简单的本地模型平均(直接聚合)即可完成优化,但在数据高度异质化时,这种方法可能导致性能下降。

通过无监督知识蒸馏进行全局模型微调: 本文的创新之一是在服务器端使用无监督知识蒸馏来微调全局模型。微调的损失函数可以表示为:

$$\operatorname{argmin}_{\omega} E_{z \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), y \sim c_k} [L_{md}] \quad (3-3)$$

其中 L_{md} 是模型差异损失,它结合了负对数似然损失和 KL 散度损失, α_y^k 控制每个客户端对全局模型贡献的权重,该权重基于类级别的采样。

3.3 联邦重采样微调算法

在真实世界的数据中也常常会出现严重的类不平衡数据,客户端的有些类在数量上会远远超过其他的一部分类。此外,全局数据在客户端的分布上呈现出较高的非独立同分布的特征,这导致了局部目标函数与全局目标函数之间的不一致性,客户端最小化的是局部经验损失,是导致联邦学习中模型性能难以提升的关键所在^[4]。

为了应对相关挑战,联邦优化算法主要为局部客户端的训练过程中嵌入了正则化项,旨在对齐模型更新,减少数据异构性带来的影响^[65,66,68,69]。然而这些算法简单采用服务器端普通聚合,不仅严重忽视了服务器端的强大算力,而且简单的聚合难以高效融合具备数据异构性而训练的模型。此外,在全局数据分布未知的情况下,全局模型与局部模型的一致性模型更新也难以通过惩罚项来拟合全局最优的模型更新。联邦知识蒸馏和采用生成器的一些方法^[28-35],同 1.2.3 章节的

分析,一部分方法致力于通过生成器构建均衡的数据来进行模型微调,一部分方法深入模型潜在特征层面进行知识蒸馏传递。这些方法一定程度上忽略了局部数据和全局数据分布,而专注于特征一致性或是模型一致性,而忽略了对全局数据分布的感知,这对于解决数据异构性带来的影响非常关键。




图 3-1 FedRef 的整体框架

基于上述的观测结果,本文重新考虑了在联邦学习中如何使用生成模型来进行模型的微调,为对齐全局目标与局部目标,本文以生成器作为载体,对局部头类数据的分布进行学习,在服务器端进行聚合,以此完成对全局数据分布的感知。FedRef 结构如图 3-1 所示,在客户端首轮训练中,首先维护一个易于收敛的 CVAE 网络,并上传类分布信息和 CVAE 解码器到服务器端,用以生成集成蒸馏的伪数据。在客户端后续训练轮次中仅执行联邦学习部分。服务器端在每一轮次的通信中,首先通过 CVAE 解码器生成伪数据,接着基于伪数据集集成客户端模型输出的知识,并通过蒸馏的方式传递知识到全局模型,最后将微调后的全局模型发送给客户端。具体而言, FedRef 在初始训练轮中由客户端训练轻量级 CVAE 网络,随后仅将解码器参数上传至服务器端。服务器端通过整合多个客户端的解码器,构建统一的伪数据生成机制,用于集成蒸馏优化。该设计不仅提升了模型聚合的效果,还充分利用了服务器端的计算能力以及客户端头类数据的信息,从而增强了全局模型对数据分布的适应能力。

3.3.1 算法动机

在长尾数据的相关研究中^[9],类不平衡的数据作为训练数据,促使模型在头类数据表现优秀,而尾类数据上表现差劲,凸显了模型对数据的强依赖性。此外,本文观察到大部分现有研究通过 Dirichlet 分布来模拟非独立同分布数据,首先在

局部客户端数据上是类不平衡的,其次在全局数据分布上也呈现出较大幅的不一致性。进而,本文认识到数据分布对模型训练的关键影响,考虑到局部模型在局部数据集头类数据上表现优秀,此外,发挥局部模型的优势,对全局模型进行蒸馏,且知识的载体能够在一定程度上体现全局数据的分布(不仅是标签数量分布,更是图像数据分布),这对于解决数据异构性对模型性能的影响十分关键。本文在模型微调时,为了让模型能够感知到数据全局的分布,采用了生成器作为载体,用以学习客户端数据的分布,考虑到数据隐私性保护,通过了收敛速度快、可拆分的 CVAE 模型作为的生成模型。




图 3-2 CIFAR10 上基于不同来源数据的模型微调性能




图 3-3 Fashion MNIST 上基于不同来源数据的模型微调性能

为了确认服务器端集成蒸馏的有效性, 本节分别在 CIFAR 10 数据集和 Fashion MNIST 数据集上进行了两组对比实验。实验使用了标准的 FedAvg 算法作为基准, 在相同的实验环境下进行, Dirichlet 分布参数设置为 0.3, 用以模拟非独立同分布数据。以 CIFAR 10 数据集为例, 一部分训练数据集作为子数据集, 剩余数据作为模型训练数据, 实验进行了一组标准的 FedAvg 算法实验作为基准。接着, 实验基于标准的 FedAvg 算法, 实验融入 FedRef 的服务器集成蒸馏模块, 使用预先抽出的子数据集作为集成蒸馏使用的数据, 并进行 FedRef-FedAvg 算法实验。最后, 本节将生成模型生成的伪数据代替第二组实验的子数据集, 进行了实验。如图 3-2 和图 3-3 所示, 本文采用的策略非常有效, 由生成模型直接感知局部训练数据, 全局模型的性能得到了显著提高。

3.3.2 数据采样

在联邦学习中, 一般假设有 N 个客户端和一个可以表示为 $\mathcal{D} = \{\mathcal{D}_i\}_{i=1}^N$ 的 M 类数据集, 其中 $\mathcal{D}_i = \{(x_{i,j}, y_{i,j})\}_{j=1}^{N_i}$ 表示客户端 i 的本地数据集, N_i 表示对应的样本数量, 联邦学习的目标是获取一个全局模型 ω , 在 Non-IID 数据上能够获得更好的性能, 解决的目标是:

$$\arg \min_{\phi} \sum_{i=1}^N \frac{|\mathcal{D}_i|}{|\mathcal{D}|} \mathcal{L}_i(\theta_i), \quad \mathcal{L}_i(\theta_i) = \mathbb{E}_{(x_{i,j}, y_{i,j}) \in \mathcal{D}_i} l(f(x_{i,j}; \theta_i), y_{i,j}) \quad (3-4)$$

上式描述的是联邦学习的目标优化函数, 其中 $l(\cdot, \cdot)$ 表示客户端共有的损失函数, 对于每一个 $i \in \{1, 2, \dots, N\}$ 的客户端数据集 $\mathcal{D}_i$ 是分布不均匀的, 并且互相不能直接访问, 针对解决目标(1), 现有的方法主要通过收集本地经过 $\mathcal{L}_i(\theta_i)$ 优化后的模型 θ_i , 在服务器端通过平均梯度来进行聚合获得全局模型。客户端的损失函数根据不同的任务进行选择, 可以是交叉熵损失或者平均绝对误差损失。

然而, 在数据异构性的场景下, 传统的直接聚合方式使得更新后的全局模型的性能受到局部客户端的漂移影响而大幅降低, 现有的方法主要通过限制客户端更新来解决此问题, 忽略了服务器端丰富的计算资源。为了解决这个问题, 本文提出了基于知识蒸馏的无监督全局模型微调方法, 将客户端模型的知识转移到全局模型之中, 以最大程度保证全局模型的性能。具体来说, 本文基于一个直观的思想: 集成的局部模型预测结果的高度多样化使得集成模型相比全局模型能够更好的地工作, 同时比起经过梯度平均的全局模型具有更好的泛化能力^[37,92]。

为了生成用以集成蒸馏的数据, 本算法引入了生成器, 目前基于 VAE 的模型和基于 GAN 的模型是两种被广泛使用的生成器, 其中, 基于 VAE 的生成器相对更加轻量也更易于收敛, 在通信资源和客户端计算资源有限的情况下, 更加适

用^[83,93]。本算法在每个客户端初始训练时,首先维护一个 CVAE 网络,针对客户端数据进行训练,用于捕获客户端数据地类特征信息,在首轮客户端上传 CVAE 网络的解码器部分,并在服务器端由此生成伪数据进行集成蒸馏,如下:

$$\hat{x} = G(z, y; \theta) \quad (3-5)$$

其中 θ 是 CVAE 解码器的网络参数, $z \sim \mathcal{N}(0,1)$ 是一个标准的高斯噪声, y 是从预定义采样类别 $\mathcal{C}_k$ 中采样得到的类标签,生成的伪数据满足 $\hat{x} \sim p(\hat{x}|(z, y))$ 。如图 3-1,之后 FedRef 将伪数据样本 $\hat{x}$ 送入全局模型以解决下方问题:

$$\min_{\Phi} \mathbb{E}_{z \sim \mathcal{N}(0,1)} \mathbb{E}_{y \sim \mathcal{C}_k} [\mathcal{L}_{md}], \mathcal{L}_{md} = \sum_{k \in \mathcal{N}} \alpha_t^{k,y} \mathcal{L}_{md}^k \quad (3-6)$$

上式表示的是基于伪数据进行无监督知识蒸馏的全局模型微调目标,其中 $\mathcal{L}_{md}^k$ 表示全局模型 Φ 和本地模型 θ_i 之间的模型差异, $\alpha_t^{k,y}$ 控制在集成过程中从不同本地模型中学习知识的权重,下一小节将详细说明如何进行标签采样和权重集成。

高效的集成蒸馏数据生成。FedRef 在客户端部署了 CVAE 生成器,基于客户端头类数据训练以生成拟合局部模型输入空间的数据。CVAE 是一个边际似然的有向概率图模型,旨在将潜在变量 z 的分布于输入样本 x 的分布联系起来,模型由编码器和解码器组成。编码器用以推断后验分布 $q(z|x, y)$,其中 x 是训练数据, y 表示条件信息,通过输入样本 x 和条件 y 推断潜在变量 z 的后验分布,在算法中表示为标签,并编码为一个热向量。解码器对条件似然 $p(y|x, z)$ 进行建模,通过输入潜在变量 z 和样本 x 来建模条件似然分布,从而生成标记样本 y 。为了生成高质量的输入样本,CVAE 最大化似然 $p(y|x)$ 的变分下界(ELBO)。目标函数为:

$$\mathcal{L}_{ELBO} = \mathbb{E}_{q(z|x, y)} [\log p(y|x, z)] - D_{KL}(q(z|x, y) || p(z)) \quad (3-7)$$

上式为条件变分自编码器(CVAE)的训练目标,即最大化边际似然的变分下界,其中,第一项损失是重构损失,表示在潜变量 z 上的期望对数似然,第二项是后验分布 $q(z|x, y)$ 和先验分布 $p(z)$ 的 Kullback-Leibler 散度。通过最大化变分下届,CVAE 能够有效学习到条件 y 和样本 x 的复杂关系,从而生成高质量的标记样本。具体来说,为了确保能够使模型输出能够更好地拟合客户端地输入空间,CVAE 的损失由 KL 散度和重构损失组成:

$$\mathcal{L}_{ELBO} = \mathcal{L}_{Recon} - \mathcal{L}_{KL} \quad (3-8)$$

其中重构损失 $\mathcal{L}_{Recon}$ 主要用于确保生成的数据尽可能接近原始地输入数据,具体而言,它衡量解码器输出 μ_{out} 与输入数据 x 之间地差异。在实现中,重构损失使用无方差模型的解码器,即:

$$\mathcal{L}_{Recon} = -\frac{1}{2} \sum (x - \mu_{out})^2 \quad (3-9)$$

通过最小化重构损失，以期解码器能够生成高质量的重构数据，使其与原始数据在输入空间尽可能匹配。这有助于模型捕捉输入数据的分布特性，从而在生成过程中保持数据的真实性和一致性。

简单地使用 $\mathcal{L}_{\text{Recon}}$ 会导致模型崩溃，生成器还需要使用 $\mathcal{L}_{KL}$ 用于衡量潜在变量 z 的近似后验分布 $q(z|x, y)$ 与先验分布 $p(z)$ 之间的差异，如下：

$$\mathcal{L}_{KL} = \frac{1}{2} \sum_{i=1}^d (\mu_i^2 + \sigma_i^2 - \log(\sigma_i^2 + 1e-8) - 1) \quad (3-10)$$

上式为用于约束潜变量分布的 KL 散度损失的具体计算公式，其中， μ 和 σ 分别是潜在变量的均值和标准差， d 是潜在变量的维度。通过最小化 $\mathcal{L}_{KL}$ ，本算法希望近似后验分布尽可能接近先验分布。这有助于模型在潜在空间中学习到一种合理的分布，使得生成的数据除了与输入数据相似以外，在潜在空间中具有良好的分布特性，从而提升生成空间的多样性和分布的合理性。

3.3.3 集成蒸馏




图 3-4 集成蒸馏示意图

在数据异构的场景中，局部客户端的标签分布通常是类不平衡的，客户端之间的分布也是不同的，客户端内也存在类不平衡的情况。在高度的非独立同分布的情况下，局部客户端的训练偏向于局部数据集的头类数据，对尾类数据的泛化能力较差。具体来说，对于同一个类，不同的局部客户端在类标签数量的影响下所获取的模型知识重要性是不同的。因此本算法在服务器端提出了定制的标签采样来针对客户端高度的类不平衡问题进行有效的集成蒸馏，其结构如图 3-4 所示。

类级标签采样。有研究表明，类不平衡会使得深度神经网络针对尾类的泛化能力下降^[94]。因此，局部客户端通过本地数据维护的 CVAE 网络，难以捕获其中

尾类的数据信息,通过尾类标签指导生成的伪数据不能有效模拟局部客户端的输入空间,以进行有效的知识传递。如果实验采用全部类别标签指导 CVAE 解码器在服务器端生成局部模型的输入数据,则可能会因为局部客户端的长尾数据训练的 CVAE 解码器导致部分尾类数据生成错误的伪数据,进而影响集成蒸馏过程中模型间知识的传递。为了缓解这一问题,本文根据客户端的数据分布的统计信息,自定义采样类别 $\mathcal{C}_k$,从而生成更高效的伪数据。

FedRef 算法首先计算客户端的样本数,

$$\bar{n}_k = \frac{1}{|\mathcal{Y}|} \sum_{y \in \mathcal{Y}} n_k^y \quad (3-11)$$

其中 n_k^y 表示类别 y 在客户端 k 中的样本数, $\bar{n}_k$ 表示客户端 k 中所有类别的平均样本数, $\mathcal{Y}$ 表示所有类别的集合。

接着, FedRef 算法筛选出大于平均样本数的类别集合 $\mathcal{C}_k$,

$$\mathcal{C}_k = \{y \in \mathcal{Y} \mid n_k^y > \bar{n}_k\} \quad (3-12)$$

对于每个客户端 k , FedRef 使用其生成网络 G_k 和根据其类别统计信息筛选出来的类别集合 $\mathcal{C}_k$ 生成伪数据:

$$\hat{x}_i^k = G_k(z_i, y_i) \quad (3-13)$$

其中, $y_i \in \mathcal{C}_k$, $z_i \sim \mathcal{N}(0,1)$ 是一个标准的高斯噪声。本文的这种策略保证了生成的数据主要集中在客户端样本数较多的类别上,从而有效利用了客户端的统计信息,提高了生成数据的质量。此外,结合本文的发现,如图 3-2 和图 3-3 所示,通过集成的头类数据在服务器端直接对全局模型进行微调,能够有效提升模型的性能。因此 FedRef 能够在数据异构性较高的情况下进行有效的知识蒸馏。

类级集成蒸馏。如何集成多个客户端模型的知识以相同的权重传递到全局模型是集成蒸馏的关键^[28]。在数据异构性的场景下,模型的性能与标签的分布是强相关的,不同的类在不同的本地模型中的重要性是不同的,简单地直接对所有的教师模型的贡献分配相同的权重是不可行的,会忽略一些关键的知识,从而影响模型的性能。因此,本文提出了集成类分布信息来分配知识的权重,

具体来说,在式 3-6 中通过 $\alpha_t^{k,y}$ 分配权重,对于每个客户端 k , FedRef 定义类 y 的样本数为 n_k^y ,客户端中类别 y 的总样本数为 N_t^y ,计算如下:

$$\alpha_t^{k,y} = \frac{n_k^y}{N_t^y} \quad (3-14)$$

这种方式能够更准确地反映各类在不同客户端中的重要性,从而提高知识蒸馏的效果。在式 3-6 中的 $\mathcal{L}_{md}^k$,具体来说,本算法采用了一种综合蒸馏损失函数

来优化全局模型,该损失函数结合了负对数似然损失(NLL),KL 散度损失(KL)。具体而言:

$$\mathcal{L}_{md}^k = \mathcal{L}_{NLL}^k + \mathcal{L}_{KL}^k \quad (3-15)$$

上式定义了全局模型微调时所采用的综合蒸馏损失函数,其中负对数似然损失 $\mathcal{L}_{NLL}$ 用于衡量学生模型的预测分布与教师模型分布之间的差异。定义为:

$$\mathcal{L}_{NLL}^k = -\mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\sum_{i=1}^C t_i^k \log(\sigma_i^k(s)) \right] \quad (3-16)$$

其中, s 和 t 分别是学生模型和教师模型的输出, σ 是 softmax 函数。此外,KL 散度损失 $\mathcal{L}_{KL}^k$ 用于衡量全局模型和集成的局部客户端模型预测分布之间的差异,定义为:

$$\mathcal{L}_{KL}^k = \text{KL} \left(\sigma \left(\frac{s}{T} \right) \middle| \sigma \left(\frac{t}{T} \right) \right) \quad (3-17)$$

其中, T 是温度参数。

3.3.4 算法流程

初始化阶段: 初始化全局模型参数 ω , 客户端模型参数 $\{\theta_k\}_{k \in K}$ 以及生成器参数 $\{\omega(k, G)\}_{k \in K}$ 。每个客户端初始化其 CVAE 生成器模型,并准备训练数据。

客户端训练阶段: 首次通信: 在首次通信时,客户端上传客户端的类级分布统计信息 C_k ,以及客户端的解码器参数 $\omega(k, \text{decoder})$ 。

生成器训练: 对于每个客户端 k , 执行以下步骤:

(1) 如果是第一次通信,客户端将训练其生成器 G_k 并进行 n 次迭代,通过最大化变分下界来优化生成器。

(2) 在每轮迭代中,生成器参数 $\omega(k, G)$ 根据以下公式进行更新:

$$\omega(k, G) \leftarrow \text{更新函数}(L_{\text{ELBO}})$$

(3) 使用生成器训练后,客户端根据本地数据 D_k 训练其分类模型,得到更新后的客户端模型参数 θ_k 。

服务器聚合阶段: 服务器接收所有客户端上传的模型参数 $\{\theta_k\}_{k \in K}$ 和生成器解码器参数 $\{\omega(k, \text{decoder})\}_{k \in K}$, 然后进行以下操作:

1) 全局模型更新: 使用聚合的客户端模型参数更新全局模型 ω , 计算全局模型的更新量:

$$\Delta \omega = \frac{1}{K} \sum_{k=1}^K (\theta_k - \omega)$$

更新全局模型:

$$\omega \leftarrow \omega + \Delta \omega$$

2) 伪数据生成: 服务器根据各客户端的生成器解码器 $\omega(k, \text{decoder})$ 和类级分布 C_k 生成伪数据, 用于知识蒸馏。每个客户端的生成器根据标准正态分布生成潜变量 z , 并使用类标签 y 从预定义类集中进行采样。伪数据生成公式如下:

$$\hat{x}_i = G(z, y; \omega(k, \text{decoder}))$$

伪数据 $\hat{x}_i$ 用于在全局模型中进行无监督训练。

3) 知识蒸馏: 将生成的伪数据输入到全局模型中, 进行知识蒸馏。对于每个客户端, 服务器计算知识蒸馏损失 L_{md} , 该损失结合了局部模型和全局模型之间的差异。

$$L_{\text{md}} = \sum_{k \in N} \alpha_{k,y}^t L_k^{\text{md}}$$

其中, $\alpha_{k,y}^t$ 是基于客户端数据分布统计信息对各类样本的加权因子。损失函数 L_k^{md} 由负对数似然损失和 KL 散度损失两部分组成, 具体如下:

负对数似然损失:

$$L_k^{\text{NLL}} = -E_{(x,y) \sim D} \left[\sum_{i=1}^C t_{ki} \log(\sigma_k(s)) \right]$$

KL 散度损失:

$$L_k^{\text{KL}} = \text{KL}(\sigma(s) | \sigma(t))$$

其中, t_{ki} 是客户端的标签分布, σ 和 t 分别是学生模型和教师模型的输出, $\sigma(s)$ 是学生模型的 softmax 输出, $\sigma(t)$ 是教师模型的 softmax 输出。

模型更新与反馈: 服务器完成伪数据生成和知识蒸馏后, 使用更新后的全局模型参数 ω 进行训练, 优化后的全局模型会被发送回客户端。

客户端根据新的全局模型继续进行本地训练, 以提高本地模型性能。此过程循环进行, 直到达到预定的通信轮数 T 。

终止与返回结果: 经过 T 轮通信和训练后, FedRef 算法终止, 最终得到一个经过精细调优的全局模型 ω , 该模型能够有效融合来自各个客户端的知识, 并且在非独立同分布 (Non-IID) 数据场景下具有更强的泛化能力。

算法 1 描述了 FedRef 的主算法流程, 概述了在整个联邦学习过程中, 全局模型如何通过客户端参与训练并逐轮优化。**算法 2** 展示了客户端模型的更新过程, 客户端在本地数据集上进行多轮本地训练以优化其模型参数, 并在每轮通信后将更新结果返回服务器。**算法 3** 则详细说明了服务器端模型的更新流程。在接收到客户端上传的模型参数和由 CVAE 生成的伪数据后, 服务器首先执行传统

的参数聚合操作, 并进一步利用合成数据对全局模型进行知识蒸馏式训练, 从而实现对不同客户端特征分布的适应性增强。

算法 1 FedRef	
输入: T : 通信轮次; K : 客户端数量; $\{\mathcal{D}_k\}_{k \in K}$: 客户端的数据集; Φ : 全局模型的参数; $\{\theta_k\}_{k \in K}$: 客户端模型的参数; C : 客户端集合; I_G : 生成器训练迭代次数; $\{\varphi_{(k,G)}\}_{k \in K}$: 生成器的参数; $\{\varphi_{(k,decoder)}\}_{k \in K}$: 生成器解码器的参数; $\mathcal{M}$: 联邦学习算法, 比如 FedAvg, FedProx, MOON, SCAFFOLD.	
1:	Initialize global model parameters Φ , client parameters $\{\theta_k\}_{k \in K}$ and generators parameters $\{\varphi_{(k,G)}\}_{k \in K}$
2:	for $t = 1, \dots, T$ do
3:	$C_t \leftarrow$ the set of K clients
4:	for each client $k \in C_t$ in parallel do
5:	if $t = 1$ then
6:	for $j = 1, \dots, I_G$ do
7:	update generator $\varphi_{(k,G)}$ according to Eq.(3-8), Eq.(3-9) and Eq.(3-10) acquiring knowledge from the client.
8:	end for
9:	end if
10:	$\theta_k \leftarrow \text{ClientUpdate}(\Phi, \mathcal{D}_k, \text{SelectMethod}(\mathcal{M}))$
11:	end for
12:	$\Phi \leftarrow \text{ServerUpdate}(\Phi, \{\theta_k\}_{k \in K}, \{\varphi_{(k,decoder)}\}_{k \in K})$
13:	end for

算法 2 ClientUpdate(FedAvg)	
输入: $\mathcal{D}_k$: 客户端 k 的数据集; Φ : 全局模型的参数; θ_k : 客户端模型 k 的参数。	
1:	Initialize local model parameters $\theta_k \leftarrow \Phi$
2:	for each local epoch do
3:	for each batch $(x, y) \in \mathcal{D}_k$ do
4:	Compute local loss on batch (x, y) Update local model parameters θ_k
5:	end for
6:	end for
7:	return θ_k

算法 3 ServerUpdate

输入: I : 服务器端训练轮次; K : 客户端数量; $\mathcal{C}_k$: 客户端头类数据集合;
 $\alpha_t^{k,y}$: 类级知识聚合权重; $\{\mathcal{D}_{(k,G)}\}_{k \in K}$: 通过客户端 k 的 CVAE 解码器生成的数据集 ; Φ : 全局模型的权重参数; $\{\theta_k\}_{k \in K}$: 客户端模型的权重参数;
 $\{\varphi_{(k,G)}\}_{k \in K}$: 生成模型的参数; $\{\varphi_{(k,decoder)}\}_{k \in K}$: 生成模型解码器的参数。

1:	$\Delta\Phi \leftarrow \frac{1}{C_t} \sum_{k \in K} (\theta_k - \Phi), \Phi \leftarrow \Phi + \Delta\Phi$
2:	compute $\{\mathcal{C}_k\}_{k \in K}$ according to Eq.(3-11) and Eq.(3-12)
3:	compute $\{\alpha_t^{k,y}\}_{k \in K, y \in Y}$ according to Eq.(3-14)
4:	for $i = 1, \dots, I$ do
5:	for $k = 1, \dots, K$ do
6:	$(Z_k, Y_k) \leftarrow (\text{sample a batch of } z \sim \mathcal{N}(0,1) \text{ and } y \in \mathcal{C}_k)$
7:	$(\mathcal{D}_{(k,G)}) \leftarrow (\text{generate a batch of data})$ according to Eq. (2): $G_k(Z_k, Y_k; \varphi_{(k,decoder)})$
8:	end for
9:	for each batch $(x, y) \in \mathcal{D}_{(k,G)}$ do
10:	update the global model Φ according to Eq.(3-15), Eq.(3-16) and Eq.(3-17) to transfer the knowledge from the local model to the global model
11:	end for
12:	end for
13:	return Φ

3.4 与现有研究的异同

近年来, 人工智能顶级会议在联邦优化算法^[62-70,110,109]和联邦知识蒸馏/生成器/表征转换网络^[28-37,47,72-75,59,60]等方向有全面而深入的研究。通过对上述相关研究工作的学习, 读者能够进一步加深对联邦学习的了解。对于其中大部分算法实现细节, 本文分别在 1.2.1, 1.2.2 和 1.2.3 等章节做出了详细阐述。本节并没有将使用了生成器的联邦学习算法全部列出, 但这些相关研究表明, 基于知识蒸馏与生成模型的联邦学习方法仍受到学术界广泛关注。

3.4.1 目标不同

联邦学习中的数据分布对模型的收敛性和泛化能力具有重要影响。相比于现有的联邦优化算法、联邦知识蒸馏和生成器辅助的联邦学习方法，FedRef 方法的核心目标在于增强全局模型对非独立同分布数据的适应性，并加速模型的收敛过程。具体来说，目标上的差异体现在以下几个方面：

全局数据分布建模：现有的联邦优化算法（如 FedAvg、FedProx、MOON 等）主要通过局部梯度调整、正则化项约束等方式来对齐全局模型更新方向，使各客户端在训练过程中保持一定的一致性。然而，这些方法往往忽略了全局数据分布的建模，导致全局模型在面对非独立同分布数据时，泛化能力不足。FedRef 方法的核心目标之一是通过生成器建模全局数据分布，即在服务器端构建一个动态的类级数据分布，使得全局模型不仅仅是多个局部模型的简单聚合，而是能够捕获并适应全局的特征分布。

局部数据分布的利用：传统的联邦优化算法通常着重于特征一致性，这样有利于模型收敛，但也难以获得高性能模型。而一些知识蒸馏类的方法（如 FedDF、FedMD、FedGen）虽然使用了知识蒸馏策略，但它们仍然主要关注模型之间的表征转换，而不是直接建模数据分布。FedRef 采用条件变分自编码器（CVAE），让客户端训练其本地数据的生成器，并在服务器端集成多个客户端的解码器。这样，全局模型能够通过生成的伪数据感知各客户端的分布特征，使得训练过程更具针对性。

加速模型收敛：由于非独立同分布数据的影响，传统联邦学习模型往往需要较长的训练周期才能达到收敛。FedAvg 及其改进方法（如 SCAFFOLD、FedOpt）试图通过优化局部更新方向来加速收敛，但这些方法的核心仍然是梯度优化策略，并未有效利用生成器的特性。FedRef 通过在服务器端执行无监督知识蒸馏，结合类级生成数据进行全局微调，使得模型能够更快地调整到全局数据分布，从而减少通信轮数，加速训练过程。

隐私保护与数据高效利用：许多基于数据增强的联邦学习方法（如 FedDF、FedCVAE）在服务器端引入辅助数据集，这可能会带来额外的数据隐私风险，尤其是在涉及医疗或金融等敏感数据时。FedRef 仅使用生成器的解码器进行数据生成，不依赖真实数据的共享，从而在提高模型泛化能力的同时，最大程度上避免了隐私泄露的风险。

综上，FedRef 在目标上不同于现有研究，其核心在于结合生成器建模全局数据分布、加速模型收敛，并增强全局模型对非独立同分布数据的适应性。

3.4.2 实现不同

FedRef 在实现方式上也与现有的联邦优化算法、联邦知识蒸馏方法、以及基于生成器的联邦学习模型存在显著区别,尤其是 Dense, FedFed, FedDF, FedFTG, FedCVAE, FedGen 和 FedDA^[90]等算法,主要体现在以下几个方面:

客户端生成器的使用方式不同: FedRef 的独特之处在于,每个客户端的生成模型只上传 CVAE 的解码器,并在首次通信时上传解码器到服务器。服务器端集成多个解码器,生成伪数据用于全局模型微调。这种方法避免了在客户端维护过重的生成器,同时确保服务器端的计算资源得到了充分利用。值得注意的是 CVAE 训练对于算力需求低,而 FedRef 集成蒸馏过程对算力需求较高,这也是为客户端低算力,服务器端高算力的考量

服务器端的知识蒸馏策略不同: FedRef 不仅利用集成蒸馏,还结合类级生成数据进行特征对齐。服务器端通过 CVAE 生成伪数据,结合局部模型的知识进行微调,使得全局模型能够更准确地学习到各客户端的特征分布。

标签采样策略不同: 在传统的联邦优化方法中,客户端的更新通常是基于本地数据进行的,并不会特别考虑各类别样本的均衡性。FedRef 在服务器端采用类级标签采样策略,即在生成伪数据时,优先生成客户端中数据量较多的类别样本,以确保生成的数据分布能够有效匹配局部训练数据。这种策略使得模型能够更快适应数据异构性,提高泛化性能。

服务器端计算资源的利用方式不同: 许多联邦学习算法主要在服务器端执行简单的参数聚合,而计算过程主要发生在客户端。FedRef 充分利用服务器端的计算资源,不仅执行全局模型聚合,还通过生成器生成伪数据,并结合知识蒸馏进行全局模型微调。这种方式减少了客户端的计算负担,同时提高了全局模型的适应性。

数据隐私保护: FedRef 仅上传 CVAE 的解码器,不传输任何原始数据或梯度信息,从而有效降低了数据泄露的风险,提升了联邦学习的安全性。

通过这些创新, FedRef 在泛化能力、收敛速度等方面超越了现有的联邦学习优化方法,此外,相对于直接采用生成器学习原始数据构建辅助数据集的联邦学习算法, FedRef 巧妙利用 CVAE 的“对称”且轻量化的网络结构,在能够有效感知局部数据构建全局数据分布的前提下,最大程度上实现数据隐私保护,为非独立同分布数据场景下的联邦学习提供了一种更高效、更安全的解决方案。

3.5 实验与性能评估

本节将通过实验评估 FedRef 算法模型的性能,并验证其有效性。第 3.5.1 节介绍了比较的基准测试,非独立同分布数据集的设置,模型架构以及实验的细节设置;第 3.5.2 节将 FedRef 与最先进的 FL 方法进行了比较,并进行了消融研究,验证了 FedRef 与其他方法的兼容性,以及各组件的必要性。

3.5.1 实验设置

基准。本实验将 FedRef 与经典的联邦学习方法 FedAvg、FedProx、Scaffold、MOON、FedDyn、FedGen、FedDF 和 FedFTG 进行了比较。实验在一台搭载 3090ti GPU、13700k CPU 和 32 G 内存的设备上运行。

网络架构。针对 CIFAR10 和 CIFAR100,与现有的工作相同^[29],FedRef 使用了 ResNet-18^[95]作为骨干网络。在 Fashion-MNIST 数据集上,对于分类器,本算法采用了一个具有 4 个卷积层和 3 个全连接层的 ConvNet^[96]作为的基本网络架构。CVAE 网络被用作生成器。对于 Fashion-MNIST, CIFAR10 和 CIFAR100 数据集, CVAE 网络包括一个高斯编码器和一个解码器。编码器的结构如下:对于 FMNIST,输入尺寸为 $1 \times 28 \times 28$ 的灰度图像,通过两层卷积层和两层全连接层,分别输出均值 (μ) 和标准差 (σ)。对于 CIFAR10 和 CIFAR100,输入的图像数据通过三层卷积层和一层全连接层,分别输出均值和标准差。解码器的结构如下:对于 FMNIST,通过两层全连接层和两层反卷积层,将潜在变量解码回原始图像。对于 CIFAR10 和 CIFAR100,通过一层全连接层和四层反卷积层,将潜在变量解码回原始图像。

Non-IID 数据集设置。实验采用了在 FL 场景中被广泛采用的三个数据集,主要基于 CIFAR-10 和 CIFAR-100 来验证 FedRef 的有效性,并在 Fashion-MNIST 上采用更高数据异构性的采样方法,进一步验证了模型的有效性。同现有的工作^[29,97,98],实验引入了狄利克雷分布 $\text{Dir}(\alpha)$ 模拟客户端之间的非独立同分布数据^[79],在实验中主要采用了 $\alpha = 0.3$ 和 $\alpha = 0.6$ 的设置。对于 Fashion-MNIST,实验采用 $\alpha = 0.1$ 和 $\alpha = 0.3$ 的设置,并针对类别进行采样生成异质性更高的数据分布。

详细的超参数设置:对于 CIFAR10 和 CIFAR100,实验设置了客户端数量为 100,活跃分数为 0.1,代表了每轮参与的客户端数量是 10,客户端本地训练周期数为 5,通信轮次为 1000,本地训练批量大小为 50,权重衰减为 $1e-3$,分类器学习率是 0.1,生成器学习率为 $3e-4$,并采用 SCAFFOLD 作为 FedRef 的优化算法(考虑到 SCAFFOLD 在异构数据中的卓越性能,实验发现, FedRef 能进一步加强此模型性能)。对于 Fashion-MNIST,实验设置了客户端数量为 10,本地训

训练周期数为 5, 通信轮次为 100, 本地训练批量大小为 64, 分类器学习率为 0.01, 生成器学习率为 $3e^{-4}$, 同样采用 SCAFFOLD 作为 FedRef 的优化算法。




图 3-5 CIFAR10 数据集上不同 α 取值的狄利克雷分布下的可视化

客户端数据异构性的可视化。在图 3-5 中, 本节绘制了 10 个客户端的数据分布, 展示了不同狄利克雷设置下客户端类别的分布, 以表示非 IID 条件。对于不同的 α 值, 从图中可以看出, 随着 α 值的增加, 各客户端之间的数据分布趋于均衡, 类别样本在客户端间更为均匀地分布, 非 IID 程度显著减弱。相反, 当 α 较小时, 客户端内会存在部分类别的样本缺失现象, 分布呈现显著不同, 类别分布呈现高度倾斜的特征, 部分客户端甚至完全缺失某些类别样本。该结果从可视化层面验证了 Dirichlet 分布参数对数据异质性控制的有效性, 也为后续算法在不同非 IID 程度下的鲁棒性分析提供了基础依据。

3.5.2 模型性能与分析

3.5.2.1 与最先进的方法（State-of-the-art Methods）比较

表 3-3 FedRef 和基准方法在不同非独立同分布设置的数据集上的测试准确率（%）

#setting	CIFAR-10		CIFAR-100	
	0.6	0.3	0.6	0.3
FedAvg ^[4]	82.04±0.46*	81.13±1.01	50.67±0.34*	48.19±0.19
FedProx ^[65]	82.36±0.38*	82.14±0.43	50.94±0.40*	48.74±0.20
FedGen ^[28]	82.23±0.73*	79.72±0.85*	50.71±0.55*	50.08±0.24*
MOON ^[68]	82.67±0.08*	81.31±0.46	52.55±0.49*	49.25±0.25
FedDyn ^[66]	82.87±0.62*	83.39±1.00	51.68±0.31*	53.60±0.34
SCAFFOLD ^[69]	84.55±0.30*	83.87±1.20	53.91±0.33*	52.98±0.32
FedDF ^[37]	82.92±0.64*	80.97±0.74*	51.36±0.02*	51.26±0.09*
FedFTG ^[29]	86.06±0.19*	84.38±0.49*	56.49±0.55*	55.96±0.39*
FedRef	87.6±0.23	86.21±0.37	57.18±0.32	56.83±0.49

表中*表示在相同的实验设置下先前的研究^[29]中报告的结果。

表 3-4 将达到目标测试准确率 (acc) 所需的通信轮数作为依据，对基于 CIFAR10 和 CIFAR100 数据集上的方法进行评估。请注意，表中以粗体突出显示前两名结果。

	CIFAR10		CIFAR100	
	acc=75%	acc=80%	acc=40%	acc=50%
FedAvg ^[4]	136.00±15.78	416.00±130.30	94.02±7.36	788.51±1.29
FedProx ^[65]	144.92±14.61	386.60±75.13	87.72±5.63	896.51±61.64
FedGen ^[28]	140.00±4.00*	406.67±29.33*	95.00±1.00*	684.00±92.00*
MOON ^[68]	143.34±15.19	444.72±98.79	78.41±5.63	755.09±160.65
FedDyn ^[66]	96.36±2.45	175.71±17.96	88.33±1.87	250.00±27.20
SCAFFOLD ^[69]	105.49±10.34	221.54±21.64	68.34±4.76	213.00±17.58
FedDF ^[37]	132.67±11.33*	329.00±42.00*	94.50±1.50*	452.00±5.00*
FedFTG ^[29]	92.67±14.33*	188.67±31.33*	57.00±1.00*	166.33±10.67*
FedRef	96.10±6.21	178.28±19.90	63.73±4.18	154.70±9.81

表中*表示在相同的实验设置下先前的研究^[29]中报告的结果。

测试集模型准确性。表 3-3 详细展示了各种算法在 CIFAR10 和 CIFAR100 数据集上的测试精度。从表中数据可以看出，FedRef 在所有测试基准下均实现了最佳性能，尤其在 CIFAR10 数据集下，当狄利克雷分布参数设置为 0.3 时，其准确率比排名第二的 FedFTG 高出 1.83 个百分点，这一结果充分证明了 FedRef 在处理数据异质性问题上的优势。其中，FedDF 和 FedFTG 均采用了无数据蒸馏技术，在服务器端进行全局模型微调，从而有效地弥补了传统联邦优化方法在全局模型更新时存在的信息丢失问题。得益于这一策略，FedDF 和 FedFTG 在准确率

上明显优于那些仅依赖于传统联邦优化的方案，需要注意的是 FedFTG 在联邦优化方法的基础上实现了大幅的提升，进一步验证了在服务器端进行模型微调的可行性。此外，FedGen 通过引入一个轻量级生成器来学习和生成伪特征，并将其广播给客户，以规范本地培训。实验结果表明，性能方面在某些情况下表现比 FedAvg 和 FedProx 更好，也在另一种层面说明了生成器在联邦学习中的有效性。实验结果表明，FedRef 通过融入轻量级生成器，学习客户端局部知识，并在服务器端进行知识聚合，以感知全局数据分布，针对全局模型进行微调，这些架构中的关键设计使其在应对数据异构性方面表现尤为突出，让模型取得了有竞争力的性能。




图 3-6 CIFAR10 上不同 FL 方法在 1000 轮通信中的学习曲线， $\alpha = 0.3$




图 3-7 CIFAR100 上不同 FL 方法在 1000 轮通信中的学习曲线， $\alpha = 0.3$

通信轮数。如表 3-4 所示,不同联邦学习方法在达到指定测试准确率目标时所需的通信轮数进行了对比。在 CIFAR-10 数据集上,目标测试准确率分别设定为 75% 和 80%;在 CIFAR-100 数据集上,目标测试准确率分别为 40% 和 50%。FedRef 在两个数据集上均获得了前二名的好成绩,相比 SCAFFOLD 算法大幅减少了其所需的通信轮数。对于 CIFAR10, FedRef 所需通信轮数虽略高于 FedDyn 和 FedFTG,但更稳定,且最终精度明显高于两者。如图 3-6 和图 3-7 所示,不同 FL 方法在 1000 轮通信中的学习曲线呈现出一定差异,虽然各种 FL 方法在 150 轮左右不能看出有明显的性能差距,但是不同于其他 FL 方法在性能增长上出现放缓, FedRef 在 200 轮通信后仍保持明显的增长趋势,与其他方法拉开了性能差距。尤其需要关注的是 FedDyn,最初有较快的增长速度,但是在 200 轮通信后增长趋势逐渐放缓,且远低于 FedRef。

观察图 3-6 和图 3-7 可以发现, FedDyn、FedFTG 等部分算法在初始阶段均表现出较快的精度提升,这是由于这些方法通常能够在训练早期有效捕捉并利用数据中易于学习的共性知识,从而迅速提升模型性能。然而,随着通信轮数的增加,这些方法逐渐进入学习瓶颈期。例如 FedDyn 在达到一定通信轮数后,其知识传输机制未能持续深入挖掘并充分利用客户端数据的多样性或特殊性,模型易陷入局部最优或出现过早饱和,导致后续训练中的性能增长明显趋缓。此外, FedFTG 尽管初期表现出较好的精度提升,但其后期更新也逐渐放缓,显示其数据合成与模型微调策略在长期训练中存在一定局限性。相比之下, FedRef 巧妙利用生成器感知全局数据分布,能够持续提供更加丰富、全面且差异化的知识,从而在模型训练的后期阶段使参数更新的方向更为高效和准确,持续保持稳健的性能增长趋势,体现出了更好的泛化能力和优化潜力。

3.5.2.2 FedRef 与现有的联邦优化算法的正交性

本节在表 3-5 中展示了 FedAvg、FedProx、MOON、FedDyn、SCAFFOLD 和 FedRef 结合的测试性能。在测试结果中, SCAFFOLD+FedRef 取得了最佳的测试准确率,相对其他方法有更大的提升。在达到目标测试准确率所需的通信轮次中, FedDyn+FedRef 和 SCAFFOLD+FedRef 分别取得了最优和次优的表现,与表 3-4 中报告的所需通信轮次结果上一致, FedDyn 能够使得模型更快收敛到目标准确率。通过对比表 3-5 与表 3-3,可以注意到结合 FedRef 能大幅提升现有的联邦优化算法的性能,其中仅使用 FedAvg 作为优化器获得的性能,也超过了一众联邦优化算法。此外,通过对比表 3-6 和表 3-4 可见,现有的联邦优化算法结合 FedRef 能够大大提高模型的收敛速度,包含 FedDyn 在内的联邦优化算法,结合

FedRef 后模型收敛速度获得了不同程度上的提升,尤其是原本收敛缓慢的方法,比如 FedAvg 和 FedProx。这些实验也验证了 FedRef 的有效性和正交性。

表 3-5 FedRef 对联邦优化算法的影响。实验将 FedRef 与现有联邦优化算法结合,在 CIFAR10 上进行,获取了测试准确率(%), $\alpha = 0.3$ 。

	Accuracy (%)
FedAvg+FedRef	84.19±0.31
FedProx+FedRef	83.99±0.34
MOON+FedRef	84.55±0.43
FedDyn+FedRef	83.66±0.6
SCAFFOLD+FedRef	86.21±0.37

表 3-6 在 CIFAR10 数据集上, $\alpha = 0.3$ 时,达到目标测试准确率的轮数,目标准确率分别设置为 75% 和 80%。

	Round	
	acc=75%	acc=80%
FedAvg+ FedRef	114.06±12.35	250.09±32.57
FedProx+ FedRef	111.31±12.56	238.57±26.12
MOON+ FedRef	110.63±11.04	235.00±27.94
FedDyn+ FedRef	89.06±25.66	159.51±10.82
SCAFFOLD+ FedRef	96.10±6.21	178.28±19.90

本节进一步验证了 FedRef 方法与现有联邦学习 (FL) 算法之间的兼容性和正交性。这里的“正交性”特指 FedRef 作为一种独立的泛化增强机制,可以在不改变现有 FL 算法本身的设计理念和具体实现的情况下,有效提升其性能。需要指出的是,本节讨论的联邦优化算法(如 FedProx、MOON、FedDyn 及 SCAFFOLD 等),是指部分通过调整模型更新方向和步长以提升模型性能的算法,这里统称为联邦优化算法。

3.5.2.3 高数据异构性下模型测试准确性

本节在表 3-7 中展示了在高数据异质性划分下的 Fashion MNIST 数据集上的测试准确率。实验基于类别数通过狄利克雷分布参数 $\alpha = 0.3$ 和 $\alpha = 0.1$ 生成狄利克雷分布进行采样。在采样方法下,参与联邦学习训练的整体数据集是一个通用类分布高度长尾,并在客户端内存在部分类别达到 5000 个样本,部分类别未被采样的较高类不平衡的场景。在表 3-7 中, FedRef 在所有场景中取得了最好的性能,即使基线模型之间性能差异不大, FedRef 仍能取得明显优势,拉开了性能差距,显示了当通用类分布高度长尾时 FedRef 的泛化能力。不同于 FedAvg, FedProx, SCAFFOLD 和 MOON 等方法,它们只处理数据的非独立同分布性,而不考虑全局的类不平衡性, FedRef 通过学习各个客户端头类数据特征,在服务

器端进行模型的集成蒸馏,在一定程度上缓解了全局类不平衡带来的模型性能下降。

表 3-7 FedRef 和部分基准方法在高数据异质性划分下的 Fashion MNIST 数据集上的测试准确率 (%)

#client	5		10	
#setting	0.3	0.1	0.3	0.1
FedAvg ^[4]	88.33±0.37	73.94±3.77	89.68±0.21	86.22±0.66
FedProx ^[65]	88.33±0.22	73.2±2.06	89.65±0.14	86.17±0.49
SCAFFOLD ^[69]	88.57±0.67	77.78±3.46	89.89±0.35	87.74±0.37
MOON ^[68]	88.47±0.44	74.62±3.45	89.77±0.19	86.2±0.76
FedRef	89.01±0.52	78.2±1.65	90.7±0.39	88.03±0.43

3.5.2.4 消融研究




图 3-8 数据异质性影响下的模型测试准确率

数据异构性影响。数据异构性是联邦学习旨在解决的关键问题,本文通过实验证明了在多种设置下, FedRef 取得了最好的成绩。如图 3-8 所示,图中报告了各种 FL 方法在不同 α 值上的测试精度, FedRef 在高数据异质性的场景 $\alpha = 0.2$ 中表现出更好的性能,此外随着数据异质性程度的降低, FL 方法的测试准确率都有不同程度上的提升,但是面对数据异质性的影响, FedRef 表现出了更好的鲁棒性。

FedRef 中各组件对模型测试准确率的影响。本实验在 CIFAR10 上进行了 500 轮通信训练 ($\alpha = 0.3$), 报告了在去除单个模块后模型训练的测试精度。如表 3-8 所示, 表中 Mean Sample 代表通过客户端类别超过均值的数据训练 CVAE

模型，Global Class Information Integration (GCII) 代表全局类信息集成。通过观察可以知道，这两个模块对模型性能有比较大的影响，尤其是采用 Mean Sample 方式训练，对模型的准确度和置信区间都有很大影响。需要注意的是，在去除单一的损失函数后，也可以看到模型性能会受到影响。

表 3-8 在 CIFAR10 上 FedRef 各模块对测试准确率的影响 ($\alpha = 0.3$)。

Method	Accuracy(%)
FedRef	85.11 ± 0.35
-Mean Sample	83.37 ± 0.62
-GCII	84.29 ± 0.33
- $\mathcal{L}_{NLL}^k$	84.97 ± 0.32
- $\mathcal{L}_{KL}^k$	84.91 ± 0.27
- $\mathcal{L}_{\text{Recon}}$	84.99 ± 0.4
- $\mathcal{L}_{\text{CVAE-KL}}$	84.66 ± 0.41




图 3-9 联邦客户端模型贡献率影响下的模型测试准确率

集成蒸馏客户端 CVAE 解码器采样率的影响。在服务器端，FedRef 通过客户端上传的 CVAE 解码器生成用于集成蒸馏的输入空间，全部或者部分客户端解码器参与集成蒸馏对模型都会产生影响，为此实验使用联邦客户端模型贡献率 (Federated Client Model Contribution Rate, FCMCR) 来表示在服务器端设置的采样率，并基于 $FCMCR \in \{0.1, 0.3, 0.6, 0.9, 1\}$ 的设置进行了对比实验。如图 3-9 所示，当大多数客户端在集成蒸馏时参与贡献会获得更好的模型性能。考虑到中心化训练的模型精度是 $92.55 \pm 0.05^{[29]}$ ，并且 FedRef 模型后期性能达到了 85% 以

上, 所以模型性能提升放缓。可见, FCMCR 对模型性能和收敛速度都存在较大影响。

客户端采样率的影响。本实验主要探讨在每轮通信中使用不同比例的活跃客户端对模型性能的影响, 实验的采样率设置为 $s \in \{0.05, 0.1, 0.15, 0.2, 0.25\}$, 即每轮训练过程中, 仅有一定比例的客户端参与全局模型的聚合。如图 3-10 所示, FedAvg 的性能受采样率影响较大, 当采样率较低 (如 0.05 或 0.1) 时, FedAvg 的测试准确率较高, 但随着采样率的增加, 准确率先下降后缓慢上升。其整体波动较明显, 表明 FedAvg 在低采样率条件下仍能维持一定的性能, 但在更高的采样率下无法充分利用更多的客户端信息。相比之下, FedRef 在保持最佳检测性能的同时, 随着参与的客户端数量增加, 模型性能呈现出更加明显的提升趋势。在采样率较低时, FedRef 的性能优势仍然明显, 反映了 FedRef 具备较强的鲁棒性, 能够更好地适应不同的客户端参与比例, 降低失活客户端带来的负面影响。




图 3-10 客户端采样率影响下的模型测试准确率

3.6 本章小结

本文提出了一种新颖的无监督知识蒸馏方法, 该方法利用全局分布数据的重采样来微调服务器上的全局模型, 从而提升联邦学习模型的性能。首先提出了采用易于收敛的 CVAE 模型作为生成器, 在模型训练首轮针对客户端数据集头类数据进行学习, 为了高效学习局部模型的输入空间, 本文提出了重构损失和 KL 散度作为 CVAE 模型的损失。同时, FedRef 通过上传 CVAE 解码器, 在服务器端通过伪数据生成客户端模型的输入空间, 以此进行模型的集成蒸馏。为了最大

程度通过集成蒸馏进行模型间的知识传递，FedRef 采用了定制输入空间样本生成和全局类信息集成方法促进模型间知识传递。

本章节的研究内容已被期刊《Tsinghua Science and Technology》接收。

第四章 基于生成模型与原型增强的双重微调联邦学习算法

4.1 引言

随着联邦学习 (Federated Learning, FL) 在分布式数据环境中的广泛应用, 如何有效应对非独立同分布数据场景下的挑战成为了当前研究的热点问题。尤其是在面临数据分布存在概念偏移和特征分布倾斜的情况下, 客户端模型间的特征不一致性严重影响了模型的收敛。这一问题和跨域问题相似, 通常在深度学习包括图像识别、自然语言处理和自动驾驶等领域, 其中普遍存在的假设是, 训练数据集和测试数据集的所有样本都是独立的、同分布的^[99], 这种假设在现实场景中通常不成立。这种差异一般称为域偏移, 模型遇见不可见域时, 通常会显著降低模型的性能。不考虑模型异构性, 联邦学习在解决数据异构性时, 通常也会遇到相关的情况, 并有一个研究方向为联邦域泛化^[100], 这与本文想要针对解决的非独立同分布下数据出现的概念偏移和特征分布倾斜较为一致。

为了解决上述问题, 域对齐相关算法被提出以解决目标域和源域之间的特征分布对齐^[101,102], 以提升模型的泛化性能。此外, 还有本文之前提到的一些生成模型相关的联邦学习, 主要通过维护一个生成器来学习模型的嵌入特征^[28,32], 并在服务器或者客户端进行特征对齐。在使用轻量级的表征转换网络或者生成模型方面, FRAug^[89]通过共享嵌入生成器与本地表示转换网络结合, 实现客户端特征分布对齐; pFedPG^[112]在服务器端部署个性化提示生成器, 为各客户端提供视觉引导以适应本地数据分布。此外, 还有使用预训练模型在服务器端进行联邦特征的生成^[60], 以优化模型。这些方向的算法都在一定程度上对模型的优化有帮助, 不过轻量化的指导对于模型训练过程影响有限, 在模型潜在特征一致性上还需要进一步的限制, 以加快模型收敛。

与此同时, 联邦原型学习逐渐成为应对客户端异构性的新思路。代表性方法如 FedProto、FedPCL、ProtoFL 等, 采用类原型作为通信与聚合的载体, 在提升个性化能力、保护隐私和降低通信成本方面表现出优势, 详见 1.2.1.4 节。特别地, FedTGP 进一步引入可训练的全局原型与边界增强对比学习机制, 有效改善了原型收敛边界模糊的问题。此外, 对比学习在原型共享与表示对齐方面也被广泛应用 (如 FedPCL、FedTGP 等), 增强了模型在非独立同分布数据下的鲁棒性。

为了解决上述非独立同分布场景下特征分布偏移的问题, 考虑到模型的收敛速度和客户端数据异构导致的特征不一致性, 本文提出了 FedDualAlign 算法。

本文创新性地结合轻量级生成器和原型网络,通过类原型一致性促进模型更新方向一致,利用神经网络高效地拟合性能学习局部偏差。此外,本文通过轻量的生成模型学习全局模型和集成模型的隐层特征嵌入,并下发生成器到客户端指导客户端更新,用以增强模型的泛化性能。FedDualAlign 中进一步地设计了生成模型地匹配损失、输出差异损失以及增强的多样性损失,全面地提升了生成模型对隐层特征的学习能力,使其能够更加有效地指导局部模型地更新。在原型网络方面,FedDualAlign 通过引入全新的边际自适应对比损失函数,自适应促进调整类原型之间的间距,增强模型在不同类别间的识别能力,能够高效捕捉类别间差异,提升了模型的精度。此外,在局部模型训练过程中,本文引入了原型对比损失和领域重加权损失,进一步促进了类特征一致性,加速了模型的收敛。

FedDualAlign 算法贡献如下:

(1) FedDualAlign 在服务器端对全局模型和集成模型的隐层特征向量采用生成模型进行无数据学习建模,以生成器为载体学习因数据分布不一致导致的各个模型的独有特征分布,并在局部模型训练过程中发挥指导模型更新的作用。

(2) FedDualAlign 在服务器端维护了一个全局原型网络,在服务器端对客户端上传的类原型进行学习和原型边际自适应调整,创新性地引入了原型对比损失和领域重加权损失,促进了同类原型的拉近,且增强了不同类别的原型可分性,确保了原型特征的一致性和协调性,加速了模型的收敛。

(3) FedDualAlign 有效地利用了服务器端算力,并主要通过隐层特征来指导局部模型更新,增强模型的泛化能力,以及保证了训练过程中模型输出的一致性。本文通过大量的实验,在多个基准数据集上验证了 FedDualAlign 的优越性能,并与现有的前沿算法相比,取得有竞争力的性能和模型收敛速度。

本章节接下来安排如下:在 4.2 节将对 FedDualAlign 的优化目标进行问题建模;在 4.3 节将详细介绍 FedDualAlign 算法的设计动机、生成模型的应用、原型网络的引入以及算法流程等方面;在 4.4 节将对比 FedDualAlign 与现有的前沿研究在算法目标、解决方案以及实现方式上的异同;在 4.5 节将对比 FedDualAlign 在多个数据集上的实验结果,并对模型的性能和收敛速度进行评估;在 4.6 节将对本章研究内容进行总结。

4.2 问题分析

FedDualAlign 的设计目标如下:

(1) 加速模型收敛与特征对齐：在数据异质性较为严重的场景下，不同客户端之间存在显著的特征分布偏移。FedDualAlign 通过引入轻量级生成模型来高效拟合和传递隐层特征，并结合原型网络进行类原型对齐，利用原型对比损失与领域重加权损失，实现全局与局部模型特征的有效协同，进而加速模型的收敛。

(2) 充分利用服务器端的计算资源：服务器具备强大的计算能力，FedDualAlign 利用这一优势在服务器端进行全局生成器和原型网络的训练，从而在保证隐私安全的前提下，降低客户端的计算负担和通信成本，实现更高效的知识迁移与聚合。

(3) 提升模型泛化能力与通信效率：本方法在最小化数据传输和客户端运算量的前提下，通过生成模型下发轻量化的指导信息，使客户端能够在本地快速适应数据偏差；同时，通过全局原型网络对不同类别间的边际进行自适应调整，确保了跨域数据的有效对齐和隐层特征的一致性，从而显著提升了模型的泛化性能。

FedDualAlign 不同模块间的优化目标如下：

本地模型的优化目标是通过更新本地模型参数 θ_k 来最小化本地损失函数，优化本地模型在客户端数据上的表现。目标可以通过以下公式表示：

$$\theta_k^* = \arg \min_{\theta_k} L_{local}(\theta_k, \mathcal{D}_k) = \arg \min_{\theta_k} [L_{client_gen} + L_p + L_{CE}] \quad (4-1)$$

其中， L_{client_gen} 是生成器引导损失， L_p 是原型增强损失， L_{CE} 是交叉熵损失， $\mathcal{D}_k$ 是客户端 k 的本地数据集。

全局模型的优化目标是通过聚合客户端模型更新来最小化全局数据集上的损失函数。全局模型优化目标为：

$$\Phi^* = \arg \min_{\Phi} L_{global}(\Phi, D) = \arg \min_{\Phi} \left[\frac{1}{|C|} \sum_{k \in C} L_{local}(\theta_k, \mathcal{D}_k) \right] \quad (4-2)$$

其中， L_{local} 是每个客户端的本地损失函数， Φ 是全局模型参数， D 是全局数据集。

特征生成模型的优化目标是生成质量高，具有多样性的特征，优化生成器的参数 φ_G 。生成器优化的目标可以通过以下公式表示：

$$\varphi_G^* = \arg \min_{\varphi_G} L_{gen}(\varphi_G) = \arg \min_{\varphi_G} [L_{match} + L_{diff} + L_{div}] \quad (4-3)$$

其中， L_{match} 是匹配损失， L_{diff} 是输出差异损失， L_{div} 是多样性损失。

原型网络的优化目标是优化客户端原型，确保其与全局目标一致，并通过优化边际损失来增强原型之间的分离性。原型网络的优化目标可以表示为：

$$\varphi_P^* = \arg \min_{\varphi_P} L_p(\varphi_P) = \arg \min_{\varphi_P} [L_c^P] \quad (4-4)$$

其中, L_c^P 是原型自适应边际对比损失函数。

4.3 联邦双重微调算法

现实世界中常常存在对同一对象的不同看法和认识, 人类具有超凡的能力, 能够通过以往类似事物的认知, 来给予新的对象定义和相关专业知识。这种问题对于神经网络算法来说, 是一项困难的挑战^[100]。一定程度上, 神经网络受制于训练数据, 具有对数据的强依赖性, 而数据具备不同的分布, 一个数据的分布如果未在训练集中体现, 那么神经网络模型对此数据的识别则存在困难。在联邦学习中, 同类数据的分布不一致问题或者是在异构分布上训练的模型到未知分布的客户端推广的问题, 显著影响了模型跨不可见域的泛化性能和鲁棒性^[103]。

为了解决相关问题, FedProto 提出共享轻量级类级别代表, 即原型(prototype), 在异构联邦学习中取得了良好的效果。在后续的研究中, 通过聚合客户端的类原型来实现模型更新的对齐。这些方法旨在通过共享类别的代表性原型, 减少数据分布不一致带来的挑战, 从而提升各个客户端模型的泛化能力。然而, 传统的基于原型的聚合方法通常依赖简单的原型均值计算, 忽视了不同客户端之间在模型架构和数据分布上的差异。此类简单的聚合策略难以有效整合客户端的知识, 尤其是在面临复杂的全局数据分布时^[104]。现有的一些研究^[59,105], 从提升原型类内紧凑性和跨类别的区分度的方向, 取得了良好的效果。在联邦学习中采用生成模型主要分为对隐层特征的建模和模型输入空间的建模^[28-30,32,35], 都取得了不错的模型性能。但值得注意的是, 隐层特征的学习难度远低于输入空间的建模, 此外, 隐层特征的建模相比于输入空间建模能够更加有效地保护客户端隐私。最后, 现有的研究一定程度上忽略了对生成器的优化^[28,29,35], FedFTG 和 Dense 分别面向模型同构与异构场景, 利用 DFKD(Data-Free Knowledge Distillation)对全局模型进行微调。在此基础上, DFRD^[30]进一步优化了生成器设计, 从生成样本的保真度、可迁移性和多样性等方面提高了局部训练空间的拟合质量。2024 年, Zhang 等人^[106]提出 FedSD2C, 通过合成蒸馏-蒸馏物通信 (Synthetic Distiller-Distillate Communication) 机制优化知识传输过程, 并引入 V-information 核心集选择策略。该方法显著提升了模型在非独立同分布数据下的表现。值得注意的是, 这些算法主要集中在采用 DFKD 学习模型的输入空间, 这将对于服务器端算力和高效生成模型的设计带来较大的困难。为了提升生成模型的有效性, 本文采用在服务器端采用生成模型学习集成模型和全局模型的隐层嵌入特征, 能够更加快速地收敛,

并且采用更低的算力。这与扩散模型算法设计思想一致，一定程度上减轻了模型学习的压力，采用更易于学习的目标。




图 4-1 FedDualAlign 的整体框架

基于上述的观测结果，本文考虑了客户端数据分布不一致导致的客户端特征的不一致性，利用了深度神经网络模型对偏差学习的高效学习能力，采用中期特征泛化和一致性对齐的策略，分别从生成模型学习全局模型和集成模型的知识，以及原型增强对齐的角度，设计了双重模型微调的联邦学习算法，如图 4-1 所示，为 FedDualAlign 的整体框架，客户端首先初始化模型，训练后上传本地原型；服务器端执行隐层特征生成器和原型网络两部分模型更新，其中，生成器采用匹配损失 L_{match} ，输出差异损失 L_{diff} 和多样性损失 L_{div} 来更新生成器 ϕ_G ，原型网络通过自适应边际对比损失函数 L_c^p 进行模型更新。此外，服务器端执行增强原型向客户端的下发，以及生成器参数的下发。客户端局部训练过程中通过增强原型，以及生成器数据来提升类特征一致性。

4.3.1 算法动机

图 4-2 展示了这一问题，图中虚线为加入生成数据训练后的决策边界，蓝色实线是基于原始数据训练的决策边界，蓝色圆圈表示原始数据，三角形，方形和菱形分别为生成数据。子图 (a) 中展示了生成模型有偏导致决策边界左移。子图 (b) 中，生成模型成功在正确位置生成数据，表明生成器在此情形下能够有效地生成接近真实数据的样本，提升了模型性能。子图 (c) 展示了另一个生成器生成的错误示例，其中红色菱形表示生成的数据，这些数据点越过了决策边界，表示生成器未能准确地生成符合决策边界的数据。有偏生成器具体表现如图 4-2 (a)

和图 4-2 (c) 所示, 会导致模型的性能下降, 而高效的生成模型能够更好地学习分类器的输入空间。如图 4-2 (b) 所示, 高效的生成模型能够生成有效的边缘样本 (即难以识别的样本), 从而增强分类器的性能。基于上述实验结果, 本文认为这主要源于现有研究中生成模型简单的设计难以拟合分类模型的输入空间 [28,29,35], 此外, DFKD 从模型反向到数据的传输中会产生一定的信息损失, 尤其是原始数据存在非独立同分布的性质, 使其更加难以学习和拟合, 这两点造成了生成模型在联邦学习微调模型时发挥的作用有限。同时, 对模型复杂的输入空间的学习消耗了大量的训练时间。由此, 本文进一步关注了相对生成模型更加简单的任务, 即生成隐层特征, 并优化了生成模型的设计。




图 4-2 生成数据对决策边界的影响

进一步地, 本文基于 CIFAR10 数据集训练了两个不同精度的模型, 采用相同的超参数设置以及相同的网络结构 (Resnet18), 两个模型的精度分别为 42.49% 和 85.41%。实验针对数据集的每个类别进行了相同数量的随机采样, 并送入模型检测, 保存了分类头前的隐层特征, 本节通过余弦相似度和 JS 散度可视化了不同类在两个模型上的隐层特征的关联。如图 4-3 所示, 低精度模型不同类别之间的隐层特征余弦相似度较高, 意味着不同样本的嵌入向量在方向上非常相似, 即它们的角度几乎一致。此外, 类间 JS 散度较低, 意味着嵌入向量的概率分布差异较小。这种相似性和类间特征嵌入低差异性为模型分类头带来了较大的困难, 反之, 高精度模型类间的隐层特征差异较大, 区分度比较明显, 在相同的网络结构下, 明显高精度模型分类头受益于此, 而能保持较高的模型性能。




图 4-3 不同模型类别嵌入特征之间的关系

4.3.2 生成模型辅助微调

在联邦学习（Federated Learning）中，存在一个客户端集合 $\mathcal{C}$ ，其中包含 $|\mathcal{C}|$ 个客户端。每个客户端 $c_t \in \mathcal{C}$ 拥有一个私有的本地数据集 $D^t = \{(x_i, y_i)\}_{i=1}^{n_t}$ ，其中 $n_t = |D^t|$ 表示该客户端本地数据样本数。令所有客户端的数据联合构成全局数据集 $D = \bigcup_{t=1}^{|\mathcal{C}|} D^t$ ，其大小为 $|D| = \sum_{t=1}^{|\mathcal{C}|} n_t$ 。联邦学习的目标是在不直接传输原始数据，训练得到一个全局模型参数 θ_S ，使得在全局数据 D 上的损失函数最小化，即：

$$\min_{\theta_S} L(\theta_S) = \frac{1}{|D|} \sum_{t=1}^{|\mathcal{C}|} \sum_{(x_i, y_i) \in D^t} \ell(f_S(x_i; \theta_S), y_i) \quad (4-5)$$

上式表示联邦学习的全局优化目标，其中 $\ell(\cdot)$ 一般为交叉熵损失函数， $f_S(x_i; \theta_S)$ 表示在模型参数 θ_S 下对输入 x_i 输出的预测（例如最后一层全连接网

络的 logits)。在实际执行时,每个客户端基于其本地数据 D^t 计算本地更新或梯度 $\nabla_{\theta_S} L_t(\theta_S)$,并在一次通信中将该更新发送给服务器;服务器对所有客户端的更新进行聚合(例如按各客户端数据量 $\frac{n_t}{|D|}$ 进行加权平均),从而得到更新后的全局参数 θ_S 。这样,无需传输任何原始数据即可完成对分散数据的联合训练,同时兼顾隐私保护与模型性能。

为了提升模型的泛化性能,本文在服务器端引入条件对抗生成网络,以无数据的方式进行学习,对全局模型和集成模型的特征嵌入进行建模。不同于 FedGen 主要关注生成样本的质量、生成器与用户模型的匹配, FedDualAlign 引入匹配损失、输出差异损失和多样性损失更加注重生成样本的可用性和多样性。

匹配损失: 该损失用于衡量生成样本与目标分布之间的差异,通过对多个教师模型的输出进行加权求和后与真实标签进行交叉熵计算,确保生成器能够输出高质量且与目标标签一致的样本。为了实现这一点, FedDualAlign 采用了加权的交叉熵损失:

$$L_{\text{match}} = \text{CE} \left(\sum_{k=1}^K w_k \cdot z_{\text{teacher}}^{(k)}, y \right) \quad (4-6)$$

上式为匹配损失函数,其中, $z_{\text{teacher}}^{(k)}$ 表示第 k 个客户端模型对生成样本的输出 logits; w_k 表示第 k 个教师模型的权重(通常根据各教师对应标签的样本数量归一化得到); y 是生成样本的真实标签; CE 为交叉熵损失函数,用于衡量预测分布与真实标签之间的差距。

此损失的目标是让合成数据通过生成器生成的样本,经各教师模型 " 加权平均 " 后,其预测分布尽可能接近输入标签分布,从而 " 匹配 " 目标标签。

输出差异损失: 该损失用于衡量各教师模型在生成样本上的预测输出之间的差异。通过计算成对教师模型输出的均方误差,以鼓励生成器生成的样本能够引起各教师模型响应上的分歧,从而促使生成器探索更多潜在特征。为了实现这一点, FedDualAlign 采用了成对均方误差损失,此外,为了进一步提升生成器对全局模型和集成模型特征嵌入的建模能力,本算法引入了 FedGen 中客户端的集成输出 (teacher logit) 与全局模型 (student) 的输出之间的 KL 散度约束:

$$L_{\text{diff}} = \alpha \frac{2}{K(K-1)} \sum_{i < j} \text{MSE} \left(z_{\text{teacher}}^{(i)}, z_{\text{teacher}}^{(j)} \right) - \beta \text{KL} \left(\sum_{i \in S_t} \tau_{i,y} f_i(s, \theta_i), f(s, \theta) \right) \quad (4-7)$$

上式为输出差异损失函数，其中， $z_{\text{teacher}}^{(i)}$ 和 $z_{\text{teacher}}^{(j)}$ 分别表示第 i 个和第 j 个客户端模型对生成样本的输出 *logits*； MSE 为均方误差损失函数，用于衡量两个预测输出之间的平均平方差； $\tau_{i,y}$ 表示教师 i 在标签 y 上的权重， $f_i(\cdot)$ 表示第 i 个客户端模型的输出分布， $f(s, \theta)$ 表示全局模型对合成数据 s 的输出分布。

此损失的目标是使得各教师模型对生成样本的响应尽可能具有多样性和分歧性，从而引导生成器生成更加丰富的特征，并有效缓解模式崩溃问题。此外，通过引导全局模型与集成模型输出相互靠近，从而提升整体训练的稳定性与泛化能力。

增强的多样性损失：该损失用于提升生成样本之间的多样性，避免生成器输出重复或相似的样本。通过引入样本间的欧几里得距离和梯度惩罚项，确保生成器在训练过程中生成的样本更加分散且具有更强的变异性。为了实现这一点，FedDualAlign 采用了基于欧几里得距离和梯度惩罚的多样性损失：

$$L_{\text{div}} = \sum_{j \in J, j \neq k} (|s_j - s_k|_2^2 + (1 + \lambda) |\nabla f(s_j, \theta)|_2^2) \quad (4-8)$$

上式为增强的多样性损失函数，其中， s_j 和 s_k 分别表示生成器输出的两个样本， $|s_j - s_k|_2^2$ 表示它们之间的欧几里得距离， $\nabla f(s_j, \theta)$ 表示对生成样本 s_j 进行求导后的梯度， λ 是一个超参数，用于控制梯度惩罚项的权重。第一项 $|s_j - s_k|_2^2$ 用于衡量了生成样本 s_j 和 s_k 之间的欧几里得距离，即样本之间的差异。通过最小化这个损失，生成器会被鼓励生成更多差异化的样本。具体来说，当两个样本 s_j 和 s_k 之间的欧几里得距离较大时，说明它们在特征空间中存在较大的差异，生成器的目标是使这些差异变得更加明显，从而增加样本之间的多样性。通过这一项的引导，生成器能够避免模式崩溃，确保输出的样本之间存在显著的多样性。 $(1 + \lambda) |\nabla f(s_j, \theta)|_2^2$ 这一项是梯度惩罚项，用于增强生成器对样本变动的敏感性，从而提高样本生成过程中的多样性。通过计算生成器输出样本 s_j 在某些参数变动下的梯度（即 $\nabla f(s_j, \theta)$ ），该项鼓励生成器在训练过程中对样本的变化更加敏感。具体来说，较大的梯度意味着模型在生成过程中会做出更大的调整，从而避免生成样本过于接近，进一步增加样本之间的差异性。超参数 λ 控制这一项对损失的贡献，确保梯度惩罚项不会过度影响生成器的训练。

结合 L_{match} ， L_{diff} 和 L_{div} ，生成器的整体目标函数可以形式化为：

$$L_{\text{gen}} = L_{\text{match}} + \beta_{\text{diff}} \cdot L_{\text{diff}} + \beta_{\text{div}} \cdot L_{\text{div}} \quad (4-9)$$

其中， β_{tran} 和 β_{div} 是可调超参数。值得注意的是，经过良好训练的生成器生成的合成数据应与真实数据在视觉上保持明显区别，以确保隐私保护，同时能

够捕捉本地模型的共同知识，从而确保合成数据的分布与真实数据相似，以保证其在实际应用中的有效性。

现在，FedDualAlign 采用生成器输出来更新客户端的局部模型，并使用与 FedGen 一致的更新策略，具体如下：

$$L_{\text{clien_gen}} = E_{y \sim p(y)} \left[\mathcal{L}_c \left(f_\theta \left(g_\phi(z, y) \right), y \right) \right] + \beta \cdot \text{KL} \left(f_\theta \left(g_\phi(z, y) \right), f_\theta(X) \right) \quad (4-10)$$

上式为生成模型引导下客户端模型更新的目标损失函数，其中， y 为客户端 mini batch 的原始标签， z 为标准的高斯噪声， $g_\phi(y)$ 为生成器根据合成数据生成的隐层特征， $f_\theta(g_\phi(z, y))$ 为客户端分类模型对生成特征的分类结果， X 为局部客户端的原始数据， $f_\theta(X)$ 为客户端模型针对原始数据的分类结果。

4.3.3 原型增强对齐

近年来，联邦学习领域研究者针对模型异构和跨域问题，为了提升性能考虑了采用原型^[59,56,57,107,108]，表示为同一语义类内的向量平均值，现有部分研究致力于获取高效原型，然后用于正则化局部模型来解决非独立同分布问题。除了对原型在聚类，选择和加权的现有方案以外，FedTGP^[59]考虑了在服务器端对原型的增强，取得了良好的模型效果。依照原型增强的思路，FedDualAlign 进一步采用全局原型网络来在服务器端对客户端原型进行学习，具体而言，本算法重新设计了自适应边际对比损失函数，以及局部模型的对比学习。首先每个客户端从本地数据中提取原型，用于在服务器端进行全局聚合，遵循 FedProto 的方法，每个客户端 i 首先通过从其本地数据 D_i 中提取每个类别的原型来初始化其模型。具体来说，客户端 i 通过以下公式计算每个类别 c 的原型 P_i^c ：

$$P_i^c = E_{(x,c) \sim D_i} [f_i(x; \theta_i)] \quad (4-11)$$

其中， f_i 是客户端 i 上的特征提取器，参数为 θ_i ，它将输入数据 x 映射到特征空间 R^K 。对于每个类别 c ，原型 P_i^c 是所有属于该类别的数据样本 x 在特征空间中的均值。因此，原型 P_i^c 表示类别 c 在客户端 i 上的典型特征向量。

当每个客户端计算并上传自己的原型后，服务器会聚合客户端原型，进行加权平均以生成全局原型。全局原型的计算公式如下：

$$\overline{P}^c = \frac{1}{|N_c|} \sum_{i \in N_c} \frac{|D_i^c|}{N_c} P_i^c \quad (4-12)$$

其中， N_c 是所有客户端中包含类别 c 的客户端的集合， D_i^c 表示客户端 i 上属于类别 c 的数据集，且 $|D_i^c|$ 是该数据集的大小。全局原型 $\overline{P}^c$ 是所有客户

端计算的原型 P_i^c 的加权平均, 权重为每个客户端的类别 c 数据集大小的比值。这种加权平均能够使得原型更好地反映全局数据的特征, 并减少由于数据不均衡导致的偏差。

接下来, 服务器会采用一个轻量级的原型网络对所有客户端的原型进行学习, 同样的生成模型输入为标准的高斯噪声加为标签, 这在采用生成模型的联邦学习中是常见的。

定义原型间的曼哈顿距离 $\phi(P_i^c, P_j^{c'})$, 计算公式为:

$$\phi(P_i^c, P_j^{c'}) = \sum_{k=1}^d |P_i^c[k] - P_j^{c'}[k]| \quad (4-13)$$

其中, P_i^c 和 $P_j^{c'}$ 分别是第 i 和第 j 个客户端原型的 c 类和 c' 类原型, d 是原型的维度, $|P_i^c[k] - P_j^{c'}[k]|$ 是在每个维度上计算的绝对差值。

接下来, 本文将原型距离按升序排列, 并计算其中前 60% 数据的均值, 作为 $\alpha(t)$ 的取值。具体来说, 假设原型对的曼哈顿距离排序为 $D_1, D_2, \dots, D_n$, 则 $\alpha(t)$ 为前 60% 的距离均值:

$$\alpha(t) = \frac{1}{[0.6n]} \sum_{i=1}^{[0.6n]} D_i \quad (4-14)$$

其中, n 是所有原型对的总数, $[0.6n]$ 是取 60% 的原型对。

依据^[59]提到模型早期迭代导致较大的边际可能会误导原型训练和客户端模型的训练, 本文将其自适应边际函数进行了调整, 如下:

$$\delta(t) = \min \left(\max_{c \in [C], c' \in [C], c \neq c'} \phi(Q_t^c, Q_t^{c'}), \alpha(t) \right) \quad (4-15)$$

FedDualAlign 中动态调整不仅考虑了原型之间的距离分布, 还通过 60% 的排序均值来进行更平滑的边际调整, 确保了边际随着训练进程的不断变化而变化。FedTGP 的原型学习设计通过引入生成器和原型网络来优化每个客户端的原型, 而边际函数通常依赖于最大距离或固定的阈值来控制原型的分离度。

最后, 本文定义了原型网络训练的损失函数, 其目的是通过增加类别间的距离, 增强类间分离性。值得注意的是, 曼哈顿距离计算的是每个维度上的绝对差值, 这对于稀疏数据和大规模数据集具有更高的稳定性和效率, 尤其是在高维空间中, 且具有更加高效的计算效率。FedDualAlign 采用了动态边际调整的设计, 能够依据原型对的曼哈顿距离进行动态调整, 能够更加平滑地适应训练过程中的变化。

$$L_c^P = \sum_{i \in I_t} \left[-\log \frac{e^{-(|p_i^c - \widehat{P}^c| + \delta)}}{e^{-(|p_i^c - \widehat{P}^c| + \delta)} + \sum_{c' \neq c} e^{-|p_i^c - \widehat{P}^{c'}|}} \right] \quad (4-16)$$

上式为原型网络训练的损失函数，其中， $|p_i^c - \widehat{P}^c|$ 计算客户端原型和全局原型之间的曼哈顿距离。 p_i^c 表示第 i 个客户端的类别 c 的原型。 $\widehat{P}^c$ 表示全局原型。 δ 是一个动态调整的边际。 $|p_i^c - \widehat{P}^c|$ 表示客户端原型 p_i^c 与全局原型 $\widehat{P}^c$ 之间的曼哈顿距离，这是计算原型间差异的方式。 $\sum_{c' \neq c} e^{-|p_i^c - \widehat{P}^{c'}|}$ 对于每个类别 c ，求和所有其他类别 c' 的客户端原型之间的曼哈顿距离，并通过指数加权，确保不同类别的原型间有更大的差异。

原型网络在联邦学习训练过程中会下发到客户端进行本地类特征的指导，FedDualAlign 进一步地采用了域内对比损失，旨在通过对同一域内的特征进行对比学习，增强本地特征的多样性，同时减少域特定的过拟合。它直接对比来自同一域内同一类别的特征，定义如下：

$$L_{\text{IDKTL}} = \frac{1}{B} \sum_{i=1}^B \left(\sum_{k \in K} |h_i - g_k|_2^2 \right) \quad (4-17)$$

其中， h_i 是本地样本 i 的特征向量。 g_k 是类别 k 的通过原型网络生成的原型。 K 是所有类别的集合。 B 是批量大小。

进一步地，可以通过计算每个本地特征 h_i 和它的对应类别原型 g_{y_i} 之间的余弦相似度，鼓励特征与原型更接近：

$$L_{\text{CE}} = -\frac{1}{B} \sum_{i=1}^B \log \left(\frac{\exp(s(h_i, g_{y_i})/\tau)}{\sum_{k \in K} \exp(s(h_i, g_k)/\tau)} \right) \quad (4-18)$$

其中， $s(u, v) = \frac{u^T v}{\|u\| \|v\|}$ 是余弦相似度，用来衡量特征向量与原型之间的相似性。 τ 是温度参数，控制对比的强度。

结合原型网络、余弦相似度损失和域内对比损失的目标，可以形式化地将其表示为如下的损失函数：

$$L_p = L_{\text{IDKTL}} + \beta_{\text{CE}} \cdot L_{\text{CE}} \quad (4-19)$$

其中， L_{IDKTL} 为域内对比损失， L_{CE} 为基于余弦相似度的损失， β_{CE} 为可调超参数。具体地，域内对比损失旨在通过对同一类别，同一域内的特征进行对比学习，增强本地特征的多样性，并减少域特定的过拟合；而余弦相似度损失则进一步鼓励本地特征与其对应类别原型之间的相似性。

综上所述，本地客户端的损失函数由生成器引导的模型更新损失和原型增强对齐损失两部分组成。其中，生成器引导的模型更新损失 ($L_{\text{client_gen}}$) 通过合成

数据增强客户端模型, 确保局部模型能够学习到全局共享的信息, 同时通过 KL 散度约束客户端模型的输出, 使其与原始数据保持一致性。而原型增强对齐损失 (L_p) 则通过域内对比损失 (L_{IDKTL}) 和余弦相似度损失 (L_{CE}) 进一步优化本地模型的特征表示, 提升其对全局特征分布的适应能力, 从而有效缓解数据异构性带来的模型泛化性下降, 具体公式如下:

$$L_c = L_{CE}(f_{\theta}(X), y) + L_{client_gen} + L_p \quad (4-20)$$

其中, $L_{CE}(f_{\theta}(X), y)$ 为分类模型的交叉熵损失。

4.3.4 算法流程

FedDualAlign 通过在服务器端引入生成器和原型网络, 联合学习全局模型的嵌入特征分布, 分别从潜在特征生成与类别原型建模两个维度对特征进行学习和建模, 并下发生成器和原型网络到本地客户端, 以指导模型的更新, 具体算法流程如算法 1 所示。

算法 1 FedDualAlign	
输入: T : 通信轮次; K : 客户端数量; $\{\mathcal{D}_k\}_{k \in K}$: 客户端的数据集; Φ : 全局模型的参数; $\{\theta_k\}_{k \in K}$: 客户端模型的参数; C : 客户端集合; I_G : 生成器训练迭代次数; φ_G : 生成器的参数; I_P : 原型网络训练迭代次数; φ_P : 原型网络的参数;	
1:	Initialize global model parameters Φ , client parameters $\{\theta_k\}_{k \in K}$ and generators parameters $\{\varphi_{(k,G)}\}_{k \in K}$
2:	for $t = 1, \dots, T$ do
3:	$C_t \leftarrow$ the set of K clients, $\theta \leftarrow \Phi$
4:	for each local epoch do
5:	for each batch $(x, y) \in \mathcal{D}_k$ do
6:	Update θ_i according to Eq.(4-10), Eq.(4-19) and Eq.(4-20) .
7:	end for
8:	Calculate the prototype according to Eq.(4-11) and upload.
9:	end for
10:	for $i = 1, \dots, I_g$ do
11:	update generator φ_G according to Eq.(4-9).
12:	end for
13:	for $i = 1, \dots, I_p$ do
14:	update generator φ_P according to Eq.(4-16).
15:	end for
16:	end for

步骤 10-12 和 步骤 13-15 中,生成器和原型网络的迭代训练分别进行。这两个网络的训练是 FedDualAlign 算法的关键,生成器负责生成数据以增强本地模型训练,原型网络则用于优化原型的表达,使得各个客户端的模型更新趋向一致性。

4.4 与现有研究的异同

在解决非独立同分布数据场景中的模型优化问题时,FedDualAlign 采用了与 FedGen 和 FedTGP 相同的生成器结构。尽管这些方法使用相似的生成器设计,FedDualAlign 的创新体现在“双生成器”策略上,结合了生成器与原型增强来处理数据偏移和特征不一致性的问题。

4.4.1 目标不同

在目标上,FedDualAlign 与现有方法相比,更加注重生成器的设计和生成样本的质量。传统的生成对抗方法,如 FedGen,主要集中在生成样本的质量和生成器与客户端模型的匹配上。然而,FedDualAlign 不仅关注生成数据的质量,还特别强调避免生成错例或负样本,以提升生成数据的可用性和多样性。通过引入匹配损失、输出差异损失和多样性损失,FedDualAlign 能够有效控制生成器输出的样本,使其在生成过程中避免模式崩溃,并确保生成的样本能够准确反映目标数据的分布,从而有效改善生成样本的可靠性。

与传统方法学习模型输入空间的方式不同,FedDualAlign 通过引导生成器探索潜在的特征空间,促进了生成样本的分布多样性。生成器通过与多个教师模型的输出对比,从而生成更具代表性和更符合全局目标分布的样本,进一步提升了全局模型的泛化能力。因此,FedDualAlign 在生成模型的设计和生成样本的质量上,较传统方法具有更为显著的优势。

在目标方面,FedDualAlign 在原型增强的基础上引入了对比损失,这一设计使得本地模型能够更加专注于学习类别间的差异,并提升其对全局特征分布的适应性。此外,FedDualAlign 在原型增强方面进行了进一步的优化,特别是在边际函数的设计上。与 FedTGP 使用固定阈值或最大距离来控制原型的分离度不同,FedDualAlign 引入了自适应边际的策略,根据原型间的曼哈顿距离动态调整边际。这种自适应边际的设计能够平滑地适应训练过程中原型间距离的变化,从而更加准确地控制原型之间的差异,避免因边际过大或过小导致的训练不稳定。

4.4.2 实现不同

在实现方面, FedDualAlign 相较于传统的联邦学习方法, 特别是在 FedTGP 的基础上, 引入了更为精细的损失函数设计, 从而增强了模型的训练效果和稳定性。首先, FedDualAlign 通过引入匹配损失、输出差异损失和多样性损失等多重损失函数, 使得生成器能够更加有效地生成高质量的样本, 避免了模式崩溃和生成错误样本的问题。这些损失函数的结合使得生成样本不仅更加符合全局目标分布, 还能够保持多样性, 从而提升了生成样本在本地客户端模型训练中的有效性。

另一个显著的实现差异是 FedDualAlign 采用的“双生成器”结构, 这一设计极大提升了模型在生成过程中的表现。双生成器结构不仅能增强生成数据的多样性, 还通过两个生成器的协同作用, 分别优化数据的生成和原型的学习。

总体来说, FedDualAlign 在实现上不仅通过精心设计的损失函数提升了模型的训练质量, 还通过“双生成器”策略进一步优化了生成数据的质量和多样性。

4.5 实验与性能评估

本节将通过实验评估 FedDualAlign 算法模型的性能, 并验证其有效性。第 4.5.1 节介绍了比较的基准测试算法, 非独立同分布数据集设置, 模型架构以及实验的细节设置; 第 4.5.2 节将 FedDualAlign 与现有的联邦方法进行了比较, 并进行了分析。最后, 本节进行了消融研究, 验证了各模块设计的必要性。

4.5.1 实验设置

基准。实验中将 FedDualAlign 与经典的联邦学习算法 FedAvg、FedProx、SCAFFOLD、MOON、FedDyn、FedLC、FedGen、FedOpt、Fedproto 和 FedFed 进行了比较。

网络架构。本研究涉及三个独立的网络结构: 分类器、生成器和原型网络。**分类器**包含两层卷积层和两层全连接层。具体结构为: 首先输入图像通过一个 5x5 卷积层 (6 个输出通道) 进行特征提取, 接着通过批归一化和 ReLU 激活函数进行处理, 再经过 2x2 最大池化层进行降维。第二层卷积层 (16 个输出通道) 同样经过批归一化、ReLU 激活和池化处理。接下来, 经过一层 Flatten 层将二维特征图展平, 进入两个全连接层, 最后通过一个全连接层输出分类结果。**生成器**采用多层感知机 (MLP) 结构。输入由噪声向量和类别信息组成, 噪声向量与类别信息通过嵌入层进行编码, 并在 MLP 中经过一系列全连接层处理。生成器的输出是一个潜在特征向量, 经过最后一层线性变换得到。该网络的主要目标是生成潜在特征, 以便后续任务使用。**原型网络**的主要结构包括一个嵌入层和两层全

连接层。嵌入层将类别映射到一个特征空间中，然后经过一个中间的全连接层进行处理，最终通过一个全连接层输出每个类别的原型特征。该网络的设计旨在为每个类别学习一个原型特征表示。

非独立同分布数据。实验使用 CIFAR-10、CIFAR-100 和 Fashion MNIST 等广泛应用于联邦学习算法研究的数据集。首先，通过狄利克雷分布来模拟分独立同分布数据，模拟现实数据中的异构性。接着，为了增强数据的特征偏移，实验对客户端之间的数据增加了数据扰动，包含随机遮挡，图片翻转，颜色抖动，高斯模糊等，进一步增强了不同客户端之间数据特征分布上的不一致性。




图 4-4 CIFAR10 数据集上不同 α 取值的狄利克雷分布下的可视化

客户端数据异构性的可视化。不同狄利克雷分布参数下客户端数据分布如图 4-4 所示，客户端的局部数据是类不平衡的，不同客户端的数据总量之间也存在差异。同样的，随着 α 值的增加，客户端数据分布差异逐渐减少，类别分布变得更加均匀。

超参数设置：实验采用的客户端数量为 100，活跃客户端比例为 0.3，意味着每轮参与的客户端数量为 30，客户端本地训练周期数为 5，通信轮次为 100，全局训练批量大小为 64，分类器学习率为 0.01，优化器采用 SGD，动量为 0.9，生成器地优化器采用 Adam，原型网络的优化器采用 SGD。考虑到 CIFAR100 数据集对于分类器学习难度较大，CIFAR100 实验提升通信轮次为 200。

4.5.2 模型性能与分析

4.5.2.1 基于 CIFAR10 数据集与前沿算法进行比较

表 4-1 FedDualAlign 和基准方法在不同非独立同分布设置的 CIFAR10 数据集上的测试准确率（%）

#setting	CIFAR-10			
	0.1	0.3	0.6	1.0
FedAvg ^[4]	51.14±1.06	55.64±1.01	60.09±0.88	62.32±0.53
FedProx ^[65]	51.16±1.02	55.74±0.81	61.69±0.51	64.33±0.32
FedGen ^[28]	53.08±2.73	57.63±1.05	66.78±0.85	67.27±0.54
MOON ^[68]	56.75±1.08	57.48±0.88	64.99±0.55	65.37±0.35
FedDyn ^[66]	60.14±2.20	62.32±1.10	58.54±0.71	62.62±0.53
SCAFFOLD ^[69]	59.59±2.38	60.33±1.25	61.73±1.33	63.43±1.02
FedLC ^[110]	57.76±1.12	59.34±0.74	67.60±0.44	69.10±0.33
FedOpt ^[67]	61.42±1.2	63.13±1.01	64.49±0.42	63.58±0.21
FedProto ^[56]	67.24±4.10	70.67±2.02	65.57±1.23	66.61±0.88
FedFed ^[32]	57.68±3.02	62.65±2.10	65.52±1.51	68.76±1.09
FedDualAlign	64.07±2.23	67.55±1.97	68.87±1.24	69.51±0.99

*其中 FedProto 作为个性化联邦学习算法进行训练和推理。

CIFAR10 测试集上模型性能。表 4-1 展示了不同算法在 CIFAR-10 数据集上的表现。从实验结果可以看出，FedDualAlign 在多个测试基准下均取得了领先性能，尤其在 CIFAR10 数据集狄利克雷分布参数为 0.3 的情况下，测试精度相比于个性化联邦学习算法 FedProto 较低，但相比第三名 FedOpt 提高了 4.42%。值得注意的是，FedDyn、MOON 和 FedOpt 等优化方法在不同设置下的表现存在波动，而 FedProto 在小数据量（0.1 和 0.3）时展现出较优的性能，但在数据量增加（0.6 和 1.0）后略有下降。相比之下，FedDualAlign 在各个数据量下均保持稳定的优势，在所有狄利克雷分布参数下取得了最高的测试精度。实验结果表明，在服务器端引入生成器进行伪数据增强，同时结合全局原型网络进行嵌入优化，是提升联邦学习在非独立同分布数据场景下性能的有效方法。

在联邦学习的训练过程中，收敛速度是衡量算法效率的重要指标。本文在图 4-5 报告了个算法模型在相同异构程度下不同通信轮次中模型的测试集准确率，

从图中可以看出, FedDualAlign 以最快的速度实现收敛, 并在各个通信轮次下始终保持领先。在初始阶段(前 20 轮次), FedDualAlign 的准确率就已经超过了其他方法, 展现出良好的优化效果。相比之下, FedAvg、MOON 和 FedGen 在前期收敛速度较慢, 需要更多轮次才能达到较高精度, 而 FedLC 和 FedFed 在部分阶段虽表现较优, 但最终仍未能超越 FedDualAlign。这一结果表明, FedDualAlign 通过生成器和全局原型网络的双重微调策略, 显著加速了模型收敛, 并有效缓解了非独立同分布数据带来的优化挑战。




图 4-5 CIFAR10 数据集上不同通信轮次各算法的准确率, $\alpha = 0.3$

4.5.2.2 基于 CIFAR100 数据集与前沿算法进行比较

CIFAR100 测试集上模型性能。表 4-2 展示了 FedDualAlign 与多个基准方法在 CIFAR-100 数据集上针对不同非独立同分布设置的测试精度结果。实验结果表明, FedDualAlign 在多个测试基准下均取得了稳定且较优的性能, 尤其在 Dirichlet 分布参数为 0.3 和 0.6 的情况下, FedDualAlign 分别取得了 32.55% 和 33.24% 的测试准确率, 相比大部分基准方法均表现更优。在对比方法中, FedProto 作为个性化联邦学习方法, 在部分设置(0.1)下取得了较高的准确率, 但在其他场景下表现不够稳定。而 FedGen 采用生成器生成伪特征进行全局对齐, MOON 通过对比学习优化本地训练, 它们在多个场景下均优于传统的 FedAvg 和 FedProx, 进一步说明生成器和对比学习策略在联邦学习中的有效性。然而, FedDualAlign 通过引入生成器和全局原型网络, 进一步优化了特征对齐和概念一致性, 使其在不同数据划分场景下均保持稳定的优势。相比之下, FedDyn

和 SCAFFOLD 在 CIFAR100 上的表现较为波动,在部分场景(0.1、0.3)下略有优势,但整体效果不如 FedDualAlign。FedLC 和 FedFed 在某些情况下能够取得接近 FedDualAlign 的精度,但在整体稳定性方面仍存在不足。

表 4-2 FedDualAlign 和基准方法在不同非独立同分布设置的 CIFAR100 数据集上的测试准确率 (%)

#setting	CIFAR-100			
	0.1	0.3	0.6	1.0
FedAvg ^[4]	24.27±3.10	28.08±2.22	29.01±1.77	30.68±1.23
FedProx ^[65]	24.66±2.52	29.65±1.91	29.09±2.22	32.12±1.17
FedGen ^[28]	30.99±3.22	31.93±2.89	32.98±1.24	33.82±0.55
MOON ^[68]	29.88±3.38	31.79±2.19	33.05±2.55	33.24±1.09
FedDyn ^[66]	25.86±4.20	28.32±3.25	28.98±2.36	32.86±2.13
SCAFFOLD ^[69]	30.28±4.01	29.47±2.25	31.98±2.53	32.98±1.10
FedLC ^[110]	27.52±2.82	31.33±2.42	32.70±1.64	31.69±1.02
FedOpt ^[67]	24.77±4.42	28.93±4.12	30.04±3.01	32.19±1.83
FedProto ^[56]	39.37±3.10	29.91±2.99	31.00±1.89	33.85±0.79
FedFed ^[32]	31.29±2.11	32.19±1.11	32.33±0.97	34.84±1.19
FedDualAlign	32.11±3.11	32.55±2.49	33.24±1.94	34.03±1.19

*其中 FedProto 作为个性化联邦学习算法进行训练和推理。




图 4-6 CIFAR100 数据集上不同通信轮次各算法的准确率, $\alpha = 0.3$

在 CIFAR100 数据集上,不同方法在联邦学习过程中的收敛速度和最终精度如图 4-6 所示。从整体趋势来看,FedDualAlign 在整个训练过程中均保持领先,并在 200 轮通信后达到最高精度,展现出较快的收敛速度和优越的泛化能力。

在初始阶段（25 轮通信以内），FedDualAlign 相较于其他方法已经展现出更快的优化趋势，而 FedAvg 和 MOON 的初始收敛速度较慢，需要更多的轮次才能提升模型性能。随着通信轮次的增加，各方法的精度逐步提高，但 FedDualAlign 在整个过程中始终领先，尤其在 100 轮通信后，优势愈加明显。这表明 FedDualAlign 结合了生成器与全局原型增强的双重微调策略，使得模型能够更快地适应非独立同分布数据，从而提升优化效率。

4.5.2.3 基于 Fashion MNIST 数据集与前沿算法进行比较

表 4-3 FedDualAlign 和基准方法在不同非独立同分布设置的 Fashion MNIST 数据集上的测试准确率（%）

#setting	Fashion MNIST			
	0.1	0.3	0.6	1.0
FedAvg ^[4]	86.57±2.01	87.43±1.98	88.02±1.47	89.75±1.14
FedProx ^[65]	89.28±3.19	89.83±2.12	88.12±1.14	90.11±0.95
FedGen ^[28]	92.22±2.76	93.57±2.19	94.01±1.54	92.57±1.13
MOON ^[68]	91.29±1.20	93.27±1.09	93.81±1.02	94.14±0.78
FedDyn ^[66]	90.03±2.10	88.99±2.55	90.78±1.65	91.01±0.91
SCAFFOLD ^[69]	93.21±3.49	94.20±1.85	89.91±0.92	92.14±1.10
FedLC ^[110]	90.29±1.97	91.23±2.10	92.04±1.73	92.93±0.89
FedOpt ^[67]	93.21±3.31	94.00±2.56	94.65±1.44	95.13±1.15
FedProto ^[56]	96.95±2.41	93.03±1.89	93.19±1.24	92.88±0.94
FedFed ^[32]	92.67±1.11	92.89±1.41	94.12±1.32	94.89±0.79
FedDualAlign	93.85±2.54	94.25±1.93	95.33±1.48	95.09±0.81

*其中 FedProto 作为个性化联邦学习算法进行训练和推理。

Fashion MNIST 测试集上模型性能。 在表 4-3 中，本文展示了 FedDualAlign 与多种基准方法在 Fashion MNIST 数据集不同非独立同分布设置下的测试精度。从实验结果来看，FedDualAlign 在所有测试基准下均展现出优异的性能，尤其在 Dirichlet 分布参数为 0.3 和 0.6 时，取得了最高的准确率，分别达到了 94.25% 和 95.33%，表明其在非独立同分布数据场景下的鲁棒性和稳定性。在对比方法中，FedFed 在大多数情况下的性能也较为稳定，在 1.0 设定下达到 94.89%，略低于 FedDualAlign，但在非独立性较强的情况下表现稍逊。此外，MOON、FedGen 和 FedFed 依靠对比学习、生成器增强和联邦优化策略，在部分参数下展现出了较高的准确率，但整体仍未能超越 FedDualAlign。从整体趋势来看，FedDualAlign 在所有数据划分情况下均保持较高的准确率，在不同的狄利克雷分布下均取得较优的精度，验证了其通过生成器和全局原型增强优化特

征对齐的策略,能够更有效地提升联邦学习模型在非独立同分布数据上的适应性和泛化能力。




图 4-7 Fashion MNIST 数据集上不同通信轮次各算法的准确率, $\alpha = 0.3$

Fashion MNIST 数据集上模型收敛速度分析。在图 4-7 中,本文比较了不同联邦学习算法在相同数据异构程度下的收敛速度。可以看出, FedDualAlign 以最快的速度收敛,并在整个训练过程中始终保持领先优势。在早期训练阶段(20 轮通信以内), FedDualAlign 的准确率已明显高于很多方法,表明其在优化初期能够快速调整全局模型,使其更快适应非独立同分布数据。相比之下, MOON、FedGen 和 FedOpt 在 40 轮通信后收敛趋势加快,但整体仍略低于 FedDualAlign。FedFed 的收敛速度相对较快,但在后期(100 轮通信)仍未能超越 FedDualAlign,表明单独的优化策略在一定程度上提升了模型性能,但仍不足以完全克服数据异构带来的挑战。

4.5.2.4 消融研究

数据异构性影响。在非独立同分布(Non-IID)数据场景下,数据异构性会对联邦学习模型的收敛速度和最终性能产生显著影响。本节在 CIFAR10、CIFAR100 和 Fashion MNIST 数据集上在不同迪利克雷浓度参数下进行了详尽的实验,如表 4-1、表 4-2 和表 4-3, FedDualAlign 在不同程度的数据异构性下均展现了较强的鲁棒性和适应能力,但仍受到一定程度的影响。然而,在同样非独立同分布数据下, FedDualAlign 模型相较于前沿算法具备较好的性能和鲁棒性。

FedDualAlign 中各组件对模型测试准确率的影响。组件消融实验在 CIFAR10 上进行, 通信轮次为 100 轮, 狄利克雷分布参数为 $\alpha = 0.3$, 并在表 4-4 中记录了去除单个模块后模型训练的测试精度。如表 4-4 所示, 完整的 FedDualAlign 模型取得了 67.55% 的测试精度, 而去除不同模块后, 模型的性能均有所下降, 表明各个组件对整体性能的贡献。在隐层特征生成器部分, 本文分别去除了不同的损失项进行实验: 去除匹配损失后, 模型精度下降至 62.19%, 表明生成器输出特征匹配客户端模型隐层特征一致性方面起到了关键作用。这一损失项通过确保生成数据的特征分布与目标标签一致, 提升了生成数据的准确度; 去除输出差异损失后, 模型精度下降至 65.48%, 说明该损失项在鼓励生成器探索多样性特征、促进高质量特征生成方面具有重要作用; 去除多样性损失后, 模型精度下降至 63.33%, 表明该项有助于提升生成数据的多样性, 防止生成器产生高度相似的特征分布, 从而增强模型的泛化能力。去除客户端生成器优化损失后, 模型精度降至 61.15%, 表明该损失项对于提升客户端模型对生成数据的适应性至关重要。去除该损失后, 客户端模型难以进行泛化特征的学习, 导致模型性能大幅下降。在原型增强对齐部分, 实验中同样去除了不同的损失项: 去除原型一致性损失后, 模型精度下降至 64.87%, 相比简单的原型平均聚合, FedDualAlign 采用边际自适应原型生成, 有效提升了模型性能。去除基于对比学习的原型优化损失后, 模型精度下降至 62.87%, 说明全局原型对于对齐客户端特征分布具有重要作用, 缺失该项会导致局部模型难以获得稳定的全局特征指导, 值得注意的是, 在去除掉此项限制后, 模型收敛速度也收到了影响, 需要更多的通信轮次才能收敛。

表 4-4 在 CIFAR10 上 FedDualAlign 各模块对测试准确率的影响 ($\alpha = 0.3$)。

	Method	Accuracy(%)
	FedDualAlign	67.55$\pm$1.97
隐层特征生成器	$-L_{match}$	62.19 $\pm$ 2.22
	$-L_{diff}$	65.48 $\pm$ 1.01
	$-L_{div}$	63.33 $\pm$ 1.76
	$-L_{client_gen}$	61.15 $\pm$ 1.28
原型网络	$-L_c^P$	64.87 $\pm$ 0.99
	$-L_p$	62.87 $\pm$ 1.16

4.6 本章小结

本章提出了一种新颖的联邦学习优化方法 **FedDualAlign**，该方法通过生成器引导特征对齐与全局原型增强的双重微调策略，针对概念偏移和特征分布倾斜的非独立同分布数据场景，提升了联邦学习模型的性能和收敛效率。首先，本文在服务器端引入了轻量级辅助生成器，用于建模分类模型的潜在特征空间，并引导客户端进行特征空间对齐，以减少客户端间的特征分布差异。针对生成器的训练，本文设计了匹配损失、输出差异损失以及增强的多样性损失，确保生成数据的可用性和多样性，同时通过在局部训练中引入特征生成器，从而提高了全局模型的泛化能力。此外，为了进一步提升收敛速度，本文引入了全局原型网络，该网络基于客户端上传的局部类原型，在服务器端进行训练，并采用自适应边际对比损失来优化类原型之间的距离，从而增强类别区分性，提高分类精度。在客户端本地训练过程中，**FedDualAlign** 引入了原型对比损失和领域重加权损失，促进同类特征的聚合，确保各客户端在训练过程中保持数据分布的协调性，进而加速全局模型的收敛。我们在多个基准数据集上进行了广泛的实验，结果表明 **FedDualAlign** 在模型收敛速度、泛化能力和特征对齐能力方面优于现有最先进的联邦学习方法。同时，**FedDualAlign** 的生成器采用无数据方式训练，仅在特征层面进行学习，进一步增强了隐私保护能力。这些实验结果验证了 **FedDualAlign** 在非独立同分布数据场景下的有效性和鲁棒性，为联邦学习在复杂分布数据上的优化提供了一种新思路。

第五章 总结与展望

5.1 总结

联邦学习作为一种新兴的分布式机器学习范式,近年来在数据隐私保护、数据量爆炸式增长以及边缘计算资源利用等需求的推动下迅速兴起。与传统集中式训练不同,联邦学习允许多个客户端在本地数据上协同训练全局模型,而无需直接共享原始数据,从而在保障用户隐私的同时有效利用了分散的数据与算力资源。这一优势使联邦学习在学术界和工业界都引起了广泛关注。然而,联邦学习面临的主要挑战是数据异构性,即不同客户端间的数据分布存在差异(非独立同分布问题)。各客户端数据的分布不一致会导致局部模型偏移,模型难以泛化全局知识,引发模型性能下降和收敛变慢等问题。特别地,标签分布倾斜和特征漂移是数据异构性的典型表现,它们对联邦学习模型的性能影响显著:前者指不同客户端的标签类别分布不均衡,后者指不同客户端的数据特征空间存在分布差异。这些异构性问题如果处理不当,将严重削弱全局模型的精度和稳定性。

基于此,本文提出并研究了两种有效的联邦学习算法: FedRef 和 FedDualAlign。FedRef 算法主要面向标签分布倾斜和数量倾斜等数据层面的非独立同分布场景。它在服务器端引入了条件变分自编码器(CVAE)生成器和知识集成蒸馏机制:通过 CVAE 生成接近全局分布的辅助样本来缓解各客户端标签分布的不均衡,并利用知识蒸馏将客户端的局部知识融合到全局模型中,从而减小由于标签不均衡导致的模型偏差。这样的设计有效地平衡了各客户端的数据贡献,加速了全局模型的收敛。FedDualAlign 算法主要针对概念偏移和特征分布倾斜等特征层面的非独立同分布场景。该方法结合轻量级生成器和全局原型网络,采取“双重对齐”的策略来优化模型:在服务器端通过生成器建模聚合模型的潜在特征空间,并下发该生成器以对齐客户端的本地特征分布;同时维护一个可训练的全局原型网络,通过原型对比学习和特征域重加权等策略增强不同客户端之间特征表示的一致性。通过这种方式, FedDualAlign 在保证隐私的前提下有效消除了客户端特征空间的不一致,显著提升了全局模型在异构特征分布下的泛化能力。实验结果表明,这两种算法在非独立同分布数据环境中均表现出优越的性能:与现有的联邦学习基准方法相比, FedRef 和 FedDualAlign 无论在模型准确率还是收敛速度方面都取得了更好的效果。其中, FedRef 显著降低了全局模型所需的通信轮次并增强了模型对不均衡数据的适应能力; FedDualAlign 则有效提高了模型

在不同特征域下的稳健性和精度。综合来看，本文所提出的算法成功缓解了联邦学习中的数据异构性难题，在保护数据隐私的同时提升了全局模型的性能和训练效率。

具体而言，FedRef 在 CIFAR-10 和 CIFAR-100 数据集的非独立同分布设置下展现出显著优势。例如在 CIFAR-10 中，当 Dirichlet 分布参数 $\alpha = 0.3$ 时，FedRef 的测试准确率达到 86.21%，比当前最优基线方法 FedFTG 高出 1.83 个百分点。同时，在达到 80% 准确率目标所需的通信轮数上，FedRef 仅需 178 轮，远低于 FedAvg 的 416 轮和 FedProx 的 386 轮，表明其具有更高的收敛效率。在 CIFAR-100 更具挑战性的设置下，FedRef 在 $\alpha = 0.3$ 时仍取得了 56.83% 的准确率，相较于 FedFTG 提升 0.87 个百分点，进一步验证其对标签分布倾斜的适应性。

FedDualAlign 在处理特征空间异构性方面也同样表现出色。在 CIFAR-10 数据集上，FedDualAlign 在 $\alpha = 0.3$ 时实现了 67.55% 的准确率，超过多数对比方法，包括 FedLC (59.34%) 和 MOON (57.48%)。而在 CIFAR-100 数据集的多个非独立同分布设定下，FedDualAlign 的准确率均优于 FedOpt、FedLC 和 FedFed 等主流方法，体现出其高维细粒度分类任务中的稳定性与优势。在 Fashion MNIST 的 $\alpha = 0.3$ 异构设置下，FedDualAlign 仍取得 94.25% 的准确率，领先于所有对比方法，进一步验证了其在类不平衡和异构环境下的强泛化能力。。

更进一步地，FedRef 与 SCAFFOLD、FedDyn 等优化方法结合后，准确率和收敛速度均有大幅提升。例如在 CIFAR-10 上，SCAFFOLD+FedRef 在 $\alpha = 0.3$ 时准确率达到 86.21%，通信轮数降低至 178 轮，显著优于单独使用 SCAFFOLD (221 轮) 时的性能表现，充分展示了 FedRef 作为模块化增强机制的正交性和广泛适配性。

此外，本文较为全面地整理了采用生成模型的联邦学习最新研究进展，以及部分联邦优化算法和联邦知识蒸馏方面的探索。通过对比分析不同方法在数据生成、知识蒸馏以及模型聚合方面的优势与不足，本文不仅为解决非独立同分布数据问题提供了新的思路，也为后续相关研究指明了方向。

由于本人水平有限，尽管已反复认真校对，文中仍可能存在不足之处，恳请各位专家批评指正。

5.2 展望

尽管本文围绕非独立同分布数据下联邦学习的若干关键问题进行了探索并取得了有益的成果，但联邦学习领域仍有许多方向值得进一步研究和拓展。

首先，本文主要采用了有中心服务器的集中式联邦学习框架，但在实际应用中，许多场景下参与方的网络拓扑是动态或点对点的，可能并不存在固定的中心服务器。针对这种分散式联邦学习，未来需要探索更加鲁棒的模型更新和通信机制，使联邦学习即使在节点随机加入退出或对等通信的情况下仍能稳定收敛。

其次，本文的研究主要在单一模态下展开，未来的工作可拓展到多模态联邦学习，即在保护隐私的前提下，实现不同类型数据的联合训练。通过融合多模态信息，联邦学习有望在更广泛、更复杂的数据场景中发挥更大的作用。

最后，本文采用了生成器辅助的特征对齐策略，以增强不同客户端间模型内部表示的一致性。然而，这种方法在实际应用中可能受限于生成器的建模能力，当在辛普森悖论场景中时^[111]，需要针对生成器进行进一步优化。未来的研究可以考虑结合更丰富的数据分布信息或利用模型更新的历史轨迹来改进隐藏层特征的一致性约束，也可以尝试结合数据和特征两个层面的算法融合。

综上所述，联邦学习作为解决数据隐私和分布式训练需求的重要技术，虽然在本文的研究中取得了一定进展，但仍有大量前沿课题亟待深入。未来的工作将继续拓展和完善联邦学习的理论与方法，使其能够更好地应对数据和模型的异构性挑战，在更广泛的应用场景中发挥更大的价值。

参考文献

- [1] Dong S, Wang P, Abbas K. A survey on deep learning and its applications[J]. Computer Science Review, 2021, 40: 100379.
- [2] Jordan M I, Mitchell T M. Machine learning: Trends, perspectives, and prospects[J]. Science, 2015, 349(6245): 255-260.
- [3] Kotsiantis S B, Zaharakis I D, Pintelas P E. Machine learning: a review of classification and combining techniques[J]. Artificial Intelligence Review, 2006, 26: 159-190.
- [4] McMahan B, Moore E, Ramage D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017: 1273-1282.
- [5] Fantauzzo L, Fanì E, Caldarola D, et al. Feddrive: Generalizing federated learning to semantic segmentation in autonomous driving[C]//2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2022: 11504-11511.
- [6] Miao J, Yang Z, Fan L, et al. FedSeg: Class-Heterogeneous Federated Learning for Semantic Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 8042-8052.
- [7] Lu D, Weng Q. A survey of image classification methods and techniques for improving classification performance[J]. International journal of Remote sensing, 2007, 28(5): 823-870.
- [8] 杨强.AI与数据隐私保护：联邦学习的破解之道[J].信息安全研究,2019,5(11):961-965.
- [9] Zhao Y, Li M, Lai L, et al. Federated learning with non-iid data[J]. arXiv preprint arXiv:1806.00582, 2018.
- [10] Zhu H, Xu J, Liu S, et al. Federated learning on non-IID data: A survey[J]. Neurocomputing, 2021, 465: 371-390.
- [11] Kairouz P, McMahan H B, Avent B, et al. Advances and open problems in federated learning[J]. Foundations and Trends® in Machine Learning, 2021, 14(1-2): 1-210.
- [12] Xu J, Wang H. Client selection and bandwidth allocation in wireless federated learning networks: A long-term perspective[J]. IEEE Transactions on Wireless Communications, 2020, 20(2): 1188-1200.
- [13] Chen M, Shlezinger N, Poor H V, et al. Communication-efficient federated learning[J]. Proceedings of the National Academy of Sciences, 2021, 118(17): e2024789118.
- [14] Li Y, Wang X, Zeng R, et al. Federated Knowledge Alignment: A Federated Learning Approach to Domain Generalization[J]. IEEE Transactions on Knowledge and Data Engineering, 2023.
- [15] Zhang L, Lei X, Shi Y, et al. Federated Adversarial Domain Generalization Network: A Novel Federated Learning Approach for Domain Generalization with Data Privacy[J]. IEEE Transactions on Knowledge and Data Engineering, 2022.
- [16] Wu G, Zhang Z, Liu H, et al. Federated Open-set Domain Adaptation: A Cross-Client Collaborative Framework for Domain Generalization[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023.

- [17] Zhou K, Yang Y, Qiao Y, et al. Mixstyle: A Cross-Domain Learning Approach for Domain Generalization in Federated Learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV), 2021.
- [18] Zhang Z, Liu X, He H, et al. Federated Adversarial Domain Hallucination: A Privacy-Preserving Method for Domain Generalization in Federated Learning[J]. IEEE Transactions on Multimedia, 2023.
- [19] Xu G, Li H, Liu S, et al. Verifynet: Secure and verifiable federated learning[J]. IEEE Transactions on Information Forensics and Security, 2019, 15: 911-926.
- [20] Bhagoji A N, Chakraborty S, Mittal P, et al. Analyzing federated learning through an adversarial lens[C]//International Conference on Machine Learning. PMLR, 2019: 634-643.
- [21] Ma C, Li J, Ding M, et al. On safeguarding privacy and security in the framework of federated learning[J]. IEEE network, 2020, 34(4): 242-248.
- [22] Zhu L, Liu Z, Han S. Deep leakage from gradients[J]. Advances in neural information processing systems, 2019, 32.
- [23] Wen H, Wu Y, Li J, et al. Transferring Inter-Class Correlation for Teacher-Student frameworks with flexible models[J]. Knowledge-Based Systems, 2022, 242: 108316.
- [24] Alistarh D, Grubic D, Li J, et al. QSGD: Communication-efficient SGD via gradient quantization and encoding[J]. Advances in neural information processing systems, 2017, 30.
- [25] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. arXiv preprint arXiv:1503.02531, 2015.
- [26] Gou J, Sun L, Yu B, et al. Multilevel Attention-Based Sample Correlations for Knowledge Distillation[J]. IEEE Transactions on Industrial Informatics, 2022, 19(5): 7099-7109.
- [27] Kang J, Gwak J. Ensemble learning of lightweight deep learning models using knowledge distillation for image classification[J]. Mathematics, 2020, 8(10): 1652.
- [28] Zhu Z, Hong J, Zhou J. Data-free knowledge distillation for heterogeneous federated learning[C]//International conference on machine learning. PMLR, 2021: 12878-12889.
- [29] Zhang L, Shen L, Ding L, et al. Fine-tuning global model via data-free knowledge distillation for non-iid federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10174-10183.
- [30] Wang S, Fu Y, Li X, et al. DFRD: Data-Free Robustness Distillation for Heterogeneous Federated Learning[J]. Advances in Neural Information Processing Systems, 2024, 36.
- [31] Heinbaugh C E, Luz-Ricca E, Shao H. Data-free one-shot federated learning under very high statistical heterogeneity[C]//The Eleventh International Conference on Learning Representations. 2023.
- [32] Yang Z, Zhang Y, Zheng Y, et al. FedFed: Feature distillation against data heterogeneity in federated learning[J]. Advances in Neural Information Processing Systems, 2024, 36.
- [33] Dai, R., Zhang, Y., Li, A., et al. (2024). Enhancing one-shot federated learning through data and ensemble co-boosting. *Proceedings of the 2024 International Conference on Learning Representations (ICLR)*, Poster.
- [34] Luo, K., Wang, S., Fu, Y., et al. (2024). DFDG: Data-free dual-generator adversarial distillation for one-shot federated learning. *Proceedings of the 2024 IEEE International Conference on Data Mining (ICDM)*.

- [35] Zhang J, Chen C, Li B, et al. Dense: Data-free one-shot federated learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 21414-21428.
- [36] Li D, Wang J. Fedmd: Heterogenous federated learning via model distillation[J]. arXiv preprint arXiv:1910.03581, 2019.
- [37] Lin T, Kong L, Stich S U, et al. Ensemble distillation for robust model fusion in federated learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 2351-2363.
- [38] Wang Z, She Q, Ward T E. Generative adversarial networks in computer vision: A survey and taxonomy[J]. ACM Computing Surveys (CSUR), 2021, 54(2): 1-38.
- [39] Wang L, Ma C, Feng X, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6): 186345.
- [40] Zhang S, Yao L, Sun A, et al. Deep learning based recommender system: A survey and new perspectives[J]. ACM computing surveys (CSUR), 2019, 52(1): 1-38.
- [41] Liu B, Lv N, Guo Y, et al. Recent advances on federated learning: A systematic survey[J]. Neurocomputing, 2024: 128019.
- [42] Deng Y, Lyu F, Ren J, et al. Fair: Quality-aware federated learning with precise user incentive and model aggregation[C]//IEEE INFOCOM 2021-IEEE Conference on Computer Communications. IEEE, 2021: 1-10.
- [43] Ma X, Zhang J, Guo S, et al. Layer-wised model aggregation for personalized federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10092-10101.
- [44] Wang M, Bodonheli A, Bozkir E, et al. TurboSVM-FL: Boosting Federated Learning through SVM Aggregation for Lazy Clients[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(14): 15546-15554.
- [45] Feng C M, Yu K, Liu N, et al. Towards instance-adaptive inference for federated learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 23287-23296.
- [46] Fan B, Wu C, Su X, et al. Fedtsa: A cluster-based two-stage aggregation method for model-heterogeneous federated learning[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 370-389.
- [47] Jeong E, Oh S, Kim H, et al. Communication-efficient on-device machine learning: Federated distillation and augmentation under non-iid private data[J]. arXiv preprint arXiv:1811.11479, 2018.
- [48] Gong X, Sharma A, Karanam S, et al. Ensemble attention distillation for privacy-preserving federated learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 15076-15086.
- [49] Sattler F, Korjakow T, Rischke R, et al. Fedaux: Leveraging unlabeled auxiliary data in federated learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021.
- [50] Arivazhagan M G, Aggarwal V, Singh A K, et al. Federated learning with personalization layers[J]. arXiv preprint arXiv:1912.00818, 2019.
- [51] Li T, Hu S, Beirami A, et al. Ditto: Fair and robust federated learning through personalization[C]//International conference on machine learning. PMLR, 2021: 6357-6368.

- [52] Collins L, Hassani H, Mokhtari A, et al. Exploiting shared representations for personalized federated learning[C]//International conference on machine learning. PMLR, 2021: 2089-2099.
- [53] Chen H Y, Chao W L. On bridging generic and personalized federated learning for image classification[J]. arXiv preprint arXiv:2107.00778, 2021.
- [54] Zhang J, Hua Y, Wang H, et al. Fedcp: Separating feature information for personalized federated learning via conditional policy[C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. 2023: 3249-3261.
- [55] Yang X, Huang W, Ye M. FedAS: Bridging Inconsistency in Personalized Federated Learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 11986-11995.
- [56] Tan Y, Long G, Liu L, et al. Fedproto: Federated prototype learning across heterogeneous clients[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2022, 36(8): 8432-8440.
- [57] Tan Y, Long G, Ma J, et al. Federated learning from pre-trained models: A contrastive learning approach[J]. Advances in neural information processing systems, 2022, 35: 19332-19344.
- [58] Kim H, Kwak Y, Jung M, et al. Protofl: Unsupervised federated learning via prototypical distillation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6470-6479.
- [59] Zhang J, Liu Y, Hua Y, et al. Fedtgp: Trainable global prototypes with adaptive-margin-enhanced contrastive learning for data and model heterogeneity in federated learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(15): 16768-16776.
- [60] Shi J, Zheng S, Yin X, et al. Clip-guided federated learning on heterogeneity and long-tailed data[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(13): 14955-14963.
- [61] Cheng S L, Yeh C Y, Chen T A, et al. Fedgcr: Achieving performance and fairness for federated learning with distinct client types via group customization and reweighting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(10): 11498-11506.
- [62] Tang M, Ning X, Wang Y, et al. FedCor: Correlation-based active client selection strategy for heterogeneous federated learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10102-10111.
- [63] Xu J, Chen Z, Quek T Q S, et al. Fedcorr: Multi-stage federated learning for label noise correction[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10184-10193.
- [64] Nguyen A T, Torr P, Lim S N. Fedsr: A simple and effective domain generalization method for federated learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 38831-38843.
- [65] Li T, Sahu A K, Zaheer M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine learning and systems, 2020, 2: 429-450.
- [66] Acar D A E, Zhao Y, Navarro R M, et al. Federated learning based on dynamic regularization[J]. arXiv preprint arXiv:2111.04263, 2021.

- [67] Reddi S, Charles Z, Zaheer M, et al. Adaptive federated optimization[J]. arXiv preprint arXiv:2003.00295, 2020.
- [68] Li Q, He B, Song D. Model-contrastive federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 10713-10722.
- [69] Karimireddy S P, Kale S, Mohri M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]//International conference on machine learning. PMLR, 2020: 5132-5143.
- [70] Chen D, Hu J, Tan V J, et al. Elastic aggregation for federated optimization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 12187-12197.
- [71] Chang H, Shejwalkar V, Shokri R, et al. Cronus: Robust and heterogeneous collaborative learning with black-box knowledge transfer[J]. arXiv preprint arXiv:1912.11279, 2019.
- [72] Qi P, Zhou X, Ding Y, et al. Fedbkd: Heterogenous federated learning via bidirectional knowledge distillation for modulation classification in iot-edge system[J]. IEEE Journal of Selected Topics in Signal Processing, 2022, 17(1): 189-204.
- [73] Kang H, Cha S, Kang J. GeFL: Model-Agnostic Federated Learning with Generative Models[J]. arXiv preprint arXiv:2412.18460, 2024.
- [74] Li Q, He B, Song D. Practical one-shot federated learning for cross-silo setting[J]. arXiv preprint arXiv:2010.01017, 2020.
- [75] Yang M, Su S, Li B, et al. Exploring One-Shot Semi-supervised Federated Learning with Pre-trained Diffusion Models[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2024, 38(15): 16325-16333.
- [76] Chen H, Zhu T, Zhou W, et al. AFed: Algorithmic Fair Federated Learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2025.
- [77] Krämer K. AI & robotics briefing: The year machines will run out of data[J]. Nature, 2024.
- [78] Nguyen D C, Ding M, Pathirana P N, et al. Federated learning for internet of things: A comprehensive survey[J]. IEEE Communications Surveys & Tutorials, 2021, 23(3): 1622-1658.
- [79] Li X, Huang K, Yang W, et al. On the convergence of fedavg on non-iid data[J]. arXiv preprint arXiv:1907.02189, 2019.
- [80] Hinton G E, Zemel R. Autoencoders, minimum description length and Helmholtz free energy[J]. Advances in neural information processing systems, 1993, 6.
- [81] Kingma D P, Welling M. Auto-encoding variational bayes[EB/OL].(2013-12-20)
- [82] Nayak A A, Venugopala P S, Ashwini B. A Systematic Review on Generative Adversarial Network (GAN): Challenges and Future Directions[J]. Archives of Computational Methods in Engineering, 2024: 1-34.
- [83] Mirza M, Osindero S. Conditional generative adversarial nets[J]. arXiv preprint arXiv:1411.1784, 2014.
- [84] Kingma D P, Dhariwal P. Glow: Generative flow with invertible 1x1 convolutions[J]. Advances in neural information processing systems, 2018, 31.
- [85] Cao H, Tan C, Gao Z, et al. A survey on generative diffusion models[J]. IEEE Transactions on Knowledge and Data Engineering, 2024.
- [86] Tian K, Jiang Y, Yuan Z, et al. Visual autoregressive modeling: Scalable image generation via next-scale prediction[J]. Advances in neural information processing systems, 2025, 37: 84839-84865.

- [87] Arjovsky M, Chintala S, Bottou L. Wasserstein generative adversarial networks[C]//International conference on machine learning. PMLR, 2017: 214-223.
- [88] 周勤, 范永胜, 桑彬彬, 等. 基于双路径投影层和注意力机制的知识蒸馏[J]. *Application Research of Computers*/Jisuanji Yingyong Yanjiu, 2025, 42(2).
- [89] Chen H, Frikha A, Krompass D, et al. FRAug: Tackling federated learning with Non-IID features via representation augmentation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 4849-4859.
- [90] Wen H, Wu Y, Li J, et al. Communication-efficient federated data augmentation on non-iid data[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 3377-3386.
- [91] Shang X, Lu Y, Cheung Y, et al. Fedic: Federated learning on non-iid and long-tailed data via calibrated distillation[C]//2022 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2022: 1-6.
- [92] Dietterich T G. Ensemble methods in machine learning[C]//International workshop on multiple classifier systems. Berlin, Heidelberg: Springer Berlin Heidelberg, 2000: 1-15.
- [93] Sohn K, Lee H, Yan X. Learning structured output representation using deep conditional generative models[J]. *Advances in neural information processing systems*, 2015, 28.
- [94] Thabtah F, Hammoud S, Kamalov F, et al. Data imbalance in classification: Experimental evaluation[J]. *Information Sciences*, 2020, 513: 429-441.
- [95] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [96] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.
- [97] Gao L, Fu H, Li L, et al. Feddc: Federated learning with non-iid data via local drift decoupling and correction[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10112-10121.
- [98] Li H, Cai Z, Wang J, et al. Fedtp: Federated learning by transformer personalization[J]. *IEEE transactions on neural networks and learning systems*, 2023.
- [99] Šajina R, Tanković N, Ipšić I. Peer-to-peer deep learning with non-IID data[J]. *Expert systems with applications*, 2023, 214: 119159.
- [100] Li Y, Wang X, Zeng R, et al. Federated domain generalization: A survey[J]. *arXiv preprint arXiv:2306.01334*, 2023.
- [101] Shao R, Lan X, Li J, et al. Multi-adversarial discriminative deep domain generalization for face presentation attack detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 10023-10031.
- [102] Yoon C, Hamarneh G, Garbi R. Generalizable feature learning in the presence of data bias and domain class imbalance with application to skin lesion classification[C]//Medical Image Computing and Computer Assisted Intervention—MICCAI 2019: 22nd International Conference, Shenzhen, China, October 13–17, 2019, Proceedings, Part IV 22. Springer International Publishing, 2019: 365-373.

- [103]Zhang R, Xu Q, Yao J, et al. Federated domain generalization with generalization adjustment[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 3954-3963.
- [104]Zhang K, Sato Y. Semantic image segmentation by dynamic discriminative prototypes[J]. IEEE Transactions on Multimedia, 2023, 26: 737-749.
- [105]Xu W, Xian Y, Wang J, et al. Attribute prototype network for zero-shot learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 21969-21980.
- [106]Zhang J, Liu S, Wang X. One-shot federated learning via synthetic distiller-distillate communication[J]. arXiv preprint arXiv:2412.05186, 2024.
- [107]Le H Q, Tun Y L, Qiao Y, et al. Mitigating Domain Shift in Federated Learning via Intra-and Inter-Domain Prototypes[J]. arXiv preprint arXiv:2501.08521, 2025.
- [108]Huang W, Ye M, Shi Z, et al. Rethinking federated learning with domain shift: A prototype view[C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). IEEE, 2023: 16312-16322.
- [109]Luo M, Chen F, Hu D, et al. No fear of heterogeneity: Classifier calibration for federated learning with non-iid data[J]. Advances in Neural Information Processing Systems, 2021, 34: 5972-5984.
- [110]Zhang J, Li Z, Li B, et al. Federated learning with label distribution skew via logits calibration[C]//International Conference on Machine Learning. PMLR, 2022: 26311-26329.
- [111]Jiang Z, Xu J, Zhang S, et al. FedCFA: Alleviating Simpson's Paradox in Model Aggregation with Counterfactual Federated Learning[J]. arXiv preprint arXiv:2412.18904, 2024.
- [112]Yang F E, Wang C Y, Wang Y C F. Efficient model personalization in federated learning via client-specific prompt generation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 19159-19168.