



廣東工業大學
GUANGDONG UNIVERSITY OF TECHNOLOGY

硕士学位论文


面对非独立同分布的联邦 学习聚合优化研究

作者姓名：朱桁颖

导师姓名：刘海林

学科（专业）或领域名称：数学

论文答辩年月：2025年5月21日



中图分类号:

学校代号: 11845

UDC:

密级:

学 号: 2112214047

广东工业大学硕士学位论文

(理学硕士)

面对非独立同分布的联邦学习聚合优化研究

朱桁颖

指导教师姓名、职称: 刘海林 教授

学科(专业)或领域名称: 数学

学生所属学院: 数学与统计学院

答辩委员会主席: 姚正安 教授

论文答辩日期: 2025 年 5 月 21 日

A Dissertation Submitted to Guangdong University of Technology
in Partial Fulfillment of the Requirement
for the Degree of Master of Science

Research on Aggregation Optimization for Federated
Learning with Non-IID Data Distribution

Candidate: ZHU Hengying

Supervisor: LIU Hailin

May 21, 2025

School of Mathematics and Statistics
Guangdong University of Technology
Guangzhou, Guangdong, P. R. China, 510520

摘要

近年来,随着人们对数据安全和数据隐私的重视,获得海量优质数据以驱动发展机器学习技术变得十分困难。而联邦学习是一种只在本地训练模型,不必上传本地数据的机器学习范式,在不泄露本地隐私和获得高质量神经网络模型两个诉求中获得了平衡。但是联邦学习在现实场景中存在着一系列的挑战,例如非独立同分布数据挑战等,这些挑战会导致联邦学习训练的模型性能下降、收敛速度降低的情况出现。

为了解决上述问题,本文在联邦学习的聚合阶段提出了一种基于客户端梯度自适应调整聚合学习率的策略(Fedalr)。该算法通过计算客户端上传的梯度与全局梯度的差距来获得对应聚合时的学习率,从而控制聚合梯度方向尽可能靠近全局梯度方向,目的是提高了联邦学习的收敛速度和全局模型性能。特别的,在该算法中,估算全局梯度十分重要,于是我们采用了动量的思想,使得估算出来的全局梯度减少震荡,更加稳定,从而可以更好地指导聚合梯度方向。在理论层面我们证明了算法的收敛性。另外通过不同种类统计异质性数据的仿真实验,证明了该算法比起当前基准算法性能更优秀,性能最多优化提升了30.74%。另外,针对非独立同分布数据挑战还会导致模型在本地客户端的性能有差异的不公平情况出现,本文提出了FedBEF算法。该算法目的是在保证全局模型性能的基础上,尽可能保证各客户端性能。该算法首先通过在聚合前将相似的客户端进行合并以保证聚合模型不会偏向,然后本文通过将联邦学习损失函数的收敛性上界和联邦学习更新过程相结合,为聚合权重设定了目标,通过计算聚合权重来控制模型以提高模型性能和收敛效率。最后在理论上,我们证明了FedBEF的收敛性;在实验上,我们证明了FedBEF算法是一种兼顾效率与公平的联邦聚合算法。通过消融实验,证明了聚合前的机制与计算出来的聚合权重并不冲突。

综上,本文工作围绕联邦学习受到的非独立同分布挑战,针对联邦学习的聚合阶段进行优化并提出了两种优化策略。这项工作通过理论推导来解决非独立同分布设置中的性能下降和公平性问题,推动了联邦学习的发展,为实际的联邦学习系统提供了切实可行的解决方案。

关键词: 联邦学习; 非独立同分布; 统计异质性; 分布式学习

ABSTRACT

In recent years, growing concerns over data security and privacy have made it challenging to acquire vast amounts of high-quality data for driving advancements in machine learning. Federated learning (FL), a paradigm that enables local model training without sharing raw data, balances the need to preserve local data privacy with the pursuit of high-quality neural network models. However, real-world FL scenarios face critical challenges, such as non-independent and identically distributed (non-IID) data, which degrade model performance and slow convergence.

To address these issues, this thesis proposes Fedalr, a client gradient-based adaptive learning rate adjustment strategy for the FL aggregation phase. Fedalr dynamically adjusts aggregation learning rates by measuring the discrepancy between client-uploaded gradients and the global gradient, thereby aligning aggregated gradient directions with the global trajectory to enhance convergence speed and model performance. Notably, we employ momentum to estimate a stable and oscillation-reduced global gradient, ensuring reliable guidance for aggregation. Theoretical analysis proves the algorithm's convergence. Experiments on diverse non-IID datasets demonstrate that Fedalr outperforms baseline methods, achieving up to 30.74% improvement in performance. Furthermore, to mitigate the unfair performance disparities across clients caused by non-IID data, we propose FedBEF, a fairness-aware aggregation algorithm. FedBEF ensures balanced client performance while maintaining global model efficacy. It clusters clients with similar data distributions before aggregation to prevent bias and optimizes aggregation weights by integrating convergence upper bounds of FL loss functions with the update process. Theoretical convergence guarantees are provided. Empirical results validate that FedBEF achieves a robust balance between efficiency and fairness.

In summary, this thesis focuses on the non-independent and identically distributed (non-IID) challenge faced by federated learning and optimizes the aggregation stage of federated learning, proposing two optimization strategies. This work advances FL by addressing both performance degradation and fairness issues in non-IID settings, offering practical solutions for real-world federated learning systems.

Key words: Federated learning; Non-Independent and Identically Distributed; Statistical heterogeneity; Distributed learning

目 录

第一章 绪论.....	1
1.1 本课题研究背景及研究意义	1
1.2 国内外相关研究现状.....	2
1.2.1 基于客户端优化方法.....	2
1.2.2 基于服务器优化方法.....	3
1.3 主要研究内容.....	4
1.4 论文结构安排.....	5
第二章 相关背景以及知识	7
2.1 联邦学习概述.....	7
2.1.1 联邦学习的更新过程.....	8
2.2 非独立同分布数据概述.....	9
2.2.1 非独立同分布数据对联邦学习的冲击	10
2.3 本章小结.....	11
第三章 基于客户端梯度自适应学习率聚合的联邦学习算法	12
3.1 引言.....	12
3.2 问题设置.....	12
3.3 提出的 Fedalr 算法	12
3.3.1 联邦学习全局损失函数上界的优化探讨	12
3.3.2 Fedalr 算法框架	14
3.4 Fedalr 算法收敛性分析	15
3.5 实验评估.....	19
3.5.1 实验设置.....	19
3.5.2 算法性能比较.....	20
3.5.3 不同实验参数对联邦算法的影响.....	22
3.5.4 设备 epoch 参数异质性对联邦算法的影响	24
3.6 本章小结.....	26
第四章 基于兼顾性能与公平的联邦学习：FedBEF	27
4.1 引言.....	27
4.2 问题设置和场景描述.....	28
4.2.1 目标函数介绍.....	28
4.2.2 非独立同分布数据对联邦学习的影响	30
4.3 提出的算法.....	31
4.3.1 聚合前的优化.....	31
4.3.2 全局目标函数转换与分解.....	33

4.3.3 FedBEF 算法介绍	34
4.3.4 FedBEF 算法收敛性分析	36
4.4 实验部分	38
4.4.1 实验设置	38
4.4.2 算法性能评估	39
4.4.3 不同算法的公平性比较	41
4.4.4 消融实验	44
4.4.5 与不同优化部分的算法性能比较	45
4.5 本章小结	45
第五章 结论与展望	47
参考文献	49

第一章 绪论

1.1 本课题研究背景及研究意义

数据作为机器学习系统的“信息燃料”，其规模、质量与分布特性直接决定模型的表征能力与泛化性能，Vapnik-Chervonenkis 理论证明，模型泛化误差上界与训练数据量呈负相关^[1]。当前随着电脑、手机等边缘计算设备的大量普及和使用，海量的边缘数据被产生，带动了机器学习领域的发展，进而促进了人工智能技术的进步^[2, 3]。例如当前比较火热的计算机视觉、语言识别、自然语言处理、大模型等等人工智能应用技术得到不断优化以及改进，这些技术无一不是以数据为驱动进行发展的^[4]。机器学习技术通常通过对海量数据进行处理分析，将数据中的特征进行凝练提取，发掘数据中宝贵的信息和价值，之后运用在机器学习的模型训练中^[5-7]。这种生成的优秀模型可以进一步的发挥在实际应用中，为未来的技术革新和科技进步带来方向与灵感，进而产生更多的更有用的优秀数据，从而反哺人工智能技术^[8]。因此，人工智能和现实应用技术是通过数据为纽带相互促进相互影响的。

但是在现实环境下，能够得到优质海量数据的机会是很稀少的。一方面，数据供给侧存在结构性矛盾，业务场景的数据稀疏性和数据治理成本的经济约束都导致优质数据量积累受到阻碍。具体来说垂直领域（如高端装备制造、罕见病诊疗）^[9, 10] 受限于低频事件特性，天然缺乏大规模数据生成机制。例如航空发动机故障检测，单台设备年均故障次数不足 0.1 次，导致故障样本累积速率远低于深度学习需求阈值。另外高质量数据标注成本呈现超线性增长，医学影像标注费用高达 \$5-10/张，导致 80% 以上中小机构难以构建合规标注流水线^[11]。与此同时，数据泄露事件的频频发生，导致人们越来越重视隐私。伴随着大量隐私保护的法律出台^[12]，例如跨境数据流动受《网络安全法》限制^[13, 14]，导致数据逐渐“孤岛”化。这些现实因素形成“数据荒漠化-算法退化-场景收缩”的负向循环：数据受限迫使模型简化假设空间，而简化模型又无法充分挖掘有限数据价值，最终导致技术应用范围收窄^[15]。

基于上述的种种限制，一种不需要上传数据或者数据交流的机器学习新范式：联邦学习于 2016 年被 McMahan 等人第一次提出^[16]。该方法是基于边缘计算的框架，结构可以分为两部分：大量存放着隐私数据的客户端以及一个中央服务器。它的工作过程如下：中央服务器广播全局模型给每一个客户端，被选中参与聚合的客户端根据本

地数据对模型进行训练，训练完毕后返回模型给中央服务器，中央服务器采用模型聚合技术对各个客户端上传的本地模型进行聚合生成新的全局模型，然后开始新一轮下发模型进行训练。在这个过程中，参与的客户端不需要分享任何个人的隐私数据，同时可以推进全局模型的训练，这在保护用户的数据隐私前提下尽可能缓解“数据孤岛”问题，在隐私保护与效率之间达成了平衡^[17]。

虽然联邦学习能有效地缓解“数据孤岛”问题同时保护用户们的数据隐私，但是联邦学习的系统模式也面临着一定的缺陷和挑战^[18]。例如系统异质性挑战，具体来说在现实应用环境下，因为不同客户端网络传输时延、存储空间、内存、算力、活跃程度等，用户之间的硬件条件存在较大差异，导致本地训练不完全、或者模型信息上传缺失等问题出现，这些原因都会影响联邦学习的模型性能、通信效率、收敛性等^[19]。

除此之外，联邦学习客户端数据的非独立同分布问题也是热门挑战之一^[17, 18]。在联邦学习系统中，在现实环境下不同的客户端极大部分拥有不同的数据特征和数据分布，甚至数据量也有很大的差异，这种现象被称之为数据异构性。数据异构性导致的客户端分布不一致，当某些客户端被抽取来进行聚合，由于这些客户端的数据分布难以代表其他被代表的客户端，聚合产生的全局模型会产生性能下降，收敛速度下降等问题。这使得在现实应用中联邦学习产生一个性能优秀的模型变得困难^[20, 21]。因此，在非独立同分布数据的条件下，如何产生一个能够在不同客户端中仍能保持性能优秀的、高效的全局模型的联邦学习算法研究方向是有一定的现实意义和应用价值的。

1.2 国内外相关研究现状

由于现实生活中，联邦学习的各个客户端数据很大概率是非独立同分布的，这些数据产生的模型会阻碍全局模型的收敛速度，使全局模型的性能降低。因此面对这类挑战，国内外已经开始有各类研究，在理论上的研究已经有了相当的规模例如^[22]证明了联邦学习在非独立同分布下全设备参与以及部分设备参与的收敛性、^[23]研究了联邦极小极大问题（如 GANs）的收敛性。接下来将各种优化策略根据联邦学习的结构按照基于客户端的优化方法和基于服务器的优化方法进行介绍。

1.2.1 基于客户端优化方法

由于客户端数据的非独立同分布性，因此客户端在训练本地模型时会与真正的全局模型产生偏差，这种现象称之为客户端漂移^[24]。为了降低客户端漂移的影响，研究

人员提出了通过局部校正机制来减少客户端在本地更新时偏移的策略。例如 FedProx 算法核心创新在于引入近端正则化项 (Proximal Term) 以约束客户端本地更新, 有效缓解因数据分布偏移导致的模型发散问题^[25]。而 SCAFFOLD 通过引入控制变量方法对全局模型更新方向和本地模型更新方向的差距进行估计, 从而修正客户端本地更新的偏差, 显著提升收敛效率^[26]。在这些基础上, FedAvgM 算法通过在聚合时候加入了动量机制, 使得全局模型更新更加平稳, 减少了震荡^[27]。而 MOON 通过利用本地损失函数增加了对比函数来获得全局模型与本地模型的表征差异, 从而约束本地训练方向, 显著提升模型收敛性和泛化性能^[28]。

除了通过添加正则项这种策略外, 相似数据的客户端之间进行聚类的策略近年来也十分火热。具体来说该策略是将数据分布或者模型特征相似的客户端分为同一类, 目的是产生一个统一的数据环境, 以提升全局的收敛速度^[29-31]。例如 CFL(Clustered Federated Learning) 算法将相似数据分布的客户端分组, 每组独立训练子模型, 从而避免全局模型因分布冲突导致的性能退化^[32]。然而, 该方法受到聚类数量的影响很大, 聚类数量设置不当将会影响算法的性能效果。^[33] 实验结果表明, 选择聚类数合理与否对模型的表现好坏起到了决定性的作用。

另外还有客户端选择的策略, 其目的是通过选择与全局数据分布相似的客户端进行训练或者增加这类客户端的参与比例, 从而提高全局模型性能和速度^[34]。具体来说有为局部损失较大的客户端提供较高概率被选择的策略^[35] 以及优先选择损失最大的客户端进行训练的策略^[36]。客户端选择除了自动选择客户端参与聚合的策略外, 还有选择剔除异常更新客户端的方法。例如^[37] 提出了使用 k 近邻算法来计算每个参与聚合的客户端的偏移量, 再使用标准差找到异常值的方法, 从而剔除掉不相关的客户端更新。

1.2.2 基于服务器优化方法

在服务器上的优化方法, 一般可以分为优化策略调整、数据共享以及知识蒸馏三种方法^[18]。首先介绍优化策略调整的方法, 通过合理调整本地模型的聚合方式, 有助于降低非独立同分布数据对全局模型的不良影响^[38, 39]。传统的 FedAvg 聚合方法在数据异质性背景下, 可能会导致权重分配不公平的情况发生, 针对这类现象, Fedadp 根据上传的梯度对整体梯度的贡献程度来自适应优化权重^[40]; Fedmgda+ 算法将各客户

端的需求看成一个多目标问题，要求聚合模型不降低各客户端性能^[41]；而 Fedfv 通过梯度投影技术消除客户端梯度方向冲突，提升全局模型稳定性^[42]。

数据共享方法是通过在客户端之间分享一定比例的数据，将这些数据汇总成一个集合，每次聚合时都参考该数据集生成的模型，以此来降低因数据偏差而导致的模型偏差，从而提升全局模型的性能和收敛性^[43]。例如文献^[20]提出的主要策略是通过设定共享比例，将部分客户端数据汇集到数据共享池中。在本地训练中，客户端使用一定比例的共享数据进行训练，从而提升了模型的泛化能力。但是由于各个客户端需要传输一定的数据到一个公共集合当中，这会有数据泄露的风险，因此需要额外的技术来进行保证。

知识蒸馏方法 (Knowledge Distillation, KD) 是一种模型压缩与知识迁移技术，其核心思想是将复杂模型 (教师模型) 的“知识”迁移到轻量模型 (学生模型) 中，使小模型能够模仿大模型的行为，在保持性能的同时降低计算成本^[44-46]。FedDistill (Federated Distillation) 的核心思想是通过知识迁移而非参数聚合实现模型协同训练，支持客户端使用个性化异构模型架构，即使是全局模型与本地数据完全不匹配，但仍能通过本地个性化模型提高本地性能，从而缓解了数据异质性带来的性能下降的问题^[47, 48]。虽然知识蒸馏的方式在解决非独立同分布时能取得较好的效果，但是目前仍面临在复杂环境下计算开销大的挑战。

1.3 主要研究内容

本文根据上述的背景介绍，根据联邦学习在非独立同分布数据下出现的收敛速度下降、全局模型性能下降以及全局模型在不同客户端上性能差异明显等现象进行深入分析，通过现有的理论和技术，目标是设计出更收敛速度更快、全局性能更好、更为公平的联邦学习算法。

本文主要的工作如下：

- (1) 针对联邦学习在非独立同分布数据下全局模型精度下降这个现象，本文提出了一种基于本地梯度自适应调整学习率的聚合算法 (Fedalr)。通过估计全局梯度，再根据全局梯度与上传的本地梯度差距计算学习率，通过调整聚合时候的学习率来改善全局模型的更新方向更加与全局梯度接近，从而改善非独立同分布数据带来的全局模型偏移的情况。在理论上我们证明了该算法的收敛性，并通过精度实验

证明了该方法提高了收敛速度和全局模型精度。除此之外，本文还对该算法受到实验参数的影响进行了实验探讨，结果表明该算法无论在何种参数环境下，都表现出优秀的性能。

- (2) 除了联邦学习在非独立同分布数据下导致全局模型精度下降的情况，全局模型在不同数据分布的客户端性能也会有差异。为了减少这种差异，我们提出了 FedBEF 算法。该算法目的是在尽可能保证全局模型的性能下，降低客户端的性能差异。我们首先在聚合前将相似的客户端梯度进行合并以避免聚合模型偏向相似的客户端，该方法不需要具体设定客户端需要分成几类，减少了预设种类数量导致分类效果不好的情况；之后通过转换联邦学习的目标，为联邦学习的聚合权重设定了目标函数，通过这个目标函数，可以让聚合模型更加接近适合全局数据分布，从而提高了全局模型的性能。我们对该算法的收敛性进行了考察，证明了是可收敛的，并对该算法进行了仿真实验，证明该算法是能够兼顾全局模型性能以及公平性的。我们也通过消融实验，证明了该算法的两种优化机制的结合是有机的，不会相互冲突。

虽然本文提出的工作都是针对非独立同分布数据对联邦学习的聚合阶段进行优化，但是工作侧重点各有区别。在优化的细节上，一个仅针对聚合时的学习率进行优化 (Fedalr)，一个是针对整个聚合阶段进行优化 (FedBEF)：聚合前合并相似梯度以及聚合时聚合权重优化；另外在目的上也有所不同：相比第一种算法只需要提高全局模型精度，第二种算法更加在意的时全局模型在不同客户端上的性能表现差异显著，同时还需要保持全局模型较为良好的精度。本文提出的两种策略均不需要客户端做额外操作例如上传、计算相关信息等，保证了较低的通信消耗以及计算需求的同时也保证了较高的全局性能，在面对现实复杂环境下拥有一定优势。

1.4 论文结构安排

本文章节安排如下：

第一章绪论，主要介绍本课题的研究背景和意义；然后对国内外对非独立同分布下的联邦学习的研究现状进行分析；最后介绍了本文的研究重点和本文章节结构安排。

第二章是相关背景以及相关知识介绍。具体介绍了联邦学习的分类、本文主要研究的联邦学习相关种类的更新方法、非独立同分布数据问题的相关概念以及联邦学习

在非独立同分布数据下受到的挑战。

第三章是介绍了基于本地梯度的自适应学习率的联邦聚合算法。针对非独立同分布数据下，联邦学习出现全局模型性能下降，收敛速度降低等问题，本章聚焦于联邦学习的聚合阶段，通过理论分析，结合联邦学习全局损失的收敛上界和更新过程提出了 Fedalr 算法。该算法通过使用动量方法估计全局梯度，自适应计算出局部梯度的学习率来优化聚合模型，目的是提高了联邦学习的收敛速度和全局模型性能。在理论方面，我们证明了该算法的收敛性；在实验方面，通过不同种类统计异质性数据的仿真实验，证明了该算法比起当前基准算法性能更优秀，性能最多优化提升了 30.74%。

第四章介绍了一种兼顾效率与公平的联邦学习聚合算法。在非独立同分布数据下，联邦学习不仅出现全局模型性能下降，收敛速度降低等问题，还会导致全局模型客户端性能差异。为了解决上述问题，本章提出了兼顾效率与公平的 FedBEF 算法。该算法通过聚合前将相似的客户端梯度进行合并的 SNG 机制提高算法的公平性，并且通过优化聚合权重使得聚合模型距离全局模型差距更小来提高聚合模型的性能。然后通过理论推导出该算法的收敛性，同时通过实验证明我们的算法是既能保证性能又能保证公平的。我们还对该算法进行了消融实验，证明了 SNG 机制和聚合权重的计算是相互配合的。

第五章是总结与展望。内容大概是对本文提出的基于本地梯度的自适应学习率的联邦聚合算法以及兼顾效率与公平的联邦学习聚合算法进行了总结，并提出了未来展望。

第二章 相关背景以及知识

2.1 联邦学习概述

随着人们越来越重视数据隐私，数据隐私保护法规逐步完善，“数据孤岛”问题愈发严重，传统集中式机器学习方式难以满足数据安全和隐私保护的需求，因此联邦学习（Federated Learning, FL）应运而生。联邦学习一般由两部分组成：各个客户端和中央服务器。其中客户端通常负责储存本地数据、接收全局模型、训练模型以及上传模型；服务器的主要工作是广播全局模型给各个客户端、抽取客户端进行训练、接收客户端上传的模型、将上传的模型进行聚合。相比于传统分布式机器学习，联邦学习最重要的特点是每个客户端不用向服务器上传本地数据，只需要将本地数据对模型进行训练，因此联邦学习能够很好地保护本地数据隐私，并且可以减少数据运输过程中所需要的带宽消耗。

联邦学习可以根据参与者的数据分布差异角度来分类，大致可以分为以下三种典型范式^[49]：

- (1) 横向联邦学习（Horizontal FL）^[50]：适用于参与方拥有相同特征空间但不同样本的场景，具体来说，就是通过不同用户在相似的使用环境下，训练本地模型并上传，服务器聚合来实现全局模型更新。例如智能手机用户输入习惯建模，尽管各地使用者文化差异、地域差别等原因呈现地域性特征，但是用户们的输入习惯仍然存在着大量的重叠特征，因此通过横向联邦学习有助于联合模型的构建和完善。本文所讨论的联邦学习对象就是横向联邦学习。
- (2) 纵向联邦学习（Vertical FL）：面向样本 ID 重叠但特征空间互补的场景。具体来说就是同一个用户在不同的应用环境下产生了不同特征的模型，通过纵向联邦学习可以完善该用户的行为特征，进而可以分析并提供相对应的策略。典型应用如银行与电商平台联合构建信用评估模型^[51]，通过安全多方计算（Secure Multi-Party Computation, SMPC）实现特征维度的知识融合，关键技术包括同态加密与差分隐私^[52]。
- (3) 联邦迁移学习（Federated Transfer Learning）：针对样本与特征重叠存在明显差异的跨域场景。该学习模式利用数据、任务或者模型的相似程度，通过迁移学习将




图 2-1 联邦学习基础框架

Figure 2-1 Federal Learning Foundation Framework

从源领域模型作用在其他目标领域，如医疗机构间的罕见病研究^[53]。通过引入领域自适应（Domain Adaptation）技术，利用对抗生成网络（GAN）对齐源域与目标域的特征分布，提升模型在目标域的泛化能力^[54, 55]。

2.1.1 联邦学习的更新过程

本节以横向联邦学习为例子，简单介绍联邦学习的更新过程。具体每一个通讯轮的更新过程如图所示。在一定数量的通信轮 T 里，假设每一轮都有 N 个客户端参与训练，首先服务器广播模型参数 w^t 给各个参与训练的客户端，其中每一个客户端 i 上拥有本地数据集 D_i ，每个客户端都使用随机梯度下降算法 (SGD) 对本地数据进行模型训练，最后得到本地模型参数 w_i^{t+1} 并上传到服务器端。服务器将模型进行聚合得到新一轮模型参 w^{t+1} 并广播给各个客户端。因此联邦学习的更新公式可以概括为：

$$w^{t+1} = \sum_{i=1}^N \lambda_i w_i^{t+1}. \quad (2.1)$$

其中， η 代表学习率， λ_i 代表第 i 个本地模型的聚合权重，一般来说 $\lambda_i = \frac{|D_i|}{\sum_{i=1}^N |D_i|}$ ， $|D_i|$ 代表客户端 i 的数据量， $\nabla f_i(w^t)$ 代表客户端 i 本地损失函数的梯度具体来说，每一

个参与聚合的客户端使用本地数据训练模型都遵从训练神经网络的梯度下降公式，即

$$w_i^{t+1} = w^t - \eta \nabla f_i(w^t). \quad (2.2)$$

联邦学习评估全局模型的性能效果为全局损失函数 $F(w^t)$ ，当全局损失函数在一定区间内变动时，我们可以认为该算法收敛，全局模型训练完成。由于联邦学习的服务端无法获得全局数据，所以无法基于全局数据计算出相对应的全局损失函数，因此难以评估全局模型性能状态。所以在理想状态下，假设全部共 N 个客户端参与训练，因此我们可以获得各个客户端的本地损失函数 $f_i(w^t)$ ，通过平均本地损失函数来得到全局损失函数：

$$F(w^t) = \frac{1}{N} \sum_{i=1}^N f_i(w^t). \quad (2.3)$$

其中， $f_i(w^t) = \frac{1}{|D_i|} \sum_{(x_i, y_i) \in D_i} l(x_i, y_i, w)$ ， x_i 是训练模型时的本地输入数据， y_i 是本地输入数据的标签， w^t 是第 t 通讯轮的模型参数。

2.2 非独立同分布数据概述

以往在机器学习领域中，人们通常是假设数据是独立同分布 (independent and identically distributed, IID) 的。但是在现实世界里面，IID 数据是比较稀有的。用户们由于文化、地理以及设备使用者的使用习惯等等原因，现实生活中的边缘设备数据分布大多数并非是一致的，因此设备数据通常是非独立同分布 (Non-Independent and Identically Distributed, Non-IID) 的。非独立同分布数据类型有以下几种，本文重要研究的是第二种和第三种非独立同分布数据类型^[56]：

- (1) 数据特征分布偏差：是指不同客户端的数据特征不一样。通常是指同一个事物由于个人风格不一样而导致的特征不一致，例如客户端 i 的手写数字风格比较粗犷，因此该客户端相对应的写得比较柔和的手写数字比例则比较少；反过来客户端 j 的手写数字风格比较柔和，则该客户端相对应的写得粗犷的手写数字数量比较少。这展示了同一类型的图像在不同客户端上存在着不同的特征分布差异。
- (2) 数据标签分布偏差：是指不同客户端上标签的分布不一致。通常是指由于个人风格导致对事物的追求不一致。例如用户 i 比较喜欢自然风光，他的设备里自然风光的图片则占比较高，其余类型图片的占比较低；用户 j 比较喜欢人文风景，那

么他的设备人文风景的图片占比较高，其余类型的图片占比较低，因此他们的设备里数据种类的分布不一致。

- (3) 数据量偏差：是指不同客户端上储存的数据量差异较大。例如老用户拥有几万条使用记录而新用户可能才几百条使用记录，假如对他们进行行为分析得到整体用户的行为特点，由于数据量的偏差会导致分析结果更偏向老用户而忽视新用户。

2.2.1 非独立同分布数据对联邦学习的冲击

在联邦学习中，为了保护各地的数据隐私，各个用户的数据是不允许上传和相互交流的，因此客户端的数据分布很大概率是互不相同的，所以联邦学习中数据非独立同分布的现象十分普遍。而非独立同分布数据对联邦学习的性能带来了冲击和挑战，McMahan 等人通过和独立同分布数据下的实验以及理论推导，证明了非独立同分布数据会让联邦学习算法模型精度和收敛速度下降。具体来说，非独立同分布数据对联邦学习算法框架的冲击表现有以下几个方面：

- (1) 从模型性能来看，由于客户端数据的非独立同分布，导致每个客户端训练出来的本地模型彼此之间的差异十分的明显。假如选取全部的客户端本地模型进行聚合，虽然可以通过彼此差异相互抵消降低非独立同分布数据的影响，但是模型性能下降的情况仍会出现。假如选取部分客户端参与聚合，那么有很大概率这部分客户端的数据分布和全局客户端数据分布存在偏差，这会导致聚合出来的全局模型在客户端上性能下降的情况出现。很不幸的是，在现实环境下，很难让全体客户端一起参与聚合，这无疑让联邦学习的挑战更为困难^[57]。
- (2) 从本地训练角度来看，由于本地数据的非独立同分布，这就说明了本地数据分布无法代表整体数据分布，这会导致本地模型在训练过程中可能会陷入局部最优的困境。本地数据中，假如某种数据缺失或者数据量较少，那么局部模型可能只能对本地大部分数据有良好的预测效果，而对于由于没有学到缺失或者较少数据量的数据类型而导致相应的预测效果不理想，泛化能力大打折扣。假如这种模型对其简单加权进行聚合产生新的全局模型，其性能难免有所下降，甚至会低于各客户端本地训练的模型性能。而含有没有学到相应数据类型的客户端而言，这样的聚合模型显然是没有兼顾到全体客户端，这对他们而言是不公平的^[58]。

- (3) 从收敛速度来看, 由于本地数据的非独立同分布, 局部参与的客户端上传的模型往往拥有一定的偏向性, 当这些客户端模型聚合产生的全局模型也存在偏向性。等到下一通讯轮, 本地客户端上传的本地模型与上一代上传的本地模型偏向不一样, 这就导致新聚合产生的全局模型偏向与上一代不一致, 产生一定幅度的振动, 这会导致收敛速度的降低^[59]。

非独立同分布数据现象是当前影响联邦学习发展的挑战之一, 受到越来越多的专家和学者的关注与研究。

2.3 本章小结

本章主要介绍了联邦学习的类型以及联邦学习的训练更新过程, 同时介绍了非独立同分布数据的产生以及类型。最后介绍了非独立同分布数据对联邦学习的冲击, 为后文的联邦学习面对非独立同分布数据冲击时的优化奠定了基础。

第三章 基于客户端梯度自适应学习率聚合的联邦学习算法

3.1 引言

本章首先在联邦学习的框架范式基础上进行理论分析，目标是找到一个全局模型以降低全局损失的上界，通过理论分析以及联邦学习的更新公式相结合，提出了 Fedalr 算法，该算法在联邦学习的聚合阶段进行优化，通过计算本地梯度与全局梯度来自适应地计算聚合时各梯度的学习率，能够有效抗击非独立同分布数据的冲击，提升了全局模型的收敛速度和性能。同时我们通过理论证明了 Fedalr 是可收敛的。最后我们通过仿真实验模拟当前非独立同分布的两种数据类型，发现 Fedalr 算法效果更优于当前其他基准算法。

3.2 问题设置

在联邦学习的经典框架下，含有 N 个用于本地训练模型的客户端 $p_i (i = 1 \dots N)$ 以及一个中心服务器。假设每个客户端都拥有本地数据集 D_i ，且 n_i 为数据集 D_i 的数据量， $\sum_{i=1}^N n_i = n$ 为全体客户端数据集总量。由于在每个通信轮，中心服务器都会对客户

端上传的模型参数聚合，因此中心服务器的目标为以下形式：

$$\min_{w^t} F(w^t) = \frac{1}{N} \sum_{i=1}^N f_i(w^t). \quad (3.1)$$

其中， w^t 代表全局模型参数， f_i 是本地客户端上的损失， F 是全局损失。一般而言，在机器学习中，损失函数 f_i 定义如下：

$$f_i = \frac{1}{|D_i|} \sum_{(x_i, y_i) \in D_i} l(x_i, y_i, w). \quad (3.2)$$

上式中， x_i 是训练模型时的本地输入数据， y_i 是本地输入数据的标签， w 是模型参数。因此，联邦学习在非独立同分布数据下的优化目标是寻求一个模型，该模型需要在不同客户端下尽可能性能表现良好。

3.3 提出的 Fedalr 算法

3.3.1 联邦学习全局损失函数上界的优化探讨

在探讨联邦学习全局损失前，我们对目标损失函数进行了如下假设^[59, 60]：

假设 3-1 (光滑性): 假设全局损失函数 F 和局部损失函数 $f_i, i \in (1, 2, \dots, N)$ 在 $\mathbb{R}^m$ 上可微且服从 L-smooth:

$$F(w^{t+1}) \leq F(w^t) + \langle w^{t+1} - w^t, \nabla F(w^t) \rangle + \frac{L}{2} \|w^{t+1} - w^t\|^2, \quad (3.3)$$

$$f_i(w^{t+1}) \leq f_i(w^t) + \langle w^{t+1} - w^t, \nabla f_i(w^t) \rangle + \frac{L}{2} \|w^{t+1} - w^t\|^2. \quad (3.4)$$

假设 3-2 (全局方差有界): 假设 ξ_i^t 从第 i 个客户端的本地数据中随机均匀采样。每个设备中随机梯度方差有界:

$$\mathbb{E} \|\nabla f_i(w^t, \xi_i) - \nabla f_i(w^t)\|^2 \leq \delta^2. \quad (3.5)$$

令全局梯度等于局部全体梯度的平均值, 即 $\nabla F(w^t) = \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t)$, 同时令随机梯度下降 (SGD) 的估计全局均值定义为局部梯度的平均值: $\frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t)$, 则有 $\nabla F(w^t) = \mathbb{E} \left(\frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) \right)$ 。因此, 全局方差有界:

$$\mathbb{E} \left\| \nabla F(w^t) - \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) \right\|^2 \leq \frac{1}{N} \sum_{i=1}^N \delta_i^2. \quad (3.6)$$

为了最小化目标(3.1), 我们将3-1应用于(3.1)中, 可以得到:

$$\min_{w^{t+1}} F(w^{t+1}) \leq F(w^t) + \langle w^{t+1} - w^t, \nabla F(w^t) \rangle + \frac{L}{2} \|w^{t+1} - w^t\|^2. \quad (3.7)$$

该上限可以对应不等式(3.7)的右侧项。根据联邦学习的更新过程(2.1)和(2.2)可以得到, 在给定的全局模型 w^t 中, 每一轮全新聚合模型更新是由 $\sum_{i=1}^n \frac{n_i}{N} \eta_i \nabla f_i(w^t, \xi_i^t)$ 控制, 因此我们可以通过聚合每一个通信轮中每一个客户端的局部梯度 $\nabla f_i(w^t, \xi_i^t)$ 来最小化目标函数(3.1)的上限。在给定的 K 个本地梯度 $\mathcal{G} = \{\nabla f_1(w^t, \xi_1^t), \nabla f_2(w^t, \xi_2^t), \dots, \nabla f_K(w^t, \xi_K^t)\}$ 中, 中心服务器需要解决的目标函数如下所示:

$$\min F(w^t) + \left\langle - \sum_{i=1}^N \frac{n_i}{n} \eta_i \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) \right\rangle + \frac{L}{2} \left\| \sum_{i=1}^N \frac{n_i}{n} \eta_i \nabla f_i(w^t, \xi_i^t) \right\|^2. \quad (3.8)$$

由于根据不同客户端数据量不同导致聚合权重更加偏向数据量大的客户端而忽视了数据量小的客户端，为了降低梯度的权重偏移的影响，我们采用 $\frac{1}{N}$ 来替代 $\frac{n_i}{n}$ ， N 为参与聚合的客户端数量。在不改变本地上传的模型参数情况下，我们的优化目标转变为如下所示：

$$\min_{\eta_1, \eta_2, \dots, \eta_N} F(w^t) + \left\langle -\frac{1}{N} \sum_{i=1}^N \eta_i \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) \right\rangle + \frac{L}{2N^2} \left\| \sum_{i=1}^N \eta_i \nabla f_i(w^t, \xi_i^t) \right\|^2. \quad (3.9)$$

令 $L \leq N$ 并对 η_i 求偏导，可得：

$$\eta_i = \frac{\langle \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) \rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2}. \quad (3.10)$$

由此我们可以通过公式(3.10)对聚合时不同客户端上传的梯度学习率进行优化。这种优化结果有如下性质：公式(3.10)近似于求局部梯度向量 $\nabla f_i(w^t, \xi_i^t)$ 和全局梯度 $\nabla F(w^t)$ 的余弦，由此可以推断出该方法求得的学习率大小与 $\nabla f_i(w^t, \xi_i^t)$ 和 $\nabla F(w^t)$ 的夹角有关，夹角越小则学习率越大，从而控制聚合梯度往全局方向前进，从而加快模型的收敛速度。

3.3.2 Fedalr 算法框架

我们基于上述的结论，结合联邦学习更新过程，进行进一步地优化，从而提出 Fedalr 算法。

3.3.2.1 全局梯度替代 在上述我们提出的结论中，全局梯度 $\nabla F(w^t)$ 是一个很重要的量，因为这会影响不同梯度的学习率进而模型的学习速度。在实际场景中，由于联邦学习的客户端数据保密性，全局模型 $\nabla F(w^t)$ 是很难通过计算、观测等方式得到，因此，目前^[16, 25] 通常使用 $\nabla F(w^t) = \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t)$ 来替代全局梯度。为了减少由于随机选择客户端带来的梯度动荡，我们在前人计算全局梯度 $\nabla F(w^t)$ 的基础上加入动量 (Momentum) 机制^[61]，因此 $\nabla F(w^t)$ 的计算过程如下：

$$\nabla F(w^t) = \begin{cases} \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) & t = 1 \\ \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) * \frac{1}{t} + \nabla F(w^t) * \frac{t-1}{t} & t > 1 \end{cases} \quad (3.11)$$

3.3.2.2 局部梯度单位化以及学习率范围限定 为了防止不同客户端设置不同的训练参数,某些客户端训练的步长或者轮次不一致,即参数异质性,这样会导致上传的梯度长度不一致,进而导致聚合梯度出现偏置,影响全局模型性能。因此我们在计算学习率前对局部梯度 $\nabla f_i(w^t, \xi_i^t)$ 进行标准化处理 $\nabla f_i(w^t, \xi_i^t) = \frac{\nabla f_i(w^t, \xi_i^t)}{\|\nabla f_i(w^t, \xi_i^t)\|}$ 来统一梯度长度,同时减少模型震荡。

由于 $\langle \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) \rangle$ 计算会出现负数形式,我们设计了一个函数 $\eta_i = e^{\eta_i - 1}$, 目的是将 η_i 的映射范围缩小为 $(0, 1]$, 目的是防止学习率小于 0 或者过大的情况出现导致全局模型出现负优化的情况出现。

3.3.2.3 学习率动荡抑制机制 由于学习率 η_i 的计算与 $\nabla f_i(w^t, \xi_i^t)$ 和 $\nabla F(w^t)$ 有关,由于通过(3.11)估计得到的全局梯度与真实的全局梯度有差距,因此为了防止有客户端的梯度和估计的梯度相似而导致聚合时学习率太大而导致全局模型震荡,本文借鉴了 Adam 优化器的策略^[62], 对每个客户端的学习率采用了加权平均历史学习率,在前期加快模型的学习速度的同时使其保证稳定。具体方法如下:

$$\eta_i = \begin{cases} \frac{\langle \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) \rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2} & t = 1 \\ \frac{\langle \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) \rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2} * \frac{1}{t} + \eta_i * \frac{t-1}{t} & t > 1 \end{cases} \quad (3.12)$$

Fedralr 算法的整个训练过程如算法 3-1 所示。

该算法首先在服务器段将全局模型 w^t 广播给全体客户端,然后随机选择一部分客户端来进行训练本地模型。被选择的客户端根据本地数据进行小批量随机梯度下降(SGD)对模型参数进行更新。经过 E 个 epoch 更新后,上传本地梯度 $\nabla f_i(w^t, \xi_i^t)$ 给服务器。当服务器收到全部客户端上传的梯度后,对每个梯度进行标准化处理(第十三行),然后计算估算全局梯度 $\nabla F(w^t)$ (第十四行),接下来通过全局梯度以及不同的局部梯度计算出相对应的学习率 η_i (第十六行),最后将计算出来的学习率映射到 $(0, 1]$ 范围内(第十七行)。服务器使用计算好的聚合学习率和相对应的局部梯度进行统一聚合,之后生成全新的全局模型 w^{t+1} 。

3.4 Fedalr 算法收敛性分析

本小节将展示 Fedalr 算法的收敛性分析结果。在证明 Fedalr 算法是收敛性前,我们先讨论通过公式(3.10)所计算出来的学习率的性质。下文中我们采用以下符号以区分全局梯度($\nabla F(w^t)$)与模拟的全局梯度($\widetilde{\nabla F(w^t)}$)以及带动量的全局模拟梯度($\widetilde{\nabla F_m(w^t)}$)。

算法 3-1 Fedalr 算法过程

输入: 通讯轮数 T , 每个通信轮参与训练的本地客户端数量 N , 本地 epoch 次数 E , 本地训练学习率 η , 本地训练批次 B 。

输出: 最终全局模型 w^T 。

初始化模型参数 w^0 。

while $t \leq T$ **do**

if $t = 1$ **then**

$$w^t = w^0,$$

else

$$w^t = w^{t+1}.$$

end if

 广播全局模型 w^t 到全体客户端。

 随机选择 N 个客户端进行训练, 将这 N 个客户端编号视为一个集合 C^t 。

 被选择客户端接收全局模型 w^t 后, 开始根据本地实验参数进行训练: 通过训练 E 个 epoch 局部小批量 SGD 步骤的 w^t 来解决局部问题, 并在最后得到新的局部模型 w_i^{t+1} 。

 上传局部梯度 $\nabla f_i(w^t, \xi_i^t) = w_i^{t+1} - w^t$ 到服务器。

 服务器接收到所有客户端上传的本地梯度 $\nabla f_i(w^t, \xi_i^t), i \in C^t$ 。

 梯度标准化处理: $\nabla f_i(w^t, \xi_i^t) = \frac{\nabla f_i(w^t, \xi_i^t)}{\|\nabla f_i(w^t, \xi_i^t)\|}$ 。

 通过(3.11)式估计全局梯度 $\nabla F(w^t)$ 。

for $i \in C^t$ **do**

 根据不同客户端上传的局部梯度 $\nabla f_i(w^t, \xi_i^t)$ 通过(3.12)式计算出相对应的学习率 η_i ;

$$\eta_i = e^{\eta_i - 1}.$$

end for

 生成新的全局模型: $w^{t+1} = w^t - \frac{1}{N} \sum_{i=1}^N \eta_i \nabla f_i(w^t, \xi_i^t)$ 。

end while

输出 w^T 。

引理 3-1 (自适应学习率 η_i 的上界): 经过算法 3-1 第十三行至十七行计算出来的任意 η_i , 都有 $\eta_i \leq 1$ 。

该引理证明如下所示:

证明: 先证不带动量的全局模拟梯度 $\widetilde{\nabla F}(w^t)$ 下计算得到的 η_i 性质。

因为 $\eta_i = \frac{\langle \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) \rangle}{\|\nabla f_i(w^t, \xi_i^t)\|^2}$, 且 $\widetilde{\nabla F}(w^t) = \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t)$, 所以

$$\eta_i = \frac{\left\langle \nabla f_i(w^t, \xi_i^t), \sum_{j=1}^N \nabla f_j(w^t, \xi_j^t) \right\rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2}. \quad (3.13)$$

又因为 $\forall i \in [N]$, $\nabla f_i(w^t, \xi_i^t) = \frac{\nabla f_i(w^t, \xi_i^t)}{\|\nabla f_i(w^t, \xi_i^t)\|}$, 所以 $\|\nabla f_i(w^t, \xi_i^t)\| = 1$ 。

$$\begin{aligned} \eta_i &= \sum_{j=1}^N \frac{\langle \nabla f_i(w^t, \xi_i^t), \nabla f_j(w^t, \xi_j^t) \rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2} * \frac{\|\nabla f_j(w^t, \xi_j^t)\|}{\|\nabla f_j(w^t, \xi_j^t)\|} \\ &= \sum_{j=1}^N \frac{\langle \nabla f_i(w^t, \xi_i^t), \nabla f_j(w^t, \xi_j^t) \rangle}{N \|\nabla f_i(w^t, \xi_i^t)\| \|\nabla f_j(w^t, \xi_j^t)\|} * \frac{\|\nabla f_j(w^t, \xi_j^t)\|}{\|\nabla f_i(w^t, \xi_i^t)\|} \\ &= \frac{1}{N} \sum_{j=1}^N \cos \theta_{ij} \leq 1. \end{aligned} \quad (3.14)$$

现考虑带动量的全局模拟梯度 $\widetilde{\nabla F_m}(w^t)$ 的情况:

当 $t = 1$ 时, 此时全局模拟梯度 $\widetilde{\nabla F_m}(w^t)$ 与 $\widetilde{\nabla F}(w^t)$ 情况一样。当 $t > 1$ 时, $\widetilde{\nabla F_m}(w^t) = \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) * \frac{1}{t} + \nabla F(w^t) * \frac{t-1}{t}$ 。因此,

$$\begin{aligned} \eta_i &= \frac{\left\langle \nabla f_i(w^t, \xi_i^t), \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) * \frac{1}{t} + \nabla F(w^t) * \frac{t-1}{t} \right\rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2} \\ &= \frac{\left\langle \nabla f_i(w^t, \xi_i^t), \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) * \frac{1}{t} \right\rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2} + \frac{\left\langle \nabla f_i(w^t, \xi_i^t), \nabla F(w^t) * \frac{t-1}{t} \right\rangle}{N \|\nabla f_i(w^t, \xi_i^t)\|^2} \\ &\leq \frac{1}{t} + \frac{t-1}{t} = 1 \end{aligned} \quad (3.15)$$

□

然后我们可以得到算法 Fedalr 的收敛保证:

定理 3-1 (算法 3-1收敛性分析): 当前文中的假设3-1、3-2成立, 并且假设 $L \geq 1$, 根据引理3-1可以得到算法 Fedalr 收敛到全局损失函数 F 的稳定点, 其中收敛结果如下所示:

$$\min_{t=1,2,\dots,T} \|\nabla F(w^t)\|^2 \leq \frac{\sum_{t=1}^T \|\nabla F(w^t)\|^2}{T} \leq \sigma^2 + 2 \frac{\mathbb{E}(F(w^0) - F(w^{t+1}))}{T} \quad (3.16)$$

证明过程如下所示:

证明: 当假设3-1且 $L \geq 1$ 成立时, 有:

$$F(w^{t+1}) - F(w^t) \leq \left\langle -\sum_{i=1}^N \frac{1}{N} \eta_i \nabla f_i(w^t), \nabla F(w^t) \right\rangle + \frac{1}{2} \left\| \sum_{i=1}^N \frac{1}{N} \eta_i \nabla f_i(w^t) \right\|^2. \quad (3.17)$$

可以得到:

$$\begin{aligned} & \left\langle -\sum_{i=1}^N \frac{1}{N} \eta_i \nabla f_i(w^t), \nabla F(w^t) \right\rangle \\ & \leq \frac{1}{2} \left(\left\| \nabla F(w^t) - \sum_{i=1}^N \frac{1}{N} \eta_i \nabla f_i(w^t) \right\|^2 - \|\nabla F(w^t)\|^2 - \left\| \sum_{i=1}^N \frac{1}{N} \eta_i \nabla f_i(w^t) \right\|^2 \right). \end{aligned} \quad (3.18)$$

代入可得:

$$F(w^{t+1}) - F(w^t) \leq \frac{1}{2} \left(\left\| \nabla F(w^t) - \sum_{i=1}^N \frac{1}{N} \eta_i \nabla f_i(w^t) \right\|^2 - \|\nabla F(w^t)\|^2 \right). \quad (3.19)$$

两边取期望, 再结合引理3-1以及假设3-2, 可得:

$$\|\nabla F(w^t)\|^2 \leq \delta^2 + 2(F(w^t) - F(w^{t+1})). \quad (3.20)$$

因此可以得证:

$$\min_{t=1,2,\dots,T} \|\nabla F(w^t)\|^2 \leq \frac{\sum_{t=1}^T \|\nabla F(w^t)\|^2}{T} \leq \delta^2 + 2 \frac{(F(w^0) - F(w^{t+1}))}{T}. \quad (3.21)$$

□

3.5 实验评估

本环节将介绍仿真实验设置以及实验结果。通过在数据集 CIFAR-10 与 CIFAR-100 上进行的仿真实验来证明本文提出的算法与当前基准算法相比具有优越性。

3.5.1 实验设置

数据集介绍：本章实验将使用两个不同的数据集：CIFAR-10 和 CIFAR-100。CIFAR-10 数据集是一个广泛使用的图像分类基准数据集，包含 10 个不同类别的彩色图像，每个类别有图像分辨率为 32×32 像素的 6000 张图像，共计 60000 张，其中 50000 张将被划分为训练集，10000 张将被划分为测试集。CIFAR-100 数据集也是一个用于图像分类的基准数据集，包含 100 个不同的类别，每个类别有 600 张图像，共计 60000 张图像。与 CIFAR-10 数据集类似，CIFAR-100 中的图像是彩色的，分辨率为 32×32 像素。该数据集分为 50000 张训练图像和 10000 张测试图像。

数据划分：在我们的实验中，为了营造客户端数据非独立同分布的情况，我们打算对客户端数据进行如下两类形式划分：第一种是固定种类划分：我们计划将训练集数据先按照种类进行排序，并将每类数据平均分为 20 份总共 200 个分片，每个客户端随机分配 2 个分片，确保每个客户端拥有的分片有且只有 2 个且种类各不相同，我们将这种划分称为 $c=2$ ；第二种是固定分布划分：通过 Dirichlet 分布生成抽样矩阵，确定每个客户端拥有的图像数据种类和数量。我们使用的是参数 $d=0.1$ 的 Dirichlet 分布进行仿真实验。以 CIFAR-10 为例，具体数据分布情况如图3-1所示：横坐标代表客户端数据数量，列坐标代表客户端编号，每一行都代表了客户端里拥有的数据，不同颜色代表不同数据类型。

基线：为了证明我们提出的算法优越性，我们将 Fedalr 和如下几种算法作比较，其中包括 Fedavg，一种经典的联邦学习算法以及 Fedprox、Scaffold、Moon、q-Fedavg 以及 Fedmgda+ 这几种为了对抗非独立同分布数据冲击导致全局模型下降的算法。

实验参数设置：我们将客户端设置为 100 个，每轮随机抽取 20 个客户端参与训练和聚合 (Participation rate = 0.2)，总共 2000 次通讯轮数。其中本地训练优化器为 SGD，CIFAR-10 的 batchsize 为 64，CIFAR-100 的 batchsize 为 10，本地学习率 (Learning rate) 为 0.01，epoch=1。为了防止实验结果出现随机性，所有算法的实验结果将在四个随机种子下实验平均后得到。




图 3-1 CIFAR-10 数据集在不同数据划分情况下的数据分布图

Figure 3-1 Data distribution diagrams of the CIFAR-10 dataset under different data partitioning scenarios


模型设置：我们的模型是当前流行的双层卷积层的卷积神经网络（CNN）模型，每一层卷积核大小均为 5×5 ，后面均有一个尺寸为 2×2 的池化层。模型后面还有三层全连接层，确保输出的结果为 10 个类别的预测分数。

实验环境及配置：本文实验均基于开发语言 python3.8.0，实验集成环境包 flgo 0.4.3^[63] 上进行。使用 GPU 分别为两个 NVIDIA GeForce RTX 3090 以及一个 NVIDIA GeForce RTX 4090。


3.5.2 算法性能比较

如图3-2所示，在 CIFAR-10 数据集中，Fedalr（黄色折线）表现出更快的收敛速度以及全局模型表现出更高的性能，具体来看，如表3-1所示（最优性能已用粗体标出）：在 $c=2$ 的数据分布下，Fedalr 第 2000 轮的全局模型性能达到 72.15%，比起当前最优算法 Fedavg 性能 63.91% 提升了 12.89%（(Fedalr 性能-最好的基线算法性能)/最好的基线算法性能）；而在 $d=0.1$ 的数据分布下，Fedalr 算法的全局模型性能高达 68.68%，比起当前最优算法提升了 30.74%。

在 CIFAR-100 数据集中，虽然 Fedalr 前期没有表现出较快的收敛性，这可能是因为 CIFAR-100 任务下难以找到较为合适的全局梯度导致收敛速度下降，但是最后面的全局模型性能仍然超过各个算法。根据表3-3可以看到， $c=2$ 和 $d=0.1$ 的情况下，Fedalr 算法性能均达到 32.2% 和 26.21%，比起当前最优算法 Fedmgda+ 性能分别提升了 3.57% 和 7.07%。




(a) 数据划分 $c=2$ 时的算法性能结果




(b) 数据划分 $d=0.1$ 时的算法性能结果

图 3-2 CIFAR-10 数据集不同算法的性能结果

Figure 3-2 Performance results of different algorithms on the CIFAR-10 dataset



(a) 数据划分 $c=2$ 时的算法性能结果



(b) 数据划分 $d=0.1$ 时的算法性能结果

图 3-3 CIFAR-100 数据集不同算法的性能结果

Figure 3-3 Performance results of different algorithms on the CIFAR-100 dataset

表 3-1 不同算法在不同类型非独立同分布数据划分下的精度情况

Table 3-1 The accuracy of different algorithms under the division of various types of non-independent and identically distributed data

算法	CIFAR-10		CIFAR-100	
	c=2	d=0.1	c=2	d=0.1
Fedavg	63.91%	52.53%	28.45%	22.90%
Fedmgda+	61.81%	52.19%	31.10%	24.48%
Fedprox	62.11%	51.12%	28.27%	21.69%
Moon	62.47%	51.02%	28.84%	22.44%
q-Fedavg	46.51%	39.87%	14.49%	11.90%
Scaffold	52.95%	30.01%	20.46%	9.81%
Fedalr	72.15%	68.68%	32.21%	26.21%
提升比例	12.89%	30.74%	3.57%	7.07%

在不同的数据划分下，我们提出的算法仍然保持稳健。具体来说，相比于第一种数据划分（ $c=2$ ）方式，第二种数据划分（ $d=0.1$ ）对联邦学习框架的冲击更大。从图3-2可以看出，同种数据任务下，所有算法在 $c=2$ 的表现（如模型性能、收敛速度等）比 $d=0.1$ 要更好这是因为 $c=2$ 的划分情况与 $d=0.1$ 的划分情况相比，局部数据分布更容易接近全局数据分布。这和前文提到的局部数据分布与整体数据不一致会影响该算法的收敛速度相吻合的。但是无论是哪种数据划分方式，我们提出的 Fedalr 算法性能以及收敛速度等方面均优于其他基准算法。

3.5.3 不同实验参数对联邦算法的影响

在以往的研究中，不同的参数设置往往对联邦学习算法产生的全局模型性能有着相当大的影响。假如一个算法换了实验参数效果大打折扣，则认为该算法受到实验参数影响很大，鲁棒性较差，这就意味着需要花大量的资源来调控出一个较优的参数来保证算法的性能，因此考察不同实验参数对算法的影响尤为重要。为了考察不同实验参数对算法的影响，我们在 CIFAR-10 数据集任务 $c=2$ 和 $d=0.1$ 的数据划分下设置了不同参数进行实验，具体参数设置如表3-2所示：

由图3-4可以观察到，相比于基础算法 Fedavg（虚线），我们的 Fedalr 算法（实线）无论参数如何改变，收敛速度以及模型性能均优于 Fedavg。从收敛速度角度来说，无

表 3-2 实验参数设置表

Table 3-2 Experimental parameter setting table

	Learning rate	Batch size	Participation rate
设置 1（绿色折线）	0.01	10	0.1
设置 2（蓝色折线）	0.1	400	0.1
设置 3（红色折线）	0.01	64	0.2




图 3-4 不同实验参数算法性能折线图

Figure 3-4 Algorithm performance line graph with different experimental parameters




图 3-5 设备 epoch 参数异质性下不同联邦算法性能折线图

Figure 3-5 Line chart of performance of different federated learning algorithms under heterogeneity of device epoch parameters

论哪种数据划分，不同参数设置下 Fedalr 算法的收敛速度都十分相近。从模型性能角度来说，当数据划分为 $c=2$ 时，不同参数下的 2000 轮训练后模型性能差别不大；当数据划分为 $d=0.1$ 时，不同参数下的 2000 轮训练后模型性能略有差别，最好的参数设置情况是设置 2，2000 轮模型性能为 72.18%，最差的参数设置是设置 1，性能为 62.03%，性能差为 10.15%；而在同种数据划分下的 Fedavg 算法性能最好是设置 2，为 66.23%，最差的设置是设置 3，性能为 52.53%，性能差为 13.70%。因此可以认为 Fedalr 算法对于实验参数的敏感性不高，属于鲁棒性较高的算法。

3.5.4 设备 epoch 参数异质性对联邦算法的影响

现实情况下，通常各个用户由于设备算力、通讯环境等现实原因，难以能够完整地按照既定的实验参数 epoch 训练完毕。为了进一步探讨我们提出的算法 Fedalr 鲁棒性，我们通过设置不同客户端拥有不同的 epoch 来模拟现实环境。我们首先设置 epoch 范围为 $[1, 10]$ ，然后再这个范围内随机取整数作为某个客户端的 epoch。当每个客户端都拥有自己的 epoch 时，我们将随机抽取客户端进行训练。接下来的训练流程和普通环境下的联邦学习一样。

在本实验中，我们的实验参数除了 epoch 做出如上文改变之外，其余参数均和前文 3.5.1 的实验参数设置相同。实验在 CIFAR-10 的两个数据划分 ($c=2$ 和 $d=0.1$) 下进行。如图 3-5 显然可以看出，通过比较前文所比较的基线算法，进一步说明了算法 Fedalr 在对抗设备 epoch 参数异质性环境下拥有一定的优势。具体来说，如表格 3-3 和表格 3-4 所

表 3-3 数据分布 $c=2$ 普通情况下和 epoch 异质下性能对比表Table 3-3 Table of performance comparison under normal circumstances with data distribution $c=2$ and under heterogeneous epoch conditions

联邦算法	epoch 异质	普通情况	差距
Fedavg	45.47%	63.91%	-18.44%
Fedmgda+	45.47%	61.81%	-16.34%
Fedprox	44.20%	62.11 %	-17.91%
Moon	45.38 %	62.47 %	-17.09%
q-Fedavg	40.80%	46.51 %	-5.71%
Scaffold	46.00%	52.95%	-6.95%
Fedalr	76.35 %	72.15 %	4.2%

表 3-4 数据分布 $d=0.1$ 普通情况下和 epoch 异质下性能对比表Table 3-4 Table of performance comparison under normal circumstances with data distribution $d=0.1$ and under heterogeneous epoch conditions

联邦算法	epoch 异质	普通情况	差距
Fedavg	44.14%	52.53%	-8.39%
Fedmgda+	44.14%	52.19%	-8.05%
Fedprox	43.98%	51.12 %	-7.14%
Moon	44.04 %	51.02 %	-6.98%
q-Fedavg	38.88%	39.87 %	-0.99%
Scaffold	47.22%	30.01%	-17.21%
Fedalr	73.96%	68.68 %	5.28%

示, 相比较于普通情况下, 在 epoch 异质影响下, 基准算法的全局模型性能都出现了衰退情况。而我们提出的 Fedalr 却在大多数算法性能衰减的情况下仍能保持普通情况下的性能, 甚至更优于普通情况。另外, 无论是普通情况还是 epoch 异质情况下, Fedalr 算法的性能都优于其他基线算法。总而言之, 结合两表来看, Fedalr 算法无论是何种数据分布下、何种现实情况下, 都表现出优秀的性能, 都能让全局模型快速收敛。因此, 我们可以认为 Fedalr 算法是一种十分稳定的高效的联邦学习算法。

3.6 本章小结

在本章中,我们针对联邦学习受到非独立同分布数据的挑战导致收敛速度降低,全局模型性能下降等问题,提出了 Fedalr 算法,该算法通过计算近似不同客户端上传的本地梯度 $\nabla f_i(w^t)$ 以及全局梯度 $\nabla F(w^t)$ 的余弦来自适应地分配不同本地梯度 $\nabla f_i(w^t)$ 的聚合学习率,从而提高全局模型的性能以及收敛速度,从而减少在非独立同分布数据环境下联邦学习的通信轮次。为了更准确地计算出全局模型,我们在前人不同本地梯度的基础上采用了动量策略,以消除随机性。最后我们通过实验证明了我们的算法比起其他基线算法性能更加优秀,性能提升比例高达 30.64%。在受到不同的实验参数的影响下,算法性能表现出较为稳定的特点。

第四章 基于兼顾性能与公平的联邦学习：FedBEF

4.1 引言

由于近年来边缘设备的发展迅速，边缘计算越来越受到人们的重视。由于联邦学习无需共享用户数据保护隐私的特性，已经成为了通过客户端协作训练深度神经网络的关键框架。其核心机制是将模型训练任务分布到各客户端，由客户端在本地数据上进行模型更新，并将模型参数而非原始数据上传至中心服务器进行聚合。

经典 Fedavg 算法在许多应用拥有良好性能，其在独立同分布 (Independent and Identically Distributed, IID) 数据下收敛性已经被证明。然而，联邦学习在实际应用中面临诸多挑战，其中之一是由于文化、地理以及设备使用者的使用习惯等等原因，现实生活中的边缘设备数据大多数是非独立同分布 (Non-Independent and Identically Distributed, non-IID) 的。非独立同分布数据挑战主要体现在以下几个方面：客户端数据类别不均衡、特征分布差异显著以及数据量差异悬殊。这些问题会导致全局模型训练中的梯度方向偏移、收敛速度减慢以及模型性能下降等不利影响，严重制约了联邦学习的效果与公平性。

为了解决现实应用中的统计异质性问题，我们提出了 FedBEF 算法，目的是解决联邦学习受到非独立同分布数据冲击下导致全局模型性能下降的问题。该算法的框架图如图4-1所示。该算法主要针对了联邦学习的服务器聚合部分，具体来说，我们针对在聚合前对于客户端梯度以及聚合时的聚合权重做出了优化调整。需要注意的是，与第三章的工作重点不同，第三章主要聚焦的是联邦学习的全局模型在非独立同分布数据下的性能问题，而本章聚焦的不仅是非独立同分布数据下的性能问题，而且试图去解决非独立同分布数据下的全局模型对于各客户端的性能公平性问题。

我们本章的工作量如下所示：一、我们结合了联邦学习数据不可知的特性以及现实环境下的非独立同分布数据特点，提出了 SNG 机制。该机制可以找到相似数据的客户端并进行归类合并。注意，与以往的聚类算法不同，SNG 机制不需要填写需要分成几类的超参数，这符合联邦学习的保护数据隐私的需求。二、我们根据联邦学习的收敛性，提出 FedBEF 算法来优化聚合参数，目的是兼顾聚合模型的性能以及公平性，缓解非独立同分布数据导致模型性能下降以及泛化性下降的问题。该方法是使聚合梯度寻找一个方向，该方向的投影方向与全局梯度最大化。三、我们对 FedBEF 在非独立同




图 4-1 FedBEF 算法框架图

Figure 4-1 FedBEF Algorithm framework diagram

分布数据场景下的收敛性进行严格的收敛性理论分析，并且可以证明该算法可以收敛于全局损失的驻点。四、通过对多个联邦学习的算法进行比较，在精度、收敛速度、公平性等方面进行评估，证明了 FedBEF 算法优势。

本章接下来结构分为以下几个部分：首先主要介绍了联邦学习的运行机制以及现实中非独立同分布数据的特点。其次主要介绍了 SNG 机制以及 FedBEF 算法的详细原理。然后主要展示了 FedBEF 算法与各个联邦学习算法仿真实验，对他的实验精度性能等方面进行分析。最后，我们对本章进行了总结。

4.2 问题设置和场景描述

4.2.1 目标函数介绍

联邦学习的训练目标是寻求一个模型参数 w^{t+1} ，该参数要求使得每个客户端上的数据集损失函数最小化，其目标函数如下所示：

$$\min_{w^{t+1}} \left\{ F(w^{t+1}) \triangleq \frac{1}{N} \sum_{i=1}^N f_i(w^{t+1}) \right\}. \quad (4.1)$$

其中假设有 N 个客户端参与聚合， n_i 是每个参与聚合的客户端的数据量， $f_i(w^{t+1}) = \frac{1}{|D_i|} \sum_{(x_j, y_j) \in D_i} l(x_j, y_j, w^{t+1})$ 代表本地客户端的损失函数，意思是客户端 i 基于模型




图 4-2 独立同分布数据和非独立同分布数据分布情况图

Figure 4-2 Graphs of the distribution of IID data and non-IID data

w^{t+1} 和本地数据集 D_i 中输入的数据 x_j 得出来的结果与真实结果 y_j 之间的差距, $F(w^{t+1})$ 是全局损失函数。

在非独立同分布数据场景下,不同客户端因本地数据分布差异(如标签偏斜、特征偏移)导致聚合模型出现偏移现象,这会导致聚合模型在偏向的客户端性能会好,而其他客户端性能则会下降甚至难以完成相应的任务。联邦学习公平性是指全局模型在各客户端上的预测性能相对均衡,避免出现部分客户端准确率显著低于平均水平的情况,具体的测量指标是聚合模型在各客户端上的损失方差,因此追求联邦学习的公平性目标式如下所示:

$$\min_{w^{t+1}} \left\{ \frac{1}{N} \sum_{i=1}^N (f_i(w^{t+1}) - F(w^{t+1}))^2 \right\}. \quad (4.2)$$

4.2.2 非独立同分布数据对联邦学习的影响

在独立同分布数据条件下，由于随机梯度相当于全局梯度的无偏估计，因此联邦学习的基础算法 Fedavg 被证明是行之有效的。如图4-2所示，全局数据代表整体客户端的全部数据，而独立同分布数据图和非独立同分布数据图中每一行都代表一个客户端，不同的颜色方块代表该客户端上拥有的数据种类。可以看到，当数据分布是独立同分布时，很显然，无论是全体客户端参与聚合还是部分客户端参与聚合，这些客户端的数据分布与全局数相似，因此聚合得到的全局模型参数均可适合各个客户端。

但在现实环境下，大部分客户端的数据分布是非独立同分布的。因此当数据分布是非独立同分布时，假设是全体客户参与聚合，那么尽管客户端上传的模型参数拥有本地的数据偏向，但是经过聚合平均之后该模型参数与全局数据训练的模型参数相似。如图所示，将非独立同分布数据图中的所有同颜色的方块加起来，就可得到全局数据的分布形状。就算这样，当全局模型参数返回到各个客户端后，性能也会有所下降，因为全局模型参数与本地模型参数已经有所差距。假设是部分客户端参与聚合，那么这部分客户端的全部数据的分布很难达到全体客户端的数据分布，参与聚合的客户端数据分布都与全局数据分布有差距，这会导致聚合的模型参数偏向性更大，更加倾向于参与聚合的客户端以及有相似分布的客户端，这对其他客户端来说聚合模型是不够公平的。如图4-2所示，假设某次通信轮中，随机选择到第一个和第二个客户端参与聚合，由于这两个客户端中蓝色数据和黄色数据的量比其他数据量少，训练出来的模型对于这两种数据比起其他数据要更不敏感，因此聚合出来的模型放到第三个和第四个客户端性能效果必然比不过第一个和第二个客户端，特别是第三个客户端拥有大量的黄色和蓝色数据，性能差异会更加明显。以上的例子很清晰地说明了非独立同分布数据是如何导致客户端性能不公平的。

我们针对客户端参与聚合的比例进行了实验，目的是为了直观地了解当数据分布是非独立同分布时，客户端参与聚合的比例对联邦学习算法的影响。该实验将考察不同参与比例下的联邦基础算法 Fedavg 产生的全局模型在各客户端上的平均性能以及性能的方差，具体的实验设置如下：本地训练的轮次 epoch 为 1，学习率固定为 $\eta_t = 0.01$ ，batchsize 大小是 64，采用 7 层的 CNN 卷积神经网络，实验使用 SGD 优化器，将在使用 Dirichlet 分布参数为 0.1 的数据划分的 CIFAR-10 数据集上进行。我们设置客户端参




图 4-3 不同客户端参与聚合比例的 Fedavg 结果

Figure 4-3 The FedAvg results of different client participation ratios in aggregation

与率比例分别为 100%($p=1$), 20%($p=0.2$), 10%($p=0.1$)。如图4-3所示, 可以明显的观察到, 在同一个数据划分下, 客户端参与比例越高, 客户端平均测试精度越高, 精度方差越低, 收敛速度也越快。

但是在现实环境下, 由于现实设备可能由于受到算力问题, 通讯网络问题, 设备电量问题等诸多现实环境影响, 全体设备参加聚合是很困难的。因此基于上述的现状, 我们的目标是寻找一个算法尽可能地在部分设备参与聚合的情况下提高全局模型性能, 同时保障整体客户端的公平性。

4.3 提出的算法

在本节中, 我们将设计的联邦优化算法分成两部分进行详细介绍。第一部分是聚合前的优化操作, 目的是缓解相近数据分布客户端导致聚合模型偏向的情况; 第二部分是通过对联联邦学习的全局目标函数进行转换与分解, 并由此设计了一种聚合方法, 最后我们将两部分的优化和联邦学习更新过程进行了结合, 提出了对应的优化算法, 我们称为 FedBEF。同时我们对该算法进行了收敛性分析, 证明该算法的是收敛的。

4.3.1 聚合前的优化

由于联邦学习无法获得本地数据, 因此想要通过获得各客户端数据分布再进行调整权重的方法似乎比较困难针对这种情况, 我们计划在上传梯度进行聚合之前进行梯度相似性的优化, 从而减缓参与聚合的客户端中相近数据的客户端获得较多权重的情况。为了缓解在聚合过程中, 有相似数据的客户端参与聚合导致模型偏转的情况, 我们

算法 4-1 SNG 机制

输入: 上传的梯度 $\text{list}G = [\nabla f_1(w^t), \nabla f_2(w^t) \cdots \nabla f_N(w^t)]$, 距离参数 D 。

输出: 分好类后的梯度 $\widetilde{\nabla f_1(w^t)}, \widetilde{\nabla f_2(w^t)}, \cdots, \widetilde{\nabla f_k(w^t)}$ 。

- 1: 存放新组的 $\text{list}M = []$ 。
 - 2: **while** $G = []$ **do**
 - 3: $S = []$;
 - 4: 将 G 的第一个梯度 $\nabla f_1(w^t)$ 提取出来放入 S 中。
 - 5: **if** $G = []$ **then**
 - 6: 将 S 中元素放入 M 中,
 - 7: **else**
 - 8: 将 G 剩下的梯度 $\nabla f_i(w^t)$ 与通过(4.3)式计算出 S_{ij} ,
 - 9: **if** $S_{ij} > D$ **then**
 - 10: 将梯度 $\nabla f_i(w^t)$ 放入 S 中。
 - 11: **end if**
 - 12: 将 S 中所有梯度计算出平均梯度后放入 M 中。
 - 13: **end if**
 - 14: **end while**
 - 15: 输出 M 中的所有梯度 $\widetilde{\nabla f_1(w^t)}, \widetilde{\nabla f_2(w^t)}, \cdots, \widetilde{\nabla f_k(w^t)}$ 。
-

提出了 SNG 机制。为了寻找相似的数据,以往人们会通常使用聚类算法例如 K-means 聚类、层次聚类等等,这类算法通常需要设置参数 X 来将数据归为 X 类^[30, 64]。但是由于联邦学习的数据保密性,很难去估计应该将参与聚合的客户端分为 X 类,而我们的目标并不需要具体将客户端分类,只需要将相近的客户端进行合并。

为了寻找相似数据分布的客户端,我们考虑了度量的选择,一般启发式方法是计算模型之间的欧几里得距离,但是这种方式在某些客户端训练次数不一致的情况下效果不理想。由于客户端本地的数据训练影响本地梯度从而影响模型参数,因此可以把各客户端上传的梯度视为另一种模式下的数据,同时可以通过计算不同客户端梯度与梯度之间的余弦值相似性来替代度量。任意两个客户端梯度的余弦相似度的定义如下:

$$S_{ij} \triangleq \frac{\langle \nabla f_i(w^t), \nabla f_j(w^t) \rangle}{\|\nabla f_i(w^t)\| \|\nabla f_j(w^t)\|} = \cos \theta \in [-1, 1]. \quad (4.3)$$

这种通过计算余弦值的方法,有效地将高维的抽象梯度向量之间的关系投影到范围一定的坐标轴中,同时运用越相似的梯度向量的余弦值越接近 1 的性质,我们可以很清晰地判断梯度向量之间的关系。具体的 SNG 机制过程如算法 4-1 所示。

4.3.2 全局目标函数转换与分解

首先我们通过(2.1)和(2.2),我们可以得到联邦学习的更新关系,如下所示:

$$w^{t+1} = \sum_{i=1}^N \lambda_i w_i^{t+1} = w^t - \eta \sum_{i=1}^N \lambda_i \nabla f_i(w^t). \quad (4.4)$$

该关系表明,新的全局模型参数 w^{t+1} 可以分解为前代模型参数 w^t 、不同客户端上传的梯度 $\nabla f_i(w^t)$ 、学习率 η 以及聚合权重 λ_i 这几个因素。接下来,我们尝试将(4.4)带入到 L-Lipschitz 不等式中,可得:

$$\begin{aligned} F(w^{t+1}) &\leq F(w^t) + \langle w^{t+1} - w^t, \nabla F(w^t) \rangle + \frac{L}{2} \|w^{t+1} - w^t\|^2 \\ &= F(w^t) - \eta \left\langle \sum_{i=1}^N \lambda_i \nabla f_i(w^t), \nabla F(w^t) \right\rangle + \frac{L\eta^2}{2} \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2. \end{aligned} \quad (4.5)$$

(4.1)的目标是寻找一个全局模型 w^{t+1} 使得全局损失最小。根据联邦学习更新公式,新的全局模型 w^{t+1} 被 w^t 、 $\nabla f_i(w^t)$ 、 η 与 λ_i 所控制。而且前代全局模型参数 w^t 和不同客户端上传的梯度 $\nabla f_i(w^t)$ 一般不做调整。同时为了方便分析聚合权重对全局模型的影响,所有接下来全文均假设学习率 η 也一般不发生变化。令 $0 < L \leq \frac{2}{\eta}$, 目标函

数(4.1)可以转换为

$$\begin{aligned} \min_{\lambda \in (\lambda_1, \dots, \lambda_2)} & -\eta \left\langle \sum_{i=1}^N \lambda_i \nabla f_i(w^t), \nabla F(w^t) \right\rangle + \eta \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2, \\ \text{s.t. } & \sum_{i=1}^N \lambda_i = 1. \end{aligned} \quad (4.6)$$

此时目标(4.1)转换成为(4.6)求一组权重的凸组合优化问题。我们可以运用目标(4.6)自适应地求得每一轮的聚合权重，从而降低全局损失函数 $F(w^{t+1})$ 的上界，从而加快模型参数收敛的速度。具体来说，假如将目标(4.6)除以 $\left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2$ 将会得到：

$$\min_{\lambda \in (\lambda_1, \dots, \lambda_1)} - \frac{\left\langle \nabla F(w^t), \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\rangle}{\left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2} + 1 \quad (4.7)$$

这代表了在几何向量角度，目的是求一组聚合权重使得聚合向量 $\sum_{i=1}^N \lambda_i \nabla f_i(w^t)$ 在全局梯度 $\nabla F(w^t)$ 方向上的投影最大，从而加速了聚合模型的收敛速度。由于优化问题(4.6)是一个线性优化问题，因此可以通过 python 中的凸优化问题的第三方库 cvxpy 来解决。

4.3.3 FedBEF 算法介绍

根据前文介绍的 SNG 机制以及聚合权重 λ_i 的优化方法，我们将在本章节详细介绍 FedBEF 算法的过程。前文的聚合权重 λ_i 计算过程中，由于联邦学习的特性，全局变量 $\nabla F(w^t)$ 的获取是一个挑战。在以往文献中^[16, 25] 通常使用局部平均梯度 $\frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t)$ 来替代。在 FedBEF 中，我们使用 SNG 算法聚合后的梯度来进行平均做为全局梯度。为了降低随机性选取的客户端上传梯度聚合后偏向性严重导致拟合的全局梯度性能效果下降，我们对局部平均梯度采用了动量策略^[61]，如下所示：

$$\nabla F(w^t) = \begin{cases} \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) & t = 1 \\ \nabla F(w^t) * \beta + \frac{1}{N} \sum_{i=1}^N \nabla f_i(w^t, \xi_i^t) * (1 - \beta) & t > 1 \end{cases} \quad (4.8)$$

，通常 $\beta = 0.9$ 。

算法 4-2 FedBEF 算法

输入: 通讯轮数 T , 每个通信轮参与训练的本地客户端数量 N , 本地 epoch 次数 E , 本地训练学习率 η , 本地训练批次 B 。

输出: 最终全局模型 w^T 。

- 1: 初始化模型参数 w^0 。
- 2: **while** $t \leq T$ **do**
- 3: **if** $t = 1$ **then**
- 4: $w^t = w^0$,
- 5: **else**
- 6: $w^t = w^{t+1}$ 。
- 7: **end if**
- 8: 广播全局模型 w^t 到全体客户端。
- 9: 随机选择 N 个客户端进行训练, 将这 N 个客户端编号视为一个集合 C^t 。
- 10: 被选择客户端接收全局模型 w^t 后, 开始根据本地实验参数进行训练: 通过训练 E 个 epoch 局部小批量 SGD 步骤的 w^t 来解决局部问题, 并在最后得到新的局部模型 w_i^{t+1} 。
- 11: 上传局部梯度 $\nabla f_i(w^t, \xi_i^t) = w_i^{t+1} - w^t$ 到服务器。
- 12: 服务器接收到所有客户端上传的本地梯度 $\nabla f_i(w^t, \xi_i^t), i \in C^t$ 。
- 13: 梯度标准化处理: $\nabla f_i(w^t, \xi_i^t) = \frac{\nabla f_i(w^t, \xi_i^t)}{\|\nabla f_i(w^t, \xi_i^t)\|}$ 。
- 14: 调用算法 2, 将相似的本地梯度进行聚合, 得到新的本地梯度 $\widetilde{\nabla f_1(w^t)}, \widetilde{\nabla f_2(w^t)}, \dots, \widetilde{\nabla f_k(w^t)}$ 。
- 15: 通过(4.8)式估计全局梯度 $\nabla F(w^t)$ 。
- 16: 通过(4.6)式计算出聚合权重 λ_i 。
- 17: 生成新的全局模型: $w^{t+1} = w^t - \eta \sum_{i=1}^N \lambda_i \nabla f_i(w^t, \xi_i^t)$ 。
- 18: **end while**
- 19: 输出 w^T 。

FedBEF 详细过程在算法 4-2 给出。我们和基本算法 Fedavg 主要的区别在于第 13 行到第 16 行。具体来说，我们的算法要求服务器在接收到各个客户端上传的本地梯度 ∇f_i 后将进行梯度标准化处理。之后采用 SNG 机制将相似的本地梯度进行聚合分组，分好组后的梯度用(4.8)式来估计全局梯度 $\nabla F(w^t)$ 。最后通过解决目标(4.6)来求得聚合权重 λ_i ，从而通过聚合各个梯度来生成新的全局模型。

从 FedBEF 算法的优化部分来看，聚合前的 SNG 机制要求对相似的梯度进行聚合，实际上是为了降低在同一轮通讯中相似数据分布的客户端比重。这是因为假如有相似分布的客户端参与聚合，聚合后的全局模型将会偏向这些客户端，从而对于其他客户端而言这是不公平的。因此，SNG 机制是算法 FedBEF 公平性的第一道保证。而聚合时对聚合权重的优化，目的是在当前的梯度信息下探寻到全局梯度，全局梯度采用了动量的策略，减少了部分客户端训练导致的聚合梯度偏移情况^[26, 27, 65]，这是 FedBEF 公平性的第二道保证。除此之外，FedBEF 要求参与聚合后的梯度尽可能地与全局梯度方向相似，从而加快全局模型的进化速度，因此这是对 FedBEF 算法的效率保证。综上所述可以认为，FedBEF 算法一种兼顾效率与公平性的联邦学习算法。

4.3.4 FedBEF 算法收敛性分析

针对我们提出来的算法，我们对其进行了收敛性分析，保证了我们提出的算法是收敛的。首先我们的理论主要考察了 FedBEF 所求解的聚合权重 λ 的特点以及主要性质，同时将经典的基于聚合的联邦学习收敛性分析方法相结合，进而得到收敛性证明过程。

引理 4-1: 假设 $\lambda \in (\lambda_1, \dots, \lambda_N)$ 为通过目标(4.6)求得的聚合权重，则对于任意聚合权重 $\mu \in (\mu_1, \dots, \mu_N)$ ， $\sum_{i=1}^N \mu = 1$ ，都有

$$\begin{aligned} & - \left\langle \nabla F(w^t), \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\rangle + \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 \\ & \leq - \left\langle \nabla F(w^t), \sum_{i=1}^N \mu_i \nabla f_i(w^t) \right\rangle + \left\| \sum_{i=1}^N \mu_i \nabla f_i(w^t) \right\|^2. \end{aligned}$$

上面性质4-1是显然的。通过上述性质，我们可以得到以下结论：

定理 4-1 (算法 4-2收敛性分析): 在 T 轮通讯之后，FedBEF 算法的累积梯度存在

上界:

$$\sum_{t=0}^T \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 \leq \frac{2}{\eta} (F(w^0) - F(w^{T+1})). \quad (4.9)$$

又因为 $\left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 \geq 0$, 所以根据级数收敛的必要条件:

$$\lim_{T \rightarrow \infty} \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 = 0. \quad (4.10)$$

因此梯度范数渐近趋近于零, 表明 FedBEF 收敛到全局目标函数的一个驻点。

证明过程如下:

证明: 根据4-1, 我们假设 $\mu \in \left(\frac{1}{N}, \dots, \frac{1}{N}\right)$ 。根据这个假设, 有:

$$\begin{aligned} & -\left\langle \nabla F(w^t), \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\rangle + \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 \\ & \leq -\left\langle \nabla F(w^t), \sum_{i=1}^N \frac{1}{N} \nabla f_i(w^t) \right\rangle + \left\| \sum_{i=1}^N \frac{1}{N} \nabla f_i(w^t) \right\|^2. \end{aligned} \quad (4.11)$$

又因为 $\nabla F(w^t) = \sum_{i=1}^N \frac{1}{N} \nabla f_i(w^t)$, 所以:

$$-\left\langle \nabla F(w^t), \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\rangle + \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 \leq 0. \quad (4.12)$$

根据 L-Lipschitz 不等式且 $0 < L \leq \frac{1}{\eta}$, 代入(4.12), 可以得到:

$$\begin{aligned} & F(w^{t+1}) - F(w^t) \\ & \leq \langle w^{t+1} - w^t, \nabla F(w^t) \rangle + \frac{L}{2} \|w^{t+1} - w^t\|^2 \\ & \leq -\eta \left\langle \nabla F(w^t), \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\rangle + \frac{\eta}{2} \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 \\ & \leq -\frac{\eta}{2} \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2. \end{aligned} \quad (4.13)$$

累加即可得到

$$\sum_{t=0}^T \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 \leq \frac{2}{\eta} (F(w^0) - F(w^{T+1})). \quad (4.14)$$

因此当 $T \rightarrow \infty$:

$$\lim_{T \rightarrow \infty} \left\| \sum_{i=1}^N \lambda_i \nabla f_i(w^t) \right\|^2 = 0. \quad (4.15)$$

在非凸性和 L-光滑性的假设下，聚合梯度的范数收敛到零，该算法可以被证明收敛到一阶平稳点。□

4.4 实验部分

在本节中，主要对为了证明我们提出的 FedBEF 算法是一个兼顾效率与公平的联邦算法，于是对 FedBEF 算法进行了实验评估，并在不同环境下对不同的联邦基准算法进行了比较。首先将该方法进行收敛速度和模型准确性进行评估。其次是对其进行公平性评估，它有两个指标：更平坦的小提琴图代表更公平；将结束轮的各客户端上验证集的方差除以精度均值所得到的结果越小则越视为综合性能越好，兼顾了全局模型性能与公平。然后对 FedBEF 进行消融实验，调查 SNG 机制在 FedBEF 算法上的作用以及不同的方法代替全局模型对 FedBEF 算法的影响。最后我们将 FedBEF 和其他当前优秀的不同优化方向的联邦学习算法进行比较来进一步说明我们提出的 FedBEF 算法的优越性。

4.4.1 实验设置

在实验中，我们采用两个比较流行的实验数据集：CIFAR-10 与 CIFAR-100。这两个数据集都是图像识别任务。其中 CIFAR-10 数据集包含 10 个类别的图像，每个类别有 6,000 张分辨率为 32×32 的彩色图片，总计 60,000 张图片，其中 50,000 张用于训练，10,000 张用于测试。CIFAR-100 的结构类似，但包含 100 个类别，每类图片数量较少，每个类别包含 600 张分辨率为 32×32 的彩色图片，总计同样为 60,000 张，其中 50,000 张用于训练，10,000 张用于测试。

本文对于 CIFAR-10 任务和 CIFAR-100 任务使用均使用七层 CNN 模型，该模型的卷积层有两层，卷积核均为 5×5 ，池化层 2×2 两层，两层全连接层，分别维数是 384 和 192 以及一个最终输出的全连接层。

在实验中，我们规定本地训练的轮次 $E = 1$ ，学习率固定为 $\eta_t = 0.01$ 。我们在本地更新将使用最小批量梯度下降法（mini-batch gradient descent, MBGD）方法^[66, 67]，并且规定 $B_{CIFAR-10} = 64$ ， $B_{CIFAR-100} = 10$ 。对于联邦学习客户端，我们设置客户端 $N = 100$ ，并且每轮客户端参与的比例是 $P = 0.2$ 。如无特殊说明，本文 FedBEF 算法参数 D 均设为 0.8。

为了评估我们的算法在数据异构场景下的性能，我们采用了两种非独立同分布数据分区方法：标签数量倾斜以及标签分布倾斜。标签分布倾斜指的是每一个客户端只拥有一定数量的标签。在实验中，我们打算将每个客户端分别分配两类且互不相同的标签数据（ $c = 2$ ）。具体来说，我们将每一类数据进行排序后并将其分成 200 份相同大小的块，随机分配到各个客户端中，确保每个客户端只分到互不相同的 2 个数据块。标签数量倾斜是指每一个客户端的数据标签数量不一致，并不限定一个客户端拥有的数据标签种类的数量。在实验中，我们将使用 Dirichlet 分布对客户端进行数据分配 [29]，其中超参数设置为 $d = 0.1$ ，代表了现实中极端数据的异质性。

在我们的实验中，我们比较了几种算法，一种是经典的联邦学习算法例如 Fedavg、Fedprox、Scaffold 和 Moon，一种是针对全局模型不均衡的现象算法例如 Fedmgda+、q-Fedavg 和 FedFV。为了防止实验的随机性我们的实验结果是使用不同的随机种子进行 4 次实验，并将结果取均值得到。

本文的实验均在 flgo 0.4.3、torch 1.7.0 进行^[63]。使用的 GPU 分别为一块 NVIDIA GeForce RTX 4090 和两块 NVIDIA GeForce RTX 3090。

4.4.2 算法性能评估

为了证明我们提出的算法性能，我们对于 CIFAR-10 与 CIFAR-100 均采用了上述的标签数量倾斜和标签分布倾斜两种数据分割方式进行试验。实验结果如表4-1所示，最优结果已用粗体标出。从表4-1中可以看出，FedBEF 算法几乎在不同的数据集以及不同非独立同分布程度的交叉影响下，算法性能都达到了最佳。具体来说，在 CIFAR-100 数据集的任务中，FedBEF 算法均优于其他联邦学习基线算法。在 CIFAR-10 任务中，只有在 $c=2$ （每个客户端两类）的环境下，FedBEF 算法准确性达到 71.08%，而最优的联邦算法 Fedfv 仅有 67.48%。尽管在 $d=0.1$ 的情况下，我们的方法效果并不算最好，但是从图4-4可以观察到，在这种情况下我们仅次于 Fedfv 且与 Fedfv 差距不大，准确性




图 4-4 CIFAR-10 数据集上测试结果

Figure 4-4 The accuracy over communication rounds on CIFAR-10

表 4-1 全局模型最终测试精度

Table 4-1 Global model final test accuracy

算法	CIFAR-10		CIFAR-100	
	d=0.1	c=2	d=0.1	c=2
Fedavg	52.53±2.15%	63.91±1.59%	22.90±1.25%	29.53±1.01%
Fedprox	51.12±6.26%	62.11±2.42%	21.85±0.83%	28.31±1.11%
Scaffold	30.01±7.32%	52.95±1.09%	9.82±3.18%	20.17±1.50%
Fedmgda+	52.19±2.23%	61.81±3.39%	24.03±2.20%	30.65±1.70%
q-Fedavg	39.87±8.24%	46.51±6.74%	11.96±0.44%	14.25±0.09%
Fedfv	60.86±2.74%	67.48±1.10%	22.91±0.56%	29.35±1.07%
Moon	51.03±2.21%	62.47±3.26%	22.32±0.83%	29.19±1.30%
Ours	60.73±3.24%	71.08±3.60%	24.46±3.12%	31.01±1.32%




图 4-5 CIFAR-100 数据集上测试结果

Figure 4-5 The accuracy over communication rounds on CIFAR-100


仍有 60.73%。甚至比起其他的基准方法，FedBEF 的准确性拉开了不少差距，距离最近的算法 Fedavg 精度只有 52.53%。另外 Fedfv 方法除了梯度外还需要客户端上传各客户端的 loss 作为算法的投影依据，而我们的方法仅需要上传各客户端的梯度即可。综上所述可以看到，FedBEF 方法不太需要依靠其他信息的同时为全局模型的性能做出了更多的改进。

4.4.3 不同算法的公平性比较


公平性一般是指全局模型照顾到所有客户端的情况，目的是衡量该算法计算出来的全局模型是否能在不同数据分布下客户端上拥有较好的性能，评判一个算法的泛用程度。因此我们采用最后一轮全局模型在客户端验证集上的性能精度分布情况进行评估公平性，而小提琴图能够直观地反应数据分布情况^[41, 68]，通常被使用于公平性比较中。

图4-6和4-7是我们利用小提琴图来描述各个算法最后一轮的全局模型在各个客户端验证集的准确性分布情况。可以看出，大部分情况下，FedBEF 算法的全局模型在客户端数据集上的性能更均匀。小提琴图整体分布越高则全局模型在不同客户端的性能就越好。尽管在数据集 CIFAR-10， $d=0.1$ 的情况下表现出不算均匀，但是可以看到全局模型在大部分的客户端上的性能较优，因此这并不违背我们算法在追求性能的前提下追求公平性的初衷。

然而一味只追求公平性（全体客户端性能标准差，表4-2中的 S）而忽视各客户端的




(a) The performance of the global model under CIFAR-10 with $c=2$ on each client




(b) The performance of the global model under CIFAR-10 with $d=0.1$ on each client

图 4-6 CIFAR-10 数据集上公平性情况

Figure 4-6 The fairness situation on the CIFAR-10 dataset



(a) The performance of the global model under CIFAR-100 with $c=2$ on each client



(b) The performance of the global model under CIFAR-100 with $d=0.1$ on each client

图 4-7 CIFAR-100 数据集上公平性情况

Figure 4-7 The fairness situation on the CIFAR-100 dataset

表 4-2 CIFAR-10 客户端验证集精度分散系数

Table 4-2 CIFAR-10 client verification set accuracy dispersion coefficient

算法	CIFAR-10					
	d=0.1			c=2		
	M(%)	S	S/M	M(%)	S	S/M
Fedavg	51.89	18.44	0.36	64.41	9.43	0.15
Fedprox	50.10	15.33	0.31	62.83	12.55	0.20
Scaffold	29.00	11.44	0.39	53.42	13.40	0.25
Fedmgda+	51.24	19.18	0.37	62.42	10.19	0.16
q-Fedavg	39.10	16.67	0.43	46.77	9.19	0.20
Fedfv	60.23	16.05	0.27	67.92	8.94	0.13
Moon	50.21	19.56	0.39	62.85	10.33	0.16
Ours	60.68	18.75	0.31	72.39	8.19	0.11

表 4-3 CIFAR-100 客户端验证集精度分散系数

Table 4-3 CIFAR-100 client verification set accuracy dispersion coefficient

算法	CIFAR-100					
	d=0.1			c=2		
	M(%)	S	S/M	M(%)	S	S/M
Fedavg	23.12	15.16	0.66	29.54	12.31	0.42
Fedprox	21.95	14.13	0.64	28.31	12.18	0.43
Scaffold	10.12	13.05	1.29	20.17	12.58	0.62
Fedmgda+	24.33	14.00	0.58	30.66	12.72	0.41
q-Fedavg	12.16	14.00	1.15	14.25	10.33	0.73
Fedfv	23.10	15.33	0.66	29.36	12.54	0.43
Moon	22.49	15.22	0.68	29.19	12.72	0.44
Ours	24.80	14.25	0.57	30.66	12.77	0.41

平均性能（表4-2中的 M ）的评价联邦学习算法其实是不够全面的，为了避免过分追求公平性而忽视了全局模型性能，因此性能也可以作为公平性的指标之一来看待。这意味着我们的目标是在追求高性能的同时减少不同客户端的性能差异。由于不同联邦算法各客户端的性能不同，而且整体客户端的性能标准差也不一致。为了更加准确客观地评价各联邦算法的公平性，我们根据在相同平均性能比较标准差的原则，采用了标准差除以平均性能（ S/M ）的方法，结果越小代表综合性能越好。结果如表4-2和4-3所示，优秀结果均用粗体标出。可以看出 FedBEF 算法除了在 CIFAR-10 数据集在 $d=0.1$ 数据划分下的情况外，在大多数情况下获得比较优秀的整体性性能。另一方面，虽然算法 Fedfv 在 CIFAR-10 数据集下性能和公平性都表现得较好，但是在 CIFAR-100 数据集下则表现得一般，在基准算法下略逊于 Fedmgda+。但是，我们提出的 FedBEF 算法仅在 CIFAR-10 数据集在 $d=0.1$ 数据划分下的综合表现略差于 Fedfv，在 $c=2$ 数据划分以及 CIFAR-100 的条件下综合表现都良好。因此总体而言，FedBEF 算法是一种优秀的兼顾全局性能和公平的联邦学习算法。

4.4.4 消融实验

由前文所示，FedBEF 算法（本节称为完全 FedBEF 算法）由 SNG 机制与 FedBEF 算法组成，而 SNG 机制是通过参数 D 来控制客户端分组的。因此为了探讨完全 FedBEF 算法的不同组成部分对算法影响，我们设计了消融实验，标准是比较各个部分的机制产生的全局模型性能情况。具体来说，我们设置了三个对照组：FedBEF 算法 + SNG 机制， $D=0.8$ ；只有 FedBEF 算法（图例为 no SNG）；只有 SNG 机制且 $D=0.8$ ，聚合方案用 Fedavg 算法替代（图例为 no FedBEF）。以上算法均在 $c=2$ 数据分布的 CIFAR-10 任务下进行，设置实验轮数为 500 轮，其他实验设置均如前文相同。

如图4-8所示，只存在 SNG 机制的全局模型性能最差，其次是只存在 FedBEF 算法的性能，他们均低于完全 FedBEF 算法的模型。这说明 SNG 机制与 FedBEF 算法的结合是有机的，不是相互排斥的。从收敛速度来看，完全 FedBEF 算法的收敛速度均快于只有 SNG 机制和只有 FedBEF 算法的情况，因此 SNG 机制有助于 FedBEF 算法的收敛。

为了进一步探讨 SNG 机制在不同参数 D 下对 FedBEF 算法的影响，我们设置了 FedBEF 算法 + SNG 机制， $D=0.5$ 的情况进行仿真实验。如图4-8所示， $D=0.5$ 的收敛速




图 4-8 消融实验结果

Figure 4-8 Ablation results

度与性能均不及 $D=0.8$ 的情况。而 $D=0.5$ 的收敛速度与只有 FedBEF 算法的情况下相当，这表明了在选择合适的参数 D 情况下，SNG 机制有助于提高 FedBEF 算法的收敛速度以及全局模型性能。


4.4.5 与不同优化部分的算法性能比较

与不同联邦学习结构上进行修改优化的算法不同，本文仅在聚合参数进行优化调整。为了显示出本文算法的优化效果，接下来我们将与当前先进的不同结构进行优化的基准算法进行全局模型性能的比较。比较的算法有的提出了个性化模型框架，例如 FedALA^[69]，FedPAC^[70]，也有的在客户端选择策略上进行优化，例如 CA2FL^[71]。结果如图4-9所示。我们的实验任务设置均为 $c=2$ 的 CIFAR-10 数据集，实验设置均可与前文 4.4.1 相同。

在模型性能比较中，我们提出的算法 FedBEF 在收敛速度以及性能上均有优势。同时在精度标准差的比较中，该算法可以获得较低的标准差，这意味着我们提出的算法训练出来的全局模型在各个客户端上的性能差距较小。这充分的表明了本文所提出的算法比起其他当前较为先进的的算法生成的全局模型具有良好的性能，同时保持了较好的公平性。

4.5 本章小结

在本章中，我们为了全面解决联邦学习受到非独立同分布数据导致全局模型性能下降挑战，首先通过分析现实中联邦学习非独立同分布数据出现的特点以及联邦学习



(a) Algorithm accuracy comparison


(b) Global model performance standard deviation
in different clients

图 4-9 与不同角度优化的联邦算法的性能比较

Figure 4-9 Performance comparison with federated algorithms optimized from different perspectives

收敛性，提出了 SNG 机制和 FedBEF 聚合策略。SNG 机制是为了解决相似数据客户端与联邦学习特点相结合的情况，该机制不需要知道客户端数据具体情况，只需要比较各客户端上传的梯度角度。FedBEF 聚合策略目的是要求客户端上传的局部梯度寻找一个梯度方向，该方向的投影与全局梯度比例最大。通过理论分析，我们验证了 FedBEF 算法的收敛性，证明了该算法收敛于全局损失函数的一个平稳点。最后面通过大量的实验结果证明，与其他的联邦学习算法相比，我们的方法能够兼顾更优的效率以及更好的公平性。

第五章 结论与展望

研究结论

近年来,数据安全与隐私保护需求日益增长,传统依赖海量集中数据的机器学习范式面临严峻挑战。联邦学习作为一种分布式学习框架,允许客户端在本地训练模型而无需共享原始数据,为隐私保护与模型性能的平衡提供了可行方案。然而,实际场景中普遍存在的非独立同分布数据问题,导致联邦学习模型收敛速度慢、性能下降以及客户端间性能差异显著等挑战。针对这些问题,本文提出两种创新算法,分别从收敛效率优化和公平性增强两个维度推动联邦学习技术的进步。

针对非独立同分布数据现象带来的模型性能下降问题,本文提出了基于客户端梯度自适应学习率的聚合策略(Fedalr),通过计算本地梯度与全局梯度的差距来控制聚合时的本地梯度学习率,从而降低局部模型的偏移导致聚合模型一起偏移的影响,加速了模型收敛速度。本文还对Fedalr算法进行了收敛性分析,确保了该算法的收敛性。同时通过和基线算法进行了精度实验,结果表明该算法具有相当的竞争力和可行性。除此之外,本文还对该算法受到实验参数的影响进行了实验探讨,结果表明该算法无论在何种参数环境下,都表现出优秀的性能。

为了缓解非独立同分布数据带来的聚合模型在不同客户端上性能差异明显的问题,本文提出了FedBEF聚合策略,目标是提出在保障全局模型性能的同时,优化客户端本地模型的均衡性。该策略通过聚合前将相似的客户端模型进行合并以缓解聚合模型偏向相似客户端的情况来保证公平性,同时通过将联邦学习损失函数的收敛性上界和联邦学习更新过程相结合,为聚合权重设定了目标,然后通过计算聚合权重来控制模型以提高模型性能和收敛效率。本文不仅对该策略进行了收敛性分析,而且通过精度实验和公平性实验来确保我们提出的算法是兼顾效率与公平的。

未来研究展望

但是,由于本人能力,本文提出的算法并不十全十美,仍存在一定的局限。首先本文提出的算法需要去估算全局模型对后续的自适应计算做为指导,尽管相比于以前的算法直接采用当前轮客户端上传的梯度取均值来估算全局梯度,本文估算全局梯度采用了动量策略以减少全局梯度的震荡,但是对于真正的全局梯度仍有差距。在未来,我们会进一步研究非独立同分布数据下的联邦学习的梯度特征与联系,尽可能地减少

差距。其次，本文的优化部分仅仅针对联邦学习的聚合环节进行优化，虽然在模型精度等指标获得了一定的效果，但是在未来我们希望通过优化联邦学习的其他环节以解决当前的挑战。第三，本文的优化场景只设定在非独立同分布的环境下，在未来我们希望在更多的和非独立同分布一起交叉的环境下进行进一步的优化。

参考文献

- [1] CHERKASSKY V. The nature of statistical learning theory[J]. IEEE Trans. Neural Networks, 1997, 8(6): 1564.
- [2] HOLMES T, MCLARTY C, SHI Y, et al. Energy efficiency on edge computing: Challenges and vision[C]//IEEE International Performance, Computing, and Communications Conference, IPCCC 2022, Austin, TX, USA, November 11-13, 2022. IEEE, 2022: 1-6.
- [3] ZHOU Z, CHEN X, LI E, et al. Edge intelligence: Paving the last mile of artificial intelligence with edge computing[J]. Proc. IEEE, 2019, 107(8): 1738-1762.
- [4] HALEVY A Y, NORVIG P, PEREIRA F. The unreasonable effectiveness of data[J]. IEEE Intell. Syst., 2009, 24(2): 8-12.
- [5] LECUN Y, BENGIO Y, HINTON G E. Deep learning[J]. Nat., 2015, 521(7553): 436-444.
- [6] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021. OpenReview.net, 2021.
- [7] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020.
- [8] AMERSHI S, BEGEL A, BIRD C, et al. Software engineering for machine learning: a case study[C]//SHARP H, WHALEN M. Proceedings of the 41st International Conference on Software Engineering: Software Engineering in Practice, ICSE (SEIP) 2019, Montreal, QC, Canada, May 25-31, 2019. IEEE / ACM, 2019: 291-300.
- [9] LANG P, PENG K, CUI J, et al. Data augmentation for fault prediction of aircraft engine with generative adversarial networks[C]//CAA Symposium on Fault Detection, Supervision, and Safety for Technical Processes, SAFEPROCESS 2021, Chengdu, China, December 17-18, 2021. IEEE, 2021: 1-5.

-
-
- [10] BERGER A, LAGONES T A, GRIGULL L, et al. Tackling data sparsity and combinatorial challenges in rare disease matching with medical informed machine learning[C]//DING W, LU C, WANG F, et al. IEEE International Conference on Big Data, BigData 2024, Washington, DC, USA, December 15-18, 2024. IEEE, 2024: 6430-6438.
- [11] SAMBASIVAN N, KAPANIA S, HIGHFILL H, et al. "everyone wants to do the model work, not the data work": Data cascades in high-stakes AI[C]//KITAMURA Y, QUIGLEY A, ISBISTER K, et al. CHI '21: CHI Conference on Human Factors in Computing Systems, Virtual Event / Yokohama, Japan, May 8-13, 2021. ACM, 2021: 39:1-39:15.
- [12] ANDREW J, BAKER M. The general data protection regulation in the age of surveillance capitalism[J]. Journal of Business Ethics, 2021, 168: 565-578.
- [13] 中华人民共和国网络安全法[R]. 人民公安报, 2016-11-08.
- [14] CHADDAD A, WU Y, DESROSIERS C. Federated learning for healthcare applications [J]. IEEE Internet Things J., 2024, 11(5): 7339-7358.
- [15] SCULLEY D, HOLT G, GOLOVIN D, et al. Machine learning: The high interest credit card of technical debt[C]//SE4ML: software engineering for machine learning (NIPS 2014 Workshop): Vol. 8. Cambridge, MA, 2014.
- [16] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//SINGH A, ZHU X J. Proceedings of Machine Learning Research: Vol. 54 Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, AISTATS 2017, 20-22 April 2017, Fort Lauderdale, FL, USA. PMLR, 2017: 1273-1282.
- [17] LI T, SAHU A K, TALWALKAR A, et al. Federated learning: Challenges, methods, and future directions[J]. IEEE Signal Process. Mag., 2020, 37(3): 50-60.
- [18] KAIROUZ P, MCMAHAN H B, AVENT B, et al. Advances and open problems in federated learning[J]. Found. Trends Mach. Learn., 2021, 14(1-2): 1-210.
- [19] BONAOWITZ K A, EICHNER H, GRIESKAMP W, et al. Towards federated learning at scale: System design[C]//TALWALKAR A, SMITH V, ZAHARIA M. Proceedings of

- the Second Conference on Machine Learning and Systems, SysML 2019, Stanford, CA, USA, March 31 - April 2, 2019. mlsys.org, 2019.
- [20] ZHAO Y, LI M, LAI L, et al. Federated learning with non-iid data[J]. CoRR, 2018, abs/1806.00582.
- [21] WANG J, LIU Q, LIANG H, et al. Tackling the objective inconsistency problem in heterogeneous federated optimization[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020.
- [22] LI X, HUANG K, YANG W, et al. On the convergence of fedavg on non-iid data[C]//8th International Conference on Learning Representations, ICLR 2020, Addis Ababa, Ethiopia, April 26-30, 2020. OpenReview.net, 2020.
- [23] SHARMA P, PANDA R, JOSHI G, et al. Federated minimax optimization: Improved convergence analyses and algorithms[C]//CHAUDHURI K, JEGELKA S, SONG L, et al. Proceedings of Machine Learning Research: Vol. 162 International Conference on Machine Learning, ICML 2022, 17-23 July 2022, Baltimore, Maryland, USA. PMLR, 2022: 19683-19730.
- [24] CHARLES Z, KONEČNÝ J. Convergence and accuracy trade-offs in federated learning and meta-learning[C]//BANERJEE A, FUKUMIZU K. Proceedings of Machine Learning Research: Vol. 130 The 24th International Conference on Artificial Intelligence and Statistics, AISTATS 2021, April 13-15, 2021, Virtual Event. PMLR, 2021: 2575-2583.
- [25] LI T, SAHU A K, ZAHEER M, et al. Federated optimization in heterogeneous networks [C]//DHILLON I S, PAPAILIOPOULOS D S, SZE V. Proceedings of the Third Conference on Machine Learning and Systems, MLSys 2020, Austin, TX, USA, March 2-4, 2020. mlsys.org, 2020.
- [26] KARIMIREDDY S P, KALE S, MOHRI M, et al. SCAFFOLD: stochastic controlled averaging for federated learning[C]//Proceedings of Machine Learning Research: Vol. 119 Proceedings of the 37th International Conference on Machine Learning, ICML

- 2020, 13-18 July 2020, Virtual Event. PMLR, 2020: 5132-5143.
- [27] HSU T H, QI H, BROWN M. Measuring the effects of non-identical data distribution for federated visual classification[J]. CoRR, 2019, abs/1909.06335.
- [28] LI Q, HE B, SONG D. Model-contrastive federated learning[C]//IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2021, virtual, June 19-25, 2021. Computer Vision Foundation / IEEE, 2021: 10713-10722.
- [29] LONG G, XIE M, SHEN T, et al. Multi-center federated learning: clients clustering for better personalization[J]. World Wide Web (WWW), 2023, 26(1): 481-500.
- [30] DUAN M, LIU D, JI X, et al. Fedgroup: Efficient federated learning via decomposed similarity-based clustering[C]//2021 IEEE Intl Conf on Parallel & Distributed Processing with Applications, Big Data & Cloud Computing, Sustainable Computing & Communications, Social Computing & Networking (ISPA/BDCLOUD/SocialCom/SustainCom), New York City, NY, USA, September 30 - Oct. 3, 2021. IEEE, 2021: 228-237.
- [31] YANG M S, SINAGA K P. Federated multi-view k-means clustering[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(4): 2446-2459. DOI: 10.1109/TPAMI.2024.3520708.
- [32] SATTLER F, MÜLLER K R, SAMEK W. Clustered federated learning: Model-agnostic distributed multitask optimization under privacy constraints[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(8): 3710-3722.
- [33] DUAN M, LIU D, JI X, et al. Flexible clustered federated learning for client-level data distribution shift[J]. IEEE Transactions on Parallel and Distributed Systems, 2022, 33(11): 2661-2674.
- [34] TANG M, NING X, WANG Y, et al. Fedcor: Correlation-based active client selection strategy for heterogeneous federated learning[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022. IEEE, 2022: 10092-10101.
- [35] BALAKRISHNAN R, LI T, ZHOU T, et al. Diverse client selection for federated learning via submodular maximization[C]//The Tenth International Conference on Learning

- Representations, ICLR 2022, Virtual Event, April 25-29, 2022. OpenReview.net, 2022.
- [36] CHO Y J, WANG J, JOSHI G. Client selection in federated learning: Convergence analysis and power-of-choice selection strategies[J]. CoRR, 2020, abs/2010.01243.
- [37] NAAS S A, SIGG S. Fast converging federated learning with non-iid data[C]//2023 IEEE 97th Vehicular Technology Conference (VTC2023-Spring). 2023: 1-6.
- [38] HU Z, YU Y. Leveraging variable sparsity to refine pareto stationarity in multi-objective optimization[C/OL]//The Thirteenth International Conference on Learning Representations. 2025. <https://openreview.net/forum?id=Bl3e8HV9xW>.
- [39] GUO P, ZENG S, WANG Y, et al. Selective aggregation for low-rank adaptation in federated learning[C/OL]//The Thirteenth International Conference on Learning Representations. 2025. <https://openreview.net/forum?id=iX3uESGdsO>.
- [40] REDDI S J, CHARLES Z, ZAHEER M, et al. Adaptive federated optimization[C]//9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021. OpenReview.net, 2021.
- [41] HU Z, SHALOUDEGI K, ZHANG G, et al. Federated learning meets multi-objective optimization[J]. IEEE Trans. Netw. Sci. Eng., 2022, 9(4): 2039-2051.
- [42] ZHOU Z. Proceedings of the thirtieth international joint conference on artificial intelligence, IJCAI 2021, virtual event / montreal, canada, 19-27 august 2021[C]. ijcai.org, 2021.
- [43] LI Z, SUN Y, SHAO J, et al. Feature matching data synthesis for non-iid federated learning[J]. IEEE Transactions on Mobile Computing, 2024, 23(10): 9352-9367.
- [44] HINTON G E, VINYALS O, DEAN J. Distilling the knowledge in a neural network[J]. CoRR, 2015, abs/1503.02531.
- [45] GONG X, LI S, BAO Y, et al. Federated learning via input-output collaborative distillation[C/OL]//WOOLDRIDGE M J, DY J G, NATARAJAN S. Thirty-Eighth AAAI Conference on Artificial Intelligence, AAAI 2024, Thirty-Sixth Conference on Innovative Applications of Artificial Intelligence, IAAI 2024, Fourteenth Symposium on Educational Advances in Artificial Intelligence, EAAI 2014, February 20-27, 2024, Vancouver,

- Canada. AAAI Press, 2024: 22058-22066. <https://doi.org/10.1609/aaai.v38i20.30209>. DOI: 10.1609/AAAI.V38I20.30209.
- [46] VAHIDIAN S, WANG M, GU J, et al. Group distributionally robust dataset distillation with risk minimization[C/OL]//The Thirteenth International Conference on Learning Representations. 2025. <https://openreview.net/forum?id=3JsU5QXNru>.
- [47] LIN T, KONG L, STICH S U, et al. Ensemble distillation for robust model fusion in federated learning[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020.
- [48] ZHU Z, HONG J, ZHOU J. Data-free knowledge distillation for heterogeneous federated learning[C]//MEILA M, ZHANG T. Proceedings of Machine Learning Research: Vol. 139 Proceedings of the 38th International Conference on Machine Learning, ICML 2021, 18-24 July 2021, Virtual Event. PMLR, 2021: 12878-12889.
- [49] YANG Q, LIU Y, CHEN T, et al. Federated machine learning: Concept and applications [J]. ACM Trans. Intell. Syst. Technol., 2019, 10(2): 12:1-12:19.
- [50] LIU Y, KANG Y, XING C, et al. A secure federated transfer learning framework[J]. IEEE Intell. Syst., 2020, 35(4): 70-82.
- [51] PINGULKAR S, PAWADE D. Federated learning architectures for credit risk assessment: A comparative analysis of vertical, horizontal, and transfer learning approaches [C]//2024 IEEE International Conference on Blockchain and Distributed Systems Security (ICBDS). 2024: 1-7.
- [52] HARDY S, HENECKA W, IVEY-LAW H, et al. Private federated learning on vertically partitioned data via entity resolution and additively homomorphic encryption[J]. CoRR, 2017, abs/1711.10677.
- [53] CHEN Y, QIN X, WANG J, et al. Fedhealth: A federated transfer learning framework for wearable healthcare[J]. IEEE Intelligent Systems, 2020, 35(4): 83-93.
- [54] PENG X, BAI Q, XIA X, et al. Moment matching for multi-source domain adaptation [C]//2019 IEEE/CVF International Conference on Computer Vision, ICCV 2019, Seoul,

-
- Korea (South), October 27 - November 2, 2019. IEEE, 2019: 1406-1415.
- [55] NGUYEN A T, TORR P H S, LIM S N. Fedshr: A simple and effective domain generalization method for federated learning[C]//KOYEJO S, MOHAMED S, AGARWAL A, et al. Advances in Neural Information Processing Systems 35: Annual Conference on Neural Information Processing Systems 2022, NeurIPS 2022, New Orleans, LA, USA, November 28 - December 9, 2022. 2022.
- [56] LI Q, DIAO Y, CHEN Q, et al. Federated learning on non-iid data silos: An experimental study[C]//38th IEEE International Conference on Data Engineering, ICDE 2022, Kuala Lumpur, Malaysia, May 9-12, 2022. IEEE, 2022: 965-978.
- [57] BONAWITZ K, EICHNER H, GRIESKAMP W, et al. Towards federated learning at scale: System design[C]//TALWALKAR A, SMITH V, ZAHARIA M. Proceedings of Machine Learning and Systems: Vol. 1. 2019: 374-388.
- [58] LI T, SANJABI M, BEIRAMI A, et al. Fair resource allocation in federated learning[C]//8th International Conference on Learning Representations, ICLR 2020, Addis Ababa, Ethiopia, April 26-30, 2020. OpenReview.net, 2020.
- [59] WANG J, LIU Q, LIANG H, et al. Tackling the objective inconsistency problem in heterogeneous federated optimization[C]//NIPS '20: Proceedings of the 34th International Conference on Neural Information Processing Systems. Red Hook, NY, USA: Curran Associates Inc., 2020.
- [60] DINH C T, TRAN N H, NGUYEN T D. Personalized federated learning with moreau envelopes[C]//LAROCHELLE H, RANZATO M, HADSELL R, et al. Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6-12, 2020, virtual. 2020.
- [61] SUTSKEVER I, MARTENS J, DAHL G E, et al. On the importance of initialization and momentum in deep learning[C]//JMLR Workshop and Conference Proceedings: Vol. 28 Proceedings of the 30th International Conference on Machine Learning, ICML 2013, Atlanta, GA, USA, 16-21 June 2013. JMLR.org, 2013: 1139-1147.
- [62] KINGMA D P, BA J. Adam: A method for stochastic optimization[C]//BENGIO Y,

- LECUN Y. 3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings. 2015.
- [63] WANG Z, FAN X, PENG Z, et al. Flgo: A fully customizable federated learning platform [J/OL]. CoRR, 2023, abs/2306.12079. <https://doi.org/10.48550/arXiv.2306.12079>. DOI: 10.48550/ARXIV.2306.12079.
- [64] GARST S, REINDERS M J T. Federated k-means clustering[C]//ANTONACOPOULOS A, CHAUDHURI S, CHELLAPPA R, et al. Lecture Notes in Computer Science: Vol. 15302 Pattern Recognition - 27th International Conference, ICPR 2024, Kolkata, India, December 1-5, 2024, Proceedings, Part II. Springer, 2024: 107-122.
- [65] STICH S U. Local SGD converges fast and communicates little[C]//7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6-9, 2019. OpenReview.net, 2019.
- [66] BOTTOU L. Large-scale machine learning with stochastic gradient descent[C]//LECHEVALLIER Y, SAPORTA G. 19th International Conference on Computational Statistics, COMPSTAT 2010, Paris, France, August 22-27, 2010 - Keynote, Invited and Contributed Papers. Physica-Verlag, 2010: 177-186.
- [67] MA Y, RUSU F, WU K, et al. Adaptive stochastic gradient descent for deep learning on heterogeneous CPU+GPU architectures[C]//IEEE International Parallel and Distributed Processing Symposium Workshops, IPDPS Workshops 2021, Portland, OR, USA, June 17-21, 2021. IEEE, 2021: 6-15.
- [68] SHEN Y, XI W, CAI Y, et al. Multi-objective federated learning: Balancing global performance and individual fairness[J]. Future Gener. Comput. Syst., 2025, 162: 107468.
- [69] ZHANG J, HUA Y, WANG H, et al. Fedala: Adaptive local aggregation for personalized federated learning[C]//WILLIAMS B, CHEN Y, NEVILLE J. Thirty-Seventh AAAI Conference on Artificial Intelligence, AAAI 2023, Thirty-Fifth Conference on Innovative Applications of Artificial Intelligence, IAAI 2023, Thirteenth Symposium on Educational Advances in Artificial Intelligence, EAAI 2023, Washington, DC, USA, February 7-14, 2023. 11237-11244.

- [70] XU J, TONG X, HUANG S. Personalized federated learning with feature alignment and classifier collaboration[C]//The Eleventh International Conference on Learning Representations, ICLR 2023, Kigali, Rwanda, May 1-5, 2023. OpenReview.net, 2023.
- [71] WANG Y, CAO Y, WU J, et al. Tackling the data heterogeneity in asynchronous federated learning with cached update calibration[C]//The Twelfth International Conference on Learning Representations, ICLR 2024, Vienna, Austria, May 7-11, 2024. OpenReview.net, 2024.

